

Fiche 25 — Optimisation affine par morceaux : tout ramener à un LP

Matière	Maths · Optimisation
Cours source	Vandenberghe, EE236A — <i>Linear Programming</i> (UCLA), Lecture 2 « Piecewise-linear optimization », 24 diapositives
Difficulté	Must know — la technique la plus rentable du cours
Temps d'étude estimé	2 h
Prérequis	Fiche 24 (forme matricielle d'un LP), fiche 11 (convexité)
Concepts clés	Fonction affine par morceaux, variable auxiliaire, épigraphe, approximation en norme 1 et en norme infinie, parcimonie, classification linéaire
Poids à l'examen	C'est la compétence transférable : reconnaître qu'un problème non linéaire en apparence est un LP déguisé, et écrire la reformulation. Presque tous les exercices de modélisation de <code>ZZ_EXERCICES_problems.pdf</code> se jouent là.

Vue d'ensemble

Un objectif écrit avec des **max**, des valeurs absolues, des normes $\|\cdot\|_1$ ou $\|\cdot\|_\infty$ **n'est pas linéaire** — et pourtant le problème est un LP. La technique tient en une phrase, et elle se répète à l'identique dans tout le cours :

OBJECTIF NON LINÉAIRE → on ajoute une VARIABLE AUXILIAIRE t
→ on impose « t majore chaque morceau »
→ on minimise t

Pourquoi ça marche : à x fixé, la contrainte $t \geq$ (chaque morceau) force $t \geq f(x)$, et comme on minimise t , l'optimum prend $t = f(x)$. **On n'a rien changé au problème, on a juste déplacé la difficulté dans les contraintes** — là où elle devient linéaire. C'est le passage à l'**épigraphe**.

● Concept 1 — Linéaire, affine, affine par morceaux

Fonction linéaire. $f : \mathbb{R}^n \rightarrow \mathbb{R}$ est linéaire si

$$f(\alpha x + \beta y) = \alpha f(x) + \beta f(y) \quad \forall x, y \in \mathbb{R}^n, \forall \alpha, \beta \in \mathbb{R}$$

Propriété : f est linéaire **si et seulement si** $f(x) = a^T x$ pour un certain a .

Fonction affine. f est affine si

$$f(\alpha x + (1 - \alpha)y) = \alpha f(x) + (1 - \alpha)f(y) \quad \forall x, y \in \mathbb{R}^n, \forall \alpha \in \mathbb{R}$$

Propriété : f est affine **si et seulement si** $f(x) = a^T x + b$ pour certains a et b .

La différence tient au coefficient : linéaire autorise **toutes** les combinaisons α, β ; affine n'autorise que celles dont les poids somment à **1**. Une fonction affine avec $b \neq 0$ n'est pas linéaire, bien que son graphe soit une droite. Le cours parle de « fonction linéaire » pour l'objectif d'un LP, alors qu'un $+b$ ne changerait rien à l'argmin.

Fonction affine par morceaux (convexe). $f : \mathbb{R}^n \rightarrow \mathbb{R}$ est dite affine par morceaux convexe si

$$f(x) = \max_{i=1, \dots, m} (a_i^T x + b_i)$$

Elle est paramétrée par m vecteurs $a_i \in \mathbb{R}^n$ et m scalaires b_i . Son graphe est l'enveloppe supérieure de m hyperplans : une surface « en toit », anguleuse aux intersections.

Le cours note lui-même que *piecewise-affine* serait plus juste que *piecewise-linear*, mais que le second est l'usage.

● Concept 2 — La reformulation reine : minimiser un maximum

$$\min_x f(x) = \max_{i=1, \dots, m} (a_i^T x + b_i)$$

LP équivalent (variables x et un scalaire auxiliaire t) :

$$\begin{array}{ll} \text{minimiser} & t \\ \text{sous} & a_i^T x + b_i \leq t, \quad i = 1, \dots, m \end{array}$$

Pourquoi c'est équivalent. À x fixé, les m contraintes disent exactement $t \geq \max_i (a_i^T x + b_i) = f(x)$. Comme on minimise t , l'optimum choisit la plus petite valeur permise : $t^* = f(x)$. Minimiser en (x, t) revient donc à minimiser f en x .

Écriture matricielle. En posant $\tilde{x} = \begin{pmatrix} x \\ t \end{pmatrix}$:

$$\tilde{c} = \begin{pmatrix} 0 \\ 1 \end{pmatrix}, \quad \tilde{A} = \begin{pmatrix} a_1^T & -1 \\ \vdots & \vdots \\ a_m^T & -1 \end{pmatrix}, \quad \tilde{b} = \begin{pmatrix} -b_1 \\ \vdots \\ -b_m \end{pmatrix}$$

et le problème est $\min \tilde{c}^T \tilde{x}$ sous $\tilde{A} \tilde{x} \preceq \tilde{b}$ — un LP standard à $n + 1$ variables et m contraintes.

Somme de deux fonctions affines par morceaux

$$\min_x f(x) + g(x) = \max_{i=1,\dots,m} (a_i^T x + b_i) + \max_{j=1,\dots,p} (c_j^T x + d_j)$$

Première idée (mauvaise). La somme est encore affine par morceaux :

$$f(x) + g(x) = \max_{\substack{i=1,\dots,m \\ j=1,\dots,p}} (a_i + c_j)^T x + (b_i + d_j)$$

mais c'est un maximum de mp fonctions affines : le LP aurait mp contraintes.

Bonne idée : une variable auxiliaire par morceau.

$$\begin{array}{ll} \text{minimiser} & t_1 + t_2 \\ \text{sous} & a_i^T x + b_i \leq t_1, \quad i = 1, \dots, m \\ & c_j^T x + d_j \leq t_2, \quad j = 1, \dots, p \end{array}$$

soit $m + p$ contraintes au lieu de mp . À x fixé, les optima sont $t_1 = f(x)$ et $t_2 = g(x)$.

La leçon générale. Ajouter des variables auxiliaires **réduit** la taille du problème au lieu de l'augmenter. C'est contre-intuitif et c'est central : ne développez jamais un produit de maxima, introduisez une variable par terme.

● Concept 3 — Approximation en norme infinie (Tchebychev)

$$\min_x \|Ax - b\|_\infty, \quad A \in \mathbb{R}^{m \times n}, \quad b \in \mathbb{R}^m$$

La norme infinie d'un vecteur $y \in \mathbb{R}^m$ s'écrit comme un maximum de fonctions affines :

$$\|y\|_{\infty} = \max_{i=1,\dots,m} |y_i| = \max_{i=1,\dots,m} \max\{y_i, -y_i\}$$

LP équivalent (variables x et un scalaire t) :

$$\begin{array}{ll} \text{minimiser} & t \\ \text{sous} & -t\mathbf{1} \preceq Ax - b \preceq t\mathbf{1} \end{array}$$

À x fixé, l'optimum est $t = \|Ax - b\|_{\infty}$.

Forme matricielle. Avec $\tilde{x} = (x, t)$:

$$\min \begin{pmatrix} 0 \\ 1 \end{pmatrix}^T \tilde{x} \quad \text{sous} \quad \begin{pmatrix} A & -\mathbf{1} \\ -A & -\mathbf{1} \end{pmatrix} \begin{pmatrix} x \\ t \end{pmatrix} \preceq \begin{pmatrix} b \\ -b \end{pmatrix}$$

● Concept 4 — Approximation en norme 1

$$\min_x \|Ax - b\|_1$$

Ici la norme est une **somme** de valeurs absolues :

$$\|y\|_1 = \sum_{i=1}^m |y_i| = \sum_{i=1}^m \max\{y_i, -y_i\}$$

On applique donc la leçon du concept 2 : **une variable auxiliaire par terme**, c'est-à-dire un **vecteur** $u \in \mathbb{R}^m$ et non un scalaire.

LP équivalent :

$$\begin{array}{ll} \text{minimiser} & \sum_{i=1}^m u_i \\ \text{sous} & -u \preceq Ax - b \preceq u \end{array}$$

À x fixé, l'optimum est $u_i = |(Ax - b)_i|$.

Forme matricielle. Avec $\tilde{x} = (x, u)$:

$$\min \begin{pmatrix} 0 \\ \mathbf{1} \end{pmatrix}^T \tilde{x} \quad \text{sous} \quad \begin{pmatrix} A & -I \\ -A & -I \end{pmatrix} \begin{pmatrix} x \\ u \end{pmatrix} \preceq \begin{pmatrix} b \\ -b \end{pmatrix}$$

Ne confondez pas les deux reformulations : **norme infinie** $\rightarrow$ **un scalaire** t (on borne le pire résidu), **norme 1** $\rightarrow$ **un vecteur** u (on borne chaque résidu séparément). Utiliser un scalaire pour la norme 1 donnerait $m \cdot \max_i |y_i|$, ce qui n'est pas $\|y\|_1$.

Ce que chaque norme fait aux résidus

Le cours compare les histogrammes des résidus $Ax - b$ pour $A \in \mathbb{R}^{200 \times 80}$ tirée au hasard, entre $x_{mc} = \arg \min \|Ax - b\|_2$ (moindres carrés) et $x_1 = \arg \min \|Ax - b\|_1$.

Norme minimisée	Ce qu'elle produit	Quand la choisir
$\ \cdot\ _2$ (moindres carrés)	résidus étalés en cloche, tous petits mais aucun nul	bruit gaussien, pas de valeur aberrante
$\ \cdot\ _1$	beaucoup de résidus exactement nuls , mais quelques grands	données avec valeurs aberrantes ; on veut un ajustement robuste
$\ \cdot\ _\infty$	tous les résidus de même amplitude maximale	on veut garantir une erreur maximale faible (conception, tolérances)

Intuition. La norme 1 ne pénalise pas davantage un gros écart qu'un petit à somme égale : elle « laisse tomber » quelques points aberrants pour coller parfaitement aux autres. La norme 2 punit le carré : elle refuse tout gros écart et le répartit. La norme infinie ne regarde **que** le pire. C'est le même phénomène qui rend la norme 1 favorable à la **parcimonie** (concept 6).

● Concept 5 — Ajustement de données

Ajuster une fonction affine $f(t) = \alpha + \beta t$ à m points (t_i, y_i) : c'est un problème d'approximation $Ax \approx b$ avec

$$A = \begin{pmatrix} 1 & t_1 \\ \vdots & \vdots \\ 1 & t_m \end{pmatrix}, \quad x = \begin{pmatrix} \alpha \\ \beta \end{pmatrix}, \quad b = \begin{pmatrix} y_1 \\ \vdots \\ y_m \end{pmatrix}$$

Minimiser $\|Ax - b\|_1$ donne une régression **robuste** (résistante aux points aberrants) ; $\|Ax - b\|_\infty$ donne l'ajustement **minimax** ; les deux sont des LP.

● Concept 6 — Reconstruction de signaux parcimonieux

Le problème. $\hat{x} \in \mathbb{R}^n$ est un signal inconnu, connu pour être **très parcimonieux** (*sparse*). On dispose de mesures linéaires $y = A\hat{x}$ avec $A \in \mathbb{R}^{m \times n}$ et $m < n$: le système est **sous-déterminé**, il a une infinité de solutions.

Les deux problèmes.

$$\begin{array}{ll} \text{minimiser} & \text{card}(x) \\ \text{sous} & Ax = y \end{array} \qquad \begin{array}{ll} \text{minimiser} & \|x\|_1 \\ \text{sous} & Ax = y \end{array}$$

où **card**(x) est le nombre de composantes non nulles. Le premier est combinatoire et hors de portée ; le second est un **LP**. Quand sont-ils équivalents ?

Définition (du cours). A permet la reconstruction exacte des vecteurs k -parcimonieux si

$$\hat{x} = \arg \min_{Ax=y} \|x\|_1 \quad \text{dès que} \quad y = A\hat{x} \text{ et } \text{card}(\hat{x}) \leq k$$

(l'argmin désignant l'unique minimiseur). C'est une propriété **du noyau** de la matrice de mesure A .

Condition du noyau (nécessaire et suffisante). Pour tout $z \in \text{nullspace}(A) \setminus \{0\}$ et tout ensemble de support I avec $|I| \leq k$:

$$\|P_I z\|_1 < \frac{1}{2} \|z\|_1$$

où P_I met à zéro les composantes hors de I ; de façon équivalente, $|z_{(1)}| + \dots + |z_{(k)}| < \frac{1}{2} \|z\|_1$ pour les k plus grandes composantes en valeur absolue.

Preuve de la suffisance (celle du cours, à savoir refaire). Soit $\hat{x}$ k -parcimonieux de support I (donc $P_I \hat{x} = \hat{x}$) et $y = A\hat{x}$. Soit x admissible ($Ax = y$), différent de $\hat{x}$; posons $z = x - \hat{x}$, vecteur non nul du noyau de A . Alors

$$\begin{aligned} \|x\|_1 &= \|\hat{x} + z\|_1 \geq \|\hat{x} + P_I z\|_1 - \|P_I z\|_1 \\ &= \sum_{k \in I} |\hat{x}_k + z_k| + \sum_{k \notin I} |z_k| - \|P_I z\|_1 \geq \|\hat{x}\|_1 + \|z\|_1 - 2\|P_I z\|_1 > \|\hat{x}\|_1 \end{aligned}$$

La deuxième ligne utilise l'inégalité triangulaire, la dernière la condition du noyau. Donc $\hat{x}$ est bien l'unique minimiseur.

Nécessité. Si la condition échoue, il existe $z \neq 0$ dans le noyau et I avec $|I| \leq k$ tels que $\|P_I z\|_1 \geq \frac{1}{2} \|z\|_1$. On pose $\hat{x} = -P_I z$ (k -parcimonieux) et $y = A\hat{x}$; alors $x = \hat{x} + z$ vérifie $Ax = y$ et

$$\|x\|_1 = \|-P_I z + z\|_1 = \|z\|_1 - \|P_I z\|_1 \leq 2\|P_I z\|_1 - \|P_I z\|_1 = \|\hat{x}\|_1$$

donc $\hat{x}$ n'est pas l'unique minimiseur en norme 1.

Pourquoi c'est important. C'est le fondement du *compressed sensing* et l'explication théorique du LASSO : remplacer un comptage combinatoire par une norme 1 **ne perd rien**, sous une condition portant uniquement sur la matrice de mesure.

● Concept 7 — Classification linéaire

On dispose de points $v_1, \dots, v_N$ avec des étiquettes binaires $s_i \in \{-1, 1\}$, et l'on cherche un hyperplan qui sépare **strictement** les deux classes : trouver a et b tels que

$$s_i (a^T v_i + b) > 0 \quad \text{pour tout } i$$

Quand les classes ne sont pas séparables, on minimise la somme des violations, avec la **perte charnière** (*hinge loss*) :

$$\min_{a,b} \sum_{i=1}^N \max\{0, 1 - s_i(a^T v_i + b)\}$$

C'est une somme de N fonctions affines par morceaux (chacune un maximum de deux affines) : par le concept 2, c'est un **LP** à N variables auxiliaires :

$$\begin{array}{ll} \text{minimiser} & \sum_{i=1}^N u_i \\ \text{sous} & u_i \geq 0, \quad u_i \geq 1 - s_i(a^T v_i + b), \quad i = 1, \dots, N \end{array}$$

● Concept 8 — Les outils de modélisation

Le cours termine sur les logiciels de modélisation, qui « simplifient la formulation des LP (et d'autres problèmes) » : ils acceptent l'écriture **naturelle** (**max**, $\|\cdot\|_1$, valeurs absolues) et effectuent eux-mêmes la conversion en forme standard. On écrit par exemple, directement,

$$\min \|Ax - b\|_1 \quad \text{sous} \quad 0 \leq x_k \leq 1, \quad k = 1, \dots, n$$

et l'outil fabrique le LP à variables auxiliaires du concept 4.

Savoir écrire la reformulation **à la main** reste indispensable : c'est ce qui est demandé en examen, et c'est ce qui permet de comprendre pourquoi un problème passe ou ne passe pas.

Comment résoudre l'exercice type (protocole)

1. **Repérer la non-linéarité** : $\max$, $\min$, $|\cdot|$, $\|\cdot\|_1$, $\|\cdot\|_\infty$, ou une somme de tels termes.
2. **Vérifier le sens** : on minimise un $\max$ (ou un $\|\cdot\|$), ou on maximise un $\min$. Dans l'autre sens (minimiser un min, maximiser un max), la reformulation **ne marche pas** — le problème n'est pas convexe.
3. **Compter les variables auxiliaires** : un seul scalaire t si l'objectif est **un** maximum ; un vecteur u si c'est une **somme** de maxima (un par terme).
4. **Écrire les contraintes de majoration** : chaque morceau $\leq$ la variable auxiliaire associée.
5. **Remplacer l'objectif** par la variable auxiliaire (ou leur somme).
6. **Vérifier l'équivalence** : à x fixé, l'optimum des auxiliaires reconstitue bien la valeur d'origine.
7. **Mettre sous forme matricielle** $\min \tilde{c}^T \tilde{x}$ s.c. $\tilde{A}\tilde{x} \preceq \tilde{b}$.

Le tableau des reformulations à connaître par cœur

Objectif	Variables ajoutées	Contraintes ajoutées	Nouvel objectif
$\max_i (a_i^T x + b_i)$	$t \in \mathbb{R}$	$a_i^T x + b_i \leq t$	t
$f(x) + g(x)$, deux max	$t_1, t_2 \in \mathbb{R}$	chaque morceau $\leq t_1$ ou t_2	$t_1 + t_2$
$\ Ax - b\ _\infty$	$t \in \mathbb{R}$	$-t\mathbf{1} \preceq Ax - b \preceq t\mathbf{1}$	t
$\ Ax - b\ _1$	$u \in \mathbb{R}^m$	$-u \preceq Ax - b \preceq u$	$\mathbf{1}^T u$
$\sum_i \max\{0, \ell_i(x)\}$	$u \in \mathbb{R}^N$	$u_i \geq 0, u_i \geq \ell_i(x)$	$\mathbf{1}^T u$
$\max \min_i (a_i^T x + b_i)$	$t \in \mathbb{R}$	$a_i^T x + b_i \geq t$	t (à maximiser)

Exercices progressifs

Niveau 1 — Reformulez en LP : $\min_x |x_1 - 1| + |x_2 + 2|$.

Somme de deux valeurs absolues, donc **deux** auxiliaires :

$$\min u_1 + u_2 \quad \text{s.c.} \quad -u_1 \leq x_1 - 1 \leq u_1, \quad -u_2 \leq x_2 + 2 \leq u_2$$

Optimum évident : $x = (1, -2)$, valeur **0**. L'intérêt est la méthode, pas le résultat.

Niveau 2 — Reformulez $\min_x \max\{|x_1|, |x_2|, |x_1 + x_2 - 1|\}$.

C'est **un** maximum, donc **un** scalaire t , et chaque valeur absolue donne deux inégalités :

$$\min t \quad \text{s.c.} \quad -t \leq x_1 \leq t, \quad -t \leq x_2 \leq t, \quad -t \leq x_1 + x_2 - 1 \leq t$$

Valeur optimale : par symétrie $x_1 = x_2 = s$, on minimise $\max\{|s|, |2s - 1|\}$; l'égalité $s = 1 - 2s$ donne $s = 1/3$ et $t = 1/3$.

Niveau 3 — Le problème de suivi de sortie de la fiche 24 : $\min \max_{t=0, \dots, N} |y(t) - y_{\text{des}}(t)|$ sous $|u(t)| \leq U$ et $|u(t+1) - u(t)| \leq S$, avec $y = Hu$ linéaire en u . Écrivez le LP.

Les variables sont $u(0), \dots, u(M)$ et un scalaire s :

$$\begin{array}{ll} \text{minimiser} & s \\ \text{sous} & -s \leq y(t) - y_{\text{des}}(t) \leq s, \quad t = 0, \dots, N \\ & -U \leq u(t) \leq U \\ & -S \leq u(t+1) - u(t) \leq S \end{array}$$

Tout est linéaire en u puisque $y(t) = \sum_k h_k u(t-k)$. **C'est la réponse à la promesse laissée en suspens au slide 1-4** : le problème de commande « se formule comme un LP ».

Niveau 4 — type feuille d'exercices — Montrez que $\min_x \|Ax - b\|_\infty$ et $\min_x \|Ax - b\|_1$ ont, en général, des solutions différentes, sur $A = \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}$ et $b = (0, 1, 10)$.

Ici x est un scalaire et $Ax - b = (x, x - 1, x - 10)$.

Norme 1 : $\|Ax - b\|_1 = |x| + |x - 1| + |x - 10|$ — somme de valeurs absolues d'une variable, minimisée à la **médiane** des points $\{0, 1, 10\}$, soit $x_1^* = 1$, valeur $1 + 0 + 9 = 10$.

Norme infinie : $\|Ax - b\|_\infty = \max\{|x|, |x - 1|, |x - 10|\}$, minimisé au **milieu de l'étendue**, soit $x_\infty^* = 5$, valeur 5.

Les deux solutions diffèrent (1 contre 5), et l'écart raconte la différence de philosophie : la norme 1 suit la masse des points et ignore l'aberrant 10 ; la norme infinie se place à mi-chemin des

extrêmes pour minimiser le pire écart. (Pour comparaison, les moindres carrés donneraient la moyenne, $11/3 \approx 3,67$.)

● Common mistakes

1. **Un scalaire là où il faut un vecteur** — norme 1 et somme de max exigent **une auxiliaire par terme** ; seule une norme infinie ou un max unique se contente d'un scalaire.
2. **Reformuler dans le mauvais sens** — on minimise un **max** et on maximise un **min**. Minimiser un **min** ne se ramène pas à un LP : le problème n'est pas convexe.
3. **Oublier le double sens de la valeur absolue** — $|z| \leq t$ vaut **deux** inégalités $-t \leq z \leq t$. N'en écrire qu'une est l'erreur la plus fréquente.
4. **Développer un produit de maxima** — mp contraintes au lieu de $m + p$: correct mais inutilement coûteux, et souvent hors délai.
5. **Croire que la norme 2 se met en LP** — $\|Ax - b\|_2$ n'est pas affine par morceaux ; c'est un problème quadratique (ou SOCP), pas un LP.
6. **Oublier les contraintes de positivité des auxiliaires** dans la perte charnière — $u_i \geq 0$ et $u_i \geq 1 - s_i(a_i^T v_i + b)$: c'est le max de deux termes.
7. **Confondre $\text{card}(x)$ et $\|x\|_1$ sans condition** — leur équivalence n'est pas gratuite : elle exige la condition du noyau sur A .

Ultimate Review

1. Affine par morceaux convexe : $f(x) = \max_i(a_i^T x + b_i)$.
2. Recette centrale : minimiser $f \iff$ minimiser t sous $a_i^T x + b_i \leq t$ — passage à l'épigraphe.
3. Somme de deux max : **une auxiliaire par terme**, $m + p$ contraintes au lieu de mp .
4. $\|Ax - b\|_\infty$: un scalaire t , contrainte $-t\mathbf{1} \preceq Ax - b \preceq t\mathbf{1}$.
5. $\|Ax - b\|_1$: un vecteur u , contrainte $-u \preceq Ax - b \preceq u$, objectif $\mathbf{1}^T u$.
6. Norme 1 $\rightarrow$ ajustement robuste et résidus nuls ; norme 2 $\rightarrow$ résidus étalés ; norme infinie $\rightarrow$ résidus tous égaux au pire.
7. Parcimonie : **min $\text{card}(x)$** et **min $\|x\|_1$** sous $Ax = y$ coïncident **ssi** $\|P_I z\|_1 < \frac{1}{2} \|z\|_1$ pour tout z du noyau et $|I| \leq k$.
8. Classification : perte charnière $\sum_i \max\{0, 1 - s_i(a_i^T v_i + b)\}$, donc un LP.

Formulas to know

$$f(x) = \max_i (a_i^T x + b_i) \quad \min t \text{ s.c. } a_i^T x + b_i \leq t \quad -u \preceq Ax - b \preceq u \quad \|P_I z\|_1 < \frac{1}{2} \|z\|_1$$

Methods to know : le protocole de reformulation en 7 étapes ; le tableau des six reformulations ; la preuve de suffisance de la condition du noyau.

Active Recall

Basic — Écrivez le LP équivalent à $\min_x \max_i (a_i^T x + b_i)$.

$\min t$ sous $a_i^T x + b_i \leq t$ pour $i = 1, \dots, m$, avec variables (x, t) . À x fixé, l'optimum est $t = f(x)$.

Understanding — Pourquoi ajouter des variables auxiliaires **réduit-il** la taille du problème pour une somme de deux maxima ?

Développer $\max_i + \max_j$ en un seul maximum donne mp fonctions affines, donc mp contraintes. Avec une auxiliaire par terme (t_1 pour f , t_2 pour g), on n'écrit que m contraintes pour f et p pour g : $m + p$ au total. Chaque terme est traité séparément au lieu d'être croisé avec l'autre.

Application — Reformulez $\min_x \|Ax - b\|_1 + \|x\|_\infty$.

Deux termes, deux jeux d'auxiliaires : un vecteur $u \in \mathbb{R}^m$ pour la norme 1 et un scalaire t pour la norme infinie.

$$\min \mathbf{1}^T u + t \quad \text{s.c.} \quad -u \preceq Ax - b \preceq u, \quad -t\mathbf{1} \preceq x \preceq t\mathbf{1}$$

Comparison — Norme 1 ou norme infinie pour ajuster des données contenant deux capteurs défectueux ?

Norme 1. Elle produit un ajustement robuste : elle accepte de laisser deux gros résidus sur les capteurs défectueux pour coller aux autres points. La norme infinie ferait l'inverse — elle

ne regarde que le pire résidu, donc elle serait **entièrement dictée par les capteurs défaillants**.

Exam-style — Montrez que $\min_x \|Ax - b\|_\infty$ et $\min_{x,t} t$ s.c. $-t\mathbf{1} \preceq Ax - b \preceq t\mathbf{1}$ ont la même valeur optimale.

Si (x, t) est admissible pour le second, alors $|(Ax - b)_i| \leq t$ pour tout i , donc $\|Ax - b\|_\infty \leq t$: la valeur optimale du second **majoré** celle du premier. Réciproquement, pour tout x , le couple $(x, \|Ax - b\|_\infty)$ est admissible pour le second, dont la valeur optimale **minore** donc $\min_x \|Ax - b\|_\infty$. Les deux valeurs coïncident, et à l'optimum $t^* = \|Ax^* - b\|_\infty$.

Flashcards

Question	Réponse
Fonction affine par morceaux convexe ?	$f(x) = \max_{i=1..m}(a_i^T x + b_i)$
f linéaire $\iff$?	$f(x) = a^T x$
f affine $\iff$?	$f(x) = a^T x + b$
Reformulation de $\min \max_i(a_i^T x + b_i)$?	$\min t \text{ s.c. } a_i^T x + b_i \leq t$
Somme de deux max : combien de contraintes ?	$m + p$ avec deux auxiliaires (et non mp)
LP pour $\ Ax - b\ _\infty$?	$\min t \text{ s.c. } -t\mathbf{1} \preceq Ax - b \preceq t\mathbf{1}$
LP pour $\ Ax - b\ _1$?	$\min \mathbf{1}^T u \text{ s.c. } -u \preceq Ax - b \preceq u$
Scalaire ou vecteur d'auxiliaires ?	Un max $\rightarrow$ scalaire ; une somme de max $\rightarrow$ vecteur
Effet de la norme 1 sur les résidus ?	Beaucoup de résidus nuls, quelques grands — ajustement robuste
Effet de la norme infinie ?	Tous les résidus de même amplitude maximale
Condition du noyau (parcimonie) ?	$\ P_I z\ _1 < \frac{1}{2} \ z\ _1$ pour tout $z \in \text{nullspace}(A) \setminus \{0\}$, $ I \leq k$
Perte charnière ?	$\sum_i \max\{0, 1 - s_i(a^T v_i + b)\}$ — un LP
$\ Ax - b\ _2$ est-il un LP ?	Non — quadratique, pas affine par morceaux