

Fiche 37 — Les familles standard : LP, QP, SOCP, GP, SDP (Boyd, §4.3–4.7)

Matière	Maths · Optimisation
Cours source	Boyd & Vandenberghe, <i>Convex Optimization</i> , §4.3 à §4.7, p. 146–182
Difficulté	Fondamental — la carte des problèmes que l'on sait résoudre
Temps d'étude estimé	2 h
Prérequis	Fiche 36 (forme standard convexe), fiche 34 (cône du second ordre, cône PSD)
Concepts clés	LP, QP, QCQP, SOCP, programmation géométrique, forme conique, SDP, optimisation vectorielle, optimum de Pareto, scalarisation
Poids à l'examen	La compétence évaluée est le classement : reconnaître à quelle famille appartient un problème, et savoir le ramener à la plus simple possible. Un problème correctement classé est un problème résolu — les solveurs font le reste.

Vue d'ensemble

Le chapitre 4 se termine par un catalogue de **familles emboîtées**, de la plus simple à la plus générale. Chacune se résout par des algorithmes dédiés, d'autant plus rapides que la famille est étroite.

LP $\subset$ QP $\subset$ QCQP $\subset$ SOCP $\subset$ SDP (chaîne principale)
GP $\rightarrow$ convexe par changement de variable log
forme conique : le cadre qui les unifie tous

La **compétence à acquérir** n'est pas de connaître les algorithmes, mais de **placer un problème dans cette chaîne le plus à gauche possible**. Un problème écrit en SDP alors qu'il est un LP se résout des milliers de fois plus lentement.

● Concept 1 — Programmes linéaires (§4.3)

Quand l'objectif **et** toutes les contraintes sont **affines**, le problème est un **programme linéaire** :

$$\begin{array}{ll}
\text{minimiser} & c^T x + d \\
\text{sous} & Gx \preceq h \\
& Ax = b
\end{array} \tag{4.27}$$

avec $G \in \mathbb{R}^{m \times n}$ et $A \in \mathbb{R}^{p \times n}$. Les LP sont évidemment des problèmes convexes.

La constante d ne change ni l'ensemble optimal ni l'argmin : on l'omet souvent. Les deux formes particulières habituelles (fiches 24 et 26) :

Forme	Écriture
forme d'inégalités	$\min c^T x$ s.c. $Ax \preceq b$
forme standard	$\min c^T x$ s.c. $Ax = b, x \succeq 0$

(Les fiches 24 à 33 sont entièrement consacrées à cette famille : géométrie, dualité, simplexe, réseaux, nombres entiers.)

● Concept 2 — Programmes quadratiques (§4.4)

QP — objectif quadratique **convexe**, contraintes **affines** :

$$\begin{array}{ll}
\text{minimiser} & \frac{1}{2} x^T P x + q^T x + r \\
\text{sous} & Gx \preceq h \\
& Ax = b
\end{array} \tag{4.34}$$

avec $P \in \mathbf{S}_+^n$. On minimise une quadratique convexe sur un polyèdre.

La condition $P \succeq 0$ est ce qui fait la convexité (§3.1.4, exemple 3.2). Avec P indéfinie, le problème est un « QP non convexe » — objet nettement plus difficile, sans rapport avec cette famille.

QCQP — on autorise en plus des contraintes quadratiques convexes :

$$\begin{array}{ll}
\text{minimiser} & \frac{1}{2} x^T P_0 x + q_0^T x + r_0 \\
\text{sous} & \frac{1}{2} x^T P_i x + q_i^T x + r_i \leq 0, \quad i = 1, \dots, m \\
& Ax = b
\end{array}$$

avec $P_i \in \mathbf{S}_+^n$. On minimise alors une quadratique convexe sur une intersection d'**ellipsoïdes**. Les QCQP contiennent les QP (prendre $P_i = 0$), donc aussi les LP.

L'exemple canonique : les moindres carrés. Minimiser

$$\|Ax - b\|_2^2 = x^T A^T A x - 2b^T A x + b^T b$$

est un QP **sans contrainte**. On l'appelle aussi régression ou approximation au sens des moindres carrés, et il se résout analytiquement par les équations normales $A^T A x = A^T b$.

● Concept 3 — Programmes coniques du second ordre (§4.4.2)

$$\begin{array}{ll} \text{minimiser} & f^T x \\ \text{sous} & \|A_i x + b_i\|_2 \leq c_i^T x + d_i, \quad i = 1, \dots, m \\ & Fx = g \end{array} \quad (4.36)$$

avec $A_i \in \mathbb{R}^{n_i \times n}$ et $F \in \mathbb{R}^{p \times n}$. Une contrainte de la forme

$$\|Ax + b\|_2 \leq c^T x + d$$

s'appelle **contrainte conique du second ordre** : elle exprime que le vecteur affine $(Ax + b, c^T x + d)$ appartient au **cône du second ordre** (fiche 34).

Les cas particuliers, à savoir reconnaître.

Si...	on retrouve
$c_i = 0$ pour tout i	un QCQP (les contraintes deviennent $\ A_i x + b_i\ _2 \leq d_i$, des boules)
$A_i = 0$ pour tout i	un LP (les contraintes deviennent affines)

POURQUOI LE SOCP COMPTE.

Il capture d'un coup les normes euclidiennes, les contraintes d'ellipsoïde, les quotients quadratiques et une bonne partie de l'optimisation **robuste** — tout en restant très efficacement résoluble par points intérieurs. C'est le bon niveau de généralité pour la plupart des applications d'ingénierie.

● Concept 4 — Programmation géométrique (§4.5)

C'est la famille la plus surprenante : elle **n'est pas convexe** telle qu'écrite, et le devient par un changement de variable.

Monôme. Une fonction $f : \mathbb{R}^n \rightarrow \mathbb{R}$ de domaine $\mathbb{R}_{++}^n$ définie par

$$f(x) = c x_1^{a_1} x_2^{a_2} \cdots x_n^{a_n} \quad (4.41)$$

avec $c > 0$ et $a_i \in \mathbb{R}$ **quelconques** (fractionnaires ou négatifs autorisés). Le **coefficient**, lui, doit être **strictement positif**.

Boyd signale explicitement le conflit de vocabulaire : en algèbre, un monôme a des exposants entiers positifs. Ici, seul le coefficient est contraint.

Posynôme. Une **somme** de monômes :

$$f(x) = \sum_{k=1}^K c_k x_1^{a_{1k}} x_2^{a_{2k}} \cdots x_n^{a_{nk}}, \quad c_k > 0 \quad (4.42)$$

Programme géométrique (GP).

$$\begin{array}{ll} \text{minimiser} & f_0(x) \\ \text{sous} & f_i(x) \leq 1, \quad i = 1, \dots, m \\ & h_i(x) = 1, \quad i = 1, \dots, p \end{array} \quad (4.43)$$

où $f_0, \dots, f_m$ sont des **posynômes** et $h_1, \dots, h_p$ des **monômes**. Le domaine est $\mathbb{R}_{++}^n$: la contrainte $x \succ 0$ est **implicite**.

La mise en forme convexe (§4.5.3). On pose $y_i = \log x_i$, donc $x_i = e^{y_i}$. Un monôme devient

$$f(e^{y_1}, \dots, e^{y_n}) = c (e^{y_1})^{a_1} \cdots (e^{y_n})^{a_n} = e^{a^T y + b}, \quad b = \log c$$

c'est-à-dire l'**exponentielle d'une fonction affine**. Un posynôme devient une somme de telles exponentielles, et en prenant le **logarithme** de l'objectif et des contraintes, on obtient

$$\begin{array}{ll} \text{minimiser} & \log \sum_k e^{a_{0k}^T y + b_{0k}} \\ \text{sous} & \log \sum_k e^{a_{ik}^T y + b_{ik}} \leq 0 \\ & g_i^T y + h_i = 0 \end{array}$$

soit un problème **convexe** : l'objectif et les contraintes sont des **log-sum-exp** de fonctions affines (fiche 35), et les égalités sont affines.

La double transformation à retenir. Changement de variable $x = e^y$ et transformation croissante **log** de l'objectif et des contraintes — les deux mécanismes de la fiche 36, appliqués ensemble. C'est l'exemple le plus spectaculaire de « la convexité est une propriété de l'écriture ».

● Concept 5 — Forme conique et programmation semi-définie (§4.6)

Problème sous forme conique (4.49) — objectif linéaire, une seule contrainte d'inégalité **affine** au sens d'un cône propre K :

$$\begin{array}{ll}\text{minimiser} & c^T x \\ \text{sous} & Fx + g \preceq_K 0 \\ & Ax = b\end{array}$$

Quand K est l'**orthant positif**, on retrouve exactement un **LP**. On peut donc voir les problèmes coniques comme la généralisation des LP dans laquelle l'inégalité composante par composante est remplacée par une inégalité **généralisée**.

Programmation semi-définie (SDP). Lorsque $K = \mathbf{S}_+^k$, le problème conique s'écrit

$$\begin{array}{ll}\text{minimiser} & c^T x \\ \text{sous} & x_1 F_1 + \cdots + x_n F_n + G \preceq 0 \\ & Ax = b\end{array} \quad (4.50)$$

avec $G, F_1, \dots, F_n \in \mathbf{S}^k$ et $A \in \mathbb{R}^{p \times n}$. L'inégalité est une **inégalité matricielle linéaire** (LMI, exemple 2.10 — fiche 34).

Le fait qui situe le SDP. Si les matrices $G, F_1, \dots, F_n$ sont toutes **diagonales**, la LMI équivaut à n inégalités linéaires, et le SDP se réduit à un LP. Un SDP est donc littéralement « un LP dont les nombres sont devenus des matrices ». C'est la façon la plus économique de retenir ce qu'est un SDP.

La chaîne complète.

$$\text{LP} \subset \text{QP} \subset \text{QCQP} \subset \text{SOCP} \subset \text{SDP}$$

Chaque inclusion s'obtient en écrivant les contraintes de la classe plus étroite comme un cas particulier de la plus large — par exemple une contrainte SOC $\|Ax + b\|_2 \leq c^T x + d$ s'écrit comme une LMI par complément de Schur.

● Concept 6 — Optimisation vectorielle et optimalité de Pareto (§4.7)

Le problème (4.56).

$$\begin{array}{ll} \text{minimiser (par rapport à } K) & f_0(x) \\ \text{sous} & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & h_i(x) = 0, \quad i = 1, \dots, p \end{array}$$

où $K \subseteq \mathbb{R}^q$ est un **cône propre** et $f_0 : \mathbb{R}^n \rightarrow \mathbb{R}^q$ est à valeurs **vectorielles**. La seule différence avec la forme standard est là : l'objectif a plusieurs composantes, que l'on compare via $\preceq_K$.

L'ensemble des valeurs atteignables est $\mathcal{O} = \{f_0(x) \mid x \text{ admissible}\}$.

Deux situations, celles de la fiche 34.

- Si $\mathcal{O}$ possède un **élément minimum**, le problème a une solution **optimale** au sens fort : un point qui bat tous les autres sur **tous** les objectifs à la fois. C'est rare.
- Sinon — le cas usuel — on s'intéresse aux **éléments minimaux**.

Optimalité de Pareto. Un point admissible x est **Pareto optimal** (ou **efficace**) si $f_0(x)$ est un élément **minimal** de $\mathcal{O}$. Autrement dit :

$$\text{pour tout } y \text{ admissible,} \quad f_0(y) \preceq_K f_0(x) \implies f_0(y) = f_0(x)$$

Tout point admissible au moins aussi bon que x a exactement la même valeur d'objectif. On ne peut améliorer un critère qu'en dégradant un autre.

Scalarisation (§4.7.4). C'est la technique standard pour produire des points Pareto optimaux. On choisit $\lambda \succ_{K^*} 0$ — un vecteur **strictement positif au sens de l'inégalité duale** — et l'on résout le problème **scalaire**

$$\begin{array}{ll} \text{minimiser} & \lambda^T f_0(x) \\ \text{sous} & f_i(x) \leq 0, \quad h_i(x) = 0 \end{array} \quad (4.60)$$

Toute solution x est alors **Pareto optimale** pour le problème vectoriel — c'est exactement la caractérisation duale des éléments minimaux de la fiche 34.

La réciproque exige la convexité, et reste incomplète. Pour un problème **convexe**, tout point Pareto optimal s'obtient par scalarisation avec un $\lambda \succeq_{K^*} 0$ **non nul** — mais pas nécessairement avec $\lambda \succ_{K^*} 0$. Certains points du front de Pareto ne sont donc atteints qu'avec des poids **nuls** sur certains objectifs. Et pour un problème **non convexe**, la scalarisation peut manquer des points Pareto optimaux entiers — ceux situés dans les « creux » du front.

En pratique. Faire varier λ dans le simplexe et résoudre (4.60) à chaque fois **trace le front de Pareto**. C'est la méthode de base en optimisation multi-objectif : compromis rendement/risque en finance, coût/performance en ingénierie, ajustement/régularité en statistique.

Comment résoudre l'exercice type (protocole de classement)

1. **Mettre en forme standard convexe** (fiche 36) : objectif convexe, inégalités convexes, égalités affines.
2. **Regarder l'objectif** : affine ? quadratique convexe ? autre ?
3. **Regarder les contraintes** : affines ? quadratiques convexes ? normes euclidiennes ? LMI ?
4. **Classer le plus à gauche possible** dans la chaîne $LP \subset QP \subset QCQP \subset SOCP \subset SDP$.
5. **Si des monômes ou des posynômes apparaissent** avec des contraintes ≤ 1 et des variables positives : c'est un **GP** — passer en $y = \log x$.
6. **Si l'objectif est vectoriel** : optimisation vectorielle — chercher les points **Pareto optimaux** par scalarisation.
7. **Vérifier qu'aucune réécriture ne simplifie la classe** : une contrainte de norme au carré, une valeur absolue, un maximum peuvent souvent redescendre d'un cran (fiche 25).

Le tableau de reconnaissance

Objectif	Contraintes	Famille
affine	affines	LP
quadratique convexe	affines	QP
quadratique convexe	quadratiques convexes	QCQP
affine	$\ A_i x + b_i\ _2 \leq c_i^T x + d_i$	SOCP
posynôme	posynômes ≤ 1 , monômes $= 1$, $x \succ 0$	GP
affine	LMI $\sum_i x_i F_i + G \preceq 0$	SDP
vectoriel	quelconques convexes	optimisation vectorielle

Exercices progressifs

Niveau 1 — Classez : $\min \|Ax - b\|_2^2$ s.c. $x \succeq 0$.

Objectif quadratique convexe ($P = 2A^T A \succeq 0$), contraintes affines ($-x \preceq 0$) : c'est un **QP**. On ne peut pas descendre à un LP, l'objectif n'étant pas affine. (Ce problème s'appelle les *moindres carrés à variables positives* — *NNLS* — et sert en séparation de sources et en déconvolution.)

Niveau 2 — Classez : $\min \|Ax - b\|_2$ s.c. $\|x\|_1 \leq 1$.

L'objectif est une **norme euclidienne**, non affine et non quadratique. On passe en forme épigraphe : $\min t$ s.c. $\|Ax - b\|_2 \leq t$ — une contrainte **conique du second ordre**. La contrainte $\|x\|_1 \leq 1$ se linéarise en 2^n inégalités, ou mieux, avec n auxiliaires : $-u \preceq x \preceq u, \mathbf{1}^T u \leq 1$ (fiche 25). On obtient donc un **SOCP**. (C'est la formulation « *LASSO constraint* ».)

Niveau 3 — Montrez que $\min x_1^{-1} x_2^{-2}$ s.c. $x_1 + x_2 \leq 1, x \succ 0$ est un GP, et donnez sa forme convexe.

GP ? L'objectif $x_1^{-1} x_2^{-2}$ est un **monôme** (coefficient $1 > 0$, exposants -1 et -2 — négatifs, ce qui est autorisé), donc un posynôme. La contrainte $x_1 + x_2 \leq 1$ est un **posynôme** ≤ 1 . Le domaine $x \succ 0$ est implicite. C'est bien un **GP**.

Forme convexe. Avec $y_i = \log x_i$:

$$\text{objectif : } \log(e^{-y_1-2y_2}) = -y_1 - 2y_2 \quad (\text{affine !})$$

$$\text{contrainte : } \log(e^{y_1} + e^{y_2}) \leq 0$$

Le problème convexe équivalent est donc

$$\min -y_1 - 2y_2 \quad \text{s.c.} \quad \log(e^{y_1} + e^{y_2}) \leq 0$$

— objectif **affine**, contrainte **log-sum-exp** convexe. À noter : le logarithme d'un **monôme** devient toujours affine ; seuls les posynômes à plusieurs termes donnent du log-sum-exp.

Niveau 4 — **type examen** — Montrez que la contrainte conique du second ordre $\|Ax + b\|_2 \leq c^T x + d$ s'écrit comme une LMI, et concluez sur l'inclusion $\text{SOCP} \subset \text{SDP}$.

Par le **complément de Schur** : pour $t > 0$, une matrice par blocs vérifie

$$\begin{pmatrix} tI & u \\ u^T & t \end{pmatrix} \succeq 0 \iff t \geq 0 \text{ et } t^2 \geq u^T u \iff t \geq \|u\|_2$$

(le complément de Schur du bloc tI est $t - u^T(tI)^{-1}u = t - \|u\|_2^2/t$, positif ssi $t^2 \geq \|u\|_2^2$).

En posant $u = Ax + b$ et $t = c^T x + d$, la contrainte devient

$$\begin{pmatrix} (c^T x + d)I & Ax + b \\ (Ax + b)^T & c^T x + d \end{pmatrix} \succeq 0$$

et cette matrice dépend **affinement** de x : c'est une **LMI**. ■

Conclusion. Toute contrainte SOC est une LMI, donc tout SOCP est un SDP. L'inclusion est **stricte** : le SDP capture des contraintes spectrales (par exemple $\lambda_{\max}(A(x)) \leq t$) qu'aucun SOCP n'exprime.

La morale du protocole de classement. Un SOCP *peut* s'écrire en SDP, mais il ne *doit* pas : les solveurs SOC exploitent une structure bien plus étroite et vont beaucoup plus vite. Classer le plus à gauche possible n'est pas une élégance, c'est une question de temps de calcul.

● Common mistakes

1. **Écrire un QP avec P indéfinie** — la convexité exige $P \succeq 0$; sinon on quitte la famille et le problème devient difficile.
2. **Croire qu'un monôme a des exposants entiers** — en GP, les exposants sont quelconques ; c'est le **coefficient** qui doit être > 0 .
3. **Oublier la contrainte implicite $x \succ 0$ d'un GP** — sans elle, $\log x$ n'a pas de sens et la transformation s'effondre.
4. **Écrire les contraintes d'un GP avec un second membre autre que 1** — la forme standard est $f_i(x) \leq 1$ et $h_i(x) = 1$, pas ≤ 0 .
5. **Classer trop à droite** — écrire un LP en SDP est correct mais coûte des ordres de grandeur en temps de calcul.
6. **Confondre optimal et Pareto optimal** — l'optimal (élément **minimum**) bat tous les autres sur tous les critères ; le Pareto optimal (élément **minimal**) est seulement non dominé.
7. **Croire que la scalarisation atteint tout le front de Pareto** — il faut la convexité, et même alors certains points n'apparaissent qu'avec des poids λ ayant des composantes **nulles**.
8. **Prendre λ au hasard** — la scalarisation exige $\lambda \succ_{K^*} 0$, c'est-à-dire strictement positif au sens du **cône dual**.

Ultimate Review

1. **LP** : objectif et contraintes **affines**, $\min c^T x + d$ s.c. $Gx \preceq h, Ax = b$.
2. **QP** : objectif quadratique convexe ($P \succeq 0$), contraintes affines — une quadratique sur un **polyèdre**.
3. **QCQP** : contraintes quadratiques convexes en plus — une quadratique sur une intersection d'**ellipsoïdes**.
4. **SOCP** : $\min f^T x$ s.c. $\|A_i x + b_i\|_2 \leq c_i^T x + d_i$. $c_i = 0 \Rightarrow$ QCQP ; $A_i = 0 \Rightarrow$ LP.
5. **GP** : posynômes ≤ 1 , monômes $= 1$, $x \succ 0$. Non convexe tel quel ; convexe après $y = \log x$ et passage au **log** — on obtient des **log-sum-exp**.
6. Monôme $= cx_1^{a_1} \cdots x_n^{a_n}$ avec $c > 0$ et a_i **quelconques** ; posynôme = somme de monômes.
7. **Forme conique** : $\min c^T x$ s.c. $Fx + g \preceq_K 0, Ax = b$ — LP généralisé.
8. **SDP** : $K = \mathbf{S}_+^k$, contrainte LMI $\sum_i x_i F_i + G \preceq 0$. Matrices **diagonales** $\Rightarrow$ on retombe sur un LP.
9. Chaîne : **LP** $\subset$ **QP** $\subset$ **QCQP** $\subset$ **SOCP** $\subset$ **SDP** — classer le plus à **gauche** possible.
10. **Pareto optimal** : $f_0(x)$ est un élément **minimal** de $\mathcal{O}$. **Scalarisation** : $\min \lambda^T f_0(x)$ avec $\lambda \succ_{K^*} 0$ donne toujours un point Pareto optimal ; la réciproque exige la convexité et $\lambda \succeq_{K^*} 0$ non nul.

Formulas to know

$$\|A_i x + b_i\|_2 \leq c_i^T x + d_i \quad f(x) = cx_1^{a_1} \cdots x_n^{a_n}, c > 0 \quad x_1 F_1 + \cdots + x_n F_n + G \preceq 0 \quad \min \lambda^T f_0(x)$$

Methods to know : le protocole de classement en 7 étapes ; le tableau de reconnaissance ; la mise en forme convexe d'un GP ; le complément de Schur pour passer d'une contrainte SOC à une LMI.

Active Recall

Basic — Donnez la forme générale d'un QP et la condition qui le rend convexe.

$\min \frac{1}{2} x^T P x + q^T x + r$ s.c. $Gx \preceq h, Ax = b$. La convexité exige $P \in \mathbf{S}_+^n$, c'est-à-dire $P \succeq 0$ — la hessienne de l'objectif est constante et vaut P (exemple 3.2).

Understanding — Pourquoi un programme géométrique devient-il convexe après le changement $y = \log x$?

Un monôme $cx_1^{a_1} \cdots x_n^{a_n}$ devient $e^{a^T y + b}$ avec $b = \log c$: l'exponentielle d'une **affine**. Un posynôme devient une somme de telles exponentielles, et son logarithme est un **log-sum-exp** de fonctions affines, **convexe** (fiche 35). Les contraintes $f_i \leq 1$ deviennent $\log f_i \leq 0$, et les égalités monomiales deviennent **affines**. Les deux transformations de la fiche 36 — changement de variable et transformation croissante — agissent ensemble.

Application — Le problème $\min \max_i (a_i^T x + b_i)$ s.c. $Cx \preceq d$: quelle famille ?

LP. L'objectif n'est pas affine, mais la forme épigraphe le rend affine (fiche 25) :

$$\min t \quad \text{s.c.} \quad a_i^T x + b_i \leq t \quad \forall i, \quad Cx \preceq d$$

Objectif affine en (x, t) , contraintes affines : c'est un LP. *Réflexe : ne jamais classer sur l'écriture brute, toujours après réécriture.*

Comparison — SOCP et SDP : lequel est plus général, et pourquoi ne pas toujours utiliser le plus général ?

Le **SDP** est plus général : toute contrainte SOC s'écrit comme une LMI par complément de Schur, alors que le SDP capture en plus les contraintes spectrales. Mais résoudre un SOCP comme un SDP est **beaucoup plus lent** : les solveurs SOC exploitent la structure très particulière du cône du second ordre. Classer le plus à gauche possible est une exigence de performance, pas d'élégance.

Exam-style — Définissez l'optimalité de Pareto, et énoncez ce que garantit exactement la scalarisation.

Pareto optimal. x admissible est Pareto optimal si $f_0(x)$ est un élément **minimal** de $\mathcal{O} = \{f_0(y) \mid y \text{ admissible}\}$: pour tout y admissible, $f_0(y) \preceq_K f_0(x)$ entraîne $f_0(y) = f_0(x)$.

Scalarisation. Pour tout $\lambda \succ_{K^*} 0$, toute solution de $\min \lambda^T f_0(x)$ sous les mêmes contraintes est **Pareto optimale** — c'est la caractérisation duale des éléments minimaux (§2.6.3).

Récaproque. Pour un problème **convexe**, tout point Pareto optimal est solution d'un tel problème pour un $\lambda \succeq_{K^*} \mathbf{0}$ **non nul** — mais pas forcément avec λ strictement positif. Pour un problème non convexe, la réciproque est fautive : certains points Pareto optimaux échappent complètement à la scalarisation.

Flashcards

Question	Réponse
LP ?	$\min c^T x + d$ s.c. $Gx \preceq h, Ax = b$ — tout est affine
QP ?	Objectif quadratique convexe ($P \succeq 0$), contraintes affines
QCQP ?	Objectif et contraintes quadratiques convexes
SOCP ?	$\min f^T x$ s.c. $\ A_i x + b_i\ _2 \leq c_i^T x + d_i$
SOCP avec $c_i = 0$?	Un QCQP
SOCP avec $A_i = 0$?	Un LP
Monôme (au sens GP) ?	$c x_1^{a_1} \cdots x_n^{a_n}, c > 0$, exposants quelconques
Posynôme ?	Somme de monômes
Forme standard d'un GP ?	$\min f_0$ s.c. $f_i \leq 1$ (posynômes), $h_i = 1$ (monômes), $x \succ 0$
Comment rend-on un GP convexe ?	$y = \log x$, puis log de l'objectif et des contraintes $\rightarrow$ log-sum-exp
Problème sous forme conique ?	$\min c^T x$ s.c. $Fx + g \preceq_K 0, Ax = b$
SDP ?	Forme conique avec $K = \mathbf{S}_+^k$: LMI $\sum_i x_i F_i + G \preceq 0$
SDP à matrices diagonales ?	Se réduit à un LP
La chaîne d'inclusions ?	$LP \subset QP \subset QCQP \subset SOCP \subset SDP$
Pareto optimal ?	$f_0(x)$ est un élément minimal de l'ensemble des valeurs atteignables
Scalarisation ?	$\min \lambda^T f_0(x)$ avec $\lambda \succ_{K^*} 0$ — donne un point Pareto optimal
La scalarisation atteint-elle tout le front ?	Non — il faut la convexité, et même alors certains points exigent λ avec des zéros