

Fiche 39 — Minimisation sans contrainte : gradient et Newton (Boyd, chapitre 9)

Matière	Maths · Optimisation
Cours source	Boyd & Vandenberghe, <i>Convex Optimization</i> , chapitre 9 « Unconstrained minimization », p. 457–520
Difficulté	Must know — le premier chapitre algorithmique, et la base de tous les suivants
Temps d'étude estimé	2 h 30
Prérequis	Fiche 35 (conditions du second ordre), fiche 36 (critère d'optimalité), fiche 12 (descente de gradient, Garrigos)
Concepts clés	Suite minimisante, forte convexité, conditionnement, méthode de descente, recherche linéaire rétrograde, convergence linéaire, pas de Newton, décrétement de Newton, convergence en deux phases, invariance affine
Poids à l'examen	Trois choses : écrire un algorithme de descente correctement (direction, recherche linéaire, critère d'arrêt), analyser sa vitesse en fonction du conditionnement, et expliquer pourquoi Newton est invariant par changement de coordonnées.

Vue d'ensemble

On veut résoudre $\min f(x)$ avec f convexe et deux fois continûment dérivable. La condition d'optimalité est

$$\nabla f(x^*) = 0$$

c'est-à-dire un système de n équations à n inconnues. Sauf cas particuliers, on ne sait pas le résoudre analytiquement : il faut un **algorithme itératif** qui produit une **suite minimisante** $x^{(0)}, x^{(1)}, \dots$ avec $f(x^{(k)}) \rightarrow p^*$.

Tous les algorithmes du chapitre ont la même ossature, et ne diffèrent que par le **choix de la direction** :

répéter

1. choisir une DIRECTION de descente Δx ← c'est ici que les méthodes diffèrent
2. RECHERCHE LINÉAIRE : choisir un pas $t > 0$

3. mise à jour $x := x + t\Delta x$
 jusqu'au critère d'arrêt

Direction	Méthode	Vitesse
$-\nabla f(x)$	descente de gradient	linéaire , dégradée par le conditionnement
$-\nabla^2 f(x)^{-1} \nabla f(x)$	Newton	quadratique près de l'optimum, insensible au conditionnement

● Concept 1 — Le cadre et les hypothèses

Le problème. $\min f(x)$ avec $f : \mathbb{R}^n \rightarrow \mathbb{R}$ convexe et deux fois continûment dérivable — ce qui implique que **dom** f est **ouvert**. On suppose le problème **soluble** : il existe un point optimal x^* , et l'on note $p^* = f(x^*)$.

La condition d'optimalité (9.2). f étant dérivable et convexe, une condition **nécessaire et suffisante** d'optimalité est $\nabla f(x^*) = 0$ (fiche 36, §4.2.3).

Point initial et sous-niveau. Les méthodes exigent un $x^{(0)} \in \mathbf{dom} f$ tel que le sous-niveau initial

$$S = \{x \in \mathbf{dom} f \mid f(x) \leq f(x^{(0)})\}$$

soit **fermé**. C'est le cas pour tout $x^{(0)}$ si f est **fermée** (tous ses sous-niveaux le sont) : par exemple si **dom** $f = \mathbb{R}^n$ et f continue, ou si f est continue de domaine ouvert et tend vers $+\infty$ au bord.

Trois exemples fondateurs (§9.1.1).

Problème	Objectif	Condition d'optimalité
Quadratique	$\frac{1}{2} x^T P x + q^T x + r, P \succeq 0$	$Px = -q$; si $P \succ 0, x^* = -P^{-1}q$ — analytique
Moindres carrés	$\ Ax - b\ _2^2$	$A^T A x = A^T b$ — les équations normales
GP sans contrainte	$\log \sum_i e^{a_i^T x + b_i}$	pas de solution analytique — itératif obligatoire
Centre analytique	$-\sum_i \log(b_i - a_i^T x)$	domaine $\{x \mid a_i^T x < b_i\}$; f est la barrière logarithmique

Le cas quadratique est la clé du chapitre. Comme on sait le résoudre exactement, on peut à chaque itération **remplacer f par son approximation quadratique** et résoudre celle-ci : c'est exactement la méthode de Newton. Et le **centre analytique** reviendra au chapitre 11 comme brique des méthodes de points intérieurs.

● Concept 2 — Forte convexité et conditionnement (§9.1.2)

Hypothèse de forte convexité. Il existe $m > 0$ tel que

$$\nabla^2 f(x) \succeq mI \quad \forall x \in S \quad (9.7)$$

Première conséquence — une meilleure minoration. Par Taylor à l'ordre 2 avec reste,

$$f(y) \geq f(x) + \nabla f(x)^T(y - x) + \frac{m}{2} \|y - x\|_2^2 \quad (9.8)$$

Pour $m = 0$ on retrouve la condition du premier ordre de la convexité ; pour $m > 0$ la minoration est **strictement meilleure**.

Deuxième conséquence — une borne de sous-optimalité. Le membre de droite de (9.8) est une quadratique convexe en y , minimisée en $\tilde{y} = x - \frac{1}{m} \nabla f(x)$. En y évaluant :

$$p^* \geq f(x) - \frac{1}{2m} \|\nabla f(x)\|_2^2 \quad (9.9)$$

C'est le critère d'arrêt de tous les algorithmes du chapitre. Si le gradient est petit, le point est presque optimal :

$$\|\nabla f(x)\|_2 \leq (2m\varepsilon)^{1/2} \implies f(x) - p^* \leq \varepsilon \quad (9.10)$$

Troisième conséquence — une borne sur la distance à l'optimum. En appliquant (9.8) avec $y = x^*$ et Cauchy-Schwarz :

$$\|x - x^*\|_2 \leq \frac{2}{m} \|\nabla f(x)\|_2 \quad (9.11)$$

Corollaire : x^* est unique.

Borne supérieure sur la hessienne. L'inégalité (9.8) entraîne que S est **borné** ; la plus grande valeur propre de $\nabla^2 f$, continue sur S , y est donc majorée : il existe $M > 0$ avec

$$\nabla^2 f(x) \preceq MI \quad \forall x \in S \quad (9.12)$$

d'où la majoration symétrique $f(y) \leq f(x) + \nabla f(x)^T(y - x) + \frac{M}{2} \|y - x\|_2^2$ et

$$p^* \leq f(x) - \frac{1}{2M} \|\nabla f(x)\|_2^2 \quad (9.14)$$

Le conditionnement. Le rapport

$$\kappa = \frac{M}{m}$$

majoré le **conditionnement** des sous-niveaux : c'est le rapport entre le plus grand et le plus petit axe des « ellipsoïdes » de niveau. C'est la quantité qui gouverne la vitesse de la descente de gradient.

● Concept 3 — Méthodes de descente et recherche linéaire (§9.2)

Le schéma général.

$$x^{(k+1)} = x^{(k)} + t^{(k)} \Delta x^{(k)}$$

$\Delta x^{(k)}$ est le **pas** ou **direction de recherche** (le symbole Δx se lit d'un bloc), $t^{(k)} > 0$ la **longueur du pas**.

Direction de descente. Toutes les méthodes du chapitre sont des **méthodes de descente** :

$f(x^{(k+1)}) < f(x^{(k)})$ sauf à l'optimum. Par convexité, $\nabla f(x)^T(y - x) \geq 0$ entraîne $f(y) \geq f(x)$; il faut donc que

$$\nabla f(x^{(k)})^T \Delta x^{(k)} < 0$$

c'est-à-dire que la direction fasse un **angle aigu avec l'opposé du gradient**.

Algorithme 9.1 — méthode de descente générale.

donné un point de départ $x \in \text{dom } f$

répéter

1. déterminer une direction de descente Δx
2. recherche linéaire : choisir un pas $t > 0$
3. mise à jour : $x := x + t\Delta x$

jusqu'au critère d'arrêt

Recherche linéaire exacte. $t = \arg \min_{s>0} f(x + s\Delta x)$. Précise, mais coûteuse — réservée aux cas où ce sous-problème est analytique.

Algorithme 9.2 — recherche linéaire rétrograde (*backtracking*). C'est celle qu'on utilise en pratique.

```
donné une direction de descente  $\Delta x$ ,  $\alpha \in (0, 0.5)$ ,  $\beta \in (0, 1)$   
 $t := 1$   
tant que  $f(x + t\Delta x) > f(x) + \alpha t \nabla f(x)^T \Delta x$   
   $t := \beta t$ 
```

Comment la lire. La droite $t \mapsto f(x) + t \nabla f(x)^T \Delta x$ est l'extrapolation **linéaire** de f ; on en prend une version de pente α fois plus faible. La condition d'acceptation est que f passe **sous** cette droite atténuée : on exige une décroissance au moins égale à une **fraction** α de celle que prédit la linéarisation.

Les paramètres ont un sens : $\alpha \in (0, 0.5)$ — typiquement **0,01** à **0,3** — mesure l'exigence de décroissance ; $\beta \in (0, 1)$ — typiquement **0,1** à **0,8** — la brutalité de la réduction. Prendre $\alpha \geq 0,5$ peut faire rejeter le **pas de Newton complet**, ce qui détruit la convergence quadratique.

● Concept 4 — Descente de gradient et rôle du conditionnement (§9.3)

Algorithme 9.3. On prend simplement $\Delta x = -\nabla f(x)$.

```
donné un point de départ  $x \in \text{dom } f$   
répéter  
  1.  $\Delta x := -\nabla f(x)$   
  2. recherche linéaire (exacte ou rétrograde)  
  3.  $x := x + t\Delta x$   
jusqu'à  $\|\nabla f(x)\|_2 \leq \eta$ 
```

Le critère d'arrêt se vérifie en général **après l'étape 1**, pas après la mise à jour.

Analyse de convergence (recherche exacte). De $\nabla^2 f \preceq MI$ on tire la majoration quadratique

$$\tilde{f}(t) = f(x - t \nabla f(x)) \leq f(x) - t \|\nabla f(x)\|_2^2 + \frac{Mt^2}{2} \|\nabla f(x)\|_2^2 \quad (9.17)$$

Le membre de droite est minimisé en $t = 1/M$, de valeur $f(x) - \frac{1}{2M} \|\nabla f(x)\|_2^2$. Donc

$$f(x^+) - p^* \leq f(x) - p^* - \frac{1}{2M} \|\nabla f(x)\|_2^2$$

En combinant avec $\|\nabla f(x)\|_2^2 \geq 2m(f(x) - p^*)$ (issue de (9.9)) :

$$f(x^{(k)}) - p^* \leq c^k (f(x^{(0)}) - p^*), \quad c = 1 - \frac{m}{M} = 1 - \frac{1}{\kappa} \quad (9.18)$$

C'est une convergence *linéaire* (ou géométrique) : l'erreur est multipliée par $c < 1$ à chaque itération. Le nombre d'itérations pour atteindre une précision ε est

$$\frac{\log((f(x^{(0)}) - p^*)/\varepsilon)}{\log(1/c)} \quad (9.19)$$

Comment lire cette borne. Le **numérateur** est le logarithme du rapport entre la sous-optimalité initiale et la précision voulue : il dit que la qualité du point de départ compte, mais seulement

logarithmiquement. Le **dénominateur** dépend entièrement de c , donc de $\kappa = M/m$.

Le fléau du conditionnement. Si κ est grand, $c = 1 - 1/\kappa$ est proche de 1, $\log(1/c) \approx 1/\kappa$, et le nombre d'itérations croît **proportionnellement à κ** . Sur des sous-niveaux très allongés, la descente de gradient **zigzague** : la direction $-\nabla f$ pointe perpendiculairement aux lignes de niveau, donc vers le flanc de la vallée, pas vers son fond.

● Concept 5 — Descente la plus raide (§9.4)

On généralise en choisissant la direction **la plus raide au sens d'une norme $\|\cdot\|$** :

$$\Delta x_{\text{nsd}} = \arg \min \{ \nabla f(x)^T v \mid \|v\| = 1 \}$$

Norme choisie	Direction obtenue
euclidienne $\ \cdot\ _2$	$-\nabla f(x)$ — la descente de gradient
quadratique $\ u\ _P = (u^T P u)^{1/2}$	$-P^{-1} \nabla f(x)$
norme 1	$-\partial f / \partial x_i \cdot e_i$ pour la coordonnée i de plus grande dérivée partielle en valeur absolue — une méthode de descente par coordonnée

L'enseignement. « La » direction de plus forte pente n'existe pas dans l'absolu : elle dépend de la **norme** avec laquelle on mesure les déplacements. Choisir P revient à changer de coordonnées ; et la descente la plus raide en norme $\|\cdot\|_P$ converge d'autant plus vite que la hessienne, **après ce changement de coordonnées**, est bien conditionnée. D'où l'idée : prendre $P = \nabla^2 f(x)$.

● Concept 6 — La méthode de Newton (§9.5)

Le pas de Newton. Pour $x \in \text{dom } f$,

$$\Delta x_{\text{nt}} = -\nabla^2 f(x)^{-1} \nabla f(x)$$

C'est bien une direction de descente : $\nabla f(x)^T \Delta x_{\text{nt}} = -\nabla f(x)^T \nabla^2 f(x)^{-1} \nabla f(x) < 0$ dès que $\nabla f(x) \neq 0$, par définie positivité de la hessienne.

Trois interprétations, à connaître toutes les trois.

1. *Minimiseur de l'approximation quadratique.* Le modèle du second ordre

$$\hat{f}(x+v) = f(x) + \nabla f(x)^T v + \frac{1}{2} v^T \nabla^2 f(x) v \quad (9.28)$$

est une quadratique convexe en v , minimisée exactement en $v = \Delta x_{\text{nt}}$. **Si f est quadratique, $x + \Delta x_{\text{nt}}$ est l'optimum exact.**

2. *Direction la plus raide pour la norme hessienne.* Δx_{nt} est la direction de plus forte pente pour la norme quadratique $\|u\|_{\nabla^2 f(x)} = (u^T \nabla^2 f(x) u)^{1/2}$. Près de x^* , on a $\nabla^2 f(x) \approx \nabla^2 f(x^*)$: c'est le **meilleur choix possible** de norme.

3. *Solution de la condition d'optimalité linéarisée.* En linéarisant $\nabla f(x+v) \approx \nabla f(x) + \nabla^2 f(x)v = 0$, on obtient exactement $v = \Delta x_{\text{nt}}$.

Le décrement de Newton.

$$\lambda(x) = (\nabla f(x)^T \nabla^2 f(x)^{-1} \nabla f(x))^{1/2}$$

Il vérifie

$$f(x) - \inf_y \hat{f}(y) = f(x) - \hat{f}(x + \Delta x_{\text{nt}}) = \frac{1}{2} \lambda(x)^2$$

Donc $\lambda^2/2$ est une estimation de $f(x) - p^*$, fondée sur le modèle quadratique — c'est le **critère d'arrêt** de la méthode.

Algorithme 9.5 — méthode de Newton.

donné un point de départ $x \in \text{dom } f$, une tolérance $\varepsilon > 0$
répéter

1. calculer le pas et le décrement :

$$\Delta x_{\text{nt}} := -\nabla^2 f(x)^{-1} \nabla f(x) \quad ; \quad \lambda^2 := \nabla f(x)^T \nabla^2 f(x)^{-1} \nabla f(x)$$

2. arrêt : terminer si $\lambda^2/2 \leq \varepsilon$

3. recherche linéaire rétrograde
4. mise à jour : $x := x + t \Delta x_{nt}$

● Concept 7 — Convergence en deux phases (§9.5.3)

Hypothèses. f deux fois continûment dérivable, fortement convexe ($mI \preceq \nabla^2 f \preceq MI$ sur S), et hessienne **lipschitzienne** :

$$\|\nabla^2 f(x) - \nabla^2 f(y)\|_2 \leq L\|x - y\|_2 \quad (9.31)$$

La constante L borne en quelque sorte la **dérivée troisième** : elle mesure à quel point f s'écarte d'une quadratique ($L = 0$ pour une quadratique exacte). Intuitivement, Newton fonctionne très bien quand le modèle quadratique varie lentement, donc quand L est petit.

Le résultat. Il existe η avec $0 < \eta \leq m^2/L$ et $\gamma > 0$ tels que :

Phase 1 — étape amortie ($\|\nabla f(x^{(k)})\|_2 \geq \eta$) :

$$f(x^{(k+1)}) - f(x^{(k)}) \leq -\gamma$$

L'objectif baisse d'au moins une **constante** à chaque itération. Cette phase dure donc au plus $(f(x^{(0)}) - p^*)/\gamma$ itérations.

Phase 2 — convergence quadratique ($\|\nabla f(x^{(k)})\|_2 < \eta$) : la recherche linéaire accepte le **pas complet** $t = 1$, et

$$\frac{L}{2m^2} \|\nabla f(x^{(k+1)})\|_2 \leq \left(\frac{L}{2m^2} \|\nabla f(x^{(k)})\|_2 \right)^2 \quad (9.33)$$

Une fois cette phase atteinte, **on n'en sort plus** : l'erreur est **élevée au carré** à chaque itération, et le nombre de décimales exactes **double**. Il faut au plus $\log_2 \log_2(\varepsilon_0/\varepsilon)$ itérations, avec $\varepsilon_0 = 2m^3/L^2$.

Borne totale (9.36).

$$\frac{f(x^{(0)}) - p^*}{\gamma} + \log_2 \log_2(\varepsilon_0/\varepsilon)$$

Le terme $\log_2 \log_2$ croît si lentement qu'on peut le tenir pour une constante — Boyd propose cinq ou six. Six itérations de la phase quadratique donnent une précision d'environ $5 \cdot 10^{-200}$. D'où la formule mnémotechnique (9.37) :

$$\text{nombre d'itérations de Newton} \lesssim \frac{f(x^{(0)}) - p^*}{\gamma} + 6$$

● Concept 8 — Invariance affine (§9.5.4)

La propriété qui distingue Newton. La méthode est **indépendante de tout changement de coordonnées linéaire ou affine**. Si T est inversible et $\bar{f}(y) = f(Ty)$, alors les itérés de Newton appliqués à $\bar{f}$ depuis $y^{(0)} = T^{-1}x^{(0)}$ sont exactement $y^{(k)} = T^{-1}x^{(k)}$ — avec les **mêmes** paramètres de recherche linéaire.

Ce que cela implique.

- Le **décroissement de Newton** est lui aussi invariant : c'est un critère d'arrêt **sans unité**, contrairement à $\|\nabla f(x)\|_2$ qui dépend de l'échelle des variables.
- Newton est **insensible au conditionnement** : mal conditionner un problème par un changement d'échelle ne change rien à sa trajectoire. C'est exactement l'inverse de la descente de gradient, dont la vitesse est gouvernée par $\kappa = M/m$.

Le prix à payer. Chaque itération de Newton exige de **former** la hessienne et de **résoudre** un système linéaire $n \times n$ — de l'ordre de n^3 opérations (ou n^2 en exploitant la structure creuse, §9.7). La descente de gradient ne coûte qu'un gradient. Newton fait **beaucoup moins d'itérations, beaucoup plus chères**.

Comment résoudre l'exercice type (protocole)

1. **Vérifier le cadre** : f convexe, C^2 , **dom** f ouvert, sous-niveau initial fermé.
2. **Tenter l'analytique** : si $\nabla f(x) = 0$ est un système **linéaire** (objectif quadratique), résoudre directement — pas d'algorithme.
3. **Sinon, estimer m et M** : bornes sur les valeurs propres de $\nabla^2 f$ sur S . En déduire κ .
4. **Choisir la méthode** : κ modéré et n grand $\rightarrow$ gradient ; κ grand ou grande précision voulue $\rightarrow$ Newton.

5. **Écrire la direction** : $-\nabla f(x)$, ou $-\nabla^2 f(x)^{-1} \nabla f(x)$ (résoudre le système, ne **jamais** inverser la matrice).
6. **Recherche linéaire rétrograde** avec $\alpha \in (0; 0,5)$, $\beta \in (0; 1)$.
7. **Critère d'arrêt** : $\|\nabla f(x)\|_2 \leq (2m\varepsilon)^{1/2}$ pour le gradient ; $\lambda^2/2 \leq \varepsilon$ pour Newton.
8. **Conclure sur la vitesse** : linéaire de facteur $1 - 1/\kappa$, ou quadratique après une phase amortie.

Exercices progressifs

Niveau 1 — Pour $f(x) = \frac{1}{2}x^T Px + q^T x + r$ avec $P \succ 0$, que donne **une seule** itération de Newton depuis n'importe quel $x^{(0)}$?

$$\nabla f(x) = Px + q \text{ et } \nabla^2 f(x) = P, \text{ donc}$$

$$\Delta x_{\text{nt}} = -P^{-1}(Px + q) = -x - P^{-1}q$$

et $x + \Delta x_{\text{nt}} = -P^{-1}q = x^*$. **Une itération suffit, depuis n'importe quel point.** C'est le cas $L = 0$: le modèle quadratique est exact. C'est précisément l'intuition qui fonde la méthode.

Niveau 2 — Sur $f(x_1, x_2) = \frac{1}{2}(x_1^2 + \gamma x_2^2)$ avec $\gamma > 0$, calculez κ et le facteur c de convergence du gradient.

$\nabla^2 f = \text{diag}(1, \gamma)$, constante. Donc $m = \min(1, \gamma)$, $M = \max(1, \gamma)$ et

$$\kappa = \max(\gamma, 1/\gamma), \quad c = 1 - \frac{1}{\kappa}$$

Pour $\gamma = 1$: $\kappa = 1$, $c = 0$ — **une seule itération**, les lignes de niveau sont des cercles et $-\nabla f$ pointe droit vers l'origine. Pour $\gamma = 100$: $\kappa = 100$, $c = 0,99$ — il faut environ $\log(1/\varepsilon)/\log(1/0,99) \approx 230 \log(1/\varepsilon)$ itérations. **Newton, lui, converge en une itération dans les deux cas** (f est quadratique).

Niveau 3 — Pourquoi impose-t-on $\alpha < 0,5$ dans la recherche rétrograde ?

Pour une fonction **quadratique**, le pas complet $t = 1$ dans la direction de Newton donne exactement

$$f(x + \Delta x_{\text{nt}}) = f(x) + \frac{1}{2} \nabla f(x)^T \Delta x_{\text{nt}}$$

c'est-à-dire une décroissance égale à **la moitié** de celle prédite par la linéarisation. La condition d'acceptation $f(x + t\Delta x) \leq f(x) + \alpha t \nabla f(x)^T \Delta x$ est donc satisfaite en $t = 1$ si et seulement si $\alpha \leq 1/2$.

Avec $\alpha > 0,5$, la recherche linéaire **rejetterait le pas de Newton complet** même sur une quadratique parfaite — et l'on perdrait la convergence quadratique, qui suppose $t = 1$ (phase 2). D'où l'exigence $\alpha \in (0; 0,5)$.

Niveau 4 — type examen — Comparez gradient et Newton sur le **centre analytique**

$f(x) = -\sum_{i=1}^m \log(b_i - a_i^T x)$: gradient, hessienne, coût par itération, et méthode à préférer.

Calculs. Posons $s_i = b_i - a_i^T x > 0$ (les marges). Alors

$$\nabla f(x) = \sum_{i=1}^m \frac{1}{s_i} a_i = A^T d, \quad d_i = 1/s_i$$

$$\nabla^2 f(x) = \sum_{i=1}^m \frac{1}{s_i^2} a_i a_i^T = A^T \text{diag}(d)^2 A$$

La hessienne est bien $\succ 0$ dès que A est de rang n — le problème est alors strictement convexe.

Coût par itération. *Gradient* : former d et un produit $A^T d$, soit $O(mn)$. *Newton* : former $A^T \text{diag}(d)^2 A$ ($O(mn^2)$) puis factoriser par Cholesky ($O(n^3)$) — nettement plus cher.

Conditionnement. Quand x s'approche du bord du polyèdre, certaines marges s_i tendent vers 0 et les termes $1/s_i^2$ **explosent** : la hessienne devient extrêmement mal conditionnée, $\kappa \rightarrow \infty$. La descente de gradient devient **arbitrairement lente**.

Verdict : Newton, sans hésitation. Son **invariance affine** le rend insensible à ce mauvais conditionnement, et sa phase quadratique donne une précision extrême en cinq ou six itérations de plus. C'est exactement pourquoi les **méthodes de points intérieurs** (chapitre 11) sont construites sur Newton appliqué à des barrières logarithmiques, et jamais sur le gradient.

● Common mistakes

1. **Oublier de vérifier que le sous-niveau initial est fermé** — sans cette condition, la suite peut sortir du domaine et l'analyse s'effondre.

2. **Inverser la hessienne** — on **résout** $\nabla^2 f(x) \Delta x = -\nabla f(x)$, par Cholesky. Inverser coûte plus cher et est numériquement moins stable.
3. **Prendre $\alpha \geq 0,5$** — cela fait rejeter le pas de Newton complet et détruit la convergence quadratique.
4. **Utiliser $\|\nabla f(x)\|_2$ comme critère d'arrêt de Newton** — le bon critère est $\lambda^2/2 \leq \varepsilon$, **invariant** par changement d'échelle.
5. **Croire la convergence de Newton quadratique dès la première itération** — il y a d'abord une **phase amortie**, dont la longueur dépend de $f(x^{(0)}) - p^*$.
6. **Ignorer le conditionnement dans le choix de la méthode** — le gradient est proportionnellement ralenti par κ , Newton n'y est pas sensible.
7. **Comparer les méthodes au nombre d'itérations seul** — une itération de Newton coûte $O(n^3)$ contre $O(n)$ pour un gradient.
8. **Confondre convergence linéaire et convergence quadratique** — linéaire : l'erreur est **multipliée** par c ; quadratique : elle est **élevée au carré**.

Ultimate Review

1. Problème : **min** f , f convexe C^2 ; condition $\nabla f(x^*) = 0$; résolution **itérative**, sous-niveau initial **fermé**.
2. **Forte convexité** $\nabla^2 f \succeq mI$: minoration (9.8), borne $p^* \geq f(x) - \frac{1}{2m} \|\nabla f\|_2^2$, unicité de x^* .
3. Critère d'arrêt : $\|\nabla f(x)\|_2 \leq (2m\varepsilon)^{1/2} \Rightarrow f(x) - p^* \leq \varepsilon$.
4. Borne supérieure $\nabla^2 f \preceq MI$; **conditionnement** $\kappa = M/m$.
5. **Méthode de descente** : direction avec $\nabla f^T \Delta x < 0$, recherche linéaire, mise à jour.
6. **Recherche rétrograde** : $t := 1$; tant que $f(x + t\Delta x) > f(x) + \alpha t \nabla f^T \Delta x$, $t := \beta t$. $\alpha \in (0; 0,5)$, $\beta \in (0; 1)$.
7. **Gradient** : $\Delta x = -\nabla f(x)$; convergence **linéaire** $f(x^{(k)}) - p^* \leq c^k (f(x^{(0)}) - p^*)$, $c = 1 - 1/\kappa$; ralentie proportionnellement à κ .
8. **Descente la plus raide** : dépend de la **norme** choisie ; norme quadratique $\rightarrow -P^{-1} \nabla f$; norme 1 $\rightarrow$ descente par coordonnée.
9. **Newton** : $\Delta x_{nt} = -\nabla^2 f(x)^{-1} \nabla f(x)$; trois interprétations (modèle quadratique, norme hessienne, condition linéarisée).
10. **Décrément** $\lambda(x) = (\nabla f^T \nabla^2 f^{-1} \nabla f)^{1/2}$; $\lambda^2/2$ estime $f(x) - p^*$; critère d'arrêt.
11. **Deux phases** : amortie (baisse $\geq \gamma$ par itération), puis **quadratique** ($t = 1$, l'erreur est mise au carré). Total $\approx (f(x^{(0)}) - p^*)/\gamma + 6$.
12. **Invariance affine** de Newton — d'où son insensibilité au conditionnement, et un critère d'arrêt sans unité.

Formulas to know

$$p^* \geq f(x) - \frac{1}{2m} \|\nabla f(x)\|_2^2 \quad c = 1 - \frac{m}{M} \quad \Delta x_{\text{nt}} = -\nabla^2 f(x)^{-1} \nabla f(x)$$

$$\lambda(x)^2 = \nabla f(x)^T \nabla^2 f(x)^{-1} \nabla f(x) \quad \frac{f(x^{(0)}) - p^*}{\gamma} + \log_2 \log_2(\varepsilon_0/\varepsilon)$$

Methods to know : le protocole en 8 étapes ; la recherche rétrograde ; l'analyse de convergence du gradient ; les deux phases de Newton.

Active Recall

Basic — Écrivez l'algorithme de recherche linéaire rétrograde et expliquez le rôle de α et β .

$t := 1$; tant que $f(x + t\Delta x) > f(x) + \alpha t \nabla f(x)^T \Delta x$, faire $t := \beta t$. $\alpha \in (0; 0,5)$ fixe l'exigence de décroissance : on demande au moins une fraction α de ce que prédit la linéarisation. $\beta \in (0; 1)$ fixe la vitesse de réduction du pas. $\alpha < 0,5$ garantit que le pas complet de Newton est accepté sur une quadratique.

Understanding — Pourquoi la descente de gradient ralentit-elle quand $\kappa = M/m$ est grand ?

Le facteur de contraction vaut $c = 1 - m/M = 1 - 1/\kappa$: plus κ est grand, plus c est proche de 1, et le nombre d'itérations $\log((f(x^{(0)}) - p^*)/\varepsilon) / \log(1/c)$ croît **proportionnellement à κ** . Géométriquement, les sous-niveaux sont des ellipsoïdes très allongés ; $-\nabla f$ est perpendiculaire aux lignes de niveau, donc pointe vers le **flanc** de la vallée et non vers son fond : la trajectoire zigzague.

Application — Que vaut le décrément de Newton pour une fonction quadratique $\frac{1}{2}x^T P x + q^T x$, et que dit-il ?

$\nabla f = Px + q$, $\nabla^2 f = P$, donc $\lambda(x)^2 = (Px + q)^T P^{-1} (Px + q)$. Et

$$\frac{1}{2} \lambda(x)^2 = \frac{1}{2} (Px + q)^T P^{-1} (Px + q) = f(x) - p^*$$

exactement : pour une quadratique, l'estimation $\lambda^2/2$ de la sous-optimalité est **exacte**, puisque le modèle quadratique est la fonction elle-même.

Comparison — Gradient et Newton : direction, coût, vitesse, sensibilité au conditionnement.

	Gradient	Newton
Direction	$-\nabla f(x)$	$-\nabla^2 f(x)^{-1} \nabla f(x)$
Coût par itération	$O(n)$ après le gradient	$O(n^3)$ (hessienne + Cholesky)
Vitesse	linéaire, facteur $1 - 1/\kappa$	deux phases, puis quadratique
Conditionnement	vitesse $\propto \kappa$	insensible (invariance affine)

Verdict : Newton fait beaucoup moins d'itérations, beaucoup plus chères. Il s'impose dès que κ est grand ou que n reste modéré.

Exam-style — Décrivez les deux phases de la convergence de Newton et donnez la borne totale sur le nombre d'itérations.

Phase amortie, tant que $\|\nabla f(x^{(k)})\|_2 \geq \eta$: le pas est réduit par la recherche linéaire, mais l'objectif baisse d'au moins une constante γ à chaque itération. Elle dure donc au plus $(f(x^{(0)}) - p^*)/\gamma$ itérations.

Phase quadratiquement convergente, dès que $\|\nabla f(x^{(k)})\|_2 < \eta$: la recherche linéaire accepte $t = 1$, on n'en sort plus, et $\frac{L}{2m^2} \|\nabla f(x^{(k+1)})\|_2 \leq \left(\frac{L}{2m^2} \|\nabla f(x^{(k)})\|_2\right)^2$ — l'erreur est mise au carré, le nombre de décimales exactes **double** à chaque pas.

Borne totale : $\frac{f(x^{(0)}) - p^*}{\gamma} + \log_2 \log_2(\varepsilon_0/\varepsilon)$, le second terme valant en pratique **cinq ou six**.

Flashcards

Question	Réponse
Condition d'optimalité sans contrainte ?	$\nabla f(x^*) = 0$ — n équations à n inconnues
Condition sur le point de départ ?	$x^{(0)} \in \text{dom } f$ et sous-niveau initial fermé
Forte convexité ?	$\nabla^2 f(x) \succeq mI$ sur S , $m > 0$
Borne de sous-optimalité ?	$p^* \geq f(x) - \frac{1}{2m} \ \nabla f(x)\ _2^2$
Critère d'arrêt du gradient ?	$\ \nabla f(x)\ _2 \leq (2m\varepsilon)^{1/2}$
Conditionnement ?	$\kappa = M/m$, rapport des bornes sur la hessienne
Direction de descente ?	$\nabla f(x)^T \Delta x < 0$
Recherche rétrograde ?	$t := 1$; tant que $f(x + t\Delta x) > f(x) + \alpha t \nabla f^T \Delta x$, $t := \beta t$
Domaines de α et β ?	$\alpha \in (0; 0,5)$, $\beta \in (0; 1)$
Vitesse du gradient ?	Linéaire : $f(x^{(k)}) - p^* \leq c^k (f(x^{(0)}) - p^*)$, $c = 1 - 1/\kappa$
Pas de Newton ?	$\Delta x_{\text{nt}} = -\nabla^2 f(x)^{-1} \nabla f(x)$
Trois interprétations du pas de Newton ?	Minimiseur du modèle quadratique ; plus forte pente en norme hessienne ; condition d'optimalité linéarisée
Décrément de Newton ?	$\lambda(x) = (\nabla f^T \nabla^2 f^{-1} \nabla f)^{1/2}$; $\lambda^2/2 \approx f(x) - p^*$
Critère d'arrêt de Newton ?	$\lambda^2/2 \leq \varepsilon$
Les deux phases ?	Amortie (baisse $\geq \gamma$), puis quadratique ($t = 1$, erreur au carré)
Borne totale d'itérations ?	$(f(x^{(0)}) - p^*)/\gamma + \log_2 \log_2(\varepsilon_0/\varepsilon)$, soit +6 en pratique
Propriété clé de Newton ?	Invariance affine — insensible au conditionnement
Newton sur une quadratique ?	Une seule itération, depuis n'importe quel point