

Fiche 42 — Sous-gradients et sous-différentiel

Matière	Maths · Optimisation
Cours source	Boyd, Duchi, Pilanci & Vandenberghe, <i>Subgradients</i> — notes pour EE364b, Stanford, printemps 2021-22
Difficulté	Must know — la porte d'entrée de tout l'optimisation non lisse
Temps d'étude estimé	1 h 45
Prérequis	Fiche 35 (condition du premier ordre, épigraphe), fiche 34 (hyperplan d'appui)
Concepts clés	Sous-gradient, sous-différentiel, existence, condition d'optimalité $0 \in \partial f(x^*)$, dérivée directionnelle, calcul faible et fort, maximum ponctuel, minimisation partielle
Poids à l'examen	Deux compétences : calculer un sous-différentiel (valeur absolue, norme 1, maximum, $\lambda_{\max}$) et énoncer la condition d'optimalité $0 \in \partial f(x^*)$, avec sa version contrainte.

Vue d'ensemble

Toutes les méthodes vues jusqu'ici supposent **f dérivable**. Or les objectifs les plus utiles ne le sont pas : $\|x\|_1$ (parcimonie), $\max_i (a_i^T x + b_i)$ (pire cas), $\lambda_{\max}(A(x))$ (spectral), la perte charnière (classification). Le **sous-gradient** étend le gradient à ces fonctions, sans rien perdre de l'essentiel.

GRADIENT $\nabla f(x) \rightarrow$ UNE tangente, sous la courbe
SOUS-GRADIENT $g \rightarrow$ UNE des tangentes possibles, toutes sous la courbe
SOUS-DIFFÉRENTIEL $\partial f(x) =$ l'ENSEMBLE de ces $g \rightarrow$ convexe, fermé
OPTIMALITÉ $\nabla f(x^*) = \emptyset$ devient $0 \in \partial f(x^*)$

Le prix à payer : $\partial f(x)$ est un **ensemble**, pas un vecteur, et $-g$ n'est plus nécessairement une direction de descente. C'est ce qui rendra les algorithmes du chapitre suivant (fiche 43) fondamentalement plus lents.

● Concept 1 — Définition et interprétations

Définition. Un vecteur $g \in \mathbb{R}^n$ est un **sous-gradient** de $f : \mathbb{R}^n \rightarrow \mathbb{R}$ en $x \in \text{dom } f$ si, pour tout $z \in \text{dom } f$:

$$f(z) \geq f(x) + g^T(z - x) \quad (1)$$

Trois lectures.

1. **Minorant affine global** : la fonction affine $z \mapsto f(x) + g^T(z - x)$ minore **f partout**, avec égalité en x .
2. **Hyperplan d'appui** : g est un sous-gradient en x si et seulement si $(g, -1)$ définit un hyperplan d'appui à **epi f** au point $(x, f(x))$ — exactement la lecture géométrique de la fiche 35, mais sans exiger la différentiabilité.
3. **Généralisation du gradient** : si f est convexe et dérivable, $\nabla f(x)$ **est** un sous-gradient (c'est la condition du premier ordre).

Sous-différentiel. L'ensemble des sous-gradients de f en x :

$$\partial f(x) = \{g \mid f(z) \geq f(x) + g^T(z - x) \quad \forall z \in \text{dom } f\}$$

f est **sous-différentiable** en x si $\partial f(x) \neq \emptyset$.

Exemple fondateur — la valeur absolue. Pour $f(z) = |z|$:

$$\partial f(x) = \begin{cases} \{-1\} & x < 0 \\ [-1, 1] & x = 0 \\ \{1\} & x > 0 \end{cases}$$

En $x = 0$, la condition $|z| \geq gz$ pour tout z équivaut à $g \in [-1, 1]$. **Le sous-différentiel est un intervalle : toutes les pentes des droites passant sous la courbe.**

● Concept 2 — Propriétés de base

$\partial f(x)$ est toujours un ensemble convexe fermé, même si f n'est pas convexe. En effet, c'est une intersection de demi-espaces :

$$\partial f(x) = \bigcap_{z \in \text{dom } f} \{g \mid f(z) \geq f(x) + g^T(z - x)\}$$

— chacune de ces conditions étant linéaire en g (fiche 34).

Bornitude. Si f est continue en x , alors $\partial f(x)$ est borné. *Preuve par l'absurde* : si $\partial f(x)$ était non borné, il existerait $g_n \in \partial f(x)$ avec $\|g_n\|_2 \rightarrow \infty$; en prenant $y_n = x + \epsilon g_n / \|g_n\|_2$,

$$f(y_n) \geq f(x) + g_n^T(y_n - x) = f(x) + \epsilon \|g_n\|_2 \rightarrow \infty$$

ce qui contredit la bornitude de f au voisinage de x .

Existence (§2.1). Si f est **convexe** et $x \in \text{int dom } f$, alors $\partial f(x)$ est **non vide et borné**.

Démonstration. On applique le **théorème de l'hyperplan d'appui** (fiche 34) à l'ensemble convexe **epi** f au point du bord $(x, f(x))$: il existe $(a, b) \neq 0$ tel que

$$a^T(z - x) + b(t - f(x)) \leq 0 \quad \forall (z, t) \in \text{epi } f$$

Cela impose $b \leq 0$. Si $b \neq 0$, on divise par $|b|$ et l'on obtient $f(z) \geq f(x) - (a/b)^T(z - x)$, c'est-à-dire $-a/b \in \partial f(x)$. Reste à exclure $b = 0$: on aurait alors $a^T(z - x) \leq 0$ pour tout $z \in \text{dom } f$, ce qui est **impossible** si x est **intérieur** au domaine. ■

Le mot clé est « non vertical ». Une fonction convexe admet un sous-gradient en x dès qu'il existe un hyperplan d'appui **non vertical** à son épigraphe en $(x, f(x))$. Aux points du bord du domaine, l'hyperplan d'appui peut être vertical, et le sous-différentiel vide.

Cas dérivable (§2.2). Si f est convexe et **dérivable** en x , alors $\partial f(x) = \{\nabla f(x)\}$: le gradient est **l'unique** sous-gradient. **Réciproquement**, si f est convexe et $\partial f(x) = \{g\}$ est un singleton, alors f est dérivable en x et $g = \nabla f(x)$.

L'équivalence est totale : « dérivable » = « sous-différentiel réduit à un point ». C'est la meilleure façon de retenir le lien entre les deux notions.

● Concept 3 — La condition d'optimalité

Sans contrainte (§2.3). Un point x^* minimise f (convexe ou non !) **si et seulement si** f est sous-différentiable en x^* et

$$0 \in \partial f(x^*)$$

Démonstration, immédiate dans les deux sens. Si x^* est un minimiseur, $f(x) \geq f(x^*) = f(x^*) + 0^T(x - x^*)$ pour tout x : le vecteur nul vérifie la définition (1). Réciproquement, si $0 \in \partial f(x^*)$, la même inégalité donne $f(x) \geq f(x^*)$ pour tout x . ■

Cette caractérisation vaut pour des fonctions **non convexes**, mais elle n'y est pas utile : on ne sait généralement pas calculer le sous-différentiel d'une fonction non convexe. Et pour f convexe **dérivable**, elle se réduit à $\nabla f(x^*) = 0$.

Avec contraintes (§2.5). Pour minimiser f sur un **convexe fermé** X , x^* est optimal **si et seulement si il existe** un sous-gradient $g \in \partial f(x^*)$ tel que

$$g^T(y - x^*) \geq 0 \quad \forall y \in X$$

Comparez avec la fiche 36. Le critère différentiable était $\nabla f_0(x^*)^T(y - x^*) \geq 0$ pour tout y admissible. Ici, il ne suffit **pas** que l'inégalité vaille pour un g quelconque : il faut qu'**il existe** un sous-gradient qui la satisfasse. La quantification change, et c'est essentiel.

Le sens facile : si un tel g existe, alors pour $x \in X$, $f(x) \geq f(x^*) + g^T(x - x^*) \geq f(x^*)$. *Le sens difficile* passe par la dérivée directionnelle et un échange min-max, licite parce que $\partial f(x^*)$ est **borné**.

● Concept 4 — Dérivée directionnelle (§2.4)

Pour f convexe, la **dérivée directionnelle** en x dans la direction v est

$$f'(x; v) = \lim_{t \downarrow 0} \frac{f(x + tv) - f(x)}{t}$$

Cette limite existe toujours pour f convexe (éventuellement $\pm\infty$), car le rapport est **croissant en t** . La preuve tient en une ligne de convexité : pour $0 < t_1 \leq t_2$,

$$f(x + t_1 v) = f\left(\frac{t_1}{t_2}(x + t_2 v) + \left(1 - \frac{t_1}{t_2}\right)x\right) \leq \frac{t_1}{t_2} f(x + t_2 v) + \left(1 - \frac{t_1}{t_2}\right) f(x)$$

d'où, après réarrangement, $\frac{f(x + t_1 v) - f(x)}{t_1} \leq \frac{f(x + t_2 v) - f(x)}{t_2}$.

Le lien avec le sous-différentiel :

$$f'(x; v) = \sup_{g \in \partial f(x)} g^T v$$

La dérivée directionnelle est la **fonction d'appui** du sous-différentiel (fiche 35, exemple 3.7).

Conséquence. v est une direction de descente si et seulement si $f'(x; v) < 0$, c'est-à-dire si **tous** les sous-gradients font un angle obtus avec v . Il ne suffit **pas** qu'un seul le fasse — d'où le fait, capital pour la fiche 43, que $-g$ n'est pas nécessairement une direction de descente.

● Concept 5 — Le calcul des sous-gradients (§3)

Les notes distinguent **deux niveaux**, et cette distinction est structurante :

Calcul	But	Usage
faible	produire un sous-gradient, même s'il en existe d'autres	suffit en pratique : les méthodes de sous-gradient, de localisation et de plans sécants n'en demandent qu' un
fort	décrire tout l'ensemble $\partial f(x)$	théorie, conditions d'optimalité précises

Les règles.

Opération	Règle (calcul fort)
Multiplication positive	$\partial(\alpha f)(x) = \alpha \partial f(x), \alpha \geq 0$
Somme	$\partial(f_1 + \dots + f_m)(x) = \partial f_1(x) + \dots + \partial f_m(x)$ (somme d'ensembles)
Composition affine	$h(x) = f(Ax + b) \Rightarrow \partial h(x) = A^T \partial f(Ax + b)$
Maximum ponctuel	$\partial f(x) = \text{Co} \bigcup \{ \partial f_i(x) \mid f_i(x) = f(x) \}$
Supremum (index compact, s.c.s.)	$\partial f(x) = \text{Co} \bigcup \{ \partial f_\alpha(x) \mid f_\alpha(x) = f(x) \}$
Minimisation partielle	$\partial f(x) = \{ g \mid (g, 0) \in \partial F(x, y) \text{ pour un } y \in Y_x \}$

La règle du maximum, en version faible — celle qu'on utilise. Soit $f = \max_i f_i$. Choisir **un** indice k **actif** ($f_k(x) = f(x)$) et **un** sous-gradient $g \in \partial f_k(x)$: alors $g \in \partial f(x)$. La preuve tient en une ligne :

$$f(z) \geq f_k(z) \geq f_k(x) + g^T(z - x) = f(x) + g^T(z - x)$$

En pratique, on ne calcule jamais tout le sous-différentiel. On identifie une fonction active, on prend son gradient, et c'est terminé. Le calcul **fort** (enveloppe convexe des actifs) ne sert qu'à écrire des conditions d'optimalité exactes.

Exemple 1 — la norme 1

$$f(x) = \|x\|_1 = \max\{s^T x \mid s \in \{-1, 1\}^n\}$$

C'est un maximum de 2^n fonctions **linéaires**. Pour obtenir un sous-gradient, on identifie un s **actif** :

$$g_i = \begin{cases} +1 & x_i > 0 \\ -1 & x_i < 0 \\ +1 \text{ ou } -1 & x_i = 0 \end{cases}$$

Et le sous-différentiel complet est

$$\partial\|x\|_1 = \{g \mid \|g\|_\infty \leq 1, g^T x = \|x\|_1\}$$

C'est la formule qui fonde le LASSO. La condition d'optimalité $0 \in \partial(\frac{1}{2}\|Ax - b\|_2^2 + \lambda\|x\|_1)$ s'écrit $A^T(b - Ax) \in \lambda \partial\|x\|_1$, c'est-à-dire $|(A^T(b - Ax))_i| \leq \lambda$ avec **égalité et signe imposé** dès que $x_i \neq 0$. C'est cette « marge » sur les coordonnées nulles qui produit la **parcimonie**.

Exemple 2 — la plus grande valeur propre

Soit $f(x) = \lambda_{\max}(A(x))$ avec $A(x) = A_0 + x_1 A_1 + \dots + x_n A_n$, $A_i \in \mathbf{S}^m$. On l'écrit en supremum (fiche 35) :

$$f(x) = \sup_{\|y\|_2=1} y^T A(x) y$$

Chaque $f_y(x) = y^T A(x) y$ est **affine en x** :

$$y^T A(x) y = y^T A_0 y + x_1 y^T A_1 y + \dots + x_n y^T A_n y$$

donc dérivable, de gradient $(y^T A_1 y, \dots, y^T A_n y)$. Les fonctions **actives** sont celles associées aux **vecteurs propres de la plus grande valeur propre**. D'où la recette :

Pour obtenir un sous-gradient de $\lambda_{\max}(A(x))$: calculer un vecteur propre unitaire y associé à $\lambda_{\max}(A(x))$, et prendre

$$g = (y^T A_1 y, y^T A_2 y, \dots, y^T A_n y)$$

L'ensemble d'indices $\{y \mid \|y\|_2 = 1\}$ étant **compact**, le sous-différentiel complet est l'enveloppe convexe des g obtenus sur tous les vecteurs propres dominants.

Comment résoudre l'exercice type (protocole)

1. **Repérer la non-différentiabilité** : valeur absolue, **max**, norme 1 ou infinie, valeur propre.
2. **Écrire f comme un maximum ou un supremum** de fonctions plus simples — c'est presque toujours possible.
3. **Identifier les fonctions actives** au point considéré.
4. **Calcul faible** (le cas usuel) : prendre **une** active, calculer son gradient, c'est un sous-gradient.

5. **Calcul fort** (si l'énoncé le demande) : enveloppe convexe des sous-différentiels actifs.
6. **Composer** si nécessaire : somme (somme d'ensembles), composition affine ($A^T \partial f$), multiplication positive.
7. **Pour l'optimalité** : écrire $0 \in \partial f(x^*)$, ou la version contrainte $\exists g \in \partial f(x^*), g^T(y - x^*) \geq 0$ sur X .

Exercices progressifs

Niveau 1 — Calculez $\partial f(0)$ pour $f(x) = \max\{x, -2x\}$ sur $\mathbb{R}$.

Les deux fonctions $f_1(x) = x$ et $f_2(x) = -2x$ sont **actives** en 0 (elles y valent toutes deux 0), de gradients 1 et -2 . Par la règle du maximum,

$$\partial f(0) = \text{Co}\{1, -2\} = [-2, 1]$$

Contrôle : $0 \in [-2, 1]$, donc $x = 0$ est bien le minimiseur — ce qui est évident puisque $f \geq 0$ avec égalité en 0 .

Niveau 2 — Donnez un sous-gradient de $f(x) = \|Ax - b\|_1$ en un point x .

Composition affine : avec $h(u) = \|u\|_1$ et $u = Ax - b$, la règle donne

$$\partial f(x) = A^T \partial h(Ax - b)$$

Un sous-gradient explicite : poser $s_i = \text{sign}((Ax - b)_i)$ (n'importe quelle valeur de $[-1, 1]$ si la composante est nulle), puis

$$g = A^T s$$

Cas particulier utile : si aucune composante du résidu n'est nulle, f est **dérivable** en x et g est le gradient.

Niveau 3 — Montrez que si f est convexe et $\partial f(x)$ est réduit à un point, alors f est dérivable en x .

C'est le sens réciproque du §2.2. L'argument passe par la dérivée directionnelle : pour f convexe,

$$f'(x; v) = \sup_{g \in \partial f(x)} g^T v$$

Si $\partial f(x) = \{g_0\}$, alors $f'(x; v) = g_0^T v$ pour **toute** direction v : la dérivée directionnelle est **linéaire** en v . En particulier $f'(x; v) = -f'(x; -v)$, ce qui signifie que les dérivées à droite et à gauche coïncident dans chaque direction. Une fonction convexe dont la dérivée directionnelle est linéaire est **différentiable**, de gradient g_0 . ■

La lecture à retenir : un sous-différentiel « épais » mesure exactement l'écart à la différentiabilité, et sa **taille** est la largeur de l'angle formé par le graphe au point anguleux.

Niveau 4 — type examen — Écrivez la condition d'optimalité du LASSO $\min_x \frac{1}{2} \|Ax - b\|_2^2 + \lambda \|x\|_1$ et expliquez d'où vient la parcimonie.

Étape 1 — somme. Par la règle de la somme, avec le premier terme **dérivable** :

$$\partial f(x) = \{A^T(Ax - b)\} + \lambda \partial \|x\|_1$$

Étape 2 — condition d'optimalité. $0 \in \partial f(x^*)$ équivaut à

$$A^T(b - Ax^*) \in \lambda \partial \|x^*\|_1$$

Étape 3 — expliciter, coordonnée par coordonnée. En notant $c = A^T(b - Ax^*)$ le **résidu corrélé** et en utilisant $\partial \|x\|_1$ de l'exemple 1 :

$$\begin{cases} c_i = \lambda \text{sign}(x_i^*) & \text{si } x_i^* \neq 0 \\ |c_i| \leq \lambda & \text{si } x_i^* = 0 \end{cases}$$

Étape 4 — d'où vient la parcimonie. Sur les coordonnées **non nulles**, la condition est une **égalité** : elle détermine x_i^* . Sur les coordonnées **nulles**, c'est une **inégalité large** : il y a une **marge** de manœuvre de largeur 2λ . Une coordonnée peut donc rester exactement à zéro sur tout un intervalle de valeurs de c_i — et c'est **stable** : une petite perturbation des données ne la fait pas bouger.

Comparaison avec la régularisation en norme 2. Avec $\lambda \|x\|_2^2$, le terme est dérivable et la condition devient $A^T(b - Ax^*) = 2\lambda x^*$: une **égalité partout**, qui ne s'annule que pour une valeur exacte de c_i — événement de mesure nulle. Aucune coordonnée n'est jamais **exactement** nulle.

La morale : la parcimonie du LASSO ne vient pas d'une astuce numérique mais de la **géométrie du sous-différentiel** de $\|\cdot\|_1$, qui est un ensemble **épais** $[-1, 1]$ précisément là où la coordonnée s'annule.

● Common mistakes

1. **Traiter $\partial f(x)$ comme un vecteur** — c'est un **ensemble** ; on écrit $g \in \partial f(x)$, jamais $g = \partial f(x)$.
2. **Croire que $-g$ est une direction de descente** — c'est faux dès que f n'est pas dérivable en x ; il faut $f'(x; v) < 0$, c'est-à-dire que **tous** les sous-gradients s'opposent à v .
3. **Se tromper de quantificateur dans la condition contrainte** — il faut qu'il **existe** $g \in \partial f(x^*)$ avec $g^T(y - x^*) \geq 0$, pas que **tout** g le vérifie.
4. **Oublier que le sous-différentiel peut être vide** — au bord du domaine, l'hyperplan d'appui peut être **vertical**.
5. **Calculer le sous-différentiel complet quand un seul sous-gradient suffit** — le calcul **faible** est bien plus rapide et suffit à tous les algorithmes.
6. **Prendre une fonction non active dans la règle du maximum** — seules les f_i **atteignant** le maximum au point considéré comptent.
7. **Oublier l'enveloppe convexe** dans la version forte de la règle du maximum — l'union des sous-différentiels actifs n'est pas convexe en général.
8. **Confondre sous-gradient et gradient d'une approximation lisse** — le sous-gradient est exact ; le lissage (fiche 35, log-sum-exp) est une autre stratégie.

Ultimate Review

1. **Sous-gradient** : $f(z) \geq f(x) + g^T(z - x)$ pour tout z — un **minorant affine global**, exact en x .
2. **Géométrie** : $(g, -1)$ définit un hyperplan d'appui **non vertical** à **epi** f en $(x, f(x))$.
3. **Sous-différentiel $\partial f(x)$** : toujours **convexe fermé** (intersection de demi-espaces) ; **borné** si f est continue en x .
4. **Existence** : f convexe et $x \in \text{int dom } f \Rightarrow \partial f(x)$ non vide et borné (par le théorème d'appui).
5. f dérivable en $x \iff \partial f(x)$ est un **singleton**, et alors $\partial f(x) = \{\nabla f(x)\}$.
6. **Optimalité** : $0 \in \partial f(x^*)$; version contrainte sur X convexe : **il existe** $g \in \partial f(x^*)$ avec $g^T(y - x^*) \geq 0$ sur X .
7. **Dérivée directionnelle** : existe toujours pour f convexe (rapport croissant en t) et vaut $f'(x; v) = \sup_{g \in \partial f(x)} g^T v$.
8. **Calcul** : somme (somme d'ensembles), composition affine ($A^T \partial f$), multiplication positive, **maximum** (enveloppe convexe des actifs), minimisation partielle.
9. **Calcul faible contre fort** : un seul sous-gradient suffit aux algorithmes ; l'ensemble complet sert à la théorie.

10. $\partial\|x\|_1 = \{g \mid \|g\|_\infty \leq 1, g^T x = \|x\|_1\}$; sous-gradient de $\lambda_{\max}(A(x))$: $g_i = y^T A_i y$ pour y vecteur propre dominant unitaire.

Formulas to know

$$f(z) \geq f(x) + g^T(z - x) \quad 0 \in \partial f(x^*) \quad f'(x; v) = \sup_{g \in \partial f(x)} g^T v$$

$$\partial(f_1 + f_2) = \partial f_1 + \partial f_2 \quad \partial(f(Ax + b)) = A^T \partial f(Ax + b) \quad \partial \max_i f_i(x) = \text{Co} \bigcup_{i \text{ actif}} \partial f_i(x)$$

Methods to know : le protocole en 7 étapes ; la règle faible du maximum ; le calcul de $\partial\|x\|_1$ et du sous-gradient de $\lambda_{\max}$.

Active Recall

Basic — Définissez un sous-gradient et donnez son interprétation géométrique.

g est un sous-gradient de f en x si $f(z) \geq f(x) + g^T(z - x)$ pour tout $z \in \text{dom } f$: la fonction affine associée est un **minorant global** de f , exact en x . Géométriquement, $(g, -1)$ définit un **hyperplan d'appui** à l'épigraphe de f au point $(x, f(x))$.

Understanding — Pourquoi $\partial f(x)$ est-il toujours convexe et fermé ?

Parce que c'est une **intersection de demi-espaces** :

$$\partial f(x) = \bigcap_{z \in \text{dom } f} \{g \mid g^T(z - x) \leq f(z) - f(x)\}$$

Chaque condition est une inégalité **linéaire en g** , donc définit un demi-espace fermé ; une intersection quelconque de convexes fermés est convexe fermée (fiche 34). Ce raisonnement ne suppose **pas** f convexe.

Application — Donnez $\partial f(x)$ pour $f(x) = \|x\|_1$ en $x = (2, 0, -1)$.

Coordonnée par coordonnée : $x_1 = 2 > 0$ impose $g_1 = 1$; $x_3 = -1 < 0$ impose $g_3 = -1$; $x_2 = 0$ laisse g_2 libre dans $[-1, 1]$. Donc

$$\partial f(x) = \{1\} \times [-1, 1] \times \{-1\}$$

On vérifie la formule générale : $\|g\|_\infty \leq 1$ et $g^T x = 2 + 0 + 1 = 3 = \|x\|_1$.

Comparison — Condition d'optimalité sans contrainte et avec contrainte : quelle différence essentielle ?

Sans contrainte : $0 \in \partial f(x^*)$ — le vecteur nul doit **appartenir** au sous-différentiel. *Sur un convexe fermé X* : **il existe** $g \in \partial f(x^*)$ tel que $g^T(y - x^*) \geq 0$ pour tout $y \in X$.

La différence essentielle est le **quantificateur existentiel** : il suffit qu'un sous-gradient « pointe vers l'extérieur » de X . Sans contrainte, $X = \mathbb{R}^n$ et la condition force $g = 0$, donc $0 \in \partial f(x^*)$ — on retrouve le premier cas.

Exam-style — Comment obtient-on un sous-gradient de $f(x) = \max_i (a_i^T x + b_i)$, et quel est le sous-différentiel complet ?

Calcul faible. Identifier un indice **actif** k , c'est-à-dire tel que $a_k^T x + b_k = f(x)$, et prendre $g = a_k$. En effet

$$f(z) \geq a_k^T z + b_k = a_k^T x + b_k + a_k^T (z - x) = f(x) + g^T (z - x)$$

Calcul fort. $\partial f(x) = \text{Co}\{a_i \mid a_i^T x + b_i = f(x)\}$ — l'enveloppe convexe des a_i **actifs**. Là où un seul indice est actif, f est **dérivable** de gradient a_k ; là où plusieurs le sont, $\partial f(x)$ est un **polyèdre**.

Flashcards

Question	Réponse
Sous-gradient ?	g tel que $f(z) \geq f(x) + g^T(z - x)$ pour tout z
Interprétation géométrique ?	$(g, -1)$ définit un hyperplan d'appui à epi f en $(x, f(x))$
Sous-différentiel ?	$\partial f(x)$, l' ensemble des sous-gradients
Nature de $\partial f(x)$?	Convexe fermé — intersection de demi-espaces
Quand est-il non vide et borné ?	f convexe et $x \in \text{int dom } f$
$\partial f(x)$ singleton signifie ?	f est dérivable en x , et $\partial f(x) = \{\nabla f(x)\}$
$\partial x $ en 0 ?	$[-1, 1]$
Condition d'optimalité ?	$0 \in \partial f(x^*)$
Version contrainte sur X ?	Il existe $g \in \partial f(x^*)$ avec $g^T(y - x^*) \geq 0$ sur X
Dérivée directionnelle ?	$f'(x; v) = \sup_{g \in \partial f(x)} g^T v$
Règle de la somme ?	$\partial(f_1 + f_2) = \partial f_1 + \partial f_2$ (somme d'ensembles)
Règle affine ?	$\partial f(Ax + b) \rightarrow A^T \partial f(Ax + b)$
Règle du maximum (faible) ?	Prendre un sous-gradient d'une fonction active
Règle du maximum (forte) ?	Enveloppe convexe des sous-différentiels actifs
$\partial\ x\ _1$?	$\{g \mid \ g\ _\infty \leq 1, g^T x = \ x\ _1\}$
Sous-gradient de $\lambda_{\max}(A(x))$?	$g_i = y^T A_i y$, y vecteur propre dominant unitaire
$-g$ est-il une direction de descente ?	Pas nécessairement — c'est la difficulté centrale du non lisse