

Fiche 44 — Programmation dynamique : le problème de base et le principe d'optimalité

Matière	Maths · Optimisation
Cours source	Bertsekas, 6.231 <i>Dynamic Programming</i> , MIT OpenCourseWare, automne 2015 — cours 1 et 2
Difficulté	Must know — la porte d'entrée de toute la décision séquentielle
Temps d'étude estimé	2 h
Prérequis	Probabilités introductives, espérance conditionnelle ; fiche 36 (forme standard d'un problème d'optimisation)
Concepts clés	Système dynamique discret, état, commande, aléa, politique, coût additif, principe d'optimalité, algorithme DP, rétropropagation, boucle ouverte contre boucle fermée, augmentation d'état
Poids à l'examen	Deux gestes : écrire la récurrence de Bellman pour un problème donné, et la dérouler à rebours sur un petit exemple. C'est aussi le socle mathématique de la macroéconomie dynamique et des modèles de décision intertemporelle.

Vue d'ensemble

Jusqu'ici, on optimisait **un vecteur x** , une fois pour toutes. La programmation dynamique optimise **une suite de décisions**, prises l'une après l'autre, en tenant compte de l'information qui arrive **entre** les décisions.

SYSTÈME	$x_{k+1} = f_k(x_k, u_k, w_k)$	état, commande, aléa
COÛT	$E[g_N(x_N) + \sum_k g_k(x_k, u_k, w_k)]$	additif dans le temps
DÉCIDER	non pas une suite de nombres $u_0, \dots, u_{N-1}$ mais une suite de RÈGLES $u_k = \mu_k(x_k)$ ← une POLITIQUE	

L'idée qui rend tout calculable tient en une phrase : *l'optimisation du futur ne dépend pas de ce qu'on a fait dans le passé*. C'est le **principe d'optimalité**, et il transforme un problème d'optimisation sur des fonctions en une **récurrence à rebours**.

● Concept 1 — La programmation dynamique comme méthodologie

Le problème d'optimisation générique du cours :

$$\min_{u \in \mathcal{U}} g(u)$$

où u est la variable de décision, g le coût, $\mathcal{U}$ l'ensemble de contraintes. Les catégories habituelles :

- **discret** ($\mathcal{U}$ fini) ou **continu** ;
- **linéaire** (g linéaire, $\mathcal{U}$ polyédral) ou non linéaire ;
- **stochastique** ou déterministe — dans le cas stochastique, le coût fait intervenir un paramètre aléatoire w que l'on moyenne : $g(u) = \mathbb{E}_w[G(u, w)]$.

CE QUE LA DP APORTE DE SPÉCIFIQUE.

Elle sait traiter des problèmes stochastiques complexes où l'information sur w devient disponible **par étapes**, et où les décisions sont elles aussi prises **par étapes** en utilisant cette information. C'est exactement ce qu'aucun des chapitres précédents ne savait faire : là, on décidait tout d'un coup, avant de rien observer.

● Concept 2 — La structure de base

Système en temps discret.

$$x_{k+1} = f_k(x_k, u_k, w_k), \quad k = 0, 1, \dots, N-1$$

Symbole	Nom	Rôle
k	temps discret	l'étape
x_k	état	<i>résume l'information passée pertinente pour l'optimisation future</i>
u_k	commande	la décision, choisie dans un ensemble donné
w_k	aléa	perturbation ou bruit selon le contexte
N	horizon	nombre de fois où l'on applique une commande

Coût additif dans le temps.

$$\mathbb{E} \left[g_N(x_N) + \sum_{k=0}^{N-1} g_k(x_k, u_k, w_k) \right]$$

La définition de l'état est la seule chose vraiment difficile. *L'état résume l'information passée pertinente pour l'optimisation future* : ni plus (on gonflerait inutilement le problème), ni moins (la récurrence serait fausse). Tout le travail de modélisation en DP consiste à trouver le bon état.

Description alternative. Au lieu de f_k et de la loi de w_k , on peut se donner directement la **loi de transition** $P(x_{k+1} \mid x_k, u_k)$: il suffit de poser $x_{k+1} = w_k$ avec $P(w_k \mid x_k, u_k) = P(x_{k+1} \mid x_k, u_k)$. C'est la formulation « chaîne de Markov contrôlée », celle qu'on rencontre en économie.

Les deux hypothèses qui font marcher la DP

1. L'ensemble des valeurs que peut prendre u_k dépend **au plus de x_k** , et non des x ou u antérieurs.
2. La loi de w_k **ne dépend pas** des valeurs passées $w_{k-1}, \dots, w_0$; elle peut dépendre de x_k et u_k .

Sinon, les valeurs passées de w ou de x seraient utiles pour l'optimisation future — c'est-à-dire que x_k ne serait pas un état. Les deux hypothèses ne sont donc pas des restrictions techniques : elles **définissent** ce qu'est un état.

La chronologie d'une période k , à avoir en tête :

x_k apparaît, $x_k = f_{k-1}(x_{k-1}, u_{k-1}, w_{k-1}) \longrightarrow u_k$ choisi en CONNAISSANT $x_k \longrightarrow w_k$ tiré selon $P_{w_k}(\cdot \mid x_k, u_k)$

L'ordre compte : on choisit u_k **après** avoir observé x_k mais **avant** de connaître w_k . C'est ce décalage qui crée toute la difficulté — et toute la valeur de l'information.

Exemple fil rouge : la gestion de stock

$$x_{k+1} = f_k(x_k, u_k, w_k) = x_k + u_k - w_k$$

avec x_k le stock en début de période, u_k la quantité commandée, w_k la **demande** de la période. Le coût :

$$\mathbb{E} \left[g_N(x_N) + \sum_{k=0}^{N-1} (c u_k + r(x_k + u_k - w_k)) \right]$$

où c est le coût unitaire d'achat et $r(\cdot)$ le coût de stockage ou de rupture sur le stock final de période.

● Concept 3 — Politiques et problème de base

Politique. $\pi = \{\mu_0, \dots, \mu_{N-1}\}$, où chaque μ_k associe à un état x_k une commande $u_k = \mu_k(x_k)$, avec $\mu_k(x_k) \in U_k(x_k)$ pour tout x_k .

On n'optimise pas sur des nombres, on optimise sur des FONCTIONS. C'est la différence fondamentale avec tout ce qui précède. Une politique est une *règle* qui dit quoi faire dans chaque situation possible — pas un plan d'action figé.

Coût espéré d'une politique partant de x_0 :

$$J_\pi(x_0) = \mathbb{E} \left[g_N(x_N) + \sum_{k=0}^{N-1} g_k(x_k, \mu_k(x_k), w_k) \right]$$

Fonction de coût optimal et politique optimale :

$$J^*(x_0) = \min_{\pi} J_\pi(x_0), \quad \pi^* \text{ optimale si } J_{\pi^*}(x_0) = J^*(x_0)$$

Un fait remarquable, souligné par Bertsekas. Lorsqu'elle est produite par la DP, la politique optimale π^* est **indépendante de x_0** : la même règle est optimale quel que soit le point de départ. On ne calcule pas une trajectoire, on calcule une **stratégie universelle**.

● Concept 4 — Boucle ouverte contre boucle fermée

Boucle ouverte : on fixe la suite $u_0, \dots, u_{N-1}$ à l'avance, sans jamais regarder l'état. **Boucle fermée** (*feedback*) : $u_k = \mu_k(x_k)$, la décision s'adapte à ce qu'on observe.

Dans les problèmes déterministes, la boucle ouverte vaut la boucle fermée. Comme il n'y a pas d'aléa, l'état futur est parfaitement prévisible : observer ne apprend rien. **Dès qu'il y a de l'aléa, la boucle fermée est strictement meilleure** — c'est la *valeur de l'information*.

L'exemple du match d'échecs

Deux parties. Le joueur a deux styles :

Style	Résultat
prudent	nulle avec probabilité $p_d > 0$, défaite avec probabilité $1 - p_d$
audacieux	victoire avec probabilité $p_w < 1/2$, défaite avec probabilité $1 - p_w$

- **Politique en boucle ouverte** : jouer toujours audacieux.
- **Politique en boucle fermée** : *jouer prudent si et seulement si l'on mène.*

L'arbre de la politique en boucle fermée (slide 10 du cours). On n'est pas devant, donc **audacieux** en première partie :

- **victoire** (prob. p_w) → score **1-0**, on mène → **prudent** :
 - nulle (prob. p_d) → **1,5-0,5** : **match gagné** ;
 - défaite (prob. $1 - p_d$) → **1-1** : égalité ;
- **défaite** (prob. $1 - p_w$) → **0-1**, on est mené → **audacieux** :
 - victoire (prob. p_w) → **1-1** : égalité ;
 - défaite (prob. $1 - p_w$) → **0-2** : **match perdu**.

AJOUT — LE CALCUL, SOUS UNE HYPOTHÈSE EXPLICITE.

Le cours ne chiffre pas l'exemple. Si l'on suppose qu'une égalité **1-1** se départage par une partie de mort subite jouée en audacieux (gagnée avec probabilité p_w), on obtient

$$\mathbb{P}(\text{match gagné}) = \underbrace{p_w p_d}_{\text{gagné en deux parties}} + \underbrace{(p_w(1 - p_d) + (1 - p_w)p_w)}_{\mathbb{P}(1-1)} \cdot p_w = p_w p_d + p_w^2(2 - p_d - p_w)$$

Avec $p_w = 0,45$ et $p_d = 0,9$: $\approx 0,405 + 0,2025 \times 0,65 \approx 0,54$ — **le joueur est favori**, alors qu'il perd chaque partie plus souvent qu'il ne la gagne. Cette hypothèse de départage n'est **pas** dans les transparents : c'est une convention que j'ajoute pour rendre le calcul possible.

Ce que l'exemple enseigne. Adapter son style à la position **crée** un avantage à partir de deux styles individuellement défavorables. C'est la valeur de l'information, et c'est exactement pourquoi on optimise sur des **politiques** et non sur des suites.

● Concept 5 — Le principe d'optimalité

Soit $\pi^* = \{\mu_0^*, \dots, \mu_{N-1}^*\}$ une politique optimale. Considérons le **sous-problème de queue** : on est en x_i à l'instant i et l'on veut minimiser le **coût-à-venir** de i à N :

$$\mathbb{E} \left[g_N(x_N) + \sum_{k=i}^{N-1} g_k(x_k, \mu_k(x_k), w_k) \right]$$

et la **politique de queue** $\{\mu_i^*, \mu_{i+1}^*, \dots, \mu_{N-1}^*\}$.

Principe d'optimalité. *La politique de queue est optimale pour le sous-problème de queue.*
Autrement dit : **l'optimisation du futur ne dépend pas de ce qu'on a fait dans le passé.**

Ce que la DP en fait. Elle résout **d'abord tous** les sous-problèmes de queue de la **dernière** étape ; puis, à l'étape générique, elle résout **tous** les sous-problèmes de queue d'une longueur donnée, **en utilisant** la solution des sous-problèmes de queue plus courts.

Le principe d'optimalité ne dit pas que le passé est sans importance : il dit que **tout ce qui compte du passé est résumé dans l'état courant x_i** . Si ce n'est pas le cas, c'est que l'état est mal choisi — voir l'augmentation d'état (concept 8).

● Concept 6 — L'algorithme de programmation dynamique

Initialisation — le coût terminal :

$$J_N(x_N) = g_N(x_N)$$

Récurrence à rebours, pour $k = N - 1, N - 2, \dots, 0$:

$$J_k(x_k) = \min_{u_k \in U_k(x_k)} \mathbb{E}_{w_k} \left[g_k(x_k, u_k, w_k) + J_{k+1}(f_k(x_k, u_k, w_k)) \right]$$

Alors $J_0(x_0)$, produit au dernier pas, **est égal** au coût optimal $J^*(x_0)$. Et la politique $\pi^* = \{\mu_0^*, \dots, \mu_{N-1}^*\}$ où $\mu_k^*(x_k)$ **atteint le minimum** du membre de droite, pour chaque x_k et chaque k , est **optimale**.

Justification. Récurrence sur k : on montre que $J_k(x_k)$ est égal au coût optimal $J_k^*(x_k)$ du sous-problème de queue démarrant à l'instant k dans l'état x_k .

La preuve du pas de récurrence (celle du cours). En supposant $J_{k+1} = J_{k+1}^*$:

$$\begin{aligned}
 J_k^*(x_k) &= \min_{(\mu_k, \pi^{k+1})} \mathbb{E}_{w_k, \dots, w_{N-1}} \left[g_k(x_k, \mu_k(x_k), w_k) + g_N(x_N) + \sum_{i=k+1}^{N-1} g_i(x_i, \mu_i(x_i), w_i) \right] \\
 &= \min_{\mu_k} \mathbb{E}_{w_k} \left[g_k(x_k, \mu_k(x_k), w_k) + \min_{\pi^{k+1}} \mathbb{E} \left[g_N(x_N) + \sum_{i=k+1}^{N-1} g_i(x_i, \mu_i(x_i), w_i) \right] \right] \\
 &= \min_{\mu_k} \mathbb{E}_{w_k} \left[g_k(x_k, \mu_k(x_k), w_k) + J_{k+1}(f_k(x_k, \mu_k(x_k), w_k)) \right] \\
 &= \min_{u_k \in U_k(x_k)} \mathbb{E}_{w_k} \left[g_k(x_k, u_k, w_k) + J_{k+1}(f_k(x_k, u_k, w_k)) \right] = J_k(x_k)
 \end{aligned}$$

La deuxième ligne est le cœur de la preuve : on **sépare** le minimum sur μ_k de celui sur la politique de queue π^{k+1} . C'est licite précisément parce que le sous-problème de queue ne dépend du passé qu'à travers x_{k+1} — c'est le principe d'optimalité en action. **La dernière ligne** remplace la minimisation sur une **fonction** μ_k par une minimisation sur un **vecteur** u_k , état par état : c'est ce qui rend le calcul possible.

Les deux remarques du cours, à retenir.

- **Tous** les sous-problèmes de queue sont résolus, en plus du problème d'origine — on obtient bien plus qu'une trajectoire.
- **Les besoins de calcul sont intensifs** : il faut balayer tout l'espace d'états à chaque étape. C'est la fameuse « malédiction de la dimension », et c'est ce qui motivera les méthodes approchées.

Exemple : ordonnancement déterministe

Trouver l'ordre optimal des opérations A, B, C, D, sachant que **A précède B** et **C précède D**, avec des coûts de démarrage S_A, S_C et des coûts de transition C_{mn} de l'opération m à l'opération n .

La méthode. On part du **dernier** sous-problème de queue et l'on remonte. **À chaque couple état-instant, on enregistre le coût-à-venir optimal et la décision optimale.** L'état est ici la suite des opérations déjà effectuées — et le graphe des états se referme : **AC** et **CA** mènent au même état, ce qui est précisément l'économie que réalise la DP par rapport à l'énumération des **4!** ordres.

Exemple : gestion de stock stochastique

Sous-problèmes de queue de longueur 1 :

$$J_{N-1}(x_{N-1}) = \min_{u_{N-1} \geq 0} \mathbb{E}_{w_{N-1}} \left[c u_{N-1} + r(x_{N-1} + u_{N-1} - w_{N-1}) \right]$$

Sous-problèmes de queue de longueur $N - k$:

$$J_k(x_k) = \min_{u_k \geq 0} \mathbb{E}_{w_k} \left[c u_k + r(x_k + u_k - w_k) + J_{k+1}(x_k + u_k - w_k) \right]$$

et $J_0(x_0)$ est le coût optimal depuis l'état initial x_0 .

● Concept 7 — L'exemple linéaire-quadratique

Deux fours en série. Une pièce de température initiale x_0 traverse le four 1 puis le four 2 ; on veut atteindre une température cible T en dépensant peu d'énergie.

Système : $x_{k+1} = (1 - a)x_k + a u_k$ pour $k = 0, 1$, avec $a \in]0, 1[$ donné. **Coût** : $r(x_2 - T)^2 + u_0^2 + u_1^2$, avec $r > 0$ donné.

Algorithme DP.

$$J_2(x_2) = r(x_2 - T)^2$$

$$J_1(x_1) = \min_{u_1} \left[u_1^2 + r((1 - a)x_1 + a u_1 - T)^2 \right]$$

$$J_0(x_0) = \min_{u_0} \left[u_0^2 + J_1((1 - a)x_0 + a u_0) \right]$$

POURQUOI CE CAS EST CENTRAL.

Chaque minimisation est celle d'une **quadratique convexe en u_k** : elle se résout **analytiquement**, et le résultat J_1 est encore une quadratique en x_1 . La forme quadratique se **propage** à rebours. C'est le seul cadre continu où la DP se mène entièrement à la main — d'où son omniprésence en contrôle et en macroéconomie.

● Concept 8 — Augmentation d'état

Quand les hypothèses du problème de base sont violées — perturbations **corrélées**, coût **non additif**, retards — on **reformule en augmentant l'état**. L'algorithme DP s'applique toujours, mais **le problème grossit**.

Exemple : les retards. Si le système s'écrit

$$x_{k+1} = f_k(x_k, x_{k-1}, u_k, w_k)$$

alors x_k **n'est pas** un état : le passé lointain influence encore le futur. On introduit la variable supplémentaire $y_k = x_{k-1}$, et le nouveau système devient

$$\begin{pmatrix} x_{k+1} \\ y_{k+1} \end{pmatrix} = \begin{pmatrix} f_k(x_k, y_k, u_k, w_k) \\ x_k \end{pmatrix}$$

On considère $\tilde{x}_k = (x_k, y_k)$ comme le **nouvel état**, et la récurrence devient

$$J_k(x_k, x_{k-1}) = \min_{u_k \in U_k(x_k)} \mathbb{E}_{w_k} \left[g_k(x_k, u_k, w_k) + J_{k+1}(f_k(x_k, x_{k-1}, u_k, w_k), x_k) \right]$$

L'augmentation d'état n'est pas gratuite. Chaque variable ajoutée multiplie la taille de l'espace d'états, donc le coût de la récurrence. C'est le compromis permanent de la DP : un état plus riche rend le problème correct, mais plus cher.

Comment résoudre l'exercice type (protocole)

1. **Identifier l'horizon N** et le découpage temporel.
2. **Choisir l'état x_k** — la question décisive : quelle information passée est **pertinente pour le futur** ? Si un élément du passé influence encore le futur, il doit entrer dans l'état.
3. **Identifier la commande u_k** et son ensemble de contraintes $U_k(x_k)$.
4. **Identifier l'aléa w_k** et sa loi conditionnelle $P(w_k \mid x_k, u_k)$ — vérifier qu'elle ne dépend pas du passé.
5. **Écrire la dynamique $x_{k+1} = f_k(x_k, u_k, w_k)$** et le **coût par étape g_k** , plus le coût terminal g_N .
6. **Vérifier l'additivité** du coût ; sinon, augmenter l'état.
7. **Poser $J_N = g_N$** et dérouler la récurrence **à rebours**, en enregistrant à chaque couple état-instant le **coût-à-venir** et la **décision optimale**.
8. **Lire la politique** : $\mu_k^*(x_k)$ est l'argmin à l'étape k . Conclure sur $J_0(x_0)$.

Exercices progressifs

Niveau 1 — Dans le problème de gestion de stock, quel est l'état ? Pourquoi la demande passée n'en fait-elle pas partie ?

L'état est le **stock disponible x_k** . La demande passée $w_{k-1}, w_{k-2}, \dots$ n'en fait pas partie parce que, sous l'hypothèse que les w_k sont indépendants, elle n'apporte **aucune information sur la**

demande future — et son effet sur le futur est déjà **entièrement résumé** par le stock courant.

Attention à la réciproque : si les demandes étaient **corrélées** (par exemple w_k dépendant de w_{k-1}), l'hypothèse 2 tomberait, et il faudrait **augmenter l'état** en (x_k, w_{k-1}) .

Niveau 2 — Pourquoi la boucle fermée n'apporte-t-elle rien dans un problème déterministe ?

Sans aléa, la trajectoire $x_1, x_2, \dots$ est **entièrement déterminée** par x_0 et la suite $u_0, u_1, \dots$: on peut la calculer d'avance. Observer x_k en cours de route **n'apprend donc rien** qu'on ne sût déjà. Toute politique en boucle fermée $\{\mu_k\}$ engendre depuis x_0 une suite de commandes que l'on peut reproduire à l'identique en boucle ouverte, et réciproquement : les deux classes atteignent **le même coût optimal**.

La conséquence pratique : en déterministe, la DP reste utile comme **méthode de calcul** (elle décompose le problème), pas comme façon d'exploiter l'information.

Niveau 3 — Résolvez le problème des deux fours pour $a = 1/2$, $r = 1$, $T = 0$.

Avec $a = 1/2$: $x_{k+1} = \frac{1}{2}x_k + \frac{1}{2}u_k$, et le coût est $x_2^2 + u_0^2 + u_1^2$.

Étape 1 — J_2 . $J_2(x_2) = x_2^2$.

Étape 2 — J_1 .

$$J_1(x_1) = \min_{u_1} \left[u_1^2 + \left(\frac{1}{2}x_1 + \frac{1}{2}u_1 \right)^2 \right]$$

On dérive : $2u_1 + 2 \cdot \frac{1}{2} \left(\frac{1}{2}x_1 + \frac{1}{2}u_1 \right) = 0$, soit $2u_1 + \frac{1}{2}u_1 = -\frac{1}{2}x_1$, d'où

$$\mu_1^*(x_1) = -\frac{x_1}{5}$$

En reportant : $x_2 = \frac{1}{2}x_1 - \frac{1}{10}x_1 = \frac{2}{5}x_1$, et

$$J_1(x_1) = \frac{x_1^2}{25} + \frac{4x_1^2}{25} = \frac{x_1^2}{5}$$

Étape 3 — J_0 .

$$J_0(x_0) = \min_{u_0} \left[u_0^2 + \frac{1}{5} \left(\frac{1}{2}x_0 + \frac{1}{2}u_0 \right)^2 \right]$$

Dérivée : $2u_0 + \frac{1}{5} \cdot \frac{1}{2} \left(\frac{1}{2}x_0 + \frac{1}{2}u_0 \right) \cdot 2 = 0$, soit $2u_0 + \frac{1}{10}u_0 = -\frac{1}{10}x_0$, d'où

$$\mu_0^*(x_0) = -\frac{x_0}{21}, \quad J_0(x_0) = \frac{x_0^2}{21}$$

Ce qu'on observe. La politique optimale est **linéaire en l'état** ($\mu_k^*(x_k) = L_k x_k$) et le coût optimal **quadratique** ($J_k(x_k) = K_k x_k^2$) : la structure se propage à rebours. C'est le résultat général du cas linéaire-quadratique.

Niveau 4 — type examen — Un consommateur dispose d'une richesse x_0 et vit N périodes. À chaque période il consomme $u_k \in [0, x_k]$, en tire l'utilité $\log u_k$, et le reste croît au taux $R > 0$: $x_{k+1} = R(x_k - u_k)$. Il maximise $\sum_{k=0}^{N-1} \beta^k \log u_k$ avec $\beta \in]0, 1[$. Écrivez la récurrence de Bellman et résolvez pour $N = 2$.

Mise en forme. On maximise, donc on écrit la récurrence en **max** (ou l'on minimise $-\sum \beta^k \log u_k$). Avec un coût terminal nul, $J_2(x_2) = 0$ et

$$J_k(x_k) = \max_{0 \leq u_k \leq x_k} \left[\beta^k \log u_k + J_{k+1}(R(x_k - u_k)) \right]$$

Étape 1 — dernière période ($k = 1$). Comme $J_2 \equiv 0$, on maximise $\beta \log u_1$ sur $[0, x_1]$: la fonction est croissante, donc

$$\mu_1^*(x_1) = x_1, \quad J_1(x_1) = \beta \log x_1$$

On consomme tout à la dernière période — il n'y a plus de futur à financer.

Étape 2 — première période ($k = 0$).

$$J_0(x_0) = \max_{0 \leq u_0 \leq x_0} \left[\log u_0 + \beta \log (R(x_0 - u_0)) \right]$$

La dérivée en u_0 vaut $\frac{1}{u_0} - \frac{\beta}{x_0 - u_0}$, nulle pour $x_0 - u_0 = \beta u_0$, soit

$$\mu_0^*(x_0) = \frac{x_0}{1 + \beta}$$

et

$$J_0(x_0) = \log \frac{x_0}{1 + \beta} + \beta \log \frac{\beta R x_0}{1 + \beta} = (1 + \beta) \log x_0 + \text{const}$$

Lecture économique. La politique optimale est de consommer une **fraction fixe de la richesse** : $\frac{1}{1+\beta}$ à la première période, puis tout. La fraction ne dépend **pas** du niveau de richesse — propriété caractéristique de l'utilité logarithmique. Et l'on retrouve la structure du cas linéaire-quadratique : la forme fonctionnelle de J (ici $a \log x + b$) se **propage** à rebours.

Ce que l'exercice enseigne. C'est le modèle de consommation intertemporelle de la macroéconomie, écrit exactement dans le formalisme de Bertsekas : état = richesse, commande = consommation, dynamique = accumulation du capital, coût = utilité actualisée. Le passage à $N = \infty$ donnera l'équation de Bellman stationnaire.

● Common mistakes

1. **Choisir un état trop pauvre** — si un élément du passé influence encore le futur, la récurrence est **fausse**. Il faut augmenter l'état.
2. **Choisir un état trop riche** — chaque variable ajoutée multiplie le coût de calcul ; l'état doit contenir **exactement** l'information pertinente.
3. **Optimiser sur des suites au lieu de politiques** — en stochastique, une suite $u_0, \dots, u_{N-1}$ fixée d'avance est strictement moins bonne qu'une règle $\mu_k(x_k)$.
4. **Dérouler la récurrence dans le sens du temps** — la DP va **à rebours** : on part du coût terminal.
5. **Oublier l'espérance** — le minimum porte sur u_k , l'espérance sur w_k , et **dans cet ordre** : $\min_u \mathbb{E}_w$, jamais $\mathbb{E}_w \min_u$ (qui supposerait de connaître w_k avant de décider).
6. **Croire que l'ordre $\min / \mathbb{E}$ est indifférent** — $\mathbb{E}_w \min_u \leq \min_u \mathbb{E}_w$: l'inversion donne la valeur d'un devin, pas celle d'un décideur.
7. **Oublier de mémoriser la décision optimale** — la récurrence sur J_k donne le **coût** ; c'est l'argmin qui donne la **politique**, et c'est elle qu'on veut.
8. **Croire que la DP ne donne qu'une trajectoire** — elle résout **tous** les sous-problèmes de queue, donc donne la politique pour **tout** état et **tout** instant.

Ultimate Review

1. Système $x_{k+1} = f_k(x_k, u_k, w_k)$; coût **additif** $\mathbb{E}[g_N(x_N) + \sum_k g_k(x_k, u_k, w_k)]$.
2. **L'état résume l'information passée pertinente pour l'optimisation future** — c'est la définition, et le seul vrai travail de modélisation.
3. Deux hypothèses : U_k dépend au plus de x_k ; la loi de w_k ne dépend pas du passé de w .
4. Chronologie : x_k observé $\rightarrow u_k$ choisi $\rightarrow w_k$ tiré.

5. **Politique** $\pi = \{\mu_0, \dots, \mu_{N-1}\}$: on optimise sur des **fonctions**, pas sur des nombres. La politique optimale produite par la DP est **indépendante de x_0** .
6. **Boucle ouverte** = **boucle fermée en déterministe** ; en stochastique la boucle fermée est strictement meilleure — c'est la **valeur de l'information**.
7. **Principe d'optimalité** : la politique de queue est optimale pour le sous-problème de queue ; l'optimisation du futur ne dépend pas du passé.
8. **Algorithme DP** : $J_N = g_N$, puis à rebours $J_k(x_k) = \min_{u_k} \mathbb{E}_{w_k} [g_k + J_{k+1}(f_k)]$; $J_0(x_0) = J^*(x_0)$, et l'argmin donne μ_k^* .
9. Preuve par récurrence : on **sépare** le min sur μ_k du min sur la politique de queue.
10. **Linéaire-quadratique** : chaque minimisation est analytique et la forme quadratique se **propage** à rebours.
11. **Augmentation d'état** pour les retards, les aléas corrélés, les coûts non additifs — au prix d'un espace d'états plus grand.

Formulas to know

$$x_{k+1} = f_k(x_k, u_k, w_k) \quad J_\pi(x_0) = \mathbb{E} \left[g_N(x_N) + \sum_{k=0}^{N-1} g_k(x_k, \mu_k(x_k), w_k) \right]$$

$$J_N(x_N) = g_N(x_N) \quad J_k(x_k) = \min_{u_k \in U_k(x_k)} \mathbb{E}_{w_k} \left[g_k(x_k, u_k, w_k) + J_{k+1}(f_k(x_k, u_k, w_k)) \right]$$

Methods to know : le protocole de modélisation en 8 étapes ; la récurrence à rebours ; la preuve du pas de récurrence ; l'augmentation d'état.

Active Recall

Basic — Écrivez l'algorithme de programmation dynamique et dites ce que produit chacune de ses sorties.

$J_N(x_N) = g_N(x_N)$, puis pour $k = N - 1, \dots, 0$:

$$J_k(x_k) = \min_{u_k \in U_k(x_k)} \mathbb{E}_{w_k} \left[g_k(x_k, u_k, w_k) + J_{k+1}(f_k(x_k, u_k, w_k)) \right]$$

$J_0(x_0)$ est le **coût optimal** $J^*(x_0)$; l'**argmin** à chaque étape donne $\mu_k^*(x_k)$, c'est-à-dire la **politique optimale**.

Understanding — Énoncez le principe d'optimalité et expliquez où il intervient dans la preuve de l'algorithme.

Énoncé. Si π^* est optimale, alors sa **politique de queue** $\{\mu_i^*, \dots, \mu_{N-1}^*\}$ est optimale pour le **sous-problème de queue** démarrant en x_i à l'instant i — l'optimisation du futur ne dépend pas du passé.

Où il intervient. Dans la deuxième ligne de la preuve du pas de récurrence, quand on **sépare** $\min_{(\mu_k, \pi^{k+1})}$ en $\min_{\mu_k}$ puis $\min_{\pi^{k+1}}$. Cette séparation n'est licite que parce que le sous-problème de queue ne dépend du passé qu'à travers x_{k+1} .

Application — Dans quel ordre écrit-on le minimum et l'espérance, et pourquoi ?

$\min_{u_k} \mathbb{E}_{w_k}[\dots]$ — **le minimum d'abord, l'espérance ensuite**. C'est la chronologie : on choisit u_k en connaissant x_k mais **avant** de connaître w_k , donc on ne peut optimiser que la **moyenne** sur w_k .

L'ordre inverse $\mathbb{E}_{w_k} \min_{u_k}$ correspondrait à choisir u_k **après** avoir vu w_k : c'est la valeur d'un devin. On a toujours $\mathbb{E} \min \leq \min \mathbb{E}$, et l'écart est précisément la valeur de l'information future.

Comparison — Boucle ouverte et boucle fermée : quand différent-elles, et de combien ?

Elles **coïncident** en déterministe : sans aléa, la trajectoire est prévisible et observer n'apprend rien. Elles **diffèrent** dès qu'il y a de l'aléa, et l'écart est la **valeur de l'information**.

L'exemple du match d'échecs le montre de façon spectaculaire : avec deux styles individuellement défavorables ($p_w < 1/2$), la politique « prudent si et seulement si l'on mène » rend le joueur favori, ce qu'aucune politique en boucle ouverte n'obtient.

Exam-style — Une entreprise doit décider chaque mois de sa production, avec une demande aléatoire corrélée d'un mois sur l'autre. Le stock suffit-il comme état ?

Non. L'hypothèse 2 du problème de base exige que la loi de w_k ne dépende pas de $w_{k-1}, \dots, w_0$. Si les demandes sont **corrélées**, la demande passée porte de l'information sur la demande future : elle est donc « pertinente pour l'optimisation future » et doit entrer dans l'état.

La parade : augmenter l'état. On prend $\tilde{x}_k = (x_k, w_{k-1})$, ou plus généralement l'état de la chaîne qui engendre la demande. La récurrence DP s'applique alors sans changement — mais l'espace d'états est **multiplié** par le nombre de valeurs possibles de w_{k-1} , ce qui alourdit d'autant le calcul.

Flashcards

Question	Réponse
Système de la DP ?	$x_{k+1} = f_k(x_k, u_k, w_k)$
Qu'est-ce que l'état ?	Ce qui résume l'information passée pertinente pour le futur
Structure du coût ?	Additif : $\mathbb{E}[g_N(x_N) + \sum_k g_k(x_k, u_k, w_k)]$
Les deux hypothèses du problème de base ?	U_k dépend au plus de x_k ; la loi de w_k ne dépend pas du passé de w
Chronologie d'une période ?	x_k observé, puis u_k choisi, puis w_k tiré
Qu'est-ce qu'une politique ?	$\pi = \{\mu_0, \dots, \mu_{N-1}\}$, des règles $u_k = \mu_k(x_k)$
Boucle ouverte contre fermée ?	Équivalentes en déterministe ; la fermée est meilleure en stochastique
Principe d'optimalité ?	La politique de queue est optimale pour le sous-problème de queue
Initialisation de la DP ?	$J_N(x_N) = g_N(x_N)$
Récurrance de la DP ?	$J_k(x_k) = \min_{u_k} \mathbb{E}_{w_k}[g_k + J_{k+1}(f_k)]$
Dans quel sens déroule-t-on ?	À rebours , de N vers 0
Ordre du min et de l'espérance ?	$\min_u \mathbb{E}_w$ — on décide avant de connaître l'aléa
Que donne l'argmin ?	La politique optimale $\mu_k^*(x_k)$
La politique optimale dépend-elle de x_0 ?	Non , quand elle est produite par la DP
Cas linéaire-quadratique ?	Minimisations analytiques ; la forme quadratique se propage à rebours
Quand augmente-t-on l'état ?	Retards, aléas corrélés, coût non additif
Prix de l'augmentation d'état ?	L'espace d'états grossit, donc le calcul aussi