

Fiche 47 — Arrêt optimal, ordonnancement et contrôle minimax

Matière	Maths · Optimisation
Cours source	Bertsekas, <i>6.231 Dynamic Programming</i> , MIT OpenCourseWare, automne 2015 — cours 5
Difficulté	Fondamental — trois familles de problèmes à structure remarquable
Temps d'étude estimé	1 h 45
Prérequis	Fiche 44 (algorithme DP), fiche 46 (structure de la politique optimale)
Concepts clés	Problème d'arrêt, région d'arrêt et de continuation, vente d'actif, seuil décroissant, régions d'arrêt emboîtées, ordonnancement, argument d'échange, politique d'indice, contrôle minimax
Poids à l'examen	L' argument d'échange du problème du quiz est l'exercice type par excellence : court, astucieux, et généralisable. La structure à seuil des problèmes d'arrêt en est le pendant en continu.

Vue d'ensemble

Trois familles où la DP ne se contente pas de calculer : elle **révèle une structure**.

ARRÊT OPTIMAL	la politique est une PARTITION de l'espace d'états en région d'ARRÊT et région de CONTINUATION
ORDONNANCEMENT	parfois une POLITIQUE D'INDICE : un nombre par tâche, on trie
MINIMAX	l'aléa n'est plus moyenné mais ADVERSE : min-max au lieu de min-E

Dans chaque cas, on gagne beaucoup plus qu'un algorithme : on obtient une **forme** de solution — un seuil, un tri, une règle — qui se calcule en quelques opérations et s'interprète immédiatement.

● Concept 1 — Problèmes d'arrêt purs

Deux commandes seulement.

- **Arrêter** : encourir un coût d'arrêt **unique**, et passer dans un état d'arrêt **absorbant et sans coût** ;

- **Continuer** : évoluer selon $x_{k+1} = f_k(x_k, w_k)$ en encourageant le **coût par étape**.

La conséquence structurelle. *Chaque politique consiste en une partition de l'ensemble des états x_k en deux régions* : la **région d'arrêt**, où l'on s'arrête, et la **région de continuation**, où l'on continue. On ne cherche donc pas une fonction quelconque : on cherche une **frontière**.

C'est ce qui rend ces problèmes si maniables — et si présents en finance (exercice d'une option américaine), en recherche d'emploi, en essais cliniques séquentiels.

• Concept 2 — L'exemple de la vente d'un actif

Le problème. Une personne possède un actif. Aux instants $k = 0, 1, \dots, N - 1$ elle reçoit une **offre aléatoire** w_k . Elle peut :

- **accepter** w_k et placer l'argent à un taux d'intérêt fixe r ;
- **refuser** w_k et attendre w_{k+1} .

Elle **doit accepter la dernière offre** w_{N-1} .

Algorithme DP (x_k : l'offre courante, T : l'état d'arrêt) :

$$J_N(x_N) = \begin{cases} x_N & \text{si } x_N \neq T \\ 0 & \text{si } x_N = T \end{cases}$$

$$J_k(x_k) = \begin{cases} \max \{ (1+r)^{N-k} x_k, \mathbb{E}\{J_{k+1}(w_k)\} \} & \text{si } x_k \neq T \\ 0 & \text{si } x_k = T \end{cases}$$

Comment lire le maximum. Le premier terme $(1+r)^{N-k} x_k$ est ce que rapporte **accepter maintenant** et placer jusqu'à N ; le second $\mathbb{E}\{J_{k+1}(w_k)\}$ est la valeur espérée de **refuser** et de jouer de façon optimale ensuite.

La politique optimale est à seuil.

$$\text{accepter } x_k \text{ si } x_k > \alpha_k, \quad \text{refuser si } x_k < \alpha_k, \quad \text{où} \quad \alpha_k = \frac{\mathbb{E}\{J_{k+1}(w_k)\}}{(1+r)^{N-k}}$$

Le seuil décroît avec le temps

Résultat. $\alpha_k \geq \alpha_{k+1}$ pour tout k : on devient de moins en moins exigeant à mesure qu'on s'approche de la fin.

Preuve (celle du cours). Posons, pour $x_k \neq T$,

$$V_k(x_k) = \frac{J_k(x_k)}{(1+r)^{N-k}}$$

la valeur **actualisée à l'instant k** . L'algorithme DP devient alors

$$V_N(x_N) = x_N, \quad V_k(x_k) = \max \left\{ x_k, \frac{1}{1+r} \mathbb{E}_w \{ V_{k+1}(w) \} \right\}$$

et l'on a $\alpha_k = \mathbb{E}_w \{ V_{k+1}(w) \} / (1+r)$. Il suffit donc de montrer que $V_k(x) \geq V_{k+1}(x)$ pour tous x et k . On part de $V_{N-1}(x) \geq V_N(x)$ — immédiat, puisque V_{N-1} est un maximum dont x est l'un des termes — puis on utilise la **propriété de monotonie de la DP** : si deux fonctions de coût-à-venir sont ordonnées à l'étape $k+1$, leurs images par l'opérateur de Bellman le restent à l'étape k . Q.E.D.

Le renversement de perspective. Le changement de variable $V_k = J_k / (1+r)^{N-k}$ élimine le facteur d'actualisation qui dépendait du temps, et transforme une récurrence à coefficients variables en une récurrence **stationnaire**. C'est exactement le geste qui prépare le passage à l'horizon infini.

Le comportement asymptotique. Si w est **bornée**, alors $\alpha_k \rightarrow \bar{\alpha}$ quand $k \rightarrow -\infty$. Cela **suggère qu'en horizon infini la politique optimale est stationnaire** — un seuil unique, indépendant du temps. C'est la porte d'entrée du chapitre sur l'horizon infini.

● Concept 3 — Problèmes d'arrêt généraux

Le cadre. À l'instant k , on peut **arrêter** au coût $t(x_k)$, ou **choisir une commande** $u_k \in U(x_k)$ et continuer :

$$J_N(x_N) = t(x_N)$$
$$J_k(x_k) = \min \left\{ \underbrace{t(x_k)}_{\text{arrêter}}, \underbrace{\min_{u_k \in U(x_k)} \mathbb{E} \{ g(x_k, u_k, w_k) + J_{k+1}(f(x_k, u_k, w_k)) \}}_{\text{continuer}} \right\}$$

La région d'arrêt à l'instant k . Il est optimal de s'arrêter en x si

$$T_k = \left\{ x \mid t(x) \leq \min_{u \in U(x)} \mathbb{E} \{ g(x, u, w) + J_{k+1}(f(x, u, w)) \} \right\}$$

Les régions d'arrêt sont emboîtées. Puisque $J_{N-1}(x) \leq J_N(x)$, la monotonie de la DP donne $J_k(x) \leq J_{k+1}(x)$ pour tout k , d'où

$$T_0 \subseteq T_1 \subseteq \dots \subseteq T_k \subseteq T_{k+1} \subseteq \dots \subseteq T_{N-1}$$

La lecture. Plus on s'approche de l'horizon, **plus la région d'arrêt s'agrandit** : il reste moins d'occasions futures, donc on s'arrête plus volontiers. C'est le même phénomène que le seuil décroissant α_k de la vente d'actif.

Le cas intéressant. Celui où toutes les régions T_k sont **égales** — à T_{N-1} , l'ensemble où il vaut mieux s'arrêter que de faire un pas puis s'arrêter. On peut montrer que c'est le cas si

$$f(x, u, w) \in T_{N-1} \quad \text{pour tout } x \in T_{N-1}, u \in U(x), w$$

La condition dit que T_{N-1} **est absorbante** : une fois dans la région d'arrêt, la dynamique ne peut plus en sortir. Alors la règle « s'arrêter dans T_{N-1} » est optimale **à tout instant**, et la politique devient **stationnaire** — un seul ensemble à calculer au lieu de N .

● Concept 4 — Problèmes d'ordonnancement

Le cadre. On dispose d'un ensemble de tâches à exécuter, l'ordre étant à choisir. **Les coûts dépendent de l'ordre.** Il peut y avoir de l'incertitude stochastique, ainsi que des contraintes de précédence et de disponibilité de ressources.

Certains des problèmes combinatoires les plus difficiles sont de ce type — voyageur de commerce, tournées de véhicules.

Mais certains problèmes particuliers admettent une méthode de résolution quasi analytique. Le cours en distingue deux.

Méthode	Principe	Exige
Politique d'indice	chaque tâche possède un « indice de coût » facile à calculer ; il est optimal de choisir celle d'indice minimal	— (problèmes de bandits manchots)
Argument d'échange	partir d'un ordonnancement, échanger deux tâches adjacentes et regarder ce qui se passe	l'existence d'une politique optimale en boucle ouverte

L'argument d'échange n'est pas universel : il exige qu'une politique optimale **en boucle ouverte** existe, c'est-à-dire que l'ordre puisse être fixé à l'avance sans rien observer (fiche 44). Si l'ordre optimal dépendait de ce qui se produit en cours de route, l'échange n'aurait pas de sens.

L'exemple du quiz

Le problème. Une liste de N questions. Si la question i reçoit une réponse correcte — ce qui arrive avec probabilité p_i — on reçoit la récompense R_i ; sinon **le quiz s'arrête**. Choisir l'ordre des questions pour maximiser la récompense espérée.

L'argument d'échange, en trois lignes. Soient i et j les k -ième et $(k+1)$ -ième questions d'une liste ordonnée de façon optimale :

$$L = (i_0, \dots, i_{k-1}, i, j, i_{k+2}, \dots, i_{N-1})$$

La récompense espérée se décompose en

$$\mathbb{E}\{\text{récompense de } L\} = \mathbb{E}\{\text{récompense de } (i_0, \dots, i_{k-1})\} + p_{i_0} \cdots p_{i_{k-1}} (p_i R_i + p_j R_j) + p_{i_0} \cdots p_{i_{k-1}} p_i p_j \mathbb{E}\{\text{récompense de } (i_{k+2}, \dots)\}$$

Considérons maintenant la liste L' où i et j sont **échangées**. Les premier et troisième termes sont **identiques** — le préfixe est le même, et le suffixe est atteint avec la même probabilité $p_i p_j$ dans les deux cas. Comme L est optimale, $\mathbb{E}\{L\} \geq \mathbb{E}\{L'\}$, ce qui se réduit à

$$p_i R_i + p_i p_j R_j \geq p_j R_j + p_j p_i R_i$$

soit, après réarrangement,

$$\boxed{\frac{p_i R_i}{1 - p_i} \geq \frac{p_j R_j}{1 - p_j}}$$

La règle d'ordonnement. Il faut poser les questions **par indice** $\frac{p_i R_i}{1 - p_i}$ **décroissant**. C'est une **politique d'indice** : on attribue un nombre à chaque tâche, on trie, et c'est fini — $N \log N$ opérations au lieu des $N!$ ordres possibles.

Comment lire l'indice. Le numérateur $p_i R_i$ est le **gain espéré** de la question. Le dénominateur $1 - p_i$ est la **probabilité d'interruption** : plus une question risque de tout arrêter, plus elle est pénalisée. On veut donc les questions **rentables** et **sûres** d'abord — et l'indice dose exactement l'arbitrage.

● Concept 5 — Contrôle minimax

Le cadre. On reprend le problème de base, à ceci près que la perturbation w_k , **au lieu d'être aléatoire, est seulement connue pour appartenir à un ensemble donné** $W_k(x_k, u_k)$.

Le coût à minimiser devient un **pire cas** :

$$J_\pi(x_0) = \max_{\substack{w_k \in W_k(x_k, \mu_k(x_k)) \\ k=0, \dots, N-1}} \left[g_N(x_N) + \sum_{k=0}^{N-1} g_k(x_k, \mu_k(x_k), w_k) \right]$$

L'algorithme DP prend la forme

$$J_N(x_N) = g_N(x_N)$$

$$J_k(x_k) = \min_{u_k \in U(x_k)} \max_{w_k \in W_k(x_k, u_k)} \left[g_k(x_k, u_k, w_k) + J_{k+1}(f_k(x_k, u_k, w_k)) \right]$$

La seule différence avec le cas stochastique : $\mathbb{E}_{w_k}$ **devient** $\max_{w_k}$. Toute la structure — récurrence à rebours, principe d'optimalité, politique en boucle fermée — est **inchangée**. La dérivation de l'algorithme est *similaire à celle du cas stochastique*.

L'ordre min puis max compte autant qu'en stochastique. On choisit u_k **avant** de connaître w_k , et la nature (ou l'adversaire) choisit ensuite le pire w_k **sachant** u_k . C'est la même asymétrie qu'à la fiche 44 — et c'est le lien direct avec l'optimisation robuste de la fiche 32, où l'on minimisait déjà un pire cas sur une famille de modèles.

Le minimax est pessimiste par construction. Il protège contre la pire réalisation, aussi improbable soit-elle. C'est adapté quand l'aléa est réellement adverse (jeux, sûreté) ou quand on ne connaît pas la loi de w_k ; c'est excessivement conservateur quand on la connaît et qu'on peut moyenner.

Comment résoudre l'exercice type (protocole)

1. **Reconnaître la famille** : deux commandes dont une absorbante $\rightarrow$ arrêt ; ordre de tâches $\rightarrow$ ordonnancement ; aléa dans un ensemble $\rightarrow$ minimax.
2. **Pour un problème d'arrêt** : écrire $J_k = \min\{\text{arrêter}, \text{continuer}\}$ et identifier la **région d'arrêt** T_k .
3. **Chercher la structure à seuil** : si l'état est scalaire et le terme « continuer » indépendant de x_k , la règle est « arrêter au-dessus (ou en dessous) d'un seuil ».
4. **Vérifier la monotonie** : $J_k \leq J_{k+1}$ donne $T_k \subseteq T_{k+1}$, donc des seuils monotones en temps.
5. **Tester l'absorption** : si $f(x, u, w) \in T_{N-1}$ pour tout $x \in T_{N-1}$, la politique est **stationnaire**.
6. **Pour un ordonnancement** : vérifier qu'une politique optimale **en boucle ouverte** existe, puis appliquer l'**argument d'échange** sur deux tâches adjacentes.
7. **Lire l'indice** obtenu et trier les tâches selon lui.
8. **Pour un minimax** : remplacer $\mathbb{E}_{w_k}$ par $\max_{w_k \in W_k}$ et dérouler la même récurrence.

Exercices progressifs

Niveau 1 — Dans la vente d'actif, pourquoi le seuil α_k décroît-il avec k ?

Parce que $\alpha_k = \mathbb{E}_w\{V_{k+1}(w)\}/(1+r)$ et que $V_k(x) \geq V_{k+1}(x)$ pour tout x : la valeur actualisée d'une offre donnée **décroît** quand on s'approche de l'horizon, puisqu'il reste moins d'occasions futures de faire mieux.

Interprétation. En début de période on peut se permettre d'être exigeant : il reste beaucoup d'offres à venir. Près de la fin, l'option d'attendre ne vaut presque plus rien, et l'on accepte des offres qu'on aurait refusées plus tôt. À la dernière étape, on accepte **tout**.

Niveau 2 — Dans le problème du quiz, deux questions ont $(p_1, R_1) = (0,9; 10)$ et $(p_2, R_2) = (0,5; 100)$. Dans quel ordre les poser ?

Les indices valent

$$\frac{p_1 R_1}{1 - p_1} = \frac{0,9 \times 10}{0,1} = 90, \quad \frac{p_2 R_2}{1 - p_2} = \frac{0,5 \times 100}{0,5} = 100$$

Il faut poser la question **2 d'abord** (indice $100 > 90$), bien qu'elle soit deux fois moins sûre.

Vérification directe. Ordre $(2, 1)$: $0,5 \times 100 + 0,5 \times 0,9 \times 10 = 50 + 4,5 = 54,5$. Ordre $(1, 2)$: $0,9 \times 10 + 0,9 \times 0,5 \times 100 = 9 + 45 = 54$. L'ordre $(2, 1)$ est bien meilleur.

La leçon : le classement ne se fait ni sur R_i seul, ni sur p_i seul, ni même sur $p_i R_i$ (qui donnerait 9 contre 50, même conclusion ici mais pas toujours) — c'est bien $p_i R_i / (1 - p_i)$ qui tranche.

Niveau 3 — Écrivez la récurrence de contrôle minimax et dites ce qui la distingue du cas stochastique.

$$J_N(x_N) = g_N(x_N), \quad J_k(x_k) = \min_{u_k \in U(x_k)} \max_{w_k \in W_k(x_k, u_k)} \left[g_k(x_k, u_k, w_k) + J_{k+1}(f_k(x_k, u_k, w_k)) \right]$$

La seule différence est que $\mathbb{E}_{w_k}$ est remplacé par $\max_{w_k \in W_k(x_k, u_k)}$: au lieu de moyenner sur la loi de l'aléa, on prend le **pire cas** sur l'ensemble où il vit.

Tout le reste est identique : récurrence à rebours, principe d'optimalité, politique en boucle fermée $\mu_k(x_k)$, et l'ordre **min puis max** qui traduit qu'on décide **avant** de subir. On peut d'ailleurs voir le cas stochastique et le cas minimax comme deux instances d'un même schéma, avec deux « opérateurs d'agrégation » différents sur w_k .

Niveau 4 — type examen — Démontrez l'emboîtement $T_k \subseteq T_{k+1}$ des régions d'arrêt, et expliquez quand la politique devient stationnaire.

Étape 1 — la monotonie de J_k . À l'avant-dernière étape,

$$J_{N-1}(x) = \min \left\{ t(x), \min_u \mathbb{E}\{g + J_N(f)\} \right\} \leq t(x) = J_N(x)$$

puisque le minimum d'un ensemble contenant $t(x)$ lui est inférieur. Puis, par **monotonie de l'opérateur de Bellman** — si $J_{k+1} \leq J_{k+2}$ ponctuellement, alors leurs images le restent, car **min**, **max** et $\mathbb{E}$ préservent l'ordre — on obtient par récurrence descendante

$$J_k(x) \leq J_{k+1}(x) \quad \text{pour tout } k \text{ et tout } x$$

Étape 2 — l'emboîtement. Par définition,

$$x \in T_k \iff t(x) \leq \min_u \mathbb{E}\{g(x, u, w) + J_{k+1}(f(x, u, w))\}$$

Comme $J_{k+1} \leq J_{k+2}$, le membre de droite pour k est **inférieur ou égal** à celui pour $k + 1$. Donc si l'inégalité est vérifiée pour k , elle l'est a fortiori pour $k + 1$:

$$T_0 \subseteq T_1 \subseteq \dots \subseteq T_{N-1} \quad \blacksquare$$

Étape 3 — quand la politique est-elle stationnaire ? Lorsque toutes les T_k sont **égales** à T_{N-1} . Le cours donne une condition suffisante :

$$f(x, u, w) \in T_{N-1} \quad \text{pour tout } x \in T_{N-1}, u \in U(x), w$$

c'est-à-dire que T_{N-1} **est absorbante** pour la dynamique.

Pourquoi cette condition suffit, intuitivement. Si l'on est dans T_{N-1} , continuer ne peut mener qu'à un état où l'on voudra encore s'arrêter — donc continuer ne fait que retarder l'inévitable en accumulant des coûts. Il est donc optimal de s'arrêter **immédiatement**, à n'importe quel instant : la région d'arrêt ne dépend plus de k .

La portée. Une politique stationnaire est **une seule règle** au lieu de N , calculée une fois. C'est exactement ce qu'on cherchera systématiquement en horizon infini — et l'observation « $\alpha_k \rightarrow \bar{\alpha}$ si w est bornée » du concept 2 en est l'annonce.

● Common mistakes

1. **Chercher une politique compliquée dans un problème d'arrêt** — la solution est une **partition** de l'espace d'états, souvent un simple seuil.
2. **Croire le seuil constant en horizon fini** — α_k **décroît** ; il ne devient constant qu'à l'horizon infini.
3. **Se tromper de sens dans l'emboîtement** — c'est $T_k \subseteq T_{k+1}$: la région d'arrêt **grandit** quand on approche de la fin.
4. **Appliquer l'argument d'échange sans vérifier l'hypothèse** — il exige l'existence d'une politique optimale **en boucle ouverte**.
5. **Échanger deux tâches non adjacentes** — l'argument ne fonctionne que sur des tâches **voisines**, sinon les termes de préfixe et de suffixe ne se simplifient pas.
6. **Trier sur $p_i R_i$ au lieu de $p_i R_i / (1 - p_i)$** — le dénominateur encode le risque d'interruption ; l'oublier donne un ordre faux.
7. **Inverser min et max en minimax** — $\min_u \max_w$ signifie « je décide, puis le pire arrive » ; $\max_w \min_u$ donnerait à l'adversaire le désavantage de jouer en premier.

8. **Utiliser le minimax quand on connaît la loi** — il est inutilement pessimiste ; l'espérance est alors le bon critère.

Ultimate Review

1. **Arrêt pur** : deux commandes, l'arrêt menant à un état **absorbant sans coût** ; toute politique est une **partition** en région d'arrêt et région de continuation.
2. **Vente d'actif** : $J_k(x_k) = \max\{(1+r)^{N-k}x_k, \mathbb{E}\{J_{k+1}(w_k)\}\}$; accepter si $x_k > \alpha_k$ avec $\alpha_k = \mathbb{E}\{J_{k+1}(w_k)\}/(1+r)^{N-k}$.
3. Le seuil **décroît** : $\alpha_k \geq \alpha_{k+1}$ — preuve par $V_k = J_k/(1+r)^{N-k}$ et monotonie de la DP.
4. Si w est bornée, $\alpha_k \rightarrow \bar{\alpha}$: **politique stationnaire** en horizon infini.
5. **Arrêt général** : $J_k = \min\{t(x_k), \min_u \mathbb{E}[g + J_{k+1}(f)]\}$; région d'arrêt T_k .
6. **Emboîtement** $T_0 \subseteq \dots \subseteq T_{N-1}$; politique **stationnaire** si T_{N-1} est **absorbante**.
7. **Ordonnancement** : parmi les problèmes combinatoires les plus durs ; deux voies quasi analytiques — **indice** et **argument d'échange** (qui exige une politique optimale en boucle ouverte).
8. **Problème du quiz** : trier par $\frac{p_i R_i}{1-p_i}$ **décroissant** — gain espéré divisé par le risque d'interruption.
9. **Minimax** : $\mathbb{E}_{w_k}$ devient $\max_{w_k \in W_k(x_k, u_k)}$; tout le reste de la structure DP est inchangé.

Formulas to know

$$J_k(x_k) = \max\{(1+r)^{N-k}x_k, \mathbb{E}\{J_{k+1}(w_k)\}\} \quad \alpha_k = \frac{\mathbb{E}\{J_{k+1}(w_k)\}}{(1+r)^{N-k}}$$

$$T_k = \left\{x \mid t(x) \leq \min_u \mathbb{E}\{g + J_{k+1}(f)\}\right\} \quad \frac{p_i R_i}{1-p_i} \geq \frac{p_j R_j}{1-p_j}$$

$$J_k(x_k) = \min_{u_k} \max_{w_k \in W_k(x_k, u_k)} [g_k + J_{k+1}(f_k)]$$

Methods to know : le protocole en 8 étapes ; l'argument d'échange sur deux tâches adjacentes ; la preuve de monotonie des seuils et de l'emboîtement des régions d'arrêt.

Active Recall

Basic — Quelle forme prend nécessairement une politique dans un problème d'arrêt pur ?

Une **partition** de l'ensemble des états en deux régions : la **région d'arrêt**, où l'on s'arrête, et la **région de continuation**, où l'on continue. On ne cherche donc pas une fonction quelconque mais une **frontière** — souvent, en dimension un, un simple **seuil**.

Understanding — Pourquoi les régions d'arrêt sont-elles emboîtées, et dans quel sens ?

Dans le sens $T_0 \subseteq T_1 \subseteq \dots \subseteq T_{N-1}$: elles **grandissent** avec k . La raison est la monotonie $J_k \leq J_{k+1}$, elle-même issue de $J_{N-1} \leq J_N$ et de la monotonie de l'opérateur de Bellman. Comme le coût-à-venir de continuer augmente quand on approche de l'horizon, la condition « il vaut mieux s'arrêter » est satisfaite par de plus en plus d'états.

Intuitivement : près de la fin, l'option de continuer vaut de moins en moins cher, donc on s'arrête plus volontiers.

Application — Trois questions de quiz : $(0,8; 5)$, $(0,4; 20)$, $(0,6; 9)$. Quel ordre ?

Indices $p_i R_i / (1 - p_i)$:

$$\frac{0,8 \times 5}{0,2} = 20, \quad \frac{0,4 \times 20}{0,6} \approx 13,3, \quad \frac{0,6 \times 9}{0,4} = 13,5$$

Ordre optimal : **question 1** (20), puis **question 3** (13,5), puis **question 2** (13,3). Les deux dernières sont très proches, ce qui montre que le critère arbitre finement entre récompense élevée et probabilité de survie.

Comparison — Contrôle stochastique et contrôle minimax : qu'est-ce qui change, qu'est-ce qui reste ?

Ce qui change : l'agrégation sur w_k . Le stochastique **moyenne** ($\mathbb{E}_{w_k}$, avec une loi connue) ; le minimax prend le **pire cas** ($\max_{w_k \in W_k}$, avec un simple ensemble d'appartenance).

Ce qui reste : absolument tout le reste — la récurrence à rebours, le principe d'optimalité, la politique en boucle fermée, et l'ordre **min** _{u} puis agrégation sur w , qui traduit qu'on décide avant de subir.

Exam-style — Menez l'argument d'échange sur le problème du quiz.

Soit $L = (i_0, \dots, i_{k-1}, i, j, i_{k+2}, \dots)$ une liste **optimale**, où i et j occupent les positions k et $k+1$. Sa récompense espérée est

$$\mathbb{E}\{L\} = \mathbb{E}\{\text{préfixe}\} + p_{i_0} \cdots p_{i_{k-1}} (p_i R_i + p_i p_j R_j) + p_{i_0} \cdots p_{i_{k-1}} p_i p_j \mathbb{E}\{\text{suffixe}\}$$

Soit L' la même liste avec i et j **échangées**. Les termes de préfixe sont identiques, et les termes de suffixe aussi — le suffixe est atteint avec la probabilité $p_i p_j$ dans les deux ordres. L'optimalité de L donne donc $\mathbb{E}\{L\} \geq \mathbb{E}\{L'\}$, soit

$$p_i R_i + p_i p_j R_j \geq p_j R_j + p_j p_i R_i$$

En regroupant : $p_i R_i (1 - p_j) \geq p_j R_j (1 - p_i)$, puis en divisant par $(1 - p_i)(1 - p_j) > 0$:

$$\frac{p_i R_i}{1 - p_i} \geq \frac{p_j R_j}{1 - p_j}$$

Toute paire adjacente d'une liste optimale est donc ordonnée par indice décroissant : la liste entière l'est. ■

Flashcards

Question	Réponse
Les deux commandes d'un problème d'arrêt ?	Arrêter (coût unique, état absorbant sans coût) ou continuer
Forme d'une politique d'arrêt ?	Une partition : région d'arrêt / région de continuation
DP de la vente d'actif ?	$J_k(x_k) = \max\{(1+r)^{N-k}x_k, \mathbb{E}\{J_{k+1}(w_k)\}\}$
Seuil d'acceptation ?	$\alpha_k = \mathbb{E}\{J_{k+1}(w_k)\}/(1+r)^{N-k}$
Le seuil est-il constant ?	Non : $\alpha_k \geq \alpha_{k+1}$, il décroît
Que se passe-t-il si w est bornée ?	$\alpha_k \rightarrow \bar{\alpha}$: politique stationnaire en horizon infini
Sens de l'emboîtement des régions d'arrêt ?	$T_0 \subseteq T_1 \subseteq \dots \subseteq T_{N-1}$
Quand la politique d'arrêt est-elle stationnaire ?	Si T_{N-1} est absorbante pour la dynamique
Les deux voies quasi analytiques en ordonnancement ?	Politique d' indice ; argument d'échange
Que suppose l'argument d'échange ?	L'existence d'une politique optimale en boucle ouverte
Indice du problème du quiz ?	$p_i R_i / (1 - p_i)$, à trier par ordre décroissant
Comment lire cet indice ?	Gain espéré divisé par le risque d'interruption
Que change le contrôle minimax ?	$\mathbb{E}_{w_k}$ devient $\max_{w_k \in W_k(x_k, u_k)}$
Ordre des opérateurs en minimax ?	min_u puis max_w — on décide avant de subir
Quand le minimax est-il justifié ?	Aléa adverse ou loi inconnue ; sinon il est trop pessimiste