

Fiche 49 — Méthodes de calcul : itération sur les valeurs, sur les politiques, programmation linéaire

Matière	Maths · Optimisation
Cours source	Bertsekas, <i>6.231 Dynamic Programming</i> , MIT OpenCourseWare, automne 2015 — cours 11
Difficulté	Must know — les trois façons de résoudre une équation de Bellman
Temps d'étude estimé	1 h 45
Prérequis	Fiche 48 (équation de Bellman, SSP), fiche 24 (programmation linéaire)
Concepts clés	Équation de Bellman pour une politique, itération sur les valeurs, itération sur les politiques, évaluation et amélioration, monotonie de la DP, formulation par programmation linéaire
Poids à l'examen	La justification de l'itération sur les politiques — l'amélioration monotone puis la terminaison en un nombre fini d'étapes — est la démonstration type. Et savoir dire quand choisir chacune des trois méthodes.

Vue d'ensemble

L'équation de Bellman

$$J^*(i) = \min_{u \in U(i)} \left[g(i, u) + \sum_{j=1}^n p_{ij}(u) J^*(j) \right]$$

détermine J^* de façon unique (fiche 48). Reste à la **résoudre**. Trois méthodes, trois philosophies.

ITÉRATION SUR LES VALEURS	on itère l'opérateur de Bellman sur J → converge, jamais exactement, coût faible par pas
ITÉRATION SUR LES POLITIQUES	on alterne ÉVALUER une politique / l'AMÉLIORER → exacte en un nombre FINI d'étapes, chaque pas coûteux
PROGRAMMATION LINÉAIRE	J^* est le PLUS GRAND J satisfaisant les inégalités → un LP, mais de très grande taille

Le choix se joue sur la taille n de l'espace d'états — et, au-delà d'un certain seuil, aucune des trois ne s'applique : il faut approcher.

● Concept 1 — L'équation de Bellman pour une politique donnée

Le résultat. Pour une politique **stationnaire** μ , les valeurs $J_\mu(i)$, $i = 1, \dots, n$, sont l'**unique solution** du système **linéaire** de n équations

$$J_\mu(i) = g(i, \mu(i)) + \sum_{j=1}^n p_{ij}(\mu(i)) J_\mu(j), \quad i = 1, \dots, n$$

Ce qui a disparu : le minimum. L'équation de Bellman générale est **non linéaire** à cause du $\min_u$. Une fois la politique **fixée**, il ne reste qu'un système **linéaire** — c'est toute la différence, et c'est ce qui rend l'évaluation d'une politique exactement soluble.

En écriture matricielle, avec $P_\mu = [p_{ij}(\mu(i))]$ et $g_\mu = [g(i, \mu(i))]$:

$$J_\mu = g_\mu + P_\mu J_\mu \quad \Longleftrightarrow \quad (I - P_\mu) J_\mu = g_\mu$$

Le coût, et la conséquence pratique. L'équation fournit un moyen de calculer les $J_\mu(i)$, mais le calcul est substantiel pour n grand — de l'ordre de $O(n^3)$. Donc :

- **pour n grand**, l'itération sur les valeurs peut être préférable — *cas typique d'un grand système linéaire, où une méthode itérative peut battre une méthode directe* ;
- **pour n TRÈS grand**, aucune méthode exacte ne s'applique et il faut des **approximations**.

● Concept 2 — Itération sur les valeurs

$$J_{k+1}(i) = \min_{u \in U(i)} \left[g(i, u) + \sum_{j=1}^n p_{ij}(u) J_k(j) \right], \quad \forall i$$

Elle converge vers $J^\star$ **depuis toute initialisation** J_0 (fiche 48).

Coût par itération	$O(n^2 \times U)$ — un balayage de tous les états et de toutes les commandes
Nombre d'itérations	infini en théorie ; on s'arrête sur un critère de précision
Nature	méthode itérative , jamais exacte en temps fini

La comparaison à retenir est celle que fait le cours : évaluer une politique, c'est résoudre un grand système linéaire. Comme pour tout grand système linéaire, on a le choix entre une méthode **directe** ($O(n^3)$, exacte) et une méthode **itérative** (pas moins cher, approchée). L'itération sur les valeurs est la méthode itérative ; l'itération sur les politiques utilise la méthode directe à chaque étape.

● Concept 3 — Itération sur les politiques

Le principe. L'algorithme engendre une suite $\mu^0, \mu^1, \mu^2, \dots$ de politiques **stationnaires**, en partant d'une politique stationnaire quelconque μ^0 .

À l'itération typique, connaissant μ^k :

Étape 1 — évaluation de la politique. Calculer les $J_{\mu^k}(i)$ comme solution du système **linéaire**

$$J(i) = g(i, \mu^k(i)) + \sum_{j=1}^n p_{ij}(\mu^k(i)) J(j), \quad i = 1, \dots, n$$

en les n inconnues $J(1), \dots, J(n)$.

Étape 2 — amélioration de la politique.

$$\mu^{k+1}(i) = \arg \min_{u \in U(i)} \left[g(i, u) + \sum_{j=1}^n p_{ij}(u) J_{\mu^k}(j) \right], \quad \forall i$$

Terminaison. S'arrêter quand $J_{\mu^k}(i) = J_{\mu^{k+1}}(i)$ pour tout i . Alors $J_{\mu^{k+1}} = J^*$ et μ^{k+1} est **optimale**, puisque

$$J_{\mu^{k+1}}(i) = g(i, \mu^{k+1}(i)) + \sum_j p_{ij}(\mu^{k+1}(i)) J_{\mu^{k+1}}(j) = \min_{u \in U(i)} \left[g(i, u) + \sum_j p_{ij}(u) J_{\mu^{k+1}}(j) \right]$$

c'est-à-dire que $J_{\mu^{k+1}}$ **satisfait l'équation de Bellman** — dont la solution est unique.

Les deux étapes s'opposent terme à terme. L'**évaluation** fixe la politique et résout exactement en J ; l'**amélioration** fixe J et optimise exactement en μ . C'est une descente par coordonnées entre l'espace des valeurs et celui des politiques.

● Concept 4 — Pourquoi l'itération sur les politiques fonctionne

Résultat d'amélioration monotone. $J_{\mu^k}(i) \geq J_{\mu^{k+1}}(i)$ pour tout i et tout k .

Démonstration (celle du cours). Fixons k et considérons la suite engendrée par

$$J_{N+1}(i) = g(i, \mu^{k+1}(i)) + \sum_{j=1}^n p_{ij}(\mu^{k+1}(i)) J_N(j)$$

initialisée par $J_0(i) = J_{\mu^k}(i)$. On a d'une part

$$J_0(i) = g(i, \mu^k(i)) + \sum_j p_{ij}(\mu^k(i)) J_0(j)$$

et d'autre part, **par définition de μ^{k+1} comme argmin** évalué avec $J_{\mu^k} = J_0$:

$$J_0(i) \geq g(i, \mu^{k+1}(i)) + \sum_j p_{ij}(\mu^{k+1}(i)) J_0(j) = J_1(i)$$

En utilisant la **propriété de monotonie de la DP** — l'opérateur $J \mapsto g_{\mu^{k+1}} + P_{\mu^{k+1}}J$ préserve l'ordre ponctuel — on propage :

$$J_0(i) \geq J_1(i) \geq \dots \geq J_N(i) \geq J_{N+1}(i) \geq \dots$$

Or $J_N(i) \rightarrow J_{\mu^{k+1}}(i)$ quand $N \rightarrow \infty$ (c'est l'itération sur les valeurs pour la politique fixée μ^{k+1}). D'où

$$J_{\mu^k}(i) = J_0(i) \geq J_{\mu^{k+1}}(i) \quad \forall i, \forall k \quad \blacksquare$$

La terminaison. Une politique ne peut pas se répéter — il n'y a qu'un nombre **fini** de politiques stationnaires — donc l'algorithme se termine avec une politique optimale.

C'est un argument de descente stricte sur un ensemble fini, exactement comme la convergence du simplexe (fiche 30) : le coût décroît à chaque itération, il y a un nombre fini de candidats, donc on ne peut pas boucler et l'on s'arrête. La structure de preuve est la même dans les deux cas.

Le compte des politiques. Il y a $\prod_{i=1}^n |U(i)|$ politiques stationnaires — un nombre astronomique, mais **fini**. En pratique, l'itération sur les politiques converge en très peu d'itérations (souvent moins d'une dizaine), ce qui en fait la méthode de choix quand n reste modéré.

● Concept 5 — Formulation par programmation linéaire

L'affirmation. J^* est le « plus grand » J satisfaisant la contrainte

$$J(i) \leq g(i, u) + \sum_{j=1}^n p_{ij}(u) J(j) \quad (1)$$

pour tout $i = 1, \dots, n$ et tout $u \in U(i)$.

Démonstration. Si l'on lance l'itération sur les valeurs depuis un J_0 satisfaisant la contrainte, c'est-à-dire

$$J_0(i) \leq \min_{u \in U(i)} \left[g(i, u) + \sum_j p_{ij}(u) J_0(j) \right] \quad \forall i$$

alors $J_0(i) \leq J_1(i)$, et par **monotonie de la DP**, $J_k(i) \leq J_{k+1}(i)$ pour tout k et tout i . Comme $J_k \rightarrow J^*$, on conclut $J_0(i) \leq J^*(i)$ pour tout i . ■

Le programme linéaire. $J^* = (J^*(1), \dots, J^*(n))$ est donc la solution de

$$\begin{aligned} &\text{maximiser} && \sum_{i=1}^n J(i) \\ &\text{sous} && J(i) \leq g(i, u) + \sum_{j=1}^n p_{ij}(u) J(j), \quad i = 1, \dots, n, u \in U(i) \end{aligned}$$

Ce qui est remarquable ici. Le $\min_u$ de l'équation de Bellman — qui la rend **non linéaire** — se dissout en autant de **contraintes linéaires** qu'il y a de commandes. C'est exactement le mécanisme de la fiche 25 : « minimiser un maximum » devient « une variable auxiliaire et une contrainte par morceau ». Ici, « la valeur est le minimum sur u » devient « la valeur est sous chaque branche, et on la pousse le plus haut possible ».

L'inconvénient, que le cours souligne :

Pour n grand, la dimension de ce programme est très grande. De plus, le nombre de contraintes est égal au nombre de couples état-commande.

Avec n états et $|U|$ commandes par état, le LP a n variables et $n|U|$ contraintes. C'est élégant en théorie — cela relie la DP à toute la fiche 28 sur la dualité — mais rarement compétitif en pratique.

● Concept 6 — Le cas actualisé

Tout se transporte, avec le facteur $\alpha < 1$ devant la somme.

Méthode	Forme actualisée
Itération sur les valeurs	$J_{k+1}(i) = \min_u [g(i, u) + \alpha \sum_j p_{ij}(u) J_k(j)]$
Évaluation d'une politique	$J_\mu(i) = g(i, \mu(i)) + \alpha \sum_j p_{ij}(\mu(i)) J_\mu(j)$
Équation de Bellman	$J^*(i) = \min_u [g(i, u) + \alpha \sum_j p_{ij}(u) J^*(j)]$
Programmation linéaire	$\max \sum_i J(i) \text{ s.c. } J(i) \leq g(i, u) + \alpha \sum_j p_{ij}(u) J(j)$

L'itération sur les politiques se termine avec une politique optimale, et la programmation linéaire fonctionne.

Dans le cas actualisé, l'évaluation d'une politique est **toujours** bien posée : $(I - \alpha P_\mu)$ est inversible pour tout $\alpha < 1$, puisque le rayon spectral de αP_μ vaut au plus $\alpha < 1$. Pas besoin d'hypothèse de terminaison.

Comment résoudre l'exercice type (protocole)

1. **Écrire l'équation de Bellman** en énumérant les commandes état par état.
2. **Choisir la méthode** selon la taille de n :

Situation	Méthode
n petit (quelques états)	itération sur les politiques — exacte, quelques itérations
n moyen à grand	itération sur les valeurs — pas de résolution de système
structure de LP exploitable, n modéré	programmation linéaire
n très grand ou modèle de simulation	DP approchée — aucune méthode exacte

3. **Si itération sur les politiques** : partir d'une politique stationnaire quelconque, alterner évaluation (système linéaire $n \times n$) et amélioration (argmin état par état).
4. **Vérifier la décroissance** $J_{\mu^k} \geq J_{\mu^{k+1}}$ à chaque tour — c'est le contrôle de cohérence du calcul.
5. **S'arrêter** quand la politique ne change plus, ou quand $J_{\mu^k} = J_{\mu^{k+1}}$.
6. **Si itération sur les valeurs** : initialiser librement (souvent $J_0 = 0$), itérer, s'arrêter sur $\max_i |J_{k+1}(i) - J_k(i)| < \varepsilon$.
7. **Valider** : la solution obtenue satisfait-elle l'équation de Bellman en tout état ? La solution étant **unique**, c'est un contrôle complet.

Exercices progressifs

Niveau 1 — Pourquoi l'évaluation d'une politique est-elle un système **linéaire** alors que l'équation de Bellman ne l'est pas ?

Parce que le **min** _{u} a disparu. L'équation de Bellman contient une **minimisation sur les commandes**, opération non linéaire (un minimum de fonctions affines est concave, pas affine). Une fois la politique **μ fixée**, la commande en chaque état est déterminée : il ne reste que

$$J_{\mu}(i) = g(i, \mu(i)) + \sum_j p_{ij}(\mu(i)) J_{\mu}(j)$$

soit $(I - P_{\mu})J_{\mu} = g_{\mu}$ — un système linéaire de n équations à n inconnues.

C'est précisément ce que l'itération sur les politiques exploite : elle remplace un problème non linéaire par une suite de problèmes linéaires.

Niveau 2 — Combien d'itérations au maximum pour l'itération sur les politiques ?

Au plus le **nombre de politiques stationnaires**, soit $\prod_{i=1}^n |U(i)|$. En effet, le coût décroît (au sens ponctuel) à chaque itération et une politique ne peut donc jamais réapparaître ; l'ensemble étant **fini**, l'algorithme se termine.

C'est une borne astronomique mais finie — et en pratique l'algorithme converge en une poignée d'itérations. C'est la même situation que pour le simplexe (fiche 30) : borne théorique exponentielle, comportement pratique excellent.

Niveau 3 — Démontrez que J^* est le plus grand J satisfaisant $J(i) \leq g(i, u) + \sum_j p_{ij}(u)J(j)$ pour tous i, u .

Soit J_0 satisfaisant la contrainte pour tous i et u , c'est-à-dire

$$J_0(i) \leq \min_{u \in U(i)} \left[g(i, u) + \sum_j p_{ij}(u)J_0(j) \right] = J_1(i)$$

où J_1 est le résultat d'une itération sur les valeurs depuis J_0 . On a donc $J_0 \leq J_1$ ponctuellement.

Par **monotonie de l'opérateur de Bellman** — si $J \leq J'$ ponctuellement, alors $\min_u [g + \sum pJ] \leq \min_u [g + \sum pJ']$, les p_{ij} étant positifs — on propage par récurrence :

$$J_0 \leq J_1 \leq J_2 \leq \dots \leq J_k \leq \dots$$

Or $J_k \rightarrow J^*$ (fiche 48, convergence depuis toute initialisation). Par passage à la limite, $J_0 \leq J^*$.

J^* majore donc tout J admissible, et il est lui-même admissible puisqu'il satisfait l'équation de Bellman avec égalité. C'est bien le plus grand. ■

Ce qui rend la preuve possible : la **monotonie** de l'opérateur de Bellman, qui repose uniquement sur la positivité des probabilités de transition. C'est la même propriété qui sert à la fiche 47 (emboîtement des régions d'arrêt) et au concept 4 ci-dessus.

Niveau 4 — type examen — Déroulez une itération sur les politiques sur un problème à deux états $\{1, t\}$ avec, en 1, deux commandes : u_a de coût $g(1, u_a) = 1$ et $p_{1t}(u_a) = 1$; u_b de coût $g(1, u_b) = 0$ et $p_{11}(u_b) = 0,9$, $p_{1t}(u_b) = 0,1$.

Vérification préalable. La terminaison est inévitable : sous u_b , $\mathbb{P}\{x_m \neq t\} = 0,9^m \rightarrow 0$, donc $\rho < 1$ pour m assez grand.

Itération 0 — partons de $\mu^0(1) = u_b$.

Évaluation. $J_{\mu^0}(1) = 0 + 0,9 J_{\mu^0}(1) + 0,1 \times 0$, soit $0,1 J_{\mu^0}(1) = 0$, d'où

$$J_{\mu^0}(1) = 0$$

(Cohérent : la commande u_b est gratuite, on peut tourner en rond sans rien payer.)

Amélioration.

$$\mu^1(1) = \arg \min \left\{ \underbrace{1 + 1 \times 0}_{u_a}, \underbrace{0 + 0,9 \times 0 + 0,1 \times 0}_{u_b} \right\} = \arg \min \{1, 0\} = u_b$$

La politique ne change pas : $\mu^1 = \mu^0$, donc $J_{\mu^1} = J_{\mu^0}$. L'algorithme **termine** et $\mu^*(1) = u_b$, $J^*(1) = 0$.

Vérification par l'équation de Bellman. $J^*(1) = \min\{1 + 0, 0 + 0,9 \times 0\} = 0$, et le minimum est bien atteint en u_b .

Ce que l'exemple montre. L'itération sur les politiques peut **terminer dès la première itération** si la politique initiale est déjà optimale. Et le calcul d'évaluation, ici trivial, serait un système $n \times n$ en dimension réaliste — c'est là que réside le coût en $O(n^3)$.

Variante instructive : si l'on prenait $g(1, u_b) = 0,05$ au lieu de 0, l'évaluation donnerait $J_{\mu^0}(1) = 0,05/0,1 = 0,5$, puis l'amélioration comparerait $1 + 0 = 1$ à $0,05 + 0,9 \times 0,5 = 0,5$: la politique u_b resterait optimale. Il faudrait $g(1, u_b) > 0,1$ pour que u_a — payer 1 et terminer tout de suite — devienne préférable.

● Common mistakes

1. **Confondre les deux équations** — celle de Bellman contient un $\min_u$ (non linéaire) ; celle d'évaluation d'une politique n'en a pas (linéaire).
2. **Oublier la monotonie dans les preuves** — c'est elle qui propage les inégalités à travers l'opérateur de Bellman, dans les trois démonstrations du chapitre.
3. **Croire l'itération sur les valeurs exacte en temps fini** — elle converge sans jamais atteindre J^* exactement.
4. **Croire l'itération sur les politiques toujours meilleure** — chaque itération coûte $O(n^3)$; pour n grand, l'itération sur les valeurs gagne.
5. **Se tromper de sens dans le LP** — on **maximise** $\sum_i J(i)$ sous des contraintes $\leq$, car J^* est le **plus grand** J admissible.
6. **Sous-estimer la taille du LP** — le nombre de contraintes est le nombre de **couples état-commande**, pas le nombre d'états.
7. **Partir d'une politique non stationnaire** dans l'itération sur les politiques — la méthode ne manipule que des politiques stationnaires.
8. **Oublier α dans le cas actualisé** — il porte sur le terme futur $\sum_j p_{ij}(u)J(j)$, jamais sur $g(i, u)$.

Ultimate Review

1. **Évaluation d'une politique** : $J_\mu = g_\mu + P_\mu J_\mu$, système **linéaire** $n \times n$ de solution unique, coût $O(n^3)$.
2. **Itération sur les valeurs** : $J_{k+1}(i) = \min_u [g(i, u) + \sum_j p_{ij}(u) J_k(j)]$; converge depuis tout J_0 ; itérative, jamais exacte.
3. **Itération sur les politiques** : alterner **évaluation** (système linéaire) et **amélioration** (**arg min** état par état) ; s'arrêter quand $J_{\mu^k} = J_{\mu^{k+1}}$.
4. **Amélioration monotone** : $J_{\mu^k} \geq J_{\mu^{k+1}}$, démontrée en initialisant l'itération de μ^{k+1} à J_{μ^k} et en propageant par monotonie.
5. **Terminaison** : le coût décroît strictement et il n'y a qu'un nombre **fini** de politiques stationnaires — même argument que le simplexe.
6. **Programmation linéaire** : J^* est le **plus grand** J vérifiant $J(i) \leq g(i, u) + \sum_j p_{ij}(u) J(j)$; d'où $\max \sum_i J(i)$ sous ces contraintes.
7. **Inconvénient du LP** : n variables mais **autant de contraintes que de couples état-commande**.
8. **Cas actualisé** : tout se transporte avec α ; $(I - \alpha P_\mu)$ est toujours inversible.
9. **Le choix** : politiques si n petit ; valeurs si n grand ; DP approchée si n très grand.

Formulas to know

$$J_\mu(i) = g(i, \mu(i)) + \sum_{j=1}^n p_{ij}(\mu(i)) J_\mu(j) \quad \mu^{k+1}(i) = \arg \min_{u \in U(i)} \left[g(i, u) + \sum_j p_{ij}(u) J_{\mu^k}(j) \right]$$

$$\max \sum_{i=1}^n J(i) \quad \text{s.c.} \quad J(i) \leq g(i, u) + \sum_{j=1}^n p_{ij}(u) J(j), \quad \forall i, \forall u \in U(i)$$

Methods to know : le protocole de choix de méthode ; la preuve d'amélioration monotone ; la preuve que J^* est le plus grand J admissible.

Active Recall

Basic — Décrivez les deux étapes d'une itération sur les politiques.

Évaluation : connaissant μ^k , résoudre le système **linéaire**

$J(i) = g(i, \mu^k(i)) + \sum_j p_{ij}(\mu^k(i)) J(j)$ pour obtenir J_{μ^k} . **Amélioration** : poser

$\mu^{k+1}(i) = \arg \min_{u \in U(i)} [g(i, u) + \sum_j p_{ij}(u) J_{\mu^k}(j)]$ pour chaque i . On s'arrête quand $J_{\mu^k} = J_{\mu^{k+1}}$; alors μ^{k+1} est optimale.

Understanding — Pourquoi l'itération sur les politiques se termine-t-elle en un nombre fini d'étapes ?

Parce que le coût **décroît** à chaque itération ($J_{\mu^k} \geq J_{\mu^{k+1}}$ ponctuellement) et qu'il n'y a qu'un nombre **fini** de politiques stationnaires — au plus $\prod_i |U(i)|$. Une politique ne peut donc jamais réapparaître, et l'algorithme s'arrête nécessairement, sur une politique satisfaisant l'équation de Bellman, donc optimale.

C'est exactement la structure de preuve de la convergence du simplexe : décroissance stricte sur un ensemble fini de candidats.

Application — Quelle méthode choisir pour $n = 10$ états ? Pour $n = 10^6$?

$n = 10$: **l'itération sur les politiques**. Chaque évaluation est un système 10×10 , résolu instantanément, et l'algorithme converge en quelques itérations vers la solution **exacte**.

$n = 10^6$: ni l'une ni l'autre des méthodes exactes. Une évaluation coûterait $O(10^{18})$ opérations, et même un balayage d'itération sur les valeurs est coûteux. C'est le domaine de la **DP approchée** — approximation de J^* par une famille paramétrée, simulation, apprentissage.

Comparison — Itération sur les valeurs et sur les politiques : quel est le compromis ?

	Valeurs	Politiques
Coût par itération	faible : un balayage	élevé : $O(n^3)$
Nombre d'itérations	infini (approché)	fini (exact)
Nature	itérative	directe à chaque tour

C'est le compromis classique entre **méthode itérative** et **méthode directe** pour un grand système linéaire — comparaison que le cours fait explicitement. Beaucoup d'itérations bon

marché, ou peu d'itérations chères.

Exam-style — Démontrez l'amélioration monotone de l'itération sur les politiques.

Fixons k et considérons la suite définie par

$$J_{N+1}(i) = g(i, \mu^{k+1}(i)) + \sum_j p_{ij}(\mu^{k+1}(i)) J_N(j), \quad J_0 = J_{\mu^k}$$

Premier pas. J_0 vérifie $J_0(i) = g(i, \mu^k(i)) + \sum_j p_{ij}(\mu^k(i)) J_0(j)$. Or $\mu^{k+1}(i)$ est, **par définition**, l'argmin de $g(i, u) + \sum_j p_{ij}(u) J_0(j)$ sur u . Donc

$$J_0(i) \geq g(i, \mu^{k+1}(i)) + \sum_j p_{ij}(\mu^{k+1}(i)) J_0(j) = J_1(i)$$

Propagation. L'opérateur $J \mapsto g_{\mu^{k+1}} + P_{\mu^{k+1}} J$ est **monotone** (les $p_{ij} \geq 0$). De $J_0 \geq J_1$ on déduit donc $J_1 \geq J_2$, puis par récurrence

$$J_0 \geq J_1 \geq \dots \geq J_N \geq J_{N+1} \geq \dots$$

Passage à la limite. $J_N \rightarrow J_{\mu^{k+1}}$ (itération sur les valeurs à politique fixée). D'où

$$J_{\mu^k} = J_0 \geq J_{\mu^{k+1}} \quad \blacksquare$$

Flashcards

Question	Réponse
Équation d'évaluation d'une politique ?	$J_{\mu}(i) = g(i, \mu(i)) + \sum_j p_{ij}(\mu(i))J_{\mu}(j)$
Sa nature ?	Système linéaire $n \times n$, solution unique
Son coût ?	$O(n^3)$
Pourquoi est-elle linéaire ?	Le min _{u} a disparu : la politique est fixée
Itération sur les valeurs ?	$J_{k+1}(i) = \min_u [g(i, u) + \sum_j p_{ij}(u)J_k(j)]$
Les deux étapes de l'itération sur les politiques ?	Évaluation (système linéaire) puis amélioration (argmin)
Critère d'arrêt ?	$J_{\mu^k} = J_{\mu^{k+1}}$ pour tout état
Résultat d'amélioration ?	$J_{\mu^k} \geq J_{\mu^{k+1}}$ ponctuellement
Sur quoi repose sa preuve ?	La monotonie de l'opérateur de Bellman
Pourquoi la terminaison est-elle finie ?	Décroissance stricte sur un ensemble fini de politiques
J^* et les inégalités de Bellman ?	J^* est le plus grand J tel que $J(i) \leq g(i, u) + \sum_j p_{ij}(u)J(j)$
Le LP correspondant ?	max $\sum_i J(i)$ sous ces contraintes
Inconvénient du LP ?	Autant de contraintes que de couples état-commande
Quelle méthode pour n petit ?	Itération sur les politiques
Quelle méthode pour n grand ?	Itération sur les valeurs
Et pour n très grand ?	DP approchée — aucune méthode exacte