

Fiche 50 — Analyse de régression : MCO, Gauss-Markov, MCG et maximum de vraisemblance

Matière	Maths · Optimisation
Cours source	Kempthorne, <i>18.S096 Topics in Mathematics with Applications in Finance</i> , MIT OpenCourseWare, automne 2013 — cours 6 « Regression Analysis »
Difficulté	Must know — le socle de toute l'économétrie
Temps d'étude estimé	2 h 30
Prérequis	Fiche 9 (matrices, rang, définie positive), fiche 39 (moindres carrés et équations normales)
Concepts clés	Modèle linéaire général, moindres carrés ordinaires, équations normales, matrice chapeau, théorème de Gauss-Markov, BLUE, moindres carrés généralisés, loi des estimateurs, test de Student, maximum de vraisemblance, M-estimation
Poids à l'examen	Trois résultats à savoir démontrer : les équations normales , le théorème de Gauss-Markov , et le fait que l'EMV coïncide avec les MCO sous normalité. La loi de $\hat{\beta}$ donne tous les tests.

Vue d'ensemble

On dispose de n observations : une **variable de réponse** y_i et p **variables explicatives** $x_i = (x_{i,1}, \dots, x_{i,p})^T$. Le but de l'analyse de régression est d'**extraire et exploiter la relation** entre y_i et x_i — pour la **prédiction**, l'**inférence causale**, l'**approximation** ou l'étude de **relations fonctionnelles**.

MODÈLE	$y = X\beta + \varepsilon$	
CRITÈRE	$Q(\beta) = \ y - X\beta\ ^2$	← moindres carrés
SOLUTION	$X^T X \hat{\beta} = X^T y$	← équations normales
GARANTIE	Gauss-Markov : $\hat{\beta}$ est BLUE	
LOI	sous normalité : $\hat{\beta} \sim N(\beta, \sigma^2(X^T X)^{-1})$	→ tests de Student

La force du chapitre est de **séparer trois questions** qu'on confond souvent : quel **modèle** ? quel **critère** d'estimation ? quelles **hypothèses** sur les erreurs ? Ces trois choix sont indépendants, et c'est leur combinaison qui détermine les propriétés de l'estimateur.

● Concept 1 — Le modèle linéaire général

Pour chaque observation i , la distribution conditionnelle $[y_i | x_i]$ est donnée par

$$y_i = \hat{y}_i + \varepsilon_i, \quad \hat{y}_i = \beta_1 x_{i,1} + \beta_2 x_{i,2} + \cdots + \beta_p x_{i,p}$$

où $\beta = (\beta_1, \dots, \beta_p)^T$ sont les p **paramètres de régression** — **constants sur toutes les observations** — et ε_i la **variable résiduelle**, qui varie d'une observation à l'autre.

La remarque décisive du cours. La linéarité de $\hat{y}_i$ (en les **paramètres** de régression) est préservée avec des x non linéaires. Autrement dit, « régression **linéaire** » ne veut pas dire « relation linéaire entre y et la variable observée » : cela veut dire **linéaire en β** .

D'où une étendue de modèles considérable :

Modèle	Choix des variables explicatives
Approximation polynomiale	$x_{i,j} = (x_i)^j$ — différentes puissances d'une même variable
Série de Fourier	$x_{i,j} = \sin(jx_i)$ ou $\cos(jx_i)$
Régression sur séries temporelles	i indexe le temps, et les explicatives incluent les valeurs retardées de la réponse

Cette dernière ligne est capitale en finance : elle signifie qu'un modèle autorégressif $y_t = \phi_1 y_{t-1} + \cdots + \phi_p y_{t-p} + \varepsilon_t$ **est** une régression linéaire, et que tout ce chapitre s'y applique — sous réserve de vérifier les hypothèses sur les erreurs, ce qui est précisément là que le bât blesse.

Les cinq étapes de l'ajustement d'un modèle

1. **Proposer un modèle** : la variable de réponse Y (en précisant l'échelle), les explicatives $X_1, \dots, X_p$ (en incluant si besoin différentes fonctions des explicatives), et les **hypothèses sur la distribution de ε** .
2. **Spécifier un critère** pour juger les différents estimateurs.
3. **Caractériser le meilleur estimateur** et l'appliquer aux données.
4. **Vérifier les hypothèses** faites en (1).
5. Si nécessaire, **modifier** le modèle ou les hypothèses et retourner en (1).

Le point à ne pas manquer : l'étape (4). Un estimateur n'est « le meilleur » que **relativement aux hypothèses** de l'étape (1). Ne pas les vérifier, c'est revendiquer une optimalité qui n'existe peut-être pas.

● Concept 2 — Les trois choix indépendants

Hypothèses sur la distribution des résidus

Hypothèse	Contenu
Gauss-Markov	moyenne nulle, variance constante , non corrélés
Modèles normaux-linéaires	les ε_i sont i.i.d. de loi $N(0, \sigma^2)$
Gauss-Markov généralisé	moyenne nulle et matrice de covariance générale (possiblement corrélée, possiblement hétéroscédastique)
Lois non gaussiennes	Laplace, Pareto, normale contaminée : une fraction $1 - \delta$ des ε_i est i.i.d. $N(0, \sigma^2)$, la fraction restante δ suit une loi de contamination

La normale contaminée est le modèle mental de la finance. Les rendements ne sont pas gaussiens : ils ont des **queues épaisses**. Une petite fraction d'observations extrêmes suffit à ruiner un estimateur conçu sous normalité — d'où les estimateurs **robustes** du concept 8.

Critères d'estimation

Moindres carrés · **maximum de vraisemblance** · **robuste** (résistant à la contamination) · **bayésien** (les β_j sont des variables aléatoires de loi a priori connue) · accommodant des **données manquantes**.

Vérification des hypothèses

- **Analyse des résidus.** Point crucial : les *erreurs du modèle* ε_i sont **inobservables**. Ce qu'on observe, ce sont les **résidus** pour des paramètres ajustés $\tilde{\beta}_j$:

$$e_i = y_i - [\tilde{\beta}_1 x_{i,1} + \cdots + \tilde{\beta}_p x_{i,p}]$$

- **Diagnostics d'influence** : identifier les observations très « influentes ».
- **Détection d'observations aberrantes**.

Ne jamais confondre erreur et résidu. ε_i est une quantité théorique, non observée ; e_i est une quantité calculée, qui dépend de l'estimateur. Leurs propriétés diffèrent : les ε_i sont supposés non corrélés, les e_i **ne le sont jamais** (ils sont liés par p contraintes d'orthogonalité).

● Concept 3 — Les moindres carrés ordinaires

Le critère. Pour $\beta = (\beta_1, \dots, \beta_p)^T$,

$$Q(\beta) = \sum_{i=1}^n [y_i - \hat{y}_i]^2 = \sum_{i=1}^n \left[y_i - (\beta_1 x_{i,1} + \dots + \beta_p x_{i,p}) \right]^2$$

L'estimateur des MCO $\hat{\beta}$ minimise $Q(\beta)$.

En notation matricielle, avec $y \in \mathbb{R}^n$, $X \in \mathbb{R}^{n \times p}$ et $\hat{y} = X\beta$:

$$Q(\beta) = (y - X\beta)^T (y - X\beta)$$

La dérivation des équations normales. $\hat{\beta}$ annule $\partial Q / \partial \beta_j$ pour tout j :

$$\frac{\partial Q}{\partial \beta_j} = \sum_{i=1}^n 2(-x_{i,j}) [y_i - (x_{i,1}\beta_1 + \dots + x_{i,p}\beta_p)] = -2 X_{[j]}^T (y - X\beta)$$

où $X_{[j]}$ est la j -ième **colonne** de X . En empilant sur j :

$$\nabla Q(\beta) = -2X^T(y - X\beta) = 0$$

d'où les **équations normales** :

$$X^T X \hat{\beta} = X^T y \quad \implies \quad \hat{\beta} = (X^T X)^{-1} X^T y$$

Condition d'existence et d'unicité. Pour que $\hat{\beta}$ existe (de façon unique), $X^T X$ doit être inversible, c'est-à-dire que X doit être de **rang colonne plein**. Si deux explicatives sont colinéaires — ou si $p > n$ — l'estimateur n'est pas défini. C'est le problème de la **multicolinéarité**.

La matrice chapeau

$$\hat{y} = X\hat{\beta} = X(X^T X)^{-1} X^T y = Hy, \quad H = X(X^T X)^{-1} X^T$$

H est la **matrice chapeau** (*hat matrix*), de taille $n \times n$.

H projette $\mathbb{R}^n$ sur l'espace engendré par les colonnes de X . C'est la lecture géométrique de tout le chapitre : ajuster par moindres carrés, c'est **projeter orthogonalement** le vecteur de données y sur le sous-espace des combinaisons linéaires des explicatives.

Résidus.

$$\hat{\varepsilon} = y - \hat{y} = (I_n - H)y$$

et les équations normales se relisent

$$X^T(y - X\hat{\beta}) = X^T \hat{\varepsilon} = 0_p$$

Le vecteur des résidus des moindres carrés $\hat{\varepsilon}$ est **orthogonal** à l'espace des colonnes de X . C'est le fait à retenir : la projection laisse un résidu perpendiculaire au sous-espace. En particulier, si X contient une constante, les résidus sont de **somme nulle**.

● Concept 4 — Le théorème de Gauss-Markov

Les hypothèses. Les données (y, X) suivent un modèle linéaire satisfaisant les hypothèses de Gauss-Markov si y est une réalisation d'un vecteur aléatoire Y tel que

$$\mathbb{E}(Y \mid X, \beta) = X\beta, \quad \text{Cov}(Y \mid X, \beta) = \sigma^2 I_n \quad \text{pour un } \sigma^2 > 0$$

C'est-à-dire que les variables aléatoires engendrant les observations sont **non corrélées** et de **variance constante** σ^2 (conditionnellement à X et β).

Le cadre. Pour des constantes connues $c_1, \dots, c_p, c_{p+1}$, on veut estimer

$$\theta = c_1\beta_1 + \dots + c_p\beta_p + c_{p+1}$$

L'estimateur $\hat{\theta} = c_1\hat{\beta}_1 + \dots + c_p\hat{\beta}_p + c_{p+1}$ construit sur les MCO est :

1. un estimateur **sans biais** de θ ;

2. un estimateur **linéaire** de θ , c'est-à-dire $\hat{\theta} = \sum_{i=1}^n b_i y_i$ pour des constantes b_i connues (étant donné X).

THÉORÈME DE GAUSS-MARKOV.

Sous les hypothèses de Gauss-Markov, l'estimateur $\hat{\theta}$ a la plus petite (**Best**) variance parmi tous les estimateurs **Linéaires** et **Sans biais** (**Unbiased**) de θ — c'est-à-dire que $\hat{\theta}$ est **BLUE**.

Démonstration (celle du cours). Sans perte de généralité, $c_{p+1} = 0$ et $c = (c_1, \dots, c_p)^T$. L'estimateur MCO de $\theta = c^T \beta$ est

$$\hat{\theta} = c^T \hat{\beta} = c^T (X^T X)^{-1} X^T y \equiv d^T y$$

un estimateur **linéaire** en y , de coefficients d . Considérons un estimateur linéaire alternatif $\tilde{\theta} = b^T y$, et posons $f = b - d$, si bien que

$$\tilde{\theta} = b^T y = (d + f)^T y = \hat{\theta} + f^T y$$

Étape 1 — que dit l'absence de biais ? Si $\tilde{\theta}$ est sans biais, comme $\hat{\theta}$ l'est déjà,

$$0 = \mathbb{E}(f^T y) = f^T \mathbb{E}(y) = f^T (X\beta) \quad \text{pour tout } \beta \in \mathbb{R}^p$$

donc **f est orthogonal à l'espace des colonnes de X** — et en particulier à $d = X(X^T X)^{-1}c$, qui appartient à cet espace.

Étape 2 — décomposer la variance.

$$\begin{aligned} \text{Var}(\tilde{\theta}) &= \text{Var}(d^T y + f^T y) = \text{Var}(d^T y) + \text{Var}(f^T y) + 2 \text{Cov}(d^T y, f^T y) \\ &= \text{Var}(\hat{\theta}) + \text{Var}(f^T y) + 2 d^T \text{Cov}(y) f \\ &= \text{Var}(\hat{\theta}) + \text{Var}(f^T y) + 2\sigma^2 d^T f \\ &= \text{Var}(\hat{\theta}) + \text{Var}(f^T y) + 0 \geq \text{Var}(\hat{\theta}) \end{aligned}$$

■

Où chaque hypothèse est utilisée. L'absence de corrélation et la variance constante ($\text{Cov}(y) = \sigma^2 I_n$) servent à la troisième ligne : sans elles, $d^T \text{Cov}(y) f$ ne se simplifie pas en $\sigma^2 d^T f$ et le terme croisé ne s'annule pas. **La normalité n'est utilisée nulle part** — Gauss-Markov ne la suppose pas.

● Concept 5 — Les moindres carrés généralisés

Le cadre généralisé. $Y = X\beta + \varepsilon$ avec

$$\mathbb{E}[\varepsilon] = 0_n, \quad \mathbb{E}[\varepsilon\varepsilon^T] = \sigma^2 \Sigma$$

où σ^2 est un paramètre d'échelle inconnu et Σ une matrice $(n \times n)$ **définie positive connue**, spécifiant les variances relatives et les corrélations des observations.

L'astuce : blanchir les données. On transforme

$$Y^* = \Sigma^{-1/2}Y, \quad X^* = \Sigma^{-1/2}X$$

et le modèle devient

$$Y^* = X^*\beta + \varepsilon^*, \quad \mathbb{E}[\varepsilon^*] = 0_n, \quad \mathbb{E}[\varepsilon^*(\varepsilon^*)^T] = \sigma^2 I_n$$

c'est-à-dire un modèle satisfaisant **exactement** les hypothèses de Gauss-Markov. Par le théorème, le BLUE est donc

$$\hat{\beta}_{\text{MCG}} = [(X^*)^T X^*]^{-1} (X^*)^T Y^* = [X^T \Sigma^{-1} X]^{-1} X^T \Sigma^{-1} Y$$

La leçon de méthode. On ne démontre pas un nouveau théorème : on **transforme le problème** pour se ramener au théorème déjà acquis. C'est exactement le mouvement de la fiche 36 (problèmes équivalents) et de la fiche 37 (mise en forme convexe d'un GP).

En pratique, Σ est rarement connue. On l'estime — d'où les MCG *faisables*, dont les propriétés ne sont qu'asymptotiques. Les deux cas usuels en finance : **hétéroscédasticité** (Σ diagonale à termes inégaux, volatilité variable) et **autocorrélation** (Σ non diagonale, séries temporelles).

● Concept 6 — Loi des estimateurs sous normalité

Le modèle normal-linéaire.

$$y = X\beta + \varepsilon, \quad \varepsilon \sim N_n(0_n, \sigma^2 I_n) \quad \text{soit} \quad y \sim N_n(X\beta, \sigma^2 I_n)$$

Le lemme de transformation. Pour toute matrice A de taille $(m \times n)$ et de rang $m \leq n$, le vecteur normal y transformé par A , $z = Ay$, est encore un vecteur normal :

$$z \sim N_m(\mu_z, \Sigma_z), \quad \mu_z = AX\beta, \quad \Sigma_z = \sigma^2 AA^T$$

En prenant $A = (X^T X)^{-1} X^T$ on obtient immédiatement la loi de $\hat{\beta}$.

THÉORÈME.

Pour le modèle normal-linéaire avec X de rang p : (a) $\hat{\beta} = (X^T X)^{-1} X^T y$ et $\hat{\varepsilon} = y - X\hat{\beta}$ sont des variables aléatoires **indépendantes** ; (b) $\hat{\beta} \sim N_p(\beta, \sigma^2(X^T X)^{-1})$; (c) $\sum_{i=1}^n \hat{\varepsilon}_i^2 = \hat{\varepsilon}^T \hat{\varepsilon} \sim \sigma^2 \chi_{n-p}^2$; (d) pour chaque j ,

$$\hat{t}_j = \frac{\hat{\beta}_j - \beta_j}{\hat{\sigma} \sqrt{C_{j,j}}} \sim t_{n-p}, \quad \hat{\sigma}^2 = \frac{1}{n-p} \sum_{i=1}^n \hat{\varepsilon}_i^2, \quad C_{j,j} = [(X^T X)^{-1}]_{j,j}$$

Lois marginales. De (b) découle immédiatement $\hat{\beta}_j \sim N(\beta_j, \sigma^2 C_{j,j})$.

C'est ce théorème qui produit toute l'inférence. Le point (d) donne les **tests de Student** sur chaque coefficient et les **intervalles de confiance** ; le point (c) donne l'estimateur **sans biais** $\hat{\sigma}^2$ de la variance (noter le diviseur $n - p$, pas n) ; et le point (a) — l'indépendance — est **exactement** ce qui permet de former le rapport de (d) et d'obtenir une loi de Student.

L'outil de la preuve : la décomposition QR

On écrit $X = QR$ où Q est $(n \times p)$ **orthonormale** ($Q^T Q = I_p$) et R est $(p \times p)$ **triangulaire supérieure**. Les colonnes de Q se construisent par **orthonormalisation de Gram-Schmidt** sur celles de X .

Ce que la décomposition simplifie.

$$\hat{\beta} = (X^T X)^{-1} X^T y = R^{-1} Q^T y, \quad \text{Cov}(\hat{\beta}) = \sigma^2 R^{-1} (R^{-1})^T, \quad H = QQ^T$$

Le principe de la preuve. On complète Q en une matrice **orthogonale** $A = \begin{pmatrix} Q^T \\ W^T \end{pmatrix}$ de taille $(n \times n)$, et l'on pose $z = Ay$, décomposé en $z_Q = Q^T y$ et $z_W = W^T y$, **indépendants** puisque A est orthogonale et y gaussien. On montre alors

$$\hat{\beta} = R^{-1} z_Q, \quad \hat{\varepsilon} = W z_W$$

— donc $\hat{\beta}$ et $\hat{\varepsilon}$ sont fonctions de **vecteurs indépendants différents**, ce qui donne (a) — puis $\hat{\varepsilon}^T \hat{\varepsilon} = z_W^T z_W$ est une somme de $n - p$ carrés de variables i.i.d. $N(0, \sigma^2)$, ce qui donne (c).

La lecture géométrique. Q engendre l'espace des colonnes de X (dimension p), W son orthogonal (dimension $n - p$). La rotation orthogonale A **sépare** le signal du bruit : p coordonnées portent $\hat{\beta}$, les $n - p$ autres portent les résidus. L'indépendance et le χ^2_{n-p} en découlent immédiatement — d'où le nom de « degrés de liberté ».

● Concept 7 — Maximum de vraisemblance

Définitions. La **fonction de vraisemblance** est $L(\beta, \sigma^2) = p(y | X, \beta, \sigma^2)$, la densité jointe de y conditionnellement aux données X et aux paramètres inconnus. Les **estimateurs du maximum de vraisemblance** sont les valeurs qui maximisent L — celles qui rendent les données observées les plus vraisemblables au sens de leur densité.

Le calcul. Les y_i étant indépendants de loi $N(\mu_i, \sigma^2)$ avec $\mu_i = \sum_j \beta_j x_{i,j}$:

$$L(\beta, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2} (y_i - \sum_j \beta_j x_{i,j})^2} = \frac{1}{(2\pi\sigma^2)^{n/2}} e^{-\frac{1}{2} (y - X\beta)^T (\sigma^2 I_n)^{-1} (y - X\beta)}$$

En passant au logarithme et en supprimant les termes constants :

$$\log L(\beta, \sigma^2) = -\frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \underbrace{(y - X\beta)^T (y - X\beta)}_{Q(\beta), \text{ le critère des moindres carrés !}}$$

Le résultat central. L'estimateur MCO $\hat{\beta}$ **est aussi** l'estimateur du maximum de vraisemblance. Maximiser $\log L$ en β revient à **minimiser** $Q(\beta)$ — le critère des moindres carrés apparaît **mécaniquement** dès qu'on suppose les erreurs gaussiennes.

L'estimateur ML de la variance. En annulant $\partial \log L(\hat{\beta}, \sigma^2) / \partial (\sigma^2)$:

$$-\frac{n}{2} \cdot \frac{1}{\sigma^2} - \frac{1}{2} (-1) (\sigma^2)^{-2} Q(\hat{\beta}) = 0 \quad \Rightarrow \quad \hat{\sigma}_{ML}^2 = \frac{Q(\hat{\beta})}{n} = \frac{1}{n} \sum_{i=1}^n \hat{\varepsilon}_i^2$$

Cet estimateur est BIAISÉ, comme le signale le cours. Le point (c) du théorème donne $\mathbb{E}[\hat{\varepsilon}^T \hat{\varepsilon}] = \sigma^2(n - p)$, donc $\mathbb{E}[\hat{\sigma}_{ML}^2] = \sigma^2(n - p)/n < \sigma^2$. L'estimateur **sans biais** est celui de diviseur $n - p$: c'est celui qu'on utilise dans les tests.

POURQUOI LA CONNEXION MCO / MV EST IMPORTANTE.

Elle explique pourquoi les moindres carrés sont **partout** : ils ne sont pas un choix arbitraire, mais l'estimateur du maximum de vraisemblance **sous hypothèse gaussienne**. Corollaire immédiat : si les erreurs ne sont **pas** gaussiennes — queues épaisses des rendements financiers — les MCO perdent leur justification en vraisemblance, même s'ils restent BLUE au sens de Gauss-Markov.

● Concept 8 — M-estimation généralisée

Le cadre unificateur. Pour ajuster $y_i = x_i^T \beta + \varepsilon_i$, on choisit $\hat{\beta}$ minimisant

$$Q(\beta) = \sum_{i=1}^n h(y_i, x_i, \beta, \sigma^2)$$

Le choix de la fonction h distingue les différents estimateurs :

Estimateur	$h(y_i, x_i, \beta, \sigma^2)$	Comportement
Moindres carrés	$(y_i - x_i^T \beta)^2$	pénalise le carré : très sensible aux aberrants
Écart absolu moyen (MAD)	$ y_i - x_i^T \beta $	pénalise linéairement : robuste
Maximum de vraisemblance	$-\log p(y_i \beta, x_i, \sigma^2)$	optimal sous le modèle supposé

La lecture avec la fiche 25. Minimiser $\sum_i (y_i - x_i^T \beta)^2$ est un **programme quadratique** ; minimiser $\sum_i |y_i - x_i^T \beta| = \|y - X\beta\|_1$ est un **programme linéaire**. Le choix du critère est donc aussi un choix de **classe de problème d'optimisation** — et l'on retrouve exactement la comparaison des normes de la fiche 25 : la norme 1 laisse quelques gros résidus et colle au reste, la norme 2 les étale tous.

Comment résoudre l'exercice type (protocole)

1. **Écrire le modèle** $y = X\beta + \varepsilon$ en précisant ce que contient chaque colonne de X (constante ? retards ? puissances ?).
2. **Vérifier le rang** de X : rang colonne plein, sinon $\hat{\beta}$ n'existe pas.
3. **Énoncer les hypothèses** sur ε : Gauss-Markov, normale, ou covariance générale.
4. **Calculer** $\hat{\beta} = (X^T X)^{-1} X^T y$, puis $\hat{y} = H y$ et $\hat{\varepsilon} = (I - H) y$.
5. **Estimer la variance** par $\hat{\sigma}^2 = \hat{\varepsilon}^T \hat{\varepsilon} / (n - p)$ — diviseur $n - p$, jamais n .
6. **Faire l'inférence** : $\hat{t}_j = (\hat{\beta}_j - \beta_j^0) / (\hat{\sigma} \sqrt{C_{j,j}})$ comparé à t_{n-p} .
7. **Vérifier les hypothèses** : graphique des résidus, hétéroscédasticité, autocorrélation, aberrants.
8. **Corriger si besoin** : MCG en cas de covariance non sphérique, estimateur robuste en cas de contamination.

Exercices progressifs

Niveau 1 — Pourquoi exige-t-on que X soit de rang colonne plein ?

Parce que $\hat{\beta} = (X^T X)^{-1} X^T y$ requiert l'**invertibilité** de $X^T X$. Or $X^T X$ est inversible si et seulement si X est de rang colonne plein : si une colonne est combinaison linéaire des autres, il existe $v \neq 0$ avec $Xv = 0$, donc $X^T Xv = 0$ et la matrice est singulière.

Interprétation. Deux explicatives parfaitement colinéaires portent la **même information** : on ne peut pas attribuer l'effet à l'une plutôt qu'à l'autre. Les équations normales ont alors une infinité de solutions, toutes donnant le même $\hat{y}$ — la **projection** $H y$ reste bien définie, c'est seulement sa **décomposition** en coefficients qui ne l'est pas.

Niveau 2 — Que signifie géométriquement $X^T \hat{\varepsilon} = 0$?

Que le vecteur des résidus est **orthogonal** à toutes les colonnes de X , donc à l'espace qu'elles engendrent. Autrement dit, $\hat{y} = H y$ est la **projection orthogonale** de y sur cet espace, et $\hat{\varepsilon} = y - \hat{y}$ en est la composante perpendiculaire.

Deux conséquences pratiques. Si X contient une colonne de **1** (une constante), l'orthogonalité à cette colonne donne $\sum_i \hat{\varepsilon}_i = 0$: les résidus sont de **somme nulle**. Et l'orthogonalité à chaque explicative donne $\sum_i x_{i,j} \hat{\varepsilon}_i = 0$: les résidus sont **non corrélés avec les régresseurs par**

construction — ce qui explique pourquoi on ne peut pas tester l'exogénéité en regardant cette corrélation.

Niveau 3 — On estime le modèle de marché $r_{i,t} = \alpha + \beta r_{m,t} + \varepsilon_t$ sur $n = 60$ mois. On trouve $\hat{\beta} = 1,2$ et $\hat{\sigma}\sqrt{C_{2,2}} = 0,15$. Le titre est-il significativement plus risqué que le marché ?

On teste $H_0 : \beta = 1$ contre $H_1 : \beta > 1$ — « le titre amplifie-t-il les mouvements du marché ? ». La statistique du point (d) du théorème :

$$\hat{t} = \frac{\hat{\beta} - 1}{\hat{\sigma}\sqrt{C_{2,2}}} = \frac{1,2 - 1}{0,15} \approx 1,33$$

à comparer à une loi de Student à $n - p = 60 - 2 = 58$ degrés de liberté. Le quantile à 95 % unilatéral vaut environ 1,67.

Comme $1,33 < 1,67$, on ne rejette pas H_0 : le bêta n'est pas significativement supérieur à 1 au seuil de 5 %. L'écart-type d'estimation de 0,15 est trop grand pour trancher.

La validité du test suppose les hypothèses du modèle normal-linéaire : erreurs i.i.d. gaussiennes. Sur des rendements mensuels, l'hypothèse d'absence d'autocorrélation est plausible, mais la normalité et l'homoscédasticité le sont beaucoup moins (volatilité groupée) — voir les fiches sur la modélisation de la volatilité.

Niveau 4 — type examen — Démontrez le théorème de Gauss-Markov et identifiez précisément où chaque hypothèse intervient.

Cadre. Estimer $\theta = c^T \beta$. L'estimateur MCO est $\hat{\theta} = c^T \hat{\beta} = c^T (X^T X)^{-1} X^T y = d^T y$ avec $d = X(X^T X)^{-1} c$. Soit $\tilde{\theta} = b^T y$ un autre estimateur **linéaire**, et $f = b - d$, si bien que $\tilde{\theta} = \hat{\theta} + f^T y$.

Étape 1 — l'absence de biais contraint f . $\hat{\theta}$ est sans biais (car $\mathbb{E}(y) = X\beta$ donne $\mathbb{E}(\hat{\theta}) = c^T \beta$). Si $\tilde{\theta}$ l'est aussi, alors

$$0 = \mathbb{E}(f^T y) = f^T X\beta \quad \text{pour tout } \beta \in \mathbb{R}^p$$

Le « pour tout β » est essentiel : il force $f^T X = 0$, c'est-à-dire $f \perp$ **espace des colonnes de X** . Comme $d = X(X^T X)^{-1}c$ appartient à cet espace, $d^T f = 0$. → Ici intervient l'hypothèse $\mathbb{E}(Y | X, \beta) = X\beta$: la **bonne spécification** du modèle.

Étape 2 — décomposer la variance.

$$\text{Var}(\tilde{\theta}) = \text{Var}(\hat{\theta}) + \text{Var}(f^T y) + 2 \text{Cov}(d^T y, f^T y)$$

et le terme de covariance vaut

$$\text{Cov}(d^T y, f^T y) = d^T \text{Cov}(y) f = d^T (\sigma^2 I_n) f = \sigma^2 d^T f = 0$$

→ Ici intervient l'hypothèse $\text{Cov}(Y | X, \beta) = \sigma^2 I_n$: **variance constante et absence de corrélation**. Sans elle, $\text{Cov}(y) = \sigma^2 \Sigma$ et le terme croisé $\sigma^2 d^T \Sigma f$ n'a aucune raison d'être nul.

Conclusion. $\text{Var}(\tilde{\theta}) = \text{Var}(\hat{\theta}) + \text{Var}(f^T y) \geq \text{Var}(\hat{\theta})$, avec égalité si et seulement si $f^T y$ est de variance nulle. $\hat{\theta}$ est donc BLUE. ■

Ce que le théorème NE dit pas — la liste à connaître.

- Il ne suppose **pas la normalité** : elle n'intervient nulle part dans la preuve.
- Il ne dit **rien** des estimateurs **non linéaires** : un estimateur non linéaire peut battre les MCO (c'est le cas des estimateurs robustes sur des données contaminées).
- Il ne dit **rien** des estimateurs **biaisés** : un estimateur biaisé peut avoir une erreur quadratique moyenne plus faible — c'est tout le principe de la **régularisation** (ridge, LASSO).
- Il **tombe** si $\text{Cov}(y) \neq \sigma^2 I_n$ — c'est exactement le cas que les MCG traitent, en **blanchissant** les données pour se ramener au cadre du théorème.

● Common mistakes

1. **Croire que « linéaire » porte sur x** — la linéarité est en β ; polynômes, Fourier et retards restent des régressions linéaires.
2. **Confondre erreur ε_i et résidu $\hat{\varepsilon}_i$** — la première est inobservable, le second est calculé et satisfait p contraintes d'orthogonalité.
3. **Diviser par n pour estimer σ^2** — l'estimateur sans biais divise par $n - p$; celui du maximum de vraisemblance, qui divise par n , est **biaisé**.
4. **Croire que Gauss-Markov exige la normalité** — il ne l'exige pas ; c'est le calcul des **lois** et des **tests** qui en a besoin.

5. **Oublier que BLUE se restreint aux estimateurs linéaires sans biais** — hors de cette classe, on peut faire mieux.
6. **Appliquer les MCO à des données hétéroscédastiques ou autocorrélées** — ils restent sans biais mais **ne sont plus BLUE**, et les écarts-types calculés sont **faux**.
7. **Tester l'exogénéité en corrélant résidus et régresseurs** — cette corrélation est **nulle par construction** ($X^T \hat{\varepsilon} = 0$).
8. **Oublier de vérifier le rang de X** — multicollinéarité ou $p > n$ rendent $\hat{\beta}$ indéfini.

Ultimate Review

1. Modèle : $y = X\beta + \varepsilon$; **linéaire en β** , quelconque en x (polynômes, Fourier, retards).
2. Cinq étapes : modèle, critère, estimation, **vérification des hypothèses**, itération.
3. Trois choix **indépendants** : forme du modèle, hypothèses sur ε , critère d'estimation.
4. **MCO** : $Q(\beta) = \|y - X\beta\|^2$; **équations normales** $X^T X \hat{\beta} = X^T y$; $\hat{\beta} = (X^T X)^{-1} X^T y$, existence ssi X de rang colonne plein.
5. **Matrice chapeau** $H = X(X^T X)^{-1} X^T$: projection sur l'espace des colonnes ; $\hat{\varepsilon} = (I - H)y$ **orthogonal** à cet espace.
6. **Gauss-Markov** : $\mathbb{E}(Y) = X\beta$, $\text{Cov}(Y) = \sigma^2 I_n \Rightarrow \hat{\theta} = c^T \hat{\beta}$ est **BLUE**. Pas de normalité requise.
7. **MCG** : $\text{Cov} = \sigma^2 \Sigma$, on blanchit par $\Sigma^{-1/2}$, d'où $\hat{\beta}_{\text{MCG}} = [X^T \Sigma^{-1} X]^{-1} X^T \Sigma^{-1} Y$.
8. **Sous normalité** : $\hat{\beta} \sim N_p(\beta, \sigma^2 (X^T X)^{-1})$; $\hat{\beta} \perp \hat{\varepsilon}$; $\hat{\varepsilon}^T \hat{\varepsilon} \sim \sigma^2 \chi_{n-p}^2$; $\hat{t}_j \sim t_{n-p}$.
9. **QR** : $X = QR$, $\hat{\beta} = R^{-1} Q^T y$, $H = QQ^T$; la rotation orthogonale sépare signal (p) et bruit ($n - p$).
10. **Maximum de vraisemblance** : $\log L = -\frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} Q(\beta)$; l'EMV de β est l'estimateur MCO ; $\hat{\sigma}_{ML}^2 = Q(\hat{\beta})/n$ est **biaisé**.
11. **M-estimation** : le choix de h distingue MCO (carré), MAD (valeur absolue, robuste), MV ($-\log p$).

Formulas to know

$$\hat{\beta} = (X^T X)^{-1} X^T y \quad H = X(X^T X)^{-1} X^T \quad \hat{\beta}_{\text{MCG}} = [X^T \Sigma^{-1} X]^{-1} X^T \Sigma^{-1} Y$$

$$\hat{\beta} \sim N_p(\beta, \sigma^2 (X^T X)^{-1}) \quad \hat{t}_j = \frac{\hat{\beta}_j - \beta_j}{\hat{\sigma} \sqrt{C_{j,j}}} \sim t_{n-p} \quad \hat{\sigma}^2 = \frac{\hat{\varepsilon}^T \hat{\varepsilon}}{n - p}$$

Methods to know : le protocole en 8 étapes ; la dérivation des équations normales ; la preuve de Gauss-Markov et le rôle de chaque hypothèse ; le blanchiment des MCG.

Active Recall

Basic — Écrivez les équations normales et donnez la condition d'existence de $\hat{\beta}$.

$X^T X \hat{\beta} = X^T y$, d'où $\hat{\beta} = (X^T X)^{-1} X^T y$. L'existence et l'unicité exigent que $X^T X$ soit **inversible**, c'est-à-dire que X soit de **rang colonne plein** — pas de colinéarité parfaite entre explicatives, et $n \geq p$.

Understanding — Que signifie « BLUE », et quelles hypothèses sont nécessaires ?

Best Linear Unbiased Estimator : de **variance minimale** parmi tous les estimateurs **linéaires** en y et **sans biais**. Les hypothèses nécessaires sont celles de Gauss-Markov : $\mathbb{E}(Y | X, \beta) = X\beta$ (bonne spécification) et $\text{Cov}(Y | X, \beta) = \sigma^2 I_n$ (variance constante, absence de corrélation).

La normalité n'est pas requise — elle ne sert qu'à obtenir les **lois** des estimateurs, donc les tests.

Application — Les erreurs sont hétéroscédastiques. Les MCO restent-ils sans biais ? Restent-ils BLUE ?

Sans biais : oui. L'absence de biais ne dépend que de $\mathbb{E}(y) = X\beta$:

$\mathbb{E}(\hat{\beta}) = (X^T X)^{-1} X^T \mathbb{E}(y) = \beta$, quelle que soit la structure de covariance.

BLUE : non. La preuve de Gauss-Markov utilise $\text{Cov}(y) = \sigma^2 I_n$ pour annuler le terme croisé. Avec $\text{Cov}(y) = \sigma^2 \Sigma$, le BLUE devient l'estimateur des **MCG**,
 $\hat{\beta}_{\text{MCG}} = [X^T \Sigma^{-1} X]^{-1} X^T \Sigma^{-1} y$.

Et surtout : les écarts-types usuels $\hat{\sigma}^2 (X^T X)^{-1}$ sont alors **faux**, donc tous les tests le sont aussi.

Comparison — MCO et maximum de vraisemblance : quand coïncident-ils ?

Ils coïncident **pour** β dès que les erreurs sont supposées i.i.d. **gaussiennes** : la log-vraisemblance s'écrit $-\frac{n}{2}\log \sigma^2 - \frac{1}{2\sigma^2}Q(\beta)$, et la maximiser en β revient exactement à **minimiser le critère des moindres carrés** $Q(\beta)$.

Ils **diffèrent pour** σ^2 : l'EMV donne $Q(\hat{\beta})/n$, **biaisé**, alors que l'estimateur usuel divise par $n - p$.

Et ils diffèrent complètement **hors du cas gaussien** : sous une loi de Laplace, par exemple, l'EMV minimise $\sum_i |y_i - x_i^T \beta|$ — c'est l'estimateur MAD, pas les MCO.

Exam-style — Expliquez le rôle de la décomposition QR dans la théorie de la distribution.

On écrit $X = QR$ avec $Q^T Q = I_p$ et R triangulaire supérieure, puis on complète Q en une matrice **orthogonale** $A = \begin{pmatrix} Q \\ W^T \end{pmatrix}$ de taille $n \times n$. Comme y est gaussien et A orthogonale, les blocs $z_Q = Q^T y$ et $z_W = W^T y$ sont **gaussiens et indépendants**.

On montre alors $\hat{\beta} = R^{-1} z_Q$ et $\hat{\varepsilon} = W z_W$: les deux quantités sont fonctions de **vecteurs indépendants distincts**, d'où **(a)** leur indépendance. La loi **(b)** de $\hat{\beta}$ s'obtient en appliquant le lemme de transformation avec $A = R^{-1}$. Et $\hat{\varepsilon}^T \hat{\varepsilon} = z_W^T z_W$ est une somme de $n - p$ carrés de variables i.i.d. $N(0, \sigma^2)$, d'où **(c)** le $\sigma^2 \chi_{n-p}^2$. Le point **(d)** en découle immédiatement.

Géométriquement, la rotation A sépare $\mathbb{R}^n$ en l'espace des colonnes de X (dimension p , qui porte l'estimation) et son orthogonal (dimension $n - p$, qui porte le bruit) — d'où les $n - p$ « degrés de liberté ».

Flashcards

Question	Réponse
Le modèle linéaire général ?	$y_i = \beta_1 x_{i,1} + \dots + \beta_p x_{i,p} + \varepsilon_i$
« Linéaire » porte sur quoi ?	Sur les paramètres β , pas sur x
Critère des moindres carrés ?	$Q(\beta) = (y - X\beta)^T (y - X\beta)$
Équations normales ?	$X^T X \hat{\beta} = X^T y$
Condition d'existence de $\hat{\beta}$?	X de rang colonne plein
Matrice chapeau ?	$H = X(X^T X)^{-1} X^T$ — projette sur l'espace des colonnes
Propriété des résidus MCO ?	$X^T \hat{\varepsilon} = 0$: orthogonaux aux régresseurs
Hypothèses de Gauss-Markov ?	$\mathbb{E}(Y) = X\beta$ et $\text{Cov}(Y) = \sigma^2 I_n$
Que dit le théorème ?	$c^T \hat{\beta}$ est BLUE
La normalité est-elle requise ?	Non pour Gauss-Markov ; oui pour les lois et les tests
Estimateur des MCG ?	$[X^T \Sigma^{-1} X]^{-1} X^T \Sigma^{-1} Y$
Comment l'obtient-on ?	En blanchissant : $Y^* = \Sigma^{-1/2} Y$, $X^* = \Sigma^{-1/2} X$
Loi de $\hat{\beta}$ sous normalité ?	$N_p(\beta, \sigma^2 (X^T X)^{-1})$
Loi de $\hat{\varepsilon}^T \hat{\varepsilon}$?	$\sigma^2 \chi_{n-p}^2$
Statistique de test sur β_j ?	$(\hat{\beta}_j - \beta_j) / (\hat{\sigma} \sqrt{C_{j,j}}) \sim t_{n-p}$
Estimateur sans biais de σ^2 ?	$\hat{\varepsilon}^T \hat{\varepsilon} / (n - p)$
L'EMV de β sous normalité ?	C'est l' estimateur MCO
L'EMV de σ^2 ?	$Q(\hat{\beta}) / n$ — biaisé
M-estimation : quel h pour les MCO ?	$h = (y_i - x_i^T \beta)^2$
Quel h pour un estimateur robuste ?	$h = y_i - x_i^T \beta $ (MAD)