

Fiche 52 — Séries temporelles I : stationnarité, Wold, ARMA et racines unitaires

Matière	Maths · Économétrie
Cours source	Kempthorne, <i>18.S096 Topics in Mathematics with Applications in Finance</i> , MIT OpenCourseWare, automne 2013 — cours 8 « Time Series Analysis I »
Difficulté	Must know — l'outil de base de l'économétrie des marchés
Temps d'étude estimé	2 h 45
Prérequis	Fiche 50 (moindres carrés, projection linéaire), notions de variance et covariance
Concepts clés	Stationnarité stricte et en covariance, autocorrélation, théorème de représentation de Wold, opérateur retard, réponse impulsionnelle, inversibilité, ARMA, AR(p), équations de Yule-Walker, MA(q), différenciation, ARIMA, AIC/BIC/HQ, test de Dickey-Fuller
Poids à l'examen	Quatre choses : la définition de la stationnarité en covariance, la condition sur les racines du polynôme caractéristique, les moments de l'AR(1) , et la logique du test de racine unitaire .

Vue d'ensemble

Un **processus stochastique** $\{\dots, X_{t-1}, X_t, X_{t+1}, \dots\}$ constitué de variables aléatoires indexées par un indice de temps t est une **série temporelle**. Le comportement stochastique de $\{X_t\}$ est déterminé en spécifiant les densités

$$p(x_{t_1}, x_{t_2}, \dots, x_{t_m})$$

pour toutes les collections finies d'indices $\{(t_1, \dots, t_m), m < \infty\}$ — c'est-à-dire **toutes les distributions de dimension finie** de $\{X_t\}$.

STATIONNARITÉ	l'hypothèse qui rend l'estimation possible
↓	
WOLD	toute série stationnaire = déterministe + MA(∞)
↓	
ARMA(p,q)	l'approximation parcimonieuse et utilisable

↓

ARIMA(p,d,q) ce qu'on fait quand la série n'est PAS stationnaire

↓

DICKEY-FULLER comment savoir dans quel cas on est

La question qui structure tout le chapitre. On n'observe qu'une **seule** trajectoire de la série.

Comment estimer quoi que ce soit à partir d'une réalisation unique ? Réponse : en supposant que la loi **ne change pas au cours du temps** — c'est la stationnarité, et elle est ce qui permet de remplacer une moyenne d'ensemble inobservable par une moyenne temporelle calculable.

● Concept 1 — Les deux stationnarités

DÉFINITION — STATIONNARITÉ STRICTE.

Une série temporelle $\{X_t\}$ est **strictement stationnaire** si

$$p(t_1 + \tau, t_2 + \tau, \dots, t_m + \tau) = p(t_1, t_2, \dots, t_m) \quad \forall \tau, \forall m, \forall (t_1, \dots, t_m)$$

(invariance par translation du temps)

DÉFINITION — STATIONNARITÉ EN COVARIANCE.

Une série temporelle $\{X_t\}$ est **stationnaire en covariance** si

$$E(X_t) = \mu, \quad \text{Var}(X_t) = \sigma_X^2, \quad \text{Cov}(X_t, X_{t+\tau}) = \gamma(\tau)$$

toutes constantes au cours du temps t .

La fonction d'autocorrélation de $\{X_t\}$ est

$$\rho(\tau) = \frac{\text{Cov}(X_t, X_{t+\tau})}{\sqrt{\text{Var}(X_t) \cdot \text{Var}(X_{t+\tau})}} = \frac{\gamma(\tau)}{\gamma(0)}$$

La différence entre les deux, en une phrase. La stationnarité **stricte** contraint **toute la loi jointe** ; la stationnarité **en covariance** ne contraint que les **deux premiers moments**. La stricte implique la seconde (si les moments existent) ; la réciproque est fausse en général — mais **vraie pour un processus gaussien**, puisqu'une loi gaussienne est entièrement déterminée par ses deux premiers moments.

La stationnarité en covariance est celle qu'on utilise partout, parce que c'est celle qu'on peut vérifier et exploiter. Elle est parfois appelée « stationnarité au sens faible » ou « du second ordre ».

Ce que $\gamma(\tau)$ ne dépend pas de t signifie : la covariance entre deux instants ne dépend que de l'**écart** qui les sépare, jamais de leur position absolue. C'est exactement ce qui permet d'estimer $\gamma(\tau)$ en moyennant sur t .

● Concept 2 — Le théorème de représentation de Wold

THÉORÈME DE WOLD.

Toute série temporelle stationnaire $\{X_t\}$ peut être décomposée en

$$X_t = V_t + S_t$$

où :

- $\{V_t\}$ est un processus **linéairement déterministe**, c'est-à-dire une combinaison linéaire des valeurs passées de V_t à coefficients constants ;
- $S_t = \sum_{i=0}^{\infty} \psi_i \epsilon_{t-i}$ est un processus **moyenne mobile infinie** de termes d'erreur, avec

$$\psi_0 = 1, \quad \sum_{i=0}^{\infty} \psi_i^2 < \infty$$

- $\{\epsilon_t\}$ est un **bruit blanc linéairement imprévisible** :

$$E(\epsilon_t) = 0, \quad E(\epsilon_t^2) = \sigma^2, \quad E(\epsilon_t \epsilon_s) = 0 \quad \forall t, s \neq t$$

- et $\{\epsilon_t\}$ est **non corrélé** avec $\{V_t\}$: $E(\epsilon_t V_s) = 0, \quad \forall t, s$.

POURQUOI C'EST LE THÉORÈME FONDATEUR.

Il dit qu'il n'existe **aucune** autre forme de série stationnaire : **toute** série stationnaire est une partie prévisible plus une moyenne mobile infinie d'innovations. Modéliser une série stationnaire, c'est donc nécessairement estimer $\{\psi_i\}$ — le seul problème est qu'il y en a une infinité.

Attention au sens de « déterministe » ici. V_t est **linéairement** déterministe : il est parfaitement prédictible par une combinaison linéaire de son propre passé. Ce n'est pas une fonction connue du temps, c'est la partie de la série qui ne contient **aucune information nouvelle**.

Le bruit blanc de Wold n'est pas forcément i.i.d. — il est seulement **non corrélé**. C'est une différence capitale en finance : les rendements sont à peu près non corrélés, mais leurs **carrés** ne le sont pas du tout (volatilité groupée). Un bruit blanc peut donc être très loin d'être imprévisible au sens fort.

Application intuitive du théorème de Wold

Supposons qu'on veuille spécifier une série stationnaire en covariance $\{X_t\}$ pour modéliser les données réelles $\{x_t, t = 0, 1, \dots, T\}$. La stratégie du cours :

Étape 1 — initialiser p , le nombre d'observations passées dans le terme linéairement déterministe de la décomposition de Wold.

Étape 2 — estimer la projection linéaire de X_t sur $(X_{t-1}, X_{t-2}, \dots, X_{t-p})$. On prend un échantillon d'estimation de taille n de point final $t_0 \leq T$, on indexe par $\{j = -(p-1), \dots, 0, 1, \dots, n\}$ la sous-série correspondante et l'on pose $y_j = x_{t_0-n+j}$ (avec $t_0 \geq n+p$). On définit

$$y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, \quad Z = \begin{pmatrix} 1 & y_0 & y_{-1} & \cdots & y_{-(p-1)} \\ 1 & y_1 & y_0 & \cdots & y_{-(p-2)} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & y_{n-1} & y_{n-2} & \cdots & y_{n-p} \end{pmatrix}$$

et l'on applique les MCO :

$$\hat{y} = Z(Z^T Z)^{-1} Z^T y = \hat{P}(Y_t | Y_{t-1}, Y_{t-2}, \dots, Y_{t-p}) = \hat{y}^{(p)}$$

Reconnaissez la fiche 50. $Z(Z^T Z)^{-1} Z^T$ est la **matrice chapeau** : ajuster une AR(p), c'est **exactement** faire une régression linéaire dont les explicatives sont les retards de la variable expliquée.

Étape 3 — calculer le résidu de projection $\hat{\epsilon}^{(p)} = y - \hat{y}^{(p)}$.

Étape 4 — appliquer les méthodes de séries temporelles à la série des résidus $\{\hat{\epsilon}_j^{(p)}\}$ pour spécifier un modèle moyenne mobile

$$\epsilon_t^{(p)} = \sum_{i \geq 0} \theta_i \eta_{t-i}$$

ce qui fournit $\{\hat{\theta}_j\}$ et $\{\hat{\eta}_t\}$, estimations des paramètres et des innovations.

Étape 5 — conduire une analyse de cas diagnostiquant la cohérence avec les hypothèses du modèle :

- Évaluer l'**orthogonalité** de $\hat{\epsilon}^{(p)}$ à Y_{t-s} , $s > p$. S'il y a des signes de corrélation, augmenter p et recommencer.
- Évaluer la cohérence de $\{\hat{\eta}_t\}$ avec les hypothèses de **bruit blanc** du théorème. Sinon, envisager des révisions du modèle global : changer la spécification du modèle moyenne mobile, ou ajouter d'autres variables « déterministes » au modèle de projection.

Note théorique du cours. Théoriquement, $\lim_{p \rightarrow \infty} \hat{y}^{(p)} = \hat{y} = P(Y_t | Y_{t-1}, Y_{t-2}, \dots)$, mais si $p \rightarrow \infty$ est requis, alors il faut $n \rightarrow \infty$ avec $p/n \rightarrow 0$. Les **modèles utiles** de séries stationnaires ont des valeurs **finies et modestes** de p , et/ou incluent des modèles moyenne mobile dépendant d'un **nombre parcimonieux** de paramètres.

Voilà le vrai sujet du chapitre. Wold garantit une représentation $MA(\infty)$; la pratique exige un nombre **fini** de paramètres. Toute la construction ARMA n'est qu'une manière d'approcher les $\{\psi_i\}$ infinis par un **quotient de deux polynômes courts**.

● Concept 3 — L'opérateur retard et ses conséquences

DÉFINITION.

L'**opérateur retard** $L(\cdot)$ décale une série temporelle d'un incrément de temps vers le passé : $L(X_t) = X_{t-1}$.

En l'appliquant récursivement :

$$L^0(X_t) = X_t, \quad L^1(X_t) = X_{t-1}, \quad L^2(X_t) = L(L(X_t)) = X_{t-2}, \quad \dots, \quad L^n(X_t) = X_{t-n}$$

Les inverses sont bien définis : $L^{-n}(X_t) = X_{t+n}$ pour $n = 1, 2, \dots$

La représentation de Wold en notation d'opérateur.

$$X_t = \sum_{i=0}^{\infty} \psi_i \epsilon_{t-i} + V_t = \sum_{i=0}^{\infty} \psi_i L^i(\epsilon_t) + V_t = \psi(L)\epsilon_t + V_t, \quad \psi(L) = \sum_{i=0}^{\infty} \psi_i L^i$$

L'intérêt de la notation. Elle transforme des **convolutions infinies** en **produits de polynômes**.

Toutes les manipulations qui suivent — inversion, factorisation, différenciation — sont de l'algèbre élémentaire sur des séries formelles.

DÉFINITION — FONCTION DE RÉPONSE IMPULSIONNELLE.

La *Impulse Response Function* du processus stationnaire $\{X_t\}$ est

$$IR(j) = \frac{\partial X_t}{\partial \epsilon_{t-j}} = \psi_j$$

et la **réponse cumulée de long terme** est

$$\sum_{j=0}^{\infty} IR(j) = \sum_{i=0}^{\infty} \psi_i = \psi(L) \text{ avec } L = 1$$

LECTURE ÉCONOMIQUE.

$IR(j)$ répond à : « si une innovation de taille 1 frappe le système aujourd'hui, de combien la série sera-t-elle décalée dans j périodes ? » La somme $\psi(1)$ mesure l'**effet total permanent** d'un choc. Pour un processus stationnaire elle est **finie** ; pour une marche aléatoire elle est infinie — le choc ne s'estompe jamais.

Représentation autorégressive équivalente

Supposons que l'opérateur $\psi(L)$ soit **inversible**, c'est-à-dire qu'il existe

$$\psi^{-1}(L) = \sum_{i=0}^{\infty} \pi_i L^i \quad \text{tel que} \quad \psi^{-1}(L)\psi(L) = I = L^0$$

Alors, en supposant $V_t = 0$ (la série a été ajustée en $X_t \leftarrow X_t - V_t$), les deux écritures suivantes sont équivalentes :

$$X_t = \psi(L)\epsilon_t \quad \Longleftrightarrow \quad \psi^{-1}(L)X_t = \epsilon_t$$

DÉFINITION.

Quand $\psi^{-1}(L)$ existe, la série $\{X_t\}$ est **inversible** et admet une **représentation autorégressive** :

$$X_t = \left(\sum_{i \geq 0} \pi_i X_{t-i} \right) + \epsilon_t$$

La dualité AR / MA est le cœur de tout le chapitre. Une MA finie est une AR infinie, et une AR finie est une MA infinie. C'est ce qui rend ARMA(p, q) si efficace : quelques paramètres de chaque côté engendrent une structure de dépendance très riche.

● Concept 4 — Les modèles ARMA(p, q)

DÉFINITION.

La série $\{X_t\}$ suit le modèle **ARMA(p, q)**, d'ordre autorégressif p et d'ordre moyenne mobile q , si

$$X_t = \mu + \phi_1(X_{t-1} - \mu) + \phi_2(X_{t-2} - \mu) + \cdots + \phi_p(X_{t-p} - \mu) + \epsilon_t + \theta_1\epsilon_{t-1} + \theta_2\epsilon_{t-2} + \cdots + \theta_q\epsilon_{t-q}$$

où $\{\epsilon_t\}$ est un $WN(0, \sigma^2)$ — un « bruit blanc » avec

$$E(\epsilon_t) = 0 \quad \forall t, \quad E(\epsilon_t^2) = \sigma^2 < \infty \quad \forall t, \quad E(\epsilon_t \epsilon_s) = 0, \quad t \neq s$$

Avec les opérateurs retard, en posant

$$\phi(L) = 1 - \phi_1 L - \phi_2 L^2 - \cdots - \phi_p L^p, \quad \theta(L) = 1 + \theta_1 L + \theta_2 L^2 + \cdots + \theta_q L^q$$

on écrit

$$\boxed{\phi(L) \cdot (X_t - \mu) = \theta(L) \epsilon_t}$$

et la décomposition de Wold est

$$X_t = \mu + \psi(L)\epsilon_t, \quad \psi(L) = [\phi(L)]^{-1}\theta(L)$$

Voilà la réponse au problème posé par Wold. Les coefficients $\{\psi_i\}$, en nombre infini, sont obtenus comme le développement d'une **fraction rationnelle** de deux polynômes de degrés p et q . On a résumé une infinité de paramètres par $p + q + 2$.

● Concept 5 — Les modèles AR(p)

Définition. Modèle autorégressif d'ordre p :

$$\phi(L) \cdot (X_t - \mu) = \epsilon_t, \quad \{\epsilon_t\} \sim WN(0, \sigma^2), \quad \phi(L) = 1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_p L^p$$

Propriétés.

- Une **combinaison linéaire** de $\{X_t, X_{t-1}, \dots, X_{t-p}\}$ est un $WN(0, \sigma^2)$.
- X_t suit un **modèle de régression linéaire** sur les variables explicatives $(X_{t-1}, \dots, X_{t-p})$:

$$X_t = c + \sum_{j=1}^p \phi_j X_{t-j} + \epsilon_t, \quad c = \mu \cdot \phi(1)$$

(en remplaçant L par 1 dans $\phi(L)$, soit $c = \mu(1 - \phi_1 - \dots - \phi_p)$).

Le pont avec la fiche 50 est explicite. Un AR(p) **est** une régression linéaire. Tout l'appareil des MCO s'y applique — mais attention, les hypothèses de Gauss-Markov demandent réflexion : les régresseurs sont **aléatoires** et corrélés aux erreurs passées, si bien que les propriétés ne sont plus qu'**asymptotiques**.

Conditions de stationnarité

On considère $\phi(z)$ en remplaçant L par une variable **complexe** z :

$$\phi(z) = 1 - \phi_1 z - \phi_2 z^2 - \dots - \phi_p z^p$$

Soient $\lambda_1, \lambda_2, \dots, \lambda_p$ les p racines de $\phi(z) = 0$. Alors

$$\phi(L) = \left(1 - \frac{1}{\lambda_1} L\right) \left(1 - \frac{1}{\lambda_2} L\right) \dots \left(1 - \frac{1}{\lambda_p} L\right)$$

Résultat central. $\{X_t\}$ est stationnaire en covariance **si et seulement si** toutes les racines de $\phi(z) = 0$ (l'« **équation caractéristique** ») sont **en dehors du cercle unité** $\{z : |z| \leq 1\}$, c'est-à-dire $|\lambda_j| > 1, j = 1, \dots, p$.

Pourquoi. Pour un nombre complexe λ avec $|\lambda| > 1$:

$$\left(1 - \frac{1}{\lambda}L\right)^{-1} = \sum_{i=0}^{\infty} \left(\frac{1}{\lambda}\right)^i L^i = 1 + \frac{1}{\lambda}L + \left(\frac{1}{\lambda}\right)^2 L^2 + \left(\frac{1}{\lambda}\right)^3 L^3 + \dots$$

qui **converge** précisément parce que $|1/\lambda| < 1$. D'où

$$\phi^{-1}(L) = \prod_{j=1}^p \left(1 - \frac{1}{\lambda_j}L\right)^{-1}$$

et la représentation MA(∞) — la décomposition de Wold — existe.

L'erreur classique. « Les racines sont **en dehors** du cercle unité » porte sur les racines de $\phi(z)$, où z est la variable **du polynôme en L** . Certains manuels énoncent la condition sur les **valeurs propres** de la matrice compagnon, qui sont les **inverses** $1/\lambda_j$: la condition devient alors « **à l'intérieur** ». Les deux énoncés disent la même chose ; c'est la variable qui change. Vérifiez toujours laquelle est utilisée.

● Concept 6 — Le modèle AR(1) en détail

Supposons que $\{X_t\}$ suive le processus AR(1) :

$$X_t - \mu = \phi(X_{t-1} - \mu) + \epsilon_t, \quad t = 1, 2, \dots, \quad \epsilon_t \sim WN(0, \sigma^2)$$

L'**équation caractéristique** est $(1 - \phi z) = 0$, de racine $\lambda = 1/\phi$. Le modèle est stationnaire en covariance **si et seulement si**

$$|\phi| < 1 \quad (\text{de façon équivalente } |\lambda| > 1)$$

Les moments.

$$E(X_t) = \mu$$

$$\text{Var}(X_t) = \sigma_X^2 = \frac{\sigma^2}{1 - \phi^2} \quad (= \gamma(0))$$

$$\text{Cov}(X_t, X_{t-1}) = \phi \cdot \sigma_X^2, \quad \text{Cov}(X_t, X_{t-j}) = \phi^j \cdot \sigma_X^2 \quad (= \gamma(j))$$

$$\text{Corr}(X_t, X_{t-j}) = \phi^j = \rho(j)$$

L'autocorrélation décroît géométriquement. C'est la signature de l'AR(1) : $\rho(j) = \phi^j$ décroît exponentiellement et ne s'annule jamais exactement — à comparer avec le MA(q), dont l'autocorrélation **tombe brutalement à zéro** au-delà du retard q .

La décomposition de Wold. Pour $|\phi| < 1$:

$$X_t = \mu + \sum_{j=0}^{\infty} \phi^j \epsilon_{t-j}$$

Les trois régimes.

Valeur de ϕ	Comportement
$0 < \phi < 1$	retour exponentiel à la moyenne μ
$-1 < \phi < 0$	retour exponentiel oscillant à la moyenne μ
$\phi = 1$	la décomposition de Wold n'existe pas : c'est la marche aléatoire simple (non stationnaire !)
$\phi > 1$	le processus AR(1) est explosif

Exemples d'AR(1) à retour à la moyenne ($0 < \phi < 1$) cités par le cours :

- **Taux d'intérêt** (processus d'Ornstein-Uhlenbeck ; modèle de Vasicek)
- **Écarts de taux d'intérêt** (*spreads*)
- **Taux de change réels**
- **Ratios de valorisation** (dividende sur prix, bénéfice sur prix)

POURQUOI CES VARIABLES-LÀ ET PAS LES PRIX.

Ce sont toutes des grandeurs **bornées économiquement** : un taux ne peut pas dériver indéfiniment, un ratio de valorisation non plus. Le prix d'une action, lui, n'a pas de niveau d'équilibre — d'où $\phi \approx 1$ et la marche aléatoire.

● Concept 7 — Les équations de Yule-Walker

Moments d'ordre 2 des processus AR(p). À partir de la spécification

$$(X_t - \mu) = \phi_1(X_{t-1} - \mu) + \phi_2(X_{t-2} - \mu) + \cdots + \phi_p(X_{t-p} - \mu) + \epsilon_t$$

on multiplie par $(X_{t-j} - \mu)$ et l'on prend l'espérance :

$$E[(X_t - \mu)(X_{t-j} - \mu)] = \phi_1 E[(X_{t-1} - \mu)(X_{t-j} - \mu)] + \cdots + \phi_p E[(X_{t-p} - \mu)(X_{t-j} - \mu)] + E[\epsilon_t(X_{t-j} - \mu)]$$

soit les **équations de Yule-Walker** ($j = 0, 1, \dots$) :

$$\gamma(j) = \phi_1 \gamma(j-1) + \phi_2 \gamma(j-2) + \cdots + \phi_p \gamma(j-p) + \delta_{0,j} \sigma^2$$

Les équations $j = 1, \dots, p$ forment un système linéaire de p équations en les ϕ_j :

$$\begin{pmatrix} \gamma(1) \\ \gamma(2) \\ \vdots \\ \gamma(p) \end{pmatrix} = \begin{pmatrix} \gamma(0) & \gamma(-1) & \gamma(-2) & \cdots & \gamma(-(p-1)) \\ \gamma(1) & \gamma(0) & \gamma(-1) & \cdots & \gamma(-(p-2)) \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \gamma(p-1) & \gamma(p-2) & \gamma(p-3) & \cdots & \gamma(0) \end{pmatrix} \begin{pmatrix} \phi_1 \\ \phi_2 \\ \vdots \\ \phi_p \end{pmatrix}$$

Les estimateurs de Yule-Walker. Étant donné des estimations $\hat{\gamma}(j)$, $j = 0, \dots, p$ (et $\hat{\mu}$), la solution de ces équations donne les **estimations de Yule-Walker** des ϕ_j ; on utilise la propriété $\gamma(-j) = \gamma(+j)$, $\forall j$.

Et l'équation $j = 0$ fournit σ^2 . De

$$\gamma(0) = \phi_1 \gamma(-1) + \phi_2 \gamma(-2) + \cdots + \phi_p \gamma(-p) + \sigma^2$$

on tire

$$\hat{\sigma}^2 = \hat{\gamma}(0) - \sum_{j=1}^p \hat{\phi}_j \hat{\gamma}(j)$$

Quand toutes les estimations $\hat{\gamma}(j)$ et $\hat{\mu}$ sont sans biais, les estimateurs de Yule-Walker appliquent le principe d'estimation par la méthode des moments.

La matrice ci-dessus est une matrice de Toeplitz symétrique : elle est constante le long de chaque diagonale, puisque γ ne dépend que de l'écart. Cette structure permet une résolution en $O(p^2)$ (algorithme de Levinson-Durbin) au lieu de $O(p^3)$.

● Concept 8 — Les modèles MA(q)

Définition. Modèle moyenne mobile d'ordre q :

$$(X_t - \mu) = \theta(L)\epsilon_t, \quad \{\epsilon_t\} \sim WN(0, \sigma^2), \quad \theta(L) = 1 + \theta_1 L + \theta_2 L^2 + \dots + \theta_q L^q$$

Propriétés.

- Le processus $\{X_t\}$ est **inversible** si toutes les racines de $\theta(z) = 0$ sont **en dehors** du cercle unité complexe.
- Les moments de X_t sont :

$$E(X_t) = \mu, \quad \text{Var}(X_t) = \gamma(0) = \sigma^2 \cdot (1 + \theta_1^2 + \theta_2^2 + \dots + \theta_q^2)$$

$$\text{Cov}(X_t, X_{t+j}) = \begin{cases} 0 & j > q \\ \sigma^2 \cdot (\theta_j + \theta_{j+1}\theta_1 + \theta_{j+2}\theta_2 + \dots + \theta_q\theta_{q-j}) & 1 \leq j \leq q \end{cases}$$

La signature du MA(q) est la coupure nette. $\gamma(j) = 0$ dès que $j > q$ — parce que X_t et X_{t+j} ne partagent **aucune** innovation commune quand l'écart dépasse la mémoire q du filtre. C'est **le** critère d'identification pratique : si l'autocorrélogramme empirique tombe à zéro après le retard q , pensez MA(q) ; s'il décroît géométriquement sans jamais s'annuler, pensez AR.

Noter la dissymétrie des deux conditions. Pour l'AR, les racines hors du cercle unité donnent la **stationnarité**. Pour le MA, elles donnent l'**inversibilité**. Un MA(q) est **toujours stationnaire** (c'est une somme finie de bruits blancs, ses moments ne dépendent jamais de t) — l'inversibilité est une question distincte : peut-on retrouver les innovations à partir des observations ?

● Concept 9 — Non-stationnarité et différenciation

De nombreuses séries économiques présentent un comportement non stationnaire compatible avec des marches aléatoires. Box et Jenkins préconisent de retirer le comportement de tendance non stationnaire à l'aide d'opérateurs de différenciation.

$$\Delta = 1 - L, \quad \Delta^2 = (1 - L)^2 = 1 - 2L + L^2, \quad \Delta^k = (1 - L)^k = \sum_{j=0}^k \binom{k}{j} (-L)^j \quad (k > 0 \text{ entier})$$

- Si le processus $\{X_t\}$ a une **tendance linéaire** en temps, alors $\{\Delta X_t\}$ **n'a pas** de tendance.
- Si $\{X_t\}$ a une **tendance quadratique**, alors le processus **doublement différencié** $\{\Delta^2 X_t\}$ n'a pas de tendance.

Deux processus non stationnaires à ne surtout pas confondre

(a) **Modèle à retour vers une tendance linéaire (trend stationary).**

$$X_t = TD_t + \varepsilon_t, \quad TD_t = a + bt \text{ (tendance déterministe linéaire)}, \quad \varepsilon_t \sim AR(1)$$

avec $\varepsilon_t = \rho\varepsilon_{t-1} + \eta_t$, $|\rho| < 1$ et $\{\eta_t\} \sim WN(0, \sigma^2)$.

Les moments de $\{X_t\}$:

$$E(X_t) = E(TD_t) + E(\varepsilon_t) = a + bt, \quad \text{Var}(X_t) = \text{Var}(\varepsilon_t) = \frac{\sigma^2}{1 - \rho^2}$$

Le processus différencié s'écrit

$$\Delta X_t = b + \Delta\varepsilon_t = b + (\varepsilon_t - \varepsilon_{t-1}) = b + (1 - L)\varepsilon_t = b + (1 - L)(1 - \rho L)^{-1}\eta_t$$

(b) **Processus purement intégré I(1).**

$$X_t = X_{t-1} + \eta_t, \quad \{\eta_t\} \sim WN(0, \sigma^2)$$

soit, de façon équivalente, $\Delta X_t = (1 - L)X_t = \eta_t$. Étant donné X_0 :

$$X_t = X_0 + TS_t, \quad TS_t = \sum_{j=0}^t \eta_j$$

Le processus $\{TS_t\}$ est un processus à **tendance stochastique** : $TS_t = TS_{t-1} + \eta_t$.

Notes du cours. Le processus à tendance stochastique **n'est pas parfaitement prévisible**. Le processus $\{X_t\}$ est une **marche aléatoire simple** à pas bruit blanc. Il est non stationnaire car, étant donné X_0 :

$$\text{Var}(X_t) = t\sigma^2, \quad \text{Cov}(X_t, X_{t-j}) = (t-j)\sigma^2 \text{ pour } 0 < j < t$$

$$\text{Corr}(X_t, X_{t-j}) = \frac{t-j}{\sqrt{t(t-j)}} = \sqrt{1-j/t}$$

Comparez les deux. Dans (a) la variance est **constante** et les chocs s'estompent : la série revient à sa tendance. Dans (b) la variance **croît linéairement avec t** et les chocs sont **permanents** : la série n'a aucun niveau vers lequel revenir. Et remarquez la corrélation $\sqrt{1-j/t}$: pour t grand elle reste **proche de 1** même à grand écart j — c'est l'illusion d'une forte dépendance qui produit les fameuses **régressions fallacieuses**.

La conséquence pratique est brutale. Différencier un processus (a) qui n'en avait pas besoin introduit un MA non inversible ; ne pas différencier un processus (b) qui en avait besoin produit des régressions et des tests entièrement faux. C'est **exactement** pourquoi les tests de racine unitaire existent.

DÉFINITION — ARIMA(p, d, q).

La série $\{X_t\}$ suit un modèle **ARIMA(p, d, q)** (« ARMA intégré ») si $\{\Delta^d X_t\}$ est **stationnaire** (et non stationnaire pour une différenciation d'ordre inférieur) et suit un modèle ARMA(p, q).

Les trois questions que pose ce modèle :

1. **Déterminer l'ordre de différenciation** requis pour retirer les tendances temporelles (déterministes ou stochastiques).
2. **Estimer** les paramètres inconnus d'un modèle ARIMA(p, d, q).
3. **Sélectionner le modèle** : choisir parmi des modèles alternatifs de spécifications (p, d, q) différentes.

● Concept 10 — Estimation et sélection de modèle

Estimation par maximum de vraisemblance.

1. Supposer que les $\{\epsilon_t\}$ sont des variables i.i.d. $N(0, \sigma^2)$.
2. Exprimer le modèle ARMA(p, q) sous **forme espace-état**.
3. Appliquer la **décomposition en erreurs de prédiction** de la log-vraisemblance.
4. Appliquer l'une ou l'autre méthode — ou les deux :
 - **LIML** (*Limited Information Maximum-Likelihood*) : conditionner sur les p premières valeurs de $\{X_t\}$ et supposer que les q premières valeurs de $\{\epsilon_t\}$ sont **nulles**.
 - **FIML** (*Full Information Maximum-Likelihood*) : utiliser la **distribution stationnaire** des p premières valeurs pour spécifier la vraisemblance **exacte**.

La différence entre les deux, en pratique. LIML est bien plus simple : conditionner sur le début de la série évite d'avoir à écrire sa loi marginale. FIML est plus efficace, surtout sur les **échantillons courts**, où les p premières observations pèsent lourd. Sur des séries financières longues, l'écart est négligeable.

Critères de sélection de modèle. Des critères statistiques servent à choisir les ordres (p, q) :

1. Ajuster tous les modèles ARMA(p, q) avec $0 \leq p \leq p_{\max}$ et $0 \leq q \leq q_{\max}$.
2. Soit $\tilde{\sigma}^2(p, q)$ l'**EMV** de $\sigma^2 = \text{Var}(\epsilon_t)$, la variance des innovations ARMA sous hypothèse gaussienne.
3. Choisir (p, q) minimisant l'un de :

$$\mathbf{AIC}(p, q) = \log(\tilde{\sigma}^2(p, q)) + 2 \cdot \frac{p + q}{n}$$

$$\mathbf{BIC}(p, q) = \log(\tilde{\sigma}^2(p, q)) + \log(n) \cdot \frac{p + q}{n}$$

$$\mathbf{HQ}(p, q) = \log(\tilde{\sigma}^2(p, q)) + 2 \log(\log(n)) \cdot \frac{p + q}{n}$$

Ces trois critères ont la même structure : ajustement + pénalité. Le premier terme récompense la réduction de la variance résiduelle, le second pénalise le nombre de paramètres $p + q$. **Ce qui les distingue est le poids de la pénalité** : 2 pour l'AIC, $\log(n)$ pour le BIC, $2 \log \log(n)$ pour Hannan-Quinn.

Pour $n > 7$, $\log(n) > 2$: **le BIC pénalise plus fort que l'AIC** et sélectionne donc des modèles **plus parcimonieux**. Le BIC est *consistant* (il retrouve le vrai modèle quand $n \rightarrow \infty$, si le vrai modèle est dans la liste) ; l'AIC ne l'est pas mais est *efficace* en prédiction. HQ est intermédiaire.

● Concept 11 — Tester la stationnarité

Test de Dickey-Fuller (DF). Supposons que $\{X_t\}$ suive le modèle AR(1)

$$X_t = \phi X_{t-1} + \epsilon_t, \quad \{\epsilon_t\} \sim WN(0, \sigma^2)$$

On teste les hypothèses

$$H_0 : \phi = 1 \quad (\text{racine unitaire, non-stationnarité})$$

$$H_1 : |\phi| < 1 \quad (\text{stationnarité})$$

(« test de racine unitaire autorégressive »).

La statistique. On ajuste le modèle AR(1) par moindres carrés et l'on définit

$$\hat{t}_{\phi=1} = \frac{\hat{\phi} - 1}{se(\hat{\phi})}$$

où $\hat{\phi}$ est l'estimateur des moindres carrés de ϕ et $se(\hat{\phi})$ l'estimation MCO de son écart-type.

Le comportement asymptotique — et c'est là tout l'intérêt du test :

- Si $|\phi| < 1$, alors $\sqrt{T}(\hat{\phi} - \phi) \xrightarrow{d} N(0, (1 - \phi^2))$.
- Si $\phi = 1$, alors $\hat{\phi}$ est **super-consistant**, de vitesse $(1/T)$, et $\hat{t}_{\phi=1}$ suit la **distribution de Dickey-Fuller**.

Le point crucial à comprendre. Sous H_0 , la statistique **ne suit pas une loi de Student**. La loi limite est non standard — c'est une fonctionnelle de mouvement brownien — et ses quantiles sont **tabulés séparément** (ils sont plus négatifs que ceux de la normale). Utiliser les tables de Student ici conduit à **rejeter beaucoup trop souvent** la racine unitaire.

Et « super-consistant » ? Sous H_0 , $\hat{\phi}$ converge à la vitesse $1/T$ au lieu de $1/\sqrt{T}$ — bien plus vite que d'ordinaire. Intuition : sous racine unitaire, la variance du régresseur X_{t-1} **croît avec t** , ce qui donne à la régression une information bien plus riche.

Les tests disponibles.

Tests de racine unitaire (H_0 : non-stationnarité)	
Dickey et Fuller (1979)	test DF
Said et Dickey (1984)	test ADF (Dickey-Fuller augmenté)
Phillips et Perron (1988)	tests de racine unitaire PP
Elliot, Rothenberg et Stock (2001)	statistiques de racine unitaire efficaces ERS

Tests de stationnarité (H_0 : stationnarité)	
Kwiatkowski, Phillips, Schmidt et Shin (1992)	test KPSS

Regardez bien les deux tableaux : les hypothèses nulles sont inversées. Pour DF/ADF/PP/ERS, H_0 est la non-stationnarité — ne pas rejeter ne prouve **pas** la racine unitaire, cela veut souvent dire qu'on manque de puissance. Pour KPSS, H_0 est la stationnarité. **La bonne pratique est de faire les deux** : si ADF ne rejette pas et KPSS rejette, on conclut à la racine unitaire avec confiance ; si les deux rejettent, il y a un problème de spécification.

Comment résoudre l'exercice type (protocole)

1. **Tracer la série** et chercher tendance, saisonnalité, changement de variance.
2. **Tester la racine unitaire** (ADF et KPSS). Si racine unitaire, **différencier** et recommencer $\Rightarrow$ cela fixe d .
3. **Regarder l'autocorrélogramme** de la série stationnarisée : coupure nette après $q \Rightarrow \text{MA}(q)$; décroissance géométrique $\Rightarrow \text{AR}$.

4. **Ajuster** tous les ARMA(p, q) jusqu'à $(p_{\max}, q_{\max})$ par maximum de vraisemblance.
5. **Sélectionner** (p, q) par AIC, BIC ou HQ.
6. **Vérifier les racines** : $\phi(z) = 0$ hors du cercle unité (stationnarité), $\theta(z) = 0$ hors du cercle unité (invertibilité).
7. **Diagnostiquer les résidus** : sont-ils un bruit blanc ? Sinon, revenir à l'étape 4.

Comment reconnaître qu'il faut utiliser cette méthode ?

Indice dans l'énoncé	Ce qu'il faut faire
« autocorrélation nulle au-delà du retard k »	MA(k)
« autocorrélation décroissant géométriquement »	AR ; si $\rho(j) = \phi^j$, AR(1)
« retour à la moyenne » (taux, spread, ratio de valorisation)	AR(1) avec $0 < \phi < 1$
« la variance croît avec le temps »	marche aléatoire / I(1) $\Rightarrow$ différencier
« tendance linéaire »	distinguer trend stationary de I(1) avec dérive $\Rightarrow$ tester
« choisir entre plusieurs modèles »	AIC / BIC / HQ
« la série est-elle stationnaire ? »	Dickey-Fuller , tables DF et non Student

Exercices progressifs

Niveau 1 — Le processus $X_t = 0,6X_{t-1} + \epsilon_t$ est-il stationnaire ? Donnez $\gamma(0)$, $\rho(2)$ et $IR(3)$ si $\sigma^2 = 4$.

Stationnarité. L'équation caractéristique est $1 - 0,6z = 0$, de racine $\lambda = 1/0,6 \approx 1,67$. Comme $|\lambda| > 1$ (ou, ce qui revient au même, $|\phi| = 0,6 < 1$), le processus **est stationnaire en covariance**.

Variance.

$$\gamma(0) = \frac{\sigma^2}{1 - \phi^2} = \frac{4}{1 - 0,36} = \frac{4}{0,64} = 6,25$$

Autocorrélation au retard 2. $\rho(2) = \phi^2 = 0,36$.

Réponse impulsionnelle. La décomposition de Wold est $X_t = \sum_j \phi^j \epsilon_{t-j}$, donc $\psi_j = \phi^j$ et

$$IR(3) = \psi_3 = 0,6^3 = 0,216$$

Un choc unitaire aujourd'hui déplace encore la série de **0,216** dans trois périodes. La **réponse cumulée de long terme** vaut $\psi(1) = 1/(1 - 0,6) = 2,5$.

Niveau 2 — Pourquoi un MA(q) est-il toujours stationnaire, alors qu'un AR(p) ne l'est pas toujours ?

MA(q). $X_t - \mu = \epsilon_t + \theta_1\epsilon_{t-1} + \dots + \theta_q\epsilon_{t-q}$ est une **somme finie** de bruits blancs à coefficients constants. Donc

$$E(X_t) = \mu \quad \text{et} \quad \text{Var}(X_t) = \sigma^2(1 + \theta_1^2 + \dots + \theta_q^2)$$

sont **finies et indépendantes de t** , et $\gamma(j)$ ne dépend que de j . La stationnarité est **automatique**, quels que soient les θ_i .

AR(p). X_t dépend de son **propre passé**. Le processus se rétroalimente : si le coefficient est trop grand, les chocs s'accumulent au lieu de s'estomper. En développant l'AR(1) :

$$X_t = \sum_{j=0}^{\infty} \phi^j \epsilon_{t-j}$$

Cette somme **infinie** ne converge en moyenne quadratique que si $\sum_j \phi^{2j} < \infty$, soit $|\phi| < 1$. Pour $\phi = 1$ la variance est $t\sigma^2 \rightarrow \infty$; pour $\phi > 1$ elle explose géométriquement.

La formulation générale. Un AR est stationnaire quand son inverse $\phi^{-1}(L)$ existe, c'est-à-dire quand il **admet** une représentation MA(∞) convergente. La condition sur les racines est exactement la condition de convergence de cette série.

Niveau 3 — Distinguez « trend stationary » et « difference stationary », et dites pourquoi la confusion coûte cher.

Trend stationary : $X_t = a + bt + \epsilon_t$ avec ϵ_t AR(1) stationnaire.

$$E(X_t) = a + bt, \quad \text{Var}(X_t) = \frac{\sigma^2}{1 - \rho^2} \quad \text{constante}$$

Les chocs sont **transitoires** : la série revient à sa tendance déterministe. La bonne stationnarisation est de **retirer la tendance** par régression sur t .

Difference stationary (I(1)) : $X_t = X_{t-1} + \eta_t$, donc $X_t = X_0 + \sum_{j \leq t} \eta_j$.

$$\text{Var}(X_t) = t\sigma^2 \quad \text{croissante}, \quad \text{Corr}(X_t, X_{t-j}) = \sqrt{1 - j/t}$$

Les chocs sont **permanents** : il n'existe aucun niveau de référence. La bonne stationnarisation est de **différencier**.

Le coût des deux erreurs.

- **Différencier un trend stationary** : $\Delta X_t = b + (1 - L)\varepsilon_t$ contient le facteur $(1 - L)$, dont la racine $\theta(z) = 1 - z$ est **sur** le cercle unité. Le MA obtenu est **non inversible** — on parle de « sur-différenciation ». L'estimation devient instable et la prévision se dégrade.
- **Ne pas différencier un I(1)** : c'est le problème des **régressions fallacieuses**. Deux marches aléatoires **indépendantes** régressées l'une sur l'autre donnent un R^2 élevé et un t de Student très significatif — purement par artefact, parce que la corrélation $\sqrt{1 - j/t}$ reste proche de 1 sur de longs horizons. Toute l'inférence est fausse.

D'où le protocole. Tester avant de transformer. Et comme les deux familles de tests ont des H_0 opposées, faire **ADF et KPSS** et croiser leurs conclusions.

Niveau 4 — type examen — Expliquez le théorème de Wold, dites pourquoi il ne suffit pas en pratique, et comment ARMA résout le problème.

L'énoncé. Toute série stationnaire $\{X_t\}$ se décompose en $X_t = V_t + S_t$, où V_t est **linéairement déterministe** (combinaison linéaire de son propre passé à coefficients constants) et

$$S_t = \sum_{i=0}^{\infty} \psi_i \varepsilon_{t-i}, \quad \psi_0 = 1, \quad \sum_{i=0}^{\infty} \psi_i^2 < \infty$$

avec $\{\varepsilon_t\}$ un bruit blanc linéairement imprévisible ($E\varepsilon_t = 0$, $E\varepsilon_t^2 = \sigma^2$, $E\varepsilon_t \varepsilon_s = 0$ pour $s \neq t$) non corrélé avec $\{V_t\}$.

Sa portée. C'est un théorème de **structure** : il ne dit pas comment modéliser, il dit qu'il n'y a **rien d'autre** à modéliser. Toute série stationnaire est une MA(∞) plus une partie prévisible. Modéliser = estimer les $\{\psi_i\}$.

Pourquoi il ne suffit pas. Les $\{\psi_i\}$ sont en **nombre infini** et l'on ne dispose que de T observations. Le cours le dit explicitement : théoriquement $\lim_{p \rightarrow \infty} \hat{y}^{(p)} = P(Y_t | Y_{t-1}, \dots)$, mais si $p \rightarrow \infty$ est requis, il faut $n \rightarrow \infty$ avec $p/n \rightarrow 0$. On ne peut donc pas estimer directement la représentation de Wold : il faut une **paramétrisation finie**.

Comment ARMA résout le problème. ARMA(p, q) s'écrit $\phi(L)(X_t - \mu) = \theta(L)\epsilon_t$, dont la décomposition de Wold est

$$X_t = \mu + \psi(L)\epsilon_t, \quad \psi(L) = [\phi(L)]^{-1}\theta(L)$$

Les $\{\psi_i\}$ infinis sont donc engendrés comme le développement en série d'une **fraction rationnelle** de deux polynômes de degrés p et q : $p + q + 2$ paramètres seulement (avec μ et σ^2).

Pourquoi une fraction rationnelle est le bon choix. Le numérateur $\theta(L)$ crée une mémoire **courte et exacte** (autocovariances nulles au-delà de q) ; le dénominateur $\phi(L)$ crée une mémoire **longue et géométriquement décroissante** (les racines produisent des termes en λ_j^{-i}). Combiner les deux permet d'approcher n'importe quelle suite $\{\psi_i\}$ de carré sommable avec très peu de paramètres — c'est le principe des approximations de Padé, transposé aux séries temporelles.

Ce qu'il reste à faire. Choisir (p, q) — d'où AIC/BIC/HQ ; vérifier que $\phi(z) = 0$ a ses racines hors du cercle unité (stationnarité) et $\theta(z) = 0$ aussi (invertibilité) ; et si la série n'est pas stationnaire au départ, différencier d fois — d'où ARIMA(p, d, q).

● Common mistakes

1. **Confondre stationnarité stricte et stationnarité en covariance** — la première porte sur toute la loi jointe, la seconde sur les deux premiers moments seulement. Elles coïncident pour un processus gaussien.
2. **Croire que le bruit blanc de Wold est i.i.d.** — il est seulement **non corrélé**. Les rendements financiers en sont l'illustration : non corrélés mais avec des carrés fortement dépendants.
3. **Se tromper de côté sur les racines** — « hors du cercle unité » porte sur les racines de $\phi(z)$, pas sur les valeurs propres de la matrice compagnon, qui sont leurs inverses.
4. **Croire qu'un MA(q) peut être non stationnaire** — il l'est toujours ; les racines de $\theta(z)$ gouvernent l'**invertibilité**, pas la stationnarité.
5. **Utiliser les tables de Student pour Dickey-Fuller** — la loi sous H_0 est **non standard**, ses quantiles sont plus négatifs. On rejette bien trop souvent la racine unitaire sinon.
6. **Interpréter un non-rejet de ADF comme une preuve de racine unitaire** — c'est H_0 ; le non-rejet reflète souvent un simple manque de puissance. Croiser avec KPSS.
7. **Sur-différencier** — différencier une série *trend stationary* introduit un facteur $(1 - L)$ **non inversible**.
8. **Régresser deux séries I(1) sans précaution** — régression fallacieuse : R^2 élevé et t significatif sans aucune relation réelle.

9. **Comparer AIC entre modèles ajustés sur des échantillons différents** — différencier fait perdre des observations ; n doit être identique pour que les critères soient comparables.
10. **Oublier que $c = \mu\phi(1)$ et non $c = \mu$** dans l'écriture $X_t = c + \sum_j \phi_j X_{t-j} + \epsilon_t$.

Ultimate Review

1. **Série temporelle** = processus stochastique indexé par t , spécifié par toutes ses lois de dimension finie.
2. **Stationnarité stricte** : invariance de $p(\cdot)$ par translation du temps. **Stationnarité en covariance** : $E(X_t) = \mu$, $\text{Var}(X_t) = \sigma_X^2$, $\text{Cov}(X_t, X_{t+\tau}) = \gamma(\tau)$ constants.
3. **Autocorrélation** : $\rho(\tau) = \gamma(\tau)/\gamma(0)$.
4. **Wold** : $X_t = V_t + \sum_{i \geq 0} \psi_i \epsilon_{t-i}$, $\psi_0 = 1$, $\sum \psi_i^2 < \infty$, ϵ_t bruit blanc non corrélé avec V_t .
5. **Opérateur retard** : $L(X_t) = X_{t-1}$; $\psi(L) = \sum \psi_i L^i$; **réponse impulsionnelle** $IR(j) = \partial X_t / \partial \epsilon_{t-j} = \psi_j$; réponse cumulée = $\psi(1)$.
6. **Inversibilité** : si $\psi^{-1}(L)$ existe, $X_t = \sum_i \pi_i X_{t-i} + \epsilon_t$ (représentation AR).
7. **ARMA(p, q)** : $\phi(L)(X_t - \mu) = \theta(L)\epsilon_t$; Wold $\psi(L) = [\phi(L)]^{-1}\theta(L)$.
8. **AR(p)** : régression linéaire sur $(X_{t-1}, \dots, X_{t-p})$ avec $c = \mu\phi(1)$; **stationnaire ssi** toutes les racines de $\phi(z) = 0$ sont hors du cercle unité.
9. **AR(1)** : $\text{Var} = \sigma^2/(1 - \phi^2)$, $\rho(j) = \phi^j$; $0 < \phi < 1$ retour à la moyenne, $-1 < \phi < 0$ oscillant, $\phi = 1$ marche aléatoire, $\phi > 1$ explosif. Exemples : taux, spreads, changes réels, ratios de valorisation.
10. **Yule-Walker** : $\gamma(j) = \sum_k \phi_k \gamma(j-k) + \delta_{0,j} \sigma^2$; système de Toeplitz en ϕ ; $\hat{\sigma}^2 = \hat{\gamma}(0) - \sum_j \hat{\phi}_j \hat{\gamma}(j)$; **méthode des moments**.
11. **MA(q)** : toujours stationnaire ; **inversible** ssi racines de $\theta(z) = 0$ hors du cercle unité ; $\gamma(0) = \sigma^2(1 + \sum \theta_i^2)$ et $\gamma(j) = 0$ pour $j > q$.
12. **Différenciation** : $\Delta = 1 - L$; tendance linéaire $\Rightarrow \Delta$, quadratique $\Rightarrow \Delta^2$.
13. **Trend stationary** (Var constante, chocs transitoires) contre **I(1)** ($\text{Var} = t\sigma^2$, chocs permanents, $\text{Corr} = \sqrt{1 - j/t}$).
14. **ARIMA(p, d, q)** : $\{\Delta^d X_t\}$ stationnaire et ARMA(p, q).
15. **Estimation** : MV sous forme espace-état, décomposition en erreurs de prédiction, **LIML** (conditionne) ou **FIML** (loi stationnaire exacte).
16. **Sélection** : $\log \tilde{\sigma}^2(p, q) + \text{pénalité} \times \frac{p+q}{n}$, avec pénalité **2 (AIC)**, $\log n$ (**BIC**), $2 \log \log n$ (**HQ**).
17. **Dickey-Fuller** : $H_0 : \phi = 1$ contre $H_1 : |\phi| < 1$; $\hat{t} = (\hat{\phi} - 1)/se(\hat{\phi})$; sous H_0 **loi DF non standard** et $\hat{\phi}$ **super-consistant** en $1/T$.
18. **Familles de tests** : DF, ADF, PP, ERS (H_0 = non-stationnarité) · **KPSS** (H_0 = stationnarité).

Formulas to know

$$\rho(\tau) = \frac{\gamma(\tau)}{\gamma(0)} \quad \phi(L)(X_t - \mu) = \theta(L)\epsilon_t \quad \psi(L) = [\phi(L)]^{-1}\theta(L)$$

$$\text{Var}(X_t) = \frac{\sigma^2}{1 - \phi^2} \quad \text{et} \quad \rho(j) = \phi^j \quad [\text{AR}(1)] \quad \gamma(j) = 0 \quad (j > q) \quad [\text{MA}(q)]$$

$$AIC = \log \tilde{\sigma}^2 + 2 \frac{p+q}{n} \quad BIC = \log \tilde{\sigma}^2 + \log(n) \frac{p+q}{n} \quad \hat{t}_{\phi=1} = \frac{\hat{\phi} - 1}{se(\hat{\phi})}$$

Methods to know : la stratégie de Wold en 5 étapes ; la factorisation de $\phi(L)$ et l'inversion terme à terme ; la dérivation des équations de Yule-Walker ; le protocole Box-Jenkins complet.

Active Recall

Basic — Donnez la définition de la stationnarité en covariance.

$\{X_t\}$ est stationnaire en covariance si les trois quantités suivantes sont **constantes au cours du temps t** :

$$E(X_t) = \mu, \quad \text{Var}(X_t) = \sigma_X^2, \quad \text{Cov}(X_t, X_{t+\tau}) = \gamma(\tau)$$

La covariance ne dépend donc que de l'**écart τ** entre les deux dates, jamais de leur position absolue. La fonction d'autocorrélation est $\rho(\tau) = \gamma(\tau)/\gamma(0)$.

Understanding — Énoncez le théorème de Wold et dites ce qu'il garantit exactement.

Toute série stationnaire se décompose en $X_t = V_t + S_t$ avec V_t **linéairement déterministe** et $S_t = \sum_{i \geq 0} \psi_i \epsilon_{t-i}$ une **MA(∞)**, où $\psi_0 = 1$, $\sum \psi_i^2 < \infty$, $\{\epsilon_t\}$ est un bruit blanc linéairement imprévisible et $E(\epsilon_t V_s) = 0$.

Ce qu'il garantit : qu'il n'existe **aucune autre structure**. Une série stationnaire est nécessairement une partie prévisible plus une moyenne mobile infinie d'innovations. C'est un théorème d'**existence et d'exhaustivité**, pas une méthode.

Ce qu'il ne donne pas : un modèle estimable. Les $\{\psi_i\}$ sont en nombre infini ; d'où ARMA, qui les engendre par une fraction rationnelle à peu de paramètres.

Application — Comment reconnaître un AR d'un MA à partir de l'autocorrélogramme empirique ?

MA(q) : $\gamma(j) = 0$ pour $j > q$. L'autocorrélogramme **coupe net** après le retard q puis reste dans les bandes de confiance. Raison : X_t et X_{t+j} ne partagent **aucune innovation commune** au-delà de la mémoire q du filtre.

AR(p) : l'autocorrélation **décroît géométriquement** sans jamais s'annuler exactement — pour un AR(1), $\rho(j) = \phi^j$ exactement. Raison : la représentation de Wold est une MA(∞), donc toutes les autocovariances sont non nulles.

Le complément indispensable : l'autocorrélogramme **partiel** (PACF), qui présente la coupure symétrique — nette après p pour un AR(p), décroissance pour un MA. En pratique on lit ACF **et** PACF ensemble, puis on confirme par AIC/BIC.

Comparison — AIC, BIC et HQ : même structure, quelle différence ?

Les trois ont la forme $\log(\tilde{\sigma}^2(p, q)) + c_n \cdot \frac{p+q}{n}$, où $\tilde{\sigma}^2$ est l'EMV de la variance des innovations. **Seule la pénalité c_n change** :

Critère	c_n	Effet
AIC	2	pénalité la plus faible $\Rightarrow$ modèles plus riches
HQ	$2 \log \log(n)$	intermédiaire
BIC	$\log(n)$	pénalité la plus forte (dès $n > 7$) $\Rightarrow$ modèles plus parcimonieux

Le principe commun : premier terme = qualité d'ajustement, second terme = prix de la complexité. Sans pénalité, on choisirait toujours le modèle le plus gros.

Lequel choisir ? Le **BIC** est *consistant* : si le vrai modèle est dans la liste, il le retrouve quand $n \rightarrow \infty$. L'**AIC** ne l'est pas mais est *efficace* pour la prévision. En finance, où le vrai modèle n'est jamais dans la liste, l'AIC se défend bien.

Exam-style — Décrivez le test de Dickey-Fuller, son asymptotique, et pourquoi on ne peut pas y utiliser les tables usuelles.

Le cadre. $X_t = \phi X_{t-1} + \epsilon_t$ avec $\{\epsilon_t\} \sim WN(0, \sigma^2)$, et l'on teste

$H_0 : \phi = 1$ (racine unitaire, non-stationnarité) contre $H_1 : |\phi| < 1$ (stationnarité)

On ajuste par moindres carrés et l'on forme $\hat{t}_{\phi=1} = (\hat{\phi} - 1)/se(\hat{\phi})$.

L'asymptotique — deux régimes complètement différents.

- Si $|\phi| < 1$: $\sqrt{T}(\hat{\phi} - \phi) \xrightarrow{d} N(0, (1 - \phi^2))$ — vitesse standard $1/\sqrt{T}$, loi limite normale.
- Si $\phi = 1$: $\hat{\phi}$ est **super-consistant**, de vitesse $1/T$, et $\hat{t}_{\phi=1}$ suit la **distribution de Dickey-Fuller**.

Pourquoi les tables usuelles sont invalides. Sous H_0 , le régresseur X_{t-1} n'est pas stationnaire : sa variance croît en t . Les conditions du théorème central limite standard tombent, et la loi limite s'exprime comme une fonctionnelle de mouvement brownien — non standard, **asymétrique vers la gauche**, avec des quantiles nettement plus négatifs que ceux de Student. Utiliser Student conduirait à **rejeter la racine unitaire beaucoup trop souvent**.

Et l'idée derrière la super-consistance. Sous racine unitaire, la variance du régresseur explose avec t ; la régression dispose donc d'une information bien plus riche que dans le cas stationnaire, d'où une convergence en $1/T$ au lieu de $1/\sqrt{T}$.

Les extensions et le complément. ADF (Said et Dickey, 1984) ajoute des retards pour absorber l'autocorrélation résiduelle ; PP (Phillips et Perron, 1988) corrige non paramétriquement ; ERS (Elliot, Rothenberg et Stock, 2001) améliore la puissance. Et **KPSS** (Kwiatkowski *et al.*, 1992) renverse l'hypothèse nulle : H_0 y est la **stationnarité**. On croise les deux, car un non-rejet de ADF reflète souvent un simple manque de puissance.

Flashcards

Question	Réponse
Stationnarité stricte ?	Invariance de toutes les lois jointes par translation du temps
Stationnarité en covariance ?	$E(X_t), \text{Var}(X_t), \text{Cov}(X_t, X_{t+\tau})$ constants en t
Fonction d'autocorrélation ?	$\rho(\tau) = \gamma(\tau)/\gamma(0)$
Théorème de Wold ?	$X_t = V_t + \sum_{i \geq 0} \psi_i \epsilon_{t-i}, \psi_0 = 1, \sum \psi_i^2 < \infty$
Le bruit blanc de Wold est-il i.i.d. ?	Non — seulement non corrélé
Opérateur retard ?	$L(X_t) = X_{t-1}, L^n(X_t) = X_{t-n}$
Réponse impulsionnelle ?	$IR(j) = \partial X_t / \partial \epsilon_{t-j} = \psi_j$
Réponse cumulée de long terme ?	$\psi(1) = \sum_i \psi_i$
Représentation AR d'un processus inversible ?	$X_t = \sum_i \pi_i X_{t-i} + \epsilon_t$
Écriture ARMA(p, q) ?	$\phi(L)(X_t - \mu) = \theta(L)\epsilon_t$
Wold d'un ARMA ?	$\psi(L) = [\phi(L)]^{-1}\theta(L)$
Condition de stationnarité d'un AR(p) ?	Racines de $\phi(z) = 0$ hors du cercle unité
Constante d'un AR(p) en régression ?	$c = \mu \cdot \phi(1)$
Variance d'un AR(1) ?	$\sigma^2 / (1 - \phi^2)$
Autocorrélation d'un AR(1) ?	$\rho(j) = \phi^j$
AR(1) avec $\phi = 1$?	Marche aléatoire , non stationnaire, pas de Wold
Exemples financiers d'AR(1) ?	Taux d'intérêt (Vasicek), spreads, changes réels, ratios de valorisation
Équations de Yule-Walker ?	$\gamma(j) = \sum_k \phi_k \gamma(j - k) + \delta_{0,j} \sigma^2$
Estimateur de σ^2 par Yule-Walker ?	$\hat{\gamma}(0) - \sum_j \hat{\phi}_j \hat{\gamma}(j)$
Principe d'estimation de Yule-Walker ?	Méthode des moments

Question	Réponse
Un MA(q) est-il stationnaire ?	Toujours — les racines gouvernent l'inversibilité
Autocovariance d'un MA(q) au-delà de q ?	Nulle
Variance d'un MA(q) ?	$\sigma^2(1 + \theta_1^2 + \dots + \theta_q^2)$
Opérateur de différenciation ?	$\Delta = 1 - L$; $\Delta^k = (1 - L)^k$
Variance d'une marche aléatoire ?	$t\sigma^2$ — croissante, donc non stationnaire
$\text{Corr}(X_t, X_{t-j})$ pour une marche aléatoire ?	$\sqrt{1 - j/t}$
ARIMA(p, d, q) ?	$\Delta^d X_t$ stationnaire et ARMA(p, q)
LIML contre FIML ?	LIML conditionne sur les p premières valeurs ; FIML utilise leur loi stationnaire exacte
Pénalités AIC / BIC / HQ ?	$2 \cdot \log(n) \cdot 2 \log \log(n)$, le tout $\times \frac{p+q}{n}$
Hypothèses du test de Dickey-Fuller ?	$H_0 : \phi = 1$ (racine unitaire) contre $H_1 : \phi < 1$
Loi de $\hat{t}$ sous H_0 ?	Distribution de Dickey-Fuller , non standard
Vitesse de convergence sous H_0 ?	$1/T$ — $\hat{\phi}$ est super-consistant
Le test dont H_0 est la stationnarité ?	KPSS (Kwiatkowski, Phillips, Schmidt et Shin, 1992)