

Fiche 53 — Modélisation de la volatilité : historique, brownien, sauts, ARCH et GARCH

Matière	Maths · Finance de marché
Cours source	Kempthorne, <i>18.S096 Topics in Mathematics with Applications in Finance</i> , MIT OpenCourseWare, automne 2013 — cours 9 « Volatility Modeling »
Difficulté	Must know — la variable centrale de la gestion des risques
Temps d'étude estimé	2 h 30
Prérequis	Fiche 50 (moindres carrés, maximum de vraisemblance), fiche 52 (ARMA, stationnarité, AIC/BIC)
Concepts clés	Volatilité annualisée, moyennes mobiles exponentielles, RiskMetrics, mouvement brownien géométrique, estimateur de Garman-Klass, efficacité relative, diffusion à sauts de Poisson, ARCH, test du multiplicateur de Lagrange, GARCH, variance de long terme, faits stylisés
Poids à l'examen	Trois résultats : la loi des log-rendements sous le brownien géométrique (attention au $-\sigma^2/2$), l' équivalence GARCH(1,1) $\Leftrightarrow$ ARMA(1,1) en ε_t^2 , et la variance de long terme $\alpha_0/(1 - \alpha_1 - \beta_1)$.

Vue d'ensemble

DÉFINITION DE BASE.

La volatilité est l'**écart-type annualisé de la variation du prix** ou de la valeur d'un titre financier.

Les approches d'estimation et de prédiction listées par le cours :

- Mesures de volatilité **historique** ou empirique
- Modèle de **mouvement brownien géométrique**
- Modèle de **diffusion à sauts de Poisson**
- Modèles **ARCH / GARCH**
- Modèles à **volatilité stochastique (SV)**
- Volatilité **implicite** issue des options et dérivés

HISTORIQUE	σ^2 à partir des rendements passés – simple, mais lent à réagir
GBM	$dS/S = \mu dt + \sigma dW$ – σ constante, l'hypothèse de Black-Scholes
GARMAN-KLASS	exploiter haut/bas/ouverture : jusqu'à 8× plus efficace
SAUTS	$+ Z(t) d\pi(t)$ – pour les krachs que le brownien ne produit jamais
ARCH/GARCH	σ_t^2 dépend du passé – la volatilité devient PRÉVISIBLE

Le fil directeur du chapitre. On part d'une volatilité **constante** (GBM), puis on découvre que les données la contredisent — la volatilité **se regroupe** dans le temps — et l'on construit des modèles où σ_t^2 est **une fonction déterministe du passé observable**. C'est l'idée d'Engle (1982), qui lui a valu le prix Nobel.

● Concept 1 — La volatilité historique

Le calcul. On dispose des prix d'un actif en $(T + 1)$ instants, $\{P_t, t = 0, 1, \dots, T\}$, d'où T rendements

$$R_t = \log(P_t/P_{t-1}), \quad t = 1, 2, \dots, T$$

On suppose $\{R_t\}$ **stationnaire en covariance**, avec

$$\sigma^2 = \text{var}(R_t) = E[(R_t - E[R_t])^2]$$

et l'on estime

$$\hat{\sigma}^2 = \frac{1}{T-1} \sum_{t=1}^T (R_t - \bar{R})^2, \quad \bar{R} = \frac{1}{T} \sum_{t=1}^T R_t$$

L'annualisation.

$$\text{vol} = \begin{cases} \sqrt{252} \hat{\sigma} & \text{(prix quotidiens, 252 jours ouvrés par an)} \\ \sqrt{52} \hat{\sigma} & \text{(prix hebdomadaires)} \\ \sqrt{12} \hat{\sigma} & \text{(prix mensuels)} \end{cases}$$

Pourquoi une racine carrée ? Parce que sous indépendance des rendements les **variances** s'additionnent : $\text{var}(\sum_{t=1}^{252} R_t) = 252\sigma^2$, donc l'écart-type est multiplié par $\sqrt{252}$. La règle « en racine du temps » n'est valable que **sous indépendance** — dès qu'il y a autocorrélation des rendements, elle est fautive.

Pourquoi les log-rendements et non les rendements arithmétiques ? Parce qu'ils sont **additifs** dans le temps : $\log(P_T/P_0) = \sum_t \log(P_t/P_{t-1})$. C'est ce qui rend l'agrégation temporelle exacte.

● Concept 2 — Prédire la volatilité à partir de son historique

DÉFINITION.

Pour une période t , on définit la **volatilité empirique** $\hat{\sigma}_t$ = écart-type empirique des rendements de la période t .

- Si t indexe des **mois** avec des données quotidiennes, $\hat{\sigma}_t$ est l'écart-type empirique des rendements quotidiens du mois t .
- Si t indexe des **jours** avec des données quotidiennes, alors $\hat{\sigma}_t^2 = R_t^2$.
- Avec des données **haute fréquence**, $\hat{\sigma}_t$ quotidien s'obtient en **cumulant les carrés des rendements intra-journaliers**.

La deuxième ligne mérite qu'on s'y arrête. Avec une seule observation par période, le « carré du rendement » est l'estimateur de la variance. Il est **sans biais** mais extraordinairement **bruité** — sa variance vaut $2\sigma^4$. C'est exactement pourquoi les données intra-journalières valent de l'or : elles réduisent ce bruit d'un facteur égal au nombre de sous-périodes.

Les prédicteurs.

Méthode	Formule	Données utilisées
Moyenne historique	$\hat{\sigma}_{t+1}^2 = \frac{1}{t} \sum_{j=1}^t \hat{\sigma}_j^2$	toutes les données disponibles
Moyenne mobile simple	$\hat{\sigma}_{t+1}^2 = \frac{1}{m} \sum_{j=0}^{m-1} \hat{\sigma}_{t-j}^2$	les m dernières estimations
Moyenne mobile exponentielle	$\hat{\sigma}_{t+1}^2 = (1 - \beta)\hat{\sigma}_t^2 + \beta\hat{\sigma}_{t-1}^2, 0 \leq \beta \leq 1$	toutes les données disponibles
Moyenne mobile exponentielle pondérée	$\hat{\sigma}_{t+1}^2 = \left(\sum_{j=0}^{m-1} \beta^j \hat{\sigma}_{t-j}^2 \right) / \left(\sum_{j=0}^{m-1} \beta^j \right)$	les m dernières

La moyenne mobile exponentielle est la forme la plus utilisée. Elle est **réursive** — un seul nombre à stocker — et donne un poids β^j à l'observation d'il y a j périodes : la mémoire décroît géométriquement. Le paramètre β règle l'arbitrage entre réactivité (β petit) et stabilité (β grand).

Régression simple.

$$\tilde{\sigma}_{t+1}^2 = \gamma_{1,t}\hat{\sigma}_t^2 + \gamma_{2,t}\hat{\sigma}_{t-1}^2 + \dots + \gamma_{p,t}\hat{\sigma}_{t-p+1}^2 + u_t$$

La régression peut être ajustée sur toutes les données, ou sur les m dernières (fenêtres glissantes). Note : similaire mais différente d'un modèle autorégressif de $\hat{\sigma}_t^2$.

La nuance signalée par le cours. Dans une AR, la variable expliquée et les régresseurs sont **le même processus**. Ici la variable expliquée est la **prévision** $\tilde{\sigma}_{t+1}^2$ et les régresseurs des **estimations empiriques** $\hat{\sigma}_{t-j}^2$ — deux objets distincts, dont les coefficients $\gamma_{j,t}$ peuvent en outre varier avec t .

Les arbitrages.

- Utiliser **plus de données** pour augmenter la **précision** des estimateurs.
- Utiliser des données **plus proches de t** pour estimer σ_t .

C'est un arbitrage biais-variance pur. Plus de données réduisent la variance mais font entrer des régimes de volatilité anciens — donc du biais. La fenêtre optimale dépend de la vitesse à laquelle la volatilité change.

L'évaluation se fait **hors échantillon** : distinguer les actifs et les classes d'actifs, considérer différentes fréquences d'échantillonnage et différents horizons de prévision, et appliquer des mesures de performance (MSE, MAE, MAPE, etc.). **Méthodologie de référence : RiskMetrics.**

● Concept 3 — Le mouvement brownien géométrique

Le modèle. Pour $\{S(t)\}$ le prix d'un titre ou d'un portefeuille au temps t :

$$dS(t) = \mu S(t) dt + \sigma S(t) dW(t)$$

où σ est la **volatilité** du processus de prix, μ le **rendement moyen** par unité de temps, $dS(t)$ l'incrément infinitésimal de prix et $dW(t)$ l'incrément infinitésimal d'un **mouvement brownien standard** (processus de Wiener).

Les propriétés du processus de Wiener.

- Les incréments $[W(t') - W(t)]$ sont **gaussiens**, de moyenne nulle et de variance $(t' - t)$.
- Les incréments sur des **intervalles disjoints sont indépendants** : pour $t_1 < t_2 < t_3 < t_4$, $[W(t_2) - W(t_1)]$ et $[W(t_4) - W(t_3)]$ sont indépendants.

Les données du processus. Prix $\{S(t), t = t_0, t_1, \dots, t_n\}$, rendements

$$R_j = \log [S(t_j)/S(t_{j-1})], \quad j = 1, \dots, n$$

Résultat. Les R_j sont des variables aléatoires **indépendantes** avec

$$R_j \sim N(\mu^* \tau_j, \sigma^2 \tau_j), \quad \tau_j = (t_j - t_{j-1}), \quad \boxed{\mu^* = \mu - \sigma^2/2}$$

($\{\log S(t)\}$ est un mouvement brownien de dérive μ^* et de volatilité σ^2 .)

Le terme $-\sigma^2/2$ est l'erreur classique du chapitre. Le prix a un rendement espéré μ , mais son **logarithme** dérive à $\mu - \sigma^2/2$. La raison est l'inégalité de Jensen : **log** est concave, donc $E[\log S] < \log E[S]$, et l'écart est exactement $\sigma^2/2$ par unité de temps. Conséquence économique : **plus la volatilité est forte, plus la médiane du prix futur est basse à rendement espéré fixé.**

Estimation par maximum de vraisemblance. Si $\tau_j \equiv 1$:

$$\hat{\mu}^* = \bar{R} = \frac{1}{n} \sum_{t=1}^n R_t, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{t=1}^n (R_t - \bar{R})^2$$

Si τ_j varie... exercice.

Noter le diviseur n et non $n - 1$: ce sont les estimateurs du **maximum de vraisemblance**, donc biaisés pour σ^2 — exactement comme dans la fiche 50.

● Concept 4 — L'estimateur de Garman-Klass

L'idée. On dispose de plus d'information que les seuls prix de clôture : on a aussi le **plus haut**, le **plus bas** et l'**ouverture** de la période. On suppose $\mu = 0, \tau_j \equiv 1$ (par exemple quotidien), et l'on note $f \in (0, 1)$ la fraction de la journée précédant l'ouverture du marché :

$$C_j = \log[S(t_j)], \quad O_j = \log[S(t_{j-1} + f)], \quad H_j = \max_{t_{j-1}+f \leq t \leq t_j} \log[S(t)], \quad L_j = \min_{t_{j-1}+f \leq t \leq t_j} \log[S(t)]$$

Les estimateurs élémentaires (données de la première période).

Estimateur	Formule	Espérance	Variance
$\hat{\sigma}_0^2$ — clôture à clôture	$(C_1 - C_0)^2$	σ^2	$2(\sigma^2)^2 = 2\sigma^4$
$\hat{\sigma}_1^2$ — clôture à ouverture	$\frac{(O_1 - C_0)^2}{f}$	σ^2	$2\sigma^4$
$\hat{\sigma}_2^2$ — ouverture à clôture	$\frac{(C_1 - O_1)^2}{1 - f}$	σ^2	$2\sigma^4$

Note : $\hat{\sigma}_1^2$ et $\hat{\sigma}_2^2$ sont **indépendants** ! On peut donc les combiner :

$$\hat{\sigma}^2 = \frac{1}{2}\hat{\sigma}_1^2 + \frac{1}{2}\hat{\sigma}_2^2, \quad E[\hat{\sigma}^2] = \sigma^2, \quad \text{var}[\hat{\sigma}^2] = \sigma^4$$

d'où l'**efficacité**

$$\text{Eff}(\hat{\sigma}^2) = \frac{\text{var}(\hat{\sigma}_0^2)}{\text{var}(\hat{\sigma}^2)} = 2$$

La logique de tout le concept. L'indépendance permet de **moyenner** deux estimateurs sans biais, ce qui **divise la variance par deux** — pour exactement le même échantillon de prix. On n'a rien ajouté comme données : on a seulement mieux exploité celles qu'on avait.

Les raffinements successifs.

Estimateur	Formule	Efficacité
Parkinson (1976), $f = 0$	$\hat{\sigma}_3^2 = \frac{(H_1 - L_1)^2}{4 \log 2}$	$\approx 5,2$
Garman et Klass (1980), tout $0 < f < 1$	$\hat{\sigma}_4^2 = a \cdot \hat{\sigma}_1^2 + (1 - a) \hat{\sigma}_3^2$, variance minimale pour $a \approx 0,17$ (indépendant de f)	$\approx 6,2$
Meilleur estimateur analytique invariant d'échelle	$\hat{\sigma}^2 = 0,511(u_1 - d_1)^2 - 0,019\{c_1(u_1 + d_1) - 2u_1d_1\} - 0,383c_1^2$	$\approx 7,4$
Estimateur composite ($0 < f < 1$)	$\hat{\sigma}_{GK}^2 = a \frac{(O_1 - C_0)^2}{f} + (1 - a) \frac{\hat{\sigma}_{\text{analytique}}^2}{1 - f}$, variance minimale pour $a = 0,12$	$\approx 8,4$

où les valeurs haut / bas / clôture **normalisées** sont

$$u_j = H_j - O_j, \quad d_j = L_j - O_j, \quad c_j = C_j - O_j$$

CE QUE « EFFICACITÉ 8,4 » VEUT DIRE CONCRÈTEMENT.

Il faudrait **8,4 fois plus de jours** d'observation à l'estimateur clôture-à-clôture pour atteindre la même précision. Sur un an de données quotidiennes, c'est l'équivalent de plus de huit ans — sans rien changer aux données collectées. C'est un des meilleurs rapports gain/effort de toute la finance empirique.

Les hypothèses restent fortes : $\mu = 0$ (dérive négligeable, raisonnable en quotidien) et surtout un brownien **sans saut**. Les gaps d'ouverture et les cotations discrètes dégradent ces efficacités théoriques en pratique.

● Concept 5 — Diffusions à sauts de Poisson

Pour $\{S(t)\}$ le processus de prix du titre ou du portefeuille au temps t :

$$\frac{dS(t)}{S(t)} = \mu dt + \sigma dW(t) + \gamma Z(t) d\pi(t)$$

où

- $dS(t)$ = incrément infinitésimal de prix ;

- μ = rendement moyen par unité de temps ;
- σ = **volatilité de diffusion** du processus de prix ;
- $dW(t)$ = incrément d'un processus de Wiener standard ;
- $d\pi(t)$ = incrément d'un **processus de Poisson d'intensité λ** , modélisant le processus de sauts ;
- $\gamma \cdot Z(t)$ = **amplitude** du saut de rendement, avec $Z(t)$ i.i.d. $N(0, 1)$ et γ l'**échelle** des amplitudes de saut.

Estimation par maximum de vraisemblance.

- Le modèle est un **mélange poissonien de lois gaussiennes**.
- La fonction génératrice des moments se dérive comme celle d'une **somme aléatoire de variables indépendantes**.
- La fonction de vraisemblance est un **produit de sommes infinies**.
- L'**algorithme EM** s'exprime sous forme close : les **sauts sont traités comme des variables latentes**, ce qui simplifie les calculs, et l'algorithme fournit des estimations *a posteriori* du **nombre de sauts par période**.

POURQUOI AJOUTER DES SAUTS.

Un brownien géométrique ne produit **jamais** de krach : ses trajectoires sont continues, et un mouvement de **−20 %** en une séance a une probabilité astronomiquement nulle sous σ réaliste. Les sauts de Poisson introduisent des **discontinuités** et, du même coup, des **queues épaisses** — le fait stylisé du concept 9.

L'astuce de l'EM mérite d'être comprise. La vraisemblance directe est un produit de sommes infinies sur le nombre de sauts — impraticable. En traitant le nombre de sauts comme une **donnée manquante**, chaque étape M devient une simple estimation gaussienne pondérée. C'est le même principe que pour les mélanges gaussiens en général.

• Concept 6 — Les modèles ARCH

Les modèles ARCH sont spécifiés relativement au processus en **temps discret** du prix, $\{S_t, t = 1, 2, \dots\}$. **Engle (1982)** modélise les rendements discrets $y_t = \log(S_t/S_{t-1})$ par

$$y_t = \mu_t + \varepsilon_t$$

où μ_t est le rendement moyen **conditionnel** à $\mathcal{F}_{t-1}$, l'information disponible jusqu'au temps $(t - 1)$, et

$$\varepsilon_t = Z_t \cdot \sigma_t, \quad Z_t \text{ i.i.d. avec } E[Z_t] = 0, \text{ var}[Z_t] = 1$$

$$\sigma_t^2 = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \alpha_2 \varepsilon_{t-2}^2 + \cdots + \alpha_p \varepsilon_{t-p}^2$$

Contraintes de paramètres : $\alpha_j \geq 0, j = 0, 1, \dots, p$.

$\sigma_t^2 = \text{var}(R_t \mid \mathcal{F}_{t-1})$ est l'**hétéroscédasticité conditionnelle** des rendements.

Lisez bien la structure. σ_t^2 n'est **pas** aléatoire conditionnellement au passé : c'est une **fonction déterministe** des chocs passés observés. Toute la nouveauté d'Engle tient là — la variance devient **prévisible** sans cesser d'être une variance conditionnelle. Et les contraintes $\alpha_j \geq 0$ sont là pour une raison élémentaire : une variance doit rester positive.

L'équivalence avec un modèle AR

Le modèle ARCH implique un **modèle AR en ε_t^2** . On ajoute $(\varepsilon_t^2 - \sigma_t^2) = u_t$ des deux côtés :

$$\varepsilon_t^2 = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \alpha_2 \varepsilon_{t-2}^2 + \cdots + \alpha_p \varepsilon_{t-p}^2 + u_t$$

où

$$E[u_t \mid \mathcal{F}_t] = 0 \quad \text{et} \quad \text{var}[u_t \mid \mathcal{F}_t] = \text{var}(\varepsilon_t^2) = 2\sigma_t^4$$

C'est le pont avec la fiche 52. Un ARCH(p) **est** une AR(p) — non pas sur les rendements, mais sur leurs **carrés**. Tous les outils du chapitre précédent (racines du polynôme caractéristique, stationnarité, Yule-Walker) se transposent directement.

Le test du multiplicateur de Lagrange

$$H_0 : \alpha_1 = \alpha_2 = \cdots = \alpha_p = 0$$

1. Ajuster une **régression linéaire sur les résidus au carré** $\hat{\varepsilon}_t = y_t - \hat{\mu}_t$ — c'est-à-dire ajuster un modèle **AR(p)** à $[\hat{\varepsilon}_t^2], t = 1, \dots, n$.
2. La **statistique LM** vaut nR^2 , où R^2 est le coefficient de détermination du modèle AR(p) ajusté.
3. Sous H_0 , la variable aléatoire nR^2 suit approximativement une loi χ^2 à p degrés de liberté.

*Note : les estimations des paramètres par régression linéaire **ne sont pas** les EMV sous hypothèses gaussiennes ; elles correspondent à des estimations de **quasi-maximum de vraisemblance (QMLE)**.*

H_0 signifie « pas d'effet ARCH », donc volatilité conditionnelle constante. Rejeter H_0 , c'est établir la présence de **regroupement de volatilité**. Sur des rendements financiers quotidiens, ce test rejette presque toujours — et de façon spectaculaire.

Estimation par maximum de vraisemblance

Modèle ARCH. $y_t = c + \varepsilon_t$, $\varepsilon_t = z_t \sigma_t$, $\sigma_t^2 = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \dots + \alpha_p \varepsilon_{t-p}^2$, $t = 0, 1, \dots, T$.

Vraisemblance.

$$L(c, \alpha) = p(y_1, \dots, y_n \mid c, \alpha_0, \alpha_1, \dots, \alpha_p) = \prod_{t=1}^n p(y_t \mid \mathcal{F}_{t-1}, c, \alpha) = \prod_{t=1}^n \left[\frac{1}{\sqrt{2\pi\sigma_t^2}} \exp\left(-\frac{1}{2} \frac{\varepsilon_t^2}{\sigma_t^2}\right) \right]$$

où $\varepsilon_t = y_t - c$ et $\sigma_t^2 = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \dots + \alpha_p \varepsilon_{t-p}^2$.

Contraintes. $\alpha_i \geq 0$ pour $i = 1, \dots, p$, et $(\alpha_1 + \dots + \alpha_p) < 1$.

La factorisation $\prod_t p(y_t \mid \mathcal{F}_{t-1})$ est ce qui rend le calcul possible. C'est la **décomposition en erreurs de prédiction** déjà vue en fiche 52 : chaque facteur est une densité gaussienne **univariée** de variance σ_t^2 , calculable récursivement. On n'a jamais à inverser une matrice de covariance $T \times T$.

● Concept 7 — Les modèles GARCH

Bollerslev (1986) étend les modèles ARCH :

Modèle GARCH(p, q).

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^p \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^q \beta_j \sigma_{t-j}^2$$

Contraintes : $\alpha_i \geq 0 \forall i$, et $\beta_j \geq 0 \forall j$.

Modèle GARCH(1,1).

$$\sigma_t^2 = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \beta_1 \sigma_{t-1}^2$$

Parcimonieux · s'ajuste à de nombreuses séries financières

POURQUOI GARCH(1,1) SUFFIT PRESQUE TOUJOURS.

Le terme $\beta_1 \sigma_{t-1}^2$ résume **tout** le passé : en développant récursivement, $\sigma_t^2 = \frac{\alpha_0}{1-\beta_1} + \alpha_1 \sum_{k \geq 0} \beta_1^k \varepsilon_{t-1-k}^2$. Autrement dit, **GARCH(1,1) est un ARCH(∞) à poids géométriques**, avec trois paramètres seulement. C'est exactement le mouvement AR/MA de la fiche 52, transposé aux carrés.

L'équivalence avec un ARMA(1,1)

Le GARCH(1,1) implique un modèle **ARMA** en ε_t^2 . On élimine σ_t^2 à l'aide de $(\varepsilon_t^2 - \sigma_t^2) = u_t$:

$$\varepsilon_t^2 - u_t = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \beta_1 (\varepsilon_{t-1}^2 - u_{t-1})$$

$$\varepsilon_t^2 = \alpha_0 + (\alpha_1 + \beta_1) \varepsilon_{t-1}^2 + u_t - \beta_1 u_{t-1}$$

où $E[u_t | \mathcal{F}_t] = 0$ et $\text{var}[u_t | \mathcal{F}_t] = \text{var}(\varepsilon_t^2) = 2\sigma_t^4$.

GARCH(1,1) implique donc un ARMA(1,1) en ε_t^2 , avec $u_t = (\varepsilon_t^2 - \sigma_t^2) \sim WN(0, 2\sigma^4)$.

Stationnarité. Elle se déduit du modèle ARMA. En écrivant $A(L)\varepsilon_t^2 = B(L)u_t$, soit $\varepsilon_t^2 = [A(L)]^{-1}B(L)u_t$, le processus est **stationnaire en covariance** si les racines de $A(z)$ sont hors de $\{|z| \leq 1\}$, c'est-à-dire

$$|\alpha_1 + \beta_1| < 1$$

Volatilité inconditionnelle / variance de long terme. Pour GARCH(1,1), en supposant la stationnarité $0 < (\alpha_1 + \beta_1) < 1$:

$$\sigma^2 = \alpha_0 + (\alpha_1 + \beta_1)\sigma^2 \quad \implies \quad \sigma^2 = \frac{\alpha_0}{1 - \alpha_1 - \beta_1}$$

Le cas général. GARCH(p, q) implique un modèle **ARMA(max(p, q), q)**, stationnaire si

$$0 < \left(\sum_{i=1}^p \alpha_i + \sum_{j=1}^q \beta_j \right) < 1$$

et de variance de long terme

$$\sigma^2 = \frac{\alpha_0}{1 - \sum_{i=1}^{\max(p,q)} (\alpha_i + \beta_i)}$$

La somme $\alpha_1 + \beta_1$ est le nombre à regarder en premier sur une sortie de logiciel. Sur des séries financières réelles elle vaut typiquement **0,95–0,99** : la volatilité est **très persistante**, le retour à la moyenne est lent. Si l'estimation donne $\alpha_1 + \beta_1 \geq 1$, le modèle n'est **pas stationnaire** et la variance de long terme n'existe pas — c'est le cas limite IGARCH, qui est précisément ce que fait la méthodologie RiskMetrics avec $\alpha_0 = 0$ et $\alpha_1 + \beta_1 = 1$.

Estimation par maximum de vraisemblance

Modèle GARCH. $y_t = c + \varepsilon_t$, $\varepsilon_t = z_t \sigma_t$, $\sigma_t^2 = \alpha_0 + \sum_{i=1}^p \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^q \beta_j \sigma_{t-j}^2$.

Vraisemblance.

$$L(c, \alpha, \beta) = \prod_{t=1}^T p(y_t \mid \mathcal{F}_{t-1}, c, \alpha, \beta) = \prod_{t=1}^T \left[\frac{1}{\sqrt{2\pi\sigma_t^2}} \exp \left(-\frac{1}{2} \frac{\varepsilon_t^2}{\sigma_t^2} \right) \right]$$

avec $\varepsilon_t = y_t - c$.

Contraintes. $\alpha_i \geq 0 \forall i$, $\beta_j \geq 0 \forall j$, et $0 < \left(\sum_{i=1}^p \alpha_i + \sum_{j=1}^q \beta_j \right) < 1$.

● Concept 8 — Estimation, évaluation et sélection

Les sorties de l'estimation. Estimations du maximum de vraisemblance $\hat{c}$, $\hat{\alpha}$, $\hat{\beta}$, d'où $\hat{\varepsilon}_t$ et $\hat{\sigma}_t^2$ pour $t = T, T-1, \dots$

Les diagnostics.

- **Résidus standardisés** $\hat{\varepsilon}_t / \hat{\sigma}_t$: devraient être non corrélés.
- **Résidus standardisés au carré** $(\hat{\varepsilon}_t / \hat{\sigma}_t)^2$: devraient être non corrélés.

Les deux diagnostics testent deux choses différentes. Le premier vérifie qu'il ne reste pas de structure dans la **moyenne** ; le second, qu'il n'en reste pas dans la **variance** — c'est-à-dire que le modèle GARCH a bien absorbé tout le regroupement de volatilité. C'est le second qui compte ici : c'est la raison d'être du modèle.

Tests de normalité des résidus. Diagrammes quantile-quantile normaux · test de **Jarque-Bera** · test de **Shapiro-Wilk** · test d'adéquation par les **percentiles de l'EMV** · test d'adéquation de **Kolmogorov-Smirnov**.

Sélection de modèle. On applique les critères de sélection : **AIC** (critère d'information d'Akaike) et **BIC** (critère d'information bayésien) — voir la fiche 52 pour leurs formules et leur arbitrage.

Un résultat très fréquent en pratique. Même après un bon ajustement GARCH, les résidus standardisés **restent non gaussiens** : les tests de normalité rejettent. Le GARCH explique une partie des queues épaisses, pas toutes. La réponse usuelle est de remplacer la loi de Z_t par une **loi de Student** à faible nombre de degrés de liberté.

● Concept 9 — Les faits stylisés des rendements et de la volatilité

1. Regroupement de volatilité (*volatility clustering*)

Les grands ε_t^2 suivent les grands ε_{t-1}^2 Les petits ε_t^2 suivent les petits ε_{t-1}^2

Les modèles GARCH peuvent **prescrire** que les grands σ_t^2 suivent les grands σ_{t-1}^2 , et les petits σ_t^2 les petits σ_{t-1}^2 .

2. Queues épaisses (*heavy tails / fat tails*)

*La distribution des rendements a des queues plus épaisses (**kurtosis plus élevée**) que la gaussienne.*

Les modèles GARCH(p, q) sont un **mélange stochastique de lois gaussiennes**, de kurtosis plus élevée. — Engle, Bollerslev et Nelson (1994)

C'est un point conceptuel important. Chaque rendement est gaussien **conditionnellement** à σ_t^2 , mais la loi **inconditionnelle** — le mélange sur toutes les valeurs possibles de σ_t^2 — a des queues plus épaisses qu'une gaussienne. Un mélange de gaussiennes de variances différentes est toujours leptokurtique. Le GARCH produit donc les queues épaisses **sans jamais poser d'hypothèse non gaussienne**.

3. Retour à la moyenne de la volatilité

Modèle GARCH(1,1). Volatilité moyenne de long terme :

$$\sigma^2 = \frac{\alpha_0}{1 - \alpha_1 - \beta_1}$$

En partant de

$$\varepsilon_t^2 = \alpha_0 + (\alpha_1 + \beta_1)\varepsilon_{t-1}^2 + u_t - \beta_1 u_{t-1}$$

et en substituant $\alpha_0 = (1 - \alpha_1 - \beta_1)\sigma^2$:

$$(\varepsilon_t^2 - \sigma^2) = (\alpha_1 + \beta_1)(\varepsilon_{t-1}^2 - \sigma^2) + u_t - \beta_1 u_{t-1}$$

$$0 < (\alpha_1 + \beta_1) < 1 \quad \implies \quad \textbf{retour à la moyenne !}$$

C'est un processus d'Ornstein-Uhlenbeck étendu pour σ_t^2 avec des erreurs **MA(1)**.

Le sens économique. L'écart à la volatilité de long terme se contracte d'un facteur $(\alpha_1 + \beta_1)$ à chaque période. Avec $\alpha_1 + \beta_1 = 0,97$, la demi-vie d'un choc de volatilité est $\log(0,5)/\log(0,97) \approx 23$ jours : après un krach, il faut environ un mois pour que la moitié de l'excès de volatilité se résorbe. C'est **exactement** l'AR(1) de la fiche 52, appliqué aux carrés — et l'on retrouve la même famille que le modèle de Vasicek pour les taux.

Comment résoudre l'exercice type (protocole)

1. **Calculer les log-rendements** $R_t = \log(P_t/P_{t-1})$ et leur écart-type ; **annualiser** par $\sqrt{252}$, $\sqrt{52}$ ou $\sqrt{12}$.
2. **Estimer la moyenne conditionnelle** μ_t (souvent une constante c , parfois une AR courte) et récupérer $\hat{\varepsilon}_t = y_t - \hat{\mu}_t$.

3. **Tester l'effet ARCH** : ajuster une $AR(p)$ sur $\hat{\varepsilon}_t^2$, calculer nR^2 et comparer à χ_p^2 .
4. Si rejet, **ajuster un GARCH(1,1)** par maximum de vraisemblance sous les contraintes $\alpha_i, \beta_j \geq 0$ et $\sum \alpha_i + \sum \beta_j < 1$.
5. **Lire** $\alpha_1 + \beta_1$: persistance et stationnarité ; en déduire $\sigma^2 = \alpha_0 / (1 - \alpha_1 - \beta_1)$ et la demi-vie des chocs.
6. **Diagnostiquer** : $\hat{\varepsilon}_t / \hat{\sigma}_t$ et $(\hat{\varepsilon}_t / \hat{\sigma}_t)^2$ non corrélés ; normalité par QQ-plot et Jarque-Bera.
7. **Sélectionner** entre spécifications concurrentes par AIC/BIC.

Comment reconnaître qu'il faut utiliser cette méthode ?

Indice dans l'énoncé	Ce qu'il faut faire
« volatilité annualisée » à partir de données quotidiennes	$\sqrt{252} \hat{\sigma}$
« les périodes agitées succèdent aux périodes agitées »	effet ARCH $\Rightarrow$ test LM, puis GARCH
« queues plus épaisses que la normale »	mélange de gaussiennes $\Rightarrow$ GARCH , ou sauts de Poisson
« on dispose du haut, du bas et de l'ouverture »	Garman-Klass — gain d'efficacité jusqu'à 8,4
« krach en une séance »	le brownien continu ne peut pas $\Rightarrow$ diffusion à sauts
« rendement espéré μ du prix » et loi du log	attention au $\mu - \sigma^2/2$
« volatilité de long terme »	$\alpha_0 / (1 - \alpha_1 - \beta_1)$
« pondérer davantage le passé récent »	moyenne mobile exponentielle / RiskMetrics

Exercices progressifs

Niveau 1 — Un GARCH(1,1) estimé donne $\alpha_0 = 0,00001$, $\alpha_1 = 0,08$, $\beta_1 = 0,90$. Le modèle est-il stationnaire ? Quelle est la volatilité annualisée de long terme ?

Stationnarité. $\alpha_1 + \beta_1 = 0,08 + 0,90 = 0,98 < 1$: le modèle **est stationnaire en covariance**, avec une persistance élevée.

Variance de long terme.

$$\sigma^2 = \frac{\alpha_0}{1 - \alpha_1 - \beta_1} = \frac{0,00001}{1 - 0,98} = \frac{0,00001}{0,02} = 0,0005$$

Volatilité quotidienne. $\sigma = \sqrt{0,0005} \approx 0,0224$, soit **2,24 %** par jour.

Volatilité annualisée. $\sqrt{252} \times 0,0224 \approx 15,87 \times 0,0224 \approx 0,355$, soit environ **35,5 % par an**.

Bonus — la demi-vie des chocs. $\log(0,5)/\log(0,98) \approx 34$ jours : il faut environ sept semaines pour que la moitié d'un excès de volatilité se résorbe. C'est très lent, et c'est typique des marchés actions.

Niveau 2 — Pourquoi le logarithme du prix dérive-t-il à $\mu - \sigma^2/2$ et non à μ ?

Le fait. Sous $dS/S = \mu dt + \sigma dW$, les log-rendements vérifient $R_j \sim N(\mu^* \tau_j, \sigma^2 \tau_j)$ avec $\mu^* = \mu - \sigma^2/2$.

La raison — l'inégalité de Jensen. La fonction **log** est **strictement concave**, donc $E[\log X] < \log E[X]$ pour toute variable non dégénérée. L'écart est d'autant plus grand que X est dispersée. Ici, l'écart par unité de temps vaut exactement $\sigma^2/2$.

Le sens économique. Le prix a bien un rendement **espéré** μ , mais l'espérance est tirée vers le haut par des trajectoires rares et très favorables. La trajectoire **typique** — la médiane — croît moins vite, à $\mu - \sigma^2/2$.

La conséquence pratique, qui surprend toujours. Si $\sigma^2/2 > \mu$, la médiane du prix **décroît** alors même que l'espérance croît. Pour $\mu = 8\%$ et $\sigma = 45\%$: $\sigma^2/2 = 10,1\% > 8\%$. L'actif a un rendement espéré positif, et pourtant plus d'une trajectoire sur deux perd de l'argent sur le long terme. C'est la « **volatility drag** », et c'est ce qui explique pourquoi les produits à effet de levier s'érodent.

Niveau 3 — Montrez que GARCH(1,1) est un ARCH(∞) et dites ce que cela apporte.

La substitution récursive. Partant de $\sigma_t^2 = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \beta_1 \sigma_{t-1}^2$, on remplace σ_{t-1}^2 par sa propre expression, puis σ_{t-2}^2 , etc. :

$$\sigma_t^2 = \alpha_0(1 + \beta_1 + \beta_1^2 + \cdots) + \alpha_1(\varepsilon_{t-1}^2 + \beta_1 \varepsilon_{t-2}^2 + \beta_1^2 \varepsilon_{t-3}^2 + \cdots)$$

soit, si $|\beta_1| < 1$,

$$\sigma_t^2 = \frac{\alpha_0}{1 - \beta_1} + \alpha_1 \sum_{k=0}^{\infty} \beta_1^k \varepsilon_{t-1-k}^2$$

C'est bien un ARCH(∞) de coefficients $\alpha_1 \beta_1^k$ — décroissance **géométrique** de la mémoire.

Ce que cela apporte.

1. **La parcimonie.** Trois paramètres $(\alpha_0, \alpha_1, \beta_1)$ engendrent une infinité de coefficients. Un ARCH pur aurait besoin de p grand pour capter la même persistance, avec autant de paramètres à estimer et une contrainte de positivité à vérifier sur chacun.
2. **La récursivité.** σ_t^2 se calcule en une opération à partir de σ_{t-1}^2 : la vraisemblance s'évalue en $O(T)$.
3. **La forme de la mémoire.** La décroissance géométrique est empiriquement la bonne : l'influence d'un choc sur la volatilité s'estompe progressivement, pas brutalement au retard p .

Le parallèle exact. C'est le même mouvement que la fiche 52 : un MA fini est une AR infinie, et un AR fini est une MA infinie. Ici, β_1 joue le rôle du dénominateur $\phi(L)$ et transforme une somme finie en somme infinie à poids géométriques.

Niveau 4 — type examen — Expliquez comment le GARCH produit simultanément le regroupement de volatilité, les queues épaisses et le retour à la moyenne.

1. Le regroupement de volatilité — par construction. Le modèle pose

$$\sigma_t^2 = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \beta_1 \sigma_{t-1}^2$$

avec $\alpha_1, \beta_1 \geq 0$. Un grand choc ε_{t-1}^2 **augmente mécaniquement** σ_t^2 , donc l'amplitude attendue du choc suivant. Les grands ε_t^2 suivent les grands ε_{t-1}^2 , les petits suivent les petits. C'est l'effet visé, et il est direct.

2. Les queues épaisses — par mélange, sans hypothèse non gaussienne. Conditionnellement à $\mathcal{F}_{t-1}$, $\varepsilon_t = Z_t \sigma_t$ est **gaussien** de variance σ_t^2 . Mais la loi **inconditionnelle** est un **mélange** de gaussiennes de variances différentes. Or tout mélange de gaussiennes centrées de variances distinctes est **leptokurtique** : par la loi de la variance totale,

$$\text{Kurt}(\varepsilon_t) = 3 \cdot \frac{E[\sigma_t^4]}{(E[\sigma_t^2])^2} \geq 3$$

avec égalité **seulement si** σ_t^2 est constante (Jensen). Dès qu'il y a de l'hétéroscédasticité conditionnelle, la kurtosis dépasse **3**. C'est le résultat d'Engle, Bollerslev et Nelson (1994) : *les modèles GARCH sont un mélange stochastique de lois gaussiennes, de kurtosis plus élevée.*

3. Le retour à la moyenne — par la forme ARMA. En posant $u_t = \varepsilon_t^2 - \sigma_t^2$, le GARCH(1,1) s'écrit

$$\varepsilon_t^2 = \alpha_0 + (\alpha_1 + \beta_1) \varepsilon_{t-1}^2 + u_t - \beta_1 u_{t-1}$$

un **ARMA(1,1)** de coefficient autorégressif $(\alpha_1 + \beta_1)$. En substituant $\alpha_0 = (1 - \alpha_1 - \beta_1)\sigma^2$ avec $\sigma^2 = \alpha_0/(1 - \alpha_1 - \beta_1)$:

$$(\varepsilon_t^2 - \sigma^2) = (\alpha_1 + \beta_1)(\varepsilon_{t-1}^2 - \sigma^2) + u_t - \beta_1 u_{t-1}$$

Quand $0 < (\alpha_1 + \beta_1) < 1$, l'écart à la **variance de long terme se contracte** géométriquement : c'est un processus d'**Ornstein-Uhlenbeck étendu** avec erreurs MA(1).

La synthèse — et c'est ce qu'il faut savoir dire. Les trois faits stylisés ne sont **pas** trois hypothèses posées séparément : ils découlent tous de la **même** équation de récurrence à trois paramètres. Le regroupement vient des coefficients positifs, les queues épaisses du mélange que ce regroupement engendre, le retour à la moyenne de la contrainte $\alpha_1 + \beta_1 < 1$. C'est cette économie de moyens qui explique le succès durable du GARCH(1,1).

La limite qu'il faut mentionner. Le modèle est **symétrique** en ε_{t-1} : un choc de **−3 %** et un choc de **+3 %** produisent la même σ_t^2 . Or les marchés actions présentent un **effet de levier** — les baisses augmentent la volatilité davantage que les hausses. D'où les extensions asymétriques (EGARCH de Nelson, GJR-GARCH), et les résidus standardisés qui restent non gaussiens même après un bon ajustement.

● Common mistakes

1. **Oublier le $-\sigma^2/2$** dans la dérive du log-prix sous le brownien géométrique.
2. **Annualiser en multipliant par 252 au lieu de $\sqrt{252}$** — ce sont les **variances** qui s'additionnent, pas les écarts-types.
3. **Appliquer la règle en racine du temps à des rendements autocorrélés** — elle suppose l'indépendance.
4. **Diviser par $n - 1$ dans l'EMV du brownien géométrique** — l'estimateur du maximum de vraisemblance divise par n .
5. **Confondre σ_t^2 conditionnelle et σ^2 inconditionnelle** — la première varie dans le temps, la seconde vaut $\alpha_0/(1 - \alpha_1 - \beta_1)$.
6. **Oublier les contraintes de positivité $\alpha_i \geq 0, \beta_j \geq 0$** — sans elles, σ_t^2 peut devenir négative.
7. **Ne pas vérifier $\sum \alpha_i + \sum \beta_j < 1$** — sinon le processus n'est pas stationnaire et σ^2 n'existe pas.
8. **Croire que le GARCH suppose des rendements non gaussiens** — c'est l'inverse : il les suppose **conditionnellement** gaussiens et produit les queues épaisses par mélange.
9. **Prendre les estimations de la régression du test LM pour des EMV** — ce sont des **QMLE**.
10. **Croire qu'un brownien peut produire un krach** — ses trajectoires sont continues ; il faut des **sauts**.

11. **Utiliser Garman-Klass sans vérifier ses hypothèses** — $\mu = 0$ et absence de sauts ; les gaps d'ouverture dégradent l'efficacité annoncée.

Ultimate Review

- Volatilité** = écart-type **annualisé** de la variation de prix. Approches : historique · GBM · sauts de Poisson · ARCH/GARCH · volatilité stochastique · volatilité implicite.
- Historique** : $R_t = \log(P_t/P_{t-1})$, $\hat{\sigma}^2 = \frac{1}{T-1} \sum (R_t - \bar{R})^2$; annualisation par $\sqrt{252}$, $\sqrt{52}$, $\sqrt{12}$.
- Prédicteurs** : moyenne historique · moyenne mobile simple sur m · **moyenne mobile exponentielle** $\tilde{\sigma}_{t+1}^2 = (1 - \beta)\hat{\sigma}_t^2 + \beta\tilde{\sigma}_t^2$ · EWMA sur m · régression sur les $\hat{\sigma}_{t-j}^2$. Référence : **RiskMetrics**.
- Arbitrage** : plus de données (précision) contre données récentes (pertinence). Évaluation **hors échantillon** (MSE, MAE, MAPE).
- GBM** : $dS = \mu S dt + \sigma S dW$; incréments de W gaussiens $N(0, t' - t)$ et indépendants sur intervalles disjoints.
- Loi des log-rendements** : $R_j \sim N(\mu^* \tau_j, \sigma^2 \tau_j)$ avec $\mu^* = \mu - \sigma^2/2$; EMV $\hat{\mu}^* = \bar{R}$ $\hat{\sigma}^2 = \frac{1}{n} \sum (R_t - \bar{R})^2$.
- Garman-Klass** : $\hat{\sigma}_0^2 = (C_1 - C_0)^2$, $\hat{\sigma}_1^2 = (O_1 - C_0)^2/f$, $\hat{\sigma}_2^2 = (C_1 - O_1)^2/(1 - f)$, chacun d'espérance σ^2 et de variance $2\sigma^4$; $\hat{\sigma}_1^2 \perp \hat{\sigma}_2^2 \Rightarrow$ moyenne d'efficacité **2**. Parkinson $\approx 5,2$, GK $\approx 6,2$, analytique $\approx 7,4$, composite $\approx 8,4$.
- Sauts de Poisson** : $dS/S = \mu dt + \sigma dW + \gamma Z(t) d\pi(t)$, π de taux λ , $Z \sim N(0, 1)$; EMV = mélange poissonien de gaussiennes, résolu par **EM** avec les sauts en variables latentes.
- ARCH(p)** (Engle, 1982) : $y_t = \mu_t + \varepsilon_t$, $\varepsilon_t = Z_t \sigma_t$, $\sigma_t^2 = \alpha_0 + \sum_i \alpha_i \varepsilon_{t-i}^2$, $\alpha_j \geq 0$; $\sigma_t^2 = \text{var}(R_t | \mathcal{F}_{t-1})$.
- Équivalence AR** : $\varepsilon_t^2 = \alpha_0 + \sum_i \alpha_i \varepsilon_{t-i}^2 + u_t$, $E[u_t | \mathcal{F}_t] = 0$, $\text{var}[u_t | \mathcal{F}_t] = 2\sigma_t^4$.
- Test LM** : $H_0 : \alpha_1 = \dots = \alpha_p = 0$; ajuster une AR(p) sur $\hat{\varepsilon}_t^2$; $nR^2 \sim \chi_p^2$; estimations = **QMLE**.
- GARCH(p, q)** (Bollerslev, 1986) : $\sigma_t^2 = \alpha_0 + \sum_i \alpha_i \varepsilon_{t-i}^2 + \sum_j \beta_j \sigma_{t-j}^2$.
- GARCH(1,1) $\Rightarrow$ ARMA(1,1)** : $\varepsilon_t^2 = \alpha_0 + (\alpha_1 + \beta_1)\varepsilon_{t-1}^2 + u_t - \beta_1 u_{t-1}$; **stationnaire ssi** $|\alpha_1 + \beta_1| < 1$.
- Variance de long terme** : $\sigma^2 = \alpha_0/(1 - \alpha_1 - \beta_1)$; cas général $\alpha_0/[1 - \sum(\alpha_i + \beta_i)]$, ARMA($\max(p, q), q$).
- Vraisemblance** : $\prod_t \frac{1}{\sqrt{2\pi\sigma_t^2}} \exp(-\varepsilon_t^2/2\sigma_t^2)$; contraintes $\alpha_i, \beta_j \geq 0$ et $\sum \alpha_i + \sum \beta_j < 1$.
- Diagnostics** : $\hat{\varepsilon}_t/\hat{\sigma}_t$ et $(\hat{\varepsilon}_t/\hat{\sigma}_t)^2$ non corrélés ; normalité par QQ-plot, Jarque-Bera, Shapiro-Wilk, Kolmogorov-Smirnov ; sélection par AIC/BIC.
- Faits stylisés** : **regroupement** de volatilité · **queues épaisses** (mélange stochastique de gaussiennes) · **retour à la moyenne**, $(\varepsilon_t^2 - \sigma^2) = (\alpha_1 + \beta_1)(\varepsilon_{t-1}^2 - \sigma^2) + u_t - \beta_1 u_{t-1}$, processus d'**Ornstein-**

Uhlenbeck étendu à erreurs MA(1).

Formulas to know

$$\text{vol} = \sqrt{252} \hat{\sigma} \quad dS = \mu S dt + \sigma S dW \quad R_j \sim N\left((\mu - \frac{\sigma^2}{2})\tau_j, \sigma^2 \tau_j\right)$$

$$\sigma_t^2 = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \beta_1 \sigma_{t-1}^2 \quad \varepsilon_t^2 = \alpha_0 + (\alpha_1 + \beta_1) \varepsilon_{t-1}^2 + u_t - \beta_1 u_{t-1} \quad \sigma^2 = \frac{\alpha_0}{1 - \alpha_1 - \beta_1}$$

$$LM = nR^2 \sim \chi_p^2 \quad \tilde{\sigma}_{t+1}^2 = (1 - \beta) \hat{\sigma}_t^2 + \beta \tilde{\sigma}_t^2 \quad \hat{\sigma}_3^2 = \frac{(H_1 - L_1)^2}{4 \log 2}$$

Methods to know : l'annualisation et sa justification ; la dérivation de l'ARMA(1,1) à partir du GARCH(1,1) ; le calcul de la variance de long terme ; le test LM en trois étapes ; le développement du GARCH(1,1) en ARCH(∞).

Active Recall

Basic — Écrivez le modèle GARCH(1,1) avec ses contraintes, et donnez sa variance de long terme.

$$y_t = \mu_t + \varepsilon_t, \quad \varepsilon_t = Z_t \sigma_t, \quad \sigma_t^2 = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \beta_1 \sigma_{t-1}^2$$

avec Z_t i.i.d. de moyenne 0 et variance 1.

Contraintes : $\alpha_0 > 0$, $\alpha_1 \geq 0$, $\beta_1 \geq 0$ (positivité de la variance) et $\alpha_1 + \beta_1 < 1$ (stationnarité en covariance).

Variance de long terme : en prenant l'espérance inconditionnelle, $\sigma^2 = \alpha_0 + (\alpha_1 + \beta_1) \sigma^2$, d'où

$$\sigma^2 = \frac{\alpha_0}{1 - \alpha_1 - \beta_1}$$

Understanding — Pourquoi dit-on que le GARCH rend la volatilité « prévisible » alors qu'elle reste aléatoire ?

Parce que σ_t^2 est une fonction **déterministe de l'information passée** $\mathcal{F}_{t-1}$: connaissant ε_{t-1} et σ_{t-1}^2 , on calcule σ_t^2 **exactement**, sans aléa résiduel. Le rendement $\varepsilon_t = Z_t \sigma_t$ reste

imprévisible — c'est Z_t qui apporte le hasard — mais son **amplitude attendue** est connue à l'avance.

La distinction à formuler : on ne prévoit pas le **signe** ni la **valeur** du rendement (ce serait une opportunité d'arbitrage), on prévoit sa **dispersion**. C'est précisément ce dont on a besoin pour la VaR, le prix des options et le dimensionnement des positions.

Et l'aléa n'a pas disparu : σ_{t+2}^2 vu de t est aléatoire, puisqu'il dépend de ε_{t+1} , encore inconnu. La prévisibilité est **à un pas**.

Application — Un test LM sur $p = 5$ retards donne $n = 1000$ et $R^2 = 0,12$. Conclusion ?

$$LM = nR^2 = 1000 \times 0,12 = 120$$

à comparer à une χ^2 à $p = 5$ degrés de liberté. Le quantile à 99 % vaut environ 15,09.

Comme $120 \gg 15,09$, on **rejette massivement** $H_0 : \alpha_1 = \dots = \alpha_5 = 0$. Il y a une **hétéroscédasticité conditionnelle** très marquée : la variance des rendements dépend fortement des chocs passés.

La suite du travail. Ajuster un GARCH — commencer par GARCH(1,1), qui suffit presque toujours —, puis vérifier que les **résidus standardisés au carré** $(\hat{\varepsilon}_t / \hat{\sigma}_t)^2$ ne sont **plus** autocorrélés : c'est le signe que le modèle a bien absorbé le regroupement de volatilité.

Ne pas oublier que les estimations de cette régression auxiliaire sont des **QMLE**, pas des EMV : elles servent au test, pas à l'estimation finale.

Comparison — ARCH(p) contre GARCH(1,1) : pourquoi le second a-t-il gagné ?

	ARCH(p)	GARCH(1,1)
Paramètres	$p + 1$	3
Mémoire	s'arrête net au retard p	infinie, décroissance géométrique
Contraintes	$\alpha_j \geq 0$ pour chacun des p	trois contraintes
Calcul	somme de p termes	récuratif , un pas
Forme équivalente	AR(p) en ε_t^2	ARMA(1,1) en ε_t^2

La raison de fond. La volatilité financière est **très persistante** : $\alpha_1 + \beta_1 \approx 0,98$ en pratique. Reproduire cette persistance avec un ARCH pur exigerait un p très grand — donc beaucoup de paramètres à estimer, chacun contraint positif, avec une variance d'estimation qui explose.

GARCH(1,1) obtient la même chose avec **trois** paramètres, puisqu'il est un **ARCH(∞)** à poids $\alpha_1 \beta_1^k$:

$$\sigma_t^2 = \frac{\alpha_0}{1 - \beta_1} + \alpha_1 \sum_{k \geq 0} \beta_1^k \varepsilon_{t-1-k}^2$$

C'est le même argument que AR contre MA en fiche 52 : un terme autorégressif engendre une mémoire infinie pour un seul paramètre. Le cours résume en deux mots : **parcimonieux**, et **s'ajuste à de nombreuses séries financières**.

Exam-style — Un analyste calcule la volatilité annualisée à partir de **252** rendements quotidiens et obtient **18 %**. Il conclut que la volatilité sera de **18 %** l'an prochain. Critiquez.

Le calcul lui-même est correct : $\hat{\sigma}^2 = \frac{1}{251} \sum (R_t - \bar{R})^2$ puis $\sqrt{252} \hat{\sigma} = 0,18$. C'est bien l'estimateur de la volatilité **historique** annualisée.

Les cinq critiques.

1. C'est une estimation du passé, pas une prévision. L'estimateur suppose $\{R_t\}$ **stationnaire en covariance** — donc que σ ne change pas. Or le test LM d'Engle rejette cette hypothèse sur pratiquement toutes les séries financières.

2. Il ignore le regroupement de volatilité. Si la fenêtre contient un krach au début et une période calme à la fin, **18 %** mélange deux régimes. Un GARCH(1,1) partirait de $\sigma_{T'}^2$, la

volatilité **conditionnelle actuelle**, et convergerait progressivement vers la moyenne de long terme — pas l'inverse.

3. La prévision correcte est un chemin, pas un nombre. Sous GARCH(1,1),

$$E[\sigma_{T+h}^2 | \mathcal{F}_T] = \sigma^2 + (\alpha_1 + \beta_1)^h(\sigma_T^2 - \sigma^2)$$

La volatilité prévue **converge** vers $\sigma^2 = \alpha_0 / (1 - \alpha_1 - \beta_1)$ à la vitesse $(\alpha_1 + \beta_1)^h$. À horizon un an et avec $\alpha_1 + \beta_1 = 0,98$, on est déjà proche de σ^2 ; à horizon une semaine, c'est σ_T^2 qui domine.

4. Le poids uniforme est un mauvais choix. Toutes les observations pèsent $1/251$, y compris celles d'il y a onze mois. Une **moyenne mobile exponentielle** — la méthodologie **RiskMetrics** — pondère le passé récent davantage.

5. Une seule observation par jour, c'est du gaspillage. Avec les prix d'ouverture, haut et bas, l'estimateur de **Garman-Klass** atteint une efficacité de l'ordre de **8** : la même précision avec huit fois moins de jours. Et avec des données intra-journalières, on cumule les carrés des rendements intra-day.

Ce qu'il faudrait dire à l'analyste. « **18 %** est la volatilité **réalisée** des douze derniers mois. Pour prévoir, il faut d'abord tester l'effet ARCH, puis ajuster un GARCH(1,1) : la prévision partira de la volatilité conditionnelle d'aujourd'hui et convergera vers la moyenne de long terme. Et si les prix haut/bas sont disponibles, l'estimation gagnera un ordre de grandeur en précision. »

Flashcards

Question	Réponse
Définition de la volatilité ?	Écart-type annualisé de la variation de prix
Annualisation quotidienne ?	$\sqrt{252} \hat{\sigma}$
Pourquoi une racine carrée ?	Les variances s'additionnent sous indépendance
Moyenne mobile exponentielle ?	$\tilde{\sigma}_{t+1}^2 = (1 - \beta)\hat{\sigma}_t^2 + \beta\tilde{\sigma}_t^2$
Méthodologie de référence ?	RiskMetrics
Équation du brownien géométrique ?	$dS = \mu S dt + \sigma S dW$
Loi des log-rendements ?	$N((\mu - \sigma^2/2)\tau_j, \sigma^2\tau_j)$
Pourquoi le $-\sigma^2/2$?	Inégalité de Jensen : log est concave
EMV de σ^2 sous GBM ?	$\frac{1}{n} \sum (R_t - \bar{R})^2$ — diviseur n
Variance de $(C_1 - C_0)^2$?	$2\sigma^4$
Pourquoi Garman-Klass gagne ?	$\hat{\sigma}_1^2$ et $\hat{\sigma}_2^2$ sont indépendants $\Rightarrow$ moyenne de variance moitié
Estimateur de Parkinson ?	$(H_1 - L_1)^2 / (4 \log 2)$, efficacité $\approx 5,2$
Efficacité de l'estimateur composite ?	$\approx 8,4$
Modèle à sauts de Poisson ?	$dS/S = \mu dt + \sigma dW + \gamma Z(t) d\pi(t)$
Comment l'estimer ?	EM , les sauts en variables latentes
Modèle ARCH(p) ?	$\sigma_t^2 = \alpha_0 + \sum_i \alpha_i \varepsilon_{t-i}^2, \alpha_j \geq 0$
Que représente σ_t^2 ?	$\text{var}(R_t \mathcal{F}_{t-1})$ — hétéroscédasticité conditionnelle
ARCH implique quel modèle en ε_t^2 ?	Une AR(p)
Statistique du test LM ?	$nR^2 \sim \chi_p^2$ sous H_0
Que sont les estimations de cette régression ?	Des QMLE , pas des EMV
Modèle GARCH(p, q) ?	$\sigma_t^2 = \alpha_0 + \sum \alpha_i \varepsilon_{t-i}^2 + \sum \beta_j \sigma_{t-j}^2$

Question	Réponse
GARCH(1,1) implique quel modèle ?	Un ARMA(1,1) en ε_t^2
Sa forme ARMA ?	$\varepsilon_t^2 = \alpha_0 + (\alpha_1 + \beta_1)\varepsilon_{t-1}^2 + u_t - \beta_1 u_{t-1}$
Condition de stationnarité ?	$ \alpha_1 + \beta_1 < 1$
Variance de long terme ?	$\alpha_0 / (1 - \alpha_1 - \beta_1)$
Variance de u_t ?	$2\sigma_t^4$
GARCH(p, q) équivaut à quel ARMA ?	ARMA(max(p, q), q)
Les deux diagnostics de résidus ?	$\hat{\varepsilon}_t / \hat{\sigma}_t$ et $(\hat{\varepsilon}_t / \hat{\sigma}_t)^2$ non corrélés
Tests de normalité cités ?	QQ-plot, Jarque-Bera, Shapiro-Wilk, Kolmogorov-Smirnov
Les trois faits stylisés ?	Regroupement de volatilité · queues épaisses · retour à la moyenne
Pourquoi le GARCH a des queues épaisses ?	C'est un mélange stochastique de gaussiennes
Le processus du retour à la moyenne ?	Ornstein-Uhlenbeck étendu à erreurs MA(1)