

Fiche 54 — Modèles à facteurs : Sharpe, macroéconomiques, fondamentaux et statistiques

Matière	Maths · Finance de marché
Cours source	Kempthorne, <i>18.S096 Topics in Mathematics with Applications in Finance</i> , MIT OpenCourseWare, automne 2013 — cours 15 « Factor Models »
Difficulté	Must know — l'ossature de la gestion quantitative moderne
Temps d'étude estimé	2 h 45
Prérequis	Fiche 50 (MCO, Gauss-Markov, MCG), fiche 51 (matrice de covariance, contraintes factorielles), fiche 9 (valeurs propres, matrices symétriques)
Concepts clés	Modèle linéaire à facteurs, chargements factoriels, régressions transversales et temporelles, modèle à indice unique de Sharpe, facteurs macroéconomiques, approches BARRA et Fama-French, analyse factorielle, invariance par rotation, analyse en composantes principales, décomposition en valeurs singulières, méthode du facteur principal
Poids à l'examen	Trois choses : la décomposition $\Sigma_x = B\Sigma_f B^T + \Psi$ et pourquoi elle résout le problème d'estimation de la fiche 51 ; le fait que $\hat{f}_t$ du modèle sectoriel BARRA soit une moyenne par secteur ; et la construction de l'ACP par maximisation de variance.

Vue d'ensemble

Les données. m actifs, instruments ou indices ($i = 1, \dots, m$), observés sur n périodes ($t = 1, \dots, n$), formant à chaque période un vecteur aléatoire à m dimensions

$$x_t = (x_{1,t}, x_{2,t}, \dots, x_{m,t})^T$$

Par exemple : les rendements de m actions, contrats à terme ou devises ; ou les taux de rendement de m instruments du Trésor américain.

IDÉE m actifs, K facteurs communs, avec $K \ll m$
 MODÈLE $x_{\{i,t\}} = \alpha_i + \beta_i f_t + \varepsilon_{\{i,t\}}$

CONSÉQUENCE $\Sigma_x = B \Sigma_f B' + \Psi \quad \leftarrow \Psi \text{ diagonale}$
GAIN $m(m+1)/2$ paramètres $\rightarrow mK + K(K+1)/2 + m$

Le problème que les facteurs résolvent. La fiche 51 a signalé le point faible de Markowitz : estimer Σ librement demande $m(m+1)/2$ paramètres — plus de **125 000** pour $m = 500$. Un modèle à K facteurs impose une **structure** : toute la corrélation entre actifs passe par K variables communes, et le reste est **diagonal**. Le nombre de paramètres s'effondre, et $\hat{\Sigma}$ redevient bien conditionnée.

Les quatre familles, qui diffèrent seulement par **d'où viennent les facteurs** :

Famille	f_t	B
Macroéconomique	observé (inflation, PIB, taux...)	estimé par régression temporelle
Fondamental (Fama-French)	construit par tris transversaux	estimé par régression temporelle
Fondamental (BARRA)	estimé par régression transversale	observé (secteur, taille, style)
Statistique	latent	latent — les deux sont extraits de $\hat{\Sigma}_x$

● **Concept 1 — Le modèle linéaire à facteurs**

$$x_{i,t} = \alpha_i + \beta_{1,i}f_{1,t} + \beta_{2,i}f_{2,t} + \dots + \beta_{K,i}f_{K,t} + \varepsilon_{i,t} = \alpha_i + \beta_i^T f_t + \varepsilon_{i,t}$$

Symbole	Signification	Constant en
α_i	ordonnée à l'origine de l'actif i	t
$f_t = (f_{1,t}, \dots, f_{K,t})^T$	variables de facteur commun à la période t	i
$\beta_i = (\beta_{1,i}, \dots, \beta_{K,i})^T$	chargements factoriels (<i>factor loadings</i>) de l'actif i	t
$\varepsilon_{i,t}$	facteur spécifique de l'actif i à la période t	—

La dissymétrie est toute l'idée. f_t varie dans le temps mais est **le même pour tous les actifs** ; β_i varie d'un actif à l'autre mais est **constant dans le temps**. Le facteur est le mouvement d'ensemble, le chargement est la sensibilité individuelle à ce mouvement.

Les trois écritures du même modèle

(a) **Régressions transversales** (*cross-sectional*) — une équation par **période** :

$$x_t = \alpha + Bf_t + \varepsilon_t \quad \text{pour chaque } t \in \{1, \dots, T\}$$

avec

$$\alpha = \begin{pmatrix} \alpha_1 \\ \vdots \\ \alpha_m \end{pmatrix} (m \times 1), \quad B = \begin{pmatrix} \beta_1^T \\ \vdots \\ \beta_m^T \end{pmatrix} = [\beta_{i,k}] (m \times K), \quad \varepsilon_t = \begin{pmatrix} \varepsilon_{1,t} \\ \vdots \\ \varepsilon_{m,t} \end{pmatrix} (m \times 1)$$

α et B sont les mêmes pour tout t .

Les hypothèses.

- $\{f_t\}$ est (K -varié) **stationnaire en covariance** $I(0)$, avec

$$E[f_t] = \mu_f, \quad \text{Cov}[f_t] = E[(f_t - \mu_f)(f_t - \mu_f)^T] = \Sigma_f$$

- $\{\varepsilon_t\}$ est un **bruit blanc** m -varié :

$$E[\varepsilon_t] = 0_m, \quad \text{Cov}[\varepsilon_t] = E[\varepsilon_t \varepsilon_t^T] = \Psi, \quad \text{Cov}[\varepsilon_t, \varepsilon_{t'}] = E[\varepsilon_t \varepsilon_{t'}^T] = 0 \quad \forall t \neq t'$$

où Ψ est la matrice **diagonale** ($m \times m$) d'entrées $(\psi_1^2, \psi_2^2, \dots, \psi_m^2)$.

La diagonalité de Ψ est l'hypothèse-clé du chapitre, et c'est elle qui porte tout le gain. Elle dit : *une fois retirés les K facteurs communs, il ne reste **aucune** corrélation entre actifs*. Toute la dépendance transversale est passée par f_t .

Les moments. $\{x_t\}$ est une série temporelle multivariée stationnaire en covariance avec

Moments conditionnels	Moments inconditionnels
$E[x_t f_t] = \alpha + Bf_t$	$E[x_t] = \mu_x = \alpha + B\mu_f$
$\text{Cov}[x_t f_t] = \Psi$	$\boxed{\text{Cov}[x_t] = \Sigma_x = B\Sigma_f B^T + \Psi}$

Cette dernière ligne est LA formule du chapitre. La covariance des rendements se scinde en un **risque commun** $B\Sigma_f B^T$ — de rang au plus K — et un **risque spécifique** Ψ , diagonal. C'est cette décomposition qui rend l'optimisation de portefeuille de la fiche 51 praticable sur des univers de plusieurs centaines d'actifs.

Le décompte des paramètres. Σ_x libre : $m(m+1)/2$. Avec K facteurs : mK (les B) + $K(K+1)/2$ (les Σ_f) + m (les Ψ). Pour $m = 500$ et $K = 5$: 125 250 contre 3 015.

(b) Régressions temporelles (*time series*) — une équation par actif :

$$x_i = 1_T \alpha_i + F \beta_i + \varepsilon_i \quad \text{pour chaque actif } i \in \{1, \dots, m\}$$

avec

$$x_i = \begin{pmatrix} x_{i,1} \\ \vdots \\ x_{i,T} \end{pmatrix}, \quad \varepsilon_i = \begin{pmatrix} \varepsilon_{i,1} \\ \vdots \\ \varepsilon_{i,T} \end{pmatrix}, \quad F = \begin{pmatrix} f_1^T \\ \vdots \\ f_T^T \end{pmatrix} = \begin{pmatrix} f_{1,1} & f_{2,1} & \cdots & f_{K,1} \\ \vdots & \vdots & \ddots & \vdots \\ f_{1,T} & f_{2,T} & \cdots & f_{K,T} \end{pmatrix}$$

α_i et $\beta_i = (\beta_{1,i}, \dots, \beta_{K,i})^T$ sont des **paramètres de régression**, et ε_i est le T -vecteur des erreurs, de $\text{Cov}(\varepsilon_i) = \sigma_i^2 I_T$.

(c) Régression multivariée. Avec $X = [x_1 | \dots | x_m]$, $E = [\varepsilon_1 | \dots | \varepsilon_m]$ et $B = [\beta_1 | \dots | \beta_m]$:

$$X = 1_T \alpha^T + FB + E$$

(noter que ce B est la **transposée** du B transversal.)

Ces trois écritures gouvernent trois stratégies d'estimation. Si F est **observé**, on régresse dans le temps, actif par actif — écriture (b). Si B est **observé**, on régresse en coupe, période par période — écriture (a). Si **ni l'un ni l'autre** n'est observé, il faut une méthode statistique — concepts 6 à 8.

● Concept 2 — Le modèle à indice unique de Sharpe (1970)

$$x_{i,t} = \alpha_i + \beta_i R_{Mt} + \varepsilon_{i,t}, \quad i = 1, \dots, m, \quad t = 1, \dots, T$$

où

- R_{Mt} est le rendement de l'**indice de marché en excès du taux sans risque** : le **facteur de risque de marché** ;

- $x_{i,t}$ est le rendement de l'actif i en excès du taux sans risque ;
- $K = 1$ et l'unique facteur est $f_{1,t} = R_{Mt}$.

La matrice de covariance transversale inconditionnelle des actifs.

$$\text{Cov}(x_t) = \Sigma_x = \sigma_M^2 \beta \beta^T + \Psi$$

avec $\sigma_M^2 = \text{Var}(R_{Mt})$, $\beta = (\beta_1, \dots, \beta_m)^T$ et $\Psi = \text{diag}(\psi_1^2, \dots, \psi_m^2)$.

Le modèle le plus économe qui soit. Σ_x est décrite par $2m + 1$ nombres — un bêta et une variance spécifique par actif, plus la variance du marché. La corrélation entre deux actifs quelconques devient

$$\text{Corr}(x_i, x_j) = \frac{\beta_i \beta_j \sigma_M^2}{\sqrt{(\beta_i^2 \sigma_M^2 + \psi_i^2)(\beta_j^2 \sigma_M^2 + \psi_j^2)}}$$

Deux actifs ne sont corrélés que parce qu'ils réagissent tous deux au marché. C'est le « **modèle à indice unique de Sharpe** » cité comme remède à l'erreur d'estimation en fiche 51.

L'estimation. Le modèle à indice unique satisfait les hypothèses de **Gauss-Markov généralisées**, donc les estimateurs des moindres carrés ($\hat{\alpha}_i, \hat{\beta}_i$) issus de la régression temporelle de chaque actif i sont les **meilleurs estimateurs linéaires sans biais (BLUE)** et les **EMV** sous hypothèses gaussiennes.

$$x_i = 1_T \hat{\alpha}_i + R_M \hat{\beta}_i + \hat{\varepsilon}_i$$

Estimateurs sans biais des paramètres restants.

$$\hat{\psi}_i^2 = \frac{\hat{\varepsilon}_i^T \hat{\varepsilon}_i}{T-2}, \quad \hat{\sigma}_M^2 = \frac{\sum_{t=1}^T (R_{Mt} - \bar{R}_M)^2}{T-1} \quad \text{avec} \quad \bar{R}_M = \frac{1}{T} \sum_{t=1}^T R_{Mt}, \quad \hat{\Psi} = \text{diag}(\hat{\psi}_1^2, \dots, \hat{\psi}_m^2)$$

Estimateur de la matrice de covariance inconditionnelle.

$$\widehat{\text{Cov}}(x_t) = \hat{\Sigma}_x = \hat{\sigma}_M^2 \hat{\beta} \hat{\beta}^T + \hat{\Psi}$$

Le diviseur $T - 2$ vient de la fiche 50 : deux paramètres estimés par régression (α_i et β_i), donc $T - 2$ degrés de liberté.

● Concept 3 — Modèles multifactoriels macroéconomiques

Les variables de facteur commun $\{f_t\}$ sont les valeurs réalisées de **variables macroéconomiques**, telles que :

- Risque de marché
- Indices de prix (CPI, PPI, matières premières) / inflation
- Production industrielle (PIB)
- Croissance de la masse monétaire
- Taux d'intérêt
- Mises en chantier (*housing starts*)
- Chômage

Voir Chen, Ross et Roll (1986), « Economic Forces and the Stock Market ».

Le modèle comme régressions temporelles.

$$x_i = 1_T \alpha_i + F \beta_i + \varepsilon_i$$

où $F = [f_1, f_2, \dots, f_T]^T$ est la matrice $(T \times K)$ des valeurs réalisées des $K > 0$ facteurs macroéconomiques.

Matrice de covariance transversale inconditionnelle.

$$\text{Cov}(x_t) = B \Sigma_f B^T + \Psi, \quad B = (\beta_1, \dots, \beta_m)^T \quad (m \times K)$$

L'estimation. Le modèle multifactoriel satisfait les hypothèses de Gauss-Markov généralisées, donc les estimateurs des moindres carrés $\hat{\alpha}_i$ et $\hat{\beta}_i$ ($K \times 1$) issus de la régression temporelle de chaque actif sont **BLUE** et les **EMV** sous hypothèses gaussiennes.

$$x_i = 1_T \hat{\alpha}_i + F \hat{\beta}_i + \hat{\varepsilon}_i$$

Estimateurs sans biais des paramètres restants.

$$\hat{\psi}_i^2 = \frac{\hat{\varepsilon}_i^T \hat{\varepsilon}_i}{T - (K + 1)}, \quad \hat{\Psi} = \text{diag}(\hat{\psi}_1^2, \dots, \hat{\psi}_m^2)$$

$$\hat{\Sigma}_f = \frac{1}{T - 1} \sum_{t=1}^T (f_t - \hat{\mu}_f)(f_t - \hat{\mu}_f)^T \quad \text{avec} \quad \hat{\mu}_f = \frac{1}{T} \sum_{t=1}^T f_t$$

Estimateur de la matrice de covariance inconditionnelle.

$$\hat{\Sigma}_x = \hat{B}\hat{\Sigma}_f\hat{B}^T + \hat{\Psi}$$

Ici F est observé, donc tout est une simple régression. C'est la situation la plus confortable, et aussi la plus contestable : rien ne garantit que les variables macroéconomiques choisies soient **les bons** facteurs, ni qu'elles soient mesurées au bon moment (les données de PIB sont publiées avec retard et révisées).

● Concept 4 — Modèles à facteurs fondamentaux

Les variables de facteur commun $\{f_t\}$ sont déterminées à partir d'**attributs fondamentaux spécifiques aux actifs** :

- appartenance à un **secteur / une industrie**
- **taille de l'entreprise** (capitalisation boursière)
- **rendement du dividende**
- **style** (croissance / valeur, mesuré par le prix sur actif net, le bénéfice sur prix...)
- etc.

L'approche BARRA (Barr Rosenberg)

- Traiter les **attributs observables** spécifiques aux actifs **comme les bêtas factoriels**.
- Les **réalisations de facteurs $\{f_t\}$** sont **inobservables**, mais sont **estimées**.

L'approche Fama-French (Eugene Fama et Kenneth French)

- Pour chaque période t , appliquer des **tris transversaux** pour définir les réalisations de facteurs.
- Pour un attribut donné, **trier** les actifs à la période t selon cet attribut et définir des **portefeuilles par quintile**, en découpant les actifs en 5 portefeuilles équipondérés.
- Former le **portefeuille de couverture** (*hedge portfolio*) : **long** sur le quintile supérieur, **court** sur le quintile inférieur.
- Définir les réalisations de facteur commun de la période t comme les **rendements de période t des K portefeuilles de couverture** correspondant aux K attributs fondamentaux.
- **Estimer les chargements factoriels** sur les actifs par **régressions temporelles**, séparément pour chaque actif i .

La différence entre les deux approches est une inversion complète du sens de la régression.

BARRA dit : « je **connais** les bêtas (l'actif appartient au secteur bancaire, sa capitalisation est de tel montant), je **cherche** les rendements de facteurs » $\Rightarrow$ régression **transversale**, une par période.

Fama-French dit : « je **construis** les rendements de facteurs par tri en quintiles, je **cherche** les bêtas » $\Rightarrow$ régression **temporelle**, une par actif.

Le portefeuille long-court de Fama-French est astucieux : il isole l'effet de l'attribut en **annulant** l'exposition commune — c'est un facteur qui est aussi un **portefeuille investissable**.

● Concept 5 — Le modèle sectoriel BARRA en détail

Supposons que les m actifs se répartissent en K **groupes sectoriels**. Pour chaque actif i , on définit les chargements factoriels

$$\beta_{i,k} = \begin{cases} 1 & \text{si l'actif } i \text{ appartient au secteur } k \\ 0 & \text{sinon} \end{cases}$$

Ces chargements sont invariants dans le temps. Pour la période t , on note $\mathbf{f}_t = (f_{1t}, \dots, f_{Kt})^T$ les réalisations des K facteurs — **ces réalisations sont inobservées**. Le modèle sectoriel s'écrit

$$\mathbf{X}_{i,t} = \beta_{i,1}f_{1t} + \dots + \beta_{i,K}f_{Kt} + \varepsilon_{it}, \quad \forall i, t$$

avec

$$\text{var}(\varepsilon_{it}) = \psi_i^2 \quad \forall i, \quad \text{cov}(\varepsilon_{it}, f_{kt}) = 0 \quad \forall i, k, t, \quad \text{cov}(f_{k't}, f_{kt}) = [\Sigma_f]_{k',k} \quad \forall k', k, t$$

Estimation des réalisations de facteurs

Pour chaque période t , on considère la **régression transversale**

$$\mathbf{x}_t = \mathbf{B}\mathbf{f}_t + \varepsilon_t \quad (\alpha = 0, \text{ il n'apparaît donc pas})$$

avec $E[\varepsilon_t] = \mathbf{0}_m$, $E[\varepsilon_t \varepsilon_t^T] = \Psi$ et $\text{Cov}(\mathbf{f}_t) = \Sigma_f$.

On calcule $\hat{\mathbf{f}}_t$ par régression des moindres carrés de $\mathbf{x}_t$ sur $\mathbf{B}$, avec $\mathbf{f}_t$ comme paramètre de régression. $\mathbf{B}$ est la matrice $(m \times K)$ de **variables indicatrices**, la même pour tout t , donc

$$\mathbf{B}^T \mathbf{B} = \text{diag}(m_1, \dots, m_K), \quad \sum_{k=1}^K m_k = m$$

où m_k est le **nombre d'actifs du secteur k** . D'où

$$\hat{f}_t = (B^T B)^{-1} B^T x_t \quad (\text{vecteur des moyennes sectorielles !})$$

$$\hat{\varepsilon}_t = x_t - B\hat{f}_t$$

Ce résultat est magnifique de simplicité. Comme B ne contient que des indicatrices, $(B^T B)^{-1}$ est diagonale d'entrées $1/m_k$ et $B^T x_t$ somme les rendements par secteur. La régression se réduit donc à **calculer le rendement moyen de chaque secteur à la date t** — et le résidu $\hat{\varepsilon}_{i,t}$ est l'écart de l'actif i à la moyenne de son secteur.

Estimation des matrices de covariance

$$\hat{\Sigma}_f = \frac{1}{T-1} \sum_{t=1}^T (\hat{f}_t - \hat{\bar{f}})(\hat{f}_t - \hat{\bar{f}})^T, \quad \hat{\bar{f}} = \frac{1}{T} \sum_{t=1}^T \hat{f}_t$$

$$\hat{\Psi} = \text{diag}(\hat{\psi}_1^2, \dots, \hat{\psi}_m^2), \quad \hat{\psi}_i^2 = \frac{1}{T-1} \sum_{t=1}^T [\hat{\varepsilon}_{i,t} - \hat{\bar{\varepsilon}}_i]^2, \quad \hat{\bar{\varepsilon}}_i = \frac{1}{T} \sum_{t=1}^T \hat{\varepsilon}_{i,t}$$

$$\hat{\Sigma} = B\hat{\Sigma}_f B^T + \hat{\Psi}$$

Détails supplémentaires signalés par le cours.

- **Inefficacité des estimateurs des moindres carrés** due à l'**hétéroscédasticité** dans Ψ .
- **Résolution** : appliquer les **moindres carrés généralisés (MCG)**, en estimant Ψ dans les régressions transversales.
- Les réalisations de facteurs peuvent être **remises à l'échelle** pour représenter des **portefeuilles répliquants de facteurs** (*factor mimicking portfolios*).
- Le modèle sectoriel BARRA peut s'exprimer comme un modèle de **régressions empilées apparemment non reliées (SUR)**.

Le point sur l'hétéroscédasticité est exactement celui de la fiche 50. Les variances spécifiques ψ_i^2 diffèrent d'un actif à l'autre : $\text{Cov}(\varepsilon_t) = \Psi \neq \sigma^2 I_m$. Les MCO restent sans biais mais **ne sont plus BLUE** — le BLUE est l'estimateur MCG $\hat{f}_t = [B^T \Psi^{-1} B]^{-1} B^T \Psi^{-1} x_t$, qui est une moyenne sectorielle **pondérée par l'inverse des variances spécifiques**.

● Concept 6 — Les modèles à facteurs statistiques : l'analyse factorielle

Les variables de facteur commun $\{f_t\}$ sont **cachées (latentes)** et leur structure est déduite de l'analyse des rendements observés $\{x_t\}$.

Les deux méthodes principales d'extraction sont l'**analyse factorielle** et l'**analyse en composantes principales**. Toutes deux modélisent Σ , la matrice de covariance de $\{x_t\}$, en s'appuyant sur la **covariance empirique** $\hat{\Sigma}$, calculée ainsi :

$$X = [x_1 : \dots : x_T] \ (m \times T), \quad X^* = X \left(I_T - \frac{1}{T} \mathbf{1}_T \mathbf{1}_T^T \right) \text{ (« centrée » par ligne),} \quad \hat{\Sigma}_x = \frac{1}{T} X^* (X^*)^T$$

L'invariance par transformation linéaire des facteurs

Pour toute matrice $(K \times K)$ **inversible** H , on définit

$$f_t^* = H f_t \quad \text{et} \quad B^* = B H^{-1}$$

Alors le modèle à facteurs reste vrai en remplaçant f_t et B :

$$x_t = \alpha + B^* f_t^* + \varepsilon_t = \alpha + B H^{-1} H f_t + \varepsilon_t = \alpha + B f_t + \varepsilon_t$$

et en remplaçant μ_f et Σ_f par

$$\Sigma_f^* = \text{Cov}(f_t^*) = \text{Cov}(H f_t) = H \text{Cov}(f_t) H^T = H \Sigma_f H^T, \quad \mu_f^* = H \mu_f$$

Ce résultat dit que le modèle n'est PAS identifié. Une infinité de couples (B, f_t) produisent exactement la même loi des observations. On ne peut donc **jamais** interpréter les facteurs statistiques comme des grandeurs économiques bien définies : seul l'**espace** qu'ils engendrent est déterminé, pas la base choisie dans cet espace.

La formulation standard

Facteurs orthonormés : $\Sigma_f = I_K$. On y parvient en choisissant

$$H = \Lambda^{-1/2} \Gamma^T, \quad \text{où } \Sigma_f = \Gamma \Lambda \Gamma^T \text{ est la décomposition spectrale}$$

avec Γ orthogonale $(K \times K)$ et $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_K)$, $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_K > 0$.

Facteurs centrés : $\mu_f = 0_K$. On y parvient en ajustant α pour incorporer la contribution moyenne des facteurs :

$$\alpha \leftarrow \alpha + B\mu_f$$

Sous ces hypothèses, la matrice de covariance inconditionnelle devient

$$\text{Cov}(x_t) = \Sigma_x = BB^T + \Psi$$

On a utilisé la non-identifiabilité pour normaliser. Puisque le modèle est invariant par H , autant choisir le H qui rend les facteurs les plus simples possible : centrés et de covariance identité. Il reste une indétermination — les **rotations orthogonales** H avec $HH^T = I_K$ préservent $\Sigma_f = I_K$ — d'où la note finale du cours sur les *rotations de coordonnées comme interprétations alternatives du modèle*.

Estimation par maximum de vraisemblance

Le modèle. $x_t = \alpha + Bf_t + \varepsilon_t$, avec α et B constants et toutes les variables aléatoires gaussiennes :

$$x_t \text{ i.i.d. } N_m(\alpha, \Sigma_x), \quad f_t \text{ i.i.d. } N_K(0_K, I_K), \quad \varepsilon_t \text{ i.i.d. } N_m(0_m, \Psi), \quad \Sigma_x = BB^T + \Psi$$

La vraisemblance.

$$\begin{aligned} L(\alpha, \Sigma_x) &= \prod_{t=1}^T \left[(2\pi)^{-m/2} |\Sigma_x|^{-1/2} \exp \left(-\frac{1}{2} (x_t - \alpha)^T \Sigma_x^{-1} (x_t - \alpha) \right) \right] \\ &= (2\pi)^{-Tm/2} |\Sigma_x|^{-T/2} \exp \left(-\frac{1}{2} \sum_{t=1}^T (x_t - \alpha)^T \Sigma_x^{-1} (x_t - \alpha) \right) \end{aligned}$$

La log-vraisemblance.

$$\ell(\alpha, \Sigma_x) = -\frac{Tm}{2} \log(2\pi) - \frac{T}{2} \log |\Sigma_x| - \frac{1}{2} \sum_{t=1}^T (x_t - \alpha)^T \Sigma_x^{-1} (x_t - \alpha)$$

Les EMV de α , B , Ψ sont les valeurs qui **maximisent** $\ell(\alpha, \Sigma_x)$ **sous la contrainte** $\Sigma_x = BB^T + \Psi$. Ils sont calculés **numériquement** par l'**algorithme EM** (Dempster, Laird et Rubin, 1977 ; Rubin et Thayer, 1983).

POURQUOI EM PLUTÔT QU'UNE MAXIMISATION DIRECTE.

La contrainte $\Sigma_x = BB^T + \Psi$ est non linéaire et couple tous les paramètres. En traitant les **facteurs f_t comme des données manquantes** — ce qu'ils sont littéralement, puisqu'ils sont latents — l'étape M se ramène à une régression gaussienne ordinaire. C'est exactement l'astuce utilisée pour les sauts de Poisson en fiche 53.

La spécification complète.

1. Appliquer l'algorithme EM pour calculer $\hat{\alpha}$, $\hat{B}$ et $\hat{\Psi}$.
2. **Estimer les réalisations de facteurs $\{f_t\}$** en appliquant, pour chaque période t , la régression transversale

$$x_t - \hat{\alpha} = \hat{B}f_t + \hat{\varepsilon}_t$$

En tenant compte de l'**hétéroscédasticité** dans Ψ , on applique les estimateurs **MCG** :

$$\hat{f}_t = [\hat{B}^T \hat{\Psi}^{-1} \hat{B}]^{-1} [\hat{B}^T \hat{\Psi}^{-1} (x_t - \hat{\alpha})]$$

3. (Facultatif) Considérer des **rotations de coordonnées** des facteurs orthonormés comme interprétations alternatives du modèle.

Détails supplémentaires.

- Les réalisations de facteurs estimées peuvent être **remises à l'échelle** pour représenter des **portefeuilles répliquants de facteurs**.
- Un **test du rapport de vraisemblance** permet de tester le **nombre de facteurs** :

$$LR(K) = 2[\ell(\tilde{\mu}, \tilde{\Sigma}) - \ell(\hat{\alpha}, \hat{B}, \hat{\Psi})]$$

où H_0 : « K facteurs suffisent à modéliser Σ », et $\tilde{\mu}, \tilde{\Sigma}$ sont les EMV **sans restriction** de modèle factoriel.

● Concept 7 — L'analyse en composantes principales

Le cadre. Une variable aléatoire m -variée $x = (x_1, \dots, x_m)^T$ avec $E[x] = \mu$ et $\text{Cov}[x] = \Sigma$ ($m \times m$).

Valeurs et vecteurs propres de Σ . $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_m \geq 0$ sont les m valeurs propres, et $\gamma_1, \dots, \gamma_m$ les m vecteurs propres **orthonormés** :

$$\Sigma \gamma_i = \lambda_i \gamma_i, \quad \gamma_i^T \gamma_i = 1 \quad \forall i, \quad \gamma_i^T \gamma_j = 0 \quad \forall i \neq j, \quad \Sigma = \sum_{i=1}^m \lambda_i \gamma_i \gamma_i^T$$

Les variables de composantes principales.

$$p_i = \gamma_i^T (x - \mu), \quad i = 1, \dots, m$$

En forme matricielle. $\Sigma = \Gamma \Lambda \Gamma^T$ avec $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_m)$, $\Gamma = [\gamma_1 : \gamma_2 : \dots : \gamma_m]$ et $\Gamma^T \Gamma = I_m$.
Alors

$$p = \Gamma^T (x - \mu)$$

$$E[p] = \Gamma^T E[x - E[x]] = 0_m$$

$$\text{Cov}[p] = \Gamma^T \text{Cov}[x] \Gamma = \Gamma^T \Sigma \Gamma = \Gamma^T (\Gamma \Lambda \Gamma^T) \Gamma = \Lambda$$

p est un vecteur de variables aléatoires centrées et non corrélées qui fournit une base orthogonale pour x . C'est le point à retenir : l'ACP **décorrèle**. Les m variables corrélées x_i deviennent m variables **indépendantes deux à deux** (au sens de la corrélation), de variances $\lambda_1 \geq \dots \geq \lambda_m$.

x sous forme de composantes principales

$$x = \mu + \Gamma p, \quad E[p] = 0_m, \quad \text{Cov}[p] = \Lambda$$

On partitionne $\Gamma = [\Gamma_1 \Gamma_2]$, où Γ_1 correspond aux $K (< m)$ **plus grandes** valeurs propres de Σ , et $p = \begin{pmatrix} p_1 \\ p_2 \end{pmatrix}$ où p_1 contient les K premiers éléments :

$$x = \mu + \Gamma_1 p_1 + \Gamma_2 p_2 = \mu + Bf + \varepsilon$$

avec

$$B = \Gamma_1 (m \times K), \quad f = p_1 (K \times 1), \quad \varepsilon = \Gamma_2 p_2 (m \times 1)$$

C'est comme un modèle à facteurs, sauf que $\text{Cov}[\varepsilon] = \Gamma_2 \Lambda_2 \Gamma_2^T$, où Λ_2 est la matrice diagonale des $(m - K)$ dernières valeurs propres.

Voilà la différence exacte entre ACP et analyse factorielle, et c'est la question d'examen classique. Dans l'analyse factorielle, Ψ est **diagonale par hypothèse** : le modèle *impose* que le résidu soit sans corrélation croisée. Dans l'ACP, $\text{Cov}[\varepsilon] = \Gamma_2 \Lambda_2 \Gamma_2^T$ n'est **en général pas diagonale** : l'ACP ne fait que tronquer une rotation, elle ne modélise rien. L'ACP est **descriptive**, l'analyse factorielle est un **modèle statistique** avec une vraisemblance et des tests.

ACP empirique

L'analyse en composantes principales de $X = [x_1 : \dots : x_T] \ (m \times T)$ consiste en :

1. **Moyennes des lignes** : $\bar{x} = \frac{1}{T} X 1_T$
2. **Matrice centrée** : $X^* = X - \bar{x} 1_T^T$
3. **Covariance empirique** : $\hat{\Sigma}_x = \frac{1}{T} X^* (X^*)^T$
4. **Décomposition en valeurs et vecteurs propres** : $\hat{\Sigma}_x = \hat{\Gamma} \hat{\Lambda} \hat{\Gamma}^T$, donnant les estimations de Γ et Λ
5. **Composantes principales empiriques** : $P = [p_1 : \dots : p_T] = \hat{\Gamma}^T X^* \ (m \times T)$

ACP par décomposition en valeurs singulières

On considère la **SVD** de la matrice centrée :

$$X^* = V D U^T$$

où V est $(m \times m)$ **orthogonale** ($V^T V = I_m$), U est **orthonormée en colonnes** ($U^T U = I_m$), et $D = \text{diag}(d_1, \dots, d_m)$ avec $d_1 \geq d_2 \geq \dots \geq 0$.

Exercice du cours : montrer que

$$\hat{\Lambda} = \frac{1}{T} D^2, \quad \hat{\Gamma} = V, \quad P = \hat{\Gamma}^T X^* = D U^T$$

En pratique on passe TOUJOURS par la SVD et jamais par la diagonalisation explicite de $\hat{\Sigma}_x$. Deux raisons : on n'a pas besoin de former $X^* (X^*)^T$, qui coûte $O(m^2 T)$ et **carre le conditionnement** ; et quand $T < m$ — le cas usuel en finance ! — $\hat{\Sigma}_x$ est **singulière** alors que la SVD reste parfaitement définie.

Définition alternative — par maximisation de variance

Étant donné $\mathbf{x}$ m -varié avec $E[\mathbf{x}] = \boldsymbol{\mu}$ et $\text{Cov}[\mathbf{x}] = \boldsymbol{\Sigma}_x$:

Première composante principale : $p_1 = \mathbf{w}^T \mathbf{x}$, où les coefficients $\mathbf{w} = (w_1, \dots, w_m)^T$ sont choisis pour

$$\text{maximiser } \text{Var}(p_1) = \mathbf{w}^T \boldsymbol{\Sigma}_x \mathbf{w} \quad \text{sous } |\mathbf{w}|^2 = \sum_{i=1}^m w_i^2 = 1$$

Deuxième composante principale : $p_2 = \mathbf{v}^T \mathbf{x}$, où $\mathbf{v}$ est choisi pour

$$\text{maximiser } \text{Var}(p_2) = \mathbf{v}^T \boldsymbol{\Sigma}_x \mathbf{v} \quad \text{sous } |\mathbf{v}|^2 = 1 \text{ et } \mathbf{v}^T \mathbf{w} = 0$$

Et ainsi de suite jusqu'à p_m . Les vecteurs de coefficients sont donnés par

$$[\mathbf{w} : \mathbf{v} : \dots] = [\gamma_1 : \gamma_2 : \dots] = \boldsymbol{\Gamma}$$

Les deux définitions coïncident, et c'est un résultat de la fiche 7. Maximiser $\mathbf{w}^T \boldsymbol{\Sigma}_x \mathbf{w}$ sous $\mathbf{w}^T \mathbf{w} = 1$ est un problème d'extremum lié : le lagrangien $\mathbf{w}^T \boldsymbol{\Sigma}_x \mathbf{w} - \lambda(\mathbf{w}^T \mathbf{w} - 1)$ a pour condition du premier ordre $\boldsymbol{\Sigma}_x \mathbf{w} = \lambda \mathbf{w}$ — c'est **exactement** l'équation aux valeurs propres. Et la valeur du maximum est $\mathbf{w}^T \boldsymbol{\Sigma}_x \mathbf{w} = \lambda$, d'où l'ordre décroissant des λ_i .

La décomposition de la variance totale

$$\begin{aligned} \text{Variance totale}(\mathbf{x}) &= \sum_{i=1}^m \text{Var}(x_i) = \text{trace}(\boldsymbol{\Sigma}_x) = \text{trace}(\boldsymbol{\Gamma} \boldsymbol{\Lambda} \boldsymbol{\Gamma}^T) = \text{trace}(\boldsymbol{\Lambda} \boldsymbol{\Gamma}^T \boldsymbol{\Gamma}) = \text{trace}(\boldsymbol{\Lambda}) = \sum_{k=1}^m \lambda_k = \sum_{k=1}^m \text{Var}(p_k) \\ &= \text{Variance totale}(\mathbf{p}) \end{aligned}$$

La transformation de $\mathbf{x}$ vers $\mathbf{p}$ est un **changement de système de coordonnées** qui déplace l'origine vers la moyenne $E[\mathbf{x}] = \boldsymbol{\mu}$ et **fait tourner les axes** pour les aligner sur les variables de composantes principales. La **distance est préservée** dans l'espace, en raison de l'orthogonalité de la rotation.

C'est ce qui justifie la lecture « $\lambda_k / \sum_j \lambda_j$ = part de variance expliquée ». Comme la rotation conserve la variance totale, chaque valeur propre se lit directement comme une fraction du total. Sur des rendements d'actions, la première composante capte typiquement **30–50 %** de la variance : c'est le **facteur de marché**, retrouvé sans qu'on l'ait jamais spécifié.

● Concept 8 — La méthode du facteur principal

Pour ajuster un modèle à K facteurs, $K < m$ fixé, sur $X = [x_1 : \dots : x_T]$ ($m \times T$) :

Étape 1 — conduire les étapes de calcul de l'ACP.

$$\bar{x} = \frac{1}{T} X 1_T, \quad X^* = X - \bar{x} 1_T^T, \quad \hat{\Sigma}_x = \frac{1}{T} X^* (X^*)^T, \quad \hat{\Sigma}_x = \hat{\Gamma} \hat{\Lambda} \hat{\Gamma}^T$$

Étape 2 — spécifier les estimations initiales (indice $s = 0$).

$$\tilde{\alpha}_0 = \bar{x}, \quad \tilde{B}_0 = \hat{\Gamma}_{(K)} (\hat{\Lambda}_{(K)})^{1/2}$$

où $\hat{\Gamma}_{(K)}$ et $\hat{\Lambda}_{(K)}$ sont les sous-matrices des K premières colonnes de $\hat{\Gamma}$ et $\hat{\Lambda}$, puis

$$\tilde{\Psi}_0 = \text{diag}(\hat{\Sigma}_x) - \text{diag}(\tilde{B}_0 \tilde{B}_0^T), \quad \tilde{\Sigma}_0 = \tilde{B}_0 \tilde{B}_0^T + \tilde{\Psi}_0$$

Étape 3 — ajuster la covariance empirique :

$$\hat{\Sigma}_x^* = \hat{\Sigma}_x - \tilde{\Psi}_0$$

calculer sa décomposition en valeurs et vecteurs propres $\hat{\Sigma}_x^* = \tilde{\Gamma} \tilde{\Lambda} \tilde{\Gamma}^T$, ce qui donne des estimations **mises à jour** de Γ et Λ , puis **répéter l'étape 2** avec ces nouvelles estimations, obtenant $\tilde{B}_1, \tilde{\Psi}_1, \tilde{\Sigma}_1 = \tilde{B}_1 \tilde{B}_1^T + \tilde{\Psi}_1$.

Étape 4 — répéter l'étape 3, engendrant une suite d'estimations $(\tilde{B}_s, \tilde{\Psi}_s, \tilde{\Sigma}_s)$, $s = 1, 2, \dots$, **jusqu'à ce que les variations successives de $\tilde{\Sigma}_s$ soient suffisamment négligeables.**

Étape 5 — utiliser les estimations de la dernière itération de l'étape 4.

L'idée en une phrase. L'ACP brute confond le risque commun et le risque spécifique. La méthode du facteur principal **retire** l'estimation courante de Ψ de la covariance empirique **avant** de diagonaliser, puis met à jour Ψ à partir du nouveau B , et itère. Elle converge vers un point fixe où $\hat{\Sigma}_x \approx \tilde{B} \tilde{B}^T + \tilde{\Psi}$ — c'est-à-dire vers une vraie structure factorielle, et non une simple troncature de rotation.

Un piège numérique bien connu : $\tilde{\Psi}_0 = \text{diag}(\hat{\Sigma}_x) - \text{diag}(\tilde{B}_0 \tilde{B}_0^T)$ peut produire des variances **négatives** (le « cas de Heywood »). C'est le signe que K est mal choisi ou que le modèle est mal spécifié.

Comment résoudre l'exercice type (protocole)

1. **Identifier ce qui est observé** : F observé $\Rightarrow$ régressions **temporelles** ; B observé $\Rightarrow$ régressions **transversales** ; ni l'un ni l'autre $\Rightarrow$ méthode **statistique**.
2. **Écrire le modèle** dans la bonne forme (a), (b) ou (c) et poser les hypothèses sur f_t et ε_t .
3. **Estimer** : MCO si $\text{Cov} = \sigma^2 I$, **MCG** si hétéroscédasticité (le cas transversal, à cause de Ψ).
4. **Calculer les variances résiduelles** avec le bon nombre de degrés de liberté : $T - 2$ pour Sharpe, $T - (K + 1)$ en multifactoriel.
5. **Reconstituer** $\hat{\Sigma}_x = \hat{B}\hat{\Sigma}_f\hat{B}^T + \hat{\Psi}$.
6. **Vérifier** : nombre de facteurs (test LR, éboulis des valeurs propres), résidus non corrélés entre actifs, part de variance expliquée.

Comment reconnaître qu'il faut utiliser cette méthode ?

Indice dans l'énoncé	Ce qu'il faut faire
« estimer Σ pour m grand »	modèle à facteurs — c'est le remède de la fiche 51
« rendement du marché en excès du taux sans risque »	modèle à indice unique de Sharpe , $\Sigma_x = \sigma_M^2 \beta \beta^T + \Psi$
« inflation, PIB, taux, chômage »	facteurs macroéconomiques observés $\Rightarrow$ régressions temporelles
« secteur d'appartenance », « capitalisation »	BARRA : les attributs <i>sont</i> les bêtas $\Rightarrow$ régressions transversales
« quintiles », « long-court »	Fama-French : portefeuilles de couverture $\Rightarrow$ régressions temporelles
« facteurs latents / inobservés »	analyse factorielle (EM) ou ACP
« part de variance expliquée »	ACP : $\lambda_k / \sum_j \lambda_j$
« combien de facteurs ? »	test du rapport de vraisemblance $LR(K)$

Exercices progressifs

Niveau 1 — Sous le modèle de Sharpe, combien de paramètres décrivent Σ_x pour $m = 500$ actifs ? Comparez à une matrice libre.

Modèle de Sharpe. $\Sigma_x = \sigma_M^2 \beta \beta^T + \Psi$ est décrite par :

- $m = 500$ bêtas β_i ,
- $m = 500$ variances spécifiques ψ_i^2 ,
- 1 variance de marché σ_M^2 ,

soit $2m + 1 = 1\,001$ paramètres.

Matrice libre. $m(m + 1)/2 = 500 \times 501/2 = 125\,250$ paramètres.

Le rapport est de 125 pour 1. Et le point n'est pas seulement la mémoire : avec T observations mensuelles sur dix ans ($T = 120$), la covariance empirique de 500 actifs est de **rang au plus 120**, donc **singulière**. Son inverse — dont Markowitz a besoin — n'existe pas. La structure factorielle, elle, garantit $\Sigma_x = \sigma_M^2 \beta \beta^T + \Psi$ **définie positive** dès que tous les $\psi_i^2 > 0$.

Niveau 2 — Dans le modèle sectoriel BARRA, montrez que $\hat{f}_t$ est le vecteur des rendements moyens par secteur.

Étape 1 — la structure de B . B est $(m \times K)$ d'entrées $\beta_{i,k} \in \{0, 1\}$, avec exactement un 1 par ligne (chaque actif appartient à un seul secteur). La colonne k est l'indicatrice du secteur k .

Étape 2 — calculer $B^T B$. L'élément (k, k') vaut $\sum_i \beta_{i,k} \beta_{i,k'}$. Pour $k \neq k'$ le produit est toujours nul (aucun actif dans deux secteurs) ; pour $k = k'$ il vaut le nombre d'actifs du secteur k . Donc

$$B^T B = \text{diag}(m_1, \dots, m_K), \quad (B^T B)^{-1} = \text{diag}(1/m_1, \dots, 1/m_K)$$

Étape 3 — calculer $B^T x_t$. La k -ième composante vaut $\sum_i \beta_{i,k} x_{i,t} = \sum_{i \in \text{secteur } k} x_{i,t}$: la **somme** des rendements du secteur k .

Étape 4 — conclure.

$$\hat{f}_t = (B^T B)^{-1} B^T x_t \quad \Rightarrow \quad \hat{f}_{k,t} = \frac{1}{m_k} \sum_{i \in \text{secteur } k} x_{i,t}$$

C'est bien le **rendement moyen équipondéré du secteur k à la date t** . ■

Et le résidu ? $\hat{\varepsilon}_{i,t} = x_{i,t} - \hat{f}_{k(i),t}$: l'écart de l'actif à la moyenne de son propre secteur. La décomposition est donc « rendement = effet secteur + écart au secteur ».

Mais ce n'est pas l'estimateur optimal. $\text{Cov}(\varepsilon_t) = \Psi$ n'est pas $\sigma^2 I_m$: il y a **hétéroscédasticité**. Le BLUE est l'estimateur MCG $\hat{f}_t = [B^T \Psi^{-1} B]^{-1} B^T \Psi^{-1} x_t$, qui donne une moyenne sectorielle **pondérée par $1/\psi_i^2$** — les actifs les plus bruités pèsent moins.

Niveau 3 — Pourquoi les facteurs d'un modèle statistique ne sont-ils jamais interprétables économiquement ?

Le résultat d'invariance. Pour toute matrice $(K \times K)$ inversible H , en posant $f_t^* = H f_t$ et $B^* = B H^{-1}$:

$$x_t = \alpha + B^* f_t^* + \varepsilon_t = \alpha + B H^{-1} H f_t + \varepsilon_t = \alpha + B f_t + \varepsilon_t$$

Le modèle transformé est **le même modèle** — mêmes observations, même vraisemblance. Les données ne peuvent donc **pas** distinguer (B, f_t) de (B^*, f_t^*) .

Ce qui est identifié et ce qui ne l'est pas.

- **Identifié** : le **sous-espace** de $\mathbb{R}^m$ engendré par les colonnes de B ; la matrice BB^T ; la décomposition risque commun / risque spécifique ; le nombre K .
- **Non identifié** : la **base** particulière choisie dans ce sous-espace, donc les facteurs individuels et leurs chargements.

Ce que la normalisation retire — et ne retire pas. Imposer $\mu_f = 0$ et $\Sigma_f = I_K$ élimine les H généraux, mais laisse **toutes les rotations orthogonales** ($HH^T = I_K$), puisque $\text{Cov}(H f_t) = H I_K H^T = I_K$. Il reste $K(K-1)/2$ degrés de liberté d'indétermination. Le cours en fait explicitement une note : « *considérer des rotations de coordonnées des facteurs orthonormés comme interprétations alternatives du modèle* ».

La conséquence pratique. Dire « le facteur 2 est le facteur taille » n'a aucun sens statistique : une rotation le mélange au facteur 3 sans rien changer à l'ajustement. Les interprétations viennent **de l'extérieur** — en corrélant a posteriori les facteurs extraits avec des variables économiques connues, ou en choisissant une rotation qui rend les chargements « simples » (varimax).

Le contraste avec les autres familles. C'est exactement pourquoi les modèles macroéconomiques et fondamentaux existent : en **imposant** ce que sont les facteurs (l'inflation, le secteur bancaire, le quintile de capitalisation), ils sacrifient l'ajustement statistique optimal contre une **interprétabilité** garantie.

Niveau 4 — type examen — Comparez analyse factorielle et ACP : formalisme, hypothèses, ce que chacune estime.

Le point de départ commun. Les deux partent de la covariance empirique $\hat{\Sigma}_x = \frac{1}{T} X^* (X^*)^T$ et cherchent à représenter $x_t \approx \alpha + B f_t + \varepsilon_t$ avec $K \ll m$.

Analyse factorielle — un modèle statistique.

- **Hypothèses** : $x_t \sim N_m(\alpha, \Sigma_x)$, $f_t \sim N_K(0_K, I_K)$, $\varepsilon_t \sim N_m(0_m, \Psi)$, et Ψ **diagonale**.
- **Contrainte structurelle** : $\Sigma_x = B B^T + \Psi$.
- **Estimation** : maximiser $\ell(\alpha, \Sigma_x)$ sous cette contrainte, numériquement par **EM**.
- **Ce qu'elle estime** : B et Ψ séparément — elle **distingue** risque commun et risque spécifique.
- **Inférence disponible** : test du rapport de vraisemblance $LR(K) = 2[\ell(\tilde{\mu}, \tilde{\Sigma}) - \ell(\hat{\alpha}, \hat{B}, \hat{\Psi})]$ pour le nombre de facteurs.

ACP — une transformation descriptive.

- **Hypothèses** : aucune. C'est de l'algèbre linéaire sur $\Sigma_x = \Gamma \Lambda \Gamma^T$.
- **Construction** : $p = \Gamma^T(x - \mu)$, puis on tronque à K : $B = \Gamma_1$, $f = p_1$, $\varepsilon = \Gamma_2 p_2$.
- **Ce qu'elle estime** : rien, au sens statistique — elle **décompose** la variance observée.
- **La différence décisive** : $\text{Cov}[\varepsilon] = \Gamma_2 \Lambda_2 \Gamma_2^T$, qui **n'est pas diagonale**. L'ACP ne prétend pas que les résidus sont sans corrélation croisée ; elle jette simplement les $(m - K)$ directions de plus faible variance.

Le tableau de synthèse.

	Analyse factorielle	ACP
Nature	modèle probabiliste	rotation + troncature
$\text{Cov}(\varepsilon)$	Ψ diagonale par hypothèse	$\Gamma_2 \Lambda_2 \Gamma_2^T$, non diagonale
Critère	vraisemblance	variance maximale
Calcul	EM, itératif	décomposition spectrale / SVD , direct
Sensible à l'échelle	non (via Ψ)	oui — il faut standardiser
Tests	oui (LR)	non
Objectif	expliquer les covariances	expliquer la variance totale

La formulation qui résume tout. L'analyse factorielle explique les **covariances** — elle demande « qu'est-ce qui fait bouger les actifs **ensemble** ? » et met tout le reste dans Ψ . L'ACP explique la **variance totale** — elle demande « quelles directions bougent le **plus** ? », sans distinguer commun et spécifique.

Et le pont entre les deux : la méthode du facteur principal. Elle part de l'ACP mais **soustrait $\tilde{\Psi}$ avant de diagonaliser**, puis met à jour $\tilde{\Psi}$ à partir du nouveau $\tilde{B}$, et itère jusqu'à stabilisation de $\tilde{\Sigma}_g$. Elle obtient ainsi une vraie structure factorielle, avec le coût algorithmique de l'ACP et non celui de l'EM.

● Common mistakes

1. **Confondre facteur et chargement** — f_t varie en t et est commun à tous les actifs ; β_i varie en i et est constant dans le temps.
2. **Oublier que Ψ est diagonale** — c'est l'**hypothèse** qui fait tout le gain de paramètres, et c'est aussi celle qu'il faut vérifier.
3. **Utiliser les MCO en régression transversale** — $\text{Cov}(\varepsilon_t) = \Psi \neq \sigma^2 I_m$: il y a hétéroscédasticité, donc **MCG**.
4. **Se tromper de degrés de liberté** — $T - 2$ pour le modèle de Sharpe, $T - (K + 1)$ pour K facteurs.
5. **Confondre le B transversal et le B de la régression multivariée** — ils sont **transposés** l'un de l'autre.
6. **Interpréter économiquement des facteurs statistiques** — le modèle est invariant par toute H inversible, donc par toute rotation.
7. **Croire que l'ACP donne un modèle à facteurs** — $\text{Cov}[\varepsilon] = \Gamma_2 \Lambda_2 \Gamma_2^T$ n'est pas diagonale.
8. **Faire une ACP sur des variables d'échelles différentes** sans standardiser — la variable la plus dispersée capture la première composante.
9. **Inverser le sens BARRA / Fama-French** — BARRA observe B et estime f_t ; Fama-French construit f_t et estime B .
10. **Diagonaliser $\hat{\Sigma}_x$ explicitement** au lieu de passer par la SVD de X^* — surtout quand $T < m$, où $\hat{\Sigma}_x$ est singulière.

Ultimate Review

1. **Modèle** : $x_{i,t} = \alpha_i + \beta_i^T f_t + \varepsilon_{i,t}$; α_i, β_i constants en t , f_t commun à tous les i .

2. **Trois écritures** : transversale $x_t = \alpha + Bf_t + \varepsilon_t$ · temporelle $x_i = 1_T \alpha_i + F\beta_i + \varepsilon_i$ · multivariée $X = 1_T \alpha^T + FB + E$.
3. **Hypothèses** : $\{f_t\}$ stationnaire $I(0)$, $E[f_t] = \mu_f$, $\text{Cov}[f_t] = \Sigma_f$; $\{\varepsilon_t\}$ bruit blanc de $\text{Cov} = \Psi$ diagonale.
4. **Moments** : conditionnels $E[x_t | f_t] = \alpha + Bf_t$, $\text{Cov} = \Psi$; inconditionnels $\mu_x = \alpha + B\mu_f$ et $\Sigma_x = B\Sigma_f B^T + \Psi$.
5. **Sharpe (1970)** : $x_{i,t} = \alpha_i + \beta_i R_{Mt} + \varepsilon_{i,t}$, $\Sigma_x = \sigma_M^2 \beta \beta^T + \Psi$; MCO = BLUE = EMV ; $\hat{\psi}_i^2 = \hat{\varepsilon}_i^T \hat{\varepsilon}_i / (T - 2)$, $\hat{\sigma}_M^2 = \sum (R_{Mt} - \bar{R}_M)^2 / (T - 1)$.
6. **Macroéconomiques** : f_t observés (inflation, PIB, taux, chômage, mises en chantier...) — Chen, Ross et Roll (1986) ; $\hat{\psi}_i^2 = \hat{\varepsilon}_i^T \hat{\varepsilon}_i / [T - (K + 1)]$, $\hat{\Sigma}_f = \sum (f_t - \hat{\mu}_f)(f_t - \hat{\mu}_f)^T / (T - 1)$.
7. **Fondamentaux — BARRA** : les attributs observables **sont** les bêtas, f_t estimés par régression transversale.
8. **Fondamentaux — Fama-French** : tris transversaux en **quintiles**, **portefeuille de couverture** long-court, β_i estimés par régression **temporelle**.
9. **Modèle sectoriel BARRA** : $\beta_{i,k}$ indicatrices $\Rightarrow B^T B = \text{diag}(m_1, \dots, m_K)$ et $\hat{f}_t = (B^T B)^{-1} B^T x_t =$ **moyennes sectorielles** ; $\hat{\Sigma} = B\hat{\Sigma}_f B^T + \hat{\Psi}$; MCG contre l'hétéroscédasticité ; portefeuilles répliquants ; formulation SUR.
10. **Invariance** : $f_t^* = H f_t$, $B^* = B H^{-1} \Rightarrow$ même modèle. Les facteurs statistiques **ne sont pas** identifiés.
11. **Normalisation** : $\Sigma_f = I_K$ via $H = \Lambda^{-1/2} \Gamma^T$, $\mu_f = 0_K$ via $\alpha \leftarrow \alpha + B\mu_f \Rightarrow \Sigma_x = B B^T + \Psi$.
12. **Analyse factorielle** : EMV sous contrainte $\Sigma_x = B B^T + \Psi$, calculée par **EM** ; réalisations par **MCG** $\hat{f}_t = [\hat{B}^T \hat{\Psi}^{-1} \hat{B}]^{-1} \hat{B}^T \hat{\Psi}^{-1} (x_t - \hat{\alpha})$; nombre de facteurs par **LR(K)**.
13. **ACP** : $\Sigma = \Gamma \Lambda \Gamma^T$, $p = \Gamma^T (x - \mu)$, $E[p] = 0$, $\text{Cov}[p] = \Lambda$; troncature $B = \Gamma_1$, $f = p_1$, $\varepsilon = \Gamma_2 p_2$ avec $\text{Cov}[\varepsilon] = \Gamma_2 \Lambda_2 \Gamma_2^T$ **non diagonale**.
14. **ACP empirique** : $\bar{x}$, X^* , $\hat{\Sigma}_x = \frac{1}{T} X^* (X^*)^T$, $\hat{\Sigma}_x = \hat{\Gamma} \hat{\Lambda} \hat{\Gamma}^T$, $P = \hat{\Gamma}^T X^*$. Par **SVD** $X^* = V D U^T$: $\hat{\Lambda} = D^2 / T$, $\hat{\Gamma} = V$, $P = D U^T$.
15. **Définition variationnelle** : $\max w^T \Sigma_x w$ sous $|w| = 1$, puis orthogonalité successive $\Rightarrow$ les coefficients **sont** les vecteurs propres.
16. **Variance totale** : $\text{trace}(\Sigma_x) = \text{trace}(\Lambda) = \sum \lambda_k$; la rotation **préserve les distances**.
17. **Méthode du facteur principal** : ACP, puis $\tilde{B}_0 = \hat{\Gamma}_{(K)} \hat{\Lambda}_{(K)}^{1/2}$, $\tilde{\Psi}_0 = \text{diag}(\hat{\Sigma}_x) - \text{diag}(\tilde{B}_0 \tilde{B}_0^T)$, puis **itérer** sur $\hat{\Sigma}_x^* = \hat{\Sigma}_x - \tilde{\Psi}_s$ jusqu'à stabilisation.

Formulas to know

$$x_t = \alpha + Bf_t + \varepsilon_t \quad \Sigma_x = B\Sigma_f B^T + \Psi \quad \Sigma_x = \sigma_M^2 \beta \beta^T + \Psi \text{ [Sharpe]}$$

$$\hat{f}_t = (B^T B)^{-1} B^T x_t \text{ [BARRA, MCO]} \quad \hat{f}_t = [\hat{B}^T \hat{\Psi}^{-1} \hat{B}]^{-1} \hat{B}^T \hat{\Psi}^{-1} (x_t - \hat{\alpha}) \text{ [MCG]}$$

$$\Sigma = \Gamma \Lambda \Gamma^T \quad p = \Gamma^T (x - \mu) \quad \text{trace}(\Sigma_x) = \sum_k \lambda_k \quad LR(K) = 2[\ell(\tilde{\mu}, \tilde{\Sigma}) - \ell(\hat{\alpha}, \hat{B}, \hat{\Psi})]$$

Methods to know : le décompte des paramètres et le gain factoriel ; la démonstration que $\hat{f}_t$ est une moyenne sectorielle ; la preuve de l'invariance par H ; l'équivalence entre maximisation de variance et équation aux valeurs propres ; l'algorithme du facteur principal.

Active Recall

Basic — Écrivez la décomposition de la covariance dans un modèle à facteurs et nommez ses deux termes.

$$\Sigma_x = B \Sigma_f B^T + \Psi$$

- $B \Sigma_f B^T$: le **risque commun** (ou systématique), de rang au plus K — c'est la partie de la covariance qui passe par les facteurs partagés.
- Ψ : le **risque spécifique** (ou idiosyncratique), **diagonal** — propre à chaque actif et non corrélé entre actifs.

C'est cette décomposition qui rend l'estimation praticable pour m grand :

$mK + K(K+1)/2 + m$ paramètres au lieu de $m(m+1)/2$.

Understanding — Pourquoi les facteurs d'un modèle statistique ne sont-ils pas identifiés ?

Parce que pour toute matrice $(K \times K)$ **inversible** H , en posant $f_t^* = H f_t$ et $B^* = B H^{-1}$, on a

$$B^* f_t^* = B H^{-1} H f_t = B f_t$$

Le modèle transformé est **indiscernable** de l'original : mêmes observations, même vraisemblance. Seul le **sous-espace** engendré par les colonnes de B est identifié, pas la base choisie dedans.

Les normalisations $\mu_f = 0_K$ (via $\alpha \leftarrow \alpha + B \mu_f$) et $\Sigma_f = I_K$ (via $H = \Lambda^{-1/2} \Gamma^T$) réduisent l'indétermination, mais **toutes les rotations orthogonales subsistent**, puisqu'elles

préservent $\Sigma_f = I_K$.

Application — Le modèle de Sharpe donne $\beta_i = 1,2$, $\beta_j = 0,8$, $\sigma_M = 15\%$, $\psi_i = 25\%$, $\psi_j = 20\%$. Calculez la corrélation entre les deux actifs.

Covariance. Sous $\Sigma_x = \sigma_M^2 \beta \beta^T + \Psi$ avec Ψ diagonale, le terme hors diagonale est

$$\text{Cov}(x_i, x_j) = \beta_i \beta_j \sigma_M^2 = 1,2 \times 0,8 \times 0,15^2 = 0,96 \times 0,0225 = 0,0216$$

Variances.

$$\text{Var}(x_i) = \beta_i^2 \sigma_M^2 + \psi_i^2 = 1,44 \times 0,0225 + 0,0625 = 0,0324 + 0,0625 = 0,0949$$

$$\text{Var}(x_j) = 0,64 \times 0,0225 + 0,04 = 0,0144 + 0,04 = 0,0544$$

Corrélation.

$$\rho_{ij} = \frac{0,0216}{\sqrt{0,0949 \times 0,0544}} = \frac{0,0216}{\sqrt{0,005163}} = \frac{0,0216}{0,0719} \approx 0,30$$

Ce que le calcul illustre. Toute la corrélation vient du **facteur de marché** : **Cov** est un simple produit $\beta_i \beta_j \sigma_M^2$. Et la corrélation reste modeste (**30%**) parce que le risque spécifique domine ici — $\psi_i^2 = 0,0625$ contre **0,0324** de risque de marché pour l'actif i .

Comparison — BARRA contre Fama-French : quelle différence de méthode ?

Les deux sont des modèles **fondamentaux** — les facteurs viennent d'attributs spécifiques aux actifs (secteur, taille, rendement du dividende, style). Mais le **sens de la régression est inversé**.

	BARRA	Fama-French
Ce qui est observé	les chargements B (l'actif est dans le secteur bancaire)	les facteurs f_t (rendements des portefeuilles)
Ce qui est estimé	les réalisations f_t	les chargements β_i
Type de régression	transversale , une par période t	temporelle , une par actif i
Construction des facteurs	— (ils sortent de la régression)	tri en quintiles , portefeuille long le quintile haut / court le quintile bas

L'élégance de Fama-French. Le portefeuille de couverture long-court **annule** l'exposition commune et isole l'effet de l'attribut. Le facteur obtenu est donc aussi un **portefeuille investissable** — on peut littéralement acheter le facteur.

L'élégance de BARRA. Les chargements sont **connus sans erreur** (l'appartenance sectorielle n'est pas estimée), ce qui élimine une source d'erreur, et la régression transversale se réduit parfois à un calcul de moyennes par groupe.

Exam-style — Un gérant veut optimiser un portefeuille de **1 000** actions avec **5** ans de données mensuelles. Expliquez pourquoi il ne peut pas appliquer Markowitz directement et comment un modèle à facteurs le sauve.

Le blocage — un problème de rang, pas de puissance de calcul. Markowitz exige Σ^{-1} (fiche 51). Ici $m = 1\,000$ et $T = 60$ mois. La covariance empirique

$$\hat{\Sigma}_x = \frac{1}{T} X^* (X^*)^T$$

est une somme de $T = 60$ matrices de rang **1** : son **rang est au plus 59** (une dimension part au centrage), très loin de **1 000**. Elle est donc **singulière** : $\hat{\Sigma}_x^{-1}$ **n'existe pas**. Le problème n'est pas numérique, il est structurel.

Le second blocage — le décompte. Même avec assez de données, Σ libre demande $m(m+1)/2 = 500\,500$ paramètres, pour $mT = 60\,000$ observations. On estime huit fois plus de paramètres qu'on n'a de nombres.

La conséquence, déjà annoncée en fiche 51. L'optimiseur est un « *estimation error maximizer* » : il charge massivement les actifs dont le rendement a été surestimé par hasard

et exploite des corrélations qui sont du pur bruit. Les poids obtenus sont extrêmes et instables.

Le sauvetage factoriel. On pose $\Sigma_x = B\Sigma_f B^T + \Psi$ avec Ψ diagonale. Avec $K = 5$ facteurs :

$$\underbrace{mK}_{5\,000} + \underbrace{K(K+1)/2}_{15} + \underbrace{m}_{1\,000} = 6\,015 \text{ paramètres, contre } 500\,500$$

soit **dix fois moins de paramètres que d'observations**, ce qui est enfin un problème d'estimation raisonnable.

Et $\hat{\Sigma}_x$ redevient inversible. $B\Sigma_f B^T$ est semi-définie positive de rang $\leq K$, et Ψ est **définie positive** dès que tous les $\psi_i^2 > 0$. La somme est donc **définie positive**, quel que soit T . Mieux, le lemme d'inversion matricielle donne

$$\Sigma_x^{-1} = \Psi^{-1} - \Psi^{-1} B [\Sigma_f^{-1} + B^T \Psi^{-1} B]^{-1} B^T \Psi^{-1}$$

qui ne demande d'inverser qu'une matrice $(K \times K)$ et une diagonale — un calcul en $O(mK^2)$ au lieu de $O(m^3)$.

Quel modèle choisir concrètement ?

- Le plus simple : **Sharpe**, $\Sigma_x = \sigma_M^2 \beta \beta^T + \Psi$, $2m + 1$ paramètres.
- Plus riche et interprétable : **BARRA sectoriel** ou **Fama-French**, avec des facteurs qui ont un sens économique.
- Le plus ajusté aux données : **analyse factorielle** par EM, avec le test $LR(K)$ pour choisir K — au prix de facteurs non interprétables.

Le prix à payer, à mentionner. On introduit du **biais** : si Ψ n'est pas vraiment diagonale — deux banques restent corrélées au-delà du facteur commun —, le modèle sous-estime le risque du portefeuille. C'est l'arbitrage biais-variance, et sur ces dimensions il penche massivement du côté du modèle contraint.

Flashcards

Question	Réponse
Écriture du modèle à facteurs ?	$\mathbf{x}_{i,t} = \alpha_i + \beta_i^T \mathbf{f}_t + \varepsilon_{i,t}$
$\mathbf{f}_t$ est constant en quoi ?	En i — commun à tous les actifs
β_i est constant en quoi ?	En t — propre à chaque actif
Écriture transversale ?	$\mathbf{x}_t = \alpha + B\mathbf{f}_t + \varepsilon_t$, une par période
Écriture temporelle ?	$\mathbf{x}_i = \mathbf{1}_T \alpha_i + F\beta_i + \varepsilon_i$, une par actif
Structure de Ψ ?	Diagonale — c'est l'hypothèse-clé
Covariance inconditionnelle ?	$\Sigma_x = B\Sigma_f B^T + \Psi$
Modèle de Sharpe ?	$\mathbf{x}_{i,t} = \alpha_i + \beta_i R_{Mt} + \varepsilon_{i,t}$
Sa covariance ?	$\sigma_M^2 \beta \beta^T + \Psi$, soit $2m + 1$ paramètres
Degrés de liberté chez Sharpe ?	$T - 2$
Degrés de liberté à K facteurs ?	$T - (K + 1)$
Exemples de facteurs macroéconomiques ?	Marché, inflation, PIB, masse monétaire, taux, mises en chantier, chômage
Référence des facteurs macro ?	Chen, Ross et Roll (1986)
Approche BARRA ?	Les attributs observables sont les bêtas , $\mathbf{f}_t$ estimés
Approche Fama-French ?	Tris en quintiles , portefeuille long-court , β_i par régression temporelle
$B^T B$ dans le modèle sectoriel ?	$\text{diag}(m_1, \dots, m_K)$
Que vaut $\hat{\mathbf{f}}_t$?	$(B^T B)^{-1} B^T \mathbf{x}_t =$ moyennes sectorielles
Pourquoi préférer les MCG en transversal ?	Hétéroscédasticité : $\text{Cov}(\varepsilon_t) = \Psi \neq \sigma^2 I_m$
Invariance du modèle à facteurs ?	$\mathbf{f}_t^* = H\mathbf{f}_t$, $B^* = BH^{-1}$ pour toute H inversible
Comment orthonormer les facteurs ?	$H = \Lambda^{-1/2} \Gamma^T$ avec $\Sigma_f = \Gamma \Lambda \Gamma^T$

Question	Réponse
Covariance après normalisation ?	$\Sigma_x = BB^T + \Psi$
Comment estime-t-on l'analyse factorielle ?	EMV sous contrainte, par l'algorithme EM
Estimation MCG des réalisations ?	$[\hat{B}^T \hat{\Psi}^{-1} \hat{B}]^{-1} \hat{B}^T \hat{\Psi}^{-1} (x_t - \hat{\alpha})$
Test du nombre de facteurs ?	$LR(K) = 2[\ell(\tilde{\mu}, \tilde{\Sigma}) - \ell(\hat{\alpha}, \hat{B}, \hat{\Psi})]$
Variables de composantes principales ?	$p_i = \gamma_i^T (x - \mu)$
Moments de p ?	$E[p] = 0_m, \text{Cov}[p] = \Lambda$
Cov $[\varepsilon]$ en ACP tronquée ?	$\Gamma_2 \Lambda_2 \Gamma_2^T$ — pas diagonale
Définition variationnelle de l'ACP ?	$\max w^T \Sigma_x w$ sous $ w ^2 = 1$, puis orthogonalité
Résultat de cette maximisation ?	Les coefficients sont les vecteurs propres Γ
Variance totale ?	$\text{trace}(\Sigma_x) = \text{trace}(\Lambda) = \sum_k \lambda_k$
ACP par SVD ?	$X^* = VDU^T \Rightarrow \hat{\Lambda} = D^2/T, \hat{\Gamma} = V, P = DU^T$
Initialisation du facteur principal ?	$\tilde{B}_0 = \hat{\Gamma}_{(K)} \hat{\Lambda}_{(K)}^{1/2}, \tilde{\Psi}_0 = \text{diag}(\hat{\Sigma}_x) - \text{diag}(\tilde{B}_0 \tilde{B}_0^T)$
Son itération ?	Diagonaliser $\hat{\Sigma}_x - \tilde{\Psi}_s$, mettre à jour, répéter