

Fiche 58 — Séries temporelles II : processus VAR, Kronecker et estimation multivariée

Matière	Maths · Économétrie
Cours source	Kemphorne, <i>18.S096 Topics in Mathematics with Applications in Finance</i> , MIT OpenCourseWare, automne 2013 — cours 11 « Time Series Analysis II »
Difficulté	Must know — l'économétrie des systèmes, socle de la macro appliquée
Temps d'étude estimé	2 h 30
Prérequis	Fiche 50 (MCO, Gauss-Markov, MCG), fiche 52 (stationnarité, Wold, AR, AIC/BIC), fiche 54 (matrices de covariance)
Concepts clés	Stationnarité multivariée, matrices d'autocovariance croisée, avance et rétroaction, Wold multivarié, VAR(p), matrice compagnon, régressions apparemment non reliées, produit de Kronecker, opérateur vec, optimalité des MCO par composante, critères AIC/BIC/HQ multivariés, normalité asymptotique
Poids à l'examen	Trois choses : la condition de stationnarité d'un VAR(p) ; le théorème d'optimalité — pourquoi les MCO équation par équation suffisent — et savoir le démontrer par Kronecker ; la loi asymptotique $\sqrt{n}(\hat{\beta} - \beta) \rightarrow N(0, \Sigma \otimes \Gamma^{-1})$.

Vue d'ensemble

Soit $\{X_t\} = \{\dots, X_{t-1}, X_t, X_{t+1}, \dots\}$ un processus stochastique de dimension m , constitué de m -vecteurs aléatoires

$$X_t = (X_{1,t}, X_{2,t}, \dots, X_{m,t})^T, \quad \text{vecteur aléatoire sur } \mathbb{R}^m$$

$\{X_t\}$ est composé de m **séries temporelles composantes** $\{X_{1,t}\}, \{X_{2,t}\}, \dots, \{X_{m,t}\}$.

DÉFINITION.

$\{X_t\}$ est **stationnaire en covariance** si **chaque** série temporelle composante est stationnaire en covariance.

UNIVARIÉ (fiche 52)

$\gamma(k)$ scalaire

AR(p)

racines de $\phi(z)$

ESTIMATION

MULTIVARIÉ (cette fiche)

Γ_k matrice $m \times m$, NON symétrique

VAR(p) : Φ_k matrices $m \times m$

racines de $\det(I - \Phi_1 z - \dots - \Phi_p z^p)$

→ NOUVEAU : avance, retard, rétroaction

→ m régressions séparées... et c'est OPTIMAL

La question qui structure la fiche. Passer de **1** à **m** séries fait apparaître les **relations croisées** — qui précède qui, qui rétroagit sur qui — mais fait aussi exploser le nombre de paramètres : **pm^2** coefficients au lieu de **p** . La bonne nouvelle du chapitre est que, **en l'absence de restrictions**, l'estimation reste triviale : **m** régressions MCO indépendantes, et c'est **optimal**.

● Concept 1 — Les moments d'une série multivariée

Moment d'ordre 1.

$$\mu = E[X_t] = \begin{pmatrix} E(X_{1,t}) \\ E(X_{2,t}) \\ \vdots \\ E(X_{m,t}) \end{pmatrix} = \begin{pmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_m \end{pmatrix} \quad (m \times 1)$$

Matrice de variance-covariance.

$$\Gamma_0 = \text{Var}(X_t) = \begin{pmatrix} \text{var}(X_{1,t}) & \text{cov}(X_{1,t}, X_{2,t}) & \cdots \\ \vdots & \ddots & \vdots \\ \text{cov}(X_{m,t}, X_{1,t}) & \text{cov}(X_{m,t}, X_{2,t}) & \cdots & \text{var}(X_{m,t}) \end{pmatrix}$$

Matrice de corrélation.

$$R_0 = \text{corr}(X_t) = D^{-1/2} \Gamma_0 D^{-1/2}, \quad \text{où } D = \text{diag}(\Gamma_0)$$

Matrice d'autocovariance croisée au retard k .

$$\Gamma_k = \text{Cov}(X_t, X_{t-k}) = E[(X_t - \mu)(X_{t-k} - \mu)^T]$$

dont l'élément (j, j') vaut $\text{cov}(X_{j,t}, X_{j',t-k})$.

Matrice de corrélation croisée au retard k .

$$R_k = D^{-1/2} \Gamma_k D^{-1/2}, \quad D = \text{diag}(\Gamma_0)$$

Propriétés.

- Γ_0 et R_0 sont des matrices $m \times m$ **symétriques**.
- Γ_k et R_k sont $m \times m$ mais **non symétriques**.

•

$$\Gamma_k = \Gamma_{-k}^T$$

La non-symétrie de Γ_k est LE fait nouveau du cas multivarié. En univarié, $\gamma(k) = \gamma(-k)$: le passé et le futur se ressemblent. En multivarié, $\text{cov}(X_{1,t}, X_{2,t-1})$ et $\text{cov}(X_{2,t}, X_{1,t-1})$ sont deux quantités **différentes** — et c'est exactement cette différence qui porte l'information de causalité temporelle.

Avance, retard et rétroaction

- Si $[\Gamma_k]_{j,j'} = \text{Cov}(X_{t,j}, X_{t-k,j'}) \neq 0$ pour un certain $k > 0$, on dit que « $\{X_{t,j'}\}$ **précède** $\{X_{t,j}\}$ » (*leads*).
- Si « $\{X_{t,j'}\}$ précède $\{X_{t,j}\}$ » **et** « $\{X_{t,j}\}$ précède $\{X_{t,j'}\}$ », alors il y a **rétroaction** (*feedback*).

La lecture économique. Un indicateur avancé (les commandes industrielles, les indices de confiance) « précède » l'activité. Une rétroaction signifie que les deux séries s'influencent mutuellement avec décalage — cas de figure standard entre taux d'intérêt et inflation. Ce vocabulaire est la version élémentaire de ce que la causalité au sens de Granger formalise.

● Concept 2 — Le théorème de Wold multivarié

THÉORÈME DE REPRÉSENTATION DE WOLD.

Toute série temporelle multivariée (m -variée) stationnaire en covariance $\{X_t\}$ peut être décomposée en

$$X_t = V_t + \eta_t + \Psi_1 \eta_{t-1} + \Psi_2 \eta_{t-2} + \dots = V_t + \sum_{k=0}^{\infty} \Psi_k \eta_{t-k}$$

où :

- $\{V_t\}$ est un processus **linéairement déterministe** de dimension m ;
- $\{\eta_t\}$ est un processus de **bruit blanc multivarié** :

$$E[\eta_t] = 0_m, \quad \text{Var}[\eta_t] = E[\eta_t \eta_t^T] = \Sigma \quad (m \times m, \text{semi-définie positive})$$

$$\text{Cov}[\eta_t, \eta_{t-k}] = E[\eta_t \eta_{t-k}^T] = 0 \quad (k \neq 0), \quad \text{Cov}[\eta_t, V_{t-k}] = 0 \quad \forall k$$

- les $\{\Psi_k\}$ sont des matrices $m \times m$ telles que $\Psi_0 = I_m$ et $\sum_{k=0}^{\infty} \Psi_k \Psi_k^T$ **converge**.

C'est mot pour mot le théorème de la fiche 52, avec trois substitutions : les scalaires ψ_k deviennent des **matrices** $m \times m$, la condition $\psi_0 = 1$ devient $\Psi_0 = I_m$, et $\sum \psi_k^2 < \infty$ devient la convergence de $\sum \Psi_k \Psi_k^T$.

Et la même limite pratique subsiste : une infinité de matrices Ψ_k est inestimable. D'où le VAR, qui les engendre à partir d'un nombre fini de paramètres — exactement comme ARMA le faisait en univarié.

Noter que Σ n'est pas supposée diagonale. Les innovations des différentes composantes sont **contemporainement corrélées** : un choc sur les taux et un choc sur les actions peuvent survenir ensemble. Ce que le bruit blanc interdit, c'est la corrélation **entre dates** ($k \neq 0$), pas entre composantes à une même date. Ce point est décisif pour le concept 7.

● Concept 3 — Les modèles VAR(p)

DÉFINITION.

La série multivariée $\{X_t\}$ de dimension m suit le modèle **VAR(p)** d'ordre autorégressif p si

$$X_t = C + \Phi_1 X_{t-1} + \Phi_2 X_{t-2} + \cdots + \Phi_p X_{t-p} + \eta_t$$

où $C = (c_1, \dots, c_m)^T$ est un m -vecteur de constantes, $\Phi_1, \dots, \Phi_p$ sont des matrices $(m \times m)$ de coefficients, et $\{\eta_t\}$ est un bruit blanc multivarié $MVN(0_m, \Sigma)$.

Ce que cela signifie composante par composante. Pour j fixé, la série $\{X_{j,t}\}$ est une **généralisation du modèle AR(p)** incluant des termes de régression retardés sur **toutes les autres** composantes :

$$X_{j,t} = c_j + \sum_{k=1}^p [\Phi_k]_{j,j} X_{j,t-k} + \sum_{j' \neq j} \sum_{k=1}^p [\Phi_k]_{j,j'} X_{j',t-k} + \eta_{j,t}$$

Lisez la structure. Le premier terme est l'AR(p) habituel de la série sur elle-même ; le second est **nouveau** : l'influence retardée des autres séries. C'est ce second bloc qui capture les avances et les rétroactions du concept 1 — et qui coûte $pm(m-1)$ paramètres supplémentaires.

Le coût en paramètres est le vrai obstacle du VAR. Il y a pm^2 coefficients dans les Φ_k , plus m constantes, plus $m(m+1)/2$ dans Σ . Pour $m = 5$ et $p = 4$: 100 coefficients autorégressifs à estimer. C'est pourquoi les VAR appliqués restent petits ($m \leq 6, p \leq 4$) et pourquoi la sélection d'ordre du concept 8 est cruciale.

● Concept 4 — La représentation VAR(1) d'un VAR(p)

Un processus VAR(p) est **équivalent** à un processus VAR(1).

On définit les vecteurs empilés

$$Z_t = (X_t^T, X_{t-1}^T, \dots, X_{t-p+1}^T)^T, \quad Z_{t-1} = (X_{t-1}^T, X_{t-2}^T, \dots, X_{t-p}^T)^T$$

Le processus $\{Z_t\}$, de dimension $(mp \times 1)$, vérifie

$$Z_t = D + AZ_{t-1} + F$$

où D et F sont $(mp \times 1)$ et A est $(mp \times mp)$:

$$D = \begin{pmatrix} C \\ 0_m \\ 0_m \\ \vdots \\ 0_m \end{pmatrix}, \quad A = \begin{pmatrix} \Phi_1 & \Phi_2 & \Phi_3 & \cdots & \Phi_p \\ I_m & 0 & 0 & \cdots & 0 \\ 0 & I_m & 0 & \cdots & 0 \\ \vdots & & \ddots & & \vdots \\ 0 & 0 & \cdots & I_m & 0 \end{pmatrix}, \quad F = \begin{pmatrix} \eta_t \\ 0_m \\ 0_m \\ \vdots \\ 0_m \end{pmatrix}$$

A est la **matrice compagnon**.

L'astuce est purement algébrique mais très utile. En empilant les p derniers vecteurs en un seul « super-vecteur », un processus à mémoire p devient un processus **markovien** à mémoire **1**. Les lignes de I_m sous la première rangée ne font que **recopier** : $X_{t-1} = X_{t-1}$, etc.

Le bénéfice : tout ce qu'on sait des VAR(1) — condition de stationnarité, moments, prévision — s'applique immédiatement aux VAR(p). C'est le même mouvement que la mise sous forme espace-état de la fiche 52.

● Concept 5 — Stationnarité et moyenne

Un modèle VAR(p) est stationnaire si l'une ou l'autre des conditions équivalentes est vérifiée :

- toutes les **valeurs propres de la matrice compagnon** A ont un module strictement inférieur à 1 ;
ou
- toutes les racines de

$$\det(I_m - \Phi_1 z - \Phi_2 z^2 - \cdots - \Phi_p z^p) = 0$$

vues comme fonction de la variable complexe z , sont **en dehors du cercle unité complexe** $\{|z| \leq 1\}$.

Les deux formulations sont équivalentes mais portent sur des objets inverses l'un de l'autre — exactement comme en fiche 52. Les valeurs propres de $\mathbf{A}$ sont les **inverses** des racines du déterminant : « module < 1 » pour les unes, « hors du cercle unité » pour les autres. Vérifiez toujours laquelle est utilisée.

La moyenne d'un VAR(p) stationnaire. En prenant l'espérance de l'équation :

$$E[X_t] = C + \Phi_1 E[X_{t-1}] + \dots + \Phi_p E[X_{t-p}] + E[\eta_t]$$

$$\mu = C + \sum_{k=1}^p \Phi_k \mu + 0_m$$

d'où

$$\boxed{\mu = E[X_t] = (I - \Phi_1 - \dots - \Phi_p)^{-1} C} \quad \text{et} \quad C = (I - \Phi_1 - \dots - \Phi_p) \mu$$

La forme centrée.

$$[X_t - \mu] = \Phi_1 [X_{t-1} - \mu] + \Phi_2 [X_{t-2} - \mu] + \dots + \Phi_p [X_{t-p} - \mu] + \eta_t$$

L'inversibilité de $(I - \Phi_1 - \dots - \Phi_p)$ est garantie par la stationnarité : c'est le déterminant caractéristique évalué en $z = 1$, et si 1 était une racine, elle serait **sur** le cercle unité — donc le processus serait non stationnaire (racine unitaire multivariée). C'est le pendant exact de $c = \mu\phi(1)$ en fiche 52.

● Concept 6 — Le VAR(p) comme système de régressions

Les données. n observations $\mathbf{x}_t = (x_{1,t}, \dots, x_{m,t})^T$, $t = 1, \dots, n$, plus p **conditions initiales** exprimées comme observations pré-échantillon $\mathbf{x}_{-p+1}, \dots, \mathbf{x}_{-1}, \mathbf{x}_0$.

Les m modèles de régression. On pose, pour chaque composante j :

$$y^{(j)} = Z\beta^{(j)} + \epsilon^{(j)}, \quad j = 1, 2, \dots, m$$

avec

$$y^{(j)} = \begin{pmatrix} x_{j,1} \\ x_{j,2} \\ \vdots \\ x_{j,n} \end{pmatrix}, \quad Z = \begin{pmatrix} 1 & z_0^T \\ 1 & z_1^T \\ \vdots & \vdots \\ 1 & z_{n-1}^T \end{pmatrix}, \quad z_{t-1} = (x_{t-1}^T, x_{t-2}^T, \dots, x_{t-p}^T)^T$$

$y^{(j)}$ ne concerne qu'une seule composante, tandis que Z inclut les retards de TOUTES les composantes. C'est la phrase-clé : la matrice de régresseurs est la même pour les m équations. Retenez-la — c'est elle qui rend le théorème du concept 7 possible.

- $\beta^{(j)}$ est le vecteur de $(mp + 1)$ paramètres de régression de la j -ième composante.
- $\epsilon^{(j)}$ est le n -vecteur des erreurs d'innovation, de loi $WN(0, \sigma_j^2)$ — la variance dépend de la composante j .

Le modèle multivarié. Les m régressions s'écrivent ensemble

$$[y^{(1)} \ y^{(2)} \ \dots \ y^{(m)}] = Z[\beta^{(1)} \ \beta^{(2)} \ \dots \ \beta^{(m)}] + [\epsilon^{(1)} \ \epsilon^{(2)} \ \dots \ \epsilon^{(m)}]$$

$$\boxed{Y = ZB + E}$$

Forme du modèle : régressions apparemment non reliées (SUR). Le nom, dû à Zellner, dit le paradoxe : les équations **semblent** indépendantes — chacune a sa propre variable expliquée et ses propres coefficients — mais elles sont **liées par la corrélation contemporaine des erreurs**, c'est-à-dire par Σ non diagonale. En général, une telle corrélation appelle une estimation **jointe** par MCG. Le concept 7 explique pourquoi, **ici précisément**, ce n'est pas nécessaire.

• Concept 7 — MCO par composante, et pourquoi c'est optimal

L'estimation. Les paramètres $\hat{\beta}^{(j)}$ s'estiment facilement par MCO, en appliquant le même algorithme :

$$\hat{\beta}^{(j)} = (Z^T Z)^{-1} Z^T y^{(j)}, \quad j = 1, \dots, m$$

Les résidus ont la formule habituelle : $\hat{\epsilon}^{(j)} = y^{(j)} - Z\hat{\beta}^{(j)}$.

L'estimation de Σ . On identifie les estimations des innovations $\{\eta_t\}$ en **transposant** la matrice des résidus, puis

$$\hat{\Sigma} = \frac{1}{n - pm} \sum_{t=1}^n \hat{\eta}_t \hat{\eta}_t^T = \frac{1}{n - pm} Y^T (I_n - Z(Z^T Z)^{-1} Z^T) Y$$

qui est un estimateur **sans biais**.

Reconnaissez la matrice chapeau de la fiche 50 : $I_n - Z(Z^T Z)^{-1} Z^T$ est le projecteur sur l'orthogonal de l'espace des colonnes de Z . Et le diviseur $n - pm$ compte les degrés de liberté perdus par équation.

THÉORÈME — OPTIMALITÉ DES MCO.

Pour le modèle $VAR(p)$ **sans restriction** sur les matrices de coefficients $\Phi_1, \dots, \Phi_p$:

- les estimations MCO **par composante** sont **égales** aux estimations **MCG** tenant compte du cas général d'une matrice de covariance d'innovation Σ ($m \times m$) à variances possiblement inégales et corrélations non nulles ;
- sous l'hypothèse que les $\{\eta_t\}$ sont i.i.d. de loi gaussienne multivariée $MN(0_m, \Sigma)$, les estimations MCO par composante sont **aussi les estimations du maximum de vraisemblance**.

C'est le résultat le plus utile du chapitre, et il est presque trop beau. Un système SUR avec erreurs corrélées appelle normalement des MCG — donc l'estimation jointe de toutes les équations et de Σ , avec des itérations. Ici, **on peut ignorer Σ complètement** et faire m régressions MCO séparées : le résultat est **identique**.

La raison tient en un mot : Z est la même partout. Toutes les équations ont **exactement les mêmes régresseurs**. Dès qu'on impose une restriction — exclure un retard d'une seule équation, par exemple —, les régresseurs diffèrent, le théorème **tombe**, et les MCG redeviennent nécessaires.

● Concept 8 — Kronecker, vec et la démonstration

DÉFINITION — PRODUIT DE KRONECKER.

Le produit de Kronecker de la matrice $(m \times n)$ A et de la matrice $(p \times q)$ B est la matrice $(mp \times qn)$

$$C = A \otimes B = \begin{pmatrix} a_{1,1}B & a_{1,2}B & \cdots & a_{1,n}B \\ a_{2,1}B & a_{2,2}B & \cdots & a_{2,n}B \\ \vdots & \vdots & \ddots & \vdots \\ a_{m,1}B & a_{m,2}B & \cdots & a_{m,n}B \end{pmatrix}$$

Propriétés.

$$(A \otimes B)^T = A^T \otimes B^T, \quad (A \otimes B)(D \otimes F) = (AD) \otimes (BF)$$

(où D a n lignes et F a q lignes).

DÉFINITION — OPÉRATEUR VEC.

L'opérateur **vec** convertit une matrice rectangulaire en vecteur colonne en **empilant les colonnes**.
Pour A $(n \times m)$:

$$\text{vec}(A) = (a_{1,1}, \dots, a_{n,1}, a_{1,2}, \dots, a_{n,2}, \dots, a_{1,m}, \dots, a_{n,m})^T$$

Vectoriser le modèle

En partant de $Y = ZB + E$, on définit

$$y = \text{vec}(Y) \ (nm \times 1), \quad X = I_m \otimes Z \ (nm \times (1 + pm^2))$$

$$\beta = \text{vec}(B) \ ((1 + pm^2) \times 1), \quad \epsilon = \text{vec}(E) \ (nm \times 1)$$

Le modèle devient

$$y = X\beta + \epsilon, \quad \epsilon \sim WN(0_{nm}, \Omega) \text{ avec } \Omega = \Sigma \otimes I_n$$

La démonstration de l'optimalité

Par le cas MCG du théorème de Gauss-Markov (fiche 50), l'estimateur **BLUE** est

$$\hat{\beta} = [X^T \Omega^{-1} X]^{-1} [X^T \Omega^{-1} y]$$

Étape 1 — calculer $X^T \Omega^{-1} X$. Avec $\Omega^{-1} = \Sigma^{-1} \otimes I_n$:

$$X^T \Omega^{-1} X = (I_m \otimes Z)^T (\Sigma^{-1} \otimes I_n) (I_m \otimes Z) = (I_m \otimes Z^T) (\Sigma^{-1} \otimes Z) = \Sigma^{-1} \otimes (Z^T Z)$$

d'où

$$[X^T \Omega^{-1} X]^{-1} = [\Sigma^{-1} \otimes (Z^T Z)]^{-1} = \Sigma \otimes (Z^T Z)^{-1}$$

Étape 2 — calculer $X^T \Omega^{-1} y$.

$$X^T \Omega^{-1} y = (I_m \otimes Z)^T (\Sigma^{-1} \otimes I_n) y = (I_m \otimes Z^T) (\Sigma^{-1} \otimes I_n) y = (\Sigma^{-1} \otimes Z^T) y$$

Étape 3 — conclure.

$$\hat{\beta} = [\Sigma \otimes (Z^T Z)^{-1}] (\Sigma^{-1} \otimes Z^T) y = [(\Sigma \Sigma^{-1}) \otimes ((Z^T Z)^{-1} Z^T)] y = [I_m \otimes (Z^T Z)^{-1} Z^T] y$$

$$\hat{\beta} = \text{vec}((Z^T Z)^{-1} Z^T Y)$$



Regardez où Σ disparaît : à l'étape 3, dans le produit $\Sigma \Sigma^{-1} = I_m$. C'est toute la preuve. Et cette simplification n'est possible que parce que $X = I_m \otimes Z$ se **factorise** ainsi — c'est-à-dire, encore une fois, parce que toutes les équations partagent la **même** matrice de régresseurs Z .

Le résultat final $\text{vec}((Z^T Z)^{-1} Z^T Y)$ est exactement l'empilement des m estimations MCO $\hat{\beta}^{(j)} = (Z^T Z)^{-1} Z^T y^{(j)}$. Les MCG **sont** les MCO.

● Concept 9 — Maximum de vraisemblance et sélection d'ordre

La vraisemblance. Sous innovations gaussiennes, $\epsilon \sim N_{nm}(0_{nm}, \Omega)$ avec $\Omega = \Sigma \otimes I_n$:

$$L(\beta, \Omega) = \frac{1}{(2\pi)^{nm/2}} |\Omega|^{-1/2} \exp \left(-\frac{1}{2} (y - X\beta)^T \Omega^{-1} (y - X\beta) \right)$$

La log-vraisemblance, en utilisant $|\Sigma \otimes I_n| = |\Sigma|^n$:

$$\begin{aligned}\log L &= -\frac{nm}{2}\log(2\pi) - \frac{n}{2}\log|\Sigma| - \frac{1}{2}\text{trace}[(Y - ZB)\Sigma^{-1}(Y - ZB)^T] \\ &= -\frac{n}{2}\log|\Sigma| - \frac{1}{2}Q(\beta, \Sigma) + \text{const}\end{aligned}$$

L'expression $Q(\beta, \Sigma)$ est le critère des moindres carrés généralisés, qui est minimisé par les estimations MCO composante par composante de β , pour toute matrice de covariance Σ non singulière.

La vraisemblance concentrée. Avec $\hat{\beta} = \text{vec}(\hat{B})$, l'EMV de Σ minimise $\ell(\Sigma) = \log L(\hat{\beta}, \Sigma)$:

$$\log L(\hat{\beta}, \Sigma) = -\frac{n}{2}\log|\Sigma| - \frac{1}{2}\text{trace}[\Sigma^{-1}(Y - Z\hat{B})^T(Y - Z\hat{B})] = -\frac{n}{2}\log|\Sigma| - \frac{n}{2}\text{trace}[\Sigma^{-1}\tilde{\Sigma}]$$

où

$$\tilde{\Sigma} = \frac{1}{n}(Y - Z\hat{B})^T(Y - Z\hat{B})$$

THÉORÈME.

$\tilde{\Sigma}$ est l'EMV de Σ (Anderson et Olkin, 1979).

Noter le diviseur n et non $n - pm$: comme toujours, l'EMV de la covariance est **biaisé** (fiche 50). L'estimateur sans biais du concept 7 divise par $n - pm$.

Sélection de l'ordre

Des critères statistiques servent à choisir l'ordre p du processus VAR :

1. Ajuster tous les modèles VAR(p) avec $0 \leq p \leq p_{\max}$.
2. Soit $\tilde{\Sigma}(p)$ l'EMV de $\Sigma = E(\eta_t \eta_t^T)$.
3. Choisir p minimisant l'un de :

$$\mathbf{AIC}(p) = \log |\tilde{\Sigma}(p)| + 2 \cdot \frac{pm^2}{n}$$

$$\mathbf{BIC}(p) = \log |\tilde{\Sigma}(p)| + \log(n) \cdot \frac{pm^2}{n}$$

$$\mathbf{HQ}(p) = \log |\tilde{\Sigma}(p)| + 2 \log(\log(n)) \cdot \frac{pm^2}{n}$$

C'est mot pour mot les critères de la fiche 52, avec deux substitutions : $\log \tilde{\sigma}^2$ devient $\log |\tilde{\Sigma}|$ — le déterminant remplace la variance scalaire — et le nombre de paramètres $p + q$ devient pm^2 .

Et la pénalité en m^2 change tout en pratique. Passer de p à $p + 1$ ajoute m^2 paramètres, pas 1. Pour $m = 5$, chaque retard supplémentaire coûte **25** paramètres : les critères sélectionnent donc des ordres **très courts**, typiquement $p = 1$ ou **2**. Le BIC, plus sévère, est souvent préféré.

● Concept 10 — La distribution asymptotique

Le cadre. Pour un VAR(p) stationnaire en covariance, les estimations MCO sont celles d'un modèle linéaire stationnaire $y = X\beta + \epsilon$, $\epsilon \sim WN(0_{nm}, \Omega)$ avec $\Omega = \Sigma \otimes I_n$, issu de la vectorisation de $Y = ZB + E$ (Y et E sont $(n \times m)$, Z est $(n \times (mp + 1))$).

THÉORÈME.

Si le processus de bruit blanc $\{\eta_t\}$ a des **moments d'ordre 4 finis et bornés** et est **indépendant** entre dates, alors :

- la matrice $(mp + 1) \times (mp + 1)$

$$\Gamma := \text{plim}_{n \rightarrow \infty} \frac{Z^T Z}{n} \quad \text{existe et est non singulière ;}$$

- le vecteur $\hat{\beta}$, de dimension $m(mp + 1)$, est **asymptotiquement conjointement normal** :

$$\sqrt{n}(\hat{\beta} - \beta) \xrightarrow{d} N(0, \Sigma \otimes \Gamma^{-1})$$

Les estimations à utiliser quand n est grand :

$$\hat{\Gamma} = \frac{1}{n} Z^T Z, \quad \hat{\Sigma} = \frac{1}{n} Y^T [I_n - Z(Z^T Z)^{-1} Z^T] Y$$

Asymptotiquement, les estimations des moindres carrés sont distribuées **identiquement** aux estimations du maximum de vraisemblance pour le modèle supposant des innovations gaussiennes.

Deux remarques sur les hypothèses.

- Les **moments d'ordre 4** sont exigés parce que les régresseurs sont eux-mêmes aléatoires : établir la loi de $\hat{\beta}$ demande de contrôler la variance de $Z^T Z$, donc des moments d'ordre 4 de X .
- La conclusion est **asymptotique et sans hypothèse gaussienne** : la normalité de $\hat{\beta}$ ne vient pas d'une hypothèse sur η_t , mais d'un théorème central limite. C'est exactement la situation de la fiche 50 pour les MCO sur régresseurs aléatoires.

La structure de Kronecker de la variance asymptotique se lit très simplement : Σ gouverne la partie « entre équations », Γ^{-1} la partie « entre coefficients d'une même équation ». Pour tester un coefficient isolé $[\Phi_k]_{j,j'}$, on extrait l'élément diagonal correspondant : $\sigma_{jj} \cdot [\Gamma^{-1}]_{\ell\ell}/n$.

Comment résoudre l'exercice type (protocole)

1. **Vérifier la stationnarité** de chaque composante, et différencier si nécessaire (fiche 52).
2. **Choisir l'ordre p** par AIC, BIC ou HQ — en gardant à l'esprit le coût de m^2 paramètres par retard.
3. **Construire Z** : colonne de 1, puis les p retards de **toutes** les composantes.
4. **Estimer par MCO équation par équation** : $\hat{\beta}^{(j)} = (Z^T Z)^{-1} Z^T y^{(j)}$ — c'est optimal, inutile de faire des MCG.
5. **Estimer Σ** : $\hat{\Sigma} = \frac{1}{n-pm} Y^T (I_n - Z(Z^T Z)^{-1} Z^T) Y$ (sans biais), ou avec $\frac{1}{n}$ (EMV).
6. **Vérifier la stationnarité estimée** : valeurs propres de la matrice compagnon $\hat{A}$ de module < 1 .
7. **Faire l'inférence** : $\sqrt{n}(\hat{\beta} - \beta) \rightarrow N(0, \Sigma \otimes \Gamma^{-1})$, avec $\hat{\Gamma} = Z^T Z/n$.
8. **Diagnostiquer** : les résidus $\hat{\eta}_t$ doivent être un bruit blanc **multivarié** — pas d'autocorrélation, à aucun retard, dans aucune équation croisée.

Comment reconnaître qu'il faut utiliser cette méthode ?

Indice dans l'énoncé	Ce qu'il faut faire
plusieurs séries s'influençant mutuellement	VAR(p)
« telle série précède telle autre »	regarder $[\Gamma_k]_{j,j'}$ pour $k > 0$
« influence dans les deux sens »	rétroaction
« le système est-il stable ? »	valeurs propres de la matrice compagnon < 1 en module
« moyenne de long terme du système »	$\mu = (I - \Phi_1 - \dots - \Phi_p)^{-1}C$
« erreurs corrélées entre équations »	SUR — mais ici MCO suffisent
« faut-il faire des MCG ? »	non , si aucune restriction sur les Φ_k
« combien de retards ? »	AIC / BIC / HQ , pénalité en pm^2/n
« écart-type d'un coefficient »	$\Sigma \otimes \Gamma^{-1}$ divisé par n

Exercices progressifs

Niveau 1 — Combien de paramètres compte un VAR(2) à $m = 4$ séries ?

Les coefficients autorégressifs. $p = 2$ matrices Φ_k de taille 4×4 :

$$pm^2 = 2 \times 16 = 32$$

Les constantes. C est un m -vecteur : 4 paramètres.

La covariance des innovations. Σ est symétrique 4×4 : $m(m+1)/2 = 10$ paramètres.

Total : $32 + 4 + 10 = 46$ paramètres.

La lecture pratique. Par équation, il y a $mp + 1 = 9$ régresseurs. Avec $n = 100$ observations trimestrielles (25 ans !), cela fait environ 11 observations par paramètre estimé — juste acceptable. Avec $m = 8$, le même calcul donnerait 17 régresseurs par équation et 128 coefficients autorégressifs : intenable.

C'est pourquoi les VAR appliqués restent petits. Au-delà de **6** ou **7** variables, on passe à des VAR **bayésiens** (avec a priori de rétrécissement, les *Minnesota priors*) ou à des **VAR factoriels**, qui résument l'information par quelques facteurs — exactement l'idée de la fiche 54.

Niveau 2 — Pourquoi Γ_k n'est-elle pas symétrique, et qu'est-ce que cela apporte ?

Le calcul. $[\Gamma_k]_{j,j'} = \text{cov}(X_{j,t}, X_{j',t-k})$ tandis que $[\Gamma_k]_{j',j} = \text{cov}(X_{j',t}, X_{j,t-k})$. Ces deux quantités comparent des choses **différentes** : dans la première, c'est j qui est au présent et j' au passé ; dans la seconde, l'inverse. Il n'y a aucune raison qu'elles coïncident.

En revanche $\Gamma_k = \Gamma_{-k}^T$: la symétrie perdue est remplacée par une relation entre retards opposés. Et Γ_0 , elle, **est** symétrique — au retard nul, il n'y a plus de sens temporel.

Ce que cela apporte : la direction du temps. Supposons $[\Gamma_1]_{j,j'} \neq 0$ mais $[\Gamma_1]_{j',j} = 0$. Alors $X_{j'}$ d'hier explique X_j d'aujourd'hui, mais pas l'inverse : $\{X_{t,j'}\}$ **précède** $\{X_{t,j}\}$. C'est un **indicateur avancé**.

Si les deux sont non nulles, il y a **rétroaction** : chacune influence l'autre avec décalage.

Pourquoi c'est le vrai apport du multivarié. En univarié, la fonction d'autocovariance est paire et ne dit rien de la direction du temps. La matrice Γ_k , en étant asymétrique, **encode une orientation** — et c'est cette information que le VAR exploite, puis que la causalité au sens de Granger formalise en test.

Mais « précède » n'est pas « cause ». Une troisième variable non modélisée peut faire bouger $X_{j'}$ avant X_j sans qu'il y ait aucun lien causal. La corrélation croisée décalée établit un ordre temporel, pas un mécanisme.

Niveau 3 — Démontrez que les MCG coïncident avec les MCO par composante.

Le cadre vectorisé. $y = X\beta + \epsilon$ avec $y = \text{vec}(Y)$, $X = I_m \otimes Z$, $\beta = \text{vec}(B)$ et $\text{Cov}(\epsilon) = \Omega = \Sigma \otimes I_n$. Par Gauss-Markov généralisé (fiche 50), le BLUE est $\hat{\beta} = [X^T \Omega^{-1} X]^{-1} [X^T \Omega^{-1} y]$.

Étape 1. Avec $\Omega^{-1} = \Sigma^{-1} \otimes I_n$ et les propriétés $(A \otimes B)^T = A^T \otimes B^T$ et $(A \otimes B)(D \otimes F) = (AD) \otimes (BF)$:

$$X^T \Omega^{-1} X = (I_m \otimes Z^T)(\Sigma^{-1} \otimes I_n)(I_m \otimes Z) = (I_m \otimes Z^T)(\Sigma^{-1} \otimes Z) = \Sigma^{-1} \otimes (Z^T Z)$$

Étape 2. L'inverse d'un produit de Kronecker est le produit de Kronecker des inverses :

$$[X^T \Omega^{-1} X]^{-1} = \Sigma \otimes (Z^T Z)^{-1}$$

Étape 3.

$$X^T \Omega^{-1} y = (I_m \otimes Z^T)(\Sigma^{-1} \otimes I_n)y = (\Sigma^{-1} \otimes Z^T)y$$

Étape 4.

$$\hat{\beta} = [\Sigma \otimes (Z^T Z)^{-1}](\Sigma^{-1} \otimes Z^T)y = [(\Sigma \Sigma^{-1}) \otimes ((Z^T Z)^{-1} Z^T)]y = [I_m \otimes (Z^T Z)^{-1} Z^T]y$$

En dé-vectorisant : $\hat{B} = (Z^T Z)^{-1} Z^T Y$, dont la colonne j est exactement $\hat{\beta}^{(j)} = (Z^T Z)^{-1} Z^T y^{(j)}$.



Où est le cœur de la preuve ? À l'étape 4, dans $\Sigma \Sigma^{-1} = I_m$. La matrice de covariance des innovations s'annule contre elle-même, et il ne reste que le projecteur MCO.

Pourquoi cela est possible. Uniquement parce que $X = I_m \otimes Z$ se factorise en un bloc « équations » (I_m) et un bloc « régresseurs » (Z) — c'est-à-dire parce que **toutes les équations partagent la même matrice Z** .

Et voilà la condition du théorème, qu'il faut savoir énoncer : « *sans restriction sur les matrices de coefficients* ». Si l'on impose, par exemple, $[\Phi_2]_{1,3} = 0$ dans la seule première équation, les régresseurs ne sont plus les mêmes partout, X ne se factorise plus, et les MCG **redeviennent strictement meilleurs** que les MCO. C'est le cas général des systèmes SUR de Zellner.

Niveau 4 — type examen — Énoncez la condition de stationnarité d'un VAR(p), justifiez l'équivalence des deux formes, et dites ce qui se passe si elle échoue.

Les deux formes.

1. Toutes les **valeurs propres de la matrice compagnon A** ont un module < 1 .

2. Toutes les racines de $\det(I_m - \Phi_1 z - \dots - \Phi_p z^p) = 0$ sont **hors du cercle unité** $\{|z| \leq 1\}$.

Pourquoi la forme (1) est naturelle. En posant $Z_t = (X_t^T, \dots, X_{t-p+1}^T)^T$, le VAR(p) devient le VAR(1)

$$Z_t = D + AZ_{t-1} + F$$

En itérant, $Z_t = \sum_{k \geq 0} A^k (D + F_{t-k})$. Cette série converge si et seulement si $A^k \rightarrow 0$, c'est-à-dire si le **rayon spectral** de A est < 1 . C'est la version matricielle exacte de la condition $|\phi| < 1$ pour l'AR(1) de la fiche 52.

Pourquoi (1) et (2) sont équivalentes. Le polynôme caractéristique de la matrice compagnon se calcule par blocs et donne

$$\det(A - \lambda I_{mp}) = \pm \lambda^{mp} \det(I_m - \Phi_1 \lambda^{-1} - \dots - \Phi_p \lambda^{-p})$$

Donc λ est valeur propre de A si et seulement si $z = 1/\lambda$ annule $\det(I_m - \Phi_1 z - \dots - \Phi_p z^p)$. Les deux ensembles de nombres sont **inverses** l'un de l'autre : « module < 1 » pour les valeurs propres équivaut à « module > 1 » pour les racines, c'est-à-dire hors du cercle unité. ■

Ce qui se passe si la condition échoue.

- **Une racine sur le cercle unité** ($z = 1$) : le système a une **racine unitaire multivariée**. La conséquence immédiate est que $(I - \Phi_1 - \dots - \Phi_p)$ est **singulière**, donc $\mu = (I - \Phi_1 - \dots - \Phi_p)^{-1}C$ n'existe pas : le système **n'a pas de moyenne de long terme**. Comme en fiche 52, les chocs deviennent **permanents** et la variance croît sans borne.
- **Une racine à l'intérieur du cercle** : le système est **explosif**.

Le cas intéressant que le multivarié fait apparaître — la cointégration. Chaque série peut être individuellement $I(1)$ — non stationnaire — tandis que certaines **combinaisons linéaires** sont stationnaires. Le rang de $(I - \Phi_1 - \dots - \Phi_p)$ compte alors le nombre de ces relations d'équilibre de long terme. On sort du VAR standard pour entrer dans le **modèle vectoriel à correction d'erreur (VECM)**. C'est une situation sans équivalent univarié, et c'est le sujet naturel de la suite du cours.

En pratique, comment vérifier. Après estimation, on calcule les valeurs propres de $\hat{A}$: toutes doivent être **strictement à l'intérieur** du disque unité. Une valeur propre proche de 1 en module est un signal d'alerte — le système est presque non stationnaire, et l'inférence asymptotique du concept 10 devient peu fiable.

● Common mistakes

1. **Croire que Γ_k est symétrique** — seule Γ_0 l'est ; on a $\Gamma_k = \Gamma_{-k}^T$.
2. **Se tromper de côté sur les racines** — valeurs propres de A : module < 1 ; racines du déterminant : **hors** du cercle unité.
3. **Croire qu'il faut des MCG** — non, si aucune restriction n'est imposée sur les Φ_k : les MCO par composante **sont** les MCG.
4. **Oublier que ce théorème tombe sous restrictions** — dès que les équations n'ont plus les mêmes régresseurs, il faut des MCG.
5. **Oublier que Z est la même pour toutes les équations** — c'est la condition qui rend l'optimalité possible.
6. **Confondre les deux estimateurs de Σ** — $\frac{1}{n-pm}$ (sans biais) contre $\frac{1}{n}$ (EMV, biaisé).
7. **Sous-estimer le coût en paramètres** — chaque retard supplémentaire coûte m^2 coefficients, pas 1.
8. **Interpréter « précède » comme « cause »** — la corrélation croisée décalée établit un ordre, pas un mécanisme.
9. **Oublier les conditions initiales** — un VAR(p) exige p observations pré-échantillon.
10. **Faire l'inférence asymptotique sur un système presque non stationnaire** — les valeurs propres proches de 1 invalident la normalité asymptotique.

Ultimate Review

1. **Stationnarité multivariée** : $\{X_t\}$ est stationnaire en covariance si **chaque composante** l'est.
2. **Moments** : $\mu = E[X_t]$ ($m \times 1$) · $\Gamma_0 = \text{Var}(X_t)$ · $R_0 = D^{-1/2} \Gamma_0 D^{-1/2}$ avec $D = \text{diag}(\Gamma_0)$.
3. **Croisés** : $\Gamma_k = \text{Cov}(X_t, X_{t-k}) = E[(X_t - \mu)(X_{t-k} - \mu)^T]$, $R_k = D^{-1/2} \Gamma_k D^{-1/2}$.
4. **Propriétés** : Γ_0, R_0 symétriques ; Γ_k, R_k non symétriques ; $\Gamma_k = \Gamma_{-k}^T$.
5. **Avance et rétroaction** : $[\Gamma_k]_{j,j'} \neq 0$ pour $k > 0 \Rightarrow \{X_{t,j'}\}$ **précède** $\{X_{t,j}\}$; dans les deux sens $\Rightarrow$ **rétroaction**.
6. **Wold multivarié** : $X_t = V_t + \sum_{k \geq 0} \Psi_k \eta_{t-k}$, $\Psi_0 = I_m$, $\sum \Psi_k \Psi_k^T$ converge, η bruit blanc multivarié de covariance Σ .
7. **VAR(p)** : $X_t = C + \Phi_1 X_{t-1} + \dots + \Phi_p X_{t-p} + \eta_t$, $\eta_t \sim MVN(0_m, \Sigma)$.
8. **Composante j** : AR(p) sur soi-même **plus** régression sur les retards de toutes les autres.
9. **Forme compagnon** : $Z_t = D + A Z_{t-1} + F$, A de taille $mp \times mp \Rightarrow$ tout VAR(p) est un VAR(1).
10. **Stationnarité** : valeurs propres de A de module $< 1 \Leftrightarrow$ racines de $\det(I_m - \Phi_1 z - \dots - \Phi_p z^p) = 0$ **hors** du cercle unité.

11. **Moyenne** : $\mu = (I - \Phi_1 - \dots - \Phi_p)^{-1}C$, et $C = (I - \Phi_1 - \dots - \Phi_p)\mu$.
12. **Système de régressions** : $y^{(j)} = Z\beta^{(j)} + \epsilon^{(j)}$; Z identique pour tout j ; $Y = ZB + E$; forme **SUR**.
13. **Estimation** : $\hat{\beta}^{(j)} = (Z^T Z)^{-1} Z^T y^{(j)}$; $\hat{\Sigma} = \frac{1}{n-pm} Y^T (I_n - Z(Z^T Z)^{-1} Z^T) Y$.
14. **Théorème d'optimalité** : sans restriction sur les Φ_k , MCO par composante = MCG = EMV sous gaussienne.
15. **Kronecker** : $(A \otimes B)^T = A^T \otimes B^T$, $(A \otimes B)(D \otimes F) = (AD) \otimes (BF)$; **vec** empile les colonnes.
16. **Vectorisation** : $y = \text{vec}(Y)$, $X = I_m \otimes Z$, $\beta = \text{vec}(B)$, $\Omega = \Sigma \otimes I_n \Rightarrow \hat{\beta} = \text{vec}((Z^T Z)^{-1} Z^T Y)$.
17. **EMV** : $\tilde{\Sigma} = \frac{1}{n} (Y - Z\hat{B})^T (Y - Z\hat{B})$ est l'EMV (Anderson et Olkin, 1979) — **biaisé**.
18. **Sélection** : $\log|\tilde{\Sigma}(p)| + c_n \cdot \frac{pm^2}{n}$, avec $c_n = 2$ (AIC), $\log n$ (BIC), $2 \log \log n$ (HQ).
19. **Asymptotique** : moments d'ordre 4 bornés et indépendance $\Rightarrow \Gamma = \text{plim } Z^T Z/n$ non singulière et

$$\sqrt{n}(\hat{\beta} - \beta) \xrightarrow{d} N(0, \Sigma \otimes \Gamma^{-1})$$

20. **Estimations pratiques** : $\hat{\Gamma} = Z^T Z/n$, $\hat{\Sigma} = \frac{1}{n} Y^T [I_n - Z(Z^T Z)^{-1} Z^T] Y$.

Formulas to know

$$\Gamma_k = \Gamma_{-k}^T \quad X_t = C + \sum_{k=1}^p \Phi_k X_{t-k} + \eta_t \quad \mu = (I - \Phi_1 - \dots - \Phi_p)^{-1}C$$

$$\hat{\beta}^{(j)} = (Z^T Z)^{-1} Z^T y^{(j)} \quad \hat{\Sigma} = \frac{Y^T (I_n - Z(Z^T Z)^{-1} Z^T) Y}{n - pm} \quad \Omega = \Sigma \otimes I_n$$

$$AIC(p) = \log|\tilde{\Sigma}(p)| + 2 \frac{pm^2}{n} \quad \sqrt{n}(\hat{\beta} - \beta) \xrightarrow{d} N(0, \Sigma \otimes \Gamma^{-1})$$

Methods to know : la construction de la matrice compagnon ; la dérivation de μ ; la démonstration MCG = MCO par Kronecker en 4 étapes ; le décompte des paramètres.

Active Recall

Basic — Écrivez le modèle $\text{VAR}(p)$ et donnez sa condition de stationnarité.

$$X_t = C + \Phi_1 X_{t-1} + \Phi_2 X_{t-2} + \dots + \Phi_p X_{t-p} + \eta_t, \quad \eta_t \sim MVN(0_m, \Sigma)$$

avec C un m -vecteur et les Φ_k des matrices $(m \times m)$.

Stationnarité — deux formulations équivalentes :

- toutes les **valeurs propres de la matrice compagnon A** sont de module < 1 ;
- toutes les racines de $\det(I_m - \Phi_1 z - \dots - \Phi_p z^p) = 0$ sont **hors du cercle unité**.

Understanding — Pourquoi les MCO équation par équation suffisent-ils, alors que les erreurs sont corrélées entre équations ?

Parce que **toutes les équations ont exactement la même matrice de régresseurs Z** — celle qui contient les retards de toutes les composantes.

Formellement, la vectorisation donne $X = I_m \otimes Z$ et $\Omega = \Sigma \otimes I_n$, si bien que dans le calcul MCG

$$\hat{\beta} = [\Sigma \otimes (Z^T Z)^{-1}] (\Sigma^{-1} \otimes Z^T) y = [I_m \otimes (Z^T Z)^{-1} Z^T] y$$

la matrice Σ **s'annule contre son inverse**. Le résultat est l'empilement des m estimations MCO.

Ce résultat vaut « sans restriction sur les matrices de coefficients ». Dès qu'on contraint un coefficient dans une seule équation, les régresseurs diffèrent, X ne se factorise plus, et les **MCG redeviennent strictement meilleurs**.

Application — Comment détecter qu'une série en précède une autre ?

On examine les éléments hors diagonale de la matrice d'autocovariance croisée **à retard positif** :

$$[\Gamma_k]_{j,j'} = \text{Cov}(X_{t,j}, X_{t-k,j'}) \neq 0 \text{ pour un } k > 0 \implies \{X_{t,j'}\} \text{ **précède** } \{X_{t,j}\}$$

Et si la relation vaut **dans les deux sens**, il y a **rétroaction**.

Ce qui rend cette lecture possible, c'est la **non-symétrie** de Γ_k : $\text{cov}(X_{1,t}, X_{2,t-1})$ et $\text{cov}(X_{2,t}, X_{1,t-1})$ sont deux quantités différentes. En univarié, l'autocovariance est paire et ne dit rien de la direction du temps.

« Précède » n'est pas « cause » : une troisième variable non modélisée peut créer l'ordre temporel sans aucun lien causal.

Comparison — $AR(p)$ et $VAR(p)$: qu'est-ce qui change vraiment ?

	AR(p) (fiche 52)	VAR(p)
Coefficients	p scalaires ϕ_k	p matrices $\Phi_k \Rightarrow pm^2$
Autocovariance	$\gamma(k)$, paire	Γ_k , non symétrique , $\Gamma_k = \Gamma_{-k}^T$
Stationnarité	racines de $\phi(z)$ hors du cercle	racines de $\det(I - \sum \Phi_k z^k)$ hors du cercle
Moyenne	$\mu = c/\phi(1)$	$\mu = (I - \sum \Phi_k)^{-1}C$
Estimation	MCO	MCO par composante — et c'est optimal
Sélection	$\log \tilde{\sigma}^2 + c_n \frac{p+q}{n}$	$\log \tilde{\Sigma} + c_n \frac{pm^2}{n}$
Information nouvelle	—	avance, retard, rétroaction

Ce qui change vraiment, en un mot : la **direction du temps entre séries**. C'est le seul contenu véritablement nouveau, et il est porté par la non-symétrie de Γ_k .

Ce qui ne change pas : la logique d'ensemble. Wold garantit une représentation $MA(\infty)$, le VAR la paramétrise en fini, la stationnarité se lit sur des racines, et les critères d'information choisissent l'ordre.

Le prix à payer : m^2 paramètres par retard au lieu de **1**. C'est ce qui limite les VAR appliqués à quelques variables et pousse vers les VAR bayésiens ou factoriels.

Exam-style — Expliquez la vectorisation par Kronecker et son rôle dans la théorie de l'estimation du VAR.

Les deux outils.

- Le **produit de Kronecker** $A \otimes B$ remplace chaque élément $a_{i,j}$ de A par le bloc $a_{i,j}B$. Ses deux propriétés utiles : $(A \otimes B)^T = A^T \otimes B^T$ et $(A \otimes B)(D \otimes F) = (AD) \otimes (BF)$.
- L'opérateur **vec** empile les **colonnes** d'une matrice en un seul vecteur.

La vectorisation. Le modèle multivarié $Y = ZB + E$ devient

$$y = X\beta + \epsilon \quad \text{avec} \quad y = \text{vec}(Y), \quad X = I_m \otimes Z, \quad \beta = \text{vec}(B), \quad \epsilon = \text{vec}(E)$$

et $\text{Cov}(\epsilon) = \Omega = \Sigma \otimes I_n$.

Pourquoi c'est utile — trois raisons.

1. Cela ramène le multivarié à du connu. Une fois vectorisé, le modèle est un **modèle linéaire ordinaire** de la fiche 50, avec une covariance non sphérique. Tout Gauss-Markov généralisé s'applique tel quel.

2. Cela permet la démonstration d'optimalité. Le calcul MCG donne

$$X^T \Omega^{-1} X = \Sigma^{-1} \otimes (Z^T Z), \quad X^T \Omega^{-1} y = (\Sigma^{-1} \otimes Z^T) y$$

$$\hat{\beta} = [\Sigma \otimes (Z^T Z)^{-1}] (\Sigma^{-1} \otimes Z^T) y = [I_m \otimes (Z^T Z)^{-1} Z^T] y = \text{vec}((Z^T Z)^{-1} Z^T Y)$$

Le Σ s'annule contre Σ^{-1} , et les MCG se réduisent aux MCO par composante. Sans le formalisme de Kronecker, ce calcul serait à peu près inécrivable.

3. Cela structure la variance asymptotique.

$$\sqrt{n}(\hat{\beta} - \beta) \xrightarrow{d} N(0, \Sigma \otimes \Gamma^{-1}), \quad \Gamma = \text{plim} \frac{Z^T Z}{n}$$

La forme Kronecker se lit directement : Σ gouverne la dépendance **entre équations**, Γ^{-1} la dépendance **entre coefficients** d'une même équation. Pour l'écart-type d'un coefficient isolé, on prend $\sqrt{\sigma_{jj}[\Gamma^{-1}]_{\ell\ell}/n}$.

Le point conceptuel à retenir. Le produit de Kronecker est exactement le langage des situations où **deux structures indépendantes se superposent** : ici, la structure « équations » et la structure « observations et régresseurs ». Chaque fois que $X = I_m \otimes Z$ — c'est-à-dire chaque fois que toutes les équations partagent les mêmes régresseurs —, les deux structures se découpent et l'estimation se simplifie radicalement.

Flashcards

Question	Réponse
Quand $\{X_t\}$ est-elle stationnaire en covariance ?	Quand chaque composante l'est
Matrice de corrélation R_0 ?	$D^{-1/2}\Gamma_0 D^{-1/2}$, $D = \text{diag}(\Gamma_0)$
Autocovariance croisée Γ_k ?	$E[(X_t - \mu)(X_{t-k} - \mu)^T]$
Γ_k est-elle symétrique ?	Non — seule Γ_0 l'est
Relation entre Γ_k et Γ_{-k} ?	$\Gamma_k = \Gamma_{-k}^T$
Quand dit-on que j' précède j ?	Si $[\Gamma_k]_{j,j'} \neq 0$ pour un $k > 0$
Qu'est-ce que la rétroaction ?	Chacune précède l'autre
Wold multivarié ?	$X_t = V_t + \sum_k \Psi_k \eta_{t-k}$, $\Psi_0 = I_m$
Condition sur les Ψ_k ?	$\sum_k \Psi_k \Psi_k^T$ converge
Modèle VAR(p) ?	$X_t = C + \sum_{k=1}^p \Phi_k X_{t-k} + \eta_t$
Nombre de coefficients autorégressifs ?	pm^2
Forme compagnon ?	$Z_t = D + AZ_{t-1} + F$, A de taille $mp \times mp$
Stationnarité, forme 1 ?	Valeurs propres de A de module < 1
Stationnarité, forme 2 ?	Racines de $\det(I_m - \sum \Phi_k z^k) = 0$ hors du cercle unité
Moyenne d'un VAR stationnaire ?	$(I - \Phi_1 - \dots - \Phi_p)^{-1}C$
Que contient Z ?	Une constante et les p retards de toutes les composantes
Z change-t-elle selon l'équation ?	Non — c'est la clé de l'optimalité
Nom de la forme du modèle ?	SUR (régressions apparemment non reliées)
Estimateur MCO ?	$\hat{\beta}^{(j)} = (Z^T Z)^{-1} Z^T y^{(j)}$
Estimateur sans biais de Σ ?	$\frac{1}{n-pm} Y^T (I_n - Z(Z^T Z)^{-1} Z^T) Y$
Le théorème d'optimalité ?	MCO par composante = MCG = EMV (sans restriction)

Question	Réponse
Sous quelle condition tombe-t-il ?	Dès qu'on restreint les Φ_k
Propriétés du produit de Kronecker ?	$(A \otimes B)^T = A^T \otimes B^T ; (A \otimes B)(D \otimes F) = (AD) \otimes (BF)$
Que fait l'opérateur vec ?	Il empile les colonnes
X et Ω après vectorisation ?	$X = I_m \otimes Z, \Omega = \Sigma \otimes I_n$
Résultat du calcul MCG ?	$\hat{\beta} = \text{vec}((Z^T Z)^{-1} Z^T Y)$
EMV de Σ ?	$\frac{1}{n}(Y - Z\hat{B})^T(Y - Z\hat{B})$ — biaisé
Qui a démontré ce résultat ?	Anderson et Olkin (1979)
Critère AIC multivarié ?	$\log \tilde{\Sigma}(p) + 2pm^2/n$
Loi asymptotique de $\hat{\beta}$?	$\sqrt{n}(\hat{\beta} - \beta) \xrightarrow{d} N(0, \Sigma \otimes \Gamma^{-1})$
Que vaut Γ ?	plim $Z^T Z/n$
Quelle hypothèse sur les moments ?	Moments d'ordre 4 finis et bornés, indépendance entre dates