

Fiche 60 — Modèles espace-état linéaires et filtre de Kalman

Matière	Maths · Économétrie
Cours source	Kemphorne, <i>18.S096 Topics in Mathematics with Applications in Finance</i> , MIT OpenCourseWare, automne 2013 — cours 12 « Time Series Analysis III », seconde partie
Difficulté	Must know — le cadre unificateur de toutes les séries temporelles
Temps d'étude estimé	2 h 15
Prérequis	Fiche 50 (régression, maximum de vraisemblance), fiche 52 (AR, MA, ARMA), fiche 54 (matrices de covariance, EM)
Concepts clés	Vecteur d'état, équation de transition, équation d'observation, CAPM à bêtas variables, coefficients de régression variables, représentation espace-état d'ARMA, filtre de Kalman, gain de filtre, prédiction, filtrage, prévision, lissage, décomposition en erreurs de prédiction, information de Fisher
Poids à l'examen	Trois choses : écrire un modèle donné sous forme espace-état ; les quatre étapes du filtre de Kalman et ce que chacune calcule ; et pourquoi la vraisemblance se factorise en erreurs de prédiction .

Vue d'ensemble

IDÉE un état CACHÉ s_t évolue ; on n'observe que y_t , bruité
ÉTAT $s_{t+1} = T_t s_t + R_t \eta_t$ ← ce qu'on ne voit pas
OBSERVATION $y_t = Z_t s_t + \varepsilon_t$ ← ce qu'on voit
KALMAN 4 étapes : prédire · corriger · prévoir · lisser
BONUS la vraisemblance sort du filtre, gratuitement

POURQUOI CE CADRE EST CENTRAL.

Presque tout ce qu'on a vu se met sous forme espace-état : **AR**(p), **MA**(q), **ARMA**(p, q), la régression à coefficients **variables dans le temps**, le **CAPM à bêta variable**, les VAR, les modèles à facteurs dynamiques de la fiche 54. Une fois un modèle écrit ainsi, **un seul algorithme** — le filtre de Kalman — fournit la prédiction, le filtrage, la prévision, le lissage **et** la vraisemblance. C'est la raison pour laquelle la fiche 52 disait « exprimer le modèle ARMA sous forme espace-état » à l'étape 2 de l'estimation par maximum de vraisemblance.

● Concept 1 — La formulation générale

Les objets.

Symbole	Dimension	Contenu
y_t	$(k \times 1)$	vecteur d' observation au temps t
s_t	$(m \times 1)$	vecteur d' état au temps t
ε_t	$(k \times 1)$	vecteur d' erreur d'observation
η_t	$(n \times 1)$	vecteur d' innovation / erreur de transition d'état

Équation d'état / équation de transition.

$$s_{t+1} = T_t s_t + R_t \eta_t$$

où T_t ($m \times m$) est la **matrice des coefficients de transition**, R_t ($m \times n$) une **matrice fixe** — souvent des colonnes de I_p — et η_t i.i.d. $N(0_n, Q_t)$, avec Q_t ($n \times n$) **définie positive**.

Équation d'observation / équation de mesure.

$$y_t = Z_t s_t + \varepsilon_t$$

où Z_t ($k \times m$) est la **matrice des coefficients d'observation** et ε_t i.i.d. $N(0_k, H_t)$, avec H_t ($k \times k$) **définie positive**.

Équation jointe.

$$\begin{pmatrix} s_{t+1} \\ y_t \end{pmatrix} = \begin{pmatrix} T_t \\ Z_t \end{pmatrix} s_t + u_t = \Phi_t s_t + u_t, \quad u_t = \begin{pmatrix} R_t \eta_t \\ \varepsilon_t \end{pmatrix} \sim N(0, \Omega)$$

avec

$$\Omega = \begin{pmatrix} R_t Q_t R_t^T & 0 \\ 0 & H_t \end{pmatrix}$$

*Note : le modèle est **souvent invariant dans le temps** — T_t, R_t, Z_t, Q_t, H_t sont alors des constantes.*

Les deux bruits sont indépendants — c'est le zéro hors diagonale de Ω . Cette hypothèse est essentielle : elle sépare proprement l'**incertitude sur la dynamique** (Q_t) et l'**incertitude sur la mesure** (H_t), et c'est ce qui rend le filtre récursif.

Le rôle de R_t mérite attention. Il permet à n sources de bruit d'alimenter m composantes d'état, avec $n \leq m$. Dans la représentation espace-état d'un AR(p), par exemple, $R_t = (1, 0, \dots, 0)^T$: **une seule** innovation entre dans le système, les autres composantes d'état ne font que **décaler** le passé.

● Concept 2 — Exemple : le CAPM à bêtas variables

Considérons le modèle CAPM à **paramètres variables dans le temps** :

$$r_t = \alpha_t + \beta_t r_{m,t} + \varepsilon_t, \quad \varepsilon_t \sim N(0, \sigma_\varepsilon^2)$$

$$\alpha_{t+1} = \alpha_t + \xi_t, \quad \xi_t \sim N(0, \sigma_\xi^2)$$

$$\beta_{t+1} = \beta_t + \zeta_t, \quad \zeta_t \sim N(0, \sigma_\zeta^2)$$

où r_t est le rendement excédentaire d'un actif, $r_{m,t}$ celui du portefeuille de marché, et $\{\varepsilon_t\}, \{\xi_t\}, \{\zeta_t\}$ sont **mutuellement indépendants**.

*Note : $\{\alpha_t\}$ et $\{\beta_t\}$ sont des **marches aléatoires** à pas i.i.d. $N(0, \sigma_\xi^2)$ et $N(0, \sigma_\zeta^2)$.*

L'équation d'état.

$$\begin{pmatrix} \alpha_{t+1} \\ \beta_{t+1} \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \alpha_t \\ \beta_t \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \xi_t \\ \zeta_t \end{pmatrix}$$

soit $\mathbf{s}_{t+1} = \mathbf{T}_t \mathbf{s}_t + \mathbf{R}_t \boldsymbol{\eta}_t$ avec

$$\mathbf{s}_t = \begin{pmatrix} \alpha_t \\ \beta_t \end{pmatrix}, \quad \mathbf{T}_t = \mathbf{R}_t = \mathbf{I}_2, \quad \boldsymbol{\eta}_t = \begin{pmatrix} \xi_t \\ \zeta_t \end{pmatrix} \sim N_2(\mathbf{0}_2, \mathbf{Q}_t), \quad \mathbf{Q}_t = \begin{pmatrix} \sigma_\xi^2 & 0 \\ 0 & \sigma_\zeta^2 \end{pmatrix}$$

L'équation d'observation.

$$r_t = (1 \quad r_{m,t}) \begin{pmatrix} \alpha_t \\ \beta_t \end{pmatrix} + \varepsilon_t = \mathbf{Z}_t \mathbf{s}_t + \varepsilon_t$$

avec $\mathbf{Z}_t = (1 \quad r_{m,t})$ et $\varepsilon_t \sim N(0, H_t)$, $H_t = \sigma_\varepsilon^2$.

Regardez ce que ce modèle permet. Le bêta d'un titre n'est plus une constante à estimer une fois pour toutes (fiche 54) : c'est un **état caché qui dérive**. Le filtre de Kalman en produira une estimation à **chaque date**, mise à jour observation par observation.

Et l'inversion conceptuelle est notable : $\mathbf{Z}_t = (1 \quad r_{m,t})$ dépend de t — ce sont les **régresseurs** qui occupent la matrice d'observation, tandis que les **coefficients** sont dans l'état. Exactement l'inverse d'une régression ordinaire.

σ_ξ^2 et σ_ζ^2 **règlent la vitesse de dérive**. Grandes, les paramètres bougent vite et l'estimation suit les données de près, au prix du bruit. Petites, ils bougent lentement — et à la limite nulle, on retrouve la régression à coefficients constants (concept 3).

● Concept 3 — Exemple : régression à coefficients variables

Considérons un modèle de régression linéaire normal à coefficients variables dans le temps :

$$y_t = \mathbf{x}_t^T \boldsymbol{\beta}_t + \varepsilon_t, \quad \varepsilon_t \text{ i.i.d. } N(0, \sigma^2)$$

où $\mathbf{x}_t = (\mathbf{x}_{1,t}, \dots, \mathbf{x}_{p,t})^T$ est le p -vecteur des variables explicatives et $\boldsymbol{\beta}_t = (\beta_{1,t}, \dots, \beta_{p,t})^T$ le vecteur des paramètres de régression, et où **chaque composante** suit une marche aléatoire :

$$\beta_{j,t+1} = \beta_{j,t} + \xi_{j,t}, \quad \{\xi_{j,t}\} \text{ i.i.d. } N(0, \sigma_j^2), \quad j = 1, \dots, p$$

Le système espace-état joint.

$$\begin{pmatrix} s_{t+1} \\ y_t \end{pmatrix} = \begin{pmatrix} I_p \\ x_t^T \end{pmatrix} s_t + \begin{pmatrix} \xi_t \\ \varepsilon_t \end{pmatrix}, \quad s_t = \beta_t$$

c'est-à-dire $T_t = I_p$, $Z_t = x_t^T$, $R_t = I_p$, avec

$$\xi_t \sim N(0, Q_t), \quad Q_t = \text{diag}(\sigma_1^2, \dots, \sigma_p^2), \quad \varepsilon_t \sim N(0, H_t), \quad H_t = \sigma^2$$

Cas particulier $\sigma_j^2 \equiv 0$: le modèle de régression linéaire normal. L'estimation successive des paramètres du modèle espace-état pour $t = p + 1, p + 2, \dots$ fournit un **algorithme de mise à jour récursif** pour le modèle de régression sur série temporelle.

C'est un résultat remarquable et souvent méconnu. Avec $\sigma_j^2 = 0$, les coefficients sont **constants** : on retrouve exactement la régression de la fiche 50. Mais le filtre de Kalman la calcule **récursivement**, observation par observation, sans jamais inverser $X^T X$ ni stocker toutes les données.

Deux bénéfices pratiques. D'abord, un coût mémoire constant — précieux en temps réel. Ensuite, la suite des **résidus récursifs** produite chemin faisant est la base des tests de **stabilité structurelle** (CUSUM) : si les coefficients changent vraiment, ces résidus le signalent.

● Concept 4 — AR(p), MA(q) et ARMA(p, q) en espace-état

Le modèle AR(p)

$\phi(L)y_t = \varepsilon_t$ avec $\phi(L) = 1 - \sum_{j=1}^p \phi_j L^j$ et $\{\varepsilon_t\}$ i.i.d. $N(0, \sigma^2)$, donc

$$y_{t+1} = \sum_{j=1}^p \phi_j y_{t+1-j} + \varepsilon_{t+1}$$

Vecteur d'état : $s_t = (y_t, y_{t-1}, \dots, y_{t-p+1})^T$.

Équation d'état $s_{t+1} = T_t s_t + R_t \eta_t$ avec

$$T_t = \begin{pmatrix} \phi_1 & \phi_2 & \cdots & \phi_{p-1} & \phi_p \\ 1 & 0 & \cdots & 0 & 0 \\ 0 & 1 & \cdots & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \cdots & 1 & 0 \end{pmatrix}, \quad R_t = \begin{pmatrix} 1 \\ 0 \\ 0 \\ \vdots \\ 0 \end{pmatrix}, \quad \{\eta_t = \varepsilon_{t+1}\} \text{ i.i.d. } N(0, \sigma^2)$$

Équation d'observation :

$$y_t = (1 \ 0 \ 0 \ \cdots \ 0)s_t = Z_t s_t \quad (\text{pas d'erreur de mesure})$$

Reconnaissez la matrice compagnon de la fiche 58. La première ligne applique la récurrence autorégressive ; les lignes suivantes ne font que **décaler** le passé d'un cran. Et $R_t = (1, 0, \dots, 0)^T$ dit que **l'innovation n'entre que par le haut**.

Noter l'absence d'erreur de mesure : $H_t = 0$. On observe y_t **exactement** ; toute l'incertitude est dans la dynamique.

Le modèle MA(q)

$$y_t = \theta(L)\varepsilon_t \text{ avec } \theta(L) = 1 + \sum_{j=1}^q \theta_j L^j, \text{ donc } y_{t+1} = \varepsilon_{t+1} + \sum_{j=1}^q \theta_j \varepsilon_{t+1-j}.$$

$$\text{Vecteur d'état : } s_t = (\varepsilon_{t-1}, \varepsilon_{t-2}, \dots, \varepsilon_{t-q})^T.$$

$$\text{Équation d'état } s_{t+1} = T_t s_t + R_t \eta_t \text{ avec}$$

$$T_t = \begin{pmatrix} 0 & 0 & \cdots & 0 & 0 \\ 1 & 0 & \cdots & 0 & 0 \\ 0 & 1 & \cdots & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \cdots & 1 & 0 \end{pmatrix}, \quad R_t = \begin{pmatrix} 1 \\ 0 \\ 0 \\ \vdots \\ 0 \end{pmatrix}, \quad \{\eta_t = \varepsilon_t\} \text{ i.i.d. } N(0, \sigma^2)$$

Équation d'observation :

$$y_t = (\theta_1 \ \theta_2 \ \cdots \ \theta_{q-1} \ \theta_q)s_t + \varepsilon_t = Z_t s_t + \varepsilon_t$$

Comparez les deux T_t : c'est la différence AR / MA en une image. Pour l'AR, la première ligne contient les ϕ — le système se **rétroalimente**. Pour le MA, la matrice est un **pur décalage** : les innovations entrent, avancent d'un cran à chaque période, et **sortent** au bout de q pas. D'où la mémoire finie du MA (fiche 52).

Et l'erreur de mesure réapparaît ici, parce que ε_t — l'innovation **courante** — n'est pas dans l'état, qui ne contient que le passé.

Le modèle ARMA(p, q)

$\phi(L)y_t = \theta(L)\varepsilon_t$, donc

$$y_{t+1} = \sum_{j=1}^p \phi_j y_{t+1-j} + \varepsilon_{t+1} + \sum_{j=1}^q \theta_j \varepsilon_{t+1-j}$$

Le tour de passe-passe. On pose $m = \max(p, q + 1)$ et l'on **complète par des zéros** :

$$\phi_j = 0 \text{ si } p < j \leq m, \quad \theta_j = 0 \text{ si } q < j \leq m$$

de sorte que $\{y_t\} \sim \text{ARMA}(m, m - 1)$. Tout ARMA se ramène ainsi à une forme où les deux ordres sont liés.

Spécification espace-état de Harvey (1993). On définit le vecteur d'état $s_t = (s_{1,t}, \dots, s_{m,t})^T$ **récurivement**, en posant $s_{1,t} = y_t$, puis en utilisant l'équation du modèle pour définir $s_{2,t}$, puis $s_{3,t}$, etc. :

$$s_{2,t} = \sum_{i=2}^m \phi_i y_{t+1-i} + \sum_{j=1}^{m-1} \theta_j \varepsilon_{t+1-j}, \quad s_{3,t} = \sum_{i=3}^m \phi_i y_{t+2-j} + \sum_{j=2}^{m-1} \theta_j \varepsilon_{t+2-j}, \quad \dots$$

jusqu'à $s_{m,t} = \phi_m y_{t-1} + \theta_{m-1} \varepsilon_t$.

Toutes les équations s'écrivent ensemble :

$$s_{t+1} = T s_t + R \eta_t, \quad y_t = Z s_t \quad (\text{pas d'erreur de mesure})$$

$$T = \begin{pmatrix} \phi_1 & 1 & 0 & \cdots & 0 \\ \phi_2 & 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \phi_{m-1} & 0 & 0 & \cdots & 1 \\ \phi_m & 0 & 0 & \cdots & 0 \end{pmatrix}, \quad R = \begin{pmatrix} 1 \\ \theta_1 \\ \vdots \\ \theta_{m-2} \\ \theta_{m-1} \end{pmatrix}, \quad Z = (1 \quad 0 \quad \cdots \quad 0)$$

avec η_t i.i.d. $N(0, \sigma^2)$.

La structure est lumineuse une fois vue. La **première colonne** de T porte la partie **autorégressive** ; la **sur-diagonale** de 1 fait avancer l'information d'un cran ; et le vecteur R porte la partie **moyenne mobile** — c'est par lui que l'innovation courante se distribue sur toutes les composantes d'état, avec les poids θ_j .

Une seule matrice T , un seul vecteur R , et l'on a **tous** les ARMA. C'est cette économie qui fait de l'espace-état le cadre standard des logiciels de séries temporelles.

● Concept 5 — Le filtre de Kalman : notations et objectifs

Le cadre. Avec $\mathcal{F}_t = \{y_1, y_2, \dots, y_t\}$ les observations jusqu'au temps t , le **filtre de Kalman** est le calcul **récuratif** des densités de probabilité

$$p(s_{t+1} \mid \mathcal{F}_t), \quad p(s_{t+1}, y_{t+1} \mid \mathcal{F}_t), \quad p(y_{t+1} \mid \mathcal{F}_t), \quad t = 1, 2, \dots$$

On note $\theta = \{\text{tous les paramètres de } T_t, Z_t, R_t, Q_t, H_t\}$.

Les notations.

Objet	Définition
$s_{t t}$	$E(s_t \mid \mathcal{F}_t)$ — état filtré
$s_{t t-1}$	$E(s_t \mid \mathcal{F}_{t-1})$ — état prédit
$y_{t t-1}$	$E(y_t \mid \mathcal{F}_{t-1})$ — observation prédite
$\Sigma_s(t t)$	$\text{Cov}(s_t \mid \mathcal{F}_t) = E[(s_t - s_{t t})(s_t - s_{t t})^T]$
$\Sigma_s(t t-1)$	$\text{Cov}(s_t \mid \mathcal{F}_{t-1})$
$\Sigma_y(t t-1)$	$\text{Cov}(y_t \mid \mathcal{F}_{t-1})$

Innovations / résidus d'observation.

$$\tilde{\varepsilon}_t = (y_t - y_{t|t-1}) = y_t - Z_t s_{t|t-1}$$

Retenez la lecture des indices : $t|t-1$ = « au temps t , sachant l'information jusqu'en $t-1$ » — c'est une **prédiction**. $t|t$ = en incorporant l'observation du jour — c'est un **filtrage**. Et $t'|t$ avec $t' < t$ — en utilisant des observations **postérieures** — c'est un **lissage**.

● Concept 6 — Les quatre étapes du filtre

(1) Étape de prédiction

Prédire le vecteur d'état et le vecteur d'observation au temps t étant donné $\mathcal{F}_{t-1}$.

$$s_{t|t-1} = T_{t-1} s_{t-1|t-1}, \quad y_{t|t-1} = Z_t s_{t|t-1}$$

Les prédictions sont des espérances conditionnelles, dont les **erreurs quadratiques moyennes** valent

$$\Sigma_s(t|t-1) = T_t \Sigma_s(t-1|t-1) T_t^T + R_t Q_t R_t^T$$

$$\Sigma_y(t|t-1) = Z_t \Sigma_s(t|t-1) Z_t^T + H_t$$

Les deux termes de chaque ligne se lisent directement. L'incertitude sur l'état se **propage** par T (premier terme) et **augmente** du bruit de transition $R_t Q_t R_t^T$ (second terme). L'incertitude sur l'observation est l'incertitude sur l'état, vue à travers Z , **plus** le bruit de mesure H_t . Prédire, c'est toujours perdre de l'information.

(2) Étape de correction / filtrage

Mettre à jour la prédiction de l'état et son EQM étant donné l'observation au temps t .

$$s_{t|t} = s_{t|t-1} + G_t (y_t - y_{t|t-1})$$

$$\Sigma_s(t|t) = \Sigma_s(t|t-1) - G_t \Sigma_y(t|t-1) G_t^T$$

où

$$G_t = \Sigma_s(t|t-1) Z_t^T [\Sigma_y(t|t-1)]^{-1}$$

est la **matrice de gain du filtre**.

C'est l'équation la plus importante du chapitre, et elle a une forme très intuitive :

$$\text{nouvelle estimation} = \text{prédiction} + \text{gain} \times \text{surprise}$$

La « surprise » est l'innovation $\tilde{\epsilon}_t = \mathbf{y}_t - \mathbf{y}_{t|t-1}$: l'écart entre ce qu'on observe et ce qu'on attendait. Le **gain** dit quelle fraction de cette surprise attribuer à l'état plutôt qu'au bruit de mesure.

Lisez sa formule : G_t est grand quand Σ_s est grande (on est incertain sur l'état, donc on écoute la donnée) et petit quand Σ_y est grande, c'est-à-dire quand H_t domine (la mesure est bruitée, donc on s'en méfie). Le filtre **arbitre automatiquement** entre modèle et données.

Et $\Sigma_s(t|t) \leq \Sigma_s(t|t-1)$: **observer réduit toujours l'incertitude**.

(3) Étape de prévision

Pour les temps $t' > t$, utiliser les équations de récurrence suivantes pour $t' = t+1, t+2, \dots$

$$\mathbf{s}_{t'|t} = \mathbf{T}_{t'-1} \mathbf{s}_{t'-1|t}, \quad \Sigma_s(t'|t) = \mathbf{T}_{t'-1} \Sigma_s(t'-1|t) \mathbf{T}_{t'-1}^T + \mathbf{R}_{t'} \mathbf{Q}_{t'} \mathbf{R}_{t'}^T$$

$$\mathbf{y}_{t'|t} = \mathbf{Z}_{t'} \mathbf{s}_{t'|t}, \quad \Sigma_y(t'|t) = \mathbf{Z}_{t'} \Sigma_s(t'|t) \mathbf{Z}_{t'}^T + \mathbf{H}_{t'}$$

C'est l'étape de **prédiction itérée**, sans correction — puisqu'il n'y a plus d'observation à incorporer. À chaque pas, $\mathbf{R}_{t'} \mathbf{Q}_{t'} \mathbf{R}_{t'}^T$ s'ajoute : l'incertitude de prévision **croît monotonement** avec l'horizon, ce qui est la traduction exacte du bon sens.

(4) Étape de lissage

Mettre à jour les prédictions et EQM pour les temps $t' < t$, afin d'utiliser **toute** l'information de $\mathcal{F}_t$ plutôt que la seule $\mathcal{F}_{t'}$. Utiliser les récurrences pour $t' = t-1, t-2, \dots$

$$\mathbf{s}_{t'|t} = \mathbf{s}_{t'|t'} + \mathbf{S}_{t'} (\mathbf{s}_{t'+1|t} - \mathbf{s}_{t'+1|t'})$$

$$\Sigma_s(t'|t) = \Sigma_s(t'|t') - \mathbf{S}_{t'} [\Sigma_s(t'+1|t') - \Sigma_s(t'+1|t)] \mathbf{S}_{t'}^T$$

où

$$\mathbf{S}_{t'} = \Sigma_s(t'|t') \mathbf{T}_{t'}^T [\Sigma_s(t'+1|t')]^{-1}$$

est la **matrice de lissage de Kalman**.

Le lissage tourne à l'envers. Le filtrage va de **1** vers **T** ; le lissage repart de **T** vers **1**, en réinjectant l'information du futur dans les estimations passées. La structure de la formule est la même que celle du filtrage — prédiction plus gain fois surprise — mais la « surprise » est ici l'écart entre l'estimation lissée de $t' + 1$ et sa prédiction depuis t' .

Quand utilise-t-on quoi ? En **temps réel** — trading, contrôle —, on n'a que le **filtrage** : le futur n'existe pas encore. Pour une **analyse historique** — reconstituer la trajectoire d'un bêta sur dix ans —, on utilise le **lissage**, strictement plus précis puisqu'il exploite toute l'information disponible.

● Concept 7 — La vraisemblance et son maximum

La fonction de vraisemblance. Étant donné θ , on écrit

$$L(\theta) = p(y_1, \dots, y_T; \theta) = p(y_1; \theta) p(y_2 | y_1; \theta) \cdots p(y_T | y_1, \dots, y_{T-1}; \theta)$$

La clé. En supposant les erreurs de transition $\{\eta_t\}$ et d'observation $\{\varepsilon_t\}$ gaussiennes, les observations y_t ont les lois conditionnelles normales suivantes :

$$[y_t | \mathcal{F}_{t-1}; \theta] \sim N[y_{t|t-1}, \Sigma_y(t|t-1)]$$

La log-vraisemblance.

$$\begin{aligned} \ell(\theta) &= \log p(y_1, \dots, y_T; \theta) = \sum_{i=1}^T \log p(y_i | \mathcal{F}_{i-1}; \theta) \\ &= -\frac{kT}{2} \log(2\pi) - \frac{1}{2} \sum_{t=1}^T \log |\Sigma_y(t|t-1)| - \frac{1}{2} \sum_{t=1}^T (y_t - y_{t|t-1})^T [\Sigma_y(t|t-1)]^{-1} (y_t - y_{t|t-1}) \end{aligned}$$

L'algorithme du filtre de Kalman fournit tous les termes nécessaires au calcul de la fonction de vraisemblance, pour n'importe quel θ .

Voilà le bénéfice décisif — la « décomposition en erreurs de prédiction ». La vraisemblance jointe de T observations dépendantes est *a priori* une gaussienne de dimension kT : il faudrait inverser une matrice $kT \times kT$. La factorisation en conditionnelles la remplace par T gaussiennes de dimension k , chacune fournie **gratuitement** par le filtre : $y_{t|t-1}$ à l'étape de prédiction, $\Sigma_y(t|t-1)$ aussi.

On ne fait donc **qu'un seul passage** du filtre pour évaluer $\ell(\theta)$. C'est ce qui rend l'estimation praticable. Et c'est **exactement** l'étape 3 de l'estimation ARMA annoncée en fiche 52 : « *appliquer la décomposition en erreurs de prédiction de la log-vraisemblance* ».

Calculer les estimations du maximum de vraisemblance. Méthodes pour maximiser $\ell(\theta)$:

- l'**algorithme EM** (Dempster, Laird et Rubin, 1977) ;
- des **méthodes d'optimisation non linéaire**, de type Newton.

On retrouve EM une troisième fois : pour les sauts de Poisson (fiche 53), pour l'analyse factorielle (fiche 54), et ici. Le motif est toujours le même — l'**état s_t est une donnée manquante**, et l'étape E consiste précisément à en calculer l'espérance conditionnelle... c'est-à-dire à faire tourner le filtre et le lisseur.

Les propriétés asymptotiques. Pour $T \rightarrow \infty$, l'EMV $\hat{\theta}_T$ est :

- **consistant** : $\hat{\theta}_T \rightarrow \theta$, la vraie valeur ;
- **asymptotiquement normal**, de matrice de covariance $\mathcal{I}_T^{-1}$, où

$$\mathcal{I}_T = E \left[\left(\frac{\partial}{\partial \theta} \log L(\theta) \right) \left(\frac{\partial}{\partial \theta} \log L(\theta) \right)^T \right] = (-1) \cdot E \left[\frac{\partial^2}{\partial \theta \partial \theta^T} \log L(\theta) \right]$$

est la **matrice d'information de Fisher** pour θ .

● Concept 8 — Trois remarques du cours

- Sous hypothèses **gaussiennes**, toutes les variables d'état et d'observation sont **conjointement gaussiennes**, si bien que les récurrences du filtre de Kalman fournissent une **spécification complète** du modèle.
- Le **vecteur d'état initial** s_1 est modélisé comme $N(\mu_{s_1}, \Sigma_s(1))$, où moyenne et covariance sont **pré-spécifiées**. Les choix dépendent de l'application et peuvent refléter une information initiale **diffuse** (incertaine) ou **ergodique** (représentant la loi stationnaire de long terme des variables d'état).
- Sous hypothèses de **stationnarité en covariance** pour $\{\eta_t\}$ et $\{\varepsilon_t\}$, les expressions récursives restent valides pour les moyennes et covariances **conditionnelles**.

La première remarque explique pourquoi le filtre est optimal et pas seulement raisonnable.

Dans le monde gaussien, tout est conjointement gaussien, donc les lois conditionnelles sont **entièrement décrites** par une moyenne et une covariance — précisément ce que le filtre calcule. Il n'y a rien d'autre à connaître.

Hors du monde gaussien, les récurrences restent valides comme **meilleur estimateur linéaire** — c'est la troisième remarque —, mais elles ne donnent plus la loi conditionnelle complète. D'où les extensions non linéaires : filtre de Kalman étendu, filtre particulaire.

L'initialisation n'est pas un détail. Une initialisation **diffuse** ($\Sigma_s(1)$ très grande) dit « je ne sais rien de l'état de départ » : le filtre laisse alors les premières observations le déterminer presque entièrement. Une initialisation **ergodique** utilise la loi stationnaire du processus — elle n'est possible que si le système *est* stationnaire, ce qui exclut les états en marche aléatoire comme le bêta variable du concept 2.

Comment résoudre l'exercice type (protocole)

1. **Identifier ce qui est caché** (s_t) et ce qui est observé (y_t).
2. **Écrire l'équation d'état** $s_{t+1} = T_t s_t + R_t \eta_t$: comment l'état évolue.

3. **Écrire l'équation d'observation** $y_t = Z_t s_t + \varepsilon_t$: comment on le mesure.
4. **Identifier les matrices** T_t, R_t, Z_t, Q_t, H_t et leurs dimensions — c'est là que se font les erreurs.
5. **Initialiser** : $s_1 \sim N(\mu_{s_1}, \Sigma_s(1))$, diffuse ou ergodique.
6. **Faire tourner le filtre** : prédiction, puis correction, pour $t = 1, \dots, T$.
7. **Accumuler la log-vraisemblance** au passage, terme par terme.
8. **Maximiser** en θ par EM ou par une méthode de Newton.
9. **Prévoir** ($t' > T$) ou **lisser** ($t' < T$) selon le besoin.

Comment reconnaître qu'il faut utiliser cette méthode ?

Indice dans l'énoncé	Ce qu'il faut faire
« paramètre variable dans le temps »	l'état = le paramètre, transition en marche aléatoire
« bêta qui dérive »	CAPM espace-état du concept 2
« variable latente / non observée »	vecteur d' état
« erreur de mesure »	$H_t \neq 0$ dans l'équation d'observation
« estimation en temps réel »	filtrage — $s_{t t}$
« reconstituer la trajectoire passée »	lissage — $s_{t' T}$
« prévoir à h périodes »	prévision — itérer la transition
« estimer un ARMA par maximum de vraisemblance »	forme espace-état + décomposition en erreurs de prédiction
« mise à jour récursive »	$s_{t t} = s_{t t-1} + G_t \tilde{\varepsilon}_t$

Exercices progressifs

Niveau 1 — Écrivez un AR(2) sous forme espace-état.

Le modèle. $y_{t+1} = \phi_1 y_t + \phi_2 y_{t-1} + \varepsilon_{t+1}$, avec ε_t i.i.d. $N(0, \sigma^2)$.

Vecteur d'état : $s_t = (y_t, y_{t-1})^T$, de dimension $m = 2$.

Équation d'état.

$$\begin{pmatrix} y_{t+1} \\ y_t \end{pmatrix} = \begin{pmatrix} \phi_1 & \phi_2 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} y_t \\ y_{t-1} \end{pmatrix} + \begin{pmatrix} 1 \\ 0 \end{pmatrix} \varepsilon_{t+1}$$

soit $T = \begin{pmatrix} \phi_1 & \phi_2 \\ 1 & 0 \end{pmatrix}$, $R = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$, $Q = \sigma^2$.

Équation d'observation.

$$y_t = (1 \ 0) s_t \quad \text{soit } Z = (1 \ 0), \quad H = 0$$

Les deux points à vérifier.

- La **deuxième ligne** de T est $(1, 0)$: elle recopie simplement y_t en deuxième position. C'est le mécanisme de **décalage**.
- $H = 0$: **pas d'erreur de mesure**, on observe y_t exactement. Toute l'incertitude est dans la transition.

Un contrôle utile. Les valeurs propres de T sont les racines de $\lambda^2 - \phi_1 \lambda - \phi_2 = 0$. La condition de stationnarité de la fiche 52 — modules < 1 — est **exactement** la condition de stabilité de la matrice de transition. Les deux formulations coïncident.

Niveau 2 — Interprétez la matrice de gain G_t et ses deux cas limites.

L'équation de mise à jour.

$$s_{t|t} = s_{t|t-1} + G_t \underbrace{(y_t - y_{t|t-1})}_{\text{innovation, la « surprise »}}, \quad G_t = \Sigma_s(t|t-1) Z_t^T [\Sigma_y(t|t-1)]^{-1}$$

L'interprétation générale. G_t répond à : « quelle **part de la surprise** dois-je attribuer à une erreur sur l'état plutôt qu'au bruit de mesure ? » C'est un rapport entre **incertitude sur l'état** (numérateur $\Sigma_s Z^T$) et **incertitude totale sur l'observation** (dénominateur $\Sigma_y = Z \Sigma_s Z^T + H$).

Cas limite 1 — mesure parfaite ($H_t \rightarrow 0$). Alors $\Sigma_y \rightarrow Z \Sigma_s Z^T$ et, dans le cas scalaire, $G_t \rightarrow 1/Z$: la mise à jour **absorbe entièrement** l'innovation. On croit totalement la donnée, et $\Sigma_s(t|t) \rightarrow 0$ dans les directions observées.

Cas limite 2 — mesure inutilisable ($H_t \rightarrow \infty$). Alors $\Sigma_y \rightarrow \infty$ et $G_t \rightarrow 0$: la mise à jour **ignore** l'observation, $s_{t|t} = s_{t|t-1}$. On s'en remet entièrement au modèle.

Entre les deux, G_t arbitre continûment. Et l'arbitrage est **adaptatif** : $\Sigma_s(t|t-1)$ évolue à chaque pas, donc le gain aussi. Après une longue série d'observations informatives, Σ_s diminue et le filtre devient progressivement plus « confiant » dans son modèle.

Le résultat de réduction d'incertitude.

$$\Sigma_s(t|t) = \Sigma_s(t|t-1) - G_t \Sigma_y(t|t-1) G_t^T \preceq \Sigma_s(t|t-1)$$

Le terme soustrait est semi-défini positif : **observer ne peut jamais augmenter l'incertitude.**

Le parallèle à retenir. G_t est structurellement un coefficient de **régression** — covariance sur variance — de l'état sur l'innovation. Le filtre de Kalman *est* une régression réursive de l'état caché sur les surprises successives.

Niveau 3 — Pourquoi la vraisemblance se factorise-t-elle en erreurs de prédiction, et pourquoi est-ce décisif ?

La factorisation. Par la règle des probabilités conditionnelles, valable sans aucune hypothèse :

$$L(\theta) = p(y_1, \dots, y_T; \theta) = p(y_1; \theta) p(y_2 | y_1; \theta) \cdots p(y_T | y_1, \dots, y_{T-1}; \theta)$$

Ce que la gaussianité ajoute. Sous erreurs gaussiennes, tout est conjointement gaussien, donc chaque conditionnelle est une gaussienne **explicite** :

$$[y_t | \mathcal{F}_{t-1}; \theta] \sim N[y_{t|t-1}, \Sigma_y(t|t-1)]$$

d'où

$$\ell(\theta) = -\frac{kT}{2} \log(2\pi) - \frac{1}{2} \sum_t \log |\Sigma_y(t|t-1)| - \frac{1}{2} \sum_t \tilde{\epsilon}_t^T [\Sigma_y(t|t-1)]^{-1} \tilde{\epsilon}_t$$

Pourquoi c'est décisif — le décompte. Sans factorisation, $(y_1, \dots, y_T)$ est une gaussienne de dimension kT , de covariance **pleine** : il faudrait former et inverser une matrice $kT \times kT$, soit un coût en $O((kT)^3)$. Pour $T = 1000$ et $k = 1$, c'est 10^9 opérations — **par évaluation de ℓ** , et l'optimiseur en demande des milliers.

Avec la factorisation, chaque terme ne demande que l'inversion d'une matrice $k \times k$, et il y en a T : coût $O(Tk^3)$, **linéaire en T** .

Et le point le plus élégant. Les deux quantités nécessaires — $y_{t|t-1}$ et $\Sigma_y(t|t-1)$ — sont **exactement** ce que produit l'étape de prédiction du filtre. On ne fait donc **aucun calcul supplémentaire** : un seul passage du filtre donne à la fois les estimations d'état et la valeur de la vraisemblance. Le cours le dit tel quel : *l'algorithme du filtre de Kalman fournit tous les termes nécessaires au calcul de la fonction de vraisemblance, pour n'importe quel θ .*

La boucle d'estimation complète est donc : (1) choisir θ ; (2) faire tourner le filtre en accumulant $\ell(\theta)$; (3) faire un pas d'optimisation (EM ou Newton) ; (4) recommencer jusqu'à convergence.

Le retour en fiche 52. L'étape 3 de l'estimation ARMA par maximum de vraisemblance disait : « *appliquer la décomposition en erreurs de prédiction de la log-vraisemblance* ». C'est cela, et rien d'autre.

Niveau 4 — type examen — Décrivez les quatre étapes du filtre de Kalman en disant ce que chacune calcule et à quoi elle sert.

Le cadre. $s_{t+1} = T_t s_t + R_t \eta_t$ (état, caché) et $y_t = Z_t s_t + \varepsilon_t$ (observation), avec $\eta_t \sim N(0, Q_t)$, $\varepsilon_t \sim N(0, H_t)$ indépendants. $\mathcal{F}_t = \{y_1, \dots, y_t\}$.

(1) Prédiction — « où sera l'état, et que devrais-je observer ? »

$$s_{t|t-1} = T_{t-1} s_{t-1|t-1}, \quad y_{t|t-1} = Z_t s_{t|t-1}$$

$$\Sigma_s(t|t-1) = T_t \Sigma_s(t-1|t-1) T_t^T + R_t Q_t R_t^T, \quad \Sigma_y(t|t-1) = Z_t \Sigma_s(t|t-1) Z_t^T + H_t$$

On propage l'estimation d'un pas en avant. L'incertitude **augmente** de $R_t Q_t R_t^T$: le temps qui passe dégrade la connaissance.

(2) Correction / filtrage — « qu'est-ce que l'observation m'apprend ? »

$$s_{t|t} = s_{t|t-1} + G_t (y_t - y_{t|t-1}), \quad \Sigma_s(t|t) = \Sigma_s(t|t-1) - G_t \Sigma_y(t|t-1) G_t^T$$

$$G_t = \Sigma_s(t|t-1) Z_t^T [\Sigma_y(t|t-1)]^{-1}$$

« **prédiction** + **gain** × **surprise** ». Le gain arbitre entre confiance dans le modèle et confiance dans la donnée. L'incertitude **diminue** : observer informe toujours.

(3) Prévision — « et après la fin des données ? » Pour $t' > t$, on **itère la prédiction sans correction** :

$$s_{t'|t} = T_{t'-1} s_{t'-1|t}, \quad \Sigma_s(t'|t) = T_{t'-1} \Sigma_s(t'-1|t) T_{t'-1}^T + R_{t'} Q_{t'} R_{t'}^T$$

$$y_{t'|t} = Z_{t'} s_{t'|t}, \quad \Sigma_y(t'|t) = Z_{t'} \Sigma_s(t'|t) Z_{t'}^T + H_{t'}$$

L'incertitude **croît monotonement** avec l'horizon — il n'y a plus rien pour la réduire.

(4) Lissage — « avec le recul, que s'est-il vraiment passé ? » Pour $t' < t$, on repart de la fin :

$$s_{t'|t} = s_{t'|t'} + S_{t'}(s_{t'+1|t} - s_{t'+1|t'}), \quad S_{t'} = \Sigma_s(t'|t')T_{t'}^T[\Sigma_s(t' + 1|t')]^{-1}$$

$$\Sigma_s(t'|t) = \Sigma_s(t'|t') - S_{t'}[\Sigma_s(t' + 1|t') - \Sigma_s(t' + 1|t)]S_{t'}^T$$

On **réinjecte l'information du futur** dans les estimations passées.

Le tableau de synthèse.

Étape	Information utilisée	Sens du temps	Usage
Prédiction	$\mathcal{F}_{t-1}$	avant	interne au filtre
Filtrage	$\mathcal{F}_t$	avant	temps réel
Prévision	$\mathcal{F}_t, t' > t$	avant	prévision
Lissage	$\mathcal{F}_T, t' < T$	arrière	analyse historique

Les trois choses à ajouter en conclusion.

1. Le **lissage est toujours plus précis** que le filtrage : $\Sigma_s(t'|T) \preceq \Sigma_s(t'|t')$, puisqu'il utilise strictement plus d'information. Mais il est **inutilisable en temps réel**.
2. Les étapes (1) et (2) fournissent **gratuitement** $y_{t|t-1}$ et $\Sigma_y(t|t-1)$, c'est-à-dire tous les termes de la log-vraisemblance. Estimation d'état et estimation de paramètres se font **en un seul passage**.
3. Sous hypothèses gaussiennes, ces récurrences donnent une **spécification complète** du modèle — tout est jointement gaussien, donc moyennes et covariances conditionnelles suffisent. Hors du cas gaussien, elles restent le **meilleur estimateur linéaire**, mais plus la loi conditionnelle exacte.

● Common mistakes

1. **Confondre $s_{t|t}$ et $s_{t|t-1}$** — le premier incorpore l'observation du jour, le second non.
2. **Confondre filtrage et lissage** — le lissage utilise le **futur** et n'est pas disponible en temps réel.
3. **Oublier $R_t Q_t R_t^T$ dans la propagation de covariance** — l'incertitude doit **augmenter** entre deux observations.
4. **Se tromper de matrice dans le gain** — c'est $\Sigma_s(t|t-1)Z_t^T[\Sigma_y(t|t-1)]^{-1}$, avec Σ_s au numérateur et Σ_y au dénominateur.

5. **Oublier que l'AR(p) n'a pas d'erreur de mesure** — $H_t = 0$ et $y_t = Z_t s_t$ exactement.
6. **Se tromper de dimension pour l'ARMA** — il faut $m = \max(p, q + 1)$, pas $\max(p, q)$.
7. **Mettre les θ dans T pour l'ARMA** — ils vont dans R ; T ne contient que les ϕ et la sur-diagonale de 1.
8. **Négliger l'initialisation** — $\Sigma_s(1)$ change les premières estimations ; diffuse ou ergodique selon le cas.
9. **Utiliser une initialisation ergodique sur un état non stationnaire** — impossible pour une marche aléatoire comme le bêta variable.
10. **Croire que le filtre exige la gaussianité** — sans elle, il reste le **meilleur estimateur linéaire**, mais ne donne plus la loi complète.

Ultimate Review

1. **Objets** : y_t ($k \times 1$) observation · s_t ($m \times 1$) état · ε_t ($k \times 1$) erreur d'observation · η_t ($n \times 1$) innovation de transition.
2. **État** : $s_{t+1} = T_t s_t + R_t \eta_t$, η_t i.i.d. $N(0_n, Q_t)$, Q_t définie positive.
3. **Observation** : $y_t = Z_t s_t + \varepsilon_t$, ε_t i.i.d. $N(0_k, H_t)$, H_t définie positive.
4. **Jointe** : $\Omega = \text{diag}(R_t Q_t R_t^T, H_t)$ — les deux bruits sont **indépendants**.
5. **CAPM variable** : $s_t = (\alpha_t, \beta_t)^T$, $T = R = I_2$, $Q = \text{diag}(\sigma_\xi^2, \sigma_\zeta^2)$, $Z_t = (1 \ r_{m,t})$, $H = \sigma_\varepsilon^2$.
6. **Régression variable** : $s_t = \beta_t$, $T = R = I_p$, $Z_t = x_t^T$, $Q = \text{diag}(\sigma_j^2)$, $H = \sigma^2$; $\sigma_j^2 \equiv 0 \Rightarrow$ **régression ordinaire**, calculée récursivement.
7. **AR(p)** : $s_t = (y_t, \dots, y_{t-p+1})^T$, $T = \text{compagnon}$, $R = (1, 0, \dots, 0)^T$, $Z = (1, 0, \dots, 0)$, **pas d'erreur de mesure**.
8. **MA(q)** : $s_t = (\varepsilon_{t-1}, \dots, \varepsilon_{t-q})^T$, $T = \text{décalage pur}$, $R = (1, 0, \dots, 0)^T$, $Z = (\theta_1, \dots, \theta_q)$, avec erreur de mesure ε_t .
9. **ARMA(p, q)** (Harvey, 1993) : $m = \max(p, q + 1)$, $\phi_j = 0$ pour $j > p$, $\theta_j = 0$ pour $j > q$; $T = \phi$ en 1re colonne + sur-diagonale de 1, $R = (1, \theta_1, \dots, \theta_{m-1})^T$, $Z = (1, 0, \dots, 0)$.
10. **Notations** : $s_{t|t}$ filtré, $s_{t|t-1}$ prédit, $\Sigma_s(\cdot)$, $\Sigma_y(\cdot)$; innovation $\tilde{\varepsilon}_t = y_t - Z_t s_{t|t-1}$.
11. **(1) Prédiction** : $s_{t|t-1} = T_{t-1} s_{t-1|t-1}$, $\Sigma_s(t|t-1) = T_t \Sigma_s(t-1|t-1) T_t^T + R_t Q_t R_t^T$, $\Sigma_y(t|t-1) = Z_t \Sigma_s(t|t-1) Z_t^T + H_t$.
12. **(2) Correction** : $s_{t|t} = s_{t|t-1} + G_t \tilde{\varepsilon}_t$, $\Sigma_s(t|t) = \Sigma_s(t|t-1) - G_t \Sigma_y(t|t-1) G_t^T$, $G_t = \Sigma_s(t|t-1) Z_t^T [\Sigma_y(t|t-1)]^{-1}$.
13. **(3) Prévision** : itérer la transition sans correction ; l'incertitude **croît**.
14. **(4) Lissage** : $s_{t'|t} = s_{t'|t'} + S_{t'}(s_{t'+1|t} - s_{t'+1|t'})$ avec $S_{t'} = \Sigma_s(t'|t') T_{t'}^T [\Sigma_s(t'+1|t')]^{-1}$.
15. **Vraisemblance** : $[y_t | \mathcal{F}_{t-1}] \sim N[y_{t|t-1}, \Sigma_y(t|t-1)] \Rightarrow$

$$\ell(\theta) = -\frac{kT}{2} \log(2\pi) - \frac{1}{2} \sum_t \log |\Sigma_y(t|t-1)| - \frac{1}{2} \sum_t \tilde{\varepsilon}_t^T [\Sigma_y(t|t-1)]^{-1} \tilde{\varepsilon}_t$$

16. **Maximisation** : **EM** (Dempster, Laird et Rubin, 1977) ou méthodes de **Newton**.

17. **Asymptotique** : $\hat{\theta}_T$ **consistant** et asymptotiquement normal de covariance $\mathcal{I}_T^{-1}$, l'inverse de l'**information de Fisher**.

18. **Remarques** : gaussianité $\Rightarrow$ **spécification complète** · $s_1 \sim N(\mu_{s_1}, \Sigma_s(1))$, **diffuse** ou **ergodique** · sous stationnarité, les récurrences restent valides pour les moments conditionnels.

Formulas to know

$$s_{t+1} = T_t s_t + R_t \eta_t \quad y_t = Z_t s_t + \varepsilon_t \quad \tilde{\varepsilon}_t = y_t - Z_t s_{t|t-1}$$

$$s_{t|t} = s_{t|t-1} + G_t \tilde{\varepsilon}_t \quad G_t = \Sigma_s(t|t-1) Z_t^T [\Sigma_y(t|t-1)]^{-1}$$

$$\Sigma_s(t|t-1) = T_t \Sigma_s(t-1|t-1) T_t^T + R_t Q_t R_t^T \quad \Sigma_y(t|t-1) = Z_t \Sigma_s(t|t-1) Z_t^T + H_t$$

Methods to know : mettre AR, MA et ARMA sous forme espace-état ; les quatre étapes du filtre ; la décomposition de la vraisemblance en erreurs de prédiction ; l'interprétation du gain.

Active Recall

Basic — Écrivez les deux équations d'un modèle espace-état linéaire.

Équation d'état (transition) :

$$s_{t+1} = T_t s_t + R_t \eta_t, \quad \eta_t \text{ i.i.d. } N(0_n, Q_t)$$

Équation d'observation (mesure) :

$$y_t = Z_t s_t + \varepsilon_t, \quad \varepsilon_t \text{ i.i.d. } N(0_k, H_t)$$

avec s_t ($m \times 1$) l'état **caché**, y_t ($k \times 1$) l'observation, T_t ($m \times m$), R_t ($m \times n$), Z_t ($k \times m$), et Q_t , H_t définies positives. Les deux bruits sont **indépendants**.

Understanding — Que fait l'étape de correction, et comment la lire ?

Elle **incorpore l'observation du jour** dans l'estimation de l'état :

$$s_{t|t} = s_{t|t-1} + G_t(y_t - y_{t|t-1})$$

c'est-à-dire

$$\text{nouvelle estimation} = \text{prédiction} + \text{gain} \times \text{surprise}$$

La « surprise » est l'**innovation** $\tilde{\varepsilon}_t = y_t - Z_t s_{t|t-1}$: l'écart entre l'observé et l'attendu.

Le **gain**

$$G_t = \Sigma_s(t|t-1) Z_t^T [\Sigma_y(t|t-1)]^{-1}$$

dit quelle part de la surprise attribuer à une erreur sur l'état plutôt qu'au bruit de mesure.

Grand si l'on est incertain sur l'état ; **petit** si la mesure est bruitée (H_t grand).

Et l'incertitude diminue toujours :

$$\Sigma_s(t|t) = \Sigma_s(t|t-1) - G_t \Sigma_y(t|t-1) G_t^T \preceq \Sigma_s(t|t-1).$$

Application — Comment modéliser un bêta de CAPM qui dérive dans le temps ?

Le modèle.

$$r_t = \alpha_t + \beta_t r_{m,t} + \varepsilon_t, \quad \alpha_{t+1} = \alpha_t + \xi_t, \quad \beta_{t+1} = \beta_t + \zeta_t$$

avec $\varepsilon_t \sim N(0, \sigma_\varepsilon^2)$, $\xi_t \sim N(0, \sigma_\xi^2)$, $\zeta_t \sim N(0, \sigma_\zeta^2)$ **mutuellement indépendants**. Les coefficients suivent des **marches aléatoires**.

Sous forme espace-état.

$$s_t = \begin{pmatrix} \alpha_t \\ \beta_t \end{pmatrix}, \quad T_t = R_t = I_2, \quad Q_t = \begin{pmatrix} \sigma_\xi^2 & 0 \\ 0 & \sigma_\zeta^2 \end{pmatrix}, \quad Z_t = (1 \ r_{m,t}), \quad H_t = \sigma_\varepsilon^2$$

Ce que le filtre produit. Une estimation $\beta_{t|t}$ à **chaque date**, avec son intervalle de confiance $\Sigma_s(t|t)$, mise à jour observation par observation.

Le point de méthode le plus instructif : ce sont les **régresseurs** qui occupent $Z_t = (1 \ r_{m,t})$, tandis que les **coefficients** sont dans l'état. C'est exactement l'inverse d'une régression ordinaire — et c'est ce renversement qui permet aux coefficients de bouger.

σ_ξ^2 et σ_ζ^2 règlent la **vitesse de dérive**. À la limite nulle, on retrouve le CAPM à coefficients constants — estimé récursivement.

Comparison — Filtrage, prévision, lissage : quelle différence ?

	Filtrage $s_{t t}$	Prévision $s_{t' t}, t' > t$	Lissage $s_{t' t}, t' < t$
Information	jusqu'à t inclus	jusqu'à t	jusqu'à t , dont le futur de t'
Sens du temps	avant	avant	arrière
Incertitude	diminue à chaque observation	croît avec l'horizon	minimale
Disponible en direct ?	oui	oui	non
Usage	trading, contrôle temps réel	prévision	analyse historique

Filtrage : la meilleure estimation **au moment présent**, avec toute l'information disponible alors. C'est le seul mode utilisable en temps réel.

Prévision : on itère la transition **sans correction**, faute d'observations. L'incertitude s'accumule à raison de $R_t Q_t R_t^T$ par pas.

Lissage : on repart de la fin et l'on réinjecte l'information postérieure. Strictement plus précis — $\Sigma_s(t'|T) \preceq \Sigma_s(t'|t')$ — puisqu'il utilise plus d'information, mais **anachronique** : on ne peut pas trader sur une estimation qui utilise le futur.

Exam-style — Expliquez pourquoi la forme espace-état est le cadre unificateur des séries temporelles.

1. Presque tout s'y met. Le cours donne cinq exemples, tous ramenés aux deux mêmes équations :

Modèle	État s_t	T	Z
AR(p)	$(y_t, \dots, y_{t-p+1})^T$	compagnon	$(1, 0, \dots, 0)$
MA(q)	$(\varepsilon_{t-1}, \dots, \varepsilon_{t-q})^T$	décalage pur	$(\theta_1, \dots, \theta_q)$
ARMA(p, q)	Harvey, $m = \max(p, q + 1)$	ϕ + sur-diagonale	$(1, 0, \dots, 0)$
Régression variable	β_t	I_p	x_t^T
CAPM variable	$(\alpha_t, \beta_t)^T$	I_2	$(1, r_{m,t})$

Et l'on pourrait continuer : VAR (fiche 58), modèles à facteurs dynamiques (fiche 54), composantes inobservées, VECM.

2. Un seul algorithme fait tout. Une fois le modèle écrit, le **filtre de Kalman** fournit, sans rien changer :

- l'estimation en temps réel de l'état (**filtrage**) ;
- la **prévision** à tout horizon ;
- la reconstitution du passé (**lissage**) ;
- et la **vraisemblance**.

3. Le point le plus élégant : la vraisemblance est gratuite. La décomposition en erreurs de prédiction

$$L(\theta) = \prod_{t=1}^T p(y_t \mid \mathcal{F}_{t-1}; \theta), \quad [y_t \mid \mathcal{F}_{t-1}] \sim N[y_{t|t-1}, \Sigma_y(t|t-1)]$$

n'utilise que des quantités **déjà calculées** à l'étape de prédiction. Une gaussienne de dimension kT , dont l'évaluation directe coûterait $O((kT)^3)$, est remplacée par T gaussiennes de dimension k : coût **linéaire en T** .

4. La séparation conceptuelle est la bonne. Le cadre distingue proprement ce qui **évolue** (la dynamique, dans T et Q) de ce qu'on **mesure** (l'observation, dans Z et H). Cette séparation est celle du problème réel : un système physique ou économique évolue selon ses propres lois, et l'on n'y accède qu'à travers des mesures imparfaites.

5. Les limites, qu'il faut savoir énoncer. Le cadre est **linéaire** et, pour être *optimal*, **gaussien**. Hors de là, le filtre reste le meilleur estimateur **linéaire** — c'est la troisième remarque du cours, sur la stationnarité en covariance — mais ne donne plus la loi conditionnelle exacte. D'où les extensions : filtre de Kalman étendu, filtre non parfumé, filtre

particulière. Et le cadre suppose Q_t, H_t **connues** à un vecteur de paramètres θ près, qu'il faut estimer par maximum de vraisemblance — c'est là que reviennent EM et Newton.

Flashcards

Question	Réponse
Équation d'état ?	$s_{t+1} = T_t s_t + R_t \eta_t, \eta_t \sim N(0_n, Q_t)$
Équation d'observation ?	$y_t = Z_t s_t + \varepsilon_t, \varepsilon_t \sim N(0_k, H_t)$
Dimensions de T_t, R_t, Z_t ?	$(m \times m), (m \times n), (k \times m)$
Structure de Ω ?	$\text{diag}(R_t Q_t R_t^T, H_t)$ — bruits indépendants
État du CAPM à bêta variable ?	$s_t = (\alpha_t, \beta_t)^T, T = R = I_2$
Z_t du CAPM variable ?	$(1 \ r_{m,t})$
Cas $\sigma_j^2 \equiv 0$ en régression variable ?	Régression linéaire ordinaire , estimée récursivement
État d'un AR(p) ?	$(y_t, y_{t-1}, \dots, y_{t-p+1})^T$
T d'un AR(p) ?	La matrice compagnon
Erreur de mesure d'un AR(p) ?	Aucune : $y_t = Z_t s_t$ exactement
État d'un MA(q) ?	$(\varepsilon_{t-1}, \dots, \varepsilon_{t-q})^T$
T d'un MA(q) ?	Une matrice de décalage pur
Z d'un MA(q) ?	$(\theta_1, \theta_2, \dots, \theta_q)$
Dimension d'état d'un ARMA(p, q) ?	$m = \max(p, q + 1)$
Où vont les θ dans l'ARMA espace-état ?	Dans $R = (1, \theta_1, \dots, \theta_{m-1})^T$
Où vont les ϕ ?	Dans la première colonne de T
Qui a proposé cette spécification ?	Harvey (1993)
Que signifie $s_{t t-1}$?	$E(s_t \mathcal{F}_{t-1})$ — état prédit
Que signifie $s_{t t}$?	$E(s_t \mathcal{F}_t)$ — état filtré
Définition de l'innovation ?	$\tilde{\varepsilon}_t = y_t - Z_t s_{t t-1}$
Les quatre étapes du filtre ?	Prédiction · correction · prévision · lissage

Question	Réponse
Formule de mise à jour de l'état ?	$\mathbf{s}_{t t} = \mathbf{s}_{t t-1} + \mathbf{G}_t \tilde{\mathbf{e}}_t$
Matrice de gain ?	$\mathbf{G}_t = \Sigma_s(t t-1) \mathbf{Z}_t^T [\Sigma_y(t t-1)]^{-1}$
Propagation de la covariance d'état ?	$\mathbf{T}_t \Sigma_s(t-1 t-1) \mathbf{T}_t^T + \mathbf{R}_t \mathbf{Q}_t \mathbf{R}_t^T$
Covariance de l'observation prédite ?	$\mathbf{Z}_t \Sigma_s(t t-1) \mathbf{Z}_t^T + \mathbf{H}_t$
Matrice de lissage ?	$\mathbf{S}_{t'} = \Sigma_s(t' t') \mathbf{T}_{t'}^T [\Sigma_s(t'+1 t')]^{-1}$
Loi conditionnelle de $\mathbf{y}_t$?	$N[\mathbf{y}_{t t-1}, \Sigma_y(t t-1)]$
Nom de cette factorisation ?	Décomposition en erreurs de prédiction
Méthodes de maximisation ?	EM (Dempster, Laird, Rubin 1977) ou Newton
Variance asymptotique de l'EMV ?	$\mathcal{I}_T^{-1}$, l'inverse de l' information de Fisher
Loi de l'état initial ?	$\mathbf{s}_1 \sim N(\mu_{s_1}, \Sigma_s(1))$, diffuse ou ergodique
Que garantit la gaussianité ?	Une spécification complète du modèle