

Fiche 64 — Maximum de vraisemblance : de Kullback-Leibler à l'information de Fisher

Matière	Maths · Économétrie
Cours source	Rigollet, <i>18.650 Statistics for Applications</i> , MIT OpenCourseWare, automne 2016 — chapitre 3 « Maximum Likelihood Estimation »
Difficulté	Must know — la méthode d'estimation universelle
Temps d'étude estimé	2 h 30
Prérequis	Fiche 50 (maximum de vraisemblance en régression), loi des grands nombres, dérivées secondes
Concepts clés	Modèle statistique, distance en variation totale, divergence de Kullback-Leibler, principe du maximum de vraisemblance, concavité, gradient et hessienne, vraisemblance discrète et continue, estimateur du maximum de vraisemblance, information de Fisher, normalité asymptotique
Poids à l'examen	Trois choses : la chaîne KL $\Rightarrow$ maximum de vraisemblance — c'est <i>la</i> dérivation du chapitre ; l' information de Fisher sous ses deux formes ; et le théorème asymptotique avec ses hypothèses.

Vue d'ensemble

Le cadre. Soit $(E, (\mathbb{P}_\theta)_{\theta \in \Theta})$ un **modèle statistique** associé à un échantillon de variables i.i.d. $X_1, \dots, X_n$. On suppose qu'il existe $\theta^* \in \Theta$ tel que $X_1 \sim \mathbb{P}_{\theta^*}$: θ^* est le **vrai paramètre**.

Le but du statisticien. Étant donné $X_1, \dots, X_n$, trouver un estimateur $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$ tel que $\mathbb{P}_{\hat{\theta}}$ soit **proche** de $\mathbb{P}_{\theta^*}$. Cela signifie que $|\mathbb{P}_{\hat{\theta}}(A) - \mathbb{P}_{\theta^*}(A)|$ est petit **pour tout** $A \subset E$.

IDÉE	estimer θ^* = rendre $\mathbb{P}_{\hat{\theta}}$ proche de $\mathbb{P}_{\theta^*}$
DISTANCE 1	variation totale TV – belle, mais INESTIMABLE
DISTANCE 2	divergence KL – asymétrique, et c'est ce qui la sauve
CHAÎNE	$\min \text{KL} \Leftrightarrow \max \sum \log p_{\theta}(X_i) \Leftrightarrow \max \prod p_{\theta}(X_i)$

↑ le maximum de vraisemblance

PRÉCISION $\sqrt{n}(\hat{\theta} - \theta^*) \rightarrow N(0, I(\theta^*)^{-1})$ ← information de Fisher

La logique du chapitre est un raisonnement en trois temps. On veut minimiser une distance entre lois. La distance naturelle — la variation totale — **ne s'estime pas**. On la remplace par la divergence KL, qui, elle, s'estime **grâce à son asymétrie**. Et la minimisation de la KL estimée **est exactement** le maximum de vraisemblance. La méthode la plus utilisée de la statistique n'est donc pas un postulat : elle **se déduit**.

● Concept 1 — La distance en variation totale

DÉFINITION.

La **distance en variation totale** entre deux mesures de probabilité $\mathbb{P}_\theta$ et $\mathbb{P}_{\theta'}$ est

$$TV(\mathbb{P}_\theta, \mathbb{P}_{\theta'}) = \max_{A \subseteq E} |\mathbb{P}_\theta(A) - \mathbb{P}_{\theta'}(A)|$$

Cas discret. Si E est discret — fini ou dénombrable, ce qui inclut Bernoulli, binomiale, Poisson —, X a une **fonction de masse** $\mathbb{P}(X = x) = p(x)$ avec $p(x) \geq 0$ et $\sum_{x \in E} p(x) = 1$. La variation totale est alors une fonction simple des fonctions de masse :

$$TV(\mathbb{P}_\theta, \mathbb{P}_{\theta'}) = \frac{1}{2} \sum_{x \in E} |p_\theta(x) - p_{\theta'}(x)|$$

Cas continu. Si E est continu — gaussienne, exponentielle... — et si X a une densité $\mathbb{P}(X \in A) = \int_A f(x) dx$ avec $f \geq 0$ et $\int_E f = 1$:

$$TV(\mathbb{P}_\theta, \mathbb{P}_{\theta'}) = \frac{1}{2} \int_E |f_\theta(x) - f_{\theta'}(x)| dx$$

PROPRIÉTÉS DE LA VARIATION TOTALE.

- $TV(\mathbb{P}_\theta, \mathbb{P}_{\theta'}) = TV(\mathbb{P}_{\theta'}, \mathbb{P}_\theta)$ — **symétrique**
- $TV(\mathbb{P}_\theta, \mathbb{P}_{\theta'}) \geq 0$
- Si $TV(\mathbb{P}_\theta, \mathbb{P}_{\theta'}) = 0$ alors $\mathbb{P}_\theta = \mathbb{P}_{\theta'}$ — **définie**
- $TV(\mathbb{P}_\theta, \mathbb{P}_{\theta'}) \leq TV(\mathbb{P}_\theta, \mathbb{P}_{\theta''}) + TV(\mathbb{P}_{\theta''}, \mathbb{P}_{\theta'})$ — **inégalité triangulaire**

Ces propriétés impliquent que la variation totale est bien une **distance** entre distributions de probabilité.

La stratégie d'estimation. Construire un estimateur $\widehat{TV}(\mathbb{P}_\theta, \mathbb{P}_{\theta^*})$ pour tout $\theta \in \Theta$, puis trouver le $\hat{\theta}$ qui **minimise** la fonction $\theta \mapsto \widehat{TV}(\mathbb{P}_\theta, \mathbb{P}_{\theta^*})$.

PROBLÈME : ON NE VOIT PAS COMMENT CONSTRUIRE $\widehat{TV}(\mathbb{P}_\theta, \mathbb{P}_{\theta^*})$!

Comprenez précisément l'obstacle, il détermine toute la suite. La variation totale est

$$\frac{1}{2} \int |f_{\theta^*}(x) - f_\theta(x)| dx$$

Il faudrait estimer une intégrale de la **valeur absolue d'une différence** de densités. Or on ne dispose que d'un échantillon tiré selon f_{θ^*} , et la loi des grands nombres n'estime que des quantités de la forme $E_{\theta^*}[h(X)] = \int f_{\theta^*}(x)h(x)dx$ — c'est-à-dire des intégrales **pondérées par f_{θ^*}** . La valeur absolue empêche cette factorisation. **C'est là que la symétrie de TV devient un défaut.**

● Concept 2 — La divergence de Kullback-Leibler

Il existe de nombreuses distances entre mesures de probabilité pour remplacer la variation totale. Choisissons-en une qui soit **plus commode**.

DÉFINITION.

La **divergence de Kullback-Leibler (KL)** entre deux mesures $\mathbb{P}_\theta$ et $\mathbb{P}_{\theta'}$ est

$$KL(\mathbb{P}_\theta, \mathbb{P}_{\theta'}) = \begin{cases} \sum_{x \in E} p_\theta(x) \log \left(\frac{p_\theta(x)}{p_{\theta'}(x)} \right) & \text{si } E \text{ est discret} \\ \int_E f_\theta(x) \log \left(\frac{f_\theta(x)}{f_{\theta'}(x)} \right) dx & \text{si } E \text{ est continu} \end{cases}$$

PROPRIÉTÉS DE LA DIVERGENCE KL.

- $KL(\mathbb{P}_\theta, \mathbb{P}_{\theta'}) \neq KL(\mathbb{P}_{\theta'}, \mathbb{P}_\theta)$ **en général** — pas symétrique
- $KL(\mathbb{P}_\theta, \mathbb{P}_{\theta'}) \geq 0$
- Si $KL(\mathbb{P}_\theta, \mathbb{P}_{\theta'}) = 0$ alors $\mathbb{P}_\theta = \mathbb{P}_{\theta'}$ — **définie**
- $KL(\mathbb{P}_\theta, \mathbb{P}_{\theta'}) \not\leq KL(\mathbb{P}_\theta, \mathbb{P}_{\theta''}) + KL(\mathbb{P}_{\theta''}, \mathbb{P}_{\theta'})$ **en général** — pas d'inégalité triangulaire

Ce n'est **pas une distance**. On l'appelle une **divergence**.

L'asymétrie est la clé de notre capacité à l'estimer !

Cette dernière phrase est le pivot du chapitre. On abandonne deux propriétés — symétrie et inégalité triangulaire — pour en gagner une seule : **l'estimabilité**. C'est un arbitrage délibéré, et c'est ce qui fait tout fonctionner. Le concept suivant montre pourquoi.

● Concept 3 — De KL au maximum de vraisemblance

Étape 1 — écrire la KL comme une espérance sous la vraie loi.

$$KL(\mathbb{P}_{\theta^*}, \mathbb{P}_\theta) = \mathbb{E}_{\theta^*} \left[\log \left(\frac{p_{\theta^*}(X)}{p_\theta(X)} \right) \right] = \mathbb{E}_{\theta^*} [\log p_{\theta^*}(X)] - \mathbb{E}_{\theta^*} [\log p_\theta(X)]$$

Voilà pourquoi l'asymétrie sauve tout. En plaçant θ^* **en premier argument**, la pondération de l'intégrale est f_{θ^*} — exactement la loi dont on dispose d'un échantillon. La KL devient une **espérance sous la vraie loi**, donc estimable par moyenne empirique. La variation totale, symétrique, n'offrait pas ce choix.

Étape 2 — isoler la partie qui dépend de θ . La fonction $\theta \mapsto KL(\mathbb{P}_{\theta^*}, \mathbb{P}_{\theta})$ est de la forme

$$\text{« constante »} - \mathbb{E}_{\theta^*}[\log p_{\theta}(X)]$$

Le premier terme ne dépend **pas** de θ : il est inconnu, mais il ne joue aucun rôle dans la minimisation.

Étape 3 — estimer par la loi des grands nombres. Puisque $\mathbb{E}_{\theta^*}[h(X)] \approx \frac{1}{n} \sum_{i=1}^n h(X_i)$:

$$\widehat{KL}(\mathbb{P}_{\theta^*}, \mathbb{P}_{\theta}) = \text{« constante »} - \frac{1}{n} \sum_{i=1}^n \log p_{\theta}(X_i)$$

Étape 4 — la chaîne d'équivalences.

$$\begin{aligned} \min_{\theta \in \Theta} \widehat{KL}(\mathbb{P}_{\theta^*}, \mathbb{P}_{\theta}) &\iff \min_{\theta \in \Theta} -\frac{1}{n} \sum_{i=1}^n \log p_{\theta}(X_i) \iff \max_{\theta \in \Theta} \frac{1}{n} \sum_{i=1}^n \log p_{\theta}(X_i) \\ &\iff \max_{\theta \in \Theta} \sum_{i=1}^n \log p_{\theta}(X_i) \iff \boxed{\max_{\theta \in \Theta} \prod_{i=1}^n p_{\theta}(X_i)} \end{aligned}$$

C'est le principe du maximum de vraisemblance.

Relisez la chaîne : chaque flèche est élémentaire, et pourtant l'aboutissement est spectaculaire. On est parti d'un objectif abstrait — rapprocher deux lois — et l'on obtient une recette parfaitement concrète : **maximiser la probabilité d'observer les données qu'on a observées.**

Et cela répond à une question qu'on se pose rarement : pourquoi le maximum de vraisemblance ? Parce que c'est, exactement, la **minimisation empirique de la divergence de Kullback-Leibler** à la vraie loi. Ce n'est pas une heuristique séduisante, c'est une conséquence.

Le lien avec la fiche 50 : on y avait constaté que l'EMV coïncide avec les MCO sous erreurs gaussiennes. On sait maintenant pourquoi les MCO sont légitimes — ils minimisent la KL au modèle gaussien.

● Concept 4 — Interlude : maximiser une fonction

Notons que $\min_{\theta \in \Theta} -h(\theta) \iff \max_{\theta \in \Theta} h(\theta)$. Dans ce cours, on se concentre sur la maximisation. Or maximiser une fonction arbitraire peut être difficile — l'exemple donné est $\theta \mapsto \prod_{i=1}^n (\theta - X_i)$, dont le graphe oscille.

DÉFINITION.

Une fonction deux fois dérivable $h : \Theta \subset \mathbb{R} \rightarrow \mathbb{R}$ est **concave** si

$$h''(\theta) \leq 0, \quad \forall \theta \in \Theta$$

Elle est **strictement concave** si l'inégalité est stricte : $h''(\theta) < 0$. Et h est (strictement) **convexe** si $-h$ est (strictement) concave, c'est-à-dire $h''(\theta) \geq 0$ (resp. > 0).

Exemples du cours.

Θ	$h(\theta)$	Nature
$\mathbb{R}$	$-\theta^2$	strictement concave
$(0, \infty)$	$\sqrt{\theta}$	strictement concave
$(0, \infty)$	$\log \theta$	strictement concave
$[0, \pi]$	$\sin(\theta)$	concave
$\mathbb{R}$	$2\theta - 3$	concave et convexe (affine)

Le cas multivarié. Pour $h : \Theta \subset \mathbb{R}^d \rightarrow \mathbb{R}$, $d \geq 2$, on définit

$$\text{le gradient : } \nabla h(\theta) = \begin{pmatrix} \frac{\partial h}{\partial \theta_1}(\theta) \\ \vdots \\ \frac{\partial h}{\partial \theta_d}(\theta) \end{pmatrix} \in \mathbb{R}^d, \quad \text{la hessienne : } \nabla^2 h(\theta) = \begin{pmatrix} \frac{\partial^2 h}{\partial \theta_1 \partial \theta_1}(\theta) & \cdots & \frac{\partial^2 h}{\partial \theta_1 \partial \theta_d}(\theta) \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 h}{\partial \theta_d \partial \theta_1}(\theta) & \cdots & \frac{\partial^2 h}{\partial \theta_d \partial \theta_d}(\theta) \end{pmatrix} \in \mathbb{R}^{d \times d}$$

Caractérisation.

$$h \text{ concave} \iff x^\top \nabla^2 h(\theta) x \leq 0 \quad \forall x \in \mathbb{R}^d, \forall \theta \in \Theta$$

$$h \text{ strictement concave} \iff x^\top \nabla^2 h(\theta) x < 0 \quad \forall x \in \mathbb{R}^d, \forall \theta \in \Theta$$

Exemples : $\Theta = \mathbb{R}^2$ avec $h(\theta) = -\theta_1^2 - 2\theta_2^2$ ou $h(\theta) = -(\theta_1 - \theta_2)^2$; $h(\theta) = \log(\theta_1 + \theta_2)$ sur $(0, \infty)$.

POURQUOI LA CONCAVITÉ STRICTE EST CE QU'ON CHERCHE.

Les fonctions strictement concaves sont **faciles à maximiser** : si elles ont un maximum, il est **unique**. C'est l'unique solution de

$$h'(\theta) = 0 \quad \text{ou, dans le cas multivarié,} \quad \nabla h(\theta) = 0 \in \mathbb{R}^d$$

Il existe de nombreux algorithmes pour le trouver numériquement : c'est la théorie de l'**optimisation convexe**. Dans ce cours, on aura souvent une **formule fermée**.

C'est le pont explicite avec les fiches 35 à 41. La condition $x^\top \nabla^2 h(\theta) x \leq 0$ dit que la hessienne est **semi-définie négative** — c'est la condition du second ordre de la fiche 35, au signe près. Et « il existe de nombreux algorithmes » renvoie au gradient et à Newton de la fiche 39. La statistique et l'optimisation convexe sont ici le même sujet.

● Concept 5 — La vraisemblance

Cas discret

DÉFINITION.

La **vraisemblance** du modèle est l'application L_n définie par

$$L_n : E^n \times \Theta \rightarrow \mathbb{R}, \quad (x_1, \dots, x_n, \theta) \mapsto \mathbb{P}_\theta[X_1 = x_1, \dots, X_n = x_n]$$

Exemple 1 — épreuves de Bernoulli. Si $X_1, \dots, X_n \stackrel{iid}{\sim} \text{Ber}(p)$ pour $p \in (0, 1) : E = \{0, 1\}$, $\Theta = (0, 1)$, et pour tout $(x_1, \dots, x_n) \in \{0, 1\}^n$,

$$L(x_1, \dots, x_n, p) = \prod_{i=1}^n \mathbb{P}_p[X_i = x_i] = \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i} = p^{\sum_{i=1}^n x_i} (1-p)^{n-\sum_{i=1}^n x_i}$$

Exemple 2 — modèle de Poisson. Si $X_1, \dots, X_n \stackrel{iid}{\sim} \text{Pois}(\lambda)$ pour $\lambda > 0 : E = \mathbb{N}$, $\Theta = (0, \infty)$, et

$$L(x_1, \dots, x_n, \lambda) = \prod_{i=1}^n \mathbb{P}_\lambda[X_i = x_i] = \prod_{i=1}^n e^{-\lambda} \frac{\lambda^{x_i}}{x_i!} = e^{-n\lambda} \frac{\lambda^{\sum_{i=1}^n x_i}}{x_1! \cdots x_n!}$$

Cas continu

DÉFINITION.

Si toutes les $\mathbb{P}_\theta$ ont une densité f_θ , la vraisemblance est

$$L : E^n \times \Theta \rightarrow \mathbb{R}, \quad (x_1, \dots, x_n, \theta) \mapsto \prod_{i=1}^n f_\theta(x_i)$$

Exemple 1 — modèle gaussien. Si $X_1, \dots, X_n \stackrel{iid}{\sim} N(\mu, \sigma^2) : E = \mathbb{R}$, $\Theta = \mathbb{R} \times (0, \infty)$, et

$$L(x_1, \dots, x_n, \mu, \sigma^2) = \frac{1}{(\sigma\sqrt{2\pi})^n} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right)$$

Notez la forme récurrente : un produit. C'est l'indépendance qui la produit, et c'est elle qui rend le logarithme naturel — il transforme le produit en somme, donc la maximisation en un problème d'analyse ordinaire.

Et l'on reconnaît la fiche 50 : la vraisemblance gaussienne fait apparaître $\sum (x_i - \mu)^2$ — le critère des **moindres carrés**. C'est exactement la connexion établie là-bas.

● Concept 6 — L'estimateur du maximum de vraisemblance

DÉFINITION.

L'**estimateur du maximum de vraisemblance** de θ est

$$\hat{\theta}_n^{MLE} = \operatorname{argmax}_{\theta \in \Theta} L(X_1, \dots, X_n, \theta)$$

sous réserve qu'il existe.

REMARQUE — L'ESTIMATEUR DE LOG-VRAISEMBLANCE.

En pratique, on utilise le fait que

$$\hat{\theta}_n^{MLE} = \operatorname{argmax}_{\theta \in \Theta} \log L(X_1, \dots, X_n, \theta)$$

C'est légitime parce que log est strictement croissante : elle ne déplace pas l'argmax. Et c'est indispensable en pratique, pour deux raisons — le logarithme transforme le **produit en somme**, et il évite le **sous-dépassement numérique** (le produit de n probabilités devient vite trop petit pour être représenté).

Les trois exemples.

Modèle	EMV
Bernoulli	$\hat{p}_n^{MLE} = \bar{X}_n$
Poisson	$\hat{\lambda}_n^{MLE} = \bar{X}_n$
Gaussien	$(\hat{\mu}_n, \hat{\sigma}_n^2) = (\bar{X}_n, \hat{S}_n)$

où $\hat{S}_n = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$ est la variance empirique.

Les trois donnent la moyenne empirique — ce n'est pas un hasard. Pour Bernoulli comme pour Poisson, le paramètre **est** l'espérance ; la vraisemblance ne dépend des données que par $\sum \mathbf{X}_i$, et l'EMV renvoie donc naturellement $\bar{\mathbf{X}}_n$.

Et retenez le diviseur n pour la variance gaussienne : l'EMV de σ^2 est **biaisé**, comme signalé en fiche 50. L'estimateur sans biais divise par $n - 1$.

● Concept 7 — L'information de Fisher

DÉFINITION.

Définissons la **log-vraisemblance pour une observation** :

$$\ell(\theta) = \log L_1(X, \theta), \quad \theta \in \Theta \subset \mathbb{R}^d$$

Supposons ℓ presque sûrement deux fois dérivable. Sous certaines conditions de régularité, l'**information de Fisher** du modèle statistique est

$$I(\theta) = \mathbb{E}[\nabla \ell(\theta) \nabla \ell(\theta)^\top] - \mathbb{E}[\nabla \ell(\theta)] \mathbb{E}[\nabla \ell(\theta)]^\top = -\mathbb{E}[\nabla^2 \ell(\theta)]$$

Si $\Theta \subset \mathbb{R}$, on obtient

$$I(\theta) = \text{var}[\ell'(\theta)] = -\mathbb{E}[\ell''(\theta)]$$

COMMENT LIRE CETTE DÉFINITION — DEUX VISAGES DU MÊME OBJET.

- **Premier visage : une variance.** $I(\theta) = \text{var}[\ell'(\theta)]$ mesure combien la pente de la log-vraisemblance **varie** d'un échantillon à l'autre. Beaucoup de variation $\Rightarrow$ les données discriminent fortement entre les valeurs de θ .
- **Second visage : une courbure.** $I(\theta) = -\mathbb{E}[\ell''(\theta)]$ mesure à quel point la log-vraisemblance est **pointue** au maximum. Un pic étroit $\Rightarrow$ le maximum est bien localisé, donc l'estimation est précise.

Que ces deux quantités coïncident est un théorème — l'identité de l'information — et il repose sur les « conditions de régularité » mentionnées, dont la plus importante est que **le support de $\mathbb{P}_\theta$ ne dépend pas de θ** (hypothèse 2 du concept 8).

L'information de Fisher est déjà apparue en fiche 60, comme variance asymptotique de l'EMV dans les modèles espace-état. C'est le même objet, et le théorème suivant explique pourquoi il revient partout.

• Concept 8 — Le théorème asymptotique

THÉORÈME.

Soit $\theta^* \in \Theta$ le vrai paramètre. Supposons que :

1. le modèle est **identifié** ;
2. pour tout $\theta \in \Theta$, le **support de $\mathbb{P}_\theta$ ne dépend pas de θ** ;
3. θ^* **n'est pas sur la frontière** de Θ ;
4. $I(\theta)$ est **inversible** dans un voisinage de θ^* ;
5. quelques conditions techniques supplémentaires.

Alors $\hat{\theta}_n^{MLE}$ satisfait :

$$\hat{\theta}_n^{MLE} \xrightarrow[n \rightarrow \infty]{\mathbb{P}} \theta^* \quad (\text{par rapport à } \mathbb{P}_{\theta^*})$$

$$\sqrt{n}(\hat{\theta}_n^{MLE} - \theta^*) \xrightarrow[n \rightarrow \infty]{(d)} N(0, I(\theta^*)^{-1}) \quad (\text{par rapport à } \mathbb{P}_{\theta^*})$$

Ce théorème est la raison pour laquelle le maximum de vraisemblance domine la statistique. Il donne, d'un coup :

- la **consistance** — l'estimateur converge vers la vérité ;
- la **vitesse** $1/\sqrt{n}$ — la vitesse standard ;
- la **loi limite exacte**, donc les intervalles de confiance et les tests ;
- et une **variance asymptotique** $I(\theta^*)^{-1}$ qui, par la borne de Cramér-Rao, est la **plus petite possible** parmi les estimateurs réguliers. L'EMV est **asymptotiquement efficace**.

Chaque hypothèse écarte un contre-exemple précis — il faut savoir lequel.

Hypothèse	Ce qu'elle écarte
1. Modèle identifié	Sinon deux θ différents donnent la même loi : rien ne permet de les distinguer, à aucune taille d'échantillon.
2. Support indépendant de θ	C'est l'hypothèse la plus souvent violée. Contre-exemple : le modèle uniforme $U[0, \theta]$, dont l'EMV est $\max_i X_i$; il converge à la vitesse $1/n$, pas $1/\sqrt{n}$, et sa loi limite est exponentielle, pas gaussienne.
3. θ^* à l'intérieur	Sur une frontière, la condition $\nabla \ell = 0$ ne caractérise plus le maximum, et la loi limite devient une gaussienne tronquée .
4. $I(\theta)$ inversible	Sinon la variance asymptotique n'existe pas : certaines directions du paramètre ne sont pas informées par les données.

Le lien avec la fiche 50, maintenant complet. On y avait établi que, dans le modèle normal-linéaire, $\hat{\beta} \sim N_p(\beta, \sigma^2(X^T X)^{-1})$ — **exactement**, à distance finie. Le théorème ci-dessus dit que c'est un cas particulièrement heureux d'un phénomène **général** : tout EMV est asymptotiquement gaussien de variance $I(\theta^*)^{-1}$. Ici, $\sigma^2(X^T X)^{-1}$ **est** l'inverse de l'information de Fisher du modèle linéaire.

Comment résoudre l'exercice type (protocole)

1. **Écrire le modèle** : E, Θ , la famille $(\mathbb{P}_\theta)$, et vérifier l'**identifiabilité**.

2. **Écrire la vraisemblance** : produit des masses (discret) ou des densités (continu).
3. **Passer au logarithme** — le produit devient une somme.
4. **Dériver** : $\ell'(\theta) = 0$, ou $\nabla \ell(\theta) = 0$ en dimension d .
5. **Vérifier la concavité** : $\ell'' < 0$, ou hessienne définie négative $\Rightarrow$ le maximum est **unique**.
6. **Calculer l'information de Fisher** : $I(\theta) = -\mathbb{E}[\ell''(\theta)]$ pour **une** observation.
7. **Conclure** : $\sqrt{n}(\hat{\theta}_n - \theta^*) \rightarrow N(0, I(\theta^*)^{-1})$, d'où intervalles de confiance et tests.
8. **Vérifier les hypothèses du théorème** — surtout que le **support ne dépend pas de θ** .

Comment reconnaître qu'il faut utiliser cette méthode ?

Indice dans l'énoncé	Ce qu'il faut faire
« estimer le paramètre d'un modèle paramétrique »	maximum de vraisemblance
« rapprocher deux lois »	KL, puis EMV
« pourquoi maximiser la vraisemblance ? »	c'est minimiser la KL empirique
« le maximum est-il unique ? »	vérifier la stricte concavité
« quelle précision ? »	information de Fisher , $I(\theta^*)^{-1}/n$
« intervalle de confiance asymptotique »	$\hat{\theta} \pm q_{\alpha/2} \sqrt{I(\hat{\theta})^{-1}/n}$
modèle $U[0, \theta]$ ou support mobile	le théorème ne s'applique pas
θ^* au bord de Θ	hypothèse 3 violée

Exercices progressifs

Niveau 1 — Calculez l'EMV du paramètre d'un modèle de Bernoulli.

La vraisemblance.

$$L(x_1, \dots, x_n, p) = p^{\sum x_i} (1 - p)^{n - \sum x_i}$$

La log-vraisemblance. En posant $S = \sum_{i=1}^n x_i$:

$$\log L = S \log p + (n - S) \log(1 - p)$$

La dérivée.

$$\frac{\partial \log L}{\partial p} = \frac{S}{p} - \frac{n-S}{1-p}$$

L'annulation. $\frac{S}{p} = \frac{n-S}{1-p}$ donne $S(1-p) = p(n-S)$, soit $S - Sp = pn - pS$, donc $S = pn$ et

$$\hat{p}_n^{MLE} = \frac{S}{n} = \bar{X}_n$$

La vérification de concavité.

$$\frac{\partial^2 \log L}{\partial p^2} = -\frac{S}{p^2} - \frac{n-S}{(1-p)^2} < 0$$

strictement négative sur $(0, 1)$: la log-vraisemblance est **strictement concave**, le maximum est donc **unique**.

L'information de Fisher. Pour une observation, $\ell(p) = X \log p + (1-X) \log(1-p)$, donc

$$\ell''(p) = -\frac{X}{p^2} - \frac{1-X}{(1-p)^2}, \quad I(p) = -\mathbb{E}[\ell''(p)] = \frac{p}{p^2} + \frac{1-p}{(1-p)^2} = \frac{1}{p} + \frac{1}{1-p} = \frac{1}{p(1-p)}$$

La conclusion asymptotique.

$$\sqrt{n}(\hat{p}_n - p) \xrightarrow{(d)} N(0, p(1-p))$$

— qu'on aurait aussi obtenue par le théorème central limite direct, puisque $\text{var}(X_i) = p(1-p)$.
Les deux méthodes concordent.

Niveau 2 — Pourquoi ne peut-on pas estimer la distance en variation totale, alors qu'on peut estimer la divergence KL ?

Le problème de la variation totale.

$$TV(\mathbb{P}_{\theta^*}, \mathbb{P}_{\theta}) = \frac{1}{2} \int_E |f_{\theta^*}(x) - f_{\theta}(x)| dx$$

On ne dispose que d'un échantillon tiré selon f_{θ^*} . Or la loi des grands nombres ne permet d'estimer que des quantités de la forme

$$\mathbb{E}_{\theta^*}[h(X)] = \int f_{\theta^*}(x) h(x) dx \approx \frac{1}{n} \sum_i h(X_i)$$

c'est-à-dire des intégrales où f_{θ^*} apparaît **en facteur**. La **valeur absolue** $|f_{\theta^*} - f_{\theta}|$ empêche de mettre f_{θ^*} en facteur : on ne peut pas écrire TV sous la forme $\mathbb{E}_{\theta^*}[h(X)]$.

Pourquoi la KL passe. Le logarithme transforme le quotient en différence, et f_{θ^*} se factorise :

$$KL(\mathbb{P}_{\theta^*}, \mathbb{P}_{\theta}) = \int f_{\theta^*}(x) \log \left(\frac{f_{\theta^*}(x)}{f_{\theta}(x)} \right) dx = \mathbb{E}_{\theta^*} \left[\log \frac{f_{\theta^*}(X)}{f_{\theta}(X)} \right]$$

C'est bien une espérance sous la vraie loi, donc estimable par moyenne empirique.

Et l'asymétrie est ce qui rend ce choix possible. Il fallait que θ^* soit en **premier** argument pour que la pondération soit f_{θ^*} . Une divergence symétrique n'aurait pas offert ce choix — c'est le sens de la phrase du cours : *l'asymétrie est la clé de notre capacité à l'estimer*.

Le prix payé. On perd la symétrie et l'inégalité triangulaire : KL n'est **pas une distance**, seulement une **divergence**. On conserve l'essentiel — positivité et caractère défini — donc le minimum en θ est bien atteint en θ^* , ce qui suffit pour estimer.

Niveau 3 — Interprétez l'information de Fisher sous ses deux formes.

Les deux expressions, pour $\Theta \subset \mathbb{R}$:

$$I(\theta) = \text{var}[\ell'(\theta)] = -\mathbb{E}[\ell''(\theta)]$$

Première lecture — une variance. $\ell'(\theta)$ est le **score** : la pente de la log-vraisemblance au point θ . Sa variance mesure combien cette pente **change d'un échantillon à l'autre**. Une grande variance signifie que chaque observation « pousse » fortement l'estimation dans une direction ou l'autre : les données sont **informatives** sur θ .

Deuxième lecture — une courbure. $-\mathbb{E}[\ell''(\theta)]$ mesure à quel point la log-vraisemblance est **pointue** au maximum. Un pic étroit $\Rightarrow$ un petit déplacement de θ fait chuter la vraisemblance $\Rightarrow$ le maximum est **bien localisé** $\Rightarrow$ estimation précise. Un pic plat $\Rightarrow$ beaucoup de valeurs de θ sont presque aussi vraisemblables $\Rightarrow$ estimation imprécise.

La conséquence quantitative.

$$\text{Var}(\hat{\theta}_n) \approx \frac{I(\theta^*)^{-1}}{n}$$

Plus d'information, moins de variance — la relation est exactement inverse. Et par la borne de Cramér-Rao, c'est la **plus petite variance atteignable** par un estimateur régulier : l'EMV est **asymptotiquement efficace**.

Un exemple qui parle. Pour Bernoulli, $I(p) = \frac{1}{p(1-p)}$. Cette information est **minimale** en $p = 1/2$ ($I = 4$) et **explose** quand $p \rightarrow 0$ ou 1 . Autrement dit : une pièce presque truquée est facile à identifier comme telle — une seule face rare observée est très informative —, alors qu'une pièce proche de l'équilibre demande beaucoup de lancers.

Que les deux expressions coïncident est un théorème, l'identité de l'information, et il exige les conditions de régularité — en particulier que le **support ne dépende pas de θ** . Sur le modèle $\mathcal{U}[0, \theta]$, l'identité tombe, et avec elle tout le théorème asymptotique.

Niveau 4 — type examen — Dérivez le principe du maximum de vraisemblance à partir de la divergence KL, et énoncez le théorème asymptotique avec ses hypothèses.

Le point de départ. Le but est de trouver $\hat{\theta}$ tel que $\mathbb{P}_{\hat{\theta}}$ soit proche de $\mathbb{P}_{\theta^*}$. Il faut une notion de proximité **estimable**.

Pourquoi pas la variation totale. $TV(\mathbb{P}_{\theta}, \mathbb{P}_{\theta'}) = \frac{1}{2} \int |f_{\theta} - f_{\theta'}|$ est une vraie distance — symétrique, définie, triangulaire — mais la **valeur absolue** interdit de l'écrire comme une espérance sous $\mathbb{P}_{\theta^*}$, donc de l'estimer par moyenne empirique. *On ne voit pas comment construire $\widehat{TV}$.*

Le remplacement. La divergence KL

$$KL(\mathbb{P}_{\theta}, \mathbb{P}_{\theta'}) = \int f_{\theta}(x) \log \frac{f_{\theta}(x)}{f_{\theta'}(x)} dx$$

n'est **pas** une distance — ni symétrique, ni triangulaire — mais elle est **positive** et **définie**, ce qui suffit. Et *l'asymétrie est la clé de notre capacité à l'estimer*.

La dérivation, en quatre étapes.

Étape 1. En plaçant θ^* en premier argument :

$$KL(\mathbb{P}_{\theta^*}, \mathbb{P}_{\theta}) = \mathbb{E}_{\theta^*} \left[\log \frac{p_{\theta^*}(X)}{p_{\theta}(X)} \right] = \underbrace{\mathbb{E}_{\theta^*} [\log p_{\theta^*}(X)]}_{\text{« constante »}} - \mathbb{E}_{\theta^*} [\log p_{\theta}(X)]$$

Étape 2. La constante ne dépend pas de θ : elle est inconnue mais **sans effet** sur l'argmin.

Étape 3. Par la loi des grands nombres, $\mathbb{E}_{\theta^*} [h(X)] \approx \frac{1}{n} \sum_i h(X_i)$, donc

$$\widehat{KL}(\mathbb{P}_{\theta^*}, \mathbb{P}_{\theta}) = \text{« constante »} - \frac{1}{n} \sum_{i=1}^n \log p_{\theta}(X_i)$$

Étape 4 — la chaîne.

$$\min_{\theta} \widehat{KL} \iff \max_{\theta} \frac{1}{n} \sum_i \log p_{\theta}(X_i) \iff \max_{\theta} \sum_i \log p_{\theta}(X_i) \iff \max_{\theta} \prod_{i=1}^n p_{\theta}(X_i)$$

C'est le principe du maximum de vraisemblance : maximiser la probabilité d'observer ce qu'on a effectivement observé.

Le théorème asymptotique. Sous les hypothèses :

1. le modèle est **identifié** ;
2. le **support de $\mathbb{P}_{\theta}$ ne dépend pas de θ** ;
3. **θ^* n'est pas sur la frontière de Θ** ;
4. **$I(\theta)$ est inversible** au voisinage de **θ^*** ;
5. quelques conditions techniques ;

on a

$$\hat{\theta}_n^{MLE} \xrightarrow{\mathbb{P}} \theta^* \quad \text{et} \quad \sqrt{n}(\hat{\theta}_n^{MLE} - \theta^*) \xrightarrow{(d)} N(0, I(\theta^*)^{-1})$$

où $I(\theta) = -\mathbb{E}[\nabla^2 \ell(\theta)]$ est l'**information de Fisher**.

Ce qu'il faut savoir commenter.

1. La méthode n'est pas heuristique, elle est dérivée. Le maximum de vraisemblance **est** la minimisation empirique de la KL à la vraie loi. C'est ce qui justifie son omniprésence.

2. Le théorème donne tout d'un coup : consistance, vitesse $1/\sqrt{n}$, loi limite, et donc intervalles de confiance et tests. Et par Cramér-Rao, la variance $I(\theta^*)^{-1}$ est **optimale** : l'EMV est asymptotiquement efficace.

3. L'hypothèse 2 est celle qui tombe le plus souvent. Sur $U[0, \theta]$, l'EMV est **max_i X_i** ; il converge à la vitesse $1/n$ — bien **plus vite** que $1/\sqrt{n}$ — et sa loi limite est **exponentielle**, pas gaussienne. Tout le théorème s'effondre, y compris l'identité $\text{var}[\ell'] = -\mathbb{E}[\ell'']$.

4. Le lien avec les fiches précédentes. La fiche 50 avait établi $\hat{\beta} \sim N_p(\beta, \sigma^2(X^T X)^{-1})$ pour la régression normale : c'est un cas particulier **exact** de ce théorème, où $\sigma^2(X^T X)^{-1}$ est l'inverse de l'information de Fisher. Et la fiche 60 utilisait déjà $\mathcal{I}_T^{-1}$ comme variance asymptotique de l'EMV en espace-état. Le même objet, partout.

● Common mistakes

1. **Croire que la KL est une distance** — elle n'est **ni symétrique ni triangulaire** : c'est une **divergence**.
2. **Inverser les arguments de la KL** — il faut $KL(\mathbb{P}_{\theta^*}, \mathbb{P}_{\theta})$, avec le **vrai** paramètre en premier, sinon l'espérance n'est pas estimable.
3. **Oublier que la constante ne dépend pas de θ** — c'est ce qui permet de l'ignorer dans la minimisation.
4. **Maximiser L au lieu de $\log L$** — mathématiquement équivalent, numériquement désastreux (sous-dépassement).
5. **Oublier de vérifier la concavité** — sans stricte concavité, $\nabla \ell = 0$ ne garantit pas un maximum, ni son unicité.
6. **Confondre $I(\theta)$ pour une observation et pour l'échantillon** — l'information de l'échantillon vaut $nI(\theta)$, d'où le $1/n$ dans la variance.
7. **Appliquer le théorème quand le support dépend de θ** — contre-exemple : $U[0, \theta]$, vitesse $1/n$ et loi exponentielle.
8. **Oublier le biais de l'EMV de la variance gaussienne** — diviseur n , pas $n - 1$.
9. **Croire que $\hat{\theta}$ est gaussien à distance finie** — la normalité est **asymptotique**, sauf cas particuliers comme le modèle linéaire normal.

Ultimate Review

1. **Cadre** : modèle $(E, (\mathbb{P}_{\theta})_{\theta \in \Theta})$, échantillon i.i.d., **vrai paramètre θ^*** ; but : $\mathbb{P}_{\hat{\theta}}$ proche de $\mathbb{P}_{\theta^*}$.
2. **Variation totale** : $TV = \max_A |\mathbb{P}_{\theta}(A) - \mathbb{P}_{\theta'}(A)| = \frac{1}{2} \sum |p_{\theta} - p_{\theta'}|$ (discret) = $\frac{1}{2} \int |f_{\theta} - f_{\theta'}|$ (continu).
3. **C'est une distance** : symétrique, positive, définie, triangulaire. **Mais inestimable** — la valeur absolue empêche l'écriture comme espérance.
4. **Divergence KL** : $\sum p_{\theta} \log(p_{\theta}/p_{\theta'})$ ou $\int f_{\theta} \log(f_{\theta}/f_{\theta'})$.
5. **Ses propriétés** : **non symétrique**, positive, définie, **pas d'inégalité triangulaire**. *L'asymétrie est la clé de notre capacité à l'estimer.*
6. **La décomposition** : $KL(\mathbb{P}_{\theta^*}, \mathbb{P}_{\theta}) = \text{constante} - \mathbb{E}_{\theta^*}[\log p_{\theta}(X)]$.
7. **L'estimation** : $\widehat{KL} = \text{constante} - \frac{1}{n} \sum_i \log p_{\theta}(X_i)$ par la LGN.
8. **La chaîne** : $\min \widehat{KL} \iff \max \frac{1}{n} \sum \log p_{\theta}(X_i) \iff \max \sum \log p_{\theta}(X_i) \iff \max \prod p_{\theta}(X_i)$.
9. **Concavité** : $h'' \leq 0$; strictement si < 0 ; multivarié : $x^{\top} \nabla^2 h(\theta) x \leq 0 \forall x$.
10. **Pourquoi elle importe** : une fonction strictement concave a **au plus un** maximum, solution unique de $\nabla h(\theta) = 0$.

11. **Vraisemblance discrète** : $L_n = \mathbb{P}_\theta[X_1 = x_1, \dots, X_n = x_n]$; **Bernoulli** $p^{\sum x_i} (1-p)^{n-\sum x_i}$; **Poisson** $e^{-n\lambda} \lambda^{\sum x_i} / \prod x_i!$.
12. **Vraisemblance continue** : $L = \prod_i f_\theta(x_i)$; **gaussienne** $\frac{1}{(\sigma\sqrt{2\pi})^n} \exp\left(-\frac{1}{2\sigma^2} \sum (x_i - \mu)^2\right)$.
13. **EMV** : $\hat{\theta}_n^{MLE} = \operatorname{argmax}_\theta L = \operatorname{argmax}_\theta \log L$.
14. **Exemples** : Bernoulli $\hat{p} = \bar{X}_n$ · Poisson $\hat{\lambda} = \bar{X}_n$ · gaussien $(\bar{X}_n, \hat{S}_n)$, la variance étant **biaisée**.
15. **Information de Fisher** : $\ell(\theta) = \log L_1(X, \theta)$;

$$I(\theta) = \mathbb{E}[\nabla \ell \nabla \ell^\top] - \mathbb{E}[\nabla \ell] \mathbb{E}[\nabla \ell]^\top = -\mathbb{E}[\nabla^2 \ell(\theta)]$$

en dimension 1 : $I(\theta) = \operatorname{var}[\ell'(\theta)] = -\mathbb{E}[\ell''(\theta)]$.

16. **Ses deux lectures** : **variance du score** (les données discriminent-elles ?) et **courbure** de la log-vraisemblance (le maximum est-il pointu ?).
17. **Théorème** — hypothèses : modèle **identifié** · **support indépendant de θ** · θ^* à l'intérieur · $I(\theta)$ **inversible** · conditions techniques.
18. **Conclusions** : $\hat{\theta}_n \xrightarrow{\mathbb{P}} \theta^*$ et $\sqrt{n}(\hat{\theta}_n - \theta^*) \xrightarrow{(d)} N(0, I(\theta^*)^{-1})$; l'EMV est **asymptotiquement efficace**.

Formulas to know

$$TV = \frac{1}{2} \int |f_\theta - f_{\theta'}| \quad KL(\mathbb{P}_\theta, \mathbb{P}_{\theta'}) = \int f_\theta \log \frac{f_\theta}{f_{\theta'}}$$

$$KL(\mathbb{P}_{\theta^*}, \mathbb{P}_\theta) = \text{cste} - \mathbb{E}_{\theta^*}[\log p_\theta(X)] \quad \hat{\theta}_n^{MLE} = \operatorname{argmax}_\theta \prod_{i=1}^n p_\theta(X_i)$$

$$I(\theta) = -\mathbb{E}[\nabla^2 \ell(\theta)] \quad \sqrt{n}(\hat{\theta}_n - \theta^*) \xrightarrow{(d)} N(0, I(\theta^*)^{-1})$$

Methods to know : la dérivation KL $\Rightarrow$ maximum de vraisemblance en quatre étapes ; le protocole de calcul d'un EMV ; le calcul de $I(\theta)$; la vérification des hypothèses du théorème.

Active Recall

Basic — Définissez la divergence de Kullback-Leibler et donnez ses propriétés.

$$KL(\mathbb{P}_\theta, \mathbb{P}_{\theta'}) = \sum_{x \in E} p_\theta(x) \log \frac{p_\theta(x)}{p_{\theta'}(x)} \quad (\text{discret}), \quad \int_E f_\theta(x) \log \frac{f_\theta(x)}{f_{\theta'}(x)} dx \quad (\text{continu})$$

Propriétés :

- **non symétrique** en général ;
- $KL \geq 0$;
- **définie** : $KL = 0 \Rightarrow \mathbb{P}_\theta = \mathbb{P}_{\theta^*}$;
- **pas d'inégalité triangulaire** en général.

Ce n'est donc **pas une distance** mais une **divergence**. Et *l'asymétrie est la clé de notre capacité à l'estimer* : en plaçant θ^* en premier argument, la KL devient une espérance sous la vraie loi.

Understanding — Pourquoi maximise-t-on la vraisemblance ?

Parce que **c'est exactement minimiser la divergence KL empirique** à la vraie loi.

La chaîne complète :

$$KL(\mathbb{P}_{\theta^*}, \mathbb{P}_\theta) = \underbrace{\mathbb{E}_{\theta^*}[\log p_{\theta^*}(X)]}_{\text{indépendant de } \theta} - \mathbb{E}_{\theta^*}[\log p_\theta(X)]$$

Par la loi des grands nombres, le second terme s'estime par $\frac{1}{n} \sum_i \log p_\theta(X_i)$, d'où

$$\min_{\theta} \widehat{KL} \iff \max_{\theta} \sum_{i=1}^n \log p_\theta(X_i) \iff \max_{\theta} \prod_{i=1}^n p_\theta(X_i)$$

Le maximum de vraisemblance n'est donc pas un principe posé a priori — c'est une **conséquence** du choix d'une divergence estimable. Et le choix de la KL plutôt que de la variation totale est dicté par le seul critère d'estimabilité.

Application — Calculez l'information de Fisher du modèle de Poisson.

La log-vraisemblance pour une observation. $X \sim \text{Poiss}(\lambda)$ a pour masse $e^{-\lambda} \lambda^X / X!$, donc

$$\ell(\lambda) = -\lambda + X \log \lambda - \log(X!)$$

Les dérivées.

$$\ell'(\lambda) = -1 + \frac{X}{\lambda}, \quad \ell''(\lambda) = -\frac{X}{\lambda^2}$$

L'information de Fisher. Comme $\mathbb{E}[X] = \lambda$:

$$I(\lambda) = -\mathbb{E}[\ell''(\lambda)] = \frac{\mathbb{E}[X]}{\lambda^2} = \frac{\lambda}{\lambda^2} = \frac{1}{\lambda}$$

Vérification par l'autre formule. $\text{var}[\ell'(\lambda)] = \text{var}\left[\frac{X}{\lambda}\right] = \frac{\text{var}(X)}{\lambda^2} = \frac{\lambda}{\lambda^2} = \frac{1}{\lambda}$ — les deux expressions coïncident, comme le prédit l'identité de l'information.

La conclusion asymptotique. Avec $\hat{\lambda}_n = \bar{X}_n$:

$$\sqrt{n}(\hat{\lambda}_n - \lambda) \xrightarrow{(d)} N(0, I(\lambda)^{-1}) = N(0, \lambda)$$

ce qui est cohérent avec le TCL direct, puisque $\text{var}(X_i) = \lambda$.

La lecture. $I(\lambda) = 1/\lambda$ **décroît** avec λ : plus l'intensité est grande, moins chaque observation est informative **relativement**. La variance de l'estimateur, λ/n , croît donc avec λ — mais l'erreur **relative** $\sqrt{\lambda/n}/\lambda = 1/\sqrt{n\lambda}$ diminue.

Comparison — Variation totale et divergence KL : que gagne-t-on, que perd-on ?

	Variation totale	Divergence KL
Symétrique	oui	non
Positive	oui	oui
Définie	oui	oui
Inégalité triangulaire	oui	non
Est-ce une distance ?	oui	non — une divergence
Estimable ?	non	oui

Ce qu'on perd : la symétrie et l'inégalité triangulaire — donc le statut de distance.

Ce qu'on gagne : l'**estimabilité**, et c'est tout ce qui compte. La KL s'écrit comme une **espérance sous la vraie loi** :

$$KL(\mathbb{P}_{\theta^*}, \mathbb{P}_{\theta}) = \mathbb{E}_{\theta^*} \left[\log \frac{p_{\theta^*}(X)}{p_{\theta}(X)} \right]$$

donc la loi des grands nombres s'applique. La valeur absolue de TV interdit cette écriture.

Ce qui suffit pour estimer : la positivité et le caractère défini. Ces deux propriétés garantissent que $\theta \mapsto KL(\mathbb{P}_{\theta^*}, \mathbb{P}_{\theta})$ atteint son minimum — nul — **exactement en θ^*** . Ni la symétrie ni la triangulaire ne servent à cela.

La leçon de méthode : on choisit ses outils en fonction de ce qu'on peut **calculer**, pas de leur élégance formelle.

Exam-style — Énoncez le théorème asymptotique de l'EMV et expliquez le rôle de chaque hypothèse.

Énoncé. Sous les cinq hypothèses, l'EMV vérifie

$$\hat{\theta}_n^{MLE} \xrightarrow[n \rightarrow \infty]{\mathbb{P}} \theta^* \quad \text{et} \quad \sqrt{n}(\hat{\theta}_n^{MLE} - \theta^*) \xrightarrow[n \rightarrow \infty]{(d)} N(0, I(\theta^*)^{-1})$$

où $I(\theta) = -\mathbb{E}[\nabla^2 \ell(\theta)]$ est l'information de Fisher pour **une** observation.

Les hypothèses et leur rôle.

1. Le modèle est identifié. Sinon, deux valeurs distinctes de θ engendrent la même loi : aucune quantité de données ne permettra de les distinguer, et $\hat{\theta}$ ne peut converger vers un point unique.

2. Le support de $\mathbb{P}_{\theta}$ ne dépend pas de θ . C'est l'hypothèse la plus souvent violée, et la plus destructrice. Elle est nécessaire pour dériver sous l'intégrale — donc pour l'identité de l'information $\text{var}[\ell'] = -\mathbb{E}[\ell'']$, sur laquelle tout repose. *Contre-exemple* : $X_i \sim U[0, \theta]$. L'EMV est $\hat{\theta}_n = \max_i X_i$. Il converge à la vitesse $1/n$, **plus vite** que $1/\sqrt{n}$, et $n(\theta - \hat{\theta}_n)$ tend vers une loi **exponentielle**, pas gaussienne. Le théorème est entièrement faux.

3. θ^* n'est pas sur la frontière de Θ . Le raisonnement repose sur $\nabla \ell(\hat{\theta}) = 0$ — la condition du premier ordre d'un maximum **intérieur**. Sur une frontière, le maximum peut être atteint sans annulation du gradient, et la loi limite devient une gaussienne **tronquée**.

4. $I(\theta)$ est inversible au voisinage de θ^* . Sinon $I(\theta^*)^{-1}$ n'existe pas : certaines directions du paramètre ne sont **pas informées** par les données, et la variance asymptotique diverge dans ces directions.

5. Conditions techniques. Régularité suffisante pour justifier les développements de Taylor et les interversions limite-intégrale.

Ce qu'il faut savoir ajouter.

La portée du théorème. Il donne d'un coup la consistance, la vitesse $1/\sqrt{n}$, la loi limite complète — donc les intervalles de confiance $\hat{\theta}_n \pm q_{\alpha/2} \sqrt{I(\hat{\theta}_n)^{-1}/n}$ et les tests. Et par la borne de **Cramér-Rao**, $I(\theta^*)^{-1}$ est la **plus petite variance asymptotique** possible : l'EMV est **asymptotiquement efficace**. C'est pourquoi il est la méthode par défaut de toute la statistique paramétrique.

Sa limite essentielle. Tout est **asymptotique**. À n fini, l'EMV peut être biaisé — la variance gaussienne en est l'exemple canonique, avec son diviseur n au lieu de $n - 1$ — et sa loi peut être très éloignée d'une gaussienne. Le modèle linéaire normal de la fiche 50 est l'heureuse exception où la normalité est **exacte** à distance finie.

Flashcards

Question	Réponse
But du statisticien ?	Trouver $\hat{\theta}$ tel que $\mathbb{P}_{\hat{\theta}}$ soit proche de $\mathbb{P}_{\theta^*}$
Définition de la variation totale ?	$\max_{A \subset E} \mathbb{P}_{\theta}(A) - \mathbb{P}_{\theta'}(A) $
Sa forme discrète ?	$\frac{1}{2} \sum_x p_{\theta}(x) - p_{\theta'}(x) $
Sa forme continue ?	$\frac{1}{2} \int_E f_{\theta} - f_{\theta'} dx$
Est-ce une distance ?	Oui — mais elle n'est pas estimable
Pourquoi n'est-elle pas estimable ?	La valeur absolue empêche de l'écrire comme une espérance
Définition de la KL ?	$\int f_{\theta} \log(f_{\theta}/f_{\theta'})$
Est-ce une distance ?	Non — ni symétrique, ni triangulaire : une divergence
Quelle propriété la sauve ?	L' asymétrie , qui la rend estimable
Décomposition de $KL(\mathbb{P}_{\theta^*}, \mathbb{P}_{\theta})$?	« constante » — $\mathbb{E}_{\theta^*}[\log p_{\theta}(X)]$
Comment l'estime-t-on ?	Par la loi des grands nombres
La chaîne d'équivalences ?	$\min \widehat{KL} \iff \max \sum \log p_{\theta}(X_i) \iff \max \prod p_{\theta}(X_i)$
Définition de la concavité ?	$h''(\theta) \leq 0$ pour tout θ
Cas multivarié ?	$x^{\top} \nabla^2 h(\theta) x \leq 0$ pour tout x
Pourquoi la stricte concavité ?	Le maximum, s'il existe, est unique
Vraisemblance discrète ?	$\mathbb{P}_{\theta}[X_1 = x_1, \dots, X_n = x_n]$
Vraisemblance de Bernoulli ?	$p^{\sum x_i} (1-p)^{n-\sum x_i}$
Vraisemblance de Poisson ?	$e^{-n\lambda} \lambda^{\sum x_i} / (x_1! \dots x_n!)$
Vraisemblance continue ?	$\prod_{i=1}^n f_{\theta}(x_i)$
Vraisemblance gaussienne ?	$\frac{1}{(\sigma\sqrt{2\pi})^n} \exp\left(-\frac{1}{2\sigma^2} \sum (x_i - \mu)^2\right)$
Définition de l'EMV ?	$\operatorname{argmax}_{\theta} L(X_1, \dots, X_n, \theta)$

Question	Réponse
Pourquoi passer au log ?	log croissante $\Rightarrow$ même argmax ; produit $\rightarrow$ somme
EMV de Bernoulli et Poisson ?	$\bar{X}_n$ dans les deux cas
EMV du modèle gaussien ?	$(\bar{X}_n, \hat{S}_n)$ — la variance est biaisée
Log-vraisemblance pour une observation ?	$\ell(\theta) = \log L_1(X, \theta)$
Information de Fisher ?	$-\mathbb{E}[\nabla^2 \ell(\theta)]$
Sa forme unidimensionnelle ?	$\text{var}[\ell'(\theta)] = -\mathbb{E}[\ell''(\theta)]$
Ses deux interprétations ?	Variance du score · courbure de la log-vraisemblance
Les cinq hypothèses du théorème ?	Identifié · support fixe · intérieur · I inversible · technique
Les deux conclusions ?	Consistance et $\sqrt{n}(\hat{\theta}_n - \theta^*) \rightarrow N(0, I(\theta^*)^{-1})$
Quelle hypothèse tombe pour $U[0, \theta]$?	Le support dépend de θ
Que devient la vitesse dans ce cas ?	$1/n$, et la loi limite est exponentielle
Que dit Cramér-Rao ?	$I(\theta^*)^{-1}$ est la variance minimale — EMV efficace