

Fiche 65 — Tests d'hypothèses paramétriques : niveau, puissance, Wald et rapport de vraisemblance

Matière	Maths · Économétrie
Cours source	Rigollet, <i>18.650 Statistics for Applications</i> , MIT OpenCourseWare, automne 2016 — chapitre 5 « Parametric hypothesis testing »
Difficulté	Must know — tout test d'économétrie sort de ce chapitre
Temps d'étude estimé	2 h 30
Prérequis	Fiche 64 (maximum de vraisemblance, information de Fisher), fiche 50 (test de Student en régression), théorème central limite
Concepts clés	Hypothèse nulle et alternative, région de rejet, erreurs de première et seconde espèce, puissance, niveau asymptotique, statistique de test, p-valeur, paradigme de Neyman-Pearson, lois du khi-deux et de Student, théorème de Cochran, test de Wald, test du rapport de vraisemblance, méthode delta
Poids à l'examen	Trois choses : la définition exacte du niveau, de la puissance et de la p-valeur ; la statistique de Wald $n(\hat{\theta} - \theta_0)^T I(\hat{\theta})(\hat{\theta} - \theta_0) \rightarrow \chi_d^2$; et le rapport de vraisemblance $2[\ell_n(\hat{\theta}) - \ell_n(\hat{\theta}^c)] \rightarrow \chi_{d-r}^2$.

Vue d'ensemble

QUESTION les données contredisent-elles H_0 ?
TEST $\psi \in \{0,1\}$: $\psi = 1 \Rightarrow$ on REJETTE H_0
NIVEAU α = risque de rejeter H_0 à tort ← on le CONTRÔLE
PUISSANCE $1 - \beta$ = chance de rejeter H_0 à raison ← on la MAXIMISE
p-VALEUR le plus petit α auquel on rejette
DEUX TESTS UNIVERSELS
Wald $n(\hat{\theta} - \theta_0)^T I(\hat{\theta})(\hat{\theta} - \theta_0) \rightarrow \chi_d^2$
rapport de vrais. $2[\ell_n(\hat{\theta}) - \ell_n(\hat{\theta}^c)] \rightarrow \chi_{d-r}^2$

Les deux situations types

La course Cherry Blossom. Le Cherry Blossom Run est une course de 10 miles à Washington. En 2009, il y avait 14 974 participants et le temps moyen était de 103,5 minutes. **Les coureurs étaient-ils plus rapides en 2012 ?** On sélectionne n coureurs de 2012 au hasard et l'on note $X_1, \dots, X_n$ leurs temps. Les données passées montrent que le temps suit une loi gaussienne, de variance 373.

Il y a **beaucoup de façons** dont l'hypothèse $X_1 \sim N(103,5; 373)$ peut être fautive : $\mathbb{E}[X_1] \neq 103,5$, ou $\text{var}[X_1] \neq 373$, ou X_1 pas même gaussienne. On s'intéresse à une question très spécifique : a-t-on $\mathbb{E}[X_1] < 103,5$?

En faisant des hypothèses de modélisation — variance inchangée, loi gaussienne —, on **réduit le nombre de façons** dont l'hypothèse peut être rejetée. La seule qui reste est $X_1 \sim N(\mu; 373)$ avec $\mu < 103,5$. On **compare une espérance à un nombre de référence**.

Les essais cliniques. On administre un sirop antitussif au groupe test et un placebo au groupe témoin ; μ_{drug} et μ_{control} sont les nombres espérés d'expectorations par heure. On veut savoir si $\mu_{\text{drug}} < \mu_{\text{control}}$. Avec $X_1, \dots, X_{n_{\text{drug}}} \sim \text{Poiss}(\mu_{\text{drug}})$ et $Y_1, \dots, Y_{n_{\text{control}}} \sim \text{Poiss}(\mu_{\text{control}})$, on **compare deux espérances**, sans nombre de référence.

L'heuristique et sa correction

Heuristique naïve : « si $\bar{X}_n < 103,5$, alors $\mu < 103,5$ ». Cela pourrait mal tourner si je tombe par hasard sur des coureurs rapides dans mon échantillon.

Meilleure heuristique :

« si $\bar{X}_n < 103,5 - (\text{quelque chose qui} \xrightarrow{n \rightarrow \infty} 0)$, alors $\mu < 103,5$ »

Pour rendre cette intuition précise, il faut tenir compte de la **taille des fluctuations aléatoires** de $\bar{X}_n$!

« **Quelque chose qui tend vers zéro** » est la clé de tout le chapitre. Ce quelque chose est de l'ordre de $\sigma/\sqrt{n}$, et c'est le théorème central limite qui en donne la taille exacte. Toute la théorie des tests consiste à **calibrer** ce terme correcteur.

Les deux exemples numériques

Exemple 1. Une pièce est lancée 80 fois et Face sort 54 fois. Peut-on conclure que la pièce est significativement biaisée ? Avec $n = 80$, $X_i \stackrel{iid}{\sim} \text{Ber}(p)$, $\bar{X}_n = 54/80 = 0,68$. Si $p = 0,5$ était vrai, alors par le **TCL et le théorème de Slutsky** :

$$\sqrt{n} \frac{\bar{X}_n - 0,5}{\sqrt{0,5(1 - 0,5)}} \approx N(0, 1) \quad \text{et ici} \quad \sqrt{80} \frac{0,68 - 0,5}{0,5} \approx 3,22$$

Conclusion : il paraît tout à fait raisonnable de **rejeter** l'hypothèse $p = 0,5$.

Exemple 2. Une pièce est lancée 30 fois et Face sort 13 fois. Avec $\bar{X}_n = 13/30 \approx 0,43$:

$$\sqrt{30} \frac{0,43 - 0,5}{0,5} \approx -0,77$$

Le nombre 0,77 est une réalisation plausible d'une variable $Z \sim N(0, 1)$. Conclusion : nos données **ne suggèrent pas** que la pièce soit biaisée.

● Concept 1 — La formulation statistique

Soit un échantillon i.i.d. $X_1, \dots, X_n$ et un modèle statistique $(E, (\mathbb{P}_\theta)_{\theta \in \Theta})$. Soient Θ_0 et Θ_1 des sous-ensembles **disjoints** de Θ . On considère les deux hypothèses

$$\begin{cases} H_0 : \theta \in \Theta_0 \\ H_1 : \theta \in \Theta_1 \end{cases}$$

H_0 est l'**hypothèse nulle**, H_1 l'**hypothèse alternative**. On veut décider s'il faut **rejeter** H_0 — chercher dans les données des éléments **contre** H_0 .

L'asymétrie fondamentale.

- H_0 et H_1 **ne jouent pas un rôle symétrique** : les données ne servent qu'à tenter de **réfuter** H_0 .
- En particulier, une **absence de preuve** ne signifie pas que H_0 est **vraie** — « innocent jusqu'à preuve du contraire ».

DÉFINITION — UN TEST.

Un test est une statistique $\psi \in \{0, 1\}$ telle que :

- si $\psi = 0$, H_0 n'est pas rejetée ;
- si $\psi = 1$, H_0 est rejetée.

L'asymétrie est l'erreur d'interprétation la plus répandue en économétrie appliquée. « Le coefficient n'est pas significatif » ne veut **pas** dire « le coefficient est nul » : cela veut dire qu'on n'a pas assez d'éléments pour l'exclure. Sur un échantillon petit ou bruité, on ne rejette presque jamais — ce n'est pas une preuve de nullité, c'est un manque de **puissance**.

● Concept 2 — Erreurs, puissance et niveau

Région de rejet d'un test ψ :

$$R_\psi = \{x \in E^n : \psi(x) = 1\}$$

ERREUR DE PREMIÈRE ESPÈCE

(rejeter H_0 alors qu'elle est **vraie**) :

$$\alpha_\psi : \Theta_0 \rightarrow \mathbb{R}, \quad \theta \mapsto \mathbb{P}_\theta[\psi = 1]$$

ERREUR DE SECONDE ESPÈCE

(ne pas rejeter H_0 alors que H_1 est **vraie**) :

$$\beta_\psi : \Theta_1 \rightarrow \mathbb{R}, \quad \theta \mapsto \mathbb{P}_\theta[\psi = 0]$$

Puissance d'un test ψ :

$$\pi_\psi = \inf_{\theta \in \Theta_1} (1 - \beta_\psi(\theta))$$

Niveau. Un test ψ est de **niveau α** si

$$\alpha_\psi(\theta) \leq \alpha, \quad \forall \theta \in \Theta_0$$

Il est de **niveau asymptotique α** si

$$\lim_{n \rightarrow \infty} \alpha_\psi(\theta) \leq \alpha, \quad \forall \theta \in \Theta_0$$

La forme générale. En général, un test a la forme

$$\psi = \mathbf{1}\{T_n > c\}$$

pour une statistique T_n et un seuil $c \in \mathbb{R}$. T_n est la **statistique de test**, et la région de rejet est $R_\psi = \{T_n > c\}$.

REMARQUEZ LES DEUX DÉFINITIONS ASYMÉTRIQUES.

- Le **niveau** est un **sup** implicite : la contrainte porte sur **tout** $\theta \in \Theta_0$. On veut que le risque de fausse alerte soit contrôlé quelle que soit la façon dont H_0 est vraie.
- La **puissance** est un **inf** explicite sur Θ_1 : on mesure le test par son **pire cas** sous l'alternative — la performance dans la configuration la plus difficile à détecter.

Le compromis. Abaisser α — être plus prudent — réduit mécaniquement la puissance. Le test trivial $\psi \equiv 0$, qui ne rejette jamais, a un niveau **parfait** ($\alpha = 0$) et une puissance **nulle**. C'est ce que le concept 5 formalise.

● Concept 3 — L'exemple de la pièce, formalisé

Soient $X_1, \dots, X_n \stackrel{iid}{\sim} \text{Ber}(p)$ avec $p \in (0, 1)$ inconnu. On veut tester

$$H_0 : p = 1/2 \quad \text{contre} \quad H_1 : p \neq 1/2$$

au niveau asymptotique $\alpha \in (0, 1)$.

La statistique de test. Avec $\hat{p}_n$ l'EMV (fiche 64) :

$$T_n = \sqrt{n} \frac{\hat{p}_n - 0,5}{\sqrt{0,5(1 - 0,5)}}$$

Sous H_0 , par le **TCL et le théorème de Slutsky** :

$$\mathbb{P}[|T_n| > q_{\alpha/2}] \xrightarrow{n \rightarrow \infty} \alpha$$

d'où le test

$$\psi_\alpha = \mathbf{1}\{|T_n| > q_{\alpha/2}\}$$

L'application aux deux exemples. Pour $\alpha = 5 \%$, $q_{\alpha/2} = 1,96$, donc :

- **Exemple 1** ($T_n \approx 3,22$) : H_0 est **rejetée** au niveau asymptotique 5 %.
- **Exemple 2** ($T_n \approx -0,77$) : H_0 n'est **pas rejetée** au niveau asymptotique 5 %.

Question du cours. Dans l'exemple 1, pour quel niveau α le test ψ_α ne rejetterait-il **pas** H_0 ? Et dans l'exemple 2, à quel niveau α rejetterait-il H_0 ? — c'est exactement ce que la p-valeur répond.

Le rôle de Slutsky mérite d'être noté. Le TCL seul donne la loi de $\sqrt{n}(\hat{p}_n - p)/\sigma$ avec le **vrai** σ . Le théorème de Slutsky autorise à le remplacer par un estimateur convergent sans changer la loi limite. Ici, sous H_0 , $\sigma = \sqrt{0,5 \times 0,5}$ est **connu** — mais dans le cas général, c'est Slutsky qui légitime la substitution.

● Concept 4 — La p-valeur

DÉFINITION.

La **p-valeur** (asymptotique) d'un test ψ_α est le **plus petit niveau** (asymptotique) α auquel ψ_α rejette H_0 . Elle est *aléatoire* : elle dépend de l'échantillon.

La règle d'or.

$$\text{p-valeur} \leq \alpha \iff H_0 \text{ est rejetée par } \psi_\alpha \text{ au niveau } \alpha$$

Plus la p-valeur est petite, plus on peut rejeter H_0 avec confiance.

Les deux exemples.

- **Exemple 1** : $\text{p-valeur} = \mathbb{P}[|Z| > 3,22] \ll 0,01$.
- **Exemple 2** : $\text{p-valeur} = \mathbb{P}[|Z| > 0,77] \approx 0,44$.

POURQUOI LA P-VALEUR EST PLUS INFORMATIVE QUE LA DÉCISION BINAIRE.

Le test ψ_α ne rend qu'un verdict à un seuil fixé arbitrairement. La p-valeur rend **le seuil critique lui-même** : elle permet à chaque lecteur d'appliquer son propre α . Dans l'exemple 2, une p-valeur de **0,44** dit qu'il faudrait accepter un risque de fausse alerte de **44 %** pour rejeter — autant dire jamais.

Ce que la p-valeur n'est PAS. Elle n'est **pas** la probabilité que H_0 soit vraie. C'est la probabilité, **sous H_0** , d'observer une statistique au moins aussi extrême que celle observée. Confondre $\mathbb{P}[\text{données} \mid H_0]$ et $\mathbb{P}[H_0 \mid \text{données}]$ est l'erreur classique — et il faut un cadre bayésien pour accéder à la seconde.

• Concept 5 — Le paradigme de Neyman-Pearson

L'idée. Pour des hypothèses données, parmi tous les tests de niveau (asymptotique) α , est-il possible d'en trouver un de **puissance maximale** ?

L'exemple qui pose le problème. Le test trivial $\psi = 0$, qui ne rejette jamais H_0 , a un niveau **parfait** ($\alpha = 0$) mais une **puissance médiocre** ($\pi_\psi = 0$).

La théorie de Neyman-Pearson fournit les tests **les plus puissants** à niveau donné.

La logique du paradigme, en une phrase. On ne peut pas minimiser les deux erreurs à la fois : elles varient en sens inverse. On **fixe donc** la première espèce à un seuil tolérable α — c'est la contrainte —, puis on **maximise la puissance** sous cette contrainte. C'est un problème d'optimisation sous contrainte, au sens exact des fiches 7 et 38.

Et le choix de α n'est pas statistique, il est décisionnel : quelle est la conséquence d'un faux positif ? En essai clinique, mettre sur le marché un médicament inefficace est grave — on prend α petit. En exploration de données, manquer une piste coûte plus cher qu'une fausse alerte — on l'assouplit.

● Concept 6 — Les lois du khi-deux et de Student

DÉFINITION — LOI χ^2 .

Pour un entier positif d , la loi du **khi-deux à d degrés de liberté** est la loi de la variable

$$Z_1^2 + Z_2^2 + \cdots + Z_d^2, \quad Z_1, \dots, Z_d \stackrel{iid}{\sim} N(0, 1)$$

Exemples et propriétés.

- Si $Z \sim N_d(0, I_d)$, alors $\|Z\|_2^2 \sim \chi_d^2$.
- La **variance empirique** est

$$S_n = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - (\bar{X}_n)^2$$

- Le **théorème de Cochran** implique que, pour $X_1, \dots, X_n \stackrel{iid}{\sim} N(\mu, \sigma^2)$:

$$\boxed{\frac{nS_n}{\sigma^2} \sim \chi_{n-1}^2}$$

- $\chi_2^2 = \text{Exp}(1/2)$.

DÉFINITION — LOI DE STUDENT.

Pour un entier positif d , la loi de **Student à d degrés de liberté**, notée t_d , est la loi de

$$\frac{Z}{\sqrt{V/d}}, \quad Z \sim N(0, 1), \quad V \sim \chi_d^2, \quad Z \perp\!\!\!\perp V$$

Exemple. Si S_n est la variance empirique :

$$\sqrt{n-1} \frac{\bar{X}_n - \mu}{\sqrt{S_n}} \sim t_{n-1}$$

POURQUOI $n-1$ ET PAS n ?

Parce que $\bar{X}_n$ a été **estimée à partir des mêmes données**. Les n écarts $X_i - \bar{X}_n$ sont liés par une contrainte — leur somme est nulle —, donc ils ne fournissent que $n-1$ directions libres. C'est le contenu précis du théorème de Cochran, et c'est la même comptabilité de degrés de liberté qu'en fiche 50 ($n-p$ pour p paramètres estimés).

L'indépendance $Z \perp V$ dans la définition de Student est essentielle : c'est elle qui permet de former le quotient. Cochran la fournit — $\bar{X}_n$ et S_n sont **indépendants** dans le modèle gaussien, ce qui est un fait remarquable et propre à la gaussienne.

● Concept 7 — Le test de Wald

Le cadre. Échantillon i.i.d. de modèle $(E, (\mathbb{P}_\theta)_{\theta \in \Theta})$ avec $\Theta \subseteq \mathbb{R}^d$, et $\theta_0 \in \Theta$ fixé. On teste

$$\begin{cases} H_0 : \theta = \theta_0 \\ H_1 : \theta \neq \theta_0 \end{cases}$$

Le point de départ. Soit $\hat{\theta}_n^{MLE}$ l'EMV, les conditions techniques de la fiche 64 étant satisfaites. Si H_0 est vraie, alors

$$\sqrt{n} I(\hat{\theta}_n^{MLE})^{1/2} (\hat{\theta}_n^{MLE} - \theta_0) \xrightarrow[n \rightarrow \infty]{(d)} N_d(0, I_d) \quad \text{par rapport à } \mathbb{P}_{\theta_0}$$

D'où la statistique. En prenant la norme au carré :

$$T_n = n(\hat{\theta}_n^{MLE} - \theta_0)^\top I(\hat{\theta}_n^{MLE}) (\hat{\theta}_n^{MLE} - \theta_0) \xrightarrow[n \rightarrow \infty]{(d)} \chi_d^2$$

Test de Wald de niveau asymptotique $\alpha \in (0, 1)$:

$$\psi = \mathbf{1}\{T_n > q_\alpha\}$$

où q_α est le quantile d'ordre $(1 - \alpha)$ de χ_d^2 .

REMARQUE.

Le test de Wald est **aussi valide** si H_1 est de la forme « $\theta > \theta_0$ », « $\theta < \theta_0$ » ou « $\theta = \theta_1$ »...

La construction est limpide. Le théorème asymptotique de la fiche 64 dit que $\sqrt{n}(\hat{\theta}_n - \theta^*) \rightarrow N_d(0, I(\theta^*)^{-1})$. En **normalisant** par $I^{1/2}$, on obtient une gaussienne standard $N_d(0, I_d)$; en prenant la **norme au carré**, on obtient un χ_d^2 par définition même de cette loi. La statistique de Wald est simplement une **distance normalisée** entre l'estimation et la valeur testée.

Le lien avec la fiche 50 : le test de Student $\hat{t}_j = (\hat{\beta}_j - \beta_j)/(\hat{\sigma}\sqrt{C_{jj}})$ est le cas $d = 1$ de Wald, à cela près que la régression normale donne une loi **exacte** de Student, là où Wald ne donne qu'une limite en χ^2 .

● Concept 8 — Le test du rapport de vraisemblance

Le cadre. Modèle $(E, (\mathbb{P}_\theta)_{\theta \in \Theta})$ avec $\Theta \subseteq \mathbb{R}^d$. L'hypothèse nulle est de la forme

$$H_0 : (\theta_{r+1}, \dots, \theta_d) = (\theta_{r+1}^{(0)}, \dots, \theta_d^{(0)})$$

pour des nombres fixés — autrement dit, on **contraint $d - r$ des d composantes**.

Les deux estimateurs.

$$\hat{\theta}_n = \operatorname{argmax}_{\theta \in \Theta} \ell_n(\theta) \quad (\text{EMV}), \quad \hat{\theta}_n^c = \operatorname{argmax}_{\theta \in \Theta_0} \ell_n(\theta) \quad (\text{EMV **contraint**})$$

La statistique de test.

$$T_n = 2 \left[\ell_n(\hat{\theta}_n) - \ell_n(\hat{\theta}_n^c) \right]$$

THÉORÈME.

Si H_0 est vraie et si les conditions techniques de l'EMV sont satisfaites, alors

$$T_n \xrightarrow[n \rightarrow \infty]{(d)} \chi_{d-r}^2$$

Test du rapport de vraisemblance de niveau asymptotique α : $\psi = \mathbf{1}\{T_n > q_\alpha\}$, où q_α est le quantile d'ordre $(1 - \alpha)$ de χ_{d-r}^2 .

L'idée est très intuitive. $\ell_n(\hat{\theta}_n) \geq \ell_n(\hat{\theta}_n^c)$ toujours, puisque le maximum sur Θ ne peut qu'excéder le maximum sur le sous-ensemble Θ_0 . La question est : **de combien** ? Si la contrainte coûte peu en vraisemblance, elle est plausible ; si elle coûte beaucoup, on la rejette.

Et le nombre de degrés de liberté est le nombre de contraintes : $d - r$, exactement le nombre de composantes fixées par H_0 . C'est une règle très générale et facile à retenir.

Le facteur 2 n'est pas cosmétique. Il vient d'un développement de Taylor au second ordre de ℓ_n autour de $\hat{\theta}_n$: le terme dominant est $\frac{1}{2}(\hat{\theta} - \hat{\theta}^c)^\top \nabla^2 \ell_n(\hat{\theta}) (\hat{\theta} - \hat{\theta}^c)$, et le facteur 2 l'annule pour donner exactement une forme quadratique gaussienne — donc un χ^2 . C'est aussi ce qui montre que **Wald et le rapport de vraisemblance sont asymptotiquement équivalents**.

● Concept 9 — Tester des hypothèses implicites

Le cadre. Soient $X_1, \dots, X_n$ i.i.d. et $\theta \in \mathbb{R}^d$ un paramètre associé à la loi de X_1 — un moment, un paramètre de modèle, etc. Soit $g : \mathbb{R}^d \rightarrow \mathbb{R}^k$ **continûment dérivable**, avec $k < d$. On teste

$$\begin{cases} H_0 : g(\theta) = 0 \\ H_1 : g(\theta) \neq 0 \end{cases}$$

Par exemple $g(\theta) = (\theta_1, \theta_2)$ avec $k = 2$, ou $g(\theta) = \theta_1 - \theta_2$ avec $k = 1$.

Étape 1 — un estimateur asymptotiquement normal. On suppose disposer de $\hat{\theta}_n$ tel que

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow[n \rightarrow \infty]{(d)} N_d(0, \Sigma(\theta))$$

Étape 2 — la méthode delta.

$$\sqrt{n} \left(g(\hat{\theta}_n) - g(\theta) \right) \xrightarrow[n \rightarrow \infty]{(d)} N_k(0, \Gamma(\theta)), \quad \boxed{\Gamma(\theta) = \nabla g(\theta)^\top \Sigma(\theta) \nabla g(\theta) \in \mathbb{R}^{k \times k}}$$

Étape 3 — normaliser. Supposons $\Sigma(\theta)$ inversible et $\nabla g(\theta)$ de rang k ; alors $\Gamma(\theta)$ est inversible et

$$\sqrt{n} \Gamma(\theta)^{-1/2} \left(g(\hat{\theta}_n) - g(\theta) \right) \xrightarrow{(d)} N_k(0, I_k)$$

Étape 4 — remplacer θ par $\hat{\theta}_n$. Par le **théorème de Slutsky**, si Γ est continue en θ :

$$\sqrt{n} \Gamma(\hat{\theta}_n)^{-1/2} \left(g(\hat{\theta}_n) - g(\theta) \right) \xrightarrow{(d)} N_k(0, I_k)$$

Étape 5 — sous H_0 , c'est-à-dire $g(\theta) = 0$:

$$T_n = n g(\hat{\theta}_n)^\top \Gamma^{-1}(\hat{\theta}_n) g(\hat{\theta}_n) \xrightarrow[n \rightarrow \infty]{(d)} \chi_k^2$$

d'où le test de niveau asymptotique $\alpha : \psi = \mathbf{1}\{T_n > q_\alpha\}$ avec q_α le quantile de χ_k^2 .

La méthode delta est l'outil le plus utile de la statistique asymptotique, et le mécanisme est un simple développement de Taylor : $g(\hat{\theta}_n) \approx g(\theta) + \nabla g(\theta)^\top (\hat{\theta}_n - \theta)$. Une transformation régulière d'un estimateur asymptotiquement normal reste asymptotiquement normale, avec une variance transportée par le gradient.

Ce que le concept ajoute aux tests précédents. Wald teste $\theta = \theta_0$; le rapport de vraisemblance teste que certaines **composantes** valent des valeurs fixées. Ici, on teste **n'importe quelle relation régulière** entre les composantes : $\theta_1 = \theta_2$, $\theta_1 \theta_2 = 1$, une élasticité égale à un... C'est le cadre général des **restrictions non linéaires** en économétrie.

Comment résoudre l'exercice type (protocole)

1. **Formuler H_0 et H_1** en termes de Θ_0 et Θ_1 disjoints — et se rappeler qu'ils **ne sont pas symétriques**.
2. **Choisir la statistique de test T_n** et déterminer sa **loi sous H_0** (exacte ou asymptotique).
3. **Fixer le niveau α** et lire le quantile correspondant.
4. **Calculer T_n** sur les données et comparer au seuil.
5. **Calculer la p-valeur** — plus informative que la décision binaire.
6. **Conclure prudemment** : « on rejette H_0 » ou « on ne rejette pas H_0 », **jamais** « H_0 est vraie ».

Comment reconnaître qu'il faut utiliser cette méthode ?

Indice dans l'énoncé	Ce qu'il faut faire
« comparer une moyenne à une référence »	test sur une espérance, TCL + Slutsky
« comparer deux groupes »	test sur une différence d'espérances
variance connue , loi gaussienne	statistique en $\sqrt{n}(\bar{X}_n - \mu_0)/\sigma$, loi $N(0, 1)$
variance inconnue , petit échantillon gaussien	Student t_{n-1}
« la variance vaut-elle σ_0^2 ? »	Cochran : $nS_n/\sigma^2 \sim \chi_{n-1}^2$
tester $\theta = \theta_0$ en dimension d	Wald , χ_d^2
tester que $d - r$ composantes sont fixées	rapport de vraisemblance , χ_{d-r}^2
tester une relation $g(\theta) = 0$	méthode delta , χ_k^2
« à quel seuil rejette-t-on ? »	la p-valeur
« le test est-il optimal ? »	Neyman-Pearson

Exercices progressifs

Niveau 1 — Une pièce donne 54 faces sur 80 lancers. Testez $p = 1/2$ au niveau 5 %.

Les hypothèses. $H_0 : p = 1/2$ contre $H_1 : p \neq 1/2$, au niveau asymptotique $\alpha = 5\%$.

La statistique. Avec $\hat{p}_n = 54/80 = 0,68$ et $\sqrt{0,5(1 - 0,5)} = 0,5$:

$$T_n = \sqrt{80} \frac{0,68 - 0,5}{0,5} = 8,944 \times 0,36 \approx 3,22$$

La décision. Sous H_0 , $T_n \approx N(0, 1)$ par le TCL et Slutsky. Le quantile est $q_{\alpha/2} = q_{0,025} = 1,96$.
Comme

$$|3,22| > 1,96$$

on **rejette** H_0 au niveau asymptotique 5 %.

La p-valeur.

$$\text{p-valeur} = \mathbb{P}[|Z| > 3,22] = 2(1 - \Phi(3,22)) \approx 0,0013 \ll 0,01$$

On rejetterait donc même au niveau **1 %**, et même à **0,2 %**. *Il paraît tout à fait raisonnable de rejeter l'hypothèse $p = 0,5$.*

Formulez la conclusion correctement : « les données sont incompatibles avec une pièce équilibrée », et **non** « la pièce a une probabilité **0,68** de tomber sur face ». Le test rejette une hypothèse ; il n'établit pas une valeur.

Niveau 2 — Qu'est-ce que la p-valeur, et pourquoi n'est-elle pas $\mathbb{P}[H_0 \text{ vraie}]$?

La définition. La p-valeur est le **plus petit niveau α** auquel le test rejette H_0 . C'est une variable **aléatoire** : elle dépend de l'échantillon.

La règle d'or.

$$\text{p-valeur} \leq \alpha \iff H_0 \text{ est rejetée au niveau } \alpha$$

Plus la p-valeur est petite, plus on rejette avec confiance.

Ce qu'elle est vraiment. C'est

$$\mathbb{P}[\text{observer une statistique au moins aussi extrême} \mid H_0]$$

— une probabilité **conditionnelle à H_0** , calculée **sous** l'hypothèse nulle.

Pourquoi ce n'est pas $\mathbb{P}[H_0 \mid \text{données}]$. Ce sont deux conditionnements **inverses**. Passer de l'un à l'autre exige la formule de Bayes :

$$\mathbb{P}[H_0 \mid \text{données}] = \frac{\mathbb{P}[\text{données} \mid H_0] \mathbb{P}[H_0]}{\mathbb{P}[\text{données}]}$$

ce qui demande une **probabilité a priori** $\mathbb{P}[H_0]$ — objet qui n'existe pas dans le cadre fréquentiste, où θ est un paramètre **fixe**, pas une variable aléatoire. Dire « H_0 a **4 %** de chances d'être vraie » n'a **aucun sens** ici.

L'analogie du procès, que le cours suggère avec « innocent jusqu'à preuve du contraire » : la p-valeur mesure à quel point les preuves seraient **surprenantes si l'accusé était innocent**. Elle ne mesure pas la probabilité qu'il soit innocent — cela dépendrait aussi du taux de criminalité *a priori*.

La conséquence pratique. Une p-valeur de **0,44** (exemple 2) signifie : « si la pièce était équilibrée, on observerait un écart au moins aussi grand **44 %** du temps ». Rien d'étonnant, donc — mais cela ne prouve **pas** que la pièce est équilibrée.

Niveau 3 — Construisez le test de Wald et expliquez d'où vient le χ_d^2 .

Le point de départ — le théorème de la fiche 64. Sous les conditions techniques,

$$\sqrt{n}(\hat{\theta}_n^{MLE} - \theta^*) \xrightarrow{(d)} N_d(0, I(\theta^*)^{-1})$$

Étape 1 — normaliser. En multipliant par $I(\theta^*)^{1/2}$, la covariance devient $I^{1/2}I^{-1}I^{1/2} = I_d$:

$$\sqrt{n}I(\hat{\theta}_n)^{1/2}(\hat{\theta}_n - \theta_0) \xrightarrow{(d)} N_d(0, I_d) \quad \text{sous } H_0 : \theta = \theta_0$$

(on a remplacé $I(\theta^*)$ par $I(\hat{\theta}_n)$, ce que **Slutsky** autorise par continuité).

Étape 2 — prendre la norme au carré. Par définition même de la loi χ^2 — la loi de $Z_1^2 + \dots + Z_d^2$ pour Z_i i.i.d. $N(0, 1)$ —, si $Z \sim N_d(0, I_d)$ alors $\|Z\|_2^2 \sim \chi_d^2$. Donc

$$T_n = \left\| \sqrt{n}I(\hat{\theta}_n)^{1/2}(\hat{\theta}_n - \theta_0) \right\|_2^2 = n(\hat{\theta}_n - \theta_0)^\top I(\hat{\theta}_n)(\hat{\theta}_n - \theta_0) \xrightarrow{(d)} \chi_d^2$$

Étape 3 — le test. $\psi = \mathbf{1}\{T_n > q_\alpha\}$, q_α étant le quantile d'ordre $(1 - \alpha)$ de χ_d^2 .

L'interprétation géométrique. T_n est le **carré d'une distance normalisée** entre $\hat{\theta}_n$ et θ_0 , la normalisation étant faite par l'information de Fisher. Les directions où l'information est **grande** — donc l'estimation précise — pèsent **davantage** dans la distance : un petit écart y est déjà suspect. Les directions mal informées pèsent peu.

Pourquoi d degrés de liberté : on teste d composantes simultanément, donc on somme d carrés de gaussiennes standard indépendantes.

Une remarque du cours à ne pas manquer : le test de Wald est aussi valide si H_1 est de la forme $\theta > \theta_0$, $\theta < \theta_0$ ou $\theta = \theta_1$. La statistique ne change pas ; c'est seulement la puissance qui varie selon l'alternative.

Le lien avec la fiche 50 : en dimension $d = 1$, $T_n = n(\hat{\theta}_n - \theta_0)^2 I(\hat{\theta}_n)$ est le **carré** de la statistique de Student. La différence est que la régression normale donne une loi **exacte** (t_{n-p}), tandis que Wald ne fournit qu'une limite asymptotique (χ_1^2).

Niveau 4 — type examen — Comparez le test de Wald et le test du rapport de vraisemblance.

	Wald	Rapport de vraisemblance
Hypothèse testée	$\theta = \theta_0$ (valeur complète)	$(\theta_{r+1}, \dots, \theta_d) = (\theta_{r+1}^{(0)}, \dots, \theta_d^{(0)})$
Statistique	$n(\hat{\theta}_n - \theta_0)^\top I(\hat{\theta}_n)(\hat{\theta}_n - \theta_0)$	$2[\ell_n(\hat{\theta}_n) - \ell_n(\hat{\theta}_n^c)]$
Loi limite	χ_d^2	χ_{d-r}^2
Degrés de liberté	dimension de θ	nombre de contraintes
Ce qu'il faut calculer	l'EMV libre et $I(\hat{\theta}_n)$	l'EMV libre et l'EMV contraint
Ce qu'il mesure	une distance dans l'espace des paramètres	un coût en vraisemblance

L'idée de Wald. À quelle distance $\hat{\theta}_n$ est-il de θ_0 , mesurée dans la métrique de l'information de Fisher ? Le théorème asymptotique donne $\sqrt{n}I^{1/2}(\hat{\theta}_n - \theta_0) \rightarrow N_d(0, I_d)$, et la norme au carré donne le χ_d^2 .

L'idée du rapport de vraisemblance. Combien coûte la contrainte ? Comme $\Theta_0 \subset \Theta$, on a toujours $\ell_n(\hat{\theta}_n) \geq \ell_n(\hat{\theta}_n^c)$. Si l'écart est faible, la contrainte est plausible ; s'il est grand, on rejette. Le nombre de degrés de liberté, $d - r$, est exactement le **nombre de composantes contraintes**.

Le lien entre les deux — et c'est le point à savoir. Ils sont **asymptotiquement équivalents**. La raison est un développement de Taylor de ℓ_n au second ordre autour de $\hat{\theta}_n$: comme $\nabla \ell_n(\hat{\theta}_n) = 0$,

$$\ell_n(\hat{\theta}_n^c) \approx \ell_n(\hat{\theta}_n) + \frac{1}{2}(\hat{\theta}_n^c - \hat{\theta}_n)^\top \nabla^2 \ell_n(\hat{\theta}_n)(\hat{\theta}_n^c - \hat{\theta}_n)$$

d'où

$$2[\ell_n(\hat{\theta}_n) - \ell_n(\hat{\theta}_n^c)] \approx n(\hat{\theta}_n - \hat{\theta}_n^c)^\top I(\hat{\theta}_n)(\hat{\theta}_n - \hat{\theta}_n^c)$$

qui est exactement la forme de Wald. **Le facteur 2 de la statistique du rapport de vraisemblance est là pour annuler le $\frac{1}{2}$ de Taylor.**

Comment choisir en pratique.

- **Wald** est plus simple quand on a déjà l'EMV libre : pas besoin de réoptimiser sous contrainte. Mais il exige de calculer $I(\hat{\theta}_n)$, et il n'est **pas invariant par reparamétrisation** — tester $\theta = 1$ ou $\log \theta = 0$ peut donner des réponses différentes à n fini.
- **Le rapport de vraisemblance** est **invariant par reparamétrisation** et généralement mieux calibré en échantillon fini, mais il exige **deux** optimisations.

- **Un troisième test** existe, celui du **score** (multiplicateur de Lagrange), qui ne demande que l'EMV **contraint** — utile quand le modèle libre est difficile à estimer. Les trois sont asymptotiquement équivalents et forment la « trinité » des tests classiques.

La limite commune, à mentionner. Les trois reposent sur les **conditions techniques de l'EMV** de la fiche 64 — en particulier que le **support ne dépende pas de θ** et que **θ^*** ne soit pas sur la **frontière** de Θ . Tester $\sigma^2 = 0$ ou une probabilité $p = 0$ tombe précisément dans le cas exclu, et la loi limite n'est alors plus un χ^2 ordinaire.

● Common mistakes

1. **Conclure « H_0 est vraie »** — on ne peut que **ne pas la rejeter** : *innocent jusqu'à preuve du contraire*.
2. **Confondre p-valeur et $\mathbb{P}[H_0 \mid \text{données}]$** — la p-valeur est calculée **sous H_0** .
3. **Confondre erreur de première et de seconde espèce** — la première rejette à tort, la seconde manque un effet réel.
4. **Oublier que la puissance est un inf sur Θ_1** — c'est une performance de **pire cas**.
5. **Croire qu'on peut minimiser les deux erreurs** — elles varient en sens inverse : on **fixe α** et l'on maximise la puissance.
6. **Utiliser q_α au lieu de $q_{\alpha/2}$ pour un test bilatéral.**
7. **Se tromper de degrés de liberté** — χ_d^2 pour Wald, χ_{d-r}^2 pour le rapport de vraisemblance (**nombre de contraintes**), χ_k^2 pour la méthode delta.
8. **Oublier le facteur 2** dans la statistique du rapport de vraisemblance.
9. **Utiliser n au lieu de $n - 1$** dans les degrés de liberté de Cochran et de Student.
10. **Appliquer ces tests quand θ^* est sur la frontière** — les conditions techniques de l'EMV sont violées.
11. **Interpréter un non-rejet sur un petit échantillon comme une absence d'effet** — c'est un manque de **puissance**.

Ultimate Review

1. **Formulation** : Θ_0, Θ_1 disjoints ; $H_0 : \theta \in \Theta_0$ contre $H_1 : \theta \in \Theta_1$; les données servent **seulement à réfuter H_0** .
2. **Test** : $\psi \in \{0, 1\}$; $\psi = 1 \Rightarrow$ rejet. Région de rejet $R_\psi = \{x : \psi(x) = 1\}$.
3. **Erreur de 1re espèce** : $\alpha_\psi(\theta) = \mathbb{P}_\theta[\psi = 1]$ sur Θ_0 . **De 2e espèce** : $\beta_\psi(\theta) = \mathbb{P}_\theta[\psi = 0]$ sur Θ_1 .
4. **Puissance** : $\pi_\psi = \inf_{\theta \in \Theta_1} (1 - \beta_\psi(\theta))$.

5. **Niveau α** : $\alpha_\psi(\theta) \leq \alpha \forall \theta \in \Theta_0$; **asymptotique** si $\lim_n \alpha_\psi(\theta) \leq \alpha$.
6. **Forme générale** : $\psi = \mathbf{1}\{T_n > c\}$, T_n statistique de test.
7. **Exemple de la pièce** : $T_n = \sqrt{n}(\hat{p}_n - 0,5)/\sqrt{0,25}$; $\psi_\alpha = \mathbf{1}\{|T_n| > q_{\alpha/2}\}$; $q_{0,025} = 1,96$.
8. **p-valeur** : plus petit niveau auquel on rejette ; **règle d'or** p-valeur $\leq \alpha \iff$ rejet au niveau α ; **aléatoire**.
9. **Neyman-Pearson** : à niveau α fixé, chercher la **puissance maximale** ; le test trivial $\psi = 0$ a un niveau parfait et une puissance nulle.
10. **Loi χ_d^2** : loi de $Z_1^2 + \dots + Z_d^2$; si $Z \sim N_d(0, I_d)$, $\|Z\|^2 \sim \chi_d^2$; $\chi_2^2 = \text{Exp}(1/2)$.
11. **Varianse empirique** : $S_n = \frac{1}{n} \sum (X_i - \bar{X}_n)^2$; **Cochran** : $nS_n/\sigma^2 \sim \chi_{n-1}^2$ dans le modèle gaussien.
12. **Loi de Student t_d** : loi de $Z/\sqrt{V/d}$ avec $Z \sim N(0, 1)$, $V \sim \chi_d^2$, $Z \perp V$; et $\sqrt{n-1}(\bar{X}_n - \mu)/\sqrt{S_n} \sim t_{n-1}$.
13. **Wald** : $\sqrt{n}I(\hat{\theta}_n)^{1/2}(\hat{\theta}_n - \theta_0) \rightarrow N_d(0, I_d)$, d'où

$$T_n = n(\hat{\theta}_n - \theta_0)^\top I(\hat{\theta}_n)(\hat{\theta}_n - \theta_0) \rightarrow \chi_d^2$$

14. **Rapport de vraisemblance** : H_0 fixe $d - r$ composantes ; $T_n = 2[\ell_n(\hat{\theta}_n) - \ell_n(\hat{\theta}_n^c)] \rightarrow \chi_{d-r}^2$.
15. **Hypothèses implicites** : $H_0 : g(\theta) = 0$ avec $g : \mathbb{R}^d \rightarrow \mathbb{R}^k$; **méthode delta**

$$\sqrt{n}(g(\hat{\theta}_n) - g(\theta)) \rightarrow N_k(0, \Gamma(\theta)), \quad \Gamma(\theta) = \nabla g(\theta)^\top \Sigma(\theta) \nabla g(\theta)$$

$$\text{puis } T_n = n g(\hat{\theta}_n)^\top \Gamma^{-1}(\hat{\theta}_n) g(\hat{\theta}_n) \rightarrow \chi_k^2.$$

16. **Wald et rapport de vraisemblance sont asymptotiquement équivalents** — développement de Taylor au second ordre, d'où le facteur 2.

Formulas to know

$$\alpha_\psi(\theta) = \mathbb{P}_\theta[\psi = 1] \quad \pi_\psi = \inf_{\theta \in \Theta_1} (1 - \beta_\psi(\theta)) \quad \psi = \mathbf{1}\{T_n > c\}$$

$$\frac{nS_n}{\sigma^2} \sim \chi_{n-1}^2 \quad \sqrt{n-1} \frac{\bar{X}_n - \mu}{\sqrt{S_n}} \sim t_{n-1}$$

$$T_n^{\text{Wald}} = n(\hat{\theta}_n - \theta_0)^\top I(\hat{\theta}_n)(\hat{\theta}_n - \theta_0) \rightarrow \chi_d^2 \quad T_n^{\text{RV}} = 2[\ell_n(\hat{\theta}_n) - \ell_n(\hat{\theta}_n^c)] \rightarrow \chi_{d-r}^2$$

$$\Gamma(\theta) = \nabla g(\theta)^\top \Sigma(\theta) \nabla g(\theta)$$

Methods to know : la construction d'un test en six étapes ; la dérivation de la statistique de Wald à partir du théorème asymptotique ; le comptage des degrés de liberté ; la méthode delta.

Active Recall

Basic — Définissez les deux types d'erreur, la puissance et le niveau.

Erreur de première espèce — rejeter H_0 alors qu'elle est **vraie** :

$$\alpha_\psi : \Theta_0 \rightarrow \mathbb{R}, \quad \theta \mapsto \mathbb{P}_\theta[\psi = 1]$$

Erreur de seconde espèce — ne pas rejeter H_0 alors que H_1 est **vraie** :

$$\beta_\psi : \Theta_1 \rightarrow \mathbb{R}, \quad \theta \mapsto \mathbb{P}_\theta[\psi = 0]$$

Puissance — la performance de **pire cas** sous l'alternative :

$$\pi_\psi = \inf_{\theta \in \Theta_1} (1 - \beta_\psi(\theta))$$

Niveau α : $\alpha_\psi(\theta) \leq \alpha$ pour **tout** $\theta \in \Theta_0$; **niveau asymptotique α** si $\lim_{n \rightarrow \infty} \alpha_\psi(\theta) \leq \alpha$.

Understanding — Pourquoi H_0 et H_1 ne jouent-ils pas un rôle symétrique ?

Parce que *les données ne servent qu'à tenter de **réfuter** H_0* . Le test cherche des éléments **contre** H_0 ; il ne cherche jamais à la confirmer.

La conséquence : *une absence de preuve ne signifie pas que H_0 est vraie* — « innocent jusqu'à preuve du contraire ». On ne peut conclure que « on rejette H_0 » ou « on ne rejette pas H_0 ».

La traduction technique : le **niveau** — le risque de rejeter à tort — est **contrôlé par construction** à α . La **puissance** — la chance de rejeter à raison — n'est contrôlée par rien : elle dépend de la taille de l'échantillon et de l'écart réel à H_0 .

En pratique, c'est l'erreur d'interprétation la plus fréquente en économétrie. « Le coefficient n'est pas significatif » ne veut pas dire « le coefficient est nul » : sur un échantillon petit ou bruité, on ne rejette presque jamais — faute de **puissance**, pas faute d'effet.

Application — Un test donne une p-valeur de **0,03**. Que conclure aux niveaux **5 %** et **1 %** ?

Par la **règle d'or** : $p\text{-valeur} \leq \alpha \iff$ rejet au niveau α .

- **Au niveau 5 %** : $0,03 \leq 0,05 \Rightarrow$ on **rejette** H_0 .
- **Au niveau 1 %** : $0,03 > 0,01 \Rightarrow$ on **ne rejette pas** H_0 .

Ce que cela illustre. La conclusion **dépend du seuil choisi**, et le seuil est une décision, pas un fait statistique. Un résultat « significatif à 5 % » et « non significatif à 1 % » est un résultat **fragile** : il n'y a rien de magique dans 0,05.

Ce que la p-valeur apporte de plus qu'un verdict. Elle donne le **seuil critique lui-même**, ce qui permet à chaque lecteur d'appliquer son propre arbitrage. Elle mesure la force de l'évidence, pas seulement sa présence.

Et elle ne dit pas : « il y a 3 % de chances que H_0 soit vraie ». Elle dit : « **si** H_0 était vraie, on observerait un résultat au moins aussi extrême 3 % du temps ».

Comparison — χ^2 et Student : d'où viennent ces deux lois ?

	χ_d^2	t_d
Définition	$Z_1^2 + \dots + Z_d^2$, Z_i i.i.d. $N(0, 1)$	$Z/\sqrt{V/d}$, $Z \sim N(0, 1)$, $V \sim \chi_d^2$, $Z \perp V$
À quoi elle sert	tester une variance , ou plusieurs paramètres à la fois	tester une moyenne à variance inconnue
Où elle apparaît	$nS_n/\sigma^2 \sim \chi_{n-1}^2$ (Cochran)	$\sqrt{n-1}(\bar{X}_n - \mu)/\sqrt{S_n} \sim t_{n-1}$
Tests concernés	Wald, rapport de vraisemblance , méthode delta	test de Student (fiche 50)

Le lien entre les deux. Student est un **quotient** : une gaussienne divisée par la racine d'un χ^2 normalisé et **indépendant**. C'est exactement ce que produit le modèle gaussien : $\bar{X}_n$ est gaussienne, nS_n/σ^2 est un χ_{n-1}^2 , et le théorème de **Cochran** garantit leur **indépendance**. Le σ inconnu se simplifie dans le quotient — c'est tout l'intérêt.

Pourquoi $n - 1$. Les écarts $X_i - \bar{X}_n$ sont liés par une contrainte (leur somme est nulle), donc ils n'occupent que $n - 1$ dimensions. C'est la même comptabilité qu'en fiche 50, où l'estimation de p paramètres laisse $n - p$ degrés de liberté.

Et quand n grandit, $t_{n-1} \rightarrow N(0, 1)$: l'incertitude sur σ devient négligeable et Student redevient gaussienne. C'est pourquoi les tests asymptotiques du chapitre utilisent directement $N(0, 1)$ et χ^2 .

Exam-style — Construisez le test du rapport de vraisemblance et justifiez ses degrés de liberté.

Le cadre. Modèle $(E, (\mathbb{P}_\theta)_{\theta \in \Theta})$ avec $\Theta \subseteq \mathbb{R}^d$. L'hypothèse nulle **fixe $d - r$ composantes** :

$$H_0 : (\theta_{r+1}, \dots, \theta_d) = (\theta_{r+1}^{(0)}, \dots, \theta_d^{(0)})$$

Les deux estimateurs.

$$\hat{\theta}_n = \operatorname{argmax}_{\theta \in \Theta} \ell_n(\theta) \quad \text{et} \quad \hat{\theta}_n^c = \operatorname{argmax}_{\theta \in \Theta_0} \ell_n(\theta)$$

La statistique.

$$T_n = 2 \left[\ell_n(\hat{\theta}_n) - \ell_n(\hat{\theta}_n^c) \right]$$

Le théorème. Sous H_0 et les conditions techniques de l'EMV, $T_n \xrightarrow{(d)} \chi_{d-r}^2$. Le test de niveau asymptotique α est $\psi = \mathbf{1}\{T_n > q_\alpha\}$, avec q_α le quantile d'ordre $1 - \alpha$ de χ_{d-r}^2 .

L'idée. Comme $\Theta_0 \subset \Theta$, on a toujours $\ell_n(\hat{\theta}_n) \geq \ell_n(\hat{\theta}_n^c)$, donc $T_n \geq 0$. La question est : **combien coûte la contrainte** en vraisemblance ? Peu $\Rightarrow$ elle est plausible. Beaucoup $\Rightarrow$ on rejette.

Pourquoi $d - r$ degrés de liberté. C'est le **nombre de contraintes imposées par H_0** — le nombre de composantes fixées. L'argument formel est un développement de Taylor : comme $\nabla \ell_n(\hat{\theta}_n) = 0$,

$$T_n \approx n(\hat{\theta}_n - \hat{\theta}_n^c)^\top I(\hat{\theta}_n)(\hat{\theta}_n - \hat{\theta}_n^c)$$

Or $\hat{\theta}_n - \hat{\theta}_n^c$ est asymptotiquement gaussien **confiné dans le sous-espace de dimension $d - r$** orthogonal à Θ_0 — les r composantes libres sont estimées de la même façon des deux côtés et ne contribuent pas. La forme quadratique est donc une somme de $d - r$ carrés de gaussiennes standard, c'est-à-dire un χ_{d-r}^2 .

D'où vient le facteur 2. Le développement de Taylor produit un $\frac{1}{2}$ devant la forme quadratique ; le facteur **2** l'annule exactement, ce qui donne la loi χ^2 pure. Ce n'est donc pas un ajustement empirique.

Ce que ce calcul montre aussi. La forme obtenue est **celle de Wald**, avec $\hat{\theta}_n^c$ à la place de θ_0 : les deux tests sont **asymptotiquement équivalents**.

Quand préférer le rapport de vraisemblance. Il est **invariant par reparamétrisation** — contrairement à Wald, qui peut donner des réponses différentes selon qu'on teste $\theta = 1$ ou $\log \theta = 0$ à n fini — et il est généralement mieux calibré en petit échantillon. Son coût : il faut **deux** optimisations au lieu d'une.

Flashcards

Question	Réponse
Rôle des données dans un test ?	Tenter de réfuter H_0 — jamais la confirmer
Que signifie « ne pas rejeter H_0 » ?	Pas que H_0 est vraie — « innocent jusqu'à preuve du contraire »
Définition d'un test ?	Une statistique $\psi \in \{0, 1\}$; $\psi = 1 \Rightarrow$ rejet
Région de rejet ?	$R_\psi = \{x \in E^n : \psi(x) = 1\}$
Erreur de première espèce ?	$\alpha_\psi(\theta) = \mathbb{P}_\theta[\psi = 1]$ sur Θ_0
Erreur de seconde espèce ?	$\beta_\psi(\theta) = \mathbb{P}_\theta[\psi = 0]$ sur Θ_1
Puissance ?	$\pi_\psi = \inf_{\theta \in \Theta_1} (1 - \beta_\psi(\theta))$
Pourquoi un inf ?	C'est la performance de pire cas sous l'alternative
Niveau α ?	$\alpha_\psi(\theta) \leq \alpha$ pour tout $\theta \in \Theta_0$
Forme générale d'un test ?	$\psi = \mathbf{1}\{T_n > c\}$
Statistique du test de la pièce ?	$\sqrt{n}(\hat{p}_n - 0,5)/\sqrt{0,25}$
Quantile bilatéral à 5 % ?	$q_{0,025} = 1,96$
Définition de la p-valeur ?	Le plus petit niveau auquel on rejette H_0
La règle d'or ?	p-valeur $\leq \alpha \iff$ rejet au niveau α
La p-valeur est-elle $\mathbb{P}[H_0]$?	Non — elle est calculée sous H_0
Idée de Neyman-Pearson ?	À niveau α fixé, maximiser la puissance
Défaut du test trivial $\psi = 0$?	Niveau parfait, puissance nulle
Définition de χ_d^2 ?	Loi de $Z_1^2 + \dots + Z_d^2$, Z_i i.i.d. $N(0, 1)$
Variance empirique ?	$S_n = \frac{1}{n} \sum (X_i - \bar{X}_n)^2$
Théorème de Cochran ?	$nS_n/\sigma^2 \sim \chi_{n-1}^2$
Que vaut χ_2^2 ?	Exp (1/2)

Question	Réponse
Définition de t_d ?	$Z/\sqrt{V/d}$, $Z \sim N(0,1)$, $V \sim \chi_d^2$, indépendants
Statistique de Student pour la moyenne ?	$\sqrt{n-1}(\bar{X}_n - \mu)/\sqrt{S_n} \sim t_{n-1}$
Statistique de Wald ?	$n(\hat{\theta}_n - \theta_0)^\top I(\hat{\theta}_n)(\hat{\theta}_n - \theta_0)$
Sa loi limite ?	χ_d^2
D'où vient ce χ^2 ?	Norme au carré d'un $N_d(0, I_d)$
Statistique du rapport de vraisemblance ?	$2[\ell_n(\hat{\theta}_n) - \ell_n(\hat{\theta}_n^c)]$
Sa loi limite ?	χ_{d-r}^2
Que compte $d - r$?	Le nombre de contraintes de H_0
Pourquoi le facteur 2 ?	Il annule le $\frac{1}{2}$ du développement de Taylor
Formule de la méthode delta ?	$\Gamma(\theta) = \nabla g(\theta)^\top \Sigma(\theta) \nabla g(\theta)$
Loi limite du test implicite ?	χ_k^2 , k = dimension de g
Wald et rapport de vraisemblance ?	Asymptotiquement équivalents