

Fiche 66 — Modèles linéaires généralisés : famille exponentielle, lien canonique et IRLS

Matière	Maths · Économétrie
Cours source	Rigollet, <i>18.650 Statistics for Applications</i> , MIT OpenCourseWare, automne 2016 — chapitre 10 « Generalized Linear Models »
Difficulté	Must know — régression logistique, Poisson et tout le reste en une seule théorie
Temps d'étude estimé	2 h 45
Prérequis	Fiche 50 (modèle linéaire, MCG), fiche 64 (vraisemblance, information de Fisher), fiche 39 (Newton)
Concepts clés	Composante aléatoire et fonction de lien, famille exponentielle, forme canonique, paramètre de dispersion, $\mu = b'(\theta)$ et $\text{var} = b''(\theta)\phi$, logit, probit, lien canonique, stricte concavité, Newton-Raphson, scores de Fisher, moindres carrés repondérés itérativement
Poids à l'examen	Trois choses : les deux identités donnant $\mu = b'(\theta)$ et $\text{var}(Y) = b''(\theta)\phi$; le fait que le lien canonique de Bernoulli soit le logit ; et l'algorithme IRLS en quatre étapes.

Vue d'ensemble

Le modèle linéaire suppose

$$Y \mid X \sim N(\mu(X), \sigma^2 I) \quad \text{et} \quad \mathbb{E}(Y \mid X) = \mu(X) = X^\top \beta$$

Ses deux composantes — celles qu'on va relâcher.

1. **Composante aléatoire** : la réponse $Y \mid X$ est **continue** et de loi **normale**, de moyenne $\mu = \mu(X) = \mathbb{E}(Y \mid X)$.
2. **Lien** entre l'aléatoire et les covariables $X = (X^{(1)}, \dots, X^{(p)})^\top : \mu(X) = X^\top \beta$.

La généralisation. Un **modèle linéaire généralisé (GLM)** généralise dans deux directions :

1. **Composante aléatoire** : $Y \sim$ une loi de **famille exponentielle** ;
2. **Lien** :

$$g(\mu(X)) = X^\top \beta$$

où g est la **fonction de lien** et $\mu = \mathbb{E}(Y | X)$.

MODÈLE LINÉAIRE	$Y X$ gaussienne	et	$\mu = X^\top \beta$
GLM	$Y X$ exponentielle	et	$g(\mu) = X^\top \beta$
	↓		↓
	Poisson, Bernoulli, Gamma...		log, logit, probit...
CLÉ	forme canonique	$f_\theta(y) = \exp[(y\theta - b(\theta))/\phi + c(y, \phi)]$	
	$\Rightarrow \mu = b'(\theta)$	et	$\text{var}(Y) = b''(\theta)\phi$
CALCUL	Newton-Raphson $\rightarrow$ scores de Fisher $\rightarrow$ IRLS		

● Concept 1 — Trois situations que le modèle linéaire ne sait pas traiter

Exemple 1 — taux d'occurrence d'une maladie. Au début d'une épidémie, le rythme d'apparition de nouveaux cas croît souvent exponentiellement. Si μ_i est le nombre espéré de nouveaux cas au jour t_i , un modèle de la forme

$$\mu_i = \gamma \exp(\delta t_i)$$

semble approprié. On le met sous forme GLM par un **lien logarithmique** :

$$\log(\mu_i) = \log(\gamma) + \delta t_i = \beta_0 + \beta_1 t_i$$

Comme il s'agit d'un **comptage**, la loi de **Poisson** (d'espérance μ_i) est sans doute raisonnable.

Exemple 2 — taux de capture de proies. Le taux de capture y_i par un prédateur croît avec la densité de proies x_i , mais **plafonne** quand le prédateur attrape autant qu'il peut en traiter. Un modèle adapté serait

$$\mu_i = \frac{\alpha x_i}{h + x_i}$$

où α est le taux de capture maximal et h la densité à laquelle le taux vaut la moitié du maximum. Ce modèle est manifestement **non linéaire en ses paramètres**, mais un **lien réciproque** rend le membre de droite

linéaire :

$$g(\mu_i) = \frac{1}{\mu_i} = \frac{1}{\alpha} + \frac{h}{\alpha} \cdot \frac{1}{x_i} = \beta_0 + \beta_1 \frac{1}{x_i}$$

L'écart-type du taux de capture étant à peu près proportionnel au taux moyen, cela suggère une loi **Gamma** pour la réponse.

Exemple 3 — les données Kyphosis. Mesures sur 81 enfants après chirurgie corrective du rachis. La réponse **binaire** indique la présence ou l'absence d'une déformation post-opératoire. Les trois covariables sont l'âge en mois, le nombre de vertèbres concernées et le début de la plage vertébrale.

- La réponse est **binaire** : pas le choix, $Y \mid X$ est de Bernoulli, d'espérance $\mu(X) \in (0, 1)$.
- On ne peut **pas** écrire $\mu(X) = X^\top \beta$, parce que le membre de droite parcourt tout $\mathbb{R}$.
- Il faut une fonction **inversible** f telle que $f(X^\top \beta) \in (0, 1)$.

Ces trois exemples couvrent les trois obstacles. Un **domaine borné** ($\mu > 0$ pour Poisson, $\mu \in (0, 1)$ pour Bernoulli), une **non-linéarité** en les paramètres, et une **variance non constante** — dans l'exemple 2, l'écart-type croît avec la moyenne. Le modèle linéaire échoue sur les trois.

La motivation du cours : il faut un cadre de régression plus général pour tenir compte de divers types de données de réponse — les lois de la **famille exponentielle** — et développer des méthodes d'ajustement et d'inférence dans ce cadre : l'**estimation par maximum de vraisemblance**.

● Concept 2 — La famille exponentielle

DÉFINITION.

Une famille de lois $\{P_\theta : \theta \in \Theta\}$, $\Theta \subset \mathbb{R}^k$, est une **famille exponentielle à k paramètres** sur $\mathbb{R}^q$ s'il existe des fonctions réelles $\eta_1, \dots, \eta_k$ et B de θ , et $T_1, \dots, T_k$ et h de $x \in \mathbb{R}^q$, telles que la densité (ou la fonction de masse) de P_θ s'écrive

$$p_\theta(x) = \exp \left[\sum_{i=1}^k \eta_i(\theta) T_i(x) - B(\theta) \right] h(x)$$

Exemple gaussien. Pour $X \sim N(\mu, \sigma^2)$ avec $\theta = (\mu, \sigma^2)$:

$$p_{\theta}(x) = \exp \left(\frac{\mu}{\sigma^2} x - \frac{1}{2\sigma^2} x^2 - \frac{\mu^2}{2\sigma^2} \right) \frac{1}{\sigma\sqrt{2\pi}}$$

ce qui forme une famille exponentielle à **deux paramètres**, avec

$$\eta_1 = \frac{\mu}{\sigma^2}, \quad \eta_2 = -\frac{1}{2\sigma^2}, \quad T_1(x) = x, \quad T_2(x) = x^2, \quad B(\theta) = \frac{\mu^2}{2\sigma^2} + \log(\sigma\sqrt{2\pi}), \quad h(x) = 1$$

Quand σ^2 est **connue**, cela devient une famille exponentielle à **un paramètre** sur $\mathbb{R}$:

$$\eta = \frac{\mu}{\sigma^2}, \quad T(x) = x, \quad B(\theta) = \frac{\mu^2}{2\sigma^2}, \quad h(x) = \frac{e^{-x^2/2\sigma^2}}{\sigma\sqrt{2\pi}}$$

Les lois discrètes qui forment des familles exponentielles : **Bernoulli**(p) $p^x(1-p)^{1-x}$, $x \in \{0, 1\}$.
Poisson(λ) $e^{-\lambda}\lambda^x/x!$.

Les lois continues : **Gamma**(a, b) $\frac{1}{\Gamma(a)b^a} x^{a-1} e^{-x/b}$, avec a paramètre de forme et b d'échelle, reparamétrable en $\mu = ab$ (paramètre de moyenne) ; **Gamma inverse**(α, β) ; **gaussienne inverse**(μ, σ^2).
Autres : khi-deux, bêta, binomiale, binomiale négative.

CE QUE LA DÉFINITION CAPTURE.

Le paramètre θ et l'observation x n'interagissent que par le **produit** $\eta_i(\theta)T_i(x)$ — jamais de façon plus enchevêtrée. C'est cette séparation qui donne les statistiques exhaustives T_i , la concavité de la log-vraisemblance, et les identités du concept suivant. Presque toutes les lois usuelles rentrent dans ce moule.

● Concept 3 — La forme canonique à un paramètre

DÉFINITION.

La **famille exponentielle canonique** pour $k = 1$, $y \in \mathbb{R}$:

$$f_{\theta}(y) = \exp \left(\frac{y\theta - b(\theta)}{\phi} + c(y, \phi) \right)$$

pour des fonctions connues $b(\cdot)$ et $c(\cdot, \cdot)$.

- Si ϕ est **connu**, c'est une famille exponentielle à un paramètre, θ étant le **paramètre canonique**.

- Si ϕ est inconnu, cela peut ou non être une famille à deux paramètres ; ϕ s'appelle le **paramètre de dispersion**.
- Dans ce cours, on suppose toujours ϕ **connu**.

Le cas gaussien à variance connue.

$$f_{\theta}(y) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(y-\mu)^2}{2\sigma^2}} = \exp\left(\frac{y\mu - \frac{1}{2}\mu^2}{\sigma^2} - \frac{1}{2}\left(\frac{y^2}{\sigma^2} + \log(2\pi\sigma^2)\right)\right)$$

d'où

$$\theta = \mu, \quad \phi = \sigma^2, \quad b(\theta) = \frac{\theta^2}{2}, \quad c(y, \phi) = -\frac{1}{2}\left(\frac{y^2}{\phi} + \log(2\pi\phi)\right)$$

Le tableau des trois lois principales.

	Normale $N(\mu, \sigma^2)$	Poisson $P(\mu)$	Bernoulli $B(p)$
Domaine de y	$(-\infty, \infty)$	$\{0, 1, 2, \dots\}$	$\{0, 1\}$
ϕ	σ^2	1	1
$b(\theta)$	$\theta^2/2$	e^{θ}	$\log(1 + e^{\theta})$
$c(y, \phi)$	$-\frac{1}{2}\left(\frac{y^2}{\phi} + \log(2\pi\phi)\right)$	$-\log y!$	0

● Concept 4 — Moyenne et variance par les deux identités

Soit $\ell(\theta) = \log f_{\theta}(Y)$ la log-vraisemblance. La moyenne et la variance se déduisent de **deux identités**, toutes deux obtenues à partir de $\int f_{\theta}(y) dy \equiv 1$:

Première identité : $\mathbb{E}\left(\frac{\partial \ell}{\partial \theta}\right) = 0$

Seconde identité : $\mathbb{E}\left(\frac{\partial^2 \ell}{\partial \theta^2}\right) + \mathbb{E}\left(\frac{\partial \ell}{\partial \theta}\right)^2 = 0$

L'espérance. De $\ell(\theta) = \frac{Y\theta - b(\theta)}{\phi} + c(Y; \phi)$ on tire

$$\frac{\partial \ell}{\partial \theta} = \frac{Y - b'(\theta)}{\phi}$$

et la première identité donne

$$0 = \mathbb{E} \left(\frac{\partial \ell}{\partial \theta} \right) = \frac{\mathbb{E}(Y) - b'(\theta)}{\phi} \quad \Rightarrow \quad \boxed{\mathbb{E}(Y) = \mu = b'(\theta)}$$

La variance. D'autre part,

$$\frac{\partial^2 \ell}{\partial \theta^2} + \left(\frac{\partial \ell}{\partial \theta} \right)^2 = -\frac{b''(\theta)}{\phi} + \left(\frac{Y - b'(\theta)}{\phi} \right)^2$$

et comme $\frac{Y - b'(\theta)}{\phi} = \frac{Y - \mathbb{E}(Y)}{\phi}$ d'après le résultat précédent, la seconde identité donne

$$0 = -\frac{b''(\theta)}{\phi} + \frac{\text{var}(Y)}{\phi^2} \quad \Rightarrow \quad \boxed{\text{var}(Y) = V(Y) = b''(\theta)\phi}$$

Ces deux formules sont le cœur opératoire du chapitre. Toute la loi — moyenne **et** variance — est encodée dans **une seule fonction b** et ses deux premières dérivées. Il suffit d'identifier **b** pour tout connaître.

Et remarquez la conséquence majeure : la variance $b''(\theta)\phi$ est une **fonction de la moyenne**, puisque $\mu = b'(\theta)$. Dans un GLM, on ne choisit **pas** la variance indépendamment de la moyenne — elle est déterminée par la famille. C'est exactement ce que l'exemple 2 demandait (écart-type proportionnel à la moyenne, obtenu par la loi Gamma).

Exemple — la loi de Poisson.

$$f(y) = \frac{\mu^y e^{-\mu}}{y!} = e^{y \log \mu - \mu - \log(y!)}$$

d'où

$$\theta = \log \mu, \quad b(\theta) = \mu = e^\theta, \quad c(y, \phi) = -\log(y!), \quad \phi = 1$$

et donc $b'(\theta) = e^\theta = \mu$ (l'espérance) et $b''(\theta) = e^\theta = \mu$ (la variance vaut aussi μ , propriété caractéristique de Poisson).

● Concept 5 — La fonction de lien

POURQUOI IL EN FAUT UNE.

β est le paramètre d'intérêt, et il doit apparaître d'une façon ou d'une autre dans la vraisemblance pour qu'on puisse utiliser le maximum de vraisemblance.

DÉFINITION.

Une **fonction de lien** g relie le prédicteur linéaire $X^\top \beta$ au paramètre de moyenne μ :

$$X^\top \beta = g(\mu), \quad \text{donc} \quad \mu = g^{-1}(X^\top \beta)$$

g doit être **monotone croissante** et **dérivable**.

Les exemples.

Type de réponse	Contrainte	Liens possibles
Modèle linéaire	aucune	$g = \text{identité}$
Poisson ($Y \mid X \sim \text{Poiss}(\mu(X))$)	$\mu(X) > 0$	$\log(\mu(X)) = X^\top \beta$
Bernoulli / binomiale	$0 < \mu < 1$	logit , probit , log-log complémentaire

Pour des données de comptage, une fonction de lien doit envoyer $(0, +\infty)$ sur $\mathbb{R}$: le **lien logarithmique** est le choix naturel.

Pour des données de Bernoulli, g doit envoyer $(0, 1)$ sur $\mathbb{R}$ — trois choix :

$$1. \text{ logit : } \log \left(\frac{\mu(X)}{1 - \mu(X)} \right) = X^\top \beta$$

$$2. \text{ probit : } \Phi^{-1}(\mu(X)) = X^\top \beta \quad \text{où } \Phi \text{ est la fonction de répartition normale}$$

$$3. \text{ log-log complémentaire : } \log(-\log(1 - \mu(X))) = X^\top \beta$$

Le lien **logit** est le choix naturel.

Les fonctions inverses correspondantes sont $f_1(x) = \frac{e^x}{1+e^x}$ (logistique) et $f_2(x) = \Phi(x)$ (répartition gaussienne) — deux courbes en S très proches l'une de l'autre.

Le lien canonique

DÉFINITION.

La fonction g qui relie la moyenne μ au **paramètre canonique** θ s'appelle le **lien canonique** :

$$g(\mu) = \theta$$

Puisque $\mu = b'(\theta)$, le lien canonique est donné par

$$g(\mu) = (b')^{-1}(\mu)$$

Si $\phi > 0$, la fonction de lien canonique est **strictement croissante**. Pourquoi ?

La réponse à la question du cours : $g = (b')^{-1}$ est croissante si et seulement si b' l'est, c'est-à-dire si $b'' > 0$. Or $b''(\theta)\phi = \text{var}(Y) > 0$ et $\phi > 0$, donc $b'' > 0$. **La croissance stricte du lien canonique est une conséquence de la positivité de la variance.**

Exemple — la loi de Bernoulli. On vérifie $b(\theta) = \log(1 + e^\theta)$, donc

$$b'(\theta) = \frac{e^\theta}{1 + e^\theta} = \mu \quad \Longleftrightarrow \quad \theta = \log\left(\frac{\mu}{1 - \mu}\right)$$

Le lien canonique de la loi de Bernoulli est le lien logit.

Le tableau des liens canoniques.

Loi	$b(\theta)$	$g(\mu)$
Normale	$\theta^2/2$	μ (identité)
Poisson	$\exp(\theta)$	$\log \mu$
Bernoulli	$\log(1 + e^\theta)$	$\log \frac{\mu}{1 - \mu}$ (logit)
Gamma	$-\log(-\theta)$	$-\frac{1}{\mu}$

Voilà la réponse à « pourquoi le logit plutôt que le probit ? ». Ce n'est pas une commodité de calcul ni une tradition : le logit **est** le lien canonique de la loi de Bernoulli, celui qui identifie le prédicteur linéaire au paramètre canonique. Le concept suivant montre les deux propriétés remarquables que cela entraîne.

● Concept 6 — Le modèle GLM complet

Le cadre. Soient $(X_i, Y_i) \in \mathbb{R}^p \times \mathbb{R}$, $i = 1, \dots, n$, des couples aléatoires **indépendants** tels que la loi conditionnelle de Y_i sachant $X_i = x_i$ ait une densité dans la famille exponentielle canonique :

$$f_{\theta_i}(y_i) = \exp \left(\frac{y_i \theta_i - b(\theta_i)}{\phi} + c(y_i, \phi) \right)$$

La moyenne μ_i est liée au paramètre canonique par $\mu_i = b'(\theta_i)$, et μ_i dépend **linéairement** des covariables par le lien :

$$g(\mu_i) = X_i^\top \beta$$

Le retour à β . La relation entre β et θ est

$$\theta_i = (b')^{-1}(\mu_i) = (b')^{-1}(g^{-1}(X_i^\top \beta)) \equiv h(X_i^\top \beta), \quad \boxed{h = (b')^{-1} \circ g^{-1} = (g \circ b')^{-1}}$$

REMARQUE DÉCISIVE.

Si g est le **lien canonique**, alors h est l'**identité**.

La log-vraisemblance, à une constante près :

$$\ell_n(\beta; Y, X) = \sum_i \frac{Y_i \theta_i - b(\theta_i)}{\phi} = \sum_i \frac{Y_i h(X_i^\top \beta) - b(h(X_i^\top \beta))}{\phi}$$

et avec le lien canonique, on obtient l'expression plus simple

$$\ell_n(\beta, \phi; Y, X) = \sum_i \frac{Y_i X_i^\top \beta - b(X_i^\top \beta)}{\phi}$$

La stricte concavité. La log-vraisemblance $\ell(\theta)$ est **strictement concave** avec le lien canonique quand $\phi > 0$. Pourquoi ? En conséquence, l'**estimateur du maximum de vraisemblance est unique**. En revanche, si une autre paramétrisation est utilisée, la vraisemblance peut ne pas être strictement concave, ce qui conduit à **plusieurs maxima locaux**.

La réponse à la seconde question du cours. Avec le lien canonique, $\ell_n(\beta) = \sum_i \frac{Y_i X_i^\top \beta - b(X_i^\top \beta)}{\phi}$. Le premier terme est **linéaire** en β , donc de hessienne nulle ; le second a pour hessienne $-\frac{1}{\phi} \sum_i b''(X_i^\top \beta) X_i X_i^\top$. Comme $b'' > 0$ et $\phi > 0$, cette matrice est **définie négative** dès que les X_i engendrent $\mathbb{R}^p$. D'où la stricte concavité, et l'unicité du maximum par le concept 4 de la fiche 64.

C'est la seconde grande propriété du lien canonique, après la simplification de la log-vraisemblance : il **garantit l'unicité de l'EMV**. Avec un autre lien, plusieurs maxima locaux peuvent apparaître, et l'optimisation devient un problème.

● Concept 7 — Newton-Raphson et scores de Fisher

Le problème. Étant donné f définie sur $\mathcal{X} \subset \mathbb{R}^m$, trouver x^* tel que $f(x^*) \geq f(x)$ pour tout x . Trois méthodes : **Newton-Raphson, scores de Fisher, moindres carrés repondérés itérativement**.

Gradient et hessienne. $(\nabla f) = (\partial f / \partial x_1, \dots, \partial f / \partial x_m)^\top$ et $(H_f)_{ij} = \frac{\partial^2 f}{\partial x_i \partial x_j}$. Pour des fonctions régulières, la hessienne est **symétrique**. Si f est strictement concave, $H_f(x)$ est **définie négative**.

L'approximation quadratique.

$$f(x) \approx f(x_0) + \nabla f^\top(x_0)(x - x_0) + \frac{1}{2}(x - x_0)^\top H_f(x_0)(x - x_0)$$

d'où l'approximation du gradient $\nabla f(x) \approx \nabla f(x_0) + H_f(x_0)(x - x_0)$. Si x^* est un maximum, $\nabla f(x^*) = 0$, et l'on résout

$$x^* = x_0 - H_f(x_0)^{-1} \nabla f(x_0)$$

MÉTHODE DE NEWTON-RAPHSON.

Elle utilise ces approximations **séquentiellement** :

$$x^{(k+1)} = x^{(k)} - H_f(x^{(k)})^{-1} \nabla f(x^{(k)})$$

L'algorithme est **globalement convergent à vitesse quadratique** dès que f est concave et deux fois continûment dérivable.

MÉTHODE DES SCORES DE FISHER.

- Newton-Raphson fonctionne pour un cas **déterministe**, sans données aléatoires.
- Parfois, le calcul de la hessienne est assez compliqué.
- **But** : utiliser directement le fait qu'on minimise la divergence KL — $KL \llcorner = \gg - \mathbb{E}[\text{log-vraisemblance}]$.
- **Idée** : remplacer la hessienne par son **espérance**. Or $\mathbb{E}_\theta(H_{\ell_n}(\theta)) = -I(\theta)$ est l'**information de Fisher**.
- La matrice d'information de Fisher est **définie positive** et peut servir de substitut à la hessienne, d'où la mise à jour

$$\theta^{(k+1)} = \theta^{(k)} + I(\theta^{(k)})^{-1} \nabla \ell_n(\theta^{(k)})$$

*C'est l'algorithme des **scores de Fisher**. Il a essentiellement les mêmes propriétés de convergence que Newton-Raphson, mais **I est souvent plus facile à calculer que H_{ℓ_n}** .*

Notez le rappel du cours : on minimise la divergence KL. C'est le fil direct avec la fiche 64 — maximiser la vraisemblance **est** minimiser la KL empirique. Remplacer la hessienne empirique par son espérance revient à passer du critère empirique au critère théorique.

Exemple — la régression logistique

Soient $Y_i \sim \text{Bernoulli}(p_i)$ indépendants et X_i un vecteur $p \times 1$ de prédicteurs. La log-vraisemblance est

$$\ell_n(\theta \mid Y, X) = \sum_{i=1}^n \left(Y_i \theta_i - \log(1 + e^{\theta_i}) \right)$$

Avec le **lien canonique**, $\theta_i = \log\left(\frac{p_i}{1-p_i}\right) = X_i^\top \beta$, d'où

$$\ell_n(\beta \mid Y, X) = \sum_{i=1}^n \left(Y_i X_i^\top \beta - \log(1 + e^{X_i^\top \beta}) \right)$$

Le gradient.

$$\nabla \ell_n(\beta) = \sum_{i=1}^n \left(Y_i - \frac{e^{X_i^\top \beta}}{1 + e^{X_i^\top \beta}} \right) X_i$$

La hessienne.

$$H_{\ell_n}(\beta) = - \sum_{i=1}^n \frac{e^{X_i^\top \beta}}{(1 + e^{X_i^\top \beta})^2} X_i X_i^\top$$

Trois observations du cours.

- *La fonction de score est une **combinaison linéaire des X_i** , et la hessienne (ou la matrice d'information) une **combinaison linéaire des $X_i X_i^\top$** . C'est typique des modèles de régression en famille exponentielle.*
- La hessienne est **définie négative**, donc il y a un unique maximum local, qui est aussi le maximum global.
- **Les Y_i n'apparaissent pas dans $H_{\ell_n}(\beta)$** , ce qui donne

$$H_{\ell_n}(\beta) = \mathbb{E}[H_{\ell_n}(\beta)] = -I(\beta)$$

Cette dernière observation est importante. Sous le lien canonique, la hessienne **ne contient aucun aléa** : elle est égale à son espérance. Donc **Newton-Raphson et les scores de Fisher coïncident exactement**. C'est le troisième avantage du lien canonique.

● Concept 8 — Les moindres carrés repondérés itérativement (IRLS)

IRLS est un algorithme d'ajustement des GLM obtenu par Newton-Raphson / scores de Fisher.

Les quantités à relier. Avec $\ell = \sum_{i=1}^n \frac{Y_i \theta_i - b(\theta_i)}{\phi} + c(Y_i, \phi)$:

$$\mu_i = b'(\theta_i), \quad X_i^\top \beta = g(\mu_i), \quad \frac{d\mu_i}{d\theta_i} = b''(\theta_i) \equiv V_i, \quad \theta_i = h(X_i^\top \beta)$$

Le gradient par la règle de la chaîne.

$$\frac{\partial \ell_n}{\partial \beta_j} = \sum_{i=1}^n \frac{\partial \ell_i}{\partial \theta_i} \frac{\partial \theta_i}{\partial \beta_j} = \sum_i \frac{Y_i - \mu_i}{\phi} h'(X_i^\top \beta) X_{ij} = \sum_i (\tilde{Y}_i - \tilde{\mu}_i) W_i X_{ij}$$

où

$$W_i = \frac{h'(X_i^\top \beta)}{g'(\mu_i)\phi}, \quad \tilde{Y} = (g'(\mu_1)Y_1, \dots, g'(\mu_n)Y_n)^\top, \quad \tilde{\mu} = (g'(\mu_1)\mu_1, \dots, g'(\mu_n)\mu_n)^\top$$

En posant $W = \text{diag}\{W_1, \dots, W_n\}$, le gradient s'écrit

$$\boxed{\nabla \ell_n(\beta) = X^\top W(\tilde{Y} - \tilde{\mu})}$$

L'information de Fisher. L'identité $g^{-1}(\cdot) = b' \circ h(\cdot)$ donne, en dérivant, $b'' \circ h(\cdot) \cdot h'(\cdot) = \frac{1}{g' \circ g^{-1}(\cdot)}$, soit

$$b''(\theta_i) h'(X_i^\top \beta) = \frac{1}{g'(\mu_i)}$$

d'où

$$\mathbb{E}(H_{\ell_n}(\beta)) = - \sum_i \frac{h'(X_i^\top \beta)}{g'(\mu_i)\phi} X_i X_i^\top \quad \Rightarrow \quad \boxed{I(\beta) = -\mathbb{E}(H_{\ell_n}(\beta)) = X^\top W X}$$

avec $W = \text{diag}\left(\frac{h'(X_i^\top \beta)}{g'(\mu_i)\phi}\right)$.

La mise à jour par scores de Fisher.

$$\begin{aligned} \beta^{(k+1)} &= \beta^{(k)} + I(\beta^{(k)})^{-1} \nabla \ell_n(\beta^{(k)}) = \beta^{(k)} + (X^\top W X)^{-1} X^\top W(\tilde{Y} - \tilde{\mu}) \\ &= (X^\top W X)^{-1} X^\top W(\tilde{Y} - \tilde{\mu} + X\beta^{(k)}) \end{aligned}$$

La parenthèse : les moindres carrés pondérés

Supposons le modèle linéaire $Y = X\beta + \varepsilon$ avec $\varepsilon \sim N_n(0, W^{-1})$, W^{-1} diagonale. **Quand les variances sont différentes, la régression est dite hétéroscédastique.** L'EMV est la solution de

$$\min_{\beta} (Y - X\beta)^T W (Y - X\beta)$$

C'est un problème de **moindres carrés pondérés**, de solution

$$\hat{\beta} = (X^T W X)^{-1} X^T W Y$$

Il est implémenté en routine dans les logiciels statistiques.

C'est exactement l'estimateur MCG de la fiche 50, avec $\Sigma^{-1} = W$. Le pont est explicite : les MCG sont des moindres carrés **pondérés par l'inverse des variances**.

La procédure IRLS

IRLS est une procédure itérative pour calculer l'EMV dans les GLM **en utilisant les moindres carrés pondérés**. Pour passer de $\beta^{(k)}$ à $\beta^{(k+1)}$:

1. Fixer $\beta^{(k)}$ et $\mu_i^{(k)} = g^{-1}(X_i^T \beta^{(k)})$. 2. Calculer les **réponses dépendantes ajustées**

$$Z_i^{(k)} = X_i^T \beta^{(k)} + g'(\mu_i^{(k)})(Y_i - \mu_i^{(k)})$$

3. Calculer les **poids**

$$W^{(k)} = \text{diag} \left(\frac{h'(X_i^T \beta^{(k)})}{g'(\mu_i^{(k)})\phi} \right)$$

4. **Régresser** $Z^{(k)}$ sur la matrice de design X avec le poids $W^{(k)}$ pour obtenir $\beta^{(k+1)}$.

On répète jusqu'à convergence.

Deux remarques finales.

- Pour cette procédure, il suffit de connaître X , Y , la **fonction de lien** g et la **fonction de variance** $V(\mu) = b''(\theta)$. Une valeur de départ possible est $\mu^{(0)} = Y$.

- Si le **lien canonique** est utilisé, les scores de Fisher coïncident avec Newton-Raphson : $\mathbb{E}(H_{\ell_n}) = H_{\ell_n}$, il n'y a pas de composante aléatoire (Y) dans la hessienne.

L'élégance d'IRLS tient en une phrase. Ajuster un modèle **non linéaire** — logistique, Poisson, Gamma — se ramène à une **suite de régressions linéaires pondérées**, chacune résoluble par une routine existante. On n'a jamais besoin d'un optimiseur général : la structure de famille exponentielle fournit à chaque pas une pondération et une réponse ajustée, et le reste est du moindre carré ordinaire.

Comment résoudre l'exercice type (protocole)

1. **Identifier la nature de la réponse** : continue $\Rightarrow$ normale · comptage $\Rightarrow$ Poisson · binaire $\Rightarrow$ Bernoulli · positive à variance croissante $\Rightarrow$ Gamma.
2. **Mettre la loi sous forme canonique** $\exp\left(\frac{y\theta - b(\theta)}{\phi} + c(y, \phi)\right)$ et **identifier b et ϕ** .
3. **En déduire $\mu = b'(\theta)$ et $\text{var}(Y) = b''(\theta)\phi$** .
4. **Choisir le lien** — de préférence le lien **canonique** $g = (b')^{-1}$, pour la simplification et l'unicité.
5. **Écrire la log-vraisemblance** : avec le lien canonique, $\ell_n = \sum_i \frac{Y_i X_i^\top \beta - b(X_i^\top \beta)}{\phi}$.
6. **Calculer gradient et hessienne**, ou directement $I(\beta) = X^\top W X$.
7. **Estimer par IRLS** : réponses ajustées, poids, régression pondérée, itérer.
8. **Faire l'inférence** : $I(\hat{\beta})^{-1}$ donne les écarts-types, puis Wald ou rapport de vraisemblance (fiche 65).

Comment reconnaître qu'il faut utiliser cette méthode ?

Indice dans l'énoncé	Ce qu'il faut faire
réponse binaire (oui/non, succès/échec)	Bernoulli + lien logit $\Rightarrow$ régression logistique
réponse de comptage	Poisson + lien log
« croissance exponentielle du nombre de cas »	Poisson, $\log \mu = \beta_0 + \beta_1 t$
« écart-type proportionnel à la moyenne »	Gamma
relation non linéaire en les paramètres	chercher un lien qui la linéarise
« pourquoi le logit ? »	c'est le lien canonique de Bernoulli
« le maximum est-il unique ? »	oui avec le lien canonique (stricte concavité)
« comment ajuster numériquement ? »	IRLS
« variances différentes selon l'observation »	moindres carrés pondérés

Exercices progressifs

Niveau 1 — Mettez la loi de Bernoulli sous forme canonique et déduisez-en le lien canonique.

La densité. $f(y) = p^y(1-p)^{1-y}$ pour $y \in \{0, 1\}$. En passant à l'exponentielle du logarithme :

$$f(y) = \exp(y \log p + (1-y) \log(1-p)) = \exp\left(y \log \frac{p}{1-p} + \log(1-p)\right)$$

L'identification. En comparant à $\exp\left(\frac{y\theta - b(\theta)}{\phi} + c(y, \phi)\right)$:

$$\theta = \log \frac{p}{1-p}, \quad \phi = 1, \quad c(y, \phi) = 0$$

Il reste à exprimer $-\log(1-p)$ en fonction de θ . De $\theta = \log \frac{p}{1-p}$ on tire $e^\theta = \frac{p}{1-p}$, donc $p = \frac{e^\theta}{1+e^\theta}$ et $1-p = \frac{1}{1+e^\theta}$, d'où

$$b(\theta) = -\log(1-p) = \log(1+e^\theta)$$

Les moments.

$$\mu = b'(\theta) = \frac{e^\theta}{1 + e^\theta} = p \quad \checkmark$$

$$\text{var}(Y) = b''(\theta)\phi = \frac{e^\theta}{(1 + e^\theta)^2} = p(1 - p) \quad \checkmark$$

Les deux formules retrouvent les moments connus de Bernoulli.

Le lien canonique. $g = (b')^{-1}$, et l'on a déjà inversé b' :

$$g(\mu) = \log \frac{\mu}{1 - \mu}$$

C'est le lien logit. Il envoie bien $(0, 1)$ sur $\mathbb{R}$, comme l'exigeait l'exemple 3 du concept 1.

Niveau 2 — Pourquoi $\mu = b'(\theta)$ et $\text{var}(Y) = b''(\theta)\phi$?

Les deux identités, conséquences de $\int f_\theta(y)dy \equiv 1$ dérivée une puis deux fois sous l'intégrale :

$$\mathbb{E} \left(\frac{\partial \ell}{\partial \theta} \right) = 0, \quad \mathbb{E} \left(\frac{\partial^2 \ell}{\partial \theta^2} \right) + \mathbb{E} \left(\frac{\partial \ell}{\partial \theta} \right)^2 = 0$$

L'espérance. De $\ell(\theta) = \frac{Y\theta - b(\theta)}{\phi} + c(Y; \phi)$:

$$\frac{\partial \ell}{\partial \theta} = \frac{Y - b'(\theta)}{\phi}$$

La première identité donne

$$0 = \frac{\mathbb{E}(Y) - b'(\theta)}{\phi} \quad \implies \quad \mathbb{E}(Y) = b'(\theta)$$

La variance. On a $\frac{\partial^2 \ell}{\partial \theta^2} = -\frac{b''(\theta)}{\phi}$, et, grâce au résultat précédent,

$$\left(\frac{\partial \ell}{\partial \theta} \right)^2 = \left(\frac{Y - \mathbb{E}(Y)}{\phi} \right)^2$$

dont l'espérance vaut $\frac{\text{var}(Y)}{\phi^2}$. La seconde identité donne

$$0 = -\frac{b''(\theta)}{\phi} + \frac{\text{var}(Y)}{\phi^2} \quad \implies \quad \text{var}(Y) = b''(\theta)\phi$$

Ce qu'il faut retenir. Une seule fonction b encode toute la loi : sa dérivée première donne la moyenne, sa dérivée seconde la variance. C'est ce qui rend la théorie des GLM si compacte.

Et la conséquence structurelle. Puisque $\mu = b'(\theta)$, la variance $b''(\theta)\phi$ est une **fonction de la moyenne** : $V(\mu)$. Dans un GLM, on ne choisit **pas** séparément la moyenne et la variance — la famille impose leur relation. Pour Poisson, $V(\mu) = \mu$; pour Bernoulli, $V(\mu) = \mu(1 - \mu)$; pour la normale, $V(\mu) = \sigma^2$, constante. C'est précisément ce que l'exemple 2 du concept 1 exploitait en choisissant Gamma pour obtenir un écart-type proportionnel à la moyenne.

Niveau 3 — Quels sont les trois avantages du lien canonique ?

Le lien canonique est $g = (b')^{-1}$, c'est-à-dire celui qui identifie le prédicteur linéaire au **paramètre canonique** : $\theta_i = X_i^\top \beta$.

Avantage 1 — la log-vraisemblance se simplifie. En général $\theta_i = h(X_i^\top \beta)$ avec $h = (g \circ b')^{-1}$, et

$$\ell_n(\beta) = \sum_i \frac{Y_i h(X_i^\top \beta) - b(h(X_i^\top \beta))}{\phi}$$

Avec le lien canonique, **h est l'identité** et

$$\ell_n(\beta) = \sum_i \frac{Y_i X_i^\top \beta - b(X_i^\top \beta)}{\phi}$$

Avantage 2 — la stricte concavité, donc l'unicité. La hessienne vaut

$$H_{\ell_n}(\beta) = -\frac{1}{\phi} \sum_i b''(X_i^\top \beta) X_i X_i^\top$$

Comme $b''(\theta)\phi = \text{var}(Y) > 0$ et $\phi > 0$, on a $b'' > 0$, donc H_{ℓ_n} est **définie négative** dès que les X_i engendrent $\mathbb{R}^p$. La log-vraisemblance est **strictement concave** et l'EMV est **unique**.

Le cours souligne le contraste : *si une autre paramétrisation est utilisée, la vraisemblance peut ne pas être strictement concave, ce qui conduit à plusieurs maxima locaux.*

Avantage 3 — Newton-Raphson = scores de Fisher. La hessienne ci-dessus **ne contient pas les Y_i** : elle est déterministe, donc égale à son espérance :

$$H_{\ell_n}(\beta) = \mathbb{E}[H_{\ell_n}(\beta)] = -I(\beta)$$

Les deux algorithmes **coïncident exactement**, et l'on n'a pas à choisir.

La conclusion pratique. C'est pour ces trois raisons que le **logit** est le lien standard de la régression binaire, et le **log** celui de la régression de Poisson. Le probit reste utilisé — notamment en économétrie, pour son interprétation en variable latente gaussienne — mais il perd ces trois propriétés.

Niveau 4 — type examen — Décrivez l'algorithme IRLS et expliquez pourquoi il fonctionne.

Le point de départ : les scores de Fisher.

$$\beta^{(k+1)} = \beta^{(k)} + I(\beta^{(k)})^{-1} \nabla \ell_n(\beta^{(k)})$$

Les deux quantités, calculées par la règle de la chaîne. Avec $\mu_i = b'(\theta_i)$, $X_i^\top \beta = g(\mu_i)$ et $\theta_i = h(X_i^\top \beta)$:

$$\frac{\partial \ell_n}{\partial \beta_j} = \sum_i \frac{Y_i - \mu_i}{\phi} h'(X_i^\top \beta) X_{ij} = \sum_i (\tilde{Y}_i - \tilde{\mu}_i) W_i X_{ij}$$

avec $W_i = \frac{h'(X_i^\top \beta)}{g'(\mu_i)\phi}$, $\tilde{Y}_i = g'(\mu_i)Y_i$ et $\tilde{\mu}_i = g'(\mu_i)\mu_i$. En posant $W = \text{diag}(W_i)$:

$$\nabla \ell_n(\beta) = X^\top W(\tilde{Y} - \tilde{\mu}), \quad I(\beta) = X^\top W X$$

La mise à jour devient donc

$$\beta^{(k+1)} = \beta^{(k)} + (X^\top W X)^{-1} X^\top W(\tilde{Y} - \tilde{\mu}) = (X^\top W X)^{-1} X^\top W(\tilde{Y} - \tilde{\mu} + X\beta^{(k)})$$

La reconnaissance décisive. Le membre de droite a **exactement** la forme de la solution des moindres carrés pondérés

$$\hat{\beta} = (X^\top W X)^{-1} X^\top W Z$$

avec W pour matrice de poids et $Z = \tilde{Y} - \tilde{\mu} + X\beta^{(k)}$ pour réponse. On peut donc obtenir $\beta^{(k+1)}$ par n'importe quel solveur de moindres carrés pondérés.

L'algorithme, en quatre étapes.

1. Fixer $\beta^{(k)}$ et $\mu_i^{(k)} = g^{-1}(X_i^\top \beta^{(k)})$.
2. Calculer les **réponses ajustées** $Z_i^{(k)} = X_i^\top \beta^{(k)} + g'(\mu_i^{(k)})(Y_i - \mu_i^{(k)})$.
3. Calculer les **poids** $W^{(k)} = \text{diag}\left(\frac{h'(X_i^\top \beta^{(k)})}{g'(\mu_i^{(k)})\phi}\right)$.
4. **Régresser** $Z^{(k)}$ **sur** X **avec les poids** $W^{(k)} \Rightarrow \beta^{(k+1)}$. Répéter jusqu'à convergence.

Pourquoi cela fonctionne — l'interprétation des étapes 2 et 3.

- La **réponse ajustée** $Z_i^{(k)}$ est le prédicteur linéaire courant, **corrigé du résidu transporté sur l'échelle du lien** par le facteur $g'(\mu_i)$. C'est une linéarisation locale du modèle : on ramène Y_i sur l'échelle où le modèle est linéaire.
- Le **poids** W_i est d'autant plus grand que l'observation est informative — il décroît quand la variance locale augmente. C'est la correction d'**hétéroscédasticité** de la fiche 50, appliquée localement : la variance d'un GLM dépend de la moyenne, donc varie d'une observation à l'autre.

Ce qu'il faut savoir ajouter.

- Il suffit de connaître X, Y , la **fonction de lien** g et la **fonction de variance** $V(\mu) = b''(\theta)$. Un seul algorithme sert donc à toutes les familles — il suffit de changer g et V . C'est ce qui explique l'universalité des implémentations (`glm` en R, etc.).
- Une valeur de départ possible est $\mu^{(0)} = Y$.
- Si le **lien canonique** est utilisé, les scores de Fisher coïncident avec Newton-Raphson, puisque $\mathbb{E}(H_{\ell_n}) = H_{\ell_n}$ — la hessienne ne contient pas Y .

La leçon de méthode. Un problème d'optimisation **non linéaire** est transformé en une **suite de problèmes linéaires** déjà résolus. C'est exactement l'esprit de Newton (fiche 39) : approcher localement par une forme quadratique, résoudre exactement l'approximation, itérer.

● Common mistakes

1. **Écrire** $\mu(X) = X^\top \beta$ **pour une réponse bornée** — le membre de droite parcourt $\mathbb{R}$, il faut un **lien**.
2. **Confondre** θ et μ — θ est le paramètre **canonique**, $\mu = b'(\theta)$ la moyenne. Ils coïncident seulement pour la normale.
3. **Croire qu'on choisit la variance librement** — elle vaut $b''(\theta)\phi$, donc c'est une **fonction de la moyenne**.
4. **Oublier le facteur** ϕ dans $\text{var}(Y) = b''(\theta)\phi$.
5. **Croire que logit et probit sont interchangeables** — le **logit est le lien canonique** de Bernoulli, avec les trois avantages du concept 6.
6. **Croire que la log-vraisemblance est toujours concave** — c'est garanti **avec le lien canonique** ; sinon plusieurs maxima locaux sont possibles.
7. **Confondre Newton-Raphson et scores de Fisher** — le second remplace H_{ℓ_n} par $-I(\theta)$, son espérance. Ils **coïncident** sous le lien canonique.

8. **Se tromper de signe dans les mises à jour** — Newton : $x - H^{-1}\nabla$; Fisher : $\theta + I^{-1}\nabla$ (les signes se compensent, puisque $I = -\mathbb{E}[H]$).
9. **Oublier la pondération dans IRLS** — c'est elle qui corrige l'hétéroscédasticité propre au GLM.

Ultimate Review

1. **Modèle linéaire** : $Y \mid X \sim N(\mu(X), \sigma^2 I)$ et $\mu(X) = X^\top \beta$. Ses **deux composantes** : aléatoire (gaussienne) et lien (identité).
2. **GLM** : composante aléatoire dans une **famille exponentielle**, et lien $g(\mu(X)) = X^\top \beta$.
3. **Famille exponentielle à k paramètres** : $p_\theta(x) = \exp \left[\sum_i \eta_i(\theta) T_i(x) - B(\theta) \right] h(x)$.
4. **Forme canonique à un paramètre** : $f_\theta(y) = \exp \left(\frac{y\theta - b(\theta)}{\phi} + c(y, \phi) \right)$; θ **canonique**, ϕ **dispersion** (supposé connu).
5. **Tableau** : normale $b = \theta^2/2$, $\phi = \sigma^2$ · Poisson $b = e^\theta$, $\phi = 1$ · Bernoulli $b = \log(1 + e^\theta)$, $\phi = 1$.
6. **Deux identités** : $\mathbb{E}(\partial_\theta \ell) = 0$ et $\mathbb{E}(\partial_\theta^2 \ell) + \mathbb{E}(\partial_\theta \ell)^2 = 0$, issues de $\int f_\theta = 1$.
7. **Les deux formules maîtresses** : $\mu = b'(\theta)$ et $\text{var}(Y) = b''(\theta)\phi$.
8. **Fonction de lien** : $X^\top \beta = g(\mu)$, g monotone croissante et dérivable ; identité (normale), **log** (Poisson), **logit / probit / log-log complémentaire** (Bernoulli).
9. **Lien canonique** : $g = (b')^{-1}$, donc $g(\mu) = \theta$; **strictement croissant** car $b'' > 0$.
10. **Liens canoniques** : normale μ · Poisson **log** μ · Bernoulli **log** $\frac{\mu}{1-\mu}$ · Gamma $-1/\mu$.
11. **Le modèle** : $\theta_i = h(X_i^\top \beta)$ avec $h = (g \circ b')^{-1}$; $h = \text{identité}$ si g est canonique.
12. **Log-vraisemblance** : $\sum_i \frac{Y_i h(X_i^\top \beta) - b(h(X_i^\top \beta))}{\phi}$, qui devient $\sum_i \frac{Y_i X_i^\top \beta - b(X_i^\top \beta)}{\phi}$ sous lien canonique.
13. **Stricte concavité** sous lien canonique et $\phi > 0 \Rightarrow$ **EMV unique**.
14. **Newton-Raphson** : $x^{(k+1)} = x^{(k)} - H_f^{-1} \nabla f$; convergence **quadratique** si f concave.
15. **Scores de Fisher** : $\theta^{(k+1)} = \theta^{(k)} + I(\theta^{(k)})^{-1} \nabla \ell_n$; on remplace H par $\mathbb{E}[H] = -I$, souvent plus facile à calculer.
16. **Régression logistique** : $\nabla \ell_n = \sum_i (Y_i - \frac{e^{X_i^\top \beta}}{1+e^{X_i^\top \beta}}) X_i$ et $H_{\ell_n} = - \sum_i \frac{e^{X_i^\top \beta}}{(1+e^{X_i^\top \beta})^2} X_i X_i^\top$; **Y absent de H** .
17. **IRLS** : $\nabla \ell_n = X^\top W(\tilde{Y} - \tilde{\mu})$, $I(\beta) = X^\top W X$, d'où $\beta^{(k+1)} = (X^\top W X)^{-1} X^\top W(\tilde{Y} - \tilde{\mu} + X\beta^{(k)})$.
18. **Moindres carrés pondérés** : $\min_\beta (Y - X\beta)^\top W(Y - X\beta)$, de solution $(X^\top W X)^{-1} X^\top W Y$ — les **MCG** de la fiche 50.
19. **Procédure IRLS** : $\mu^{(k)}$ · réponses ajustées $Z^{(k)}$ · poids $W^{(k)}$ · **régression pondérée** $\Rightarrow \beta^{(k+1)}$.
20. **Ce qu'il suffit de connaître** : X, Y , le lien g et la **fonction de variance** $V(\mu) = b''(\theta)$; départ $\mu^{(0)} = Y$.

Formulas to know

$$f_{\theta}(y) = \exp \left(\frac{y\theta - b(\theta)}{\phi} + c(y, \phi) \right) \quad \mu = b'(\theta) \quad \text{var}(Y) = b''(\theta)\phi$$

$$g(\mu) = X^{\top} \beta \quad g_{\text{canonique}} = (b')^{-1} \quad \text{logit}(\mu) = \log \frac{\mu}{1 - \mu}$$

$$\nabla \ell_n(\beta) = X^{\top} W(\tilde{Y} - \tilde{\mu}) \quad I(\beta) = X^{\top} W X \quad \beta^{(k+1)} = (X^{\top} W X)^{-1} X^{\top} W Z^{(k)}$$

Methods to know : mettre une loi sous forme canonique ; dériver μ et **var** par les deux identités ; établir que le logit est canonique pour Bernoulli ; la procédure IRLS en quatre étapes.

Active Recall

Basic — Écrivez la forme canonique de la famille exponentielle et donnez moyenne et variance.

$$f_{\theta}(y) = \exp \left(\frac{y\theta - b(\theta)}{\phi} + c(y, \phi) \right)$$

où θ est le **paramètre canonique** et ϕ le **paramètre de dispersion** (supposé connu).

Les moments s'obtiennent par les deux identités issues de $\int f_{\theta} = 1$:

$$\mathbb{E}(Y) = \mu = b'(\theta), \quad \text{var}(Y) = b''(\theta)\phi$$

Une seule fonction b encode toute la loi — et comme $\mu = b'(\theta)$, la variance est nécessairement une **fonction de la moyenne**.

Understanding — Pourquoi faut-il une fonction de lien ?

Parce que le prédicteur linéaire $X^{\top} \beta$ parcourt **tout** $\mathbb{R}$, alors que la moyenne μ est souvent **contrainte** :

- Bernoulli : $\mu \in (0, 1)$;
- Poisson : $\mu > 0$;
- Gamma : $\mu > 0$.

Écrire $\mu(X) = X^\top \beta$ produirait des valeurs impossibles. Le cours le dit pour les données Kyphosis : *on ne peut pas écrire $\mu(X) = X^\top \beta$ parce que le membre de droite parcourt $\mathbb{R}$; il faut une fonction inversible f telle que $f(X^\top \beta) \in (0, 1)$.*

La solution : une fonction g **monotone croissante et dérivable** telle que

$$g(\mu) = X^\top \beta \quad \Longleftrightarrow \quad \mu = g^{-1}(X^\top \beta)$$

avec g envoyant le domaine de μ sur $\mathbb{R}$ tout entier. Pour un comptage, **log** envoie $(0, \infty)$ sur $\mathbb{R}$; pour une proportion, le **logit** envoie $(0, 1)$ sur $\mathbb{R}$.

Bonus : le lien peut aussi **linéariser** une relation non linéaire — c'est l'exemple 2 du cours, où le lien réciproque $1/\mu$ transforme $\mu = \frac{\alpha x}{h+x}$ en une relation affine en $1/x$.

Application — Quel GLM pour un nombre de sinistres par assuré ?

La réponse est un comptage : $Y \in \{0, 1, 2, \dots\}$. La loi naturelle est **Poisson**.

La forme canonique. $f(y) = \frac{\mu^y e^{-\mu}}{y!} = \exp(y \log \mu - \mu - \log(y!))$, d'où

$$\theta = \log \mu, \quad b(\theta) = e^\theta, \quad \phi = 1, \quad c(y, \phi) = -\log(y!)$$

Les moments. $b'(\theta) = e^\theta = \mu$ et $\text{var}(Y) = b''(\theta)\phi = e^\theta = \mu$ — la variance **égale** la moyenne, propriété caractéristique de Poisson.

Le lien canonique. $g = (b')^{-1}$, soit $g(\mu) = \log \mu$. Le modèle s'écrit donc

$$\log(\mu(X)) = X^\top \beta \quad \Longleftrightarrow \quad \mu(X) = e^{X^\top \beta}$$

ce qui garantit $\mu > 0$ automatiquement.

L'interprétation, qui est le grand avantage du lien log. Les coefficients s'interprètent **multiplicativement** : augmenter $X^{(j)}$ d'une unité multiplie le nombre espéré de sinistres par e^{β_j} . C'est exactement le langage de la tarification en assurance.

La limite à connaître. Poisson impose $\text{var}(Y) = \mu$. En assurance, on observe presque toujours une **surdispersion** — variance supérieure à la moyenne. On passe alors à une **binomiale négative** (elle aussi de famille exponentielle), ou l'on introduit un paramètre de dispersion $\phi > 1$.

Comparison — Newton-Raphson, scores de Fisher, IRLS : quelle différence ?

	Newton-Raphson	Scores de Fisher	IRLS
Mise à jour	$x - H_f^{-1} \nabla f$	$\theta + I(\theta)^{-1} \nabla \ell_n$	régression pondérée
Matrice utilisée	hessienne empirique H_{ℓ_n}	son espérance $-I(\theta)$	$X^\top W X$
Contient Y ?	oui en général	non	non
Outil requis	optimiseur	optimiseur	solveur de MCP

Newton-Raphson est la méthode générale : approximation quadratique locale, résolution exacte, itération. Convergence **quadratique** si f est concave.

Les scores de Fisher remplacent H_{ℓ_n} par son espérance $-I(\theta)$. Motivation du cours : *le calcul de la hessienne est parfois assez compliqué*, et I est **définie positive**, donc un substitut sûr. Mêmes propriétés de convergence.

IRLS est la **mise en œuvre concrète** des scores de Fisher pour les GLM. En développant, on trouve

$$\beta^{(k+1)} = (X^\top W X)^{-1} X^\top W (\tilde{Y} - \tilde{\mu} + X \beta^{(k)})$$

qui a exactement la forme d'une solution de **moindres carrés pondérés**. On n'a donc besoin d'aucun optimiseur : une routine de régression pondérée suffit.

Le cas particulier remarquable. Avec le **lien canonique**, la hessienne ne contient pas Y :

$$H_{\ell_n}(\beta) = \mathbb{E}[H_{\ell_n}(\beta)] = -I(\beta)$$

et les trois méthodes **coïncident**.

Exam-style — Construisez complètement la régression logistique comme GLM.

1. La composante aléatoire. $Y_i | X_i \sim \text{Bernoulli}(p_i)$, indépendants. La densité s'écrit

$$f(y) = p^y(1-p)^{1-y} = \exp \left(y \log \frac{p}{1-p} + \log(1-p) \right)$$

soit, sous forme canonique,

$$\theta = \log \frac{p}{1-p}, \quad b(\theta) = \log(1 + e^\theta), \quad \phi = 1, \quad c(y, \phi) = 0$$

2. Les moments. $\mu = b'(\theta) = \frac{e^\theta}{1+e^\theta} = p$ et $\text{var}(Y) = b''(\theta)\phi = \frac{e^\theta}{(1+e^\theta)^2} = p(1-p)$.

3. Le lien canonique. $g = (b')^{-1}$, donc

$$g(\mu) = \log \frac{\mu}{1-\mu} = \text{logit}(\mu)$$

Le modèle est $\text{logit}(p_i) = X_i^\top \beta$, soit $p_i = \frac{e^{X_i^\top \beta}}{1+e^{X_i^\top \beta}} \in (0, 1)$ automatiquement.

4. La log-vraisemblance. Comme h est l'identité sous lien canonique, $\theta_i = X_i^\top \beta$ et

$$\ell_n(\beta | Y, X) = \sum_{i=1}^n \left(Y_i X_i^\top \beta - \log(1 + e^{X_i^\top \beta}) \right)$$

5. Le gradient.

$$\nabla \ell_n(\beta) = \sum_{i=1}^n \left(Y_i - \frac{e^{X_i^\top \beta}}{1 + e^{X_i^\top \beta}} \right) X_i = \sum_i (Y_i - p_i) X_i = X^\top (Y - p)$$

C'est une **combinaison linéaire des X_i** , pondérée par les résidus.

6. La hessienne.

$$H_{\ell_n}(\beta) = - \sum_{i=1}^n \frac{e^{X_i^\top \beta}}{(1 + e^{X_i^\top \beta})^2} X_i X_i^\top = - \sum_i p_i(1-p_i) X_i X_i^\top = -X^\top W X$$

avec $W = \text{diag}(p_i(1-p_i))$ — c'est **exactement la fonction de variance** $V(\mu) = \mu(1-\mu)$.

7. Les trois observations du cours.

- Score linéaire en X_i , information linéaire en $X_i X_i^\top$: *typique des modèles de régression en famille exponentielle.*

- Hessienne **définie négative** $\Rightarrow$ maximum local unique, qui est le maximum global.
- Y n'apparaît pas dans $H_{\ell_n} \Rightarrow H_{\ell_n}(\beta) = \mathbb{E}[H_{\ell_n}(\beta)] = -I(\beta)$, donc **Newton-Raphson** = **scores de Fisher**.

8. L'estimation par IRLS. Avec $g'(\mu) = \frac{1}{\mu(1-\mu)}$:

- réponse ajustée : $Z_i^{(k)} = X_i^\top \beta^{(k)} + \frac{Y_i - p_i^{(k)}}{p_i^{(k)}(1 - p_i^{(k)})}$;
- poids : $W_i^{(k)} = p_i^{(k)}(1 - p_i^{(k)})$;
- régresser $Z^{(k)}$ sur X avec les poids $W^{(k)}$, itérer.

9. L'inférence. $I(\hat{\beta}) = X^\top W X$ donne les écarts-types asymptotiques, d'où les tests de **Wald** et du **rapport de vraisemblance** de la fiche 65.

Le point d'interprétation à ne pas manquer. β_j est l'effet sur le **log-odds** : augmenter $X^{(j)}$ d'une unité multiplie la cote $\frac{p}{1-p}$ par e^{β_j} . C'est l'**odds ratio**, la quantité universellement rapportée en épidémiologie et en économétrie du choix discret.

Et la remarque sur les poids. $W_i = p_i(1 - p_i)$ est **maximal en $p_i = 1/2$** et tend vers 0 quand $p_i \rightarrow 0$ ou 1. Les observations dont l'issue est presque certaine apportent peu d'information — ce sont les cas « incertains » qui déterminent les coefficients.

Flashcards

Question	Réponse
Les deux composantes d'un modèle linéaire ?	Composante aléatoire (gaussienne) et lien (identité)
Ce que généralise un GLM ?	La loi (famille exponentielle) et le lien $g(\mu) = X^T \beta$
Forme canonique de la famille exponentielle ?	$\exp\left(\frac{y\theta - b(\theta)}{\phi} + c(y, \phi)\right)$
Nom de θ ?	Paramètre canonique
Nom de ϕ ?	Paramètre de dispersion
Première identité ?	$\mathbb{E}(\partial \ell / \partial \theta) = 0$
Seconde identité ?	$\mathbb{E}(\partial^2 \ell / \partial \theta^2) + \mathbb{E}(\partial \ell / \partial \theta)^2 = 0$
Expression de la moyenne ?	$\mu = b'(\theta)$
Expression de la variance ?	$\text{var}(Y) = b''(\theta)\phi$
$b(\theta)$ pour la normale ?	$\theta^2/2$
$b(\theta)$ pour Poisson ?	e^θ
$b(\theta)$ pour Bernoulli ?	$\log(1 + e^\theta)$
ϕ pour Poisson et Bernoulli ?	1
Rôle de la fonction de lien ?	Relier $X^T \beta \in \mathbb{R}$ à μ contrainte
Propriétés exigées de g ?	Monotone croissante et dérivable
Lien naturel pour un comptage ?	log
Les trois liens pour Bernoulli ?	logit , probit , log-log complémentaire
Définition du lien canonique ?	$g(\mu) = \theta$, soit $g = (b')^{-1}$
Pourquoi est-il croissant ?	Car $b''\phi = \text{var}(Y) > 0$
Lien canonique de Bernoulli ?	Le logit $\log \frac{\mu}{1-\mu}$
Lien canonique de Poisson ?	log μ

Question	Réponse
Lien canonique de Gamma ?	$-1/\mu$
Que vaut $\boldsymbol{h}$?	$(\boldsymbol{g} \circ \boldsymbol{b}')^{-1}$; l' identité si $\boldsymbol{g}$ est canonique
Log-vraisemblance sous lien canonique ?	$\sum_i \frac{\boldsymbol{Y}_i \boldsymbol{X}_i^\top \boldsymbol{\beta} - b(\boldsymbol{X}_i^\top \boldsymbol{\beta})}{\phi}$
Pourquoi l'EMV est-il unique ?	Stricte concavité sous lien canonique
Mise à jour de Newton-Raphson ?	$\boldsymbol{x}^{(k+1)} = \boldsymbol{x}^{(k)} - \boldsymbol{H}_f^{-1} \nabla f$
Mise à jour des scores de Fisher ?	$\boldsymbol{\theta}^{(k+1)} = \boldsymbol{\theta}^{(k)} + \boldsymbol{I}(\boldsymbol{\theta}^{(k)})^{-1} \nabla \ell_n$
Pourquoi préférer $\boldsymbol{I}$ à $\boldsymbol{H}$?	Elle est définie positive et souvent plus simple
Gradient de la logistique ?	$\sum_i \left(Y_i - \frac{e^{\boldsymbol{x}_i^\top \boldsymbol{\beta}}}{1 + e^{\boldsymbol{x}_i^\top \boldsymbol{\beta}}} \right) \boldsymbol{X}_i$
Particularité de sa hessienne ?	Elle ne contient pas $\boldsymbol{Y} \Rightarrow$ Newton = Fisher
Gradient sous forme matricielle ?	$\boldsymbol{X}^\top \boldsymbol{W} (\tilde{\boldsymbol{Y}} - \tilde{\boldsymbol{\mu}})$
Information de Fisher d'un GLM ?	$\boldsymbol{I}(\boldsymbol{\beta}) = \boldsymbol{X}^\top \boldsymbol{W} \boldsymbol{X}$
Solution des moindres carrés pondérés ?	$(\boldsymbol{X}^\top \boldsymbol{W} \boldsymbol{X})^{-1} \boldsymbol{X}^\top \boldsymbol{W} \boldsymbol{Y}$
Les quatre étapes d'IRLS ?	$\boldsymbol{\mu}^{(k)}$ · réponses ajustées · poids · régression pondérée
Réponse ajustée ?	$\boldsymbol{Z}_i = \boldsymbol{X}_i^\top \boldsymbol{\beta} + \boldsymbol{g}'(\boldsymbol{\mu}_i)(Y_i - \boldsymbol{\mu}_i)$
Que suffit-il de connaître pour IRLS ?	$\boldsymbol{X}$, $\boldsymbol{Y}$, le lien $\boldsymbol{g}$ et la variance $\boldsymbol{V}(\boldsymbol{\mu}) = \boldsymbol{b}''(\boldsymbol{\theta})$