

Fiche 67 — Inférence paramétrique : estimateurs, intervalles de confiance et méthode des moments

Matière	Maths · Économétrie
Cours source	Rigollet, <i>18.650 Statistics for Applications</i> , MIT OpenCourseWare, automne 2016 — chapitre 2 « Parametric Inference » et chapitre 4 « The Method of Moments »
Difficulté	High — le vocabulaire et les outils de base de toute l'inférence
Temps d'étude estimé	2 h 15
Prérequis	Loi des grands nombres, théorème central limite, fiche 64 (maximum de vraisemblance)
Concepts clés	Modèle statistique, identifiabilité, statistique et estimateur, consistance, biais, risque quadratique, intervalle de confiance, théorème de Weierstrass, quadrature gaussienne, déterminant de Vandermonde, méthode des moments, méthode delta multivariée
Poids à l'examen	Trois choses : la décomposition risque = biais ² + variance ; la construction d'un intervalle de confiance et le problème du paramètre inconnu dans les bornes ; et la méthode des moments avec sa loi asymptotique.

Vue d'ensemble

Le raisonnement de la modélisation statistique. Soient $X_1, \dots, X_n$ des copies indépendantes de X . *Le but de la statistique est d'**apprendre la loi de X** .*

- Si $X \in \{0, 1\}$, c'est facile : c'est une **Ber**(p) et il n'y a que le paramètre p à apprendre.
- Cela peut être plus compliqué. Le cours donne un jeu de données réel : le **nombre de frères et sœurs** (soi-même inclus) relevé auprès d'étudiants —
2, 3, 2, 4, 1, 3, 1, 1, 1, 1, 1, 2, 2, 3, 2, 2, 2, 3, 2, 1, 3, 1, 2, 3, ...

Deux stratégies.

- Ne faire **aucune hypothèse** et tenter d'apprendre la fonction de masse :

x	1	2	3	4	5	6	≥ 7
$\mathbb{P}(X = x)$	p_1	p_2	p_3	p_4	p_5	p_6	$\sum_{i \geq 7} p_i$

Cela fait **7 paramètres** à apprendre.

- Ou supposer $X \sim \text{Poiss}(\lambda)$. Cela fait **1 paramètre** à apprendre !

MODÈLE $(E, (P_\theta)_{\theta \in \Theta})$ – on suppose $P = P_{\{\theta^*\}}$
 IDENTIFIABLE $\theta \mapsto P_\theta$ injective – sinon rien n'est estimable
 ESTIMATEUR toute statistique ne dépendant pas de θ
 QUALITÉ risque quadratique = biais² + variance
 INCERTITUDE intervalle de confiance de niveau $1 - \alpha$
 DEUX MÉTHODES maximum de vraisemblance (fiche 64) • MÉTHODE DES MOMENTS

L'arbitrage fondateur, posé dès la première page. Modéliser, c'est échanger de la généralité contre de la précision. Sept paramètres n'imposent presque rien mais s'estiment mal ; un seul paramètre impose beaucoup mais s'estime bien. Tout le reste du cours vit dans cet arbitrage.

● Concept 1 — Le modèle statistique

DÉFINITION FORMELLE.

Soit le résultat observé d'une expérience statistique un échantillon $X_1, \dots, X_n$ de n variables i.i.d. dans un espace mesurable E (généralement $E \subseteq \mathbb{R}$), de loi commune $\mathbb{P}$. Un **modèle statistique** associé est un couple

$$(E, (\mathbb{P}_\theta)_{\theta \in \Theta})$$

où E est l'**espace d'échantillonnage**, $(\mathbb{P}_\theta)_{\theta \in \Theta}$ une **famille de mesures de probabilité** sur E , et Θ un ensemble quelconque appelé **ensemble de paramètres**.

- On suppose généralement le modèle **bien spécifié**, c'est-à-dire défini de sorte que $\mathbb{P} = \mathbb{P}_\theta$ pour un certain $\theta \in \Theta$.
- Ce θ particulier est le **vrai paramètre**, et il est **inconnu**. Le but de l'expérience est de l'**estimer**, ou de vérifier ses propriétés lorsqu'elles ont un sens particulier ($\theta > 2$? $\theta = 1/2$?).

- On supposera toujours $\Theta \subseteq \mathbb{R}^d$ pour un $d \geq 1$: le modèle est alors dit **paramétrique**.

Les quatre exemples du cours.

Situation	Modèle
n épreuves de Bernoulli	$(\{0, 1\}, (\text{Ber}(p))_{p \in (0,1)})$
$X_i \stackrel{iid}{\sim} \text{Exp}(\lambda), \lambda > 0$ inconnu	$(\mathbb{R}_+^*, (\text{Exp}(\lambda))_{\lambda > 0})$
$X_i \stackrel{iid}{\sim} \text{Poiss}(\lambda)$	$(\mathbb{N}, (\text{Poiss}(\lambda))_{\lambda > 0})$
$X_i \stackrel{iid}{\sim} N(\mu, \sigma^2)$	$(\mathbb{R}, (N(\mu, \sigma^2))_{(\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}_+^*})$

« **Bien spécifié** » est une **hypothèse, pas un fait**. Elle affirme que la vraie loi appartient à la famille choisie. Si le nombre de frères et sœurs n'est **pas** de Poisson, aucune valeur de λ ne décrit correctement les données, et tout ce qui suit est faux. C'est pourquoi le chapitre sur les tests d'adéquation existe.

● Concept 2 — L'identifiabilité

DÉFINITION.

Le paramètre θ est **identifié** si et seulement si l'application $\theta \in \Theta \mapsto \mathbb{P}_\theta$ est **injective** :

$$\theta \neq \theta' \implies \mathbb{P}_\theta \neq \mathbb{P}_{\theta'}$$

Exemples.

- Dans les quatre exemples précédents, le paramètre est identifié.
- Si $X_i = \mathbf{1}_{Y_i \geq 0}$, où $Y_1, \dots, Y_n \stackrel{iid}{\sim} N(\mu, \sigma^2)$ sont **non observés**, alors μ et σ^2 **ne sont pas identifiés** — mais $\theta = \mu/\sigma$ l'est.

Comprenez le contre-exemple, il est instructif. On n'observe que le **signe** de Y_i , donc la seule information disponible est

$$\mathbb{P}(X_i = 1) = \mathbb{P}(Y_i \geq 0) = \Phi\left(\frac{\mu}{\sigma}\right)$$

Toute la loi observable ne dépend que du **rapport** μ/σ . Doubler μ et σ simultanément ne change **rien** aux données. Aucune quantité de données ne permettra donc de séparer μ de σ : ils ne sont pas identifiés, alors que leur rapport l'est.

C'est exactement le modèle probit de la fiche 66, et cela explique pourquoi on y normalise toujours $\sigma = 1$: sans cette normalisation, le modèle serait inestimable. L'identifiabilité est aussi l'hypothèse 1 du théorème asymptotique de la fiche 64 — sans elle, l'EMV ne peut converger vers rien de précis.

● Concept 3 — Statistiques, estimateurs et consistance

Statistique : toute fonction **mesurable** de l'échantillon — par exemple $\bar{X}_n$, $\max_i X_i$, $X_1 + \log(1 + |X_n|)$, la variance empirique, etc.

Règle empirique donnée par le cours : si vous pouvez la calculer exactement une fois les données connues, elle est mesurable.

Estimateur de θ : *toute statistique dont l'expression **ne dépend pas de θ** .*

Consistance. Un estimateur $\hat{\theta}_n$ de θ est **faiblement** (resp. **fortement**) **consistant** si et seulement si

$$\hat{\theta}_n \xrightarrow[n \rightarrow \infty]{\mathbb{P} \text{ (resp. p.s.)}} \theta \quad \text{par rapport à } \mathbb{P}_\theta$$

La condition « ne dépend pas de θ » est ce qui distingue un estimateur d'une simple statistique. $\bar{X}_n - \theta$ est une fonction parfaitement calculable si l'on connaît θ — mais on ne le connaît pas. Un estimateur doit être calculable à partir des seules données. C'est précisément le problème que soulève l'exemple d'intervalle de confiance du concept 5.

● Concept 4 — Biais et risque quadratique

Biais d'un estimateur $\hat{\theta}_n$ de θ :

$$\mathbb{E}[\hat{\theta}_n] - \theta$$

Risque (ou risque quadratique) d'un estimateur $\hat{\theta}_n$:

$$\mathbb{E}[|\hat{\theta}_n - \theta|^2]$$

REMARQUE.

Si $\Theta \subseteq \mathbb{R}$,

$$\text{risque quadratique} = \text{biais}^2 + \text{variance}$$

Cette décomposition est l'un des énoncés les plus utiles de toute la statistique. Elle se démontre en une ligne, en ajoutant et retranchant $\mathbb{E}[\hat{\theta}_n]$:

$$\mathbb{E}[(\hat{\theta}_n - \theta)^2] = \underbrace{(\mathbb{E}[\hat{\theta}_n] - \theta)^2}_{\text{biais}^2} + \underbrace{\mathbb{E}[(\hat{\theta}_n - \mathbb{E}[\hat{\theta}_n])^2]}_{\text{variance}}$$

le double produit s'annulant car $\mathbb{E}[\hat{\theta}_n - \mathbb{E}[\hat{\theta}_n]] = 0$.

Sa portée pratique : un estimateur biaisé peut être meilleur qu'un estimateur sans biais. Ce qui compte est le **risque total**, pas le biais seul. C'est toute la justification de la **régularisation** — ridge, LASSO, rétrécissement — qui accepte du biais pour réduire la variance. C'est aussi la raison profonde du modèle à un paramètre de l'introduction : supposer Poisson introduit du biais si c'est faux, mais réduit énormément la variance.

● Concept 5 — Les intervalles de confiance

Soit $(E, (\mathbb{P}_\theta)_{\theta \in \Theta})$ un modèle statistique fondé sur $X_1, \dots, X_n$, avec $\Theta \subseteq \mathbb{R}$, et $\alpha \in (0, 1)$.

Intervalle de confiance de niveau $1 - \alpha$ pour θ : tout intervalle **aléatoire** I — dépendant de $X_1, \dots, X_n$ — dont les **bornes ne dépendent pas de θ** et tel que

$$\mathbb{P}_\theta[I \ni \theta] \geq 1 - \alpha, \quad \forall \theta \in \Theta$$

Intervalle de confiance de niveau asymptotique $1 - \alpha$: tout intervalle aléatoire I dont les bornes ne dépendent pas de θ et tel que

$$\lim_{n \rightarrow \infty} \mathbb{P}_\theta[I \ni \theta] \geq 1 - \alpha, \quad \forall \theta \in \Theta$$

Attention à la notation $I \ni \theta$: elle n'est pas une coquetterie. C'est l'**intervalle qui est aléatoire**, pas θ — qui est un nombre fixe et inconnu. On ne dit donc **pas** « θ a 95 % de chances d'être dans I » mais « I a 95 % de chances de contenir θ ». La probabilité porte sur la procédure, répétée sur de nouveaux échantillons.

L'exemple de Bernoulli, et son problème

Soient $X_1, \dots, X_n \stackrel{iid}{\sim} \text{Ber}(p)$ avec $p \in (0, 1)$ inconnu.

- **LGN** : la moyenne empirique $\bar{X}_n$ est un estimateur **fortement consistant** de p .
- Soit $q_{\alpha/2}$ le quantile d'ordre $(1 - \frac{\alpha}{2})$ de $N(0, 1)$ et

$$I = \left[\bar{X}_n - \frac{q_{\alpha/2} \sqrt{p(1-p)}}{\sqrt{n}}, \bar{X}_n + \frac{q_{\alpha/2} \sqrt{p(1-p)}}{\sqrt{n}} \right]$$

- **TCL** : $\lim_{n \rightarrow \infty} \mathbb{P}_p[I \ni p] = 1 - \alpha$ pour tout $p \in (0, 1)$.

PROBLÈME : I DÉPEND DE p !

Les bornes contiennent le paramètre inconnu : ce n'est donc **pas** un intervalle de confiance au sens de la définition.

Les deux solutions du cours.

1. Remplacer $p(1-p)$ par $1/4$ dans I , puisque $p(1-p) \leq 1/4$.
2. Remplacer p par $\bar{X}_n$ dans I et invoquer le **théorème de Slutsky**.

Comparez les deux — elles illustrent deux stratégies générales.

- La première est **conservatrice** : elle majore la variance par son maximum, donc élargit l'intervalle. Le niveau réel est $\geq 1 - \alpha$ — l'inégalité de la définition est respectée, avec de la marge. Elle est **valide à n fini**.
- La seconde est **exacte asymptotiquement** : Slutsky garantit que remplacer p par un estimateur convergent ne change pas la loi limite. L'intervalle est plus court, mais le niveau n'est atteint **qu'à la limite**.

Le choix dépend de ce qu'on privilégie : la **garantie** ou la **précision**.

● Concept 6 — Le théorème de Weierstrass et son usage statistique

THÉORÈME D'APPROXIMATION DE WEIERSTRASS.

Soit f une fonction continue sur l'intervalle $[a, b]$. Alors, pour tout $\varepsilon > 0$, il existe $a_0, a_1, \dots, a_d \in \mathbb{R}$ tels que

$$\max_{x \in [a, b]} \left| f(x) - \sum_{k=0}^d a_k x^k \right| < \varepsilon$$

En un mot : **les fonctions continues peuvent être approchées arbitrairement bien par des polynômes.**

L'application statistique, en quatre pas.

1. Soit $X_1, \dots, X_n$ un échantillon i.i.d. d'un modèle **identifié** $(E, \{\mathbb{P}_\theta\}_{\theta \in \Theta})$, de vrai paramètre θ^* , et supposons que chaque $\mathbb{P}_\theta$ ait une densité f_θ .

2. Si l'on trouve θ tel que

$$\int h(x) f_{\theta^*}(x) dx = \int h(x) f_\theta(x) dx$$

pour **toute** fonction h continue bornée, alors $\theta = \theta^*$.

3. Remplaçons les espérances par des moyennes : chercher $\hat{\theta}$ tel que

$$\frac{1}{n} \sum_{i=1}^n h(X_i) = \int h(x) f_{\hat{\theta}}(x) dx$$

pour toute fonction continue bornée h . Il y en a une **infinité** : infaisable !

4. Par le théorème de Weierstrass, il suffit de considérer les **polynômes**, puis — en identifiant les coefficients — les seules **puissances** :

$$\frac{1}{n} \sum_{i=1}^n X_i^k = \int x^k f_{\hat{\theta}}(x) dx, \quad \forall k = 1, \dots, d$$

ce qui ne fait que d équations (plus la normalisation).

La quantité $m_k(\theta) := \int x^k f_\theta(x) dx = \mathbb{E}_\theta[X^k]$ est le k -ième moment de $\mathbb{P}_\theta$.

Le raisonnement est très élégant. Identifier deux lois demande de comparer une infinité d'intégrales. Weierstrass dit que les **polynômes suffisent** à tester toutes les fonctions continues ; et par linéarité, les **monômes** suffisent à tester les polynômes. On passe donc d'une infinité de conditions à un nombre **fini de moments**.

Les trois limites du théorème, signalées par le cours :

1. il ne vaut que pour les fonctions **continues** (*pas vraiment un problème*) ;
2. il ne vaut que sur des **intervalles** $[a, b]$ **bornés** ;
3. il **ne dit pas** combien de moments d prendre.

● Concept 7 — La quadrature gaussienne : le cas discret

Que se passe-t-il si E est **discret** — pas de densité mais une fonction de masse ?

Supposons $E = \{x_1, \dots, x_r\}$ **fini** à r valeurs possibles. La fonction de masse a $r - 1$ paramètres, $p(x_1), \dots, p(x_{r-1})$, puisque $p(x_r) = 1 - \sum_{j=1}^{r-1} p(x_j)$. On peut espérer n'avoir besoin de guère plus de $d = r - 1$ moments pour retrouver $p(\cdot)$.

Le système linéaire. Pour $k = 1, \dots, r - 1$:

$$m_k = \mathbb{E}[X^k] = \sum_{j=1}^r p(x_j) x_j^k, \quad \text{et} \quad \sum_{j=1}^r p(x_j) = 1$$

C'est un **système linéaire** d'inconnues $p(x_1), \dots, p(x_r)$:

$$\begin{pmatrix} x_1 & x_2 & \cdots & x_r \\ x_1^2 & x_2^2 & \cdots & x_r^2 \\ \vdots & \vdots & \ddots & \vdots \\ x_1^{r-1} & x_2^{r-1} & \cdots & x_r^{r-1} \\ 1 & 1 & \cdots & 1 \end{pmatrix} \begin{pmatrix} p(x_1) \\ p(x_2) \\ \vdots \\ p(x_{r-1}) \\ p(x_r) \end{pmatrix} = \begin{pmatrix} m_1 \\ m_2 \\ \vdots \\ m_{r-1} \\ 1 \end{pmatrix}$$

La matrice est-elle inversible ? Le déterminant de Vandermonde.

$$\det \begin{pmatrix} x_1 & x_2 & \cdots & x_r \\ x_1^2 & x_2^2 & \cdots & x_r^2 \\ \vdots & \vdots & \ddots & \vdots \\ x_1^{r-1} & x_2^{r-1} & \cdots & x_r^{r-1} \\ 1 & 1 & \cdots & 1 \end{pmatrix} = \pm \prod_{1 \leq j < k \leq r} (x_j - x_k) \neq 0$$

puisque les x_j sont **deux à deux distincts**.

Conclusion. Étant donnés $m_1, \dots, m_{r-1}$, il existe une **unique** fonction de masse ayant ces moments, obtenue en inversant le système.

CE QUE CE DÉTOUR ÉTABLIT — ET C'EST LA CONCLUSION DU COURS.

- Les moments contiennent une information importante pour retrouver la densité ou la fonction de masse.
- Si l'on peut estimer ces moments avec précision, on peut espérer **retrouver la loi**.
- Dans un cadre paramétrique, où connaître $\mathbb{P}_\theta$ revient à connaître θ , il faut souvent **encore moins** de moments. Cela se juge au cas par cas.
- **Règle empirique : si $\theta \in \Theta \subset \mathbb{R}^d$, il faut d moments.**

● Concept 8 — La méthode des moments

Soit $X_1, \dots, X_n$ un échantillon i.i.d. d'un modèle $(E, (\mathbb{P}_\theta)_{\theta \in \Theta})$ avec $\Theta \subseteq \mathbb{R}^d$.

Moments de population : $m_k(\theta) = \mathbb{E}_\theta[X_1^k]$, $1 \leq k \leq d$. **Moments empiriques :**

$\hat{m}_k = \overline{X_n^k} = \frac{1}{n} \sum_{i=1}^n X_i^k$, $1 \leq k \leq d$. Et l'application

$$\psi : \Theta \subset \mathbb{R}^d \rightarrow \mathbb{R}^d, \quad \theta \mapsto (m_1(\theta), \dots, m_d(\theta))$$

En supposant ψ **bijective**, de sorte que $\theta = \psi^{-1}(m_1(\theta), \dots, m_d(\theta))$:

DÉFINITION — ESTIMATEUR DES MOMENTS.

$$\hat{\theta}_n^{MM} = \psi^{-1}(\hat{m}_1, \dots, \hat{m}_d)$$

sous réserve qu'il existe.

L'idée, en une phrase. Les moments théoriques sont des **fonctions connues** de θ ; les moments empiriques sont **calculables** à partir des données. On **égalise les deux** et l'on résout en θ . Aucune vraisemblance à écrire, aucune optimisation à conduire — juste un système d'équations à inverser.

● Concept 9 — La loi asymptotique de l'estimateur des moments

Les notations. $M(\theta) = (m_1(\theta), \dots, m_d(\theta))$, $\hat{M} = (\hat{m}_1, \dots, \hat{m}_d)$, et

$$\Sigma(\theta) = \mathbb{V}_\theta(X, X^2, \dots, X^d)$$

la matrice de covariance du vecteur aléatoire $(X, X^2, \dots, X^d)$ pour $X \sim \mathbb{P}_\theta$. On suppose ψ^{-1} **continûment dérivable** en $M(\theta)$, de matrice gradient $\nabla \psi^{-1}|_{M(\theta)}$ de taille $d \times d$.

Les deux étapes.

- **LGN** : $\hat{\theta}_n^{MM}$ est faiblement / fortement **consistant**.
- **TCL** :

$$\sqrt{n}(\hat{M} - M(\theta)) \xrightarrow[n \rightarrow \infty]{(d)} N(0, \Sigma(\theta)) \quad \text{par rapport à } \mathbb{P}_\theta$$

D'où, par la méthode delta :

$$\sqrt{n}(\hat{\theta}_n^{MM} - \theta) \xrightarrow[n \rightarrow \infty]{(d)} N(0, \Gamma(\theta)), \quad \Gamma(\theta) = \left(\nabla \psi^{-1}|_{M(\theta)} \right)^\top \Sigma(\theta) \nabla \psi^{-1}|_{M(\theta)}$$

MÉTHODE DELTA MULTIVARIÉE.

Soit $(T_n)_{n \geq 1}$ une suite de vecteurs aléatoires de $\mathbb{R}^p$ vérifiant

$$\sqrt{n}(T_n - \theta) \xrightarrow[n \rightarrow \infty]{(d)} N(0, \Sigma)$$

pour un $\theta \in \mathbb{R}^p$ et une matrice symétrique semi-définie positive Σ . Soit $g : \mathbb{R}^p \rightarrow \mathbb{R}^k$ continûment dérivable en θ . Alors

$$\sqrt{n}(g(T_n) - g(\theta)) \xrightarrow[n \rightarrow \infty]{(d)} N(0, \nabla g(\theta)^\top \Sigma \nabla g(\theta))$$

où $\nabla g(\theta) = \left(\frac{\partial g_j}{\partial \theta_i} \right)_{1 \leq i \leq p, 1 \leq j \leq k}$.

La méthode delta est l'outil le plus rentable de la statistique asymptotique. Son mécanisme est un développement de Taylor au premier ordre : $g(T_n) \approx g(\theta) + \nabla g(\theta)^\top (T_n - \theta)$. Une transformation **régulière** d'un estimateur asymptotiquement normal reste asymptotiquement normale, avec une variance **transportée par le gradient**.

Ici, $g = \psi^{-1}$: on passe des moments au paramètre. C'est **exactement** le mécanisme utilisé pour les hypothèses implicites de la fiche 65, avec la même formule $\Gamma = \nabla g^\top \Sigma \nabla g$.

● Concept 10 — Maximum de vraisemblance ou méthode des moments ?

- **Comparaison des risques quadratiques** : en général, l'**EMV est plus précis**.
- **Questions de calcul** : parfois, l'**EMV est intraitable**.
- Si la vraisemblance est **concave**, on peut utiliser des algorithmes d'optimisation — **méthode de points intérieurs, descente de gradient, etc.**
- Si elle **n'est pas concave** : seulement des **heuristiques**, avec des maxima locaux — **espérance-maximisation, etc.**

La raison profonde de la supériorité de l'EMV. Le théorème de la fiche 64 dit que sa variance asymptotique est $I(\theta^*)^{-1}$, qui atteint la **borne de Cramér-Rao**. Aucun estimateur régulier ne peut faire mieux — en particulier pas la méthode des moments, dont la variance $\Gamma(\theta)$ est en général strictement supérieure.

Ce qui sauve la méthode des moments. Elle est **explicite** : on résout un système d'équations, sans optimisation, sans risque de maximum local. Quand la vraisemblance est intraitable ou non concave, un estimateur légèrement moins efficace mais **sûrement calculable** vaut mieux qu'un estimateur optimal introuvable.

Et elle sert souvent de point de départ : on initialise un algorithme de maximum de vraisemblance avec l'estimateur des moments.

La référence aux « points intérieurs » et à la « descente de gradient » renvoie explicitement aux fiches 39 et 41. Estimation statistique et optimisation convexe sont bien le même sujet, vu de deux côtés.

Comment résoudre l'exercice type (protocole)

1. **Écrire le modèle** $(E, (\mathbb{P}_\theta)_{\theta \in \Theta})$ et vérifier l'**identifiabilité**.
2. **Choisir la méthode** : maximum de vraisemblance si la vraisemblance est traitable ; **moments** sinon.
3. **Méthode des moments** : calculer $m_k(\theta) = \mathbb{E}_\theta[X^k]$ pour $k = 1, \dots, d$, poser ψ , **inverser**, remplacer par les moments empiriques.
4. **Évaluer la qualité** : biais, variance, risque = biais² + variance.
5. **Établir la consistance** par la LGN, la loi asymptotique par le TCL et la **méthode delta**.
6. **Construire un intervalle de confiance** — et **vérifier que les bornes ne dépendent pas de θ** ; sinon, majorer la variance ou appliquer Slutsky.

Comment reconnaître qu'il faut utiliser cette méthode ?

Indice dans l'énoncé	Ce qu'il faut faire
« deux paramètres donnent la même loi »	problème d' identifiabilité
« cet estimateur est-il bon ? »	risque quadratique = biais ² + variance
« estimateur sans biais mais très variable »	comparer les risques , pas les biais
« intervalle de confiance »	vérifier que les bornes ne contiennent pas θ
bornes dépendant du paramètre	majorer la variance, ou Slutsky
« la vraisemblance est intraitable »	méthode des moments
$\theta \in \mathbb{R}^d$	prendre d moments
« loi asymptotique d'une fonction d'un estimateur »	méthode delta
« quel estimateur est le plus précis ? »	en général l' EMV (borne de Cramér-Rao)

Exercices progressifs

Niveau 1 — Estimez les paramètres d'une loi $N(\mu, \sigma^2)$ par la méthode des moments.

Le paramètre est de dimension $d = 2$, il faut donc deux moments.

Les moments de population.

$$m_1(\theta) = \mathbb{E}[X] = \mu, \quad m_2(\theta) = \mathbb{E}[X^2] = \text{var}(X) + (\mathbb{E}[X])^2 = \sigma^2 + \mu^2$$

L'application ψ . $\psi(\mu, \sigma^2) = (\mu, \sigma^2 + \mu^2)$, dont l'inverse est

$$\psi^{-1}(m_1, m_2) = (m_1, m_2 - m_1^2)$$

L'estimateur. Avec $\hat{m}_1 = \bar{X}_n$ et $\hat{m}_2 = \frac{1}{n} \sum X_i^2$:

$$\hat{\mu}_n^{MM} = \bar{X}_n, \quad \hat{\sigma}_{n,MM}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - (\bar{X}_n)^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

La comparaison avec l'EMV. Ce sont **exactement** les mêmes estimateurs qu'en fiche 64 ! Pour le modèle gaussien, méthode des moments et maximum de vraisemblance **coïncident**.

Pourquoi. La loi gaussienne appartient à la famille exponentielle avec $T_1(x) = x$ et $T_2(x) = x^2$ (fiche 66) : les statistiques exhaustives **sont** les deux premiers moments empiriques. Les deux méthodes exploitent donc exactement la même information.

Et le même biais : $\hat{\sigma}^2$ divisé par n , il est donc biaisé ; l'estimateur sans biais divisé par $n - 1$.

Niveau 2 — Pourquoi l'intervalle de confiance naïf de Bernoulli n'en est-il pas un ?

L'intervalle proposé.

$$I = \left[\bar{X}_n - \frac{q_{\alpha/2} \sqrt{p(1-p)}}{\sqrt{n}}, \bar{X}_n + \frac{q_{\alpha/2} \sqrt{p(1-p)}}{\sqrt{n}} \right]$$

Le TCL garantit bien $\lim_n \mathbb{P}_p[I \ni p] = 1 - \alpha$ pour tout p .

Le problème. La définition exige que les **bornes ne dépendent pas de θ** . Or elles contiennent $\sqrt{p(1-p)}$ — donc **p , le paramètre inconnu**. On ne peut pas calculer I à partir des seules données : ce n'est pas une statistique, donc pas un intervalle de confiance.

Solution 1 — majorer. La fonction $p \mapsto p(1-p)$ est maximale en $p = 1/2$, où elle vaut $1/4$. Donc

$$I_1 = \left[\bar{X}_n - \frac{q_{\alpha/2}}{2\sqrt{n}}, \bar{X}_n + \frac{q_{\alpha/2}}{2\sqrt{n}} \right]$$

contient I et vérifie $\mathbb{P}_p[I_1 \ni p] \geq 1 - \alpha$. **Conservateur** — l'intervalle est plus large que nécessaire dès que p s'éloigne de $1/2$ — mais **valide**, et l'inégalité $\geq$ de la définition est bien respectée.

Solution 2 — remplacer et invoquer Slutsky.

$$I_2 = \left[\bar{X}_n - \frac{q_{\alpha/2} \sqrt{\bar{X}_n(1-\bar{X}_n)}}{\sqrt{n}}, \bar{X}_n + \frac{q_{\alpha/2} \sqrt{\bar{X}_n(1-\bar{X}_n)}}{\sqrt{n}} \right]$$

$\bar{X}_n \rightarrow p$ par la LGN, donc $\sqrt{\bar{X}_n(1-\bar{X}_n)} \rightarrow \sqrt{p(1-p)}$ par continuité, et le théorème de **Slutsky** garantit que la loi limite est inchangée. I_2 est un intervalle de niveau **asymptotique** $1 - \alpha$.

Le choix. I_1 est valide à n fini mais large ; I_2 est plus court mais son niveau n'est atteint qu'asymptotiquement. En pratique, avec n grand et p loin de 0 et 1 , on préfère I_2 .

Et la formulation correcte : « I contient p avec probabilité $1 - \alpha$ », et non « p est dans I avec probabilité $1 - \alpha$ ». C'est l'**intervalle** qui est aléatoire.

Niveau 3 — Expliquez comment le théorème de Weierstrass justifie la méthode des moments.

Le problème initial. Pour identifier θ^* , il suffirait de trouver θ tel que

$$\int h(x) f_{\theta^*}(x) dx = \int h(x) f_{\theta}(x) dx$$

pour **toute** fonction h continue bornée — car cela force $f_{\theta} = f_{\theta^*}$, donc $\theta = \theta^*$ par identifiabilité.

La version empirique. En remplaçant l'espérance par une moyenne, on chercherait $\hat{\theta}$ tel que

$$\frac{1}{n} \sum_{i=1}^n h(X_i) = \int h(x) f_{\hat{\theta}}(x) dx$$

pour toute h continue bornée. **Il y en a une infinité : infaisable.**

Le premier apport de Weierstrass. *Les fonctions continues peuvent être approchées arbitrairement bien par des **polynômes**.* Il suffit donc de tester les polynômes :

$$\frac{1}{n} \sum_i \sum_{k=0}^d a_k X_i^k = \sum_{k=0}^d a_k \int x^k f_{\hat{\theta}}(x) dx, \quad \forall a_0, \dots, a_d$$

Le second apport — la linéarité. Cette égalité doit valoir pour **tous** les coefficients a_k , donc coefficient par coefficient :

$$\frac{1}{n} \sum_{i=1}^n X_i^k = \int x^k f_{\hat{\theta}}(x) dx, \quad k = 1, \dots, d$$

soit **d équations** au lieu d'une infinité. C'est exactement $\hat{m}_k = m_k(\hat{\theta})$.

Le passage d'une infinité à un nombre fini s'est fait en deux temps : **densité des polynômes** dans les fonctions continues, puis **linéarité** ramenant les polynômes aux monômes.

Les trois limites, que le cours énonce :

1. cela ne vaut que pour les fonctions **continues** (*pas vraiment un problème*) ;
2. cela ne vaut que sur un **intervalle borné** $[a, b]$;

3. cela **ne dit pas** quel d prendre.

La réponse au point 3. Le détour par la **quadrature gaussienne** en cas discret montre que $r - 1$ moments déterminent **exactement** une loi à r valeurs — le système de Vandermonde étant inversible. D'où la **règle empirique** : si $\theta \in \Theta \subset \mathbb{R}^d$, il faut d moments. Le nombre de moments suit le nombre de paramètres, ce qui est intuitif : d inconnues, d équations.

Niveau 4 — type examen — Établissez la loi asymptotique de l'estimateur des moments et comparez-la à celle de l'EMV.

Les notations. $M(\theta) = (m_1(\theta), \dots, m_d(\theta))$, $\hat{M} = (\hat{m}_1, \dots, \hat{m}_d)$, $\Sigma(\theta) = \mathbb{V}_\theta(X, X^2, \dots, X^d)$, et ψ^{-1} continûment dérivable en $M(\theta)$.

Étape 1 — le TCL sur les moments empiriques. Les vecteurs $(X_i, X_i^2, \dots, X_i^d)$ sont i.i.d. de moyenne $M(\theta)$ et de covariance $\Sigma(\theta)$. Le TCL multivarié donne

$$\sqrt{n}(\hat{M} - M(\theta)) \xrightarrow{(d)} N(0, \Sigma(\theta))$$

Étape 2 — la méthode delta. Comme $\hat{\theta}_n^{MM} = \psi^{-1}(\hat{M})$ et $\theta = \psi^{-1}(M(\theta))$, on applique la méthode delta avec $g = \psi^{-1}$:

$$\sqrt{n}(\hat{\theta}_n^{MM} - \theta) \xrightarrow{(d)} N(0, \Gamma(\theta)), \quad \Gamma(\theta) = (\nabla \psi^{-1})^\top \Sigma(\theta) (\nabla \psi^{-1})$$

le gradient étant évalué en $M(\theta)$.

Étape 3 — la consistance, par la LGN : $\hat{M} \rightarrow M(\theta)$, donc $\hat{\theta}_n^{MM} = \psi^{-1}(\hat{M}) \rightarrow \theta$ par continuité de ψ^{-1} .

La comparaison avec l'EMV.

	Méthode des moments	Maximum de vraisemblance
Vitesse	$1/\sqrt{n}$	$1/\sqrt{n}$
Variance asymptotique	$\Gamma(\theta) = \nabla \psi^{-1\top} \Sigma \nabla \psi^{-1}$	$I(\theta)^{-1}$
Optimalité	non en général	oui (Cramér-Rao)
Calcul	explicite , système à inverser	optimisation
Risque d'échec	ψ non inversible	maxima locaux

Le point théorique décisif. Le théorème de la fiche 64 donne à l'EMV la variance $I(\theta^*)^{-1}$, qui **atteint la borne de Cramér-Rao** : c'est la plus petite variance asymptotique atteignable par un estimateur régulier. Donc

$$\Gamma(\theta) \succeq I(\theta)^{-1}$$

avec égalité seulement dans des cas particuliers. Le cours résume : *en général, l'EMV est plus précis.*

Le point pratique qui sauve la méthode des moments. Parfois, l'EMV est **intraitable**. Il faut alors optimiser : *si la vraisemblance est concave, on peut utiliser des algorithmes d'optimisation — points intérieurs, descente de gradient. Si elle n'est pas concave, seulement des heuristiques, avec des maxima locaux.*

La méthode des moments, elle, ne demande **aucune optimisation** : on résout $\hat{m}_k = m_k(\hat{\theta})$, c'est-à-dire d équations à d inconnues. Elle est donc **toujours calculable** dès que ψ est inversible, et sans risque de maximum local.

Le cas d'égalité intéressant. Pour le modèle gaussien, les deux méthodes donnent **exactement le même estimateur**. Ce n'est pas un hasard : la gaussienne est une famille exponentielle dont les statistiques exhaustives sont $T_1(x) = x$ et $T_2(x) = x^2$ (fiche 66) — précisément les deux premiers moments. Les deux méthodes utilisent la même information, donc coïncident.

En pratique, on utilise souvent l'estimateur des moments comme **point de départ** d'un algorithme de maximum de vraisemblance : facile à calculer, déjà consistant, et suffisamment proche de l'optimum pour que Newton converge rapidement.

● Common mistakes

1. **Oublier de vérifier l'identifiabilité** — sans elle, aucun estimateur ne peut converger vers un point unique.
2. **Croire qu'un estimateur peut dépendre de θ** — un estimateur doit être calculable à partir des **seules données**.
3. **Comparer des estimateurs sur leur biais seul** — c'est le **risque quadratique** qui compte, biais² + variance.
4. **Croire qu'un estimateur sans biais est toujours meilleur** — un peu de biais peut réduire beaucoup la variance.
5. **Dire « θ est dans I avec probabilité $1 - \alpha$ »** — c'est I qui est aléatoire, pas θ .
6. **Laisser θ dans les bornes d'un intervalle de confiance** — il faut majorer la variance ou appliquer Slutsky.

7. **Prendre le mauvais nombre de moments** — il en faut d pour $\theta \in \mathbb{R}^d$.
8. **Oublier de vérifier que ψ est inversible** — sans cela, l'estimateur des moments n'existe pas.
9. **Se tromper dans la méthode delta** — c'est $\nabla g^\top \Sigma \nabla g$, avec le gradient évalué au **point limite**.
10. **Croire que la méthode des moments vaut l'EMV** — sa variance est en général strictement supérieure.

Ultimate Review

1. **L'arbitrage fondateur** : plus de paramètres = moins d'hypothèses mais plus de variance ; 7 paramètres libres contre 1 pour Poisson.
2. **Modèle statistique** : $(E, (\mathbb{P}_\theta)_{\theta \in \Theta})$; E espace d'échantillonnage, Θ ensemble de paramètres ; **bien spécifié** si $\mathbb{P} = \mathbb{P}_\theta$; **paramétrique** si $\Theta \subseteq \mathbb{R}^d$.
3. **Identifiabilité** : $\theta \mapsto \mathbb{P}_\theta$ **injective**. Contre-exemple : $X_i = \mathbf{1}_{Y_i \geq 0}$ avec $Y_i \sim N(\mu, \sigma^2)$ — seul μ/σ est identifié.
4. **Statistique** : toute fonction mesurable de l'échantillon. **Estimateur** : statistique **ne dépendant pas de θ** .
5. **Consistance** : $\hat{\theta}_n \rightarrow \theta$ en probabilité (faible) ou presque sûrement (forte).
6. **Biais** = $\mathbb{E}[\hat{\theta}_n] - \theta$; **risque quadratique** = $\mathbb{E}[|\hat{\theta}_n - \theta|^2]$; et **risque** = **biais**² + **variance**.
7. **Intervalle de confiance de niveau $1 - \alpha$** : intervalle aléatoire à bornes indépendantes de θ avec $\mathbb{P}_\theta[I \ni \theta] \geq 1 - \alpha$; **asymptotique** si la limite le vérifie.
8. **Le piège de Bernoulli** : les bornes contiennent $\sqrt{p(1-p)}$. **Deux remèdes** : majorer par $1/4$ (conservateur, valide à n fini) ou remplacer p par $\bar{X}_n$ (**Slutsky**, asymptotique).
9. **Weierstrass** : toute fonction continue sur $[a, b]$ est approchable par des polynômes.
10. **Son usage** : identifier deux lois demande une infinité d'intégrales $\Rightarrow$ polynômes suffisent $\Rightarrow$ **monômes** suffisent $\Rightarrow d$ équations sur les moments.
11. **Ses trois limites** : fonctions continues · intervalles bornés · d non déterminé.
12. **Quadrature gaussienne** (cas discret à r valeurs) : système linéaire de matrice de **Vandermonde**, de déterminant $\prod_{j < k} (x_j - x_k) \neq 0 \Rightarrow r - 1$ moments déterminent **uniquement** la loi.
13. **Règle empirique** : $\theta \in \mathbb{R}^d \Rightarrow d$ moments.
14. **Méthode des moments** : $m_k(\theta) = \mathbb{E}_\theta[X^k]$, $\hat{m}_k = \frac{1}{n} \sum X_i^k$, $\psi(\theta) = (m_1(\theta), \dots, m_d(\theta))$, et

$$\hat{\theta}_n^{MM} = \psi^{-1}(\hat{m}_1, \dots, \hat{m}_d)$$

15. **Asymptotique** : LGN $\Rightarrow$ consistance ; TCL $\Rightarrow \sqrt{n}(\hat{M} - M(\theta)) \rightarrow N(0, \Sigma(\theta))$; **méthode delta** $\Rightarrow$

$$\sqrt{n}(\hat{\theta}_n^{MM} - \theta) \rightarrow N(0, \Gamma(\theta)), \quad \Gamma = (\nabla \psi^{-1})^\top \Sigma (\nabla \psi^{-1})$$

16. **Méthode delta multivariée** : $\sqrt{n}(T_n - \theta) \rightarrow N(0, \Sigma)$ et g continûment dérivable $\Rightarrow \sqrt{n}(g(T_n) - g(\theta)) \rightarrow N(0, \nabla g^\top \Sigma \nabla g)$.
17. **EMV contre moments** : l'EMV est **plus précis** en général (Cramér-Rao) ; la méthode des moments est **explicite** et sans maximum local. Elles **coïncident** pour le modèle gaussien.

Formulas to know

$$\text{risque} = \text{biais}^2 + \text{variance} \quad \mathbb{P}_\theta[I \ni \theta] \geq 1 - \alpha \quad p(1 - p) \leq \frac{1}{4}$$

$$m_k(\theta) = \mathbb{E}_\theta[X^k] \quad \hat{m}_k = \frac{1}{n} \sum_{i=1}^n X_i^k \quad \hat{\theta}_n^{MM} = \psi^{-1}(\hat{m}_1, \dots, \hat{m}_d)$$

$$\Gamma(\theta) = (\nabla \psi^{-1})^\top \Sigma(\theta) (\nabla \psi^{-1}) \quad \sqrt{n}(g(T_n) - g(\theta)) \rightarrow N(0, \nabla g^\top \Sigma \nabla g)$$

Methods to know : vérifier l'identifiabilité ; décomposer un risque ; construire un intervalle de confiance et traiter le paramètre inconnu ; appliquer la méthode des moments et sa méthode delta.

Active Recall

Basic — Définissez un modèle statistique et l'identifiabilité.

Modèle statistique : un couple $(E, (\mathbb{P}_\theta)_{\theta \in \Theta})$ où E est l'**espace d'échantillonnage**, $(\mathbb{P}_\theta)_{\theta \in \Theta}$ une **famille de lois** sur E , et Θ l'**ensemble de paramètres**. Le modèle est **bien spécifié** si la vraie loi $\mathbb{P}$ vaut $\mathbb{P}_{\theta^*}$ pour un certain $\theta^* \in \Theta$, et **paramétrique** si $\Theta \subseteq \mathbb{R}^d$.

Identifiabilité : θ est **identifié** si l'application $\theta \mapsto \mathbb{P}_\theta$ est **injective**, c'est-à-dire

$$\theta \neq \theta' \implies \mathbb{P}_\theta \neq \mathbb{P}_{\theta'}$$

Sans identifiabilité, deux valeurs différentes du paramètre engendrent exactement les mêmes données : **aucune** quantité d'observations ne permet de les distinguer.

Understanding — Que dit la décomposition risque = biais² + variance ?

$$\mathbb{E}[(\hat{\theta}_n - \theta)^2] = \underbrace{(\mathbb{E}[\hat{\theta}_n] - \theta)^2}_{\text{biais}^2} + \underbrace{\text{var}(\hat{\theta}_n)}_{\text{variance}}$$

Les deux sources d'erreur. Le **biais** est l'erreur **systématique** : l'estimateur vise-t-il la bonne cible ? La **variance** est l'erreur **aléatoire** : à quel point le tir est-il dispersé d'un échantillon à l'autre ?

La conséquence pratique, contre-intuitive. Un estimateur **biaisé** peut avoir un risque **plus faible** qu'un estimateur sans biais, si sa variance est nettement moindre. C'est toute la justification de la **régularisation** (ridge, LASSO, rétrécissement) et, plus généralement, de la modélisation paramétrique : supposer $X \sim \text{Pois}(\lambda)$ introduit du biais si c'est faux, mais fait passer de 7 paramètres à 1, donc réduit massivement la variance.

Application — Estimez λ d'une loi exponentielle par la méthode des moments.

Le paramètre est de dimension $d = 1$: un seul moment suffit.

Le moment de population. Pour $X \sim \text{Exp}(\lambda)$, $\mathbb{E}[X] = \frac{1}{\lambda}$, donc $m_1(\lambda) = \frac{1}{\lambda}$.

L'application ψ et son inverse. $\psi(\lambda) = 1/\lambda$, donc $\psi^{-1}(m) = 1/m$ — bijective sur $(0, \infty)$.

L'estimateur.

$$\hat{\lambda}_n^{MM} = \psi^{-1}(\hat{m}_1) = \frac{1}{\bar{X}_n}$$

La consistance. $\bar{X}_n \rightarrow 1/\lambda$ par la LGN, donc $\hat{\lambda}_n \rightarrow \lambda$ par continuité de $x \mapsto 1/x$ sur $(0, \infty)$.

La loi asymptotique par la méthode delta. $\text{var}(X) = 1/\lambda^2$, donc $\sqrt{n}(\bar{X}_n - 1/\lambda) \rightarrow N(0, 1/\lambda^2)$. Avec $g(m) = 1/m$ et $g'(m) = -1/m^2$, évalué en $m = 1/\lambda$: $g'(1/\lambda) = -\lambda^2$. D'où

$$\sqrt{n}(\hat{\lambda}_n - \lambda) \xrightarrow{(d)} N\left(0, \lambda^4 \cdot \frac{1}{\lambda^2}\right) = N(0, \lambda^2)$$

Comparaison avec l'EMV. Pour la loi exponentielle, l'EMV est **aussi** $1/\bar{X}_n$, et l'information de Fisher vaut $I(\lambda) = 1/\lambda^2$, d'où une variance asymptotique $I(\lambda)^{-1} = \lambda^2$ — **identique**.

Pourquoi la coïncidence. La loi exponentielle est une famille exponentielle à un paramètre dont la statistique exhaustive est $T(x) = x$: les deux méthodes utilisent la même

information.

Comparison — EMV et méthode des moments : quand préférer laquelle ?

	Maximum de vraisemblance	Méthode des moments
Précision	optimale ($I(\theta)^{-1}$, Cramér-Rao)	$\Gamma(\theta) \succeq I(\theta)^{-1}$
Calcul	optimisation	système d'équations, explicite
Risque de blocage	maxima locaux si non concave	ψ non inversible
Ce qu'il faut connaître	la vraisemblance entière	seulement d moments

Le cours tranche : *en général, l'EMV est plus précis*. La raison est le théorème de la fiche 64 : sa variance asymptotique atteint la **borne de Cramér-Rao**.

Mais : *parfois, l'EMV est **intraitable***. Il faut alors optimiser — *si la vraisemblance est concave, points intérieurs ou descente de gradient ; si elle ne l'est pas, seulement des heuristiques, avec des maxima locaux*.

Quand préférer les moments. Vraisemblance impossible à écrire ou à maximiser · besoin d'un estimateur **rapide et sûr** · besoin d'un **point de départ** pour un algorithme d'optimisation · modèle où seuls quelques moments sont spécifiés (méthode des moments **généralisée**, très utilisée en économétrie).

Quand elles coïncident. Pour les familles exponentielles dont les statistiques exhaustives sont des moments — gaussienne, exponentielle, Poisson. Les deux méthodes exploitent alors exactement la même information.

Exam-style — Expliquez comment construire un intervalle de confiance et le piège du paramètre inconnu.

La définition. Un intervalle de confiance de niveau $1 - \alpha$ est un intervalle **aléatoire** I — dépendant de $X_1, \dots, X_n$ — dont les **bornes ne dépendent pas de θ** et tel que

$$\mathbb{P}_\theta[I \ni \theta] \geq 1 - \alpha, \quad \forall \theta \in \Theta$$

La version **asymptotique** remplace l'inégalité par sa limite quand $n \rightarrow \infty$.

La construction, en trois pas.

1. Trouver un estimateur consistant $\hat{\theta}_n$.
2. Établir sa loi asymptotique par le TCL : $\sqrt{n}(\hat{\theta}_n - \theta) \rightarrow N(0, \sigma^2(\theta))$.
3. Inverser : $\mathbb{P}[|\hat{\theta}_n - \theta| \leq q_{\alpha/2}\sigma(\theta)/\sqrt{n}] \rightarrow 1 - \alpha$.

Le piège. Sur l'exemple de Bernoulli, cela donne

$$I = \left[\bar{X}_n \pm \frac{q_{\alpha/2}\sqrt{p(1-p)}}{\sqrt{n}} \right]$$

I dépend de p , le paramètre inconnu. Les bornes ne sont donc **pas calculables** : ce n'est pas un intervalle de confiance au sens de la définition. C'est exactement la contrainte du concept 3 — un estimateur ne doit pas dépendre de θ .

Les deux remèdes.

1. Majorer la variance. $p(1-p) \leq 1/4$, donc

$$I_1 = \left[\bar{X}_n \pm \frac{q_{\alpha/2}}{2\sqrt{n}} \right] \supseteq I$$

et $\mathbb{P}_p[I_1 \ni p] \geq 1 - \alpha$. **Conservateur mais valide à n fini** — et l'inégalité $\geq$ de la définition est exactement ce qui autorise cet élargissement.

2. Substituer et invoquer Slutsky.

$$I_2 = \left[\bar{X}_n \pm \frac{q_{\alpha/2}\sqrt{\bar{X}_n(1-\bar{X}_n)}}{\sqrt{n}} \right]$$

La LGN donne $\bar{X}_n \rightarrow p$, la continuité donne $\sqrt{\bar{X}_n(1-\bar{X}_n)} \rightarrow \sqrt{p(1-p)}$, et **Slutsky** garantit que la loi limite est inchangée. Niveau **asymptotique** $1 - \alpha$.

Le choix. I_1 garantit le niveau à toute taille d'échantillon, au prix d'un intervalle plus large — d'autant plus large que p est loin de $1/2$. I_2 est plus court mais ne garantit rien à n fini.

La généralité de ces deux stratégies. Elles se retrouvent partout : soit on **major**e la variance inconnue par un pire cas, soit on l'**estime** et l'on invoque Slutsky. La seconde est la plus courante — c'est exactement ce que fait la statistique de Wald de la fiche 65, en remplaçant $I(\theta^*)$ par $I(\hat{\theta}_n)$.

Et la formulation : « I contient θ avec probabilité $1 - \alpha$ ». C'est **l'intervalle** qui est aléatoire, pas θ , qui est un nombre fixe et inconnu. La probabilité porte sur la **procédure**, pas sur le paramètre.

Flashcards

Question	Réponse
L'arbitrage de la modélisation ?	Moins de paramètres = plus de biais mais moins de variance
Définition d'un modèle statistique ?	$(E, (\mathbb{P}_\theta)_{\theta \in \Theta})$
Que veut dire « bien spécifié » ?	$\mathbb{P} = \mathbb{P}_\theta$ pour un $\theta \in \Theta$
Que veut dire « paramétrique » ?	$\Theta \subseteq \mathbb{R}^d$
Définition de l'identifiabilité ?	$\theta \mapsto \mathbb{P}_\theta$ injective
Le contre-exemple du cours ?	$X_i = \mathbf{1}_{Y_i \geq 0}$: seul μ/σ est identifié
Différence entre statistique et estimateur ?	L'estimateur ne dépend pas de θ
Consistance faible / forte ?	Convergence en probabilité / presque sûre
Biais d'un estimateur ?	$\mathbb{E}[\hat{\theta}_n] - \theta$
Risque quadratique ?	$\mathbb{E}[\hat{\theta}_n - \theta ^2]$
Sa décomposition ?	biais² + variance
Définition d'un intervalle de confiance ?	Bornes indépendantes de θ , $\mathbb{P}_\theta[I \ni \theta] \geq 1 - \alpha$
Qui est aléatoire dans $I \ni \theta$?	L'intervalle , pas θ
Le problème de l'IC de Bernoulli ?	Les bornes contiennent $\sqrt{p(1-p)}$
Première solution ?	Majorer $p(1-p)$ par $1/4$
Seconde solution ?	Remplacer p par $\bar{X}_n$ et invoquer Slutsky
Théorème de Weierstrass ?	Toute fonction continue sur $[a, b]$ est approchable par des polynômes
Son usage ici ?	Ramener une infinité de conditions à d moments
Ses trois limites ?	Continuité · intervalle borné · d non déterminé
Ce qu'établit la quadrature gaussienne ?	$r - 1$ moments déterminent uniquement une loi à r valeurs
Quel déterminant intervient ?	Celui de Vandermonde , $\prod_{j < k} (x_j - x_k)$

Question	Réponse
La règle empirique du nombre de moments ?	d moments pour $\theta \in \mathbb{R}^d$
Moment de population ?	$m_k(\theta) = \mathbb{E}_\theta[X^k]$
Moment empirique ?	$\hat{m}_k = \frac{1}{n} \sum_i X_i^k$
Estimateur des moments ?	$\hat{\theta}_n^{MM} = \psi^{-1}(\hat{m}_1, \dots, \hat{m}_d)$
Quelle hypothèse sur ψ ?	Elle doit être bijective
Loi asymptotique de $\hat{\theta}^{MM}$?	$N(0, \Gamma(\theta))$ avec $\Gamma = \nabla \psi^{-1\top} \Sigma \nabla \psi^{-1}$
Énoncé de la méthode delta ?	$\sqrt{n}(g(T_n) - g(\theta)) \rightarrow N(0, \nabla g^\top \Sigma \nabla g)$
Quel estimateur est le plus précis ?	En général l' EMV
Pourquoi ?	Sa variance atteint la borne de Cramér-Rao
Quand préférer les moments ?	Quand l'EMV est intraitable
Pour quel modèle coïncident-elles ?	Le modèle gaussien (et exponentiel, Poisson)