

Fiche 68 — Tests d'adéquation : Glivenko-Cantelli, Kolmogorov-Smirnov et khi-deux

Matière	Maths · Économétrie
Cours source	Rigollet, <i>18.650 Statistics for Applications</i> , MIT OpenCourseWare, automne 2016 — chapitre 6 « Testing goodness of fit »
Difficulté	Must know — c'est ici qu'on vérifie que le modèle tient
Temps d'étude estimé	2 h 15
Prérequis	Fiche 65 (tests, niveau, p-valeur), fiche 64 (maximum de vraisemblance), fiche 62 (mouvement brownien)
Concepts clés	Fonction de répartition empirique, théorème de Glivenko-Cantelli, théorème de Donsker, pont brownien, test de Kolmogorov-Smirnov, statistique pivotale, Cramér-Von Mises, Anderson-Darling, test de Kolmogorov-Lilliefors, graphique quantile-quantile, test du khi-deux d'adéquation
Poids à l'examen	Trois choses : Glivenko-Cantelli et Donsker , et le rôle du pont brownien ; le caractère pivotal de la statistique de Kolmogorov-Smirnov ; et les degrés de liberté $K - d - 1$ du test du khi-deux.

Vue d'ensemble

Soit X une variable aléatoire. Étant données des copies i.i.d. de X , on veut répondre à des questions du type :

- X a-t-elle la loi $N(0, 1)$? (cf. la loi de Student)
- X a-t-elle la loi $U([0, 1])$? (cf. la p-valeur sous H_0)
- X a-t-elle la fonction de masse $p_1 = 0,3, p_2 = 0,5, p_3 = 0,2$?

Ce sont tous des **tests d'adéquation** : on veut savoir si la loi supposée est un bon ajustement pour les données.

Caractéristique essentielle des tests d'adéquation : aucune modélisation paramétrique.

LA QUESTION	la loi supposée décrit-elle bien les données ?
OUTIL	la fonction de répartition EMPIRIQUE F_n
GARANTIE 1	Glivenko-Cantelli : $\sup F_n - F \rightarrow 0$ (consistance)
GARANTIE 2	Donsker : $\sqrt{n} \sup F_n - F \rightarrow \sup \text{pont brownien} $ (loi)
TEST 1	Kolmogorov-Smirnov – loi continue, statistique PIVOTALE
TEST 2	khi-deux – loi discrète ou données regroupées, $\chi^2_{\{K-d-1\}}$
PIÈGE	estimer les paramètres invalide Donsker !

Ces tests répondent à la question laissée ouverte par la fiche 67. Le modèle statistique y était supposé **bien spécifié** : la vraie loi appartient à la famille choisie. C'est une **hypothèse**, et c'est ici qu'on la teste.

● Concept 1 — La fonction de répartition empirique

Rappel. Pour $X_1, \dots, X_n$ i.i.d. réelles, la fonction de répartition de X_1 est

$$F(t) = \mathbb{P}[X_1 \leq t], \quad \forall t \in \mathbb{R}$$

Elle **caractérise entièrement** la loi de X_1 .

DÉFINITION.

La **fonction de répartition empirique** de l'échantillon est

$$F_n(t) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}\{X_i \leq t\} = \frac{\#\{i = 1, \dots, n : X_i \leq t\}}{n}, \quad \forall t \in \mathbb{R}$$

Par la loi des grands nombres, pour tout $t \in \mathbb{R}$:

$$F_n(t) \xrightarrow[n \rightarrow \infty]{\text{p.s.}} F(t)$$

THÉORÈME DE GLIVENKO-CANTELLI

le théorème fondamental de la statistique.

$$\sup_{t \in \mathbb{R}} |F_n(t) - F(t)| \xrightarrow[n \rightarrow \infty]{\text{p.s.}} 0$$

POURQUOI CE NOM, ET POURQUOI CE THÉORÈME EST PLUS FORT QUE LA LGN.

La LGN donne la convergence **pour chaque t fixé** ; Glivenko-Cantelli donne la convergence **uniforme en t** — le pire écart, sur toute la droite réelle, tend vers zéro.

C'est ce qui justifie toute la statistique non paramétrique : la fonction de répartition caractérisant la loi, et F_n convergeant **uniformément** vers F , l'échantillon détermine asymptotiquement la loi **sans aucune hypothèse de modèle**. On n'a plus besoin de supposer Poisson, gaussienne ou quoi que ce soit.

● Concept 2 — Donsker et le pont brownien

Par le théorème central limite, pour tout $t \in \mathbb{R}$:

$$\sqrt{n}(F_n(t) - F(t)) \xrightarrow[n \rightarrow \infty]{(d)} N(0, F(t)(1 - F(t)))$$

THÉORÈME DE DONSKER.

Si F est **continue**, alors

$$\sqrt{n} \sup_{t \in \mathbb{R}} |F_n(t) - F(t)| \xrightarrow[n \rightarrow \infty]{(d)} \sup_{0 \leq t \leq 1} |B(t)|$$

où B est un **pont brownien** sur $[0, 1]$.

Le rapport entre les deux théorèmes est celui entre LGN et TCL. Glivenko-Cantelli dit que l'écart uniforme **tend vers zéro** ; Donsker dit **à quelle vitesse** — en $1/\sqrt{n}$ — et donne la **loi limite** de l'écart renormalisé.

Pourquoi un pont brownien. $\mathbf{1}\{X_i \leq t\}$ est une variable de Bernoulli de paramètre $F(t)$, donc la variance ponctuelle est $F(t)(1 - F(t))$ — nulle en $t = -\infty$ et $t = +\infty$, maximale au milieu. Le processus limite est donc un mouvement brownien **contraint à s'annuler aux deux extrémités** : c'est exactement la définition du **pont brownien**. La contrainte vient de $F_n(-\infty) = F(-\infty) = 0$ et $F_n(+\infty) = F(+\infty) = 1$ — les deux fonctions coïncident **exactement** aux bords.

L'hypothèse de continuité de F est essentielle, et elle sera au cœur des concepts 5 et 7.

● Concept 3 — Le test de Kolmogorov-Smirnov

Le cadre. $X_1, \dots, X_n$ i.i.d. réelles de fonction de répartition **inconnue** F , et F^0 une fonction de répartition **continue** donnée. On teste

$$H_0 : F = F^0 \quad \text{contre} \quad H_1 : F \neq F^0$$

Si $F = F^0$, alors $F_n(t) \approx F^0(t)$ pour tout t .

La statistique de test.

$$T_n = \sup_{t \in \mathbb{R}} \sqrt{n} |F_n(t) - F^0(t)|$$

Par le théorème de Donsker, si H_0 est vraie, alors $T_n \xrightarrow{(d)} Z$, où Z a une **loi connue** — le supremum d'un pont brownien.

Test KS de niveau asymptotique α :

$$\delta_\alpha^{KS} = \mathbf{1}\{T_n > q_\alpha\}$$

où q_α est le quantile d'ordre $(1 - \alpha)$ de Z , obtenu dans des tables.

p-valeur du test KS : $\mathbb{P}[Z > T_n \mid T_n]$.

● Concept 4 — La formule pratique

En pratique, comment calculer T_n ?

L'observation géométrique. F^0 est **croissante et continue** ; F_n est **constante par morceaux**, avec des sauts en $t_i = X_i$. Le supremum de l'écart est donc atteint **aux points de saut**.

Soit $X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$ l'échantillon **réordonné**. Juste à gauche de $X_{(i)}$, F_n vaut $\frac{i-1}{n}$; en $X_{(i)}$ et juste à droite, elle vaut $\frac{i}{n}$. Il y a donc **deux candidats par saut**, et

$$T_n = \sqrt{n} \max_{i=1, \dots, n} \max \left\{ \frac{i}{n} - F^0(X_{(i)}), F^0(X_{(i)}) - \frac{i-1}{n} \right\}$$

Le calcul est donc élémentaire : trier l'échantillon, évaluer F^0 en chaque point, et prendre le maximum de $2n$ nombres. C'est une raison majeure du succès du test.

● Concept 5 — Le caractère pivotale

DÉFINITION.

* T_n est une **statistique pivotale** : si H_0 est vraie, la loi de T_n **ne dépend pas de la loi des X_i** , et elle est facile à reproduire par simulation.*

La démonstration, en deux lignes. Posons $U_i = F^0(X_i)$ et soit G_n la fonction de répartition empirique de $U_1, \dots, U_n$. Si H_0 est vraie, alors $U_1, \dots, U_n \stackrel{iid}{\sim} U([0, 1])$ — c'est la transformation intégrale de probabilité — et

$$T_n = \sup_{0 \leq x \leq 1} \sqrt{n} |G_n(x) - x|$$

Voilà tout l'intérêt. La loi de T_n sous H_0 est **la même quelle que soit F^0** : gaussienne, exponentielle, Cauchy — peu importe. Une **seule table** de quantiles sert pour tous les tests d'adéquation. C'est ce qui rend le test universel.

La procédure par simulation, si l'on ne dispose pas de table. Pour un grand entier M :

- Simuler M copies i.i.d. $T_n^1, \dots, T_n^M$ de T_n — c'est possible **précisément parce que la loi ne dépend d'aucun paramètre inconnu** ;
- Estimer le quantile $q_\alpha(n)$ d'ordre $(1 - \alpha)$ par le quantile empirique $\hat{q}_\alpha^{(n,M)}$ de $T_n^1, \dots, T_n^M$.

Test de niveau approché α : $\delta_\alpha = \mathbf{1}\{T_n > \hat{q}_\alpha^{(n,M)}\}$, et

$$\text{p-valeur} \approx \frac{\#\{j = 1, \dots, M : T_n^j > T_n\}}{M}$$

Ces quantiles sont souvent précalculés dans une table.

● Concept 6 — D'autres distances, d'autres tests

On veut mesurer la **distance entre deux fonctions**, $F_n(t)$ et $F(t)$. Il y a d'autres façons de le faire, qui conduisent à d'autres tests.

Test	Distance
Kolmogorov-Smirnov	$d(F_n, F) = \sup_{t \in \mathbb{R}} F_n(t) - F(t) $
Cramér-Von Mises	$d^2(F_n, F) = \int_{\mathbb{R}} [F_n(t) - F(t)]^2 dt$
Anderson-Darling	$d^2(F_n, F) = \int_{\mathbb{R}} \frac{[F_n(t) - F(t)]^2}{F(t)(1 - F(t))} dt$

COMMENT CHOISIR — CHAQUE DISTANCE A UNE SENSIBILITÉ DIFFÉRENTE.

- **KS** ne regarde que le **pire écart** : sensible à un décalage local, mais aveugle à de nombreux petits écarts.
- **Cramér-Von Mises intègre** l'écart au carré : elle prend en compte tout le domaine, donc détecte mieux des désaccords diffus.
- **Anderson-Darling** pondère par $\frac{1}{F(1-F)}$, qui **explose aux extrémités** : elle est donc bien plus sensible aux **queues** de distribution. C'est le test de choix quand ce sont les événements extrêmes qui comptent — donc en finance (fiche 55).

● Concept 7 — Les tests composites et l'erreur classique

Que faire si l'on veut tester « X a-t-elle une loi gaussienne ? » sans connaître les paramètres ?

L'idée simple — le remplacement. Calculer

$$\sup_{t \in \mathbb{R}} |F_n(t) - \Phi_{\hat{\mu}, \hat{\sigma}^2}(t)| \quad \text{où} \quad \hat{\mu} = \bar{X}_n, \quad \hat{\sigma}^2 = S_n^2$$

et $\Phi_{\hat{\mu}, \hat{\sigma}^2}$ est la fonction de répartition de $N(\hat{\mu}, \hat{\sigma}^2)$.

Dans ce cas, **le théorème de Donsker n'est plus valide**. C'est une erreur **courante et grave** !

Pourquoi l'erreur est grave, et pourquoi elle est si tentante. En estimant μ et σ^2 sur les mêmes données, on **rapproche artificiellement** $\Phi_{\hat{\mu}, \hat{\sigma}^2}$ de F_n : la gaussienne ajustée est, par construction, celle qui colle le mieux à l'échantillon. La statistique est donc **systématiquement trop petite**, la loi limite n'est plus celle du supremum d'un pont brownien, et l'on **rejette beaucoup trop rarement** — on croit valider la normalité alors qu'on a seulement mesuré à quel point on a bien ajusté.

C'est le même mécanisme que la perte de degrés de liberté en fiche 50 : estimer des paramètres sur les données **consomme de l'information**, et il faut en tenir compte.

La solution — le test de Kolmogorov-Lilliefors. On calcule à la place les quantiles de la statistique

$$\sup_{t \in \mathbb{R}} |F_n(t) - \Phi_{\hat{\mu}, \hat{\sigma}^2}(t)|$$

Ils ne dépendent pas de paramètres inconnus !

POURQUOI CELA FONCTIONNE.

La statistique de Lilliefors reste **pivotale** : sa loi sous H_0 ne dépend ni de μ ni de σ^2 , parce que la standardisation par $\hat{\mu}$ et $\hat{\sigma}$ élimine ces deux paramètres. On peut donc tabuler ses quantiles une fois pour toutes — mais ce sont des quantiles **différents** de ceux de Kolmogorov-Smirnov, et **plus petits**, précisément pour compenser l'ajustement.

● Concept 8 — Les graphiques quantile-quantile

- Ils fournissent une façon **visuelle** de faire un test d'adéquation.
- Ce n'est **pas un test formel**, mais une vérification rapide et facile pour voir si une loi est plausible.
- L'idée : vérifier visuellement si le graphe de F_n est proche de celui de F , ou de façon équivalente si le graphe de F_n^{-1} est proche de celui de F^{-1} .
- Il est plus commode de vérifier si les points

$$\left(F^{-1}\left(\frac{1}{n}\right), F_n^{-1}\left(\frac{1}{n}\right)\right), \left(F^{-1}\left(\frac{2}{n}\right), F_n^{-1}\left(\frac{2}{n}\right)\right), \dots, \left(F^{-1}\left(\frac{n-1}{n}\right), F_n^{-1}\left(\frac{n-1}{n}\right)\right)$$

sont proches de la droite $y = x$.

F_n n'est techniquement pas inversible, mais on définit $F_n^{-1}(i/n) = X_{(i)}$, la i -ième plus grande observation.

Ce qu'un QQ-plot montre que le test ne dit pas : où ça cloche. Un test rend un verdict ; le graphique montre la **forme** du désaccord. Points au-dessus de la droite dans la queue droite et en dessous dans la queue gauche $\Rightarrow$ **queues plus épaisses** que la loi supposée. Courbure systématique $\Rightarrow$ **asymétrie**. C'est précisément le diagnostic recommandé en fiche 53 pour les résidus standardisés d'un GARCH.

● Concept 9 — Le test du khi-deux, cas fini

Le cadre. Soient $X_1, \dots, X_n$ i.i.d. sur un espace **fini** $E = \{a_1, \dots, a_K\}$, de loi $\mathbb{P}$, et $(\mathbb{P}_\theta)_{\theta \in \Theta}$ une famille paramétrique de lois sur E . Exemple : sur $E = \{1, \dots, K\}$, la famille des lois binomiales $(\text{Bin}(K, p))_{p \in (0,1)}$.

Pour $j = 1, \dots, K$ et $\theta \in \Theta$, on pose

$$p_j(\theta) = \mathbb{P}_\theta[Y = a_j] \text{ où } Y \sim \mathbb{P}_\theta, \quad \text{et} \quad p_j = \mathbb{P}[X_1 = a_j]$$

Les hypothèses.

$$H_0 : \mathbb{P} \in (\mathbb{P}_\theta)_{\theta \in \Theta} \quad \text{contre} \quad H_1 : \mathbb{P} \notin (\mathbb{P}_\theta)_{\theta \in \Theta}$$

Tester H_0 , c'est tester si le **modèle statistique** $(E, (\mathbb{P}_\theta)_{\theta \in \Theta})$ **s'ajuste aux données** — par exemple si les données proviennent bien d'une loi binomiale.

H_0 équivaut à : $p_j = p_j(\theta)$ pour tout j , pour un certain $\theta \in \Theta$.

La construction. Soit $\hat{\theta}$ l'EMV de θ sous H_0 , et

$$\hat{p}_j = \frac{1}{n} \sum_{i=1}^n \mathbf{1}\{X_i = a_j\} = \frac{\#\{i : X_i = a_j\}}{n}$$

L'idée. *Si H_0 est vraie, alors $p_j = p_j(\theta)$, donc $\hat{p}_j$ et $p_j(\hat{\theta})$ sont **tous deux de bons estimateurs de** p_j . Par conséquent $\hat{p}_j \approx p_j(\hat{\theta})$ pour tout j .*

La statistique de test.

$$T_n = n \sum_{j=1}^K \frac{(\hat{p}_j - p_j(\hat{\theta}))^2}{p_j(\hat{\theta})}$$

Le théorème. Sous certaines hypothèses techniques, si H_0 est vraie,

$$T_n \xrightarrow[n \rightarrow \infty]{(d)} \chi_{K-d-1}^2$$

où d est la dimension du paramètre θ ($\Theta \subseteq \mathbb{R}^d$ et $d < K - 1$).

Test de niveau asymptotique α : $\delta_\alpha = \mathbf{1}\{T_n > q_\alpha\}$, avec q_α le quantile d'ordre $(1 - \alpha)$ de χ_{K-d-1}^2 .
p-valeur : $\mathbb{P}[Z > T_n \mid T_n]$ où $Z \sim \chi_{K-d-1}^2$ indépendant de T_n .

Le compte des degrés de liberté, $K - d - 1$, est LA question d'examen. Il se lit en trois temps :

- K classes $\Rightarrow K$ fréquences observées ;
- moins 1 pour la contrainte $\sum_j \hat{p}_j = 1$ — les fréquences ne sont pas libres ;
- moins d pour les d paramètres **estimés sur les données**.

C'est **exactement** la même comptabilité que le $n - p$ de la fiche 50 et le $n - 1$ de Cochran en fiche 65 : **chaque paramètre estimé consomme un degré de liberté**. Et la condition $d < K - 1$ garantit qu'il en reste au moins un.

Notez aussi la normalisation par $p_j(\hat{\theta})$: l'écart $\hat{p}_j - p_j(\hat{\theta})$ est divisé par sa variance approchée, ce qui rend chaque terme comparable à un carré de gaussienne standard — d'où le χ^2 .

● Concept 10 — Le test du khi-deux, cas infini

Si E est infini — $E = \mathbb{N}$, $E = \mathbb{R} \dots$ —, on **partitionne** E en K classes disjointes :

$$E = A_1 \cup \dots \cup A_K$$

et l'on définit, pour $\theta \in \Theta$ et $j = 1, \dots, K$:

$$p_j(\theta) = \mathbb{P}_\theta[Y \in A_j] \text{ pour } Y \sim \mathbb{P}_\theta, \quad p_j = \mathbb{P}[X_1 \in A_j], \quad \hat{p}_j = \frac{\#\{i : X_i \in A_j\}}{n}$$

$\hat{\theta}$ étant obtenu comme précédemment. La statistique et la loi limite sont **inchangées** :

$$T_n = n \sum_{j=1}^K \frac{(\hat{p}_j - p_j(\hat{\theta}))^2}{p_j(\hat{\theta})} \xrightarrow[n \rightarrow \infty]{(d)} \chi_{K-d-1}^2$$

Les questions pratiques, telles que le cours les pose : choix de K ? choix des classes $A_1, \dots, A_K$? calcul de $p_j(\theta)$?

L'exemple du cours. Soit $E = \mathbb{N}$ et $H_0 : \mathbb{P} \in (\text{Pois}(\lambda))_{\lambda > 0}$. Si l'on s'attend à ce que λ ne dépasse pas un certain $\lambda_{\max}$, on peut choisir

$$A_1 = \{0\}, \quad A_2 = \{1\}, \quad \dots, \quad A_{K-1} = \{K-2\}, \quad A_K = \{K-1, K, K+1, \dots\}$$

avec K assez grand pour que $p_K(\lambda_{\max}) \approx 0$.

La construction est astucieuse. Les petites valeurs, fréquentes, ont chacune leur classe ; toute la **queue** est regroupée dans une classe finale A_K de probabilité négligeable. On respecte ainsi la contrainte pratique — chaque classe doit contenir assez d'observations pour que l'approximation χ^2 soit valable — sans perdre la résolution là où les données sont nombreuses.

Le regroupement en classes est une perte d'information, et c'est le prix du test du khi-deux. Deux lois différentes ayant les mêmes probabilités de classe seront indiscernables. Sur des données **continues**, Kolmogorov-Smirnov est donc préférable — il utilise toute l'information de l'échantillon, sans découpage arbitraire.

Comment résoudre l'exercice type (protocole)

1. **Identifier la nature de H_0** : loi **entièrement spécifiée** (test simple) ou **famille paramétrique** (test composite) ?
2. **Identifier la nature des données** : continues $\Rightarrow$ Kolmogorov-Smirnov · discrètes ou regroupées $\Rightarrow$ khi-deux.
3. **Test simple, données continues** : calculer T_n par la formule des statistiques d'ordre, comparer à la table KS.
4. **Test composite** : **ne pas** utiliser la table KS ; utiliser **Kolmogorov-Lilliefors** ou le khi-deux.
5. **Khi-deux** : estimer $\hat{\theta}$ par maximum de vraisemblance **sous H_0** , calculer $\hat{p}_j$ et $p_j(\hat{\theta})$, former T_n , comparer à χ^2_{K-d-1} .
6. **Compter les degrés de liberté** : K classes — 1 (contrainte de somme) — d (paramètres estimés).
7. **Compléter par un QQ-plot** — il montre **où** le modèle échoue.

Comment reconnaître qu'il faut utiliser cette méthode ?

Indice dans l'énoncé	Ce qu'il faut faire
« ces données suivent-elles la loi F^0 ? »	Kolmogorov-Smirnov
« ... une loi gaussienne ? » (paramètres inconnus)	Kolmogorov-Lilliefors , pas KS
données discrètes ou en classes	test du khi-deux
« le modèle s'ajuste-t-il ? »	khi-deux d'adéquation
« combien de degrés de liberté ? »	$K - d - 1$
« les queues sont-elles bien modélisées ? »	Anderson-Darling
« vérification visuelle rapide »	QQ-plot
« simuler la loi de la statistique »	elle est pivotal — c'est possible
« peut-on estimer les paramètres puis appliquer KS ? »	non — Donsker tombe

Exercices progressifs

Niveau 1 — Que disent Glivenko-Cantelli et Donsker, et quel est leur rapport ?

Glivenko-Cantelli — *le théorème fondamental de la statistique* :

$$\sup_{t \in \mathbb{R}} |F_n(t) - F(t)| \xrightarrow{\text{p.s.}} 0$$

La fonction de répartition empirique converge **uniformément** vers la vraie.

Donsker — si F est **continue** :

$$\sqrt{n} \sup_{t \in \mathbb{R}} |F_n(t) - F(t)| \xrightarrow{(d)} \sup_{0 \leq t \leq 1} |B(t)|$$

où B est un **pont brownien**.

Leur rapport est celui de la LGN au TCL.

	LGN / Glivenko-Cantelli	TCL / Donsker
Ponctuel	$F_n(t) \rightarrow F(t)$	$\sqrt{n}(F_n(t) - F(t)) \rightarrow N(0, F(1 - F))$
Uniforme	$\sup_t F_n - F \rightarrow 0$	$\sqrt{n} \sup_t F_n - F \rightarrow \sup B $
Ce qu'il donne	la convergence	la vitesse et la loi

Pourquoi ils comptent. Glivenko-Cantelli justifie qu'on **peut** apprendre la loi sans modèle paramétrique — c'est le fondement de la statistique non paramétrique. Donsker fournit la **loi limite** qui permet de construire un **test**, en calibrant le seuil de rejet.

Niveau 2 — Pourquoi la statistique de Kolmogorov-Smirnov est-elle pivotale, et pourquoi est-ce précieux ?

La démonstration. Posons $U_i = F^0(X_i)$. Sous H_0 , X_i a pour fonction de répartition F^0 , donc par la **transformation intégrale de probabilité**,

$$U_i \stackrel{iid}{\sim} U([0, 1])$$

Soit G_n la fonction de répartition empirique des U_i . Comme F^0 est continue et croissante, $\{X_i \leq t\} \iff \{U_i \leq F^0(t)\}$, et en posant $x = F^0(t)$:

$$T_n = \sup_{t \in \mathbb{R}} \sqrt{n} |F_n(t) - F^0(t)| = \sup_{0 \leq x \leq 1} \sqrt{n} |G_n(x) - x|$$

Le membre de droite ne dépend plus de F^0 . La loi de T_n sous H_0 est donc **la même quelle que soit la loi testée**.

Pourquoi c'est précieux — trois raisons.

1. **Une seule table** de quantiles sert pour tous les tests d'adéquation : gaussienne, exponentielle, Cauchy, n'importe quoi.
2. **On peut simuler** la loi de T_n — tirer M échantillons uniformes et former les T_n^j — précisément parce qu'aucun paramètre inconnu n'intervient. D'où la procédure du concept 5.
3. Le test est **exactement calibré**, sans approximation liée à la loi particulière testée.

Et c'est exactement ce qu'on perd dans le cas composite. Si l'on estime $\hat{\mu}$ et $\hat{\sigma}^2$ sur les données, $\Phi_{\hat{\mu}, \hat{\sigma}^2}(X_i)$ n'est plus uniforme — les U_i deviennent dépendants —, et **Donsker tombe**. Il faut alors la table de **Lilliefors**, différente et plus petite.

Niveau 3 — Pourquoi le test du khi-deux a-t-il $K - d - 1$ degrés de liberté ?

Le décompte, en trois temps.

- 1. On part de K fréquences.** $\hat{p}_1, \dots, \hat{p}_K : K$ quantités observées.
- 2. On retire 1 pour la contrainte de somme.** $\sum_{j=1}^K \hat{p}_j = 1$ **par construction**. Les fréquences ne sont pas libres : connaître $K - 1$ d'entre elles détermine la dernière. Il ne reste que $K - 1$ directions libres.
- 3. On retire d pour les paramètres estimés.** Le vecteur $(p_1(\hat{\theta}), \dots, p_K(\hat{\theta}))$ est ajusté aux données via $\hat{\theta} \in \mathbb{R}^d$. Les écarts $\hat{p}_j - p_j(\hat{\theta})$ sont donc **contraints dans d directions supplémentaires** : l'EMV a rendu ces directions « nulles au premier ordre ».

Total : $K - 1 - d$ directions libres, donc $T_n \rightarrow \chi^2_{K-d-1}$.

La condition $d < K - 1$ garantit qu'il reste au moins un degré de liberté. Si $d = K - 1$, le modèle a autant de paramètres que la loi générale : il s'ajuste parfaitement et il n'y a **rien à tester**.

Le principe général, à retenir. C'est la même comptabilité que partout :

Contexte	Degrés de liberté
Variance empirique (Cochran, fiche 65)	$n - 1$ (moyenne estimée)
Régression (fiche 50)	$n - p$ (p coefficients estimés)
Khi-deux d'adéquation	$K - d - 1$ (somme + d paramètres)
Rapport de vraisemblance (fiche 65)	$d - r$ (nombre de contraintes)

Chaque paramètre estimé sur les données consomme un degré de liberté.

L'erreur classique est d'utiliser $K - 1$ en oubliant les paramètres estimés. Le seuil est alors **trop élevé** et l'on rejette trop rarement — on croit valider un modèle qu'on a simplement bien ajusté.

Niveau 4 — type examen — Pourquoi ne peut-on pas estimer les paramètres puis appliquer Kolmogorov-Smirnov ?

La tentation. On veut tester « X est-elle gaussienne ? » sans connaître μ ni σ^2 . L'idée naturelle est de les estimer par $\hat{\mu} = \bar{X}_n$ et $\hat{\sigma}^2 = S_n^2$, puis de calculer

$$\sup_{t \in \mathbb{R}} |F_n(t) - \Phi_{\hat{\mu}, \hat{\sigma}^2}(t)|$$

et de comparer à la table de Kolmogorov-Smirnov.

*Dans ce cas, le théorème de Donsker n'est plus valide. **C'est une erreur courante et grave !***

Pourquoi Donsker tombe — deux raisons liées.

1. La perte du caractère pivotal. L'argument du concept 5 reposait sur $U_i = F^0(X_i) \stackrel{iid}{\sim} U([0, 1])$. Ici F^0 est remplacée par $\Phi_{\hat{\mu}, \hat{\sigma}^2}$, qui **dépend de tout l'échantillon**. Les variables $\Phi_{\hat{\mu}, \hat{\sigma}^2}(X_i)$ ne sont **ni uniformes ni indépendantes** — chacune a été « recalibrée » à l'aide des autres.

2. Le rapprochement artificiel. $\Phi_{\hat{\mu}, \hat{\sigma}^2}$ est, par construction, la gaussienne qui **colle le mieux** à l'échantillon : on a choisi $\hat{\mu}$ et $\hat{\sigma}^2$ pour cela. L'écart $\sup_t |F_n - \Phi_{\hat{\mu}, \hat{\sigma}^2}|$ est donc **systématiquement plus petit** que si l'on avait utilisé les vrais μ, σ^2 .

La conséquence pratique, et elle est grave. La statistique étant trop petite, on **rejette beaucoup trop rarement** : on conclut à la normalité alors qu'on a seulement constaté qu'on avait bien ajusté une gaussienne. Le vrai niveau du test est très inférieur au niveau nominal, donc la **puissance s'effondre**. Le modèle est validé à tort — et tout ce qui repose dessus (intervalles de confiance, tests de Student, VaR paramétrique) est faux.

La solution : le test de Kolmogorov-Lilliefors. On calcule à la place les quantiles de la statistique $\sup_t |F_n(t) - \Phi_{\hat{\mu}, \hat{\sigma}^2}(t)|$; **ils ne dépendent pas de paramètres inconnus.**

Pourquoi cela marche. Cette statistique reste **pivotal** — mais avec une **autre loi** que celle de KS. La raison est la propriété d'**invariance par location-échelle** de la famille gaussienne : si $X_i \sim N(\mu, \sigma^2)$, alors $(X_i - \hat{\mu})/\hat{\sigma}$ a une loi qui ne dépend **ni de μ ni de σ** . Les quantiles sont donc tabulables une fois pour toutes, et ils sont **plus petits** que ceux de KS — exactement pour compenser l'ajustement.

Les autres voies.

- Le test du **khi-deux**, qui gère nativement l'estimation de θ en retirant d degrés de liberté. C'est la même correction, exprimée autrement.
- Une **estimation sur des données indépendantes** de celles du test — le découpage apprentissage / validation.

Le principe général qu'il faut savoir énoncer. *Estimer des paramètres sur les données consomme de l'information, et tout test qui l'ignore est biaisé en faveur du modèle.* On le retrouve sous trois formes : —**1** dans Cochran, —**p** en régression, —**d** dans le khi-deux — et sous la forme d'une **table différente** pour Lilliefors.

● Common mistakes

1. **Utiliser la table de Kolmogorov-Smirnov après avoir estimé les paramètres** — *erreur courante et grave* : il faut **Lilliefors**.
2. **Oublier l'hypothèse de continuité de F** dans le théorème de Donsker.
3. **Confondre Glivenko-Cantelli et Donsker** — le premier donne la convergence, le second la vitesse et la loi.
4. **Se tromper de degrés de liberté au khi-deux** — c'est $K - d - 1$, pas $K - 1$.
5. **Oublier la condition $d < K - 1$** — sinon il ne reste aucun degré de liberté.
6. **Oublier de normaliser par $p_j(\hat{\theta})$** dans la statistique du khi-deux.
7. **Appliquer le khi-deux avec des classes trop peu peuplées** — l'approximation χ^2 exige assez d'observations par classe.
8. **Croire qu'un QQ-plot est un test** — c'est un diagnostic **visuel**, sans niveau ni p-valeur.
9. **Utiliser KS quand les queues comptent** — il ne voit que le pire écart, souvent au centre ; préférer **Anderson-Darling**.
10. **Chercher le supremum de $|F_n - F^0|$ ailleurs qu'aux points de saut** — il y est toujours atteint.

Ultimate Review

1. **Test d'adéquation** : la loi supposée s'ajuste-t-elle aux données ? Caractéristique : **aucune modélisation paramétrique**.
2. **Fonction de répartition empirique** : $F_n(t) = \frac{1}{n} \sum_i \mathbf{1}\{X_i \leq t\}$; F caractérise entièrement la loi.
3. **LGN** : $F_n(t) \rightarrow F(t)$ p.s. pour chaque t . **Glivenko-Cantelli** : $\sup_t |F_n(t) - F(t)| \rightarrow 0$ p.s. — *théorème fondamental de la statistique*.
4. **TCL** : $\sqrt{n}(F_n(t) - F(t)) \rightarrow N(0, F(t)(1 - F(t)))$.
5. **Donsker** (F continue) : $\sqrt{n} \sup_t |F_n - F| \rightarrow \sup_{0 \leq t \leq 1} |B(t)|$, B pont brownien.
6. **Kolmogorov-Smirnov** : $H_0 : F = F^0$; $T_n = \sup_t \sqrt{n} |F_n(t) - F^0(t)| \rightarrow Z$; $\delta_\alpha^{KS} = \mathbf{1}\{T_n > q_\alpha\}$; p-valeur $\mathbb{P}[Z > T_n \mid T_n]$.
7. **Formule pratique** : $T_n = \sqrt{n} \max_i \max\{\frac{i}{n} - F^0(X_{(i)}), F^0(X_{(i)}) - \frac{i-1}{n}\}$ — le sup est atteint **aux sauts**.
8. **Caractère pivot** : $U_i = F^0(X_i) \sim U([0, 1])$ sous H_0 , donc $T_n = \sup_{0 \leq x \leq 1} \sqrt{n} |G_n(x) - x|$ — **loi indépendante de F^0** .
9. **Simulation** : M copies de T_n , quantile empirique, p-valeur $\approx \#\{j : T_n^j > T_n\} / M$.
10. **Autres distances** : **Cramér-Von Mises** $\int (F_n - F)^2$ · **Anderson-Darling** $\int \frac{(F_n - F)^2}{F(1-F)}$, sensible aux queues.
11. **Cas composite** : remplacer les paramètres par leurs estimations **invalide Donsker** — *erreur courante et grave*.
12. **Kolmogorov-Lilliefors** : recalculer les quantiles de $\sup_t |F_n(t) - \Phi_{\hat{\mu}, \hat{\sigma}^2}(t)|$; ils **ne dépendent d'aucun paramètre inconnu**.
13. **QQ-plot** : tracer $(F^{-1}(i/n), F_n^{-1}(i/n))$ avec $F_n^{-1}(i/n) = X_{(i)}$, et comparer à $y = x$. **Pas un test formel**.
14. **Khi-deux, cas fini** : $p_j(\theta) = \mathbb{P}_\theta[Y = a_j]$, $\hat{p}_j = \#\{i : X_i = a_j\} / n$, $\hat{\theta}$ EMV sous H_0 , et

$$T_n = n \sum_{j=1}^K \frac{(\hat{p}_j - p_j(\hat{\theta}))^2}{p_j(\hat{\theta})} \xrightarrow{(d)} \chi_{K-d-1}^2$$

15. **Degrés de liberté** : K classes $- 1$ (somme) $- d$ (paramètres estimés) ; condition $d < K - 1$.
16. **Cas infini** : partitionner $E = A_1 \cup \dots \cup A_K$, même statistique, même loi limite.
17. **Questions pratiques** : choix de K , choix des classes, calcul de $p_j(\theta)$. Exemple Poisson : $A_j = \{j - 1\}$ et $A_K = \{K - 1, K, \dots\}$ avec $p_K(\lambda_{\max}) \approx 0$.

Formulas to know

$$F_n(t) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}\{X_i \leq t\} \quad \sup_t |F_n(t) - F(t)| \xrightarrow{\text{p.s.}} 0$$

$$\sqrt{n} \sup_t |F_n - F| \xrightarrow{(d)} \sup_{0 \leq t \leq 1} |B(t)| \quad T_n^{KS} = \sup_t \sqrt{n} |F_n(t) - F^0(t)|$$

$$T_n^{\chi^2} = n \sum_{j=1}^K \frac{(\hat{p}_j - p_j(\hat{\theta}))^2}{p_j(\hat{\theta})} \xrightarrow{(d)} \chi_{K-d-1}^2$$

Methods to know : le calcul pratique de T_n par les statistiques d'ordre ; la démonstration du caractère pivotal ; le décompte des degrés de liberté ; le diagnostic par QQ-plot.

Active Recall

Basic — Énoncez le théorème de Glivenko-Cantelli et celui de Donsker.

Glivenko-Cantelli — *le théorème fondamental de la statistique* :

$$\sup_{t \in \mathbb{R}} |F_n(t) - F(t)| \xrightarrow[n \rightarrow \infty]{\text{p.s.}} 0$$

La convergence est **uniforme en t** , plus forte que la convergence ponctuelle donnée par la LGN.

Donsker — si F est **continue** :

$$\sqrt{n} \sup_{t \in \mathbb{R}} |F_n(t) - F(t)| \xrightarrow[n \rightarrow \infty]{(d)} \sup_{0 \leq t \leq 1} |B(t)|$$

où B est un **pont brownien** sur $[0, 1]$ — un mouvement brownien contraint à s'annuler en 0 et en 1, ce qui traduit $F_n = F$ exactement aux deux extrémités.

Understanding — Que signifie « statistique pivotale » et pourquoi est-ce utile ?

Une statistique est **pivotale** si **sa loi sous H_0 ne dépend pas de la loi des données**.

Pour Kolmogorov-Smirnov. En posant $U_i = F^0(X_i)$, on a sous H_0 que $U_i \stackrel{iid}{\sim} U([0, 1])$ (transformation intégrale de probabilité), donc

$$T_n = \sup_{0 \leq x \leq 1} \sqrt{n} |G_n(x) - x|$$

où G_n est la fonction de répartition empirique des U_i . F^0 a disparu.

Les trois bénéfices.

1. **Une seule table** de quantiles pour tous les tests d'adéquation.
2. **On peut simuler** la loi de T_n — tirer M échantillons uniformes — puisque aucun paramètre inconnu n'intervient.
3. Le test est **exactement calibré**, quelle que soit la loi testée.

Et c'est ce qu'on perd dans le cas composite : si les paramètres sont estimés sur les données, les U_i ne sont plus ni uniformes ni indépendants, et Donsker tombe.

Application — On teste si des données suivent une loi de Poisson en les regroupant en **6** classes. Combien de degrés de liberté ?

Le décompte.

- $K = 6$ classes ;
- -1 pour la contrainte $\sum_j \hat{p}_j = 1$;
- $-d = -1$ pour le paramètre λ estimé (la loi de Poisson a **un** paramètre).

$$K - d - 1 = 6 - 1 - 1 = 4 \quad \Rightarrow \quad T_n \xrightarrow{(d)} \chi_4^2$$

Le test. $\delta_\alpha = \mathbf{1}\{T_n > q_\alpha\}$, avec q_α le quantile d'ordre $1 - \alpha$ de χ_4^2 ; à 5 %, $q_{0,05} \approx 9,49$.

La vérification de la condition. $d < K - 1$, soit $1 < 5$.

Le choix des classes, selon la recommandation du cours : $A_1 = \{0\}$, $A_2 = \{1\}$, ..., $A_5 = \{4\}$, $A_6 = \{5, 6, 7, \dots\}$ — les petites valeurs isolées, toute la queue regroupée. On choisit K assez grand pour que $p_K(\lambda_{\max}) \approx 0$.

L'erreur à éviter : utiliser χ^2_5 en oubliant le paramètre estimé. Le seuil serait alors **11,07** au lieu de **9,49**, et l'on rejetterait trop rarement.

Comparison — Kolmogorov-Smirnov ou khi-deux : lequel choisir ?

	Kolmogorov-Smirnov	Khi-deux
Données	continues (F' continue)	discrètes ou regroupées
Découpage	aucun	classes à choisir
Information utilisée	toute l'information de l'échantillon	seulement les fréquences de classes
Paramètres estimés	interdit ($\Rightarrow$ Lilliefors)	géré par $-d$ degrés de liberté
Loi limite	sup pont brownien	χ^2_{K-d-1}
Statistique pivotale	oui	asymptotiquement

KS est préférable sur données **continues avec loi entièrement spécifiée** : il n'y a pas de perte d'information par regroupement, et la statistique est exactement pivotale.

Le khi-deux est préférable sur données **discrètes**, ou dès qu'il faut **estimer des paramètres** — il traite ce cas nativement, en retirant d degrés de liberté, là où KS exige de changer de table.

Les inconvénients respectifs. KS ne regarde que le **pire écart** — souvent situé au centre —, donc il est peu sensible aux queues ; Anderson-Darling corrige ce défaut. Le khi-deux impose des **choix arbitraires** (nombre et bornes des classes) qui influencent le résultat, et il perd de l'information par regroupement.

En pratique, on combine : un test formel, un **QQ-plot** pour voir où le modèle échoue.

Exam-style — Construisez le test du khi-deux d'adéquation et justifiez sa loi limite.

Le cadre. $X_1, \dots, X_n$ i.i.d. sur $E = \{a_1, \dots, a_K\}$ de loi $\mathbb{P}$, et $(\mathbb{P}_\theta)_{\theta \in \Theta}$ une famille paramétrique avec $\Theta \subseteq \mathbb{R}^d$. On teste

$$H_0 : \mathbb{P} \in (\mathbb{P}_\theta)_{\theta \in \Theta} \quad \text{contre} \quad H_1 : \mathbb{P} \notin (\mathbb{P}_\theta)_{\theta \in \Theta}$$

c'est-à-dire : *le modèle statistique s'ajuste-t-il aux données ?* De façon équivalente, $p_j = p_j(\theta)$ pour tout j et un certain θ .

La construction, en trois étapes.

1. Estimer $\hat{\theta}$ par **maximum de vraisemblance sous H_0** .
2. Calculer les fréquences observées $\hat{p}_j = \#\{i : X_i = a_j\}/n$ et les probabilités ajustées $p_j(\hat{\theta})$.
3. *Si H_0 est vraie, $\hat{p}_j$ et $p_j(\hat{\theta})$ sont **tous deux de bons estimateurs de p_j** , donc ils doivent être proches.* D'où

$$T_n = n \sum_{j=1}^K \frac{(\hat{p}_j - p_j(\hat{\theta}))^2}{p_j(\hat{\theta})}$$

Pourquoi cette forme — la normalisation. $n\hat{p}_j$ suit approximativement une binomiale de variance $np_j(1 - p_j) \approx np_j$ pour p_j petit. Diviser l'écart au carré par $p_j(\hat{\theta})$ rend donc chaque terme comparable au **carré d'une gaussienne standard**. La somme de tels carrés est, par définition, un χ^2 (fiche 65).

Pourquoi $K - d - 1$ degrés de liberté.

- K fréquences observées ;
- -1 : elles somment à 1 par construction, donc une seule est déterminée par les autres ;
- $-d$: l'EMV $\hat{\theta}$ ajuste le modèle dans d directions supplémentaires, annulant les écarts au premier ordre dans ces directions.

D'où $T_n \xrightarrow{(d)} \chi_{K-d-1}^2$, sous la condition $d < K - 1$ — sinon il ne reste aucun degré de liberté et il n'y a rien à tester.

Le test. $\delta_\alpha = \mathbf{1}\{T_n > q_\alpha\}$ avec q_α le quantile d'ordre $1 - \alpha$ de χ_{K-d-1}^2 ; p-valeur $\mathbb{P}[Z > T_n \mid T_n], Z \sim \chi_{K-d-1}^2$.

Le cas infini. Si E est infini, on **partitionne** $E = A_1 \cup \dots \cup A_K$ et l'on remplace $\{X_i = a_j\}$ par $\{X_i \in A_j\}$. La statistique et la loi limite sont **inchangées**.

Les trois questions pratiques, que le cours pose explicitement : *choix de K ? choix des classes ? calcul de $p_j(\theta)$?* Pour Poisson, le cours recommande

$A_1 = \{0\}, \dots, A_{K-1} = \{K-2\}, A_K = \{K-1, K, \dots\}$ avec K assez grand pour que $p_K(\lambda_{\max}) \approx 0$.

Ce qu'il faut ajouter en critique. Le regroupement en classes est une **perte d'information** : deux lois ayant les mêmes probabilités de classe sont indiscernables. Et les choix de K et des bornes influencent le résultat — trop de classes et l'approximation χ^2 échoue faute d'observations ; trop peu et la puissance s'effondre. Sur données continues, Kolmogorov-Smirnov est préférable.

Flashcards

Question	Réponse
Caractéristique des tests d'adéquation ?	Aucune modélisation paramétrique
Fonction de répartition empirique ?	$F_n(t) = \frac{1}{n} \sum_i \mathbf{1}\{X_i \leq t\}$
Que dit la LGN pour F_n ?	$F_n(t) \rightarrow F(t)$ p.s. pour chaque t
Théorème de Glivenko-Cantelli ?	$\sup_t F_n(t) - F(t) \rightarrow 0$ p.s.
Son surnom ?	Le théorème fondamental de la statistique
Théorème de Donsker ?	$\sqrt{n} \sup_t F_n - F \rightarrow \sup_{[0,1]} B $
Quelle hypothèse exige-t-il ?	F continue
Quel processus limite ?	Le pont brownien
Pourquoi un pont et pas un brownien ?	$F_n = F$ exactement aux deux extrémités
Statistique de Kolmogorov-Smirnov ?	$T_n = \sup_t \sqrt{n} F_n(t) - F^0(t) $
Où le sup est-il atteint ?	Aux points de saut de F_n
Formule pratique ?	$\sqrt{n} \max_i \max\{\frac{i}{n} - F^0(X_{(i)}), F^0(X_{(i)}) - \frac{i-1}{n}\}$
Que signifie « pivotale » ?	La loi sous H_0 ne dépend pas de celle des données
Pourquoi T_n est-elle pivotale ?	$U_i = F^0(X_i) \sim U([0, 1])$ sous H_0
p-valeur du test KS ?	$\mathbb{P}[Z > T_n \mid T_n]$
Distance de Cramér-Von Mises ?	$\int (F_n - F)^2 dt$
Distance d'Anderson-Darling ?	$\int \frac{(F_n - F)^2}{F(1-F)} dt$
Que privilégie Anderson-Darling ?	Les queues de distribution
Que se passe-t-il si l'on estime les paramètres ?	Donsker n'est plus valide — erreur grave
Pourquoi la statistique devient-elle trop petite ?	La loi ajustée colle par construction aux données
Quel test utiliser alors ?	Kolmogorov-Lilliefors

Question	Réponse
Pourquoi ses quantiles existent-ils ?	Ils ne dépendent d'aucun paramètre inconnu
Qu'est-ce qu'un QQ-plot ?	Un diagnostic visuel , pas un test formel
Que trace-t-on ?	$(F^{-1}(i/n), X_{(i)})$, comparé à $y = x$
Comment définit-on $F_n^{-1}(i/n)$?	$X_{(i)}$, la i -ième plus grande observation
Hypothèses du test du khi-deux ?	$H_0 : \mathbb{P} \in (\mathbb{P}_\theta)$ contre $H_1 : \mathbb{P} \notin (\mathbb{P}_\theta)$
Statistique du khi-deux ?	$n \sum_j \frac{(\hat{p}_j - p_j(\hat{\theta}))^2}{p_j(\hat{\theta})}$
Sa loi limite ?	χ_{K-d-1}^2
Que compte $K - d - 1$?	K classes -1 (somme) $-d$ (paramètres estimés)
Quelle condition sur d ?	$d < K - 1$
Comment traiter un espace infini ?	Partitionner en K classes disjointes
Découpage recommandé pour Poisson ?	$\{0\}, \{1\}, \dots, \{K-2\}, \{K-1, K, \dots\}$