

Fiche 69 — Statistique bayésienne : a priori, a posteriori, Jeffreys et estimateur de Bayes

Matière	Maths · Économétrie
Cours source	Rigollet, <i>18.650 Statistics for Applications</i> , MIT OpenCourseWare, automne 2016 — chapitre 8 « Bayesian Statistics »
Difficulté	High — l'autre façon de faire de la statistique
Temps d'étude estimé	2 h
Prérequis	Fiche 64 (vraisemblance, information de Fisher), fiche 67 (estimateurs, intervalles de confiance)
Concepts clés	Approche fréquentiste et bayésienne, loi a priori, loi a posteriori, formule de Bayes, conjugaison bêta-binomiale, a priori non informatif, a priori impropre, a priori de Jeffreys, invariance par reparamétrisation, région de confiance bayésienne, estimateur de Bayes
Poids à l'examen	Trois choses : la formule de Bayes $\pi(\theta X) \propto \pi(\theta)p_n(X \theta)$ et la conjugaison bêta-Bernoulli ; l' a priori de Jeffreys et son invariance ; et la distinction région de confiance bayésienne / intervalle de confiance.

Vue d'ensemble

L'approche fréquentiste, celle des fiches 64 à 68 :

- on **observe des données** ;
- ces données ont été engendrées **aléatoirement** (par la Nature, par des mesures, par la conception d'un sondage...) ;
- on fait des **hypotheses** sur le processus générateur (i.i.d., données gaussiennes, densité régulière, fonction de régression linéaire...) ;
- ce processus est associé à un **objet d'intérêt** (un paramètre, une densité...) ;
- cet objet était **inconnu mais fixe**, et l'on voulait le trouver : on l'estimait, ou l'on testait une hypothèse à son sujet.

L'approche bayésienne. On observe toujours des données, supposées engendrées aléatoirement par un processus associé à un objet fixe. Mais :

- on a une **croissance a priori** à son sujet ;
- en utilisant les données, on veut **mettre à jour** cette croissance et la transformer en une **croissance a posteriori**.

FRÉQUENTISTE	θ est FIXE et inconnu $\rightarrow$ on l'estime
BAYÉSIEN	on modélise notre CROYANCE sur θ comme une loi
	a priori $\pi(\theta)$ ——— données ———> a posteriori $\pi(\theta X)$
FORMULE	$\pi(\theta X) \propto \pi(\theta) \cdot p_n(X \theta)$
	$\uparrow \qquad \qquad \uparrow$
	croissance vraisemblance
ESTIMATEUR	$\hat{\theta}$ = moyenne a posteriori

● Concept 1 — L'exemple fondateur

Soit p la **proportion de femmes** dans la population. On échantillonne n personnes au hasard avec remise et l'on note $X_1, \dots, X_n$ leur genre (1 pour une femme, 0 sinon).

Dans l'approche fréquentiste, on estimait p (par l'EMV), on construisait un intervalle de confiance, on faisait des tests d'hypothèses ($H_0 : p = 0,5$ contre $H_1 : p \neq 0,5$).

*Avant d'analyser les données, on peut croire que p est vraisemblablement **proche de 1/2**.*

L'approche bayésienne est un outil pour :

1. inclure **mathématiquement** notre croissance a priori dans les procédures statistiques ;
2. mettre à jour cette croissance a priori en utilisant les données.

Comment quantifier la croissance. On est sûr à 90 % que p est entre 0,4 et 0,6, à 95 % qu'il est entre 0,3 et 0,8, etc. On peut donc **modéliser notre croissance a priori par une loi pour p , comme si p était aléatoire.**

*En réalité, le vrai paramètre n'est pas aléatoire ! L'approche bayésienne est une façon de modéliser notre **croyance** sur le paramètre en **faisant comme si** il l'était.*

Par exemple $p \sim B(a, a)$ (loi bêta) pour un $a > 0$. Cette loi s'appelle la **loi a priori**.

Et après observation. * $X_1, \dots, X_n$ sont supposées i.i.d. de Bernoulli de paramètre p **conditionnellement à p** . Après avoir observé l'échantillon, on met à jour notre croyance en prenant la loi de p **conditionnellement aux données** : c'est la **loi a posteriori**.* Ici,

$$B\left(a + \sum_{i=1}^n X_i, a + n - \sum_{i=1}^n X_i\right)$$

● Concept 2 — La formule de Bayes

Le cadre. On considère une loi de probabilité sur l'espace des paramètres Θ , de densité $\pi(\cdot)$: la **loi a priori**. Soit $X_1, \dots, X_n$ un échantillon, et $p_n(\cdot | \theta)$ la densité jointe de $X_1, \dots, X_n$ **conditionnellement à θ** , où $\theta \sim \pi$. On suppose généralement les X_i i.i.d. conditionnellement à θ .

DÉFINITION.

La loi conditionnelle de θ sachant $X_1, \dots, X_n$ est la **loi a posteriori**, de densité $\pi(\cdot | X_1, \dots, X_n)$.

FORMULE DE BAYES.

$$\pi(\theta | X_1, \dots, X_n) \propto \pi(\theta) p_n(X_1, \dots, X_n | \theta), \quad \forall \theta \in \Theta$$

La constante ne dépend pas de θ :

$$\pi(\theta | X_1, \dots, X_n) = \frac{\pi(\theta) p_n(X_1, \dots, X_n | \theta)}{\int_{\Theta} p_n(X_1, \dots, X_n | t) d\pi(t)}$$

Lisez la formule dans les deux sens.

- **A posteriori $\propto$ a priori $\times$ vraisemblance.** La croyance finale combine ce qu'on croyait avant et ce que les données disent. Si l'a priori est plat, seule la vraisemblance compte — on retombe sur le maximum de vraisemblance.
- **Le dénominateur est une simple constante de normalisation.** C'est pourquoi on travaille presque toujours avec le symbole $\propto$: on identifie la forme fonctionnelle en θ , on reconnaît une loi connue, et la constante se déduit.

Le renversement conceptuel est complet par rapport à la fiche 65. Le fréquentiste calcule $\mathbb{P}[\text{données} \mid H_0]$ — la p-valeur. Le bayésien calcule $\mathbb{P}[\theta \mid \text{données}]$ — la loi a posteriori. Ce sont les deux conditionnements inverses, et passer de l'un à l'autre exige précisément une **loi a priori**, ce que le cadre fréquentiste refuse de fournir.

● Concept 3 — L'exemple bêta-Bernoulli en détail

L'a priori. $\pi(p) \propto p^{a-1}(1-p)^{a-1}$ pour $p \in (0, 1)$ — c'est la densité de $B(a, a)$.

La vraisemblance. Sachant p , les X_i sont i.i.d. $\text{Ber}(p)$, donc

$$p_n(X_1, \dots, X_n \mid p) = p^{\sum_{i=1}^n X_i} (1-p)^{n - \sum_{i=1}^n X_i}$$

L'a posteriori. Par la formule de Bayes,

$$\pi(p \mid X_1, \dots, X_n) \propto p^{a-1 + \sum_i X_i} (1-p)^{a-1 + n - \sum_i X_i}$$

On **reconnaît** la forme d'une densité bêta, donc

$$\pi(\cdot \mid X_1, \dots, X_n) = B\left(a + \sum_{i=1}^n X_i, a + n - \sum_{i=1}^n X_i\right)$$

C'est le phénomène de conjugaison : l'a priori est bêta, l'a posteriori aussi. La mise à jour se réduit à **ajouter les succès au premier paramètre et les échecs au second**. Aucune intégrale à calculer — on lit le résultat.

L'interprétation des paramètres de l'a priori devient alors très parlante : $B(a, a)$ équivaut à avoir déjà observé a succès et a échecs **fictifs**. Plus a est grand, plus la croyance initiale est ferme et plus il faudra de données pour la déplacer. C'est ce qu'on appelle des « observations équivalentes a priori ».

● Concept 4 — Les a priori non informatifs

L'idée. *En cas d'ignorance, ou d'absence d'information a priori, on peut vouloir utiliser un a priori aussi peu informatif que possible.*

Bon candidat : $\pi(\theta) \propto 1$, c'est-à-dire une densité **constante** sur Θ .

- Si Θ est **borné**, c'est l'a priori **uniforme** sur Θ .
- Si Θ est **non borné**, cela **ne définit pas une densité valide** sur Θ !

DÉFINITION.

Un **a priori impropre** sur Θ est une fonction mesurable, positive, définie sur Θ , **non intégrable**.

En général, on peut malgré tout définir une loi a posteriori à partir d'un a priori impropre, en utilisant la formule de Bayes.

Les deux exemples.

- Si $p \sim U(0, 1)$ et, sachant p , $X_1, \dots, X_n \stackrel{iid}{\sim} \text{Ber}(p)$:

$$\pi(p \mid X_1, \dots, X_n) \propto p^{\sum_i X_i} (1-p)^{n-\sum_i X_i} \implies B\left(1 + \sum_i X_i, 1 + n - \sum_i X_i\right)$$

- Si $\pi(\theta) = 1$ pour tout $\theta \in \mathbb{R}$ et, sachant θ , $X_1, \dots, X_n \stackrel{iid}{\sim} N(\theta, 1)$:

$$\pi(\theta \mid X_1, \dots, X_n) \propto \exp\left(-\frac{1}{2} \sum_{i=1}^n (X_i - \theta)^2\right) \implies N\left(\bar{X}_n, \frac{1}{n}\right)$$

Le second cas illustre bien le mécanisme. $\pi(\theta) = 1$ sur $\mathbb{R}$ n'est **pas** une densité — son intégrale est infinie. Pourtant, multipliée par la vraisemblance gaussienne, elle donne une a posteriori parfaitement **propre** : $N(\bar{X}_n, 1/n)$. L'impropriété de l'a priori est « absorbée » par l'intégrabilité de la vraisemblance.

Et remarquez le résultat : la moyenne a posteriori est $\bar{X}_n$, l'EMV, et la variance $1/n$ reproduit exactement la variance de $\bar{X}_n$. **Avec un a priori plat, bayésien et fréquentiste coïncident** — ce qui est rassurant, puisque ne rien croire a priori revient à laisser parler les seules données.

● Concept 5 — L'a priori de Jeffreys

DÉFINITION.

$$\pi_J(\theta) \propto \sqrt{\det I(\theta)}$$

où $I(\theta)$ est la **matrice d'information de Fisher** du modèle statistique associé à $X_1, \dots, X_n$ dans l'approche fréquentiste (lorsqu'elle existe).

Les deux exemples.

- **Exemple 1** (Bernoulli) : $I(p) = \frac{1}{p(1-p)}$ (fiche 64), donc

$$\pi_J(p) \propto \frac{1}{\sqrt{p(1-p)}}, \quad p \in (0, 1)$$

L'a priori est $B(1/2, 1/2)$.

- **Exemple 2** (gaussien de variance connue) : $\pi_J(\theta) \propto 1$ pour $\theta \in \mathbb{R}$ — c'est un **a priori impropre**.

Le principe d'invariance par reparamétrisation. Si η est une reparamétrisation de θ , c'est-à-dire $\eta = \varphi(\theta)$ pour une application bijective φ , alors la densité $\tilde{\pi}(\cdot)$ de η vérifie

$$\tilde{\pi}(\eta) \propto \sqrt{\det \tilde{I}(\eta)}$$

où $\tilde{I}(\eta)$ est l'information de Fisher du modèle paramétré par η au lieu de θ .

POURQUOI CETTE INVARIANCE EST LA JUSTIFICATION DÉCISIVE DE JEFFREYS.

L'a priori uniforme a un défaut caché : **il n'est pas invariant**. Être « uniforme sur p » n'est pas être « uniforme sur $\log \frac{p}{1-p}$ » — ignorer p n'entraîne pas ignorer son logit. Le choix de la paramétrisation, qui devrait être arbitraire, influencerait alors les conclusions.

L'a priori de Jeffreys, lui, **se transforme correctement** : appliquer π_J dans une paramétrisation ou dans une autre donne **la même loi a posteriori**. C'est ce qui en fait le candidat canonique d'a priori non informatif.

Et remarquez la belle circularité : le fréquentiste utilise $I(\theta)$ pour mesurer la **précision** de son estimateur (fiche 64) ; le bayésien l'utilise pour définir son **ignorance**. Là où l'information est grande, l'a priori de Jeffreys met **plus de masse** — précisément là où les données discrimineront le mieux.

● Concept 6 — Les régions de confiance bayésiennes

DÉFINITION.

Pour $\alpha \in (0, 1)$, une **région de confiance bayésienne de niveau α** est un sous-ensemble aléatoire R de l'espace des paramètres Θ , dépendant de l'échantillon, tel que

$$\mathbb{P}[\theta \in R \mid X_1, \dots, X_n] = 1 - \alpha$$

Noter que R dépend de l'a priori $\pi(\cdot)$.

« Région de confiance bayésienne » et « intervalle de confiance » sont deux notions distinctes.

Cette dernière phrase mérite d'être développée, car c'est le point le plus souvent confondu.

	Intervalle de confiance (fiche 67)	Région bayésienne
Ce qui est aléatoire	l'intervalle I	le paramètre θ
Énoncé	$\mathbb{P}_\theta[I \ni \theta] \geq 1 - \alpha$	$\mathbb{P}[\theta \in R \mid X] = 1 - \alpha$
Sur quoi porte la probabilité	la procédure , répétée	la croyance , ce coup-ci
Dépend d'un a priori	non	oui
Lecture	« 95 % des intervalles ainsi construits contiendraient θ »	« je crois à 95 % que $\theta \in R$ »

La lecture bayésienne est celle que tout le monde croit faire en lisant un intervalle de confiance — et c'est précisément pourquoi la confusion est si répandue. Mais elle a un prix : elle dépend de l'a priori choisi, donc elle n'est pas « objective ».

● Concept 7 — L'estimation bayésienne

Le changement de point de vue. Le cadre bayésien peut aussi servir à **estimer le vrai paramètre sous-jacent** — donc dans une approche fréquentiste. Dans ce cas, la loi a priori **ne reflète pas une croyance** : c'est un **outil artificiel** servant à définir une **nouvelle classe d'estimateurs**.

La construction. L'échantillon $X_1, \dots, X_n$ est associé à un modèle $(E, (\mathbb{P}_\theta)_{\theta \in \Theta})$. On définit une loi — éventuellement **impropre** — de densité π sur Θ , on calcule la densité a posteriori $\pi(\cdot \mid X_1, \dots, X_n)$ associée à π vue comme a priori, puis :

DÉFINITION — ESTIMATEUR DE BAYES.

$$\hat{\theta}^{(\pi)} = \int_{\Theta} \theta d\pi(\theta \mid X_1, \dots, X_n)$$

C'est la **moyenne a posteriori**.

L'estimateur bayésien **dépend du choix de l'a priori π** — d'où l'exposant.

Les exemples.

Exemple 1, avec a priori $B(a, a)$, $a > 0$:

$$\hat{p}^{(\pi)} = \frac{a + \sum_{i=1}^n X_i}{2a + n} = \frac{a/n + \bar{X}_n}{2a/n + 1}$$

En particulier, pour $a = 1/2$ (a priori de Jeffreys) :

$$\hat{p}^{(\pi_J)} = \frac{1/(2n) + \bar{X}_n}{1/n + 1}$$

Exemple 2 : $\hat{\theta}^{(\pi_J)} = \bar{X}_n$.

Les propriétés asymptotiques. Dans chacun de ces exemples, l'estimateur de Bayes est **consistant et asymptotiquement normal**. En général, les **propriétés asymptotiques de l'estimateur de Bayes ne dépendent pas du choix de l'a priori**.

C'est le résultat qui réconcilie les deux écoles. Regardez la formule de l'exemple 1 :

$$\hat{p}^{(\pi)} = \frac{a/n + \bar{X}_n}{2a/n + 1} \xrightarrow[n \rightarrow \infty]{} \bar{X}_n$$

L'a priori contribue par des termes en a/n , qui **s'évanouissent** quand n croît. Autrement dit : **les données finissent toujours par l'emporter sur la croyance initiale**.

La conséquence pratique. Le choix de l'a priori compte sur **petit échantillon** — c'est là qu'il régularise, et c'est là qu'il est contestable. Sur grand échantillon, bayésien et fréquentiste **convergent vers la même réponse**. C'est le contenu du théorème de Bernstein-von Mises.

Notez le rôle régularisateur de l'a priori sur petit échantillon. Si l'on observe $n = 3$ succès sur 3 essais, l'EMV donne $\hat{p} = 1$ — une certitude absurde. L'estimateur de Bayes avec $a = 1/2$ donne $\frac{0,5+3}{1+3} = 0,875$, bien plus raisonnable. C'est exactement l'arbitrage biais-variance de la fiche 67 : un peu de biais contre beaucoup de variance en moins.

Comment résoudre l'exercice type (protocole)

1. **Identifier le modèle** : $p_n(X \mid \theta)$, la vraisemblance.

2. **Choisir l'a priori $\pi(\theta)$** : informatif (croyance), uniforme, ou **Jeffreys** $\propto \sqrt{\det I(\theta)}$.
3. **Appliquer la formule de Bayes** : $\pi(\theta | X) \propto \pi(\theta)p_n(X | \theta)$.
4. **Reconnaître la loi** dans l'expression obtenue — la constante de normalisation se déduit.
5. **Calculer l'estimateur de Bayes** : la **moyenne a posteriori**.
6. **Vérifier le comportement asymptotique** : les termes en $1/n$ venant de l'a priori doivent s'évanouir.
7. **Pour une région de confiance** : prendre un ensemble de masse a posteriori $1 - \alpha$ — et **ne pas confondre** avec un intervalle de confiance.

Comment reconnaître qu'il faut utiliser cette méthode ?

Indice dans l'énoncé	Ce qu'il faut faire
« on croit a priori que... »	approche bayésienne , a priori informatif
« en l'absence d'information »	a priori uniforme ou de Jeffreys
« Θ non borné et a priori constant »	a priori impropre
a priori bêta + données Bernoulli	conjugaison $\Rightarrow$ a posteriori bêta
a priori plat + données gaussiennes	a posteriori $N(\bar{X}_n, 1/n)$
« quelle est la probabilité que $\theta \in R$? »	région bayésienne , pas IC
« invariance par changement de paramétrisation »	Jeffreys
« estimateur régularisé sur petit échantillon »	estimateur de Bayes
« l'a priori influence-t-il le résultat ? »	non asymptotiquement

Exercices progressifs

Niveau 1 — Calculez l'a posteriori pour un a priori $B(a, a)$ et des données de Bernoulli.

L'a priori. $\pi(p) \propto p^{a-1}(1-p)^{a-1}$ sur $(0, 1)$.

La vraisemblance. Sachant p , avec $S = \sum_{i=1}^n X_i$:

$$p_n(X_1, \dots, X_n | p) = p^S (1-p)^{n-S}$$

La formule de Bayes.

$$\pi(p | X) \propto p^{a-1}(1-p)^{a-1} \cdot p^S(1-p)^{n-S} = p^{a-1+S}(1-p)^{a-1+n-S}$$

La reconnaissance. C'est la forme d'une densité $B(\alpha, \beta)$ avec $\alpha - 1 = a - 1 + S$ et $\beta - 1 = a - 1 + n - S$, donc

$$\pi(\cdot | X) = B(a + S, a + n - S)$$

L'estimateur de Bayes. La moyenne d'une $B(\alpha, \beta)$ vaut $\frac{\alpha}{\alpha+\beta}$, donc

$$\hat{p}^{(\pi)} = \frac{a + S}{(a + S) + (a + n - S)} = \frac{a + S}{2a + n} = \frac{a/n + \bar{X}_n}{2a/n + 1}$$

La lecture. C'est une **moyenne pondérée** entre $\bar{X}_n$ (les données) et $1/2$ (le centre de l'a priori $B(a, a)$), avec un poids $\frac{2a}{2a+n}$ pour l'a priori. Ce poids tend vers 0 quand $n \rightarrow \infty$: **les données l'emportent**.

Le phénomène de conjugaison. A priori bêta $\rightarrow$ a posteriori bêta. La mise à jour se réduit à ajouter S succès et $n - S$ échecs aux paramètres. On peut donc lire $B(a, a)$ comme « a succès et a échecs fictifs déjà observés ».

Niveau 2 — Qu'est-ce qu'un a priori impropre, et pourquoi est-ce acceptable ?

La définition. Un a priori impropre sur Θ est une fonction mesurable, positive, définie sur Θ , mais **non intégrable**.

D'où cela vient. On cherche un a priori « non informatif », et le candidat naturel est $\pi(\theta) \propto 1$ — constant. Si Θ est **borné**, c'est l'uniforme, parfaitement légitime. Si Θ est **non borné** — par exemple $\Theta = \mathbb{R}$ —, alors $\int_{\mathbb{R}} 1 d\theta = \infty$: **ce n'est pas une densité**.

Pourquoi c'est malgré tout acceptable. En général, on peut quand même définir une loi a posteriori en utilisant la formule de Bayes. Ce qui compte est que le **produit** soit intégrable :

$$\pi(\theta | X) \propto \pi(\theta) p_n(X | \theta)$$

Si $\pi \equiv 1$ et $p_n(X | \theta)$ est intégrable en θ — ce qui est le cas des vraisemblances usuelles —, l'a posteriori est une **vraie densité**.

L'exemple du cours. $\pi(\theta) = 1$ sur $\mathbb{R}$ avec $X_i \stackrel{iid}{\sim} N(\theta, 1)$:

$$\pi(\theta | X) \propto \exp \left(-\frac{1}{2} \sum_i (X_i - \theta)^2 \right) \propto \exp \left(-\frac{n}{2} (\theta - \bar{X}_n)^2 \right)$$

c'est-à-dire $N(\bar{X}_n, \frac{1}{n})$ — parfaitement propre, malgré l'a priori impropre.

Le résultat remarquable. La moyenne a posteriori vaut $\bar{X}_n$, exactement l'EMV, et la variance a posteriori $1/n$ reproduit la variance de $\bar{X}_n$. **Avec un a priori plat, l'inférence bayésienne et l'inférence fréquentiste coïncident.**

La précaution à prendre. Il faut **toujours vérifier** que l'a posteriori est propre. Il existe des combinaisons a priori impropre / vraisemblance où l'intégrale diverge : on obtient alors une « loi » qui n'en est pas une, et toute conclusion est vide de sens.

Niveau 3 — Pourquoi l'a priori de Jeffreys et pas simplement l'uniforme ?

La définition. $\pi_J(\theta) \propto \sqrt{\det I(\theta)}$, où $I(\theta)$ est l'information de Fisher.

Le défaut de l'uniforme : il n'est pas invariant. Supposons qu'on veuille « ne rien croire » sur $p \in (0, 1)$ et qu'on prenne $\pi(p) \propto 1$. Reparamétrisons par le logit $\eta = \log \frac{p}{1-p}$. Par changement de variable, la densité induite sur η est

$$\tilde{\pi}(\eta) = \pi(p(\eta)) \left| \frac{dp}{d\eta} \right| \propto \frac{e^\eta}{(1 + e^\eta)^2}$$

qui n'est **pas** constante. Autrement dit : **être uniforme sur p n'est pas être uniforme sur η** . Deux personnes prétendant toutes deux « ne rien savoir », l'une raisonnant en p et l'autre en logit, arriveraient à des a posteriori **différents**. C'est incohérent — le choix de la paramétrisation devrait être sans effet.

Ce que Jeffreys corrige. Si $\eta = \varphi(\theta)$ pour une application bijective φ , alors la densité $\tilde{\pi}$ de η vérifie $\tilde{\pi}(\eta) \propto \sqrt{\det \tilde{I}(\eta)}$ — c'est-à-dire que **l'a priori de Jeffreys calculé dans la nouvelle paramétrisation est exactement l'image de celui calculé dans l'ancienne**.

Pourquoi cela marche. Sous reparamétrisation, l'information de Fisher se transforme comme $\tilde{I}(\eta) = I(\theta) \left(\frac{d\theta}{d\eta} \right)^2$, donc $\sqrt{\tilde{I}(\eta)} = \sqrt{I(\theta)} \left| \frac{d\theta}{d\eta} \right|$ — exactement la règle de changement de variable pour une densité. **Le jacobien est absorbé.**

Les deux exemples du cours.

- Bernoulli : $I(p) = \frac{1}{p(1-p)}$, donc $\pi_J(p) \propto \frac{1}{\sqrt{p(1-p)}}$, c'est-à-dire $B(1/2, 1/2)$ — une loi en U, qui met **plus de masse près de 0 et de 1** que l'uniforme.
- Gaussien de variance connue : $I(\theta)$ constante, donc $\pi_J(\theta) \propto 1$ — **impropre**, mais qui redonne l'inférence fréquentiste.

L'interprétation profonde. L'a priori de Jeffreys met plus de masse là où l'information de Fisher est **grande**, c'est-à-dire là où les données **discriminent le mieux** entre valeurs voisines du paramètre. Pour Bernoulli, c'est près de **0** et de **1** : $I(p) = \frac{1}{p(1-p)}$ y explose (fiche 64). Autrement dit, l'a priori s'adapte à la **géométrie du modèle** plutôt qu'à un système de coordonnées arbitraire.

Niveau 4 — type examen — Comparez l'approche fréquentiste et l'approche bayésienne.

	Fréquentiste	Bayésien
Statut de θ	fixe et inconnu	modélisé comme s'il était aléatoire
Ce qui est aléatoire	les données	les données et la croyance sur θ
Point de départ	un modèle $(E, (\mathbb{P}_\theta))$	un modèle plus un a priori π
Résultat	un estimateur ponctuel , un IC, un test	une loi a posteriori entière
Estimateur	EMV, moments	moyenne a posteriori
Incertitude	$\mathbb{P}_\theta[I \ni \theta] \geq 1 - \alpha$	$\mathbb{P}[\theta \in R \mid X] = 1 - \alpha$
Sur quoi porte la probabilité	la procédure , répétée	la croyance , ce coup-ci

Le point conceptuel décisif. *En réalité, le vrai paramètre n'est pas aléatoire ! L'approche bayésienne est une façon de modéliser notre **croyance** en faisant comme si il l'était.* La probabilité change donc de nature : elle mesure une **incertitude épistémique** et non plus une fréquence limite.

La formule qui articule tout.

$$\pi(\theta \mid X_1, \dots, X_n) \propto \underbrace{\pi(\theta)}_{\text{croyance}} \cdot \underbrace{p_n(X_1, \dots, X_n \mid \theta)}_{\text{vraisemblance}}$$

Le fréquentiste ne garde que le second facteur — maximiser la vraisemblance, c'est le cas particulier d'un a priori plat.

Ce que le bayésien apporte.

1. Une **distribution complète** sur θ , pas seulement un point et un écart-type.
2. Une **régularisation naturelle** sur petit échantillon : **3** succès sur **3** donnent $\hat{p} = 1$ en EMV — certitude absurde — contre **0,875** avec l'a priori de Jeffreys.
3. Des énoncés **directement interprétables** : « je crois à **95 %** que $\theta \in R$ » est ce que tout le monde croit lire dans un intervalle de confiance.

Ce qu'il coûte.

1. Il faut **choisir un a priori**, et ce choix est contestable — d'où l'effort du cours sur les a priori non informatifs et sur **Jeffreys**, qui règle au moins le problème de l'arbitraire de la paramétrisation.
2. Le calcul de l'a posteriori demande une intégrale, praticable seulement en cas de **conjugaison** ou par méthodes numériques.

La réconciliation asymptotique — et c'est la conclusion du cours. *Les propriétés asymptotiques de l'estimateur de Bayes ne dépendent pas du choix de l'a priori.* La formule

$$\hat{p}^{(\pi)} = \frac{a/n + \bar{X}_n}{2a/n + 1} \longrightarrow \bar{X}_n$$

le montre : la contribution de l'a priori est d'ordre $1/n$ et s'évanouit. **Les données finissent toujours par l'emporter.**

La conclusion pratique. Le débat n'a d'enjeu réel que sur **petit échantillon**, ou quand une information a priori véritable existe — antécédents cliniques, contraintes physiques, jugement d'expert. Sur grand échantillon, les deux écoles donnent la même réponse, et le choix relève de la commodité et de l'interprétation souhaitée.

● Common mistakes

1. **Croire que le vrai paramètre est aléatoire** — *en réalité il ne l'est pas* ; on modélise une **croissance**.
2. **Oublier la constante de normalisation** — elle ne dépend pas de θ , on peut travailler en $\propto$, mais il faut savoir qu'elle existe.
3. **Confondre région de confiance bayésienne et intervalle de confiance** — *deux notions distinctes*.
4. **Utiliser un a priori impropre sans vérifier que l'a posteriori est propre** — l'intégrale peut diverger.

5. **Croire que l'a priori uniforme est non informatif** — il **n'est pas invariant** par reparamétrisation.
6. **Oublier la racine carrée dans Jeffreys** — c'est $\sqrt{\det I(\theta)}$, pas $\det I(\theta)$.
7. **Prendre le mode a posteriori pour l'estimateur de Bayes** — c'est la **moyenne** a posteriori.
8. **Croire que le choix de l'a priori change les conclusions asymptotiques** — il ne les change pas.
9. **Négliger l'effet de l'a priori sur petit échantillon** — c'est là, au contraire, qu'il compte le plus.

Ultimate Review

1. **Fréquentiste** : θ **fixe et inconnu**, on l'estime ou on le teste. **Bayésien** : on a une **croyance a priori**, qu'on **met à jour** par les données.
2. *En réalité le vrai paramètre **n'est pas aléatoire*** ; on modélise une croyance **comme si** il l'était.
3. **Loi a priori** $\pi(\theta)$ sur Θ ; **loi a posteriori** $\pi(\theta | X_1, \dots, X_n)$ = loi conditionnelle de θ sachant les données.
4. **Formule de Bayes** : $\pi(\theta | X) \propto \pi(\theta)p_n(X | \theta)$, la constante étant $\int_{\Theta} p_n(X | t)d\pi(t)$.
5. **Conjugaison bêta-Bernoulli** : a priori $B(a, a) \Rightarrow$ a posteriori $B(a + \sum X_i, a + n - \sum X_i)$.
6. **A priori non informatif** : $\pi(\theta) \propto 1$; **uniforme** si Θ borné, **impropre** sinon.
7. **A priori impropre** : positif, mesurable, **non intégrable** ; l'a posteriori peut malgré tout être propre.
8. **Exemples** : $U(0, 1) + \text{Bernoulli} \Rightarrow B(1 + \sum X_i, 1 + n - \sum X_i)$; $\pi \equiv 1 + N(\theta, 1) \Rightarrow N(\bar{X}_n, \frac{1}{n})$.
9. **A priori de Jeffreys** : $\pi_J(\theta) \propto \sqrt{\det I(\theta)}$; Bernoulli $\Rightarrow B(1/2, 1/2)$; gaussien $\Rightarrow \pi_J \propto 1$, impropre.
10. **Invariance par reparamétrisation** : si $\eta = \varphi(\theta)$, alors $\tilde{\pi}(\eta) \propto \sqrt{\det \tilde{I}(\eta)}$ — c'est la justification de Jeffreys.
11. **Région de confiance bayésienne** : R aléatoire avec $\mathbb{P}[\theta \in R | X] = 1 - \alpha$; **dépend de l'a priori** ; **distincte** d'un intervalle de confiance.
12. **Estimation bayésienne** : l'a priori devient un **outil artificiel** définissant une classe d'estimateurs.
13. **Estimateur de Bayes** : $\hat{\theta}^{(\pi)} = \int_{\Theta} \theta d\pi(\theta | X)$, la **moyenne a posteriori**.
14. **Exemples** : $\hat{p}^{(\pi)} = \frac{a + \sum X_i}{2a + n} = \frac{a/n + \bar{X}_n}{2a/n + 1}$; pour $a = 1/2$, $\hat{p}^{(\pi_J)} = \frac{1/(2n) + \bar{X}_n}{1/n + 1}$; $\hat{\theta}^{(\pi_J)} = \bar{X}_n$.
15. **Propriétés** : consistant et asymptotiquement normal ; *les propriétés asymptotiques **ne dépendent pas** de l'a priori.*

Formulas to know

$$\pi(\theta | X_1, \dots, X_n) = \frac{\pi(\theta)p_n(X_1, \dots, X_n | \theta)}{\int_{\Theta} p_n(X_1, \dots, X_n | t)d\pi(t)}$$

$$B(a, a) + \text{Ber}(p) \implies B\left(a + \sum_i X_i, a + n - \sum_i X_i\right) \quad \pi_J(\theta) \propto \sqrt{\det I(\theta)}$$

$$\hat{\theta}^{(\pi)} = \int_{\Theta} \theta d\pi(\theta | X_1, \dots, X_n) \quad \hat{p}^{(\pi)} = \frac{a/n + \bar{X}_n}{2a/n + 1}$$

Methods to know : appliquer la formule de Bayes et reconnaître la loi a posteriori ; calculer un a priori de Jeffreys ; calculer une moyenne a posteriori ; vérifier l'évanouissement asymptotique de l'a priori.

Active Recall

Basic — Énoncez la formule de Bayes pour la loi a posteriori.

$$\pi(\theta | X_1, \dots, X_n) \propto \pi(\theta) p_n(X_1, \dots, X_n | \theta)$$

soit, avec la constante de normalisation explicite,

$$\pi(\theta | X_1, \dots, X_n) = \frac{\pi(\theta) p_n(X_1, \dots, X_n | \theta)}{\int_{\Theta} p_n(X_1, \dots, X_n | t) d\pi(t)}$$

En mots : a posteriori $\propto$ a priori $\times$ vraisemblance. Le dénominateur ne dépend pas de θ ; on travaille donc en $\propto$ et l'on reconnaît la loi obtenue.

Understanding — Pourquoi l'a priori de Jeffreys plutôt que l'uniforme ?

Parce que l'a priori uniforme **n'est pas invariant par reparamétrisation**. Être uniforme sur p n'est pas être uniforme sur $\log \frac{p}{1-p}$: deux personnes prétendant « ne rien savoir », l'une raisonnant en p et l'autre en logit, obtiendraient des a posteriori **différents**. Le choix de la paramétrisation, qui devrait être sans effet, en aurait un.

L'a priori de Jeffreys $\pi_J(\theta) \propto \sqrt{\det I(\theta)}$ satisfait le **principe d'invariance** : si $\eta = \varphi(\theta)$ avec φ bijective, alors $\tilde{\pi}(\eta) \propto \sqrt{\det \tilde{I}(\eta)}$. La raison est que $\sqrt{I}$ se transforme **exactement comme le jacobien** d'un changement de variable de densité.

Les deux exemples : Bernoulli $\implies \pi_J(p) \propto \frac{1}{\sqrt{p(1-p)}}$, c'est-à-dire $B(1/2, 1/2)$; gaussien de variance connue $\implies \pi_J \propto 1$, **impropre**.

L'interprétation : Jeffreys met plus de masse là où l'information de Fisher est grande — là où les données discriminent le mieux. Il s'adapte à la **géométrie du modèle** plutôt qu'à un système de coordonnées arbitraire.

Application — On observe 8 succès sur 10 essais. Comparez l'EMV et l'estimateur de Bayes avec a priori de Jeffreys.

L'EMV (fiche 64) : $\hat{p}^{MLE} = \bar{X}_n = \frac{8}{10} = 0,80$.

L'estimateur de Bayes avec l'a priori de Jeffreys, c'est-à-dire $a = 1/2$:

$$\hat{p}^{(\pi_J)} = \frac{a + \sum_i X_i}{2a + n} = \frac{0,5 + 8}{1 + 10} = \frac{8,5}{11} \approx 0,773$$

La loi a posteriori complète : $B(0,5 + 8, 0,5 + 10 - 8) = B(8,5; 2,5)$ — dont on peut tirer une **région de confiance bayésienne** et non seulement un point.

La lecture. L'estimateur de Bayes **tire légèrement vers le centre** : 0,773 au lieu de 0,80. C'est le **rétrécissement** (*shrinkage*) induit par l'a priori.

Le cas extrême qui rend l'effet visible. Avec 3 succès sur 3 :

- EMV : $\hat{p} = 1$ — on affirmerait qu'un échec est **impossible**, sur la foi de trois observations. Absurde.
- Bayes ($a = 1/2$) : $\frac{0,5+3}{1+3} = 0,875$ — bien plus prudent.

Et asymptotiquement. $\hat{p}^{(\pi_J)} = \frac{1/(2n) + \bar{X}_n}{1/n + 1} \rightarrow \bar{X}_n$: les deux estimateurs **coïncident** quand n grandit. L'a priori ne compte que sur petit échantillon — ce qui est exactement là où l'on en a besoin.

Comparison — Région de confiance bayésienne et intervalle de confiance : quelle différence ?

Le cours est explicite : *ce sont deux notions distinctes.*

	Intervalle de confiance	Région bayésienne
Énoncé	$\mathbb{P}_\theta[I \ni \theta] \geq 1 - \alpha$	$\mathbb{P}[\theta \in R \mid X_1, \dots, X_n] = 1 - \alpha$
Ce qui est aléatoire	l' intervalle	le paramètre (au sens de la croyance)
Conditionnement	aucun — probabilité sur les échantillons	sachant les données observées
Dépend d'un a priori	non	oui
Lecture correcte	« 95 % des intervalles ainsi construits contiendraient θ »	« je crois à 95 % que $\theta \in R$ »

Le point crucial. L'intervalle de confiance porte sur la **procédure répétée** : sur de nombreux échantillons, **95 %** des intervalles construits ainsi contiendraient le vrai θ . Il ne dit **rien** sur l'échantillon particulier qu'on a sous les yeux.

La région bayésienne porte sur la **croyance après avoir vu ces données-ci**. C'est l'énoncé que tout le monde croit lire dans un intervalle de confiance — et c'est précisément pour cela que la confusion est si répandue.

Le prix de l'interprétation naturelle : R dépend de l'a priori choisi. Il n'y a pas de région bayésienne « objective ».

Numériquement, les deux coïncident souvent — avec un a priori plat et un grand n , la région bayésienne et l'intervalle de confiance sont presque identiques. Mais leur **signification** reste différente.

Exam-style — Construisez l'inférence bayésienne complète pour un modèle de Bernoulli.

1. Le modèle. $X_1, \dots, X_n \stackrel{iid}{\sim} \text{Ber}(p)$ **conditionnellement à** p , avec $p \in (0, 1)$. On note $S = \sum_i X_i$.

2. Le choix de l'a priori. Trois options :

- **informatif** : $p \sim B(a, a)$ si l'on croit p proche de $1/2$ — le cours donne l'exemple « **90 %** sûr que $p \in [0,4; 0,6]$ » ;

- **uniforme** : $p \sim U(0, 1) = B(1, 1)$;
- **Jeffreys** : $\pi_J(p) \propto \frac{1}{\sqrt{p(1-p)}}$, c'est-à-dire $B(1/2, 1/2)$, puisque $I(p) = \frac{1}{p(1-p)}$.

3. **La vraisemblance.** $p_n(X | p) = p^S(1 - p)^{n-S}$.

4. **L'a posteriori, par la formule de Bayes.**

$$\pi(p | X) \propto p^{a-1}(1 - p)^{a-1} \cdot p^S(1 - p)^{n-S} = p^{a+S-1}(1 - p)^{a+n-S-1}$$

On **reconnait** une densité bêta :

$$\pi(\cdot | X) = B(a + S, a + n - S)$$

C'est la **conjugaison** : a priori bêta $\rightarrow$ a posteriori bêta, la mise à jour consistant simplement à ajouter succès et échecs.

5. **L'estimateur de Bayes** — la moyenne a posteriori :

$$\hat{p}^{(\pi)} = \frac{a + S}{2a + n} = \frac{a/n + \bar{X}_n}{2a/n + 1}$$

et pour Jeffreys ($a = 1/2$) : $\hat{p}^{(\pi_J)} = \frac{1/(2n) + \bar{X}_n}{1/n + 1}$.

6. **La région de confiance bayésienne.** Tout $R \subset (0, 1)$ de masse $1 - \alpha$ sous $B(a + S, a + n - S)$ — par exemple l'intervalle entre les quantiles $\alpha/2$ et $1 - \alpha/2$. **Ce n'est pas un intervalle de confiance** : c'est une région de **croyance**, et elle dépend de a .

7. **Le comportement asymptotique.** *L'estimateur de Bayes est consistant et asymptotiquement normal, et ses propriétés asymptotiques ne dépendent pas de l'a priori.* En effet,

$$\hat{p}^{(\pi)} = \frac{a/n + \bar{X}_n}{2a/n + 1} \xrightarrow[n \rightarrow \infty]{} \bar{X}_n = \hat{p}^{MLE}$$

L'a priori contribue par des termes en a/n qui s'évanouissent.

Ce qu'il faut savoir commenter.

- **Sur petit échantillon**, l'a priori **régularise** : 3 succès sur 3 donnent $\hat{p}^{MLE} = 1$ (certitude absurde) contre 0,875 pour Bayes. C'est l'arbitrage biais-variance de la fiche 67.
- **Sur grand échantillon**, les deux écoles **convergent**. Le débat n'a d'enjeu que là où les données sont rares — ce qui est aussi là où le choix de l'a priori est le plus contestable.

- **Le bayésien fournit une loi entière**, pas seulement un point : on peut en tirer n'importe quelle probabilité, région, ou décision, sans nouvelle théorie.

Flashcards

Question	Réponse
Statut de θ en fréquentiste ?	Fixe et inconnu
Statut de θ en bayésien ?	Modélisé comme s'il était aléatoire
Le vrai paramètre est-il aléatoire ?	Non — on modélise une croyance
Qu'est-ce que la loi a priori ?	La loi quantifiant la croyance avant les données
Qu'est-ce que la loi a posteriori ?	La loi de θ conditionnellement aux données
Formule de Bayes ?	$\pi(\theta X) \propto \pi(\theta)p_n(X \theta)$
Que vaut la constante ?	$\int_{\Theta} p_n(X t) d\pi(t)$
A priori bêta + Bernoulli ?	A posteriori $B(a + \sum X_i, a + n - \sum X_i)$
Nom de ce phénomène ?	La conjugaison
Comment lire $B(a, a)$?	Comme a succès et a échecs fictifs
A priori non informatif naturel ?	$\pi(\theta) \propto 1$
Quand est-il uniforme ?	Si Θ est borné
Qu'est-ce qu'un a priori impropre ?	Positif, mesurable, non intégrable
Peut-on l'utiliser ?	Oui , si l'a posteriori est propre
$\pi \equiv 1 + N(\theta, 1)$?	A posteriori $N(\bar{X}_n, 1/n)$
A priori de Jeffreys ?	$\pi_J(\theta) \propto \sqrt{\det I(\theta)}$
Jeffreys pour Bernoulli ?	$B(1/2, 1/2)$
Jeffreys pour le gaussien ?	$\pi_J \propto 1$ — impropre
Quelle propriété justifie Jeffreys ?	L' invariance par reparamétrisation
Pourquoi l'uniforme échoue-t-il ?	Uniforme sur $p \neq$ uniforme sur $\log \frac{p}{1-p}$
Région de confiance bayésienne ?	$\mathbb{P}[\theta \in R X] = 1 - \alpha$

Question	Réponse
Est-ce un intervalle de confiance ?	Non — deux notions distinctes
De quoi R dépend-il ?	De l' a priori
Estimateur de Bayes ?	La moyenne a posteriori $\int_{\Theta} \theta d\pi(\theta X)$
Sa valeur pour Bernoulli ?	$\frac{a + \sum X_i}{2a + n} = \frac{a/n + \bar{X}_n}{2a/n + 1}$
Sa valeur pour Jeffreys ?	$\frac{1/(2n) + \bar{X}_n}{1/n + 1}$
Ses propriétés asymptotiques ?	Consistant et asymptotiquement normal
Dépendent-elles de l'a priori ?	Non
Quand l'a priori compte-t-il ?	Sur petit échantillon
Quel rôle y joue-t-il ?	Il régularise — rétrécissement vers le centre