

Fiche 71 — Estimation paramétrique : vraisemblance, VAR, GMM et quasi-vraisemblance


Matière	Maths · Économétrie
Cours source	Kogan, <i>15.450 Analytics of Finance</i> , MIT Sloan / OpenCourseWare, automne 2010 — cours 7 « Parameter Estimation »
Difficulté	Must know — GMM est la méthode d'estimation de l'économétrie financière
Temps d'étude estimé	2 h 30
Prérequis	Fiche 64 (vraisemblance, Fisher), fiche 58 (VAR), fiche 50 (MCO, MCG), fiche 52 (AIC/BIC)
Concepts clés	Consistance, inégalité de Jensen, fonction de vraisemblance, EMV pour observations dépendantes, $AR(p)$ et $VAR(p)$, MCO comme EMV, critères d'information, méthode des moments généralisée, conditions d'identification, score comme moment, quasi-maximum de vraisemblance, MCG
Poids à l'examen	Trois choses : la preuve par Jensen que la vraie densité maximise l'espérance de la log-vraisemblance ; les conditions d'identification du GMM ; et le fait que QMLE soit un cas particulier de GMM — c'est ce qui le justifie.

Vue d'ensemble

Les trois approches, et leur arbitrage.

- *Si la loi de probabilité $p(X, \theta_0)$ est **entièrement connue**, on peut estimer θ_0 par **maximum de vraisemblance (MLE)**. C'est la méthode préférée : elle offre la **meilleure précision asymptotique**.*
- *Si la loi n'est pas entièrement connue mais qu'on en connaît certaines caractéristiques — les deux premiers moments, par exemple —, on peut estimer par **quasi-maximum de vraisemblance (QMLE)**.*
- *Si l'on ne connaît que **quelques moments** de la loi, mais pas la densité entière, on peut estimer par la **méthode des moments généralisée (GMM)**.*

QMLE et GMM sont moins précises (efficaces) que MLE, mais elles sont plus robustes, puisqu'elles n'exigent pas la connaissance complète de la loi.



Le fil du cours. GMM est le cadre **le plus général** : le MLE en est un cas particulier — il suffit de prendre le **score** comme fonction de moment —, et le QMLE aussi. C'est ce qui permet de **justifier** l'usage d'un modèle qu'on sait faux : *si les conditions de moment restent valides, GMM s'applique.*

● Concept 1 — Rappels de statistique et de probabilité

Le cadre. Un échantillon $X = (x_1, \dots, x_T)$ de loi jointe $p(X, \theta_0)$; un **estimateur** $\hat{\theta}$ est une fonction de l'échantillon, $\hat{\theta}(X)$.

Notion	Définition
Consistance	$\text{plim}_{T \rightarrow \infty} \hat{\theta} = \theta_0$
Absence de biais	$\mathbb{E}[\hat{\theta}] = \theta_0$
Intervalle de confiance α	intervalle aléatoire $(\hat{\theta}_i^L, \hat{\theta}_i^R)$ tel que $\text{Prob}[(\hat{\theta}_i^L, \hat{\theta}_i^R) \text{ couvre } \theta_{0,i}] = \alpha$

Loi des grands nombres. Si les $\mathbf{x}_t$ sont i.i.d. de moyenne μ :

$$\text{plim}_{T \rightarrow \infty} \frac{\sum_{t=1}^T \mathbf{x}_t}{T} = \mu$$

où **plim** est la limite en probabilité : $\text{plim}_{n \rightarrow \infty} \mathbf{x}_n = \mathbf{y}$ signifie que pour tout $\delta > 0$, $\text{Prob}[|\mathbf{x}_n - \mathbf{y}| > \delta] \rightarrow 0$.

THÉORÈME CENTRAL LIMITE.

Si les $\mathbf{x}_t$ sont des vecteurs i.i.d. de moyenne μ et de matrice de variance-covariance Ω :

$$\frac{\sum_{t=1}^T (\mathbf{x}_t - \mu)}{\sqrt{T}} \Rightarrow N(0, \Omega)$$

où « $\Rightarrow$ » désigne la convergence en loi : $\mathbf{x}_n \Rightarrow \mathbf{y}$ signifie que $F_{\mathbf{x}_n}(z) \rightarrow F_{\mathbf{y}}(z)$ en tout point z où $F_{\mathbf{y}}$ est continue.

L'exemple minimal. Pour un échantillon i.i.d. $N(\mu, 1)$, l'estimateur usuel de μ est la moyenne empirique $\hat{\mu} = \hat{\mathbb{E}}[\mathbf{x}_t] \equiv \frac{1}{T} \sum_t \mathbf{x}_t$, consistant par la LGN. Comment obtenir des estimateurs consistants dans des situations plus complexes ? — c'est tout le sujet.

● Concept 2 — Jensen et le fondement du maximum de vraisemblance

Inégalité de Jensen. Si f est **concave**, $w_n \geq 0$ et $\sum_{n=1}^N w_n = 1$, alors

$$\sum_{n=1}^N w_n f(x_n) \leq f\left(\sum_{n=1}^N w_n x_n\right)$$

Le résultat s'étend au cas continu : $\int w(x) f(x) dx \leq f\left(\int w(x) x dx\right)$ si $\int w = 1$ et $w \geq 0$.

Exemple : si x est une variable aléatoire — un rendement d'actif — et f concave — une fonction d'utilité —, alors $\mathbb{E}[f(x)] \leq f(\mathbb{E}[x])$: c'est l'**aversion au risque**.

Le fondement du maximum de vraisemblance. Pour toute densité alternative $p(x, \tilde{\theta})$:

$$\mathbb{E}[\ln p(x, \tilde{\theta})] \leq \mathbb{E}[\ln p(x, \theta_0)]$$

La démonstration, par Jensen et l'égalité $\int p(x, \tilde{\theta}) dx = 1$:

$$\mathbb{E}\left[\ln \frac{p(x_t, \tilde{\theta})}{p(x_t, \theta_0)}\right] \leq \ln \mathbb{E}\left[\frac{p(x_t, \tilde{\theta})}{p(x_t, \theta_0)}\right] = \ln \int \frac{p(x, \tilde{\theta})}{p(x, \theta_0)} p(x, \theta_0) dx = \ln \int p(x, \tilde{\theta}) dx = \ln 1 = 0$$

C'est la justification théorique du maximum de vraisemblance : la **vraie** densité maximise l'espérance de la log-vraisemblance. Il suffit alors de remplacer l'espérance par sa moyenne empirique :

$$\hat{\theta} = \arg \max_{\theta} \frac{1}{T} \sum_{t=1}^T \ln p(x_t, \theta) = \arg \max_{\theta} \frac{1}{T} \ln p(X, \theta)$$

C'est exactement l'argument de la fiche 64, sous une autre forme. L'inégalité

$\mathbb{E}[\ln p(\tilde{\theta})] \leq \mathbb{E}[\ln p(\theta_0)]$ est la positivité de la divergence de Kullback-Leibler :

$KL(\mathbb{P}_{\tilde{\theta}}, \mathbb{P}_{\theta_0}) = \mathbb{E}[\ln p(\theta_0)] - \mathbb{E}[\ln p(\tilde{\theta})] \geq 0$. Les deux cours démontrent le même résultat, l'un par la KL, l'autre par Jensen.

● Concept 3 — La fonction de vraisemblance

DÉFINITION.

$\mathcal{L}(\theta) = \ln p(X, \theta)$. La fonction de vraisemblance traite les paramètres θ comme des **variables** et les observations X comme **fixées**.

Pour des observations i.i.d.,

$$\frac{1}{T} \mathcal{L}(\theta) = \frac{1}{T} \ln \prod_{t=1}^T p(x_t, \theta) = \frac{1}{T} \sum_{t=1}^T \ln p(x_t, \theta) \quad \Rightarrow \quad \boxed{\hat{\theta} = \arg \max_{\theta} \mathcal{L}(\theta)}$$

Exemple 1 — le modèle gaussien. Pour des observations i.i.d. $N(\mu, \sigma^2)$:

$$\mathcal{L}(\theta) = \sum_{t=1}^T \ln \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right) - \frac{(x_t - \mu)^2}{2\sigma^2}$$

Conditions d'optimalité :

$$\sum_{t=1}^T \frac{(x_t - \hat{\mu})}{\hat{\sigma}^2} = 0, \quad -\frac{T}{\hat{\sigma}} + \sum_{t=1}^T \frac{(x_t - \hat{\mu})^2}{\hat{\sigma}^3} = 0$$

Elles sont **identiques aux conditions GMM** :

$$\hat{\mathbb{E}}(x_t - \hat{\mu}) = 0, \quad \hat{\mathbb{E}}[(x_t - \hat{\mu})^2] - \hat{\sigma}^2 = 0$$

Exemple 2 — la loi exponentielle. Pour T observations indépendantes de densité $p(x_t, \lambda) = \lambda \exp(-\lambda x_t)$:

$$\mathcal{L}(\lambda) = \sum_{t=1}^T (-\lambda x_t + \ln \lambda)$$

Condition du premier ordre : $-\sum_t x_t + \frac{T}{\hat{\lambda}} = 0$, d'où

$$\hat{\lambda} = \left(\frac{\sum_{t=1}^T x_t}{T} \right)^{-1} = \frac{1}{\bar{x}}$$

● Concept 4 — L'EMV pour observations dépendantes

- L'approche MLE fonctionne **même si les observations sont dépendantes**.
- Il faut que la dépendance **s'éteigne assez vite**.
- Considérons une série $x_t, x_{t+1}, \dots$ et supposons que la loi de x_{t+1} ne dépende que de L retards.
- **Log-vraisemblance conditionnelle** aux L premières observations :

$$\mathcal{L}(\theta) = \sum_{t=L}^{T-1} \ln p(x_{t+1} \mid x_t, \dots, x_{t+1-L}; \theta)$$

- θ maximise l'espérance conditionnelle de $\ln p(x_{t+1} \mid \cdot)$, donc maximise la vraisemblance conditionnelle si T est grand et x_t **stationnaire**.

C'est la décomposition en erreurs de prédiction de la fiche 60, écrite pour un modèle markovien d'ordre L . La vraisemblance jointe d'observations dépendantes se factorise en un produit de **conditionnelles** — chacune calculable.

L'AR(p) : maximum de vraisemblance = moindres carrés

$$x_{t+1} = a_0 + a_1 x_t + \dots + a_p x_{t+1-p} + \varepsilon_{t+1}, \quad \varepsilon_{t+1} \sim N(0, \sigma^2)$$

Conditionnellement à $(x_t, \dots, x_{t+1-p})$, x_{t+1} est gaussienne, d'où

$$\mathcal{L}(\theta) = \sum_{t=p}^{T-1} \left[-\ln \sqrt{2\pi\sigma^2} - \frac{(x_{t+1} - a_0 - a_1 x_t - \dots - a_p x_{t+1-p})^2}{2\sigma^2} \right]$$

Les estimations MLE de $(a_0, a_1, \dots, a_p)$ sont les mêmes que les MCO :

$$\max_{\hat{a}} \mathcal{L}(\theta) \iff \min_{\hat{a}} \sum_{t=p}^{T-1} (x_{t+1} - a_0 - a_1 x_t - \dots - a_p x_{t+1-p})^2$$

La raison est visible dans la formule : le premier terme ne dépend pas de $\mathbf{a}$, et le second est $-\frac{1}{2\sigma^2}$ fois la somme des carrés. Maximiser l'un revient à minimiser l'autre. **C'est le résultat de la fiche 50**, transposé aux séries temporelles.

● Concept 5 — Le VAR(p)

$$\mathbf{x}_{t+1} = \mathbf{a}_0 + \mathbf{A}_1 \mathbf{x}_t + \cdots + \mathbf{A}_p \mathbf{x}_{t+1-p} + \varepsilon_{t+1}, \quad \varepsilon_{t+1} \sim N(0, \Sigma)$$

où $\mathbf{x}_t$ et $\mathbf{a}_0$ sont de dimension N , les $\mathbf{A}_n$ sont $N \times N$, et ε_t est un vecteur de chocs de covariance Σ .

$$\mathcal{L}(\theta) = \sum_{t=p}^{T-1} \left[-\ln \sqrt{(2\pi)^N |\Sigma|} - \frac{1}{2} \varepsilon_{t+1}^\top \Sigma^{-1} \varepsilon_{t+1} \right]$$

L'estimation.

$$\max_{\mathbf{a}_0, \mathbf{A}_1, \dots, \mathbf{A}_p, \Sigma} \mathcal{L}(\theta) \iff \min_{\mathbf{a}_0, \mathbf{A}_1, \dots, \mathbf{A}_p, \Sigma} \sum_{t=p}^{T-1} \left[\ln \sqrt{(2\pi)^N |\Sigma|} + \frac{1}{2} \varepsilon_{t+1}^\top \Sigma^{-1} \varepsilon_{t+1} \right]$$

Conditions d'optimalité pour $\mathbf{a}_0, \mathbf{A}_1, \dots, \mathbf{A}_p$:

$$\sum_t (\mathbf{x}_{t-i} \varepsilon_{t+1}^\top) = 0, \quad i = 0, 1, \dots, p-1, \quad \sum_t \varepsilon_{t+1} = 0$$

où $\varepsilon_{t+1} = \mathbf{x}_{t+1} - (\mathbf{a}_0 + \mathbf{A}_1 \mathbf{x}_t + \cdots + \mathbf{A}_p \mathbf{x}_{t+1-p})$.

Les coefficients du VAR peuvent être estimés par MCO, équation par équation. Les écarts-types peuvent aussi être calculés séparément pour chaque équation.

C'est exactement le théorème d'optimalité de la fiche 58, redémontré ici par les conditions du premier ordre de la vraisemblance. Les conditions $\sum_t \mathbf{x}_{t-i} \varepsilon_{t+1}^\top = \mathbf{0}$ disent que les résidus sont **orthogonaux aux régresseurs** — les équations normales de la fiche 50 — et Σ n'y apparaît pas, d'où l'estimation séparée.

● Concept 6 — La sélection de modèle

En pratique, on ne connaît pas le modèle exact. Le MLE peut être adapté pour faire de la **sélection de modèle** : si l'échantillon est assez grand, on peut identifier le bon modèle en **comparant les vraisemblances maximisées** et en les **pénalisant pour le nombre de paramètres** utilisés.

Le protocole pour un VAR(p). Spécifier l'ordre maximal $\bar{p}$, en veillant à ce qu'il **croisse avec la taille d'échantillon, mais pas trop vite** :

$$\lim_{T \rightarrow \infty} \bar{p} = \infty, \quad \lim_{T \rightarrow \infty} \frac{\bar{p}}{T} = 0 \quad (\text{par exemple } \bar{p} = \frac{1}{4}(\ln T)^2)$$

puis trouver l'ordre optimal

$$\hat{p} = \arg \max_{0 \leq p \leq \bar{p}} \frac{2}{T} \mathcal{L}(\theta; p) - \text{pénalité}(p)$$

avec

$$\text{AIC : pénalité}(p) = 2 \cdot \frac{pN^2}{T}, \quad \text{BIC : pénalité}(p) = \ln(T) \cdot \frac{pN^2}{T}$$

Dans les grands échantillons, **le BIC sélectionne des modèles d'ordre inférieur à l'AIC**.

L'exemple du cours — la croissance du PIB américain. Croissance trimestrielle corrigée des variations saisonnières, en taux annualisés, avec $\bar{p} = 7$:

- **AIC** dicte $p = 5$, de coefficients $a_1, \dots, a_5 = 0,3185 ; 0,1409 ; -0,0759 ; -0,0600 ; -0,0904$.
- **BIC** dicte $p = 1$, de coefficient $a_1 = 0,3611$.

L'écart entre les deux verdicts est spectaculaire — 5 contre 1 — et illustre exactement ce que la fiche 52 annonçait. Le BIC pénalise en $\ln(T)$ contre 2 pour l'AIC ; dès $T > 7$, il est plus sévère, et l'écart croît avec l'échantillon. Le comptage pN^2 montre pourquoi : chaque retard supplémentaire coûte N^2 paramètres.

● Concept 7 — La méthode des moments généralisée (GMM)

Le cadre. Un échantillon i.i.d. $\mathbf{X} = (x_1, \dots, x_T)$ tiré d'une famille de densité $\phi(x; \theta_0)$, et l'on veut estimer un vecteur de paramètres θ_0 de dimension N . On considère un vecteur de fonctions $f_j(x, \theta)$ — les « **moments** » — avec $\dim(f) = N$.

Conditions d'identification. On suppose savoir que

$$\mathbb{E}[f(x_t, \theta_0)] = 0 \quad \text{et} \quad \sum_{j=1}^N \left(\mathbb{E}[f_j(x_t, \theta)] \right)^2 > 0 \text{ si } \theta \neq \theta_0$$

L'estimateur GMM $\hat{\theta}$ est défini par

$$\hat{\mathbb{E}}[f(x_t, \hat{\theta})] \equiv \frac{1}{T} \sum_{t=1}^T f(x_t, \hat{\theta}) = 0$$

La logique, en deux temps. La **première** condition dit que les moments s'annulent à la vraie valeur — c'est ce qui rend l'estimation possible. La **seconde** dit qu'ils ne s'annulent **qu'à** la vraie valeur — c'est l'**identification**, sans laquelle plusieurs θ résoudre le système. On remplace ensuite l'espérance par la moyenne empirique et l'on résout : **N équations, N inconnues.**

Exemple — moyenne et variance. Pour estimer $\theta_0 = (\mu_0, \sigma_0)^\top$ avec $\sigma_0 \geq 0$, on choisit

$$f_1(x_t, \theta) = x_t - \mu, \quad f_2(x_t, \theta) = (x_t - \mu)^2 - \sigma^2$$

Il est facile de voir que $\mathbb{E}[f(x, \theta_0)] = 0$, et que $\mathbb{E}[f(x, \theta)] \neq 0$ si $\theta \neq \theta_0$. Les estimations sont

$$\hat{\mathbb{E}}(x_t) - \hat{\mu} = 0 \Rightarrow \hat{\mu} = \hat{\mathbb{E}}(x_t), \quad \hat{\mathbb{E}}[(x_t - \hat{\mu})^2] - \hat{\sigma}^2 = 0 \Rightarrow \hat{\sigma}^2 = \hat{\mathbb{E}}[(x_t - \hat{\mu})^2]$$

● Concept 8 — GMM et MLE : le score comme moment

Les **conditions du premier ordre du MLE** peuvent servir de moments dans une estimation GMM. Les conditions d'optimalité pour maximiser $\mathcal{L}(\theta) = \sum_{t=1}^T \ln p(x_t, \theta)$ sont

$$\sum_{t=1}^T \frac{\partial \ln p(x_t, \theta)}{\partial \theta} = 0$$

Si l'on pose $f = \partial \ln p(x, \theta) / \partial \theta$ — le **vecteur de score** —, alors **le MLE se réduit à un GMM** de vecteur de moment f .

C'est le résultat structurant du chapitre. Le GMM **englobe** le MLE. Et l'on comprend pourquoi les conditions d'optimalité du modèle gaussien du concept 3 étaient *identiques aux conditions GMM* : le score gaussien **est** le vecteur $(x_t - \mu, (x_t - \mu)^2 - \sigma^2)$, à normalisation près.

Et cela donne une méthode de travail : quand on ne sait pas quels moments choisir, on écrit une vraisemblance — même approximative — et l'on prend son **score**. C'est exactement l'idée du QMLE.

Exemple — un modèle de taux d'intérêt.

$$r_{t+1} = a_0 + a_1 r_t + \varepsilon_{t+1}, \quad \mathbb{E}(\varepsilon_{t+1} \mid r_t) = 0, \quad \mathbb{E}(\varepsilon_{t+1}^2 \mid r_t) = b_0 + b_1 r_t$$

Pour toute fonction $g(r_t)$,

$$\mathbb{E}[g(r_t) \varepsilon_{t+1}] = \mathbb{E}[\mathbb{E}[g(r_t) \varepsilon_{t+1} \mid r_t]] = \mathbb{E}[g(r_t) \mathbb{E}[\varepsilon_{t+1} \mid r_t]] = 0$$

En prenant $g(r_t) = 1$ et $g(r_t) = r_t$, on obtient les conditions de moment

$$\mathbb{E}[(1, r_t)^\top (r_{t+1} - a_0 - a_1 r_t)] = 0, \quad \mathbb{E}[(1, r_t)^\top ((r_{t+1} - a_0 - a_1 r_t)^2 - b_0 - b_1 r_t)] = 0$$

(a_0, a_1) peut être estimé à partir de la **première paire** de conditions de moment. C'est équivalent aux **MCO**, et cela **ignore l'information sur le second moment**.

Le mécanisme $\mathbb{E}[g(r_t)\varepsilon_{t+1}] = 0$ est le plus productif de tout le GMM. Une seule hypothèse — $\mathbb{E}[\varepsilon_{t+1} \mid r_t] = 0$ — engendre une **infinité** de conditions de moment valides, une par fonction g de l'information passée. C'est la notion d'**instrument** : n'importe quelle variable connue en t fournit une équation. Reste à choisir lesquelles, et c'est là qu'intervient l'efficacité.

● Concept 9 — Le quasi-maximum de vraisemblance

- Les estimations du maximum de vraisemblance sont **optimales** : elles ont la **plus petite variance asymptotique**.
- Quand on connaît précisément $p(X, \theta)$, le MLE est l'approche la plus **efficace**.
- Le MLE est souvent une façon commode de **déterminer quelles conditions de moment imposer**.
- **Même si le modèle $p(X, \theta)$ est mal spécifié, l'approche MLE peut rester valide tant que les conditions de moment impliquées sont valides.**
- Avec un modèle **incorrect** $q(X, \theta)$, le MLE est un **cas particulier du GMM** : les résultats du GMM s'appliquent.

L'approche consistant à utiliser une fonction de vraisemblance incorrecte — typiquement gaussienne — pour estimer s'appelle le quasi-maximum de vraisemblance (QMLE).

Exemple 1 — QMLE pour un AR(p) à erreurs non gaussiennes.

$$x_{t+1} = a_0 + a_1 x_t + \dots + a_p x_{t+1-p} + \varepsilon_{t+1}, \quad \mathbb{E}[\varepsilon_{t+1} \mid x_t, \dots, x_{t+1-p}] = 0$$

On **fait comme si** les erreurs étaient gaussiennes pour construire $\mathcal{L}(\theta)$. Les conditions d'optimalité sont

$$\sum_t (x_{t-i} \varepsilon_{t+1}) = 0, \quad i = 0, \dots, p-1, \quad \sum_t \varepsilon_{t+1} = 0$$

Ce sont des **conditions de moment valides** — à vérifier. **Le GMM justifie le QMLE.**

C'est le point conceptuel décisif. On a estimé avec une vraisemblance **fausse**, et pourtant l'estimateur est consistant. La raison est que les conditions du premier ordre obtenues coïncident avec des conditions de moment **qui, elles, sont vraies** — elles ne demandent que $\mathbb{E}[\varepsilon_{t+1} \mid \text{passé}] = 0$, pas la normalité. La normalité n'a servi que d'**échafaudage** pour produire les bons moments.

Exemple 2 — QMLE avec hétéroscédasticité. Reprenons

$$r_{t+1} = a_0 + a_1 r_t + \varepsilon_{t+1}, \quad \mathbb{E}(\varepsilon_{t+1} \mid r_t) = 0, \quad \mathbb{E}(\varepsilon_{t+1}^2 \mid r_t) = b_0 + b_1 r_t$$

QMLE : on traite ε_t comme $N(0, b_0 + b_1 r_{t-1})$, d'où

$$\mathcal{L}(\theta) = \sum_{t=1}^{T-1} \left[-\frac{1}{2} \ln(2\pi(b_0 + b_1 r_t)) - \frac{(r_{t+1} - a_0 - a_1 r_t)^2}{2(b_0 + b_1 r_t)} \right]$$

(a_0, a_1) **ne peut plus être estimé séparément** de (b_0, b_1) . Les conditions d'optimalité pour (a_0, a_1) deviennent

$$\sum_{t=1}^{T-1} (1, r_t)^\top \frac{r_{t+1} - a_0 - a_1 r_t}{b_0 + b_1 r_t} = 0$$

Ce ne sont plus les MCO, mais les MCG. Estimations plus précises de (a_0, a_1) : on sous-pondère les résidus à forte variance.

La motivation empirique. Sur le taux des bons du Trésor à 3 mois (marché secondaire, données mensuelles), le nuage des variations de taux contre le niveau retardé montre une **volatilité plus forte quand les taux sont élevés**. D'où la spécification $b_0 + b_1 r_t$.

La conclusion du cours. Le QMLE aide à spécifier les moments du GMM. **Ne pas l'utiliser aveuglément** : il faut **vérifier que les conditions de moment sont valides**.

Et remarquez le lien avec les fiches 50 et 66. La pondération par $1/(b_0 + b_1 r_t)$ est exactement celle des **MCG** — division par la variance conditionnelle — et exactement la matrice **W** de l'algorithme **IRLS**. Trois cours différents, la même correction d'hétéroscédasticité.

Comment résoudre l'exercice type (protocole)

1. **Évaluer ce qu'on connaît** : densité complète $\Rightarrow$ **MLE** · deux premiers moments $\Rightarrow$ **QMLE** · quelques moments $\Rightarrow$ **GMM**.
2. **MLE** : écrire $\mathcal{L}(\theta) = \ln p(X, \theta)$ — conditionnelle si les observations sont dépendantes — puis annuler le gradient.
3. **Vérifier la simplification** : erreurs gaussiennes $\Rightarrow$ MLE = **MCO** ; hétéroscédasticité modélisée $\Rightarrow$ **MCG**.
4. **GMM** : choisir N fonctions f_j avec $\mathbb{E}[f(x, \theta_0)] = 0$, **vérifier l'identification**, puis résoudre $\frac{1}{T} \sum_t f(x_t, \hat{\theta}) = 0$.
5. **Si l'on manque d'idées de moments** : écrire une vraisemblance approximative et prendre son **score**.
6. **QMLE** : construire $\mathcal{L}$ avec une loi commode (gaussienne), en déduire les conditions du premier ordre, et **vérifier qu'elles sont des conditions de moment valides**.
7. **Sélection d'ordre** : $\hat{p} = \arg \max \frac{2}{T} \mathcal{L}(\theta; p) - \text{pénalité}(p)$, avec $2pN^2/T$ (AIC) ou $\ln(T)pN^2/T$ (BIC).

Comment reconnaître qu'il faut utiliser cette méthode ?

Indice dans l'énoncé	Ce qu'il faut faire
loi entièrement spécifiée	MLE — précision maximale
« on ne connaît que les deux premiers moments »	QMLE
« on ne connaît que quelques moments »	GMM
erreurs gaussiennes dans un AR	MLE = MCO
VAR sans restriction	MCO équation par équation
« quel ordre p choisir ? »	AIC ou BIC , pénalité en pN^2/T
$\mathbb{E}[\varepsilon_{t+1} \mid \text{passé}] = 0$	une condition de moment par instrument g
variance conditionnelle modélisée	MCG , pondérer par $1/\text{var}$
« le modèle est faux, l'estimateur reste-t-il valide ? »	oui si les moments sont valides — GMM justifie QMLE

Exercices progressifs

Niveau 1 — Montrez que l'EMV d'un AR(p) à erreurs gaussiennes coïncide avec les MCO.

Le modèle. $x_{t+1} = a_0 + a_1x_t + \dots + a_px_{t+1-p} + \varepsilon_{t+1}$ avec $\varepsilon_{t+1} \sim N(0, \sigma^2)$ i.i.d.

La vraisemblance conditionnelle. Conditionnellement à $(x_t, \dots, x_{t+1-p})$, la variable x_{t+1} est gaussienne de moyenne $a_0 + a_1x_t + \dots + a_px_{t+1-p}$ et de variance σ^2 , donc

$$\mathcal{L}(\theta) = \sum_{t=p}^{T-1} \left[-\ln \sqrt{2\pi\sigma^2} - \frac{(x_{t+1} - a_0 - a_1x_t - \dots - a_px_{t+1-p})^2}{2\sigma^2} \right]$$

La séparation. Le premier terme, $-\ln \sqrt{2\pi\sigma^2}$, ne dépend pas de a . Le second est $-\frac{1}{2\sigma^2}$ fois la somme des carrés des résidus, avec $\sigma^2 > 0$. Donc

$$\max_a \mathcal{L}(\theta) \iff \min_a \sum_{t=p}^{T-1} (x_{t+1} - a_0 - a_1x_t - \dots - a_px_{t+1-p})^2$$

qui est exactement le critère des **moindres carrés**. ■

Ce que cela apprend. Le critère des MCO n'est pas un choix arbitraire : c'est le maximum de vraisemblance **sous hypothèse gaussienne** — le même résultat qu'en fiche 50, ici transposé aux séries temporelles.

Et la réciproque est intéressante. Si les erreurs ne sont **pas** gaussiennes, les MCO restent une procédure valide — c'est le **QMLE** —, mais ils ne sont plus l'EMV et perdent l'efficacité optimale. Ce qui les sauve est que leurs conditions du premier ordre $\sum_t x_{t-i}\varepsilon_{t+1} = 0$ sont des **conditions de moment valides**, dérivant seulement de $\mathbb{E}[\varepsilon_{t+1} \mid \text{passé}] = 0$.

Niveau 2 — Énoncez les conditions d'identification du GMM et expliquez leur rôle.

Les deux conditions.

$$\mathbb{E}[f(x_t, \theta_0)] = 0 \quad (1)$$

$$\sum_{j=1}^N \left(\mathbb{E}[f_j(x_t, \theta)] \right)^2 > 0 \quad \text{si } \theta \neq \theta_0 \quad (2)$$

Le rôle de (1) — la validité. Les moments **s'annulent à la vraie valeur**. C'est ce qui rend l'estimation possible : la version empirique $\frac{1}{T} \sum_t f(x_t, \theta)$ converge vers 0 en θ_0 par la LGN, donc la solution du système empirique converge vers θ_0 .

Le rôle de (2) — l'identification. Les moments **ne s'annulent qu'à la vraie valeur**. Sans cette condition, plusieurs θ vérifieraient $\mathbb{E}[f(x, \theta)] = 0$, et rien ne permettrait de choisir. C'est exactement l'identifiabilité de la fiche 67, formulée en termes de moments.

La dimension. $\dim(f) = N = \dim(\theta)$: **autant d'équations que d'inconnues**. Le système $\frac{1}{T} \sum_t f(x_t, \hat{\theta}) = 0$ est donc exactement déterminé.

L'exemple moyenne-variance. $f_1 = x_t - \mu$, $f_2 = (x_t - \mu)^2 - \sigma^2$. La condition (1) est immédiate. La condition (2) se vérifie : si $\mu \neq \mu_0$, alors $\mathbb{E}[f_1] = \mu_0 - \mu \neq 0$; et si $\mu = \mu_0$ mais $\sigma \neq \sigma_0$, alors $\mathbb{E}[f_2] = \sigma_0^2 - \sigma^2 \neq 0$.

Le cas suridentifié, que le cours ne traite pas ici mais qu'il faut connaître : si l'on dispose de **plus** de moments que de paramètres, le système n'a en général pas de solution exacte. On minimise alors une forme quadratique $\hat{\mathbb{E}}[f]^T W \hat{\mathbb{E}}[f]$, et le choix de W détermine l'efficacité. C'est le GMM au sens de Hansen.

Niveau 3 — Pourquoi le QMLE est-il valide alors que le modèle est faux ?

Le paradoxe apparent. On estime en maximisant une vraisemblance $q(X, \theta)$ dont on **sait** qu'elle n'est pas la vraie densité — typiquement une gaussienne pour des données non gaussiennes. Comment l'estimateur peut-il rester consistant ?

La réponse : le GMM. Avec un modèle incorrect $q(X, \theta)$, le MLE est un **cas particulier du GMM**. Les résultats du GMM s'appliquent. Maximiser q revient à annuler son score :

$$\frac{1}{T} \sum_t \frac{\partial \ln q(x_t, \hat{\theta})}{\partial \theta} = 0$$

C'est un système GMM de fonction de moment $f = \partial \ln q / \partial \theta$. **La question n'est donc plus « q est-elle la vraie densité ? » mais « $\mathbb{E}[f(x, \theta_0)] = 0$ est-elle vraie ? »** — une exigence bien plus faible.

L'exemple de l'AR(p). En faisant comme si les erreurs étaient gaussiennes, les conditions du premier ordre sont

$$\sum_t (x_{t-i} \varepsilon_{t+1}) = 0, \quad i = 0, \dots, p-1, \quad \sum_t \varepsilon_{t+1} = 0$$

Or ces conditions n'expriment **que l'orthogonalité des résidus au passé** — elles découlent de la seule hypothèse $\mathbb{E}[\varepsilon_{t+1} \mid \mathbf{x}_t, \dots, \mathbf{x}_{t+1-p}] = 0$, **sans aucune hypothèse de normalité**. Elles sont donc **valides**, et le GMM garantit la consistance.

La normalité n'a servi que d'échafaudage. Elle a permis d'**écrire** une fonction objectif commode, dont les conditions du premier ordre se trouvent être les bons moments. Une fois les moments identifiés, l'échafaudage peut être retiré.

Ce qu'on perd malgré tout. *Les estimations MLE sont optimales : elles ont la plus petite variance asymptotique.* Avec une vraisemblance fausse, on garde la **consistance** mais on perd l'**efficacité** — et surtout, **les écarts-types calculés par la formule MLE sont faux**. Il faut utiliser les écarts-types **robustes** du GMM (fiche suivante du cours).

L'avertissement du cours. *Le QMLE aide à spécifier les moments du GMM. **Ne pas l'utiliser aveuglément** : vérifier que les conditions de moment sont valides.* Un contre-exemple immédiat : si l'on modélisait une variance conditionnelle **fausse** dans l'exemple hétéroscédastique, les conditions pondérées ne seraient plus des moments valides et l'estimateur serait biaisé.

Niveau 4 — type examen — Construisez l'estimation d'un modèle de taux hétéroscédastique par GMM puis par QMLE, et comparez.

Le modèle.

$$r_{t+1} = a_0 + a_1 r_t + \varepsilon_{t+1}, \quad \mathbb{E}(\varepsilon_{t+1} \mid r_t) = 0, \quad \mathbb{E}(\varepsilon_{t+1}^2 \mid r_t) = b_0 + b_1 r_t$$

La motivation empirique : sur le taux des bons du Trésor à 3 mois, le nuage des variations contre le niveau retardé montre une **volatilité croissante avec le niveau des taux**.

Approche 1 — GMM.

Étape 1 — le mécanisme des instruments. Pour toute fonction $g(r_t)$,

$$\mathbb{E}[g(r_t)\varepsilon_{t+1}] = \mathbb{E}[g(r_t) \mathbb{E}[\varepsilon_{t+1} \mid r_t]] = 0$$

par la loi des espérances itérées.

Étape 2 — choisir $g = 1$ et $g = r_t$. On obtient quatre conditions de moment :

$$\mathbb{E}[(1, r_t)^\top (r_{t+1} - a_0 - a_1 r_t)] = 0$$

$$\mathbb{E}[(1, r_t)^\top ((r_{t+1} - a_0 - a_1 r_t)^2 - b_0 - b_1 r_t)] = 0$$

Étape 3 — estimer. (a_0, a_1) s'obtient **de la première paire seule**. C'est équivalent aux MCO, et cela **ignore l'information sur le second moment**. Puis (b_0, b_1) se déduit de la seconde paire, à partir des résidus.

Approche 2 — QMLE.

On traite ε_t comme $N(0, b_0 + b_1 r_{t-1})$ et l'on construit

$$\mathcal{L}(\theta) = \sum_{t=1}^{T-1} \left[-\frac{1}{2} \ln(2\pi(b_0 + b_1 r_t)) - \frac{(r_{t+1} - a_0 - a_1 r_t)^2}{2(b_0 + b_1 r_t)} \right]$$

Conséquence immédiate : (a_0, a_1) **ne peut plus être estimé séparément** de (b_0, b_1) — les deux blocs sont couplés par la pondération.

Les conditions du premier ordre pour (a_0, a_1) :

$$\sum_{t=1}^{T-1} (1, r_t)^\top \frac{r_{t+1} - a_0 - a_1 r_t}{b_0 + b_1 r_t} = 0$$

La comparaison.

	GMM (première paire)	QMLE
Conditions	$\sum_t (1, r_t)^\top \varepsilon_{t+1} = 0$	$\sum_t (1, r_t)^\top \frac{\varepsilon_{t+1}}{b_0 + b_1 r_t} = 0$
Méthode	MCO	MCG
Pondération	uniforme	$1/\text{var}$ conditionnelle
Estimation de (a, b)	séparée	couplée
Précision	moindre	meilleure

Ce ne sont plus les MCO, mais les MCG. Estimations plus précises de (a_0, a_1) : on **sous-pondère les résidus à forte variance**.

Pourquoi les MCG sont plus précises. Les observations où la variance conditionnelle $b_0 + b_1 r_t$ est grande sont **moins informatives** sur (a_0, a_1) : leur résidu est bruité indépendamment de la valeur des coefficients. Leur donner un poids plus faible réduit la variance de l'estimateur. C'est exactement le théorème de Gauss-Markov généralisé de la fiche 50, et exactement la matrice de poids W de l'IRLS en fiche 66.

Ce qu'il faut savoir conclure.

1. Le GMM à quatre moments et le QMLE utilisent **la même information**, mais le QMLE la **combine plus efficacement** en pondérant.
2. Le QMLE reste valide **bien que la loi ne soit pas gaussienne**, parce que ses conditions du premier ordre sont des conditions de moment valides — *le GMM justifie le QMLE*.
3. Il faut néanmoins **vérifier** cette validité, et utiliser des écarts-types **robustes** : la formule d'écart-type du MLE gaussien serait fausse ici.

● Common mistakes

1. **Croire que le MLE exige des observations i.i.d.** — il fonctionne aussi pour des observations **dépendantes**, via la vraisemblance **conditionnelle**.
2. **Oublier de conditionner sur les L premières observations** dans un modèle à retards.
3. **Croire que MCO = MLE toujours** — c'est vrai sous erreurs **gaussiennes homoscédastiques** seulement.
4. **Oublier que Σ n'entre pas dans les conditions d'optimalité du VAR** — c'est ce qui autorise l'estimation équation par équation.
5. **Se tromper de pénalité** — AIC en $2pN^2/T$, BIC en $\ln(T)pN^2/T$; le BIC choisit des ordres **plus faibles**.
6. **Oublier la condition d'identification du GMM** — la validité des moments ne suffit pas.
7. **Ne pas exploiter tous les instruments** — $\mathbb{E}[\varepsilon_{t+1} \mid \text{passé}] = 0$ engendre une condition **par fonction g** du passé.
8. **Utiliser les écarts-types du MLE après un QMLE** — ils sont **faux** ; il faut les écarts-types robustes du GMM.
9. **Appliquer le QMLE aveuglément** — *vérifier que les conditions de moment sont valides*.
10. **Croire que GMM et MLE sont des méthodes rivales** — le MLE est un **cas particulier** du GMM, avec le **score** pour moment.

Ultimate Review

1. **Les trois approches** : **MLE** (densité connue, précision maximale) · **QMLE** (deux premiers moments) · **GMM** (quelques moments). *QMLE et GMM sont moins efficaces mais plus **robustes***.
2. **Consistance** : $\text{plim } \hat{\theta} = \theta_0$. **Sans biais** : $\mathbb{E}[\hat{\theta}] = \theta_0$.

3. **LGN** : $\text{plim} \frac{1}{T} \sum_t x_t = \mu$. **TCL** : $\frac{1}{\sqrt{T}} \sum_t (x_t - \mu) \Rightarrow N(0, \Omega)$.
4. **Jensen** : f concave $\Rightarrow \sum w_n f(x_n) \leq f(\sum w_n x_n)$; d'où $\mathbb{E}[f(x)] \leq f(\mathbb{E}[x])$ — l'**aversion au risque**.
5. **Fondement du MLE** : $\mathbb{E}[\ln p(x, \tilde{\theta})] \leq \mathbb{E}[\ln p(x, \theta_0)]$, démontré par Jensen et $\int p(x, \tilde{\theta}) dx = 1$.
6. **Vraisemblance** : $\mathcal{L}(\theta) = \ln p(X, \theta)$; i.i.d. $\Rightarrow \frac{1}{T} \mathcal{L} = \frac{1}{T} \sum_t \ln p(x_t, \theta)$; $\hat{\theta} = \arg \max \mathcal{L}$.
7. **Exemples** : gaussien $\Rightarrow$ conditions **identiques au GMM** ; exponentiel $\Rightarrow \hat{\lambda} = 1/\bar{x}$.
8. **Observations dépendantes** : $\mathcal{L}(\theta) = \sum_{t=L}^{T-1} \ln p(x_{t+1} | x_t, \dots, x_{t+1-L}; \theta)$ — dépendance devant s'éteindre assez vite, série **stationnaire**.
9. **AR(p) gaussien** : $\max \mathcal{L} \iff \min \sum (x_{t+1} - a_0 - \dots)^2$ — **MLE = MCO**.
10. **VAR(p)** : conditions $\sum_t x_{t-i} \varepsilon_{t+1}^\top = 0$ et $\sum_t \varepsilon_{t+1} = 0 \Rightarrow$ **MCO équation par équation**, écarts-types séparés.
11. **Sélection d'ordre** : $\hat{p} = \arg \max_{0 \leq p \leq \bar{p}} \frac{2}{T} \mathcal{L}(\theta; p) - \text{pénalité}(p)$ avec $\bar{p} \rightarrow \infty, \bar{p}/T \rightarrow 0$ (ex. $\frac{1}{4}(\ln T)^2$).
12. **Pénalités** : AIC $2pN^2/T$, BIC $\ln(T)pN^2/T$; le **BIC choisit des ordres plus faibles**. Exemple PIB : AIC $\Rightarrow p = 5$, BIC $\Rightarrow p = 1$.
13. **GMM** : $\dim(f) = N$; **validité** $\mathbb{E}[f(x_t, \theta_0)] = 0$; **identification** $\sum_j (\mathbb{E}[f_j(x_t, \theta)])^2 > 0$ si $\theta \neq \theta_0$; estimateur $\frac{1}{T} \sum_t f(x_t, \hat{\theta}) = 0$.
14. **Exemple moyenne-variance** : $f_1 = x_t - \mu, f_2 = (x_t - \mu)^2 - \sigma^2$.
15. **GMM englobe MLE** : poser $f = \partial \ln p(x, \theta) / \partial \theta$, le **vecteur de score**.
16. **Instruments** : $\mathbb{E}[\varepsilon_{t+1} | r_t] = 0 \Rightarrow \mathbb{E}[g(r_t) \varepsilon_{t+1}] = 0$ pour **toute** fonction g .
17. **QMLE** : utiliser une vraisemblance **incorrecte** — typiquement gaussienne. **Valide si les conditions de moment le sont** ; le *GMM justifie le QMLE*.
18. **QMLE hétéroscédastique** : $\sum_t (1, r_t)^\top \frac{\varepsilon_{t+1}}{b_0 + b_1 r_t} = 0$ — ce sont les **MCG**, plus précis, en sous-pondérant les résidus à forte variance.

Formulas to know

$$\mathbb{E}[\ln p(x, \tilde{\theta})] \leq \mathbb{E}[\ln p(x, \theta_0)] \quad \hat{\theta} = \arg \max_{\theta} \frac{1}{T} \sum_{t=1}^T \ln p(x_t, \theta)$$

$$\mathcal{L}(\theta) = \sum_{t=L}^{T-1} \ln p(x_{t+1} | x_t, \dots, x_{t+1-L}; \theta) \quad \hat{p} = \arg \max_p \frac{2}{T} \mathcal{L}(\theta; p) - \text{pénalité}(p)$$

$$\frac{1}{T} \sum_{t=1}^T f(x_t, \hat{\theta}) = 0 \quad f = \frac{\partial \ln p(x, \theta)}{\partial \theta} \quad \mathbb{E}[g(r_t) \varepsilon_{t+1}] = 0$$

Methods to know : la preuve par Jensen ; la construction d'une vraisemblance conditionnelle ; la vérification des deux conditions GMM ; la dérivation de moments par instruments ; la justification du QMLE par le GMM.

Active Recall

Basic — Quelles sont les trois méthodes d'estimation, et selon quel critère les choisit-on ?

Méthode	Ce qu'elle exige	Précision
MLE	la densité complète $p(X, \theta_0)$	maximale
QMLE	quelques caractéristiques (deux premiers moments)	intermédiaire
GMM	seulement quelques moments	moindre

Le critère est un **arbitrage précision / robustesse** : QMLE et GMM sont moins précises (efficaces) que MLE, mais elles sont **plus robustes**, puisqu'elles n'exigent pas la connaissance complète de la loi.

Et le **GMM englobe les deux autres** : le MLE est un GMM dont la fonction de moment est le **score** $\partial \ln p / \partial \theta$, et le QMLE est un GMM dont le score provient d'une densité **incorrecte**.

Understanding — Pourquoi la vraie densité maximise-t-elle l'espérance de la log-vraisemblance ?

L'énoncé. Pour toute densité alternative $p(x, \tilde{\theta})$:

$$\mathbb{E}[\ln p(x, \tilde{\theta})] \leq \mathbb{E}[\ln p(x, \theta_0)]$$

La démonstration, par **Jensen** appliquée à **ln**, qui est concave, et en utilisant $\int p(x, \tilde{\theta}) dx = 1$:

$$\mathbb{E} \left[\ln \frac{p(x_t, \tilde{\theta})}{p(x_t, \theta_0)} \right] \leq \ln \mathbb{E} \left[\frac{p(x_t, \tilde{\theta})}{p(x_t, \theta_0)} \right] = \ln \int \frac{p(x, \tilde{\theta})}{p(x, \theta_0)} p(x, \theta_0) dx = \ln \int p(x, \tilde{\theta}) dx = \ln 1 = 0$$

La conséquence. Il suffit de remplacer l'espérance par sa moyenne empirique :

$$\hat{\theta} = \arg \max_{\theta} \frac{1}{T} \sum_{t=1}^T \ln p(x_t, \theta)$$

C'est le même résultat que la fiche 64, démontré autrement. L'écart $\mathbb{E}[\ln p(\theta_0)] - \mathbb{E}[\ln p(\tilde{\theta})]$ est la divergence de Kullback-Leibler $KL(\mathbb{P}_{\theta_0}, \mathbb{P}_{\tilde{\theta}})$, et l'inégalité est sa positivité. Jensen et la KL disent la même chose.

Application — Écrivez les conditions de moment GMM pour $r_{t+1} = a_0 + a_1 r_t + \varepsilon_{t+1}$ avec $\mathbb{E}[\varepsilon_{t+1} | r_t] = 0$.

Le mécanisme. Pour toute fonction $g(r_t)$, la loi des espérances itérées donne

$$\mathbb{E}[g(r_t)\varepsilon_{t+1}] = \mathbb{E}[\mathbb{E}[g(r_t)\varepsilon_{t+1} | r_t]] = \mathbb{E}\left[g(r_t)\underbrace{\mathbb{E}[\varepsilon_{t+1} | r_t]}_{=0}\right] = 0$$

Le choix minimal. Avec $g = 1$ et $g = r_t$ — deux instruments pour deux paramètres :

$$\mathbb{E}\left[(1, r_t)^\top (r_{t+1} - a_0 - a_1 r_t)\right] = 0$$

L'estimateur GMM. On remplace par la moyenne empirique :

$$\frac{1}{T} \sum_t \begin{pmatrix} 1 \\ r_t \end{pmatrix} (r_{t+1} - \hat{a}_0 - \hat{a}_1 r_t) = 0$$

C'est équivalent aux **MCO** — ce sont exactement les équations normales de la fiche 50, avec pour régresseurs la constante et r_t .

Si la variance conditionnelle est modélisée, $\mathbb{E}(\varepsilon_{t+1}^2 | r_t) = b_0 + b_1 r_t$, on ajoute deux conditions :

$$\mathbb{E}\left[(1, r_t)^\top \left((r_{t+1} - a_0 - a_1 r_t)^2 - b_0 - b_1 r_t\right)\right] = 0$$

mais (a_0, a_1) s'estime **de la première paire seule** — ce qui ignore l'information sur le second moment. Le QMLE, lui, exploite cette information en pondérant, et gagne en précision.

La richesse du mécanisme : une seule hypothèse engendre une **infinité** de conditions valides, une par instrument. Le choix des instruments détermine l'efficacité — c'est tout le sujet du GMM optimal.

Comparison — MLE et GMM : quel est leur rapport exact ?

Ce ne sont pas des méthodes rivales : le MLE est un cas particulier du GMM.

Les conditions du premier ordre du MLE sont

$$\sum_{t=1}^T \frac{\partial \ln p(x_t, \theta)}{\partial \theta} = 0$$

En posant $f = \frac{\partial \ln p(x, \theta)}{\partial \theta}$ — le **vecteur de score** —, c'est exactement le système GMM $\frac{1}{T} \sum_t f(x_t, \hat{\theta}) = 0$.

La preuve de validité des moments est d'ailleurs immédiate : $\mathbb{E}[\text{score}] = 0$ à la vraie valeur, c'est la première identité de la fiche 66.

	MLE	GMM
Ce qu'il faut connaître	la densité entière	quelques moments
Fonction de moment	le score	libre
Efficacité	optimale (Cramér-Rao)	moindre
Robustesse	faible — dépend de la densité	élevée

L'exemple qui illustre le lien. Les conditions d'optimalité du MLE gaussien sont

$$\hat{\mathbb{E}}(x_t - \hat{\mu}) = 0, \quad \hat{\mathbb{E}}[(x_t - \hat{\mu})^2] - \hat{\sigma}^2 = 0$$

identiques aux conditions GMM de l'exemple moyenne-variance. Le score gaussien **est** le vecteur de moments naturel.

La conséquence méthodologique. Quand on ne sait pas quels moments choisir, on **écrit une vraisemblance** — même approximative — et l'on prend son score. *Le MLE est souvent*

une façon commode de déterminer quelles conditions de moment imposer. C'est le principe du QMLE.

Exam-style — Expliquez le QMLE, sa justification et ses limites.

La définition. L'approche consistant à utiliser une fonction de vraisemblance **incorrecte** — typiquement gaussienne — pour estimer s'appelle le **quasi-maximum de vraisemblance**.

La justification, en trois pas.

1. Avec un modèle incorrect $q(X, \theta)$, le MLE est un **cas particulier du GMM**. Maximiser q revient à annuler son score, donc à résoudre un système GMM de fonction de moment $f = \partial \ln q / \partial \theta$.
2. La question devient donc : **les conditions $\mathbb{E}[f(x, \theta_0)] = 0$ sont-elles vraies ?** — une exigence bien plus faible que « q est la vraie densité ».
3. Si oui, *les résultats du GMM s'appliquent* : consistance et normalité asymptotique.

L'exemple canonique — l'AR(p). En faisant comme si les erreurs étaient gaussiennes, les conditions du premier ordre sont

$$\sum_t (x_{t-i} \varepsilon_{t+1}) = 0, \quad i = 0, \dots, p-1, \quad \sum_t \varepsilon_{t+1} = 0$$

Ces conditions n'expriment **que l'orthogonalité des résidus au passé** — elles découlent de la seule hypothèse $\mathbb{E}[\varepsilon_{t+1} \mid x_t, \dots, x_{t+1-p}] = 0$. **Aucune normalité n'est requise.** Le GMM justifie le QMLE.

L'exemple avec hétéroscédasticité. En traitant ε_t comme $N(0, b_0 + b_1 r_{t-1})$:

$$\mathcal{L}(\theta) = \sum_t \left[-\frac{1}{2} \ln(2\pi(b_0 + b_1 r_t)) - \frac{(r_{t+1} - a_0 - a_1 r_t)^2}{2(b_0 + b_1 r_t)} \right]$$

Deux conséquences :

- (a_0, a_1) **ne peut plus être estimé séparément** de (b_0, b_1) ;
- les conditions d'optimalité deviennent $\sum_t (1, r_t)^\top \frac{\varepsilon_{t+1}}{b_0 + b_1 r_t} = 0$ — *ce ne sont plus les MCO mais les MCG, plus précises : on **sous-pondère les résidus à forte variance**.*

Les limites — trois points à mentionner.

1. **Perte d'efficacité.** *Les estimations MLE sont optimales : elles ont la plus petite variance asymptotique.* Avec une vraisemblance fausse, on garde la consistance mais on perd l'optimalité.
2. **Écart-types faux.** La formule d'écart-type du MLE — fondée sur l'information de Fisher — **suppose le modèle correct**. Après un QMLE, il faut les écart-types **robustes** du GMM.
3. **La validité n'est pas automatique.** *Ne pas l'utiliser aveuglément : vérifier que les conditions de moment sont valides.* Si l'on modélisait une variance conditionnelle **fausse** dans l'exemple ci-dessus, les conditions pondérées cesseraient d'être des moments valides et l'estimateur serait biaisé.

La conclusion du cours. *Le QMLE aide à spécifier les moments du GMM.* C'est sa vraie fonction : un **générateur de conditions de moment**, dont la validité doit ensuite être établie indépendamment de la loi supposée.

Flashcards

Question	Réponse
Les trois méthodes d'estimation ?	MLE · QMLE · GMM
Laquelle est la plus précise ?	Le MLE — densité entièrement connue
Lesquelles sont plus robustes ?	QMLE et GMM
Définition de la consistance ?	$\text{plim}_{T \rightarrow \infty} \hat{\theta} = \theta_0$
Énoncé du TCL ?	$\frac{1}{\sqrt{T}} \sum_t (x_t - \mu) \Rightarrow N(0, \Omega)$
Inégalité de Jensen ?	f concave $\Rightarrow \mathbb{E}[f(x)] \leq f(\mathbb{E}[x])$
Que représente-t-elle en finance ?	L' aversion au risque
Le fondement du MLE ?	$\mathbb{E}[\ln p(x, \tilde{\theta})] \leq \mathbb{E}[\ln p(x, \theta_0)]$
Comment se démontre-t-il ?	Par Jensen et $\int p(x, \tilde{\theta}) dx = 1$
Définition de la vraisemblance ?	$\mathcal{L}(\theta) = \ln p(X, \theta)$
Que traite-t-elle comme fixé ?	Les observations X
EMV de la loi exponentielle ?	$\hat{\lambda} = 1/\bar{x}$
Vraisemblance d'observations dépendantes ?	$\sum_{t=L}^{T-1} \ln p(x_{t+1} \mid x_t, \dots, x_{t+1-L}; \theta)$
Quelle condition sur la dépendance ?	Elle doit s'éteindre assez vite
EMV d'un AR(p) gaussien ?	Identique aux MCO
Pourquoi ?	Le terme en σ ne dépend pas de a
Conditions d'optimalité du VAR ?	$\sum_t x_{t-i} \varepsilon_{t+1}^\top = 0$ et $\sum_t \varepsilon_{t+1} = 0$
Comment estimer un VAR ?	Par MCO équation par équation
Critère de sélection d'ordre ?	$\arg \max \frac{2}{T} \mathcal{L}(\theta; p) - \text{pénalité}(p)$
Pénalité AIC ?	$2pN^2/T$
Pénalité BIC ?	$\ln(T)pN^2/T$

Question	Réponse
Lequel choisit un ordre plus faible ?	Le BIC
Exemple du PIB ?	AIC $\Rightarrow p = 5$, BIC $\Rightarrow p = 1$
Condition de validité du GMM ?	$\mathbb{E}[f(x_t, \theta_0)] = 0$
Condition d'identification ?	$\sum_j (\mathbb{E}[f_j(x_t, \theta)])^2 > 0$ si $\theta \neq \theta_0$
Définition de l'estimateur GMM ?	$\frac{1}{T} \sum_t f(x_t, \hat{\theta}) = 0$
Moments pour moyenne et variance ?	$x_t - \mu$ et $(x_t - \mu)^2 - \sigma^2$
Comment le MLE devient-il un GMM ?	En prenant le score $\partial \ln p / \partial \theta$ pour moment
Que donne $\mathbb{E}[\varepsilon_{t+1} \mid r_t] = 0$?	$\mathbb{E}[g(r_t)\varepsilon_{t+1}] = 0$ pour toute g
Définition du QMLE ?	Maximiser une vraisemblance incorrecte
Qu'est-ce qui le justifie ?	Le GMM — si les moments sont valides
Que devient l'estimation avec hétéroscédasticité ?	Des MCG , pas des MCO
Pourquoi est-ce plus précis ?	On sous-pondère les résidus à forte variance
Quelle précaution le cours impose-t-il ?	Vérifier la validité des conditions de moment