

Fiche 73 — Inférence en petit échantillon et bootstrap

Matière	Maths · Économétrie
Cours source	Kogan, <i>15.450 Analytics of Finance</i> , MIT Sloan / OpenCourseWare, automne 2010 — cours 9 « Small-Sample Inference and Bootstrap »
Difficulté	High — ce qui reste quand l'asymptotique ne tient plus
Temps d'étude estimé	2 h 15
Prérequis	Fiche 72 (écarts-types GMM, Newey-West), fiche 52 (AR(1)), fiche 67 (biais, intervalles de confiance)
Concepts clés	Biais en petit échantillon, biais de Kendall, biais de Stambaugh, simulation de Monte-Carlo, bootstrap, distribution empirique, rééchantillonnage, intervalle de confiance bootstrap, bootstrap paramétrique, correction de biais
Poids à l'examen	Trois choses : la formule de Kendall et le biais de Stambaugh ; le principe du bootstrap — la distribution empirique traitée comme la vraie ; et la formule de l'intervalle de confiance bootstrap , dont l'asymétrie surprend.

Vue d'ensemble

Les limites de l'inférence asymptotique.

- Jusqu'ici, notre inférence reposait sur des résultats **asymptotiques** : LGN et TCL.
- L'inférence asymptotique est parfois **difficile à appliquer**, trop compliquée analytiquement.
- En **petit échantillon**, l'inférence asymptotique peut être **peu fiable** :
 - les estimateurs peuvent être **consistants mais biaisés** ;
 - les écarts-types peuvent être **imprécis**, ce qui conduit à des intervalles de confiance et des tailles de test **incorrects**.

Les remèdes par simulation.

- Le **bootstrap** peut remplacer l'inférence asymptotique dans les problèmes analytiquement difficiles.
- Le **bootstrap** peut servir à **corriger le biais**.
- La **simulation de Monte-Carlo** permet de comprendre les propriétés des procédures statistiques.

ASYMPTOTIQUE	$T \rightarrow \infty$: consistance, normalité, écarts-types
EN PRATIQUE	T fini : biais réel + écarts-types faux
DIAGNOSTIC	MONTE-CARLO – simuler le vrai modèle, mesurer
REMÈDE	BOOTSTRAP – rééchantillonner les DONNÉES observées
	monde réel : P inconnue $\rightarrow \hat{\theta} = s(x)$
	monde boot. : $\hat{P}$ connue $\rightarrow \hat{\theta}^* = s(x^*)$
LIMITES	événements rares • biais de sélection • mauvaise spécification

● Concept 1 — Le biais de l'autocorrélation estimée

Le problème. On veut estimer l'autocorrélation d'ordre 1 d'une série x_t — l'inflation, par exemple — c'est-à-dire $\text{corr}(x_t, x_{t+1})$, par MCO (donc GMM) :

$$x_t = a_0 + \rho_1 x_{t-1} + \varepsilon_t$$

On sait que cet estimateur est **consistant** : $\text{plim}_{T \rightarrow \infty} \hat{\rho}_1 = \rho_1$. Mais on veut savoir s'il est **biaisé**, c'est-à-dire estimer $\mathbb{E}(\hat{\rho}_1) - \rho_1$.

L'expérience de Monte-Carlo. Simuler indépendamment N séries aléatoires de longueur T , chacune suivant un AR(1) de persistance ρ_1 et d'erreurs gaussiennes :

$$x_t = \rho_1 x_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim N(0, 1)$$

Calculer $\hat{\rho}_1^{(n)}$ pour chaque échantillon simulé, puis estimer le biais

$$\hat{\mathbb{E}}(\hat{\rho}_1) - \rho_1 = \frac{1}{N} \sum_{n=1}^N \hat{\rho}_1^{(n)} - \rho_1, \quad \hat{\sigma} = \sqrt{\frac{1}{N} \sum_{n=1}^N \left(\hat{\rho}_1^{(n)} - \hat{\mathbb{E}}(\hat{\rho}_1) \right)^2}$$

Les résultats sur 100 000 simulations.

ρ_1	T	Biais moyen
0,9	50	$-0,0826 \pm 0,0006$
0,0	50	$-0,0203 \pm 0,0009$
0,9	100	$-0,0402 \pm 0,0004$
0,0	100	$-0,0100 \pm 0,0006$

Le biais semble **croissant en ρ_1** et **décroissant avec la taille d'échantillon**.

FORMULE ANALYTIQUE DE KENDALL.

$$\mathbb{E}(\hat{\rho}_1) - \rho_1 \approx -\frac{1 + 3\rho_1}{T}$$

Quand les formules explicites ne sont pas connues, on peut utiliser le **bootstrap** pour estimer le biais.

Le biais est toujours NÉGATIF : l'autocorrélation est systématiquement sous-estimée. Pour $\rho_1 = 0,9$ et $T = 50$, on estime en moyenne **0,817** au lieu de **0,9** — un écart de près de **10 %**. Et la formule de Kendall reproduit bien les simulations : $-(1 + 2,7)/50 = -0,074$ contre **-0,0826** observé, $-1/50 = -0,020$ contre **-0,0203**.

La raison intuitive. La régression estime ρ_1 en projetant sur les écarts à la moyenne **empirique** — laquelle est calculée sur les mêmes données. Comme dans le cas de la variance empirique (fiche 65), estimer la moyenne « consomme » de l'information et tire mécaniquement l'estimation vers zéro.

● Concept 2 — Le biais de Stambaugh

Le cadre. Une régression prédictive — par exemple prévoir les rendements d'actions par le rendement du dividende :

$$r_{t+1} = \alpha + \beta x_t + u_{t+1}$$

$$x_{t+1} = \theta + \rho x_t + \varepsilon_{t+1}$$

$$(u_t, \varepsilon_t)^\top \sim N(0, \Sigma)$$

Biais de Stambaugh.

$$\mathbb{E}(\hat{\beta} - \beta) = \frac{\text{Cov}(u_t, \varepsilon_t)}{\text{Var}(\varepsilon_t)} \mathbb{E}(\hat{\rho} - \rho) \approx -\frac{1 + 3\rho}{T} \cdot \frac{\text{Cov}(u_t, \varepsilon_t)}{\text{Var}(\varepsilon_t)}$$

*Dans le cas du rendement du dividende prédisant les rendements d'actions, le biais est **positif** et peut être **substantiel comparé à l'écart-type de $\hat{\beta}$** .*

Le mécanisme, en trois pas.

1. Le prédictor x_t est **très persistant** (ρ proche de 1), donc $\hat{\rho}$ souffre du biais de Kendall — **négatif**.
2. Les innovations u_t (rendements) et ε_t (prédictor) sont **corrélées**. Pour le rendement du dividende D/P , une hausse du prix **baisse x** et **augmente r** : la covariance est **négative**.
3. Le produit de deux quantités négatives est **positif** : $\hat{\beta}$ est **surestimé**.

La conséquence. On croit détecter de la prévisibilité là où il n'y en a pas nécessairement — et le biais est du même ordre de grandeur que l'écart-type, donc il **suffit à créer une significativité apparente**.

C'est le piège annoncé à la fin de la fiche 72. Newey-West corrige les **écarts-types** mais **pas le biais du coefficient lui-même**. Ce sont deux problèmes distincts, qui exigent deux remèdes différents.

● Concept 3 — L'application empirique au S&P 500

Les données. Régression prédictive des rendements excédentaires mensuels du S&P 500 sur le logarithme du rendement du dividende, CRSP, du **31/01/1934** au **31/12/2008** :

$$r_{t+1} = \alpha + \beta x_t + u_{t+1}, \quad x_{t+1} = \theta + \rho x_t + \varepsilon_{t+1}$$

Les estimations.

$$\hat{\beta} = 0,0089, \quad \hat{\rho} = 0,9936, \quad SE(\hat{\beta}) = 0,005$$

L'expérience de Monte-Carlo. Générer 1 000 échantillons avec les paramètres égaux aux estimations empiriques. Utiliser 200 périodes de **rodage** (burn-in) et retenir des échantillons de même longueur que la série historique. Tabuler $\hat{\beta}$ et les écarts-types de chaque échantillon, en utilisant **Newey-West à 6 retards**.

Grandeur	Valeur
Moyenne de $\hat{\beta}$	0,013
Biais moyen de $\hat{\beta}$	0,004
Écart-type moyen	0,005
Statistique de Student moyenne	0,75

Lisez les deux dernières lignes ensemble : c'est le résultat le plus important de la fiche. Le biais (0,004) est **presque égal** à l'écart-type (0,005). Autrement dit, **même quand $\beta = 0$ exactement**, la régression produit en moyenne un coefficient de **0,004** et un t de Student de **0,75**.

Et $\hat{\rho} = 0,9936$ explique pourquoi. Le prédicteur est presque une marche aléatoire, donc le biais de Kendall est maximal et le biais de Stambaugh avec lui.

La conclusion. Une partie substantielle du $\hat{\beta} = 0,0089$ observé pourrait n'être **que du biais**. C'est l'un des arguments centraux du débat sur la prévisibilité des rendements.

● Concept 4 — Quand la normalité asymptotique échoue

Le problème. On estime la moyenne μ par la moyenne empirique, et les tests reposent sur

$$\frac{\hat{\mu} - \mu}{\hat{\sigma}/\sqrt{T}} \sim N(0, 1)$$

Cette approximation normale est-elle bonne en échantillon fini si la loi n'est pas gaussienne ?

L'exemple log-normal. $x_t = e^{-\frac{1}{2} + \varepsilon_t}$ avec $\varepsilon_t \sim N(0, 1)$, de sorte que

$$\mu = \mathbb{E}(x_t) = \mathbb{E}(e^{-\frac{1}{2} + \varepsilon_t}) = 1$$

L'expérience. $N = 100\,000$ simulations, $T = 50$, en documentant la loi de $\hat{t} = \frac{\hat{\mu} - 1}{\hat{\sigma}/\sqrt{T}}$.

Quantité	Théorie asymptotique	Estimation Monte-Carlo
$\text{Var}(\hat{t})$	1	1,2542 ²
$\text{Prob}(\hat{t} > 1,96)$	0,025	0,0042
$\text{Prob}(\hat{t} < -1,96)$	0,025	0,1053

Ces deux nombres sont catastrophiques, et il faut comprendre pourquoi. Un test bilatéral de niveau nominal 5 % rejette en réalité 0,42 % + 10,53 % $\approx$ 11 % du temps — **plus du double** — et de façon **massivement asymétrique**.

La cause est l'asymétrie de la loi log-normale. Elle a une longue queue à droite ; la plupart des échantillons de taille 50 ne contiennent **aucune** grande valeur, donc $\hat{\mu}$ est **sous-estimée** et $\hat{\sigma}$ aussi. La statistique $\hat{t}$ est donc **biaisée vers la gauche** — d'où les 10,5 % dans la queue gauche et à peine 0,4 % à droite.

La pertinence financière est directe : les rendements ont des queues épaisses et asymétriques (fiche 53). Toute inférence asymptotique sur des séries courtes est suspecte.

● Concept 5 — Le principe du bootstrap

Le bootstrap est une méthode de rééchantillonnage qui permet d'évaluer les propriétés des estimateurs statistiques.

Le bootstrap est en substance une étude de Monte-Carlo qui utilise la distribution EMPIRIQUE comme si elle était la vraie distribution.

Les applications principales.

- Évaluer les propriétés distributionnelles d'estimateurs **compliqués**, et faire la **correction de biais** ;
- Améliorer la précision des approximations asymptotiques en petit échantillon — intervalles de confiance, régions de rejet, etc.

Le parallèle des deux mondes, tel que le cours le présente (d'après Efron et Tibshirani) :

MONDE RÉEL	MONDE BOOTSTRAP
modèle de probabilité inconnu P	modèle estimé $\hat{P}$
données observées $\mathbf{x} = (x_1, \dots, x_n)$	échantillon bootstrap $\mathbf{x}^* = (x_1^*, \dots, x_n^*)$
paramètre d'intérêt $\theta = \theta(P)$	paramètre estimé $\hat{\theta} = \theta(\hat{P})$
estimation $\hat{\theta} = s(\mathbf{x})$	réplique bootstrap $\hat{\theta}^* = s(\mathbf{x}^*)$
$\text{Biais}_P(\hat{\theta}, \theta)$	$\text{Biais}_{\hat{P}}(\hat{\theta}^*, \hat{\theta})$

L'idée en une phrase. On ne peut pas répéter l'expérience réelle — on n'a qu'un échantillon. Mais on peut **répéter l'expérience dans un monde dont on connaît tout** : celui où la vraie loi est la loi **empirique**. La relation entre $\hat{\theta}^*$ et $\hat{\theta}$ dans ce monde artificiel imite la relation entre $\hat{\theta}$ et θ dans le monde réel.

Le cas i.i.d. Pour un échantillon i.i.d. $\mathbf{x}_t, t = 1, \dots, T$, dont on estime la moyenne $\hat{\mu} = \hat{\mathbb{E}}(\mathbf{x}_t)$: *sous la distribution empirique, $\mathbf{x}$ prend chacune des valeurs $\mathbf{x}_1, \dots, \mathbf{x}_T$ avec **probabilité égale***. Rééchantillonner, c'est donc **tirer avec remise** parmi les observations.

● Concept 6 — Les intervalles de confiance bootstrap

La procédure, à partir de R échantillons tirés de la distribution empirique :

1. Pour chaque échantillon bootstrapé, calculer $\hat{\mu}^*$ — « * » désignant les statistiques calculées sur les échantillons bootstrapés.
2. Calculer les percentiles à 2,5 % et 97,5 % de la distribution obtenue : $\hat{\mu}_{2,5\%}^*, \hat{\mu}_{97,5\%}^*$.
3. Approcher la loi de $\hat{\mu} - \mu$ par la loi simulée de $\hat{\mu}^* - \hat{\mu}$, et estimer l'intervalle de confiance

$$\left(\hat{\mu} - (\hat{\mu}_{97,5\%}^* - \hat{\mu}), \hat{\mu} - (\hat{\mu}_{2,5\%}^* - \hat{\mu}) \right)$$

Regardez attentivement l'étape 3 : les percentiles sont INVERSÉS, et ce n'est pas une coquille.
Le percentile **haut** de $\hat{\mu}^*$ donne la borne **basse** de l'intervalle.

Le raisonnement. On approche la loi de l'erreur $\hat{\mu} - \mu$ par celle de $\hat{\mu}^* - \hat{\mu}$. Si l'on constate que $\hat{\mu}^*$ dépasse $\hat{\mu}$ de δ dans 2,5 % des cas, alors on estime que $\hat{\mu}$ dépasse μ de δ dans 2,5 % des cas — donc μ pourrait être **inférieur** à $\hat{\mu}$ de δ . La borne basse est bien $\hat{\mu} - \delta$.

Et cela produit un intervalle asymétrique quand la loi de l'estimateur l'est — ce que l'approximation normale, symétrique par construction, ne peut jamais faire. C'est précisément l'avantage du bootstrap sur la log-normale du concept 4.

L'exemple log-normal

On fixe un échantillon de 50 observations d'une loi log-normale $\ln x_t \sim N(-1/2, 1)$ et l'on calcule

$$\hat{\mu} = 1,1784, \quad \hat{\sigma} = 1,5340$$

La moyenne de population est $\mu = \mathbb{E}(x_t) = 1$.

L'approximation asymptotique donne

$$\left(\hat{\mu} - 1,96 \frac{\hat{\sigma}}{\sqrt{T}}, \hat{\mu} + 1,96 \frac{\hat{\sigma}}{\sqrt{T}} \right) = (0,7532 ; 1,6036)$$

Le bootstrap sur la statistique de Student donne une variance de $1,1852^2$, à comparer à 1 (approximation normale) et $1,2542^2$ (Monte-Carlo).

*De façon cohérente avec les résultats de Monte-Carlo, la distribution en petit échantillon des statistiques de Student présente une **asymétrie à gauche**.*

Le bootstrap capture donc une bonne partie de l'écart à la normalité, sans connaître la vraie loi. 1,185 n'est pas 1,254, mais c'est bien plus proche que 1.

● Concept 7 — Le bootstrap paramétrique

Le **bootstrap paramétrique** peut traiter les échantillons **non i.i.d.**

Exemple — un processus AR(1) $x_t = a_0 + a_1 x_{t-1} + \varepsilon_t$, dont on veut un intervalle de confiance pour $\hat{a}_1$:

1. Estimer les paramètres $\hat{a}_0, \hat{a}_1$ et les **résidus** $\hat{e}_t$.
2. Générer R échantillons bootstrap pour x_t . Pour chaque échantillon : engendrer une **longue série** selon la dynamique AR(1) avec $\hat{a}_0, \hat{a}_1$, en tirant les chocs **avec remise** dans l'échantillon $\hat{e}_1, \dots, \hat{e}_T$; ne retenir que les T **dernières** observations (abandonner la période de rodage).
3. Calculer l'intervalle de confiance comme avec le bootstrap non paramétrique de base, à partir des R échantillons.

POURQUOI « PARAMÉTRIQUE ».

On ne rééchantillonne **pas les observations** — elles sont dépendantes, les tirer avec remise détruirait la structure temporelle. On rééchantillonne les **résidus**, qui, eux, sont approximativement i.i.d., et l'on **régénère** la série par le modèle estimé. La structure de dépendance est donc **imposée par le modèle**, la distribution des chocs venant des données.

Le rodage (burn-in) est essentiel : les premières observations dépendent de la condition initiale arbitraire. En n'en gardant que les T dernières, on part de la loi stationnaire.

● Concept 8 — La correction de biais par bootstrap

Le problème. Estimer le biais en petit échantillon d'une statistique $\theta : \mathbb{E}[\hat{\theta}] - \theta_0$.

L'approche bootstrap.

$$\mathbb{E}[\hat{\theta}] - \theta_0 \approx \mathbb{E}_R[\hat{\theta}^*] - \hat{\theta}$$

où $\mathbb{E}_R$ désigne la moyenne sur les R échantillons bootstrapés.

L'intuition : traiter la distribution empirique comme exacte, et calculer le biais moyen sur les échantillons bootstrapés.

La mise en garde du cours. En estimant le biais, on peut **ajouter de l'erreur d'échantillonnage**. Corriger le biais **si et seulement s'il est grand comparé à l'écart-type** de $\hat{\theta}$.

Cette mise en garde est la décomposition biais-variance de la fiche 67, appliquée à la correction elle-même. Retirer un biais estimé avec bruit peut **augmenter** le risque quadratique total. La correction ne se justifie que quand le biais domine.

L'application à la régression prédictive

Bootstrap paramétrique : 1 000 échantillons, 200 périodes de rodage, échantillons de même longueur que la série historique.

Grandeur	Monte-Carlo (vrai modèle)	Bootstrap
Moyenne de $\hat{\beta}$	0,013	0,0125
Biais moyen de $\hat{\beta}$	0,004	0,0036
Statistique de Student moyenne	0,75	0,67

Les deux colonnes concordent très bien. Le bootstrap — qui n'utilise **que les données observées** — retrouve un biais de **0,0036** là où le Monte-Carlo — qui connaît le vrai modèle — trouve **0,004**. C'est la validation empirique du principe : *la distribution empirique se comporte comme la vraie*.

Et la conclusion pour l'économétrie financière est sévère : sur $\hat{\beta} = 0,0089$ estimé, environ **0,0036** — soit **40 %** — serait attribuable au seul biais de petit échantillon.

● Concept 9 — Les limites du bootstrap

La discussion finale du cours.

- *La théorie asymptotique est très commode quand elle est disponible, mais **en petit échantillon les résultats peuvent être inexacts.***
- *Utiliser les simulations de **Monte-Carlo** pour acquérir de l'intuition.*
- *Le **bootstrap** est un outil puissant. L'utiliser quand la théorie asymptotique est **indisponible ou suspecte.***

Le bootstrap n'est pas une baguette magique :

- *il **ne fonctionne pas bien** si des **événements rares** sont absents de l'échantillon empirique ;*
- *il **ne tient pas compte** de biais plus subtils, comme le **biais du survivant** ou la **sélection d'échantillon** ;*
- *il **ne guérit pas** la **mauvaise spécification du modèle.***

Il ne remplace pas le bon sens !

La première limite est la plus grave en finance. Le bootstrap ne peut **rééchantillonner que ce qui a été observé**. Si les vingt années de données ne contiennent aucun krach, aucun échantillon bootstrap n'en contiendra — et l'on conclura à une queue mince. **Le bootstrap ne crée jamais d'événement plus extrême que le pire observé** : c'est exactement la faiblesse de la simulation historique de la fiche 55.

Les références du cours : Campbell, Lo et MacKinlay (1997) · **Efron et Tibshirani**, *An Introduction to the Bootstrap* · Davison et Hinkley, *Bootstrap Methods and Their Application* · **Stambaugh (1999)**, « Predictive Regressions », *Journal of Financial Economics*.

Comment résoudre l'exercice type (protocole)

1. **Identifier le risque** : échantillon court ? prédicteur persistant ? loi asymétrique ou à queues épaisses ?
2. **Si le vrai modèle est connu** : faire un **Monte-Carlo** — simuler, estimer, mesurer biais et couverture.
3. **Si le vrai modèle est inconnu** : faire un **bootstrap** — rééchantillonner les données observées.
4. **Données i.i.d.** : tirer **avec remise** dans les observations.

- 5. **Données dépendantes : bootstrap paramétrique** — estimer le modèle, rééchantillonner les **résidus**, régénérer, jeter le rodage.
- 6. **Intervalle de confiance** : $(\hat{\mu} - (\hat{\mu}_{97,5\%}^* - \hat{\mu}), \hat{\mu} - (\hat{\mu}_{2,5\%}^* - \hat{\mu}))$ — attention à l'**inversion**.
- 7. **Correction de biais** : $\mathbb{E}_R[\hat{\theta}^*] - \hat{\theta}$, **et seulement si** le biais est grand devant l'écart-type.
- 8. **Vérifier les limites** : événements rares présents ? biais de sélection ? modèle bien spécifié ?

Comment reconnaître qu'il faut utiliser cette méthode ?

Indice dans l'énoncé	Ce qu'il faut faire
« échantillon court »	se méfier de l'asymptotique
autocorrélation estimée	biais de Kendall $-(1 + 3\rho_1)/T$
régression prédictive, prédicteur persistant	biais de Stambaugh
loi asymétrique ou à queues épaisses	l'approximation normale échoue
« estimateur analytiquement compliqué »	bootstrap
« corriger le biais »	$\mathbb{E}_R[\hat{\theta}^*] - \hat{\theta}$
données dépendantes	bootstrap paramétrique sur les résidus
« la théorie asymptotique est-elle fiable ? »	Monte-Carlo , mesurer la couverture
événements extrêmes importants	le bootstrap ne les crée pas

Exercices progressifs

Niveau 1 — Estimez le biais de $\hat{\rho}_1$ pour $\rho_1 = 0,8$ et $T = 60$, et comparez à l'écart-type.

La formule de Kendall.

$$\mathbb{E}(\hat{\rho}_1) - \rho_1 \approx -\frac{1 + 3\rho_1}{T} = -\frac{1 + 2,4}{60} = -\frac{3,4}{60} \approx -0,057$$

L'estimation moyenne serait donc $0,8 - 0,057 = 0,743$ au lieu de $0,8$ — une sous-estimation de plus de **7 %**.

La comparaison à l'écart-type. Pour un AR(1),

$$SE(\hat{\rho}_1) \approx \sqrt{(1 - \rho_1^2)/T} = \sqrt{0,36/60} = \sqrt{0,006} \approx 0,077.$$

$$\frac{\text{biais}}{SE} = \frac{0,057}{0,077} \approx 0,74$$

Le biais vaut donc les trois quarts de l'écart-type — c'est considérable. Un intervalle de confiance centré sur $\hat{\rho}_1$ est **systématiquement décalé** vers le bas, et sa couverture réelle est bien inférieure au niveau nominal.

La vérification sur le tableau du cours. Pour $\rho_1 = 0,9$, $T = 50$: Kendall donne $-(1 + 2,7)/50 = -0,074$, et la simulation sur 100 000 tirages donne $-0,0826$. Pour $\rho_1 = 0$, $T = 50$: $-1/50 = -0,020$ contre $-0,0203$ observé — accord quasi parfait.

La leçon : sur des séries persistantes et courtes — inflation, taux, ratios de valorisation —, il faut **corriger le biais** avant toute conclusion. Et quand la formule de Kendall ne s'applique pas, on peut utiliser le *bootstrap* pour estimer le biais.

Niveau 2 — Expliquez le biais de Stambaugh et pourquoi il est positif pour la prévisibilité par le rendement du dividende.

La formule.

$$\mathbb{E}(\hat{\beta} - \beta) = \frac{\text{Cov}(u_t, \varepsilon_t)}{\text{Var}(\varepsilon_t)} \mathbb{E}(\hat{\rho} - \rho) \approx -\frac{1 + 3\rho}{T} \cdot \frac{\text{Cov}(u_t, \varepsilon_t)}{\text{Var}(\varepsilon_t)}$$

Le mécanisme, en trois pas.

1. Le prédicteur est persistant. Pour le rendement du dividende, $\hat{\rho} = 0,9936$ — presque une marche aléatoire. Le biais de Kendall $\mathbb{E}(\hat{\rho} - \rho) \approx -(1 + 3\rho)/T$ est donc **négatif** et **maximal**.

2. Les innovations sont corrélées négativement. Le rendement du dividende est $x_t = \ln(D_t/P_t)$. Une hausse **inattendue** du prix P produit simultanément :

- un **rendement élevé** $\Rightarrow u_{t+1} > 0$;
- une **baisse** de $D/P \Rightarrow \varepsilon_{t+1} < 0$.

Donc $\text{Cov}(u_t, \varepsilon_t) < 0$.

3. Le produit. $(-) \times (-) = (+)$: le biais sur $\hat{\beta}$ est **positif**. *Le biais est positif, et peut être **substantiel comparé à l'écart-type de $\hat{\beta}$** .*

L'ampleur empirique, sur les données du cours (S&P 500, 1934-2008) :

- $\hat{\beta} = 0,0089$ estimé, $SE(\hat{\beta}) = 0,005$;
- Monte-Carlo : biais moyen **0,004**, statistique de Student moyenne **0,75 même sous $H_0 : \beta = 0$** .

Le biais vaut 80 % de l'écart-type. Sur $\hat{\beta} = 0,0089$, environ **0,004** pourrait n'être **que du biais** — soit près de la moitié.

Le point de méthode à retenir. Newey-West (fiche 72) corrige les **écarts-types** ; le biais de Stambaugh affecte le **coefficient**. Ce sont **deux problèmes distincts**, et corriger l'un ne corrige pas l'autre. Le remède au second est le **bootstrap paramétrique** du concept 8, qui retrouve ici un biais de **0,0036** — très proche du **0,004** du Monte-Carlo.

Niveau 3 — Expliquez le principe du bootstrap et la formule de l'intervalle de confiance.

Le principe. *Le bootstrap est une méthode de rééchantillonnage. C'est en substance une étude de Monte-Carlo qui utilise la **distribution empirique comme si elle était la vraie distribution**.*

Le parallèle des deux mondes.

Monde réel	Monde bootstrap
P inconnue	$\hat{P}$ = loi empirique, connue
données x	échantillon x^* tiré de $\hat{P}$
$\hat{\theta} = s(x)$	$\hat{\theta}^* = s(x^*)$
$\text{Biais}_P(\hat{\theta}, \theta)$	$\text{Biais}_{\hat{P}}(\hat{\theta}^*, \hat{\theta})$

L'idée. On ne peut pas répéter l'expérience réelle — on n'a qu'un échantillon. Mais on peut la répéter dans un monde où l'on **connaît tout**, celui de la loi empirique. La relation $\hat{\theta}^* \leftrightarrow \hat{\theta}$ y imite la relation $\hat{\theta} \leftrightarrow \theta$ dans le monde réel.

Concrètement, pour des données i.i.d. : *sous la distribution empirique, x prend chacune des valeurs $x_1, \dots, x_T$ avec probabilité égale*. Rééchantillonner, c'est **tirer avec remise**.

La construction de l'intervalle, en trois pas.

1. Tirer R échantillons et calculer $\hat{\mu}^*$ pour chacun.
2. Prendre les percentiles $\hat{\mu}_{2,5\%}^*$ et $\hat{\mu}_{97,5\%}^*$.
3. **Approcher la loi de $\hat{\mu} - \mu$ par celle de $\hat{\mu}^* - \hat{\mu}$** , d'où

$$\left(\hat{\mu} - (\hat{\mu}_{97,5\%}^* - \hat{\mu}), \hat{\mu} - (\hat{\mu}_{2,5\%}^* - \hat{\mu}) \right)$$

Pourquoi les percentiles sont-ils inversés ? C'est le point qui déroute. Si dans le monde bootstrap $\hat{\mu}^*$ dépasse $\hat{\mu}$ de δ dans 2,5 % des cas, on en déduit que dans le monde réel $\hat{\mu}$ dépasse μ de δ dans 2,5 % des cas — donc que μ pourrait être **inférieur** de δ . Le percentile **haut** de $\hat{\mu}^*$ donne donc la borne **basse**.

L'avantage sur la normale. L'intervalle obtenu est **asymétrique** si la loi de l'estimateur l'est. Sur l'exemple log-normal du cours, l'approximation normale donne (0,7532; 1,6036), symétrique autour de $\hat{\mu} = 1,1784$ — alors que la vraie loi de $\hat{t}$ est fortement **asymétrique à gauche**, comme le Monte-Carlo le montre ($\text{Prob}(\hat{t} < -1,96) = 0,1053$ contre 0,0042 à droite). Le bootstrap capture cette asymétrie ; la normale ne le peut pas.

Niveau 4 — type examen — Décrivez le bootstrap paramétrique et la correction de biais, avec leurs limites.

Pourquoi une version paramétrique. *Le bootstrap paramétrique peut traiter les échantillons **non i.i.d.*** Pour des données dépendantes — une série temporelle —, tirer les **observations** avec remise **détruirait la structure temporelle** : l'échantillon bootstrap n'aurait plus aucune autocorrélation.

La procédure, sur un AR(1) $x_t = a_0 + a_1 x_{t-1} + \varepsilon_t$:

1. Estimer $\hat{a}_0, \hat{a}_1$ et les **résidus** $\hat{\varepsilon}_t$.
2. Générer R échantillons : pour chacun, engendrer une **longue** série selon la dynamique AR(1) avec $\hat{a}_0, \hat{a}_1$, en tirant les chocs **avec remise** dans $\hat{\varepsilon}_1, \dots, \hat{\varepsilon}_T$; ne retenir que les **T dernières** observations (abandonner le rodage).
3. Calculer l'intervalle comme dans le bootstrap de base.

Les deux idées.

- On rééchantillonne les **résidus** — approximativement i.i.d. — et non les observations. La **dépendance** est réimposée par le modèle, la **distribution des chocs** vient des données.

- Le **rodage** élimine l'effet de la condition initiale arbitraire, de sorte que les T observations retenues proviennent de la loi stationnaire.

La correction de biais.

$$\mathbb{E}[\hat{\theta}] - \theta_0 \approx \mathbb{E}_R[\hat{\theta}^*] - \hat{\theta}$$

Intuition : traiter la distribution empirique comme exacte et calculer le biais moyen sur les échantillons bootstrapés. On corrige ensuite en retranchant le biais estimé.

La validation empirique du cours, sur la régression prédictive du S&P 500 :

	Monte-Carlo (vrai modèle)	Bootstrap (données seules)
Moyenne de $\hat{\beta}$	0,013	0,0125
Biais	0,004	0,0036
t moyen	0,75	0,67

La concordance est frappante : le bootstrap, qui n'utilise que l'échantillon observé, retrouve presque exactement ce que le Monte-Carlo obtient en connaissant le vrai modèle.

Les limites — quatre points, tous dans le cours.

1. La mise en garde sur la correction elle-même. *En estimant le biais, on peut **ajouter de l'erreur d'échantillonnage**. Corriger **seulement si le biais est grand comparé à l'écart-type**. C'est l'arbitrage biais-variance de la fiche 67 appliqué à la correction : retirer un biais mal estimé peut **augmenter** le risque quadratique.*

2. Les événements rares. *Le bootstrap ne fonctionne pas bien si des **événements rares sont absents** de l'échantillon empirique. Il ne peut rééchantillonner que ce qui a été observé : **il ne crée jamais un événement plus extrême que le pire vu**. C'est exactement la limite de la simulation historique de la fiche 55.*

3. Les biais de sélection. *Il ne tient pas compte de biais plus subtils, comme le **biais du survivant** ou la **sélection d'échantillon**. Si les fonds disparus sont absents de la base, le bootstrap reproduira fidèlement... un échantillon biaisé.*

4. La mauvaise spécification. *Il ne guérit pas la mauvaise spécification du modèle. Le bootstrap paramétrique **régénère par le modèle estimé** : si l'AR(1) est faux, tous les échantillons bootstrap le seront aussi.*

Il ne remplace pas le bon sens !

La conclusion de méthode. La théorie asymptotique est très commode quand elle est disponible, mais en petit échantillon les résultats peuvent être inexacts. Utiliser Monte-Carlo pour acquérir de l'intuition. Utiliser le bootstrap quand la théorie asymptotique est indisponible ou suspecte.

● Common mistakes

1. **Confondre consistance et absence de biais** — $\hat{\rho}_1$ est consistant **et** biaisé.
2. **Se tromper de signe pour Kendall** — le biais est **négatif** : l'autocorrélation est sous-estimée.
3. **Croire que Newey-West corrige le biais de Stambaugh** — il corrige les **écarts-types**, pas le coefficient.
4. **Oublier que le biais de Stambaugh est positif** pour le rendement du dividende — deux effets négatifs qui se multiplient.
5. **Inverser la formule de l'intervalle bootstrap** — le percentile **haut** de $\hat{\mu}^*$ donne la borne **basse**.
6. **Rééchantillonner les observations d'une série temporelle** — cela détruit la dépendance ; rééchantillonner les **résidus**.
7. **Oublier le rodage** dans un bootstrap paramétrique.
8. **Corriger un biais petit devant l'écart-type** — on ajoute alors plus de bruit qu'on n'enlève de biais.
9. **Croire que le bootstrap crée des événements extrêmes** — il ne peut que rééchantillonner l'observé.
10. **Croire que le bootstrap corrige la mauvaise spécification** — il ne le fait pas.

Ultimate Review

1. **Les limites de l'asymptotique** : estimateurs **consistants mais biaisés** · écarts-types imprécis · intervalles et tailles de test **incorrects**.
2. **Les remèdes** : **Monte-Carlo** pour comprendre · **bootstrap** pour l'inférence et la correction de biais.
3. **Biais de l'autocorrélation** : $\hat{\rho}_1$ des MCO est consistant mais biaisé **négativement**.
4. **Simulation** (100 000 tirages) : $-0,0826$ pour $(\rho_1, T) = (0,9; 50)$ · $-0,0203$ pour $(0; 50)$ · $-0,0402$ pour $(0,9; 100)$ · $-0,0100$ pour $(0; 100)$.
5. **Formule de Kendall** : $\mathbb{E}(\hat{\rho}_1) - \rho_1 \approx -\frac{1+3\rho_1}{T}$ — croissant en ρ_1 , décroissant en T .
6. **Biais de Stambaugh** : $\mathbb{E}(\hat{\beta} - \beta) = \frac{\text{Cov}(u_t, \varepsilon_t)}{\text{Var}(\varepsilon_t)} \mathbb{E}(\hat{\rho} - \rho)$ — **positif** pour le rendement du dividende, et substantiel devant $SE(\hat{\beta})$.

7. **S&P 500 (1934-2008)** : $\hat{\beta} = 0,0089$, $\hat{\rho} = 0,9936$, $SE = 0,005$; Monte-Carlo (1 000 tirages, 200 de rodage, Newey-West à 6 retards) : moyenne **0,013**, **biais 0,004**, t moyen **0,75**.
8. **Échec de la normalité** — log-normale $x_t = e^{-1/2+\varepsilon_t}$, $T = 50$: $\text{Var}(\hat{t}) = 1,2542^2$ au lieu de 1 ; $\text{Prob}(\hat{t} > 1,96) = 0,0042$ et $\text{Prob}(\hat{t} < -1,96) = 0,1053$ au lieu de 0,025 chacune.
9. **Principe du bootstrap** : une étude de Monte-Carlo utilisant la **distribution empirique** comme si elle était la vraie.
10. **Les deux mondes** : $(P, x, \hat{\theta} = s(x)) \leftrightarrow (\hat{P}, x^*, \hat{\theta}^* = s(x^*))$.
11. **Cas i.i.d.** : tirer **avec remise** — chaque x_i a probabilité $1/T$.
12. **Intervalle bootstrap** : $(\hat{\mu} - (\hat{\mu}_{97,5\%}^* - \hat{\mu}), \hat{\mu} - (\hat{\mu}_{2,5\%}^* - \hat{\mu}))$ — percentiles **inversés**.
13. **Exemple log-normal** : $\hat{\mu} = 1,1784$, $\hat{\sigma} = 1,5340$, $T = 50$; IC asymptotique (0,7532; 1,6036) ; variance de $\hat{t}$ bootstrapée **1,1852²** contre **1,2542²** (MC) et 1 (normale).
14. **Bootstrap paramétrique** : estimer le modèle et les résidus · régénérer en tirant les **résidus** avec remise · **abandonner le rodage** · calculer comme d'habitude.
15. **Correction de biais** : $\mathbb{E}[\hat{\theta}] - \theta_0 \approx \mathbb{E}_R[\hat{\theta}^*] - \hat{\theta}$; **corriger seulement si le biais est grand devant l'écart-type**.
16. **Validation** : bootstrap sur la régression prédictive $\Rightarrow$ biais **0,0036**, t moyen **0,67** — très proche du Monte-Carlo.
17. **Limites** : **événements rares absents** · biais du **survivant** et de **sélection** · **mauvaise spécification**. // *ne remplace pas le bon sens !*

Formulas to know

$$\mathbb{E}(\hat{\rho}_1) - \rho_1 \approx -\frac{1 + 3\rho_1}{T} \quad \mathbb{E}(\hat{\beta} - \beta) = \frac{\text{Cov}(u_t, \varepsilon_t)}{\text{Var}(\varepsilon_t)} \mathbb{E}(\hat{\rho} - \rho)$$

$$(\hat{\mu} - (\hat{\mu}_{97,5\%}^* - \hat{\mu}), \hat{\mu} - (\hat{\mu}_{2,5\%}^* - \hat{\mu})) \quad \mathbb{E}[\hat{\theta}] - \theta_0 \approx \mathbb{E}_R[\hat{\theta}^*] - \hat{\theta}$$

Methods to know : conduire un Monte-Carlo de biais ; construire un intervalle bootstrap et justifier l'inversion des percentiles ; mener un bootstrap paramétrique sur une série temporelle ; décider s'il faut corriger un biais.

Active Recall

Basic — Quel est le biais de l'autocorrélation estimée ?

La formule de Kendall.

$$\mathbb{E}(\hat{\rho}_1) - \rho_1 \approx -\frac{1 + 3\rho_1}{T}$$

Le biais est **négalif** — l'autocorrélation est **sous-estimée** —, **croissant en valeur absolue avec ρ_1** et **décroissant avec T** .

Les simulations du cours (100 000 tirages) le confirment :

ρ_1	T	Biais observé	Kendall
0,9	50	−0,0826	−0,074
0,0	50	−0,0203	−0,020
0,9	100	−0,0402	−0,037
0,0	100	−0,0100	−0,010

$\hat{\rho}_1$ est **consistant mais biaisé** : les deux notions sont distinctes (fiche 67).

Understanding — Quel est le principe du bootstrap ?

Le bootstrap est une **méthode de rééchantillonnage**. C'est en substance une **étude de Monte-Carlo qui utilise la distribution empirique comme si elle était la vraie distribution**.

Le parallèle des deux mondes.

Monde réel	Monde bootstrap
P inconnue	$\hat{P}$ empirique, connue
$\hat{\theta} = s(x)$	$\hat{\theta}^* = s(x^*)$
Biais $_P(\hat{\theta}, \theta)$	Biais $_{\hat{P}}(\hat{\theta}^*, \hat{\theta})$

Le raisonnement. On ne peut pas répéter l'expérience réelle — on n'a qu'un échantillon. Mais on peut la répéter dans un monde artificiel où l'on **connaît tout**. La relation entre $\hat{\theta}^*$ et $\hat{\theta}$ y **imite** la relation entre $\hat{\theta}$ et θ dans le monde réel.

Les deux usages principaux : *évaluer les propriétés distributionnelles d'estimateurs compliqués et corriger le biais ; améliorer la précision des approximations asymptotiques en petit échantillon.*

Application — Pourquoi le bootstrap donne-t-il un intervalle asymétrique là où la normale n'en donne jamais ?

L'intervalle bootstrap.

$$\left(\hat{\mu} - (\hat{\mu}_{97,5\%}^* - \hat{\mu}), \hat{\mu} - (\hat{\mu}_{2,5\%}^* - \hat{\mu}) \right)$$

Les deux demi-largeurs sont $\hat{\mu}_{97,5\%}^* - \hat{\mu}$ et $\hat{\mu} - \hat{\mu}_{2,5\%}^*$: elles sont **différentes** dès que la loi bootstrapée de $\hat{\mu}^*$ est asymétrique.

L'intervalle normal, $\hat{\mu} \pm 1,96 \hat{\sigma} / \sqrt{T}$, est **symétrique par construction** — il ne peut jamais capturer l'asymétrie.

L'illustration du cours. Pour la log-normale $x_t = e^{-1/2 + \varepsilon_t}$ avec $T = 50$, la loi de $\hat{t}$ est fortement **asymétrique à gauche** :

$$\text{Prob}(\hat{t} > 1,96) \approx 0,0042, \quad \text{Prob}(\hat{t} < -1,96) \approx 0,1053$$

au lieu de **0,025** de chaque côté. **Un test bilatéral nominal à 5 % rejette en réalité 11 % du temps**, presque entièrement du même côté.

Ce que le bootstrap capture. La variance de $\hat{t}$ bootstrapée est $1,1852^2$, contre $1,2542^2$ pour le Monte-Carlo et **1** pour l'approximation normale. Le bootstrap récupère donc l'essentiel de l'écart à la normalité, **sans connaître la vraie loi**.

*Pour la statistique de Student, la distribution bootstrapée est **plus précise** que l'approximation normale asymptotique.*

Comparison — Monte-Carlo et bootstrap : quelle différence ?

	Monte-Carlo	Bootstrap
Loi utilisée	le vrai modèle supposé connu	la loi empirique
Ce qu'il faut	des paramètres et une forme de loi	seulement les données
Usage	comprendre les propriétés d'une procédure	inférence sur les données réelles
Question	« que se passerait-il si le modèle était vrai ? »	« que dit cet échantillon ? »

Monte-Carlo est un **outil de diagnostic** : on simule le vrai modèle, on mesure biais et couverture, on juge la fiabilité de l'asymptotique. *Utiliser les simulations de Monte-Carlo pour acquérir de l'intuition.*

Bootstrap est un **outil d'inférence** : on ne connaît pas le vrai modèle, alors on prend la loi empirique à sa place. *L'utiliser quand la théorie asymptotique est indisponible ou suspecte.*

La validation croisée du cours. Sur la régression prédictive du S&P 500 :

	Monte-Carlo	Bootstrap
Biais de $\hat{\beta}$	0,004	0,0036
t moyen	0,75	0,67

Les deux concordent — ce qui **valide empiriquement** le principe du bootstrap : la loi empirique se comporte bien comme la vraie.

Mais seulement dans la mesure où l'échantillon est représentatif. Si les événements rares en sont absents, le bootstrap les ignorera ; le Monte-Carlo, lui, les engendrera si le modèle en prévoit.

Exam-style — Quand utiliser le bootstrap, et quelles sont ses limites ?

Quand l'utiliser.

1. *Quand la théorie asymptotique est **indisponible*** — estimateur analytiquement trop compliqué pour en dériver la loi.

2. Quand elle est **suspecte** — petit échantillon, loi asymétrique ou à queues épaisses, prédicteur très persistant.
3. Pour **corriger un biais** de petit échantillon quand aucune formule analytique n'existe : *quand les formules explicites ne sont pas connues, on peut utiliser le bootstrap pour estimer le biais.*
4. Pour obtenir des intervalles **asymétriques**, que l'approximation normale ne peut pas produire.

Comment.

- Données **i.i.d.** : tirer avec remise dans les observations.
- Données **dépendantes** : **bootstrap paramétrique** — estimer le modèle, rééchantillonner les **résidus**, régénérer la série, abandonner le rodage.
- Intervalle : $(\hat{\mu} - (\hat{\mu}_{97,5\%}^* - \hat{\mu}), \hat{\mu} - (\hat{\mu}_{2,5\%}^* - \hat{\mu}))$.
- Biais : $\mathbb{E}_R[\hat{\theta}^*] - \hat{\theta}$.

Les limites — quatre, toutes énoncées par le cours.

1. Les événements rares. *Il ne fonctionne pas bien si des événements rares sont **absents de l'échantillon empirique**.* C'est la limite la plus grave en finance : le bootstrap ne peut rééchantillonner que l'observé, donc **ne crée jamais** d'événement plus extrême que le pire vu. Une base sans krach produira des queues minces — exactement le défaut de la simulation historique (fiche 55).

2. Les biais de sélection. *Il ne tient pas compte de biais plus subtils, comme le **biais du survivant** ou la sélection d'échantillon.* Si les fonds disparus manquent, le bootstrap reproduira fidèlement un échantillon biaisé.

3. La mauvaise spécification. *Il ne guérit pas la mauvaise spécification du modèle.* Le bootstrap paramétrique **régénère par le modèle estimé** : si le modèle est faux, tous les échantillons le seront.

4. L'erreur ajoutée par la correction elle-même. *En estimant le biais, on peut ajouter de l'erreur d'échantillonnage. Corriger **seulement si le biais est grand comparé à l'écart-type**.* C'est l'arbitrage biais-variance : retirer un biais mal estimé peut augmenter le risque total.

Il ne remplace pas le bon sens !

La conclusion de méthode. Le bootstrap est un **outil d'inférence**, pas un correcteur universel. Il traite l'**erreur d'échantillonnage** — l'incertitude due au fait qu'on n'a qu'un

échantillon fini. Il ne traite **ni** les erreurs de **modèle**, **ni** les erreurs de **collecte**. Diagnostiquer d'abord la nature du problème, choisir l'outil ensuite.

Flashcards

Question	Réponse
Les deux défauts de l'asymptotique en petit échantillon ?	Estimateurs biaisés · écarts-types imprécis
Formule de Kendall ?	$\mathbb{E}(\hat{\rho}_1) - \rho_1 \approx -\frac{1+3\rho_1}{T}$
Signe du biais de l'autocorrélation ?	Négatif — elle est sous-estimée
Comment varie-t-il ?	Croissant en ρ_1 , décroissant en T
Biais observé pour $(\rho_1, T) = (0,9; 50)$?	-0,0826
Formule du biais de Stambaugh ?	$\frac{\text{Cov}(u_t, \varepsilon_t)}{\text{Var}(\varepsilon_t)} \mathbb{E}(\hat{\rho} - \rho)$
Son signe pour le rendement du dividende ?	Positif — deux effets négatifs se multiplient
Persistance du rendement du dividende ?	$\hat{\rho} = 0,9936$
Biais moyen sur $\hat{\beta}$ dans l'exemple ?	0,004 pour un SE de 0,005
Statistique de Student moyenne sous H_0 ?	0,75
Newey-West corrige-t-il ce biais ?	Non — il corrige les écarts-types
Loi de l'exemple non gaussien ?	Log-normale $x_t = e^{-1/2+\varepsilon_t}$, de moyenne 1
Var($\hat{t}$) observée ?	1,2542² au lieu de 1
Prob($\hat{t} < -1,96$) ?	0,1053 au lieu de 0,025
Que montre cette asymétrie ?	La loi de $\hat{t}$ est asymétrique à gauche
Définition du bootstrap ?	Monte-Carlo utilisant la loi empirique comme vraie
Comment rééchantillonner en i.i.d. ?	Tirer avec remise , chaque x_i de probabilité 1/T
Intervalle de confiance bootstrap ?	$(\hat{\mu} - (\hat{\mu}_{97,5\%}^* - \hat{\mu}), \hat{\mu} - (\hat{\mu}_{2,5\%}^* - \hat{\mu}))$
Pourquoi les percentiles sont-ils inversés ?	On approche $\hat{\mu} - \mu$ par $\hat{\mu}^* - \hat{\mu}$
Avantage sur l'intervalle normal ?	Il peut être asymétrique
Variance de $\hat{t}$ bootstrapée ?	1,1852² — plus proche de 1,2542² que de 1

Question	Réponse
Que rééchantillonne le bootstrap paramétrique ?	Les résidus , pas les observations
Pourquoi ?	Tirer les observations détruirait la dépendance
Pourquoi le rodage ?	Éliminer l'effet de la condition initiale
Formule de correction de biais ?	$\mathbb{E}_R[\hat{\theta}^*] - \hat{\theta}$
Quand corriger ?	Si le biais est grand devant l'écart-type
Pourquoi cette réserve ?	La correction ajoute de l'erreur d'échantillonnage
Biais bootstrapé de $\hat{\beta}$?	0,0036 — proche du 0,004 du Monte-Carlo
Première limite du bootstrap ?	Les événements rares absents de l'échantillon
Deuxième limite ?	Biais du survivant et de sélection
Troisième limite ?	Il ne guérit pas la mauvaise spécification
La conclusion du cours ?	<i>Il ne remplace pas le bon sens !</i>