

Fiche 312 — Lois de probabilité, exploration d'une distribution et tests classiques

Matière	Code · Langage R
Cours source	R Core Team, <i>An Introduction to R</i> 4.6.1 — chapitre 8 « Probability distributions » (§8.1 R comme jeu de tables statistiques, §8.2 examiner la distribution d'un jeu de données, §8.3 tests à un et deux échantillons)
Difficulté	Intermédiaire — peu de langage, beaucoup de fonctions à savoir nommer
Temps d'étude estimé	1 h 30
Prérequis	Fiches 301, 304, 306, 307 (vecteurs, facteurs, listes, <code>scan()</code>)
Concepts clés	les quatre préfixes <code>d</code> , <code>p</code> , <code>q</code> , <code>r</code> , le nom du premier argument, <code>lower.tail</code> , <code>log.p</code> , <code>log</code> , fonction de hasard cumulée , <code>summary()</code> , <code>fivenum()</code> , <code>stem()</code> , <code>hist()</code> , <code>density()</code> et la largeur de bande , <code>rug()</code> , <code>ecdf()</code> , <code>qqnorm()</code> / <code>qqline()</code> / <code>qqplot()</code> , <code>ppoints()</code> , <code>shapiro.test()</code> , <code>ks.test()</code> , <code>boxplot()</code> , <code>t.test()</code> de Welch , <code>var.test()</code> , <code>var.equal = TRUE</code> , <code>wilcox.test()</code>
À retenir en priorité	<code>d / p / q / r</code> + nom de la loi · <code>t.test()</code> fait du Welch par défaut · <code>lower.tail = FALSE</code> pour la queue droite · le piège du <code>ks.test</code> à paramètres estimés.

Vue d'ensemble

QUATRE PREFIXES, UN NOM DE LOI

d + nom	la DENSITE	1er argument : x
p + nom	la REPARTITION $P(X \leq x)$	1er argument : q
q + nom	les QUANTILES	1er argument : p
r + nom	la SIMULATION	1er argument : n

(sauf `rhyper`, `rsignrank`, `rwilcox` : nn)

ARGUMENTS COMMUNS `pxxx` et `qxxx` : `lower.tail` , `log.p`
 `dxxx` : `log`

EXPLORER UNE DISTRIBUTION

```

les nombres      summary()   fivenum()   stem()
la forme         hist() + lines(density(...)) + rug()
la repartition   plot(ecdf(x), do.points=FALSE, verticals=TRUE)
la normalite     qqnorm() ; qqline()      qqplot() contre une loi choisie
les tests        shapiro.test()          ks.test()

```

DEUX ECHANTILLONS

```

voir            boxplot(A, B)      deux ecdf superposees      qqplot(A, B)
moyennes        t.test(A, B)                <- WELCH par défaut
                 t.test(A, B, var.equal=TRUE) <- t classique
variances        var.test(A, B)                <- exige la NORMALITE
sans loi         wilcox.test(A, B)              <- loi continue commune
                 ks.test(A, B)                 <- écart vertical maximal des ecdf

```

OU SONT LES TESTS ? « all "classical" tests ... are in package stats
WHICH IS NORMALLY LOADED »

Le problème posé. « *One convenient use of R is to provide a comprehensive set of statistical tables.* »

(§8.1) Avant d'être un langage, R est ici **un formulaire** : les tables de la loi normale, de Student, du khi-deux — et de quinze autres — sont des fonctions, disponibles dans les quatre directions.

INTUITION — POURQUOI QUATRE FONCTIONS PAR LOI ET PAS UNE.

Une table imprimée ne se lit que dans **un sens** : on entre par x et on lit $P(X \leq x)$. R fournit **les quatre trajets** — densité, répartition, quantile, simulation —, et c'est ce qui rend inutile toute table papier : **qnorm** inverse **pnorm**, **rnorm** échantillonne, **dnorm** donne l'ordonnée de la courbe.

● Concept 1 — Les quatre préfixes

DÉFINITION (§8.1).

*« Functions are provided to evaluate **the cumulative distribution function** $P(X \leq x)$, **the probability density function** and **the quantile function** (given q , the smallest x such that $P(X \leq x) > q$), and **to simulate from the distribution**. »*

Règle (§8.1). *« Prefix the name given here by **d** for the density, **p** for the CDF, **q** for the quantile function and **r** for simulation (random deviates). The first argument is **x** for dxxx , **q** for pxxx , **p** for qxxx and **n** for rxxx (except for rhyper , rsignrank and rwilcox , for which it is nn). »*

Préfixe	Ce qu'il calcule	1 ^{er} argument
d	la densité	x
p	la fonction de répartition , $P(X \leq x)$	q
q	la fonction quantile	p
r	une simulation	n (nn pour rhyper , rsignrank , rwilcox)

Le nom du premier argument n'est pas décoratif. Pour pnorm il s'appelle **q** et pour qnorm il s'appelle **p** — l'inverse de ce que l'initiale du préfixe suggère. C'est logique : pnorm **reçoit un quantile** et rend une probabilité ; qnorm **reçoit une probabilité** et rend un quantile. Cela compte dès qu'on nomme les arguments.

1.1 Le tableau des lois

Loi	Nom R	Arguments supplémentaires
bêta	<code>beta</code>	<code>shape1</code> , <code>shape2</code> , <code>ncp</code>
binomiale	<code>binom</code>	<code>size</code> , <code>prob</code>
Cauchy	<code>cauchy</code>	<code>location</code> , <code>scale</code>
khi-deux	<code>chisq</code>	<code>df</code> , <code>ncp</code>
exponentielle	<code>exp</code>	<code>rate</code>
F (Fisher)	<code>f</code>	<code>df1</code> , <code>df2</code> , <code>ncp</code>
gamma	<code>gamma</code>	<code>shape</code> , <code>scale</code>
géométrique	<code>geom</code>	<code>prob</code>
hypergéométrique	<code>hyper</code>	<code>m</code> , <code>n</code> , <code>k</code>
log-normale	<code>lnorm</code>	<code>meanlog</code> , <code>sdlog</code>
logistique	<code>logis</code>	<code>location</code> , <code>scale</code>
binomiale négative	<code>nbinom</code>	<code>size</code> , <code>prob</code>
normale	<code>norm</code>	<code>mean</code> , <code>sd</code>
Poisson	<code>pois</code>	<code>lambda</code>
rang signé	<code>signrank</code>	<code>n</code>
Student	<code>t</code>	<code>df</code> , <code>ncp</code>
uniforme	<code>unif</code>	<code>min</code> , <code>max</code>
Weibull	<code>weibull</code>	<code>shape</code> , <code>scale</code>
Wilcoxon	<code>wilcox</code>	<code>m</code> , <code>n</code>

« *In not quite all cases is the non-centrality parameter `ncp` currently available* : see the on-line help for details. »

Au-delà du tableau (§8.1) : « there are functions `ptukey` and `qtukey` for the distribution of the *studentized range* of samples from a normal distribution, and `dmultinom` and `rmultinom` for the multinomial distribution. **Further distributions are available in contributed packages, notably `SuppDists`** . »

1.2 Les arguments communs, et pourquoi ils existent

Règle (§8.1). *« The `pxxx` and `qxxx` functions all have logical arguments `lower.tail` and `log.p` , and the `dxxx` ones have `log` . »*

MÉTHODE — CE QUE CELA PERMET (§8.1).

« This allows, e.g., getting **the cumulative (or "integrated") hazard function**, $H(t) = -\log(1 - F(t))$, by

```
- pxxx(t, ..., lower.tail = FALSE, log.p = TRUE)
```

or **more accurate log-likelihoods** (by `dxxx(..., Log = TRUE)`), **directly**. »

Le mot important est « directly ». L'intérêt n'est pas la concision mais **la précision numérique** :

- `lower.tail = FALSE` rend $1 - F(t)$ **calculé directement**, et non par soustraction. Quand $F(t)$ vaut 0,999999999, la soustraction perd presque tous les chiffres significatifs ; le calcul direct les garde.
- `log.p = TRUE` rend **le logarithme**, calculé sans passer par la probabilité — indispensable quand celle-ci vaut 10^{-300} et **sous-passerait** en zéro.
- `log = TRUE` sur une densité donne des **log-vraisemblances plus précises**, ce qui importe dès qu'on somme des centaines de termes.

CONTRÔLE — VÉRIFIER LA FORMULE DU HASARD CUMULÉ.

Par définition $H(t) = -\log(1 - F(t))$, où $1 - F(t) = P(X > t)$ est la **queue supérieure**. Or `pxxx(t, lower.tail = FALSE)` **est** cette queue, et `log.p = TRUE` en donne le logarithme. Le signe moins devant l'appel complète la formule.

Les deux exemples du cours (§8.1) :

```
## valeur p bilaterale pour une loi de Student
2*pt(-2.43, df = 13)

## point superieur a 1 % pour une loi F(2, 7)
qf(0.01, 2, 7, lower.tail = FALSE)
```

CONTRÔLE — LIRE CES DEUX LIGNES.

La première : $P(T \leq -2,43)$ pour 13 degrés de liberté, **doublé** — la loi de Student étant **symétrique**, la valeur **p** bilatérale est deux fois la queue inférieure au point négatif. La seconde : `lower.tail = FALSE` inverse le sens, donc `qf(0.01, ..., lower.tail = FALSE)` rend le point tel que **1 % de la masse est au-dessus** — le « point supérieur à 1 % ». Sans cet argument, on obtiendrait le point à 1 % **par le bas**.

« See the on-line help on `RNG` for how random-number generation is done in R. »

● Concept 2 — Examiner la distribution d'un échantillon

Cadrage (§8.2). « Given a (univariate) set of data we can examine its distribution in **a large number of ways**. *The simplest is to examine the numbers.* »

2.1 Les résumés numériques

```
attach(faithful)
summary(eruptions)
```

#	Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
#	1.600	2.163	4.000	3.488	4.454	5.100

```
fivenum(eruptions)
# [1] 1.6000 2.1585 4.0000 4.4585 5.1000
```

« *Two slightly different summaries are given by `summary` and `fivenum` and a display of the numbers by `stem` (a "stem and leaf" plot).* »

EN CLAIR — POURQUOI « SLIGHTLY DIFFERENT ».

Les deux rendent minimum, quartiles, médiane et maximum ; les valeurs diffèrent légèrement (**2,163 contre 2,1585, 4,454 contre 4,4585**). `summary` utilise la définition de quantile par défaut de R, `fivenum` **le résumé de Tukey** (les « charnières »), qui se calcule autrement. Ni l'un ni l'autre n'est faux — ce sont **deux conventions**.

Et `summary` donne **la moyenne** ; `fivenum` **non**. Sur ces données, moyenne **3,488** contre médiane **4,000** : l'écart signale déjà une distribution **non symétrique**.

```
> stem(eruptions)
```

The decimal point is 1 digit(s) to the left of the |

```
16 | 07035555588
18 | 00002223333335777777888822335777888
20 | 00002223378800035778
22 | 0002335578023578
24 | 00228
26 | 23
28 | 080
30 | 7
32 | 2337
34 | 250077
36 | 0000823577
38 | 2333335582225577
40 | 0000003357788888002233555577778
42 | 03335555778800233333555577778
44 | 0222233555778000000023333357778888
```

```
46 | 0000233357700000023578
48 | 00000022335800333
50 | 0370
```

Étape 1 — lire l'échelle. « The decimal point is **1 digit(s) to the left of the** `|` » : la tige `16` se lit **1,6**, la tige `50` se lit **5,0**.

Étape 2 — lire une ligne. `16 | 070355555588` signifie douze observations comprises entre 1,60 et 1,69 : $1,60 \cdot 1,67 \cdot 1,60 \cdot 1,63 \cdot 1,65 (\times 5) \cdot 1,68 (\times 2)$.

Étape 3 — voir la forme. Deux zones denses — autour de **1,8-2,2** et autour de **4,0-4,8** — séparées par une zone presque vide entre **2,6 et 3,4**. **La distribution est bimodale.**

Étape 4 — la conséquence. Le cours l'énonce plus loin : « **This distribution is obviously far from any standard distribution.** » Aucun ajustement d'une loi usuelle n'a de sens **sur l'ensemble** — d'où l'idée de n'en étudier **qu'un mode**.

Étape 5 — pourquoi ce diagramme et pas un histogramme. « **A stem-and-leaf plot is like a histogram** », mais il **conserve les chiffres** : on y lit les valeurs individuelles, et donc les arrondis, les répétitions, les valeurs aberrantes. C'est un histogramme **qui n'a rien perdu**.

2.2 Les vues graphiques

```
hist(eruptions)
## des classes plus fines, et un trace de densité
hist(eruptions, seq(1.6, 5.2, 0.2), prob = TRUE)
lines(density(eruptions, bw = 0.1))
rug(eruptions) # montrer les points de données réels
```

Trois précisions du cours (§8.2).

- « **More elegant density plots can be made by** `density` ».
- « **The bandwidth** `bw` **was chosen by trial-and-error as the default gives too much smoothing (it usually does for "interesting" densities).** »
- « **Better automated methods of bandwidth choice are available, and in this example** `bw = "SJ"` **gives a good result.** »

La largeur de bande est le paramètre décisif d'une estimation de densité. Trop grande, elle lisse les deux modes en un seul — c'est précisément ce que fait le défaut ici, et le cours en avertit. Trop petite, elle transforme le bruit en structure. Le cours donne les deux voies : **l'essai** (`bw = 0.1`) et **une règle automatique** (`bw = "SJ"`).

`prob = TRUE` **est indispensable** avant de superposer une densité : sans lui, l'histogramme affiche des **effectifs**, et la courbe de densité — d'intégrale 1 — serait invisible à côté.

La fonction de répartition empirique :

```
plot(ecdf(eruptions), do.points = FALSE, verticals = TRUE)
```

2.3 Ajuster une loi à un mode

MÉTHODE (§8.2).

« *This distribution is obviously far from any standard distribution. How about the right-hand mode, say eruptions of longer than 3 minutes? Let us fit a normal distribution and overlay the fitted CDF.* »

```
long <- eruptions[eruptions > 3]
plot(ecdf(long), do.points = FALSE, verticals = TRUE)
x <- seq(3, 5.4, 0.01)
lines(x, pnorm(x, mean = mean(long), sd = sqrt(var(long))), lty = 3)
```

CONTRÔLE — LIRE LES TROIS ARGUMENTS DE P NORM.

`x` est le vecteur de quantiles (le premier argument, nommé `q`) ; `mean` et `sd` sont **estimés sur l'échantillon**. Et `sd = sqrt(var(long))` : le cours passe par `var` puis la racine — équivalent à `sd(long)` , mais explicite sur ce qui est calculé. `lty = 3` trace **en pointillé**, pour distinguer l'ajustement des données.

Les diagrammes quantile-quantile :

```
par(pty = "s")          # une region de trace CARREE
qqnorm(long); qqline(long)
```

« ***This shows a reasonable fit but a shorter right tail than one would expect from a normal distribution.*** »

`par(pty = "s")` **n'est pas cosmétique** dans un Q-Q : une région carrée est ce qui permet de juger l'alignement sur la diagonale **sans distorsion d'échelle**. Et il faudra le restaurer (fiche 314).

La comparaison avec une loi connue (§8.2) :

```
x <- rt(250, df = 5)
qqnorm(x); qqline(x)
```

« *which will **usually (if it is a random sample)** show longer tails than expected for a normal* ».

```
qqplot(qt(ppoints(250), df = 5), x, xlab = "Q-Q plot for t dsn")
qqline(x)
```

« ***We can make a Q-Q plot against the generating distribution*** » — c'est-à-dire comparer l'échantillon à la loi dont il sort, et non à la normale. `ppoints(250)` fabrique les 250 probabilités théoriques, `qt(...)` les convertit en quantiles de Student.

2.4 Les tests de normalité

```
shapiro.test(long)
# Shapiro-Wilk normality test
# data: long
# W = 0.9793, p-value = 0.01052

ks.test(long, "pnorm", mean = mean(long), sd = sqrt(var(long)))
# One-sample Kolmogorov-Smirnov test
# data: long
# D = 0.0661, p-value = 0.4284
# alternative hypothesis: two.sided
```

La mise en garde du cours, à ne jamais oublier (§8.2). *« (Note that the distribution theory is not valid here as we have estimated the parameters of the normal distribution from the same sample.) »*

Le test de Kolmogorov-Smirnov suppose la loi de référence **entièrement spécifiée à l'avance**. Ici, `mean` et `sd` viennent **des données testées** : l'ajustement est meilleur qu'il ne devrait, la statistique D est **trop petite**, et la valeur p **trop grande**. Le test est **conservateur au mauvais sens** — il accepte trop facilement.

C'est ce qui explique la contradiction apparente entre les deux résultats : Shapiro-Wilk rejette ($p = 0,0105$), Kolmogorov-Smirnov non ($p = 0,428$). Le premier est **conçu** pour des paramètres estimés ; le second ne l'est pas.

● Concept 3 — Comparer deux échantillons

Cadrage (§8.3). « *So far we have compared a single sample to a normal distribution. A much more common operation is to compare aspects of two samples. Note that in R, all "classical" tests including the ones used below are in package `stats` which is normally loaded.* »

Les données du cours — « *on the latent heat of the fusion of ice (cal/gm) from Rice (1995, p. 490)* » :

```
A <- scan()  
79.98 80.04 80.02 80.04 80.03 80.03 80.04 79.97  
80.05 80.03 80.02 80.00 80.02  
  
B <- scan()  
80.02 79.94 79.98 79.97 79.97 80.03 79.95 79.97  
  
boxplot(A, B)
```

Noter l'usage de `scan()` sans argument : c'est l'idiome de la fiche 307 — `stdin()` désigne le **fichier de script**, donc les données suivent directement dans le source.

« *The plot indicates that the first group tends to give higher results than the second.* »

3.1 Comparer les moyennes

```
t.test(A, B)
#           Welch Two Sample t-test
# data:  A and B
# t = 3.2499, df = 12.027, p-value = 0.00694
# alternative hypothesis: true difference in means is not equal to 0
# 95 percent confidence interval:
#  0.01385526 0.07018320
# sample estimates:
# mean of x mean of y
#  80.02077  79.97875
```

La phrase décisive (§8.3). « *which does indicate **a significant difference, assuming normality**. By default the R function does not assume equality of variances in the two samples.* »

`t.test(A, B)` fait du Welch, pas du Student classique. C'est ce que révèle le titre de la sortie, et surtout **le degré de liberté non entier** : `df = 12.027`. Un `t` classique aurait $n_A + n_B - 2 = 13 + 8 - 2 = 19$ degrés de liberté. **Le df fractionnaire est la signature de Welch.**

3.2 Vérifier l'égalité des variances

```
var.test(A, B)
#           F test to compare two variances
# data:  A and B
# F = 0.5837, num df = 12, denom df = 7, p-value = 0.3938
# alternative hypothesis: true ratio of variances is not equal to 1
# 95 percent confidence interval:
#  0.1251097 2.1052687
# sample estimates:
```

```
# ratio of variances
# 0.5837405
```

« We can use **the F test to test for equality in the variances, provided that the two samples are from normal populations ... which shows no evidence of a significant difference, and so we can use the classical t-test that assumes equality of the variances.** »

CONTRÔLE — VÉRIFIER LES DEGRÉS DE LIBERTÉ.

num df = 12 et denom df = 7 : ce sont $n_A - 1 = 13 - 1 = 12$ et $n_B - 1 = 8 - 1 = 7$. Cela confirme au passage que **A a 13 valeurs et B en a 8.**

3.3 Le t classique

```
t.test(A, B, var.equal = TRUE)
# Two Sample t-test
# data: A and B
# t = 3.4722, df = 19, p-value = 0.002551
# 95 percent confidence interval:
# 0.01669058 0.06734788
```

CONTRÔLE — LA COHÉRENCE DE TOUTE LA SECTION.

Le degré de liberté vaut maintenant **19**, soit $13 + 8 - 2$.

Et l'intervalle est **centré sur la différence des moyennes** : $\frac{0,01669058 + 0,06734788}{2} = 0,04201923$, tandis que $80,02077 - 79,97875 = 0,04202$. Les deux sorties se recourent.

L'intervalle de Welch est plus large (0,0563 contre 0,0507) et la valeur **p** plus grande (**0,0069 contre 0,0026**) : ne pas supposer l'égalité des variances **coûte de la puissance**. C'est le prix d'une hypothèse en moins.

3.4 Sans hypothèse de loi

```
wilcox.test(A, B)
# Wilcoxon rank sum test with continuity correction
# data: A and B
```

```
# W = 89, p-value = 0.007497
# alternative hypothesis: true location shift is not equal to 0
#
# Warning message:
# Cannot compute exact p-value with ties in: wilcox.test(A, B)
```

Règle (§8.3). « *All these tests assume normality of the two samples. The two-sample Wilcoxon (or Mann-Whitney) test only assumes a common continuous distribution under the null hypothesis.* »

L'avertissement est une information, pas une nuisance (§8.3). « *Note the warning : there are several ties in each sample, which suggests strongly that these data are from a discrete distribution (probably due to rounding).* »

Le test suppose une loi **continue** — donc **aucune égalité** entre observations. Les ex æquo présents prouvent que l'hypothèse est violée. Le cours en tire une **conclusion sur les données** : elles sont arrondies au centième. **L'avertissement du logiciel devient un diagnostic statistique.**

Comparer graphiquement, et le test de Kolmogorov-Smirnov à deux échantillons :

```
plot(ecdf(A), do.points = FALSE, verticals = TRUE, xlim = range(A, B))
plot(ecdf(B), do.points = FALSE, verticals = TRUE, add = TRUE)

ks.test(A, B)
#          Two-sample Kolmogorov-Smirnov test
# data:  A and B
# D = 0.5962, p-value = 0.05919
#
# Warning message:
# cannot compute correct p-values with ties in: ks.test(A, B)
```

« *The Kolmogorov-Smirnov test is of the maximal vertical distance between the two ecdfs, assuming a common continuous distribution.* » — même avertissement d'ex æquo, même cause.

`xlim = range(A, B)` avant `add = TRUE` : sans lui, la seconde courbe pourrait sortir du cadre fixé par la première. C'est le `range` de la fiche 301, ici employé sur **deux** vecteurs à la fois — `max / min` acceptant plusieurs arguments.

Énoncé. À partir des deux séries de mesures de chaleur latente, retracer la démarche du cours : quelles questions, dans quel ordre, et pourquoi.

Étape 1 — regarder avant de tester. `boxplot(A, B)`. « *The plot indicates that **the first group tends to give higher results than the second.*** » On formule l'hypothèse à partir du graphique, on ne la teste pas encore.

Étape 2 — le test le plus robuste d'abord. `t.test(A, B)` sans option. Résultat : $t = 3,2499$, $df = 12,027$, $p = 0,00694$. **Différence significative** — « *assuming normality* ».

Étape 3 — comprendre ce qui vient d'être fait. Le `df = 12,027` **non entier** signale Welch : « *By default the R function does not assume equality of variances* ». R a choisi, sans le demander, la **variante prudente**.

Étape 4 — peut-on faire mieux ? Si les variances sont égales, le test classique est **plus puissant**. On teste donc l'hypothèse : `var.test(A, B)` → $F = 0,5837$, $p = 0,3938$. « *provided that the two samples are from normal populations* » — le test F **ajoute** une hypothèse de normalité.

Étape 5 — appliquer le test classique. `t.test(A, B, var.equal = TRUE)` → $t = 3,4722$, $df = 19$, $p = 0,002551$.

Étape 6 — comparer les deux conclusions.

	Welch	Classique
df	12,027	19
t	3,2499	3,4722
p	0,00694	0,002551
Largeur de l'IC	0,0563	0,0507

La même conclusion, avec plus de puissance — au prix d'une hypothèse supplémentaire, elle-même vérifiée sous une autre hypothèse. **La chaîne d'hypothèses s'allonge à mesure qu'on gagne en précision.**

Étape 7 — se passer de la normalité. `wilcox.test(A, B)` → $W = 89, p = 0,007497$. « **only assumes a common continuous distribution** ». **Conclusion inchangée** — ce qui est rassurant : le résultat ne dépend pas de la normalité.

Étape 8 — lire l'avertissement. « there are **several ties in each sample, which suggests strongly that these data are from a discrete distribution (probably due to rounding)** ». Les données sont au **centième** près. L'hypothèse de continuité est violée — pour Wilcoxon **comme** pour Kolmogorov-Smirnov, qui émet le même avertissement.

Étape 9 — le dernier regard. Deux `ecdf` superposées, et `ks.test(A, B)` → $D = 0,5962, p = 0,05919$. **Non significatif au seuil de 5 %** — le KS à deux échantillons teste **toute différence de loi**, pas seulement un décalage de position ; il est donc **moins puissant** contre une alternative de décalage. Trois tests, trois valeurs p , une seule conclusion à formuler prudemment.

Étape 10 — la leçon de méthode. Le cours ne présente pas un test, mais **une démarche** : voir, tester au plus robuste, vérifier si l'on peut resserrer, confirmer sans hypothèse de loi, **et lire les avertissements comme des résultats**.

Comment reconnaître le type d'exercice

Le signal dans l'énoncé	Ce qu'il faut mobiliser
« la probabilité que $X \leq a$ »	<code>p</code> + nom de loi
« la valeur telle que 5 % soient au-dessus »	<code>q</code> + nom , avec <code>lower.tail = FALSE</code>
« tracer la courbe de densité théorique »	<code>d</code> + nom
« simuler un échantillon »	<code>r</code> + nom
« une valeur p bilatérale »	2 × la queue, si la loi est symétrique
« une probabilité minuscule »	<code>log.p = TRUE</code> — sinon sous-passement
« la fonction de hasard cumulée »	<code>-pxxx(t, lower.tail = FALSE, log.p = TRUE)</code>
« une log-vraisemblance »	<code>dxxx(..., log = TRUE)</code>
« résumer un échantillon »	<code>summary()</code> , <code>fivenum()</code> , <code>stem()</code>
« la forme de la distribution »	<code>hist()</code> + <code>density()</code> + <code>rug()</code>
« ma densité estimée n'a qu'un mode »	la largeur de bande est trop grande
« la répartition empirique »	<code>ecdf()</code>
« est-ce normal ? » — visuellement	<code>qqnorm()</code> / <code>qqline()</code>
« est-ce normal ? » — formellement	<code>shapiro.test()</code>
« comparer à une loi donnée »	<code>ks.test(x, "pnorm", ...)</code>
« comparer à la loi qui a engendré »	<code>qqplot(qt(ppoints(n), df), x)</code>
« comparer deux moyennes »	<code>t.test(A, B)</code> — Welch par défaut
« les variances sont-elles égales ? »	<code>var.test()</code> — exige la normalité
« un df non entier »	c'est Welch
« sans hypothèse de normalité »	<code>wilcox.test()</code>
« comparer deux lois entières »	<code>ks.test(A, B)</code>

Le signal dans l'énoncé	Ce qu'il faut mobiliser
« avertissement d'ex æquo »	les données sont discrètes ou arrondies

Comment résoudre ce type d'exercice

Protocole « lire une table statistique » — 4 étapes.

1. **Choisir le préfixe** selon ce qu'on cherche : `d` densité, `p` probabilité, `q` quantile, `r` simulation.
2. **Ajouter le nom de la loi et ses paramètres** (colonne « arguments supplémentaires »).
3. **Choisir la queue** : `lower.tail = FALSE` pour la queue droite — plus précis qu'un `1 - p`.
4. Si la probabilité risque d'être extrême, **passer en logarithme** (`log.p` , `log`).

Protocole « explorer une distribution » — 5 étapes.

1. **Les nombres** : `summary()` — et comparer **moyenne et médiane** pour détecter l'asymétrie.
2. **Le détail** : `stem()` , qui conserve les chiffres et révèle arrondis et multimodalité.
3. **La forme** : `hist(..., prob = TRUE)` + `lines(density(..., bw = ...))` + `rug()` . **Toujours régler la bande.**
4. **La répartition** : `plot(ecdf(x), do.points = FALSE, verticals = TRUE)` .
5. **La normalité** : `qqnorm()` / `qqline()` d'abord — puis `shapiro.test()` si un chiffre est exigé.

Protocole « comparer deux échantillons » — 5 étapes.

1. **Regarder** : `boxplot(A, B)` , deux `ecdf` superposées, `qqplot(A, B)` .
2. `t.test(A, B)` — c'est **du Welch**, donc l'hypothèse la plus faible.
3. Si l'on veut le test classique : `var.test()` d'abord, puis `t.test(..., var.equal = TRUE)` .
4. `wilcox.test(A, B)` pour se passer de la normalité.
5. **Lire les avertissements** : les ex æquo disent quelque chose **sur les données**.

● Common mistakes

Erreur	Correction
Confondre <code>pnorm</code> et <code>qnorm</code>	<code>p</code> rend une probabilité, <code>q</code> rend un quantile
Nommer <code>p =</code> le premier argument de <code>pnorm</code>	il s'appelle <code>q</code>
Utiliser <code>n</code> pour <code>rhyper</code> , <code>rsignrank</code> , <code>rwilcox</code>	c'est <code>nn</code>
Écrire <code>1 - pnorm(x)</code>	<code>pnorm(x, lower.tail = FALSE)</code> est plus précis
Calculer <code>log(dnorm(x))</code>	<code>dnorm(x, log = TRUE)</code> évite le sous-passement
Oublier <code>lower.tail = FALSE</code> pour un point supérieur	on obtient le point inférieur
Croire <code>summary</code> et <code>fivenum</code> identiques	« <i>slightly different</i> » — deux conventions de quantile
Se fier au <code>bw</code> par défaut de <code>density</code>	« <i>gives too much smoothing</i> » — essayer, ou <code>bw = "SJ"</code>
Superposer une densité sans <code>prob = TRUE</code>	l'histogramme est en effectifs
Faire un Q-Q sans région carrée	<code>par(pty = "s")</code> — sinon l'alignement est illisible
Utiliser <code>ks.test</code> avec des paramètres estimés	« <i>the distribution theory is not valid</i> »
Croire <code>t.test(A, B)</code> classique	c'est du Welch — voir le df non entier
Utiliser <code>var.test</code> sans penser à la normalité	« <i>provided that the two samples are from normal populations</i> »
Ignorer un avertissement d'ex æquo	il révèle des données discrètes ou arrondies
Croire <code>wilcox.test</code> sans hypothèse	il suppose une loi continue commune
Superposer deux <code>ecdf</code> sans <code>xlim</code>	la seconde peut sortir du cadre
Chercher à charger un paquet pour les tests	ils sont dans <code>stats</code> , « <i>normally loaded</i> »

Ultimate Review

Les quatre préfixes. `d` densité (1^{er} arg. `x`) · `p` répartition $P(X \leq x)$ (1^{er} arg. `q`) · `q` quantile — « *the smallest x such that $P(X \leq x) > q$* » (1^{er} arg. `p`) · `r` simulation (1^{er} arg. `n`, `nn` pour `rhyper`, `rsignrank`, `rwilcox`).

Les dix-neuf lois. `beta` `binom` `cauchy` `chisq` `exp` `f` `gamma` `geom` `hyper` `lnorm` `logis` `nbinom` `norm` `pois` `signrank` `t` `unif` `weibull` `wilcox` · `ncp` **n'est pas partout disponible** · en plus : `ptukey` / `qtukey` (étendue studentisée), `dmultinom` / `rmultinom` ; ailleurs, `SuppDists`.

Arguments communs. `pxxx` et `qxxx` : `lower.tail`, `log.p` · `dxxx` : `log` · usage : **fonction de hasard cumulée** $H(t) = -\log(1 - F(t))$ par `-pxxx(t, lower.tail = FALSE, log.p = TRUE)`, et **log-vraisemblances plus exactes** par `dxxx(..., log = TRUE)` — « *directly* », donc **sans perte de précision**.

Deux exemples. `2*pt(-2.43, df = 13)` — valeur ***p* bilatérale** · `qf(0.01, 2, 7, lower.tail = FALSE)` — **point supérieur à 1 %**. Génération aléatoire : voir `RNG`.

Résumés numériques. `summary` (avec la **moyenne**) · `fivenum` (résumé de Tukey, « *slightly different* ») · `stem` — un histogramme **qui conserve les chiffres**. Sur `eruptions` : min **1,600**, médiane **4,000**, moyenne **3,488**, max **5,100** ; `fivenum` donne **2,1585** et **4,4585** là où `summary` donne **2,163** et **4,454**.

Graphiques. `hist(x, seq(...), prob = TRUE)` + `lines(density(x, bw = ...))` + `rug(x)` · « *the default gives too much smoothing (it usually does for "interesting" densities)* », et `bw = "SJ"` est cité comme bon choix ici · `plot(ecdf(x), do.points = FALSE, verticals = TRUE)` · `par(pty = "s")` avant un Q-Q · `qqnorm` / `qqline` / `qqplot` / `ppoints`.

Tests d'ajustement. `shapiro.test(long)` → $W = 0,9793$, $p = 0,01052$ · `ks.test(long, "pnorm", ...)` → $D = 0,0661$, $p = 0,4284$ · « *the distribution theory is not valid here as we have estimated the parameters of the normal distribution from the same sample* » — d'où la divergence entre les deux.

Où sont les tests. « *all "classical" tests ... are in package stats which is normally loaded* ».

Deux échantillons. `boxplot(A, B)` pour voir · `t.test(A, B)` → Welch, $t = 3,2499$, $df = 12,027$, $p = 0,00694$ — « *By default the R function does not assume equality of variances* » · `var.test(A, B)` → $F = 0,5837$, df 12 et 7, $p = 0,3938$, « *provided that the two samples are from normal populations* » · `t.test(A, B, var.equal = TRUE)` → $t = 3,4722$, $df = 19$, $p = 0,002551$ · `wilcox.test(A, B)` → $W = 89$, $p = 0,007497$, « *only assumes a common continuous distribution* » · `ks.test(A, B)` → $D = 0,5962$, $p = 0,05919$, « *the maximal vertical distance between the two ecdfs* ».

Moyennes. $\bar{A} = 80,02077$, $\bar{B} = 79,97875$, différence **0,04202** — centre des deux intervalles de confiance.

L'avertissement des ex æquo. « *there are **several ties in each sample**, which **suggests strongly that these data are from a discrete distribution (probably due to rounding)*** » — un message du logiciel qui est un résultat statistique.

Active Recall

*« Prefix the name ... by **d** for the density, **p** for the CDF, **q** for the quantile function and **r** for simulation (random deviates). The first argument is **x** for **dxxx**, **q** for **pxxx**, **p** for **qxxx** and **n** for **rxxx** (except for **rhyper**, **rsignrank** and **rwilcox**, for which it is **nn**). »* (§8.1)

Préfixe	Calcule	1 ^{er} argument
d	la densité	x
p	$P(X \leq x)$	q
q	le quantile	p
r	une simulation	n (ou nn)

Le croisement est délibéré : **pnorm** reçoit un quantile, **qnorm** reçoit une probabilité. Le nom de l'argument décrit **ce qui entre**, le préfixe **ce qui sort**.

« This allows, e.g., getting **the cumulative (or "integrated") hazard function**, $H(t) = -\log(1 - F(t))$, by

```
- pxxx(t, ..., lower.tail = FALSE, log.p = TRUE)
```

or **more accurate log-likelihoods** (by `dxxx(..., Log = TRUE)`), **directly**. » (§8.1)

Pourquoi pas `-log(1 - pxxx(t))` . Le mot du cours est « **directly** », et l'enjeu est **numérique** :

- quand $F(t) \approx 0,999999999$, la soustraction $1 - F(t)$ **perd presque tous les chiffres significatifs** ; `lower.tail = FALSE` calcule la queue **sans soustraire** ;
- quand cette queue vaut 10^{-320} , elle **sous-passe** en zéro et le logarithme vaut $-\infty$;
`log.p = TRUE` rend **le logarithme directement**, sans passer par la probabilité.

```
2*pt(-2.43, df = 13)           # valeur p bilaterale
qf(0.01, 2, 7, lower.tail = FALSE) # point superieur a 1 % d'une F(2,7)
```

Le premier : `pt(-2.43, df = 13)` est $P(T \leq -2,43)$, la queue **inférieure**. La loi de Student étant **symétrique**, la valeur **p** bilatérale est **le double**.

Le second : sans `lower.tail = FALSE` , `qf(0.01, 2, 7)` rendrait le point tel que **1 % de la masse est en dessous**. L'argument **inverse le sens** : on obtient le point tel que 1 % est **au-dessus** — le « point supérieur à 1 % », soit le quantile à 99 %.

« *Two slightly different summaries are given by* `summary` *and* `fivenum` » (§8.2).

```
summary(eruptions)
#   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
#   1.600   2.163   4.000   3.488   4.454   5.100
fivenum(eruptions)
# [1] 1.6000 2.1585 4.0000 4.4585 5.1000
```

Deux différences. (1) Les quartiles diffèrent — **2,163 contre 2,1585, 4,454 contre 4,4585** : `summary` utilise la définition de quantile par défaut de R, `fivenum` **les charnières de Tukey**. Ni l'un ni l'autre n'est faux. (2) `summary` **donne la moyenne**, `fivenum` non.

Et la comparaison **moyenne 3,488 / médiane 4,000** signale déjà une distribution **non symétrique** — ce que `stem()` confirmera en montrant **deux modes**.

« *The bandwidth `bw` was chosen by trial-and-error as the default gives too much smoothing (it usually does for "interesting" densities). Better automated methods of bandwidth choice are available, and in this example `bw = "SJ"` gives a good result.* » (§8.2)

C'est le paramètre décisif. Trop grand, il **lisse les deux modes en un seul** — exactement ce que fait le défaut sur `eruptions`, dont la bimodalité est le fait saillant. Trop petit, il transforme le bruit en structure.

Deux voies : **l'essai** (`bw = 0.1` ici) ou **une règle automatique** (`bw = "SJ"`).

Et `hist(..., prob = TRUE)` est requis avant `lines(density(...))` : sinon l'histogramme est en **effectifs** et la densité, d'intégrale 1, sera invisible.

Parce que « *This distribution is obviously far from any standard distribution.* » — `stem()` révèle **deux modes**, séparés par une zone presque vide entre 2,6 et 3,4.

« *How about the right-hand mode, say eruptions of longer than 3 minutes ? Let us fit a normal distribution and overlay the fitted CDF.* » (§8.2)

```
long <- eruptions[eruptions > 3]
plot(ecdf(long), do.points = FALSE, verticals = TRUE)
x <- seq(3, 5.4, 0.01)
lines(x, pnorm(x, mean = mean(long), sd = sqrt(var(long))), lty = 3)
```

La leçon de méthode : on n'ajuste pas une loi unimodale à des données bimodales. **On isole d'abord le mode**, puis on ajuste. Le filtrage se fait par indexation logique (fiche 302).

Les deux résultats du cours :

```
shapiro.test(long)  W = 0.9793, p-value = 0.01052  -> rejette a 5 %  
ks.test(long, "pnorm", mean = mean(long), sd = sqrt(var(long)))  
D = 0.0661, p-value = 0.4284  -> ne rejette pas
```

La cause est donnée par le cours lui-même : *« (Note that the distribution theory is not valid here as we have estimated the parameters of the normal distribution from the same sample.) »*

Le test de Kolmogorov-Smirnov suppose la loi de référence **entièrement spécifiée d'avance**. Ici `mean` et `sd` viennent **des données testées** : l'ajustement est **artificiellement bon**, **D trop petit**, **p trop grand**. Shapiro-Wilk, lui, **est conçu** pour des paramètres estimés. **En cas de désaccord, c'est Shapiro-Wilk qu'il faut croire ici.**

« By default the R function does not assume equality of variances in the two samples. » (§8.3)

C'est **le test de Welch**, et deux indices le montrent dans la sortie :

1. le **titre** : `Welch Two Sample t-test` ;
2. surtout, **le degré de liberté non entier** : `df = 12.027` .

Un t classique aurait $n_A + n_B - 2 = 13 + 8 - 2 = 19$ degrés de liberté — c'est bien ce qu'affiche `t.test(A, B, var.equal = TRUE)` .

Le df fractionnaire est la signature de Welch, et le moyen le plus rapide de savoir quel test on a réellement lancé.

	Welch	Classique (<code>var.equal = TRUE</code>)
df	12,027	19
<i>t</i>	3,2499	3,4722
<i>p</i>	0,00694	0,002551
IC à 95 %	[0,01386 ; 0,07018]	[0,01669 ; 0,06735]
Largeur	0,0563	0,0507

Même conclusion, puissance différente. Ne pas supposer l'égalité des variances **coûte des degrés de liberté**, donc élargit l'intervalle et augmente la valeur *p*.

Contrôle de cohérence : les deux intervalles sont centrés sur $\frac{0,01669+0,06735}{2} = 0,04202$, qui est bien $80,02077 - 79,97875$.

Et le chemin pour passer de l'un à l'autre est `var.test(A, B)` → *p* = 0,3938, « **no evidence of a significant difference** ».

« *All these tests assume normality of the two samples. The two-sample Wilcoxon (or Mann-Whitney) test only assumes a common continuous distribution under the null hypothesis.* » (§8.3)

Résultat : *W* = 89, *p* = 0,007497 — **même conclusion** que le test *t*, sans hypothèse de normalité.

L'avertissement est un résultat : *« Note the warning : **there are several ties in each sample, which suggests strongly that these data are from a discrete distribution (probably due to rounding).** »*

Le test suppose une loi **continue**, donc **aucune égalité** entre observations. Les ex æquo prouvent que l'hypothèse est violée — et le cours en tire une **conclusion sur les données** : elles sont arrondies au centième. **Le même avertissement apparaît pour** `ks.test(A, B)`, **pour la même raison.**

« *The Kolmogorov-Smirnov test is of the maximal vertical distance between the two ecdfs, assuming a common continuous distribution.* » (§8.3)

```
ks.test(A, B) D = 0.5962, p-value = 0.05919
```

Non significatif à 5 %, alors que le test t donnait $p = 0,0026$ et Wilcoxon $p = 0,0075$.

La raison est la nature de l'alternative. Le KS teste **toute différence entre les deux lois** — forme, dispersion, position. Contre une alternative précise de **décalage de position**, il est donc **moins puissant** qu'un test conçu pour elle. Un test général paie sa généralité en puissance.

Et le même avertissement d'ex æquo s'applique : « *cannot compute correct p-values with ties* ».

Le cours donne **trois** voies (§8.3) :

1. **Boîtes à moustaches** : `boxplot(A, B)` — « *We have already seen a pair of boxplots.* »
2. **Deux répartitions empiriques superposées** :

```
plot(ecdf(A), do.points = FALSE, verticals = TRUE, xlim = range(A, B))  
plot(ecdf(B), do.points = FALSE, verticals = TRUE, add = TRUE)
```

3. `qqplot` — « *qqPlot will perform a Q-Q plot of the two samples* ».

`xlim = range(A, B)` **est indispensable** : la première courbe fixe le cadre, et sans un domaine couvrant **les deux** échantillons, la seconde en sortirait. Noter que `range` accepte **plusieurs vecteurs** (fiche 301) — il rend `c(min, max)` de l'ensemble.

Flashcards

Question	Réponse
Le préfixe de la densité ?	<code>d</code>
De la fonction de répartition ?	<code>p</code>
De la fonction quantile ?	<code>q</code>
De la simulation ?	<code>r</code>
Premier argument de <code>dxxx</code> ?	<code>x</code>
De <code>pxxx</code> ?	<code>q</code>
De <code>qxxx</code> ?	<code>p</code>
De <code>rxxx</code> ?	<code>n</code>
Les trois exceptions à <code>n</code> ?	<code>rhyper</code> · <code>rsignrank</code> · <code>rwilcox</code> → <code>nn</code>
Définition de la fonction quantile ?	Le plus petit x tel que $P(X \leq x) > q$
Nom R de la loi normale ?	<code>norm</code> — <code>mean</code> , <code>sd</code>
De la loi de Student ?	<code>t</code> — <code>df</code> , <code>ncp</code>
De la loi F ?	<code>f</code> — <code>df1</code> , <code>df2</code> , <code>ncp</code>
Du khi-deux ?	<code>chisq</code> — <code>df</code> , <code>ncp</code>
De la binomiale ?	<code>binom</code> — <code>size</code> , <code>prob</code>
De la loi de Poisson ?	<code>pois</code> — <code>lambda</code>
De l'exponentielle ?	<code>exp</code> — <code>rate</code>
De l'uniforme ?	<code>unif</code> — <code>min</code> , <code>max</code>
Le paramètre <code>ncp</code> est-il partout ?	Non
Deux fonctions hors tableau ?	<code>ptukey</code> / <code>qtukey</code> , <code>dmultinom</code> / <code>rmultinom</code>
Un paquet pour d'autres lois ?	<code>SuppDists</code>

Question	Réponse
Les deux arguments de <code>pxxx</code> et <code>qxxx</code> ?	<code>lower.tail</code> et <code>log.p</code>
L'argument de <code>dxxx</code> ?	<code>log</code>
La formule du hasard cumulé ?	$H(t) = -\log(1 - F(t))$
Comment le calculer ?	<code>-pxxx(t, lower.tail = FALSE, log.p = TRUE)</code>
Pourquoi pas par soustraction ?	Perte de précision et sous-passement
Valeur p bilatérale d'un t ?	2 × la queue — la loi est symétrique
Point supérieur à 1 % d'une F(2,7) ?	<code>qf(0.01, 2, 7, lower.tail = FALSE)</code>
Où lire comment R tire au hasard ?	L'aide de <code>RNG</code>
Deux résumés à cinq nombres ?	<code>summary()</code> et <code>fivenum()</code>
Lequel donne la moyenne ?	<code>summary()</code>
Pourquoi différent-ils ?	Deux conventions de quantile
Qu'est-ce que <code>stem()</code> ?	Un diagramme à tiges et feuilles
Son avantage sur l'histogramme ?	Il conserve les chiffres
Que révèle-t-il sur <code>eruptions</code> ?	Une distribution bimodale
Moyenne et médiane de <code>eruptions</code> ?	3,488 et 4,000
Que faut-il avant <code>lines(density(...))</code> ?	<code>prob = TRUE</code> dans <code>hist</code>
Que fait <code>rug()</code> ?	Il montre les points de données
Le défaut de <code>bw</code> est-il bon ?	Non — « <i>too much smoothing</i> »
Une bonne règle automatique ?	<code>bw = "SJ"</code>
Tracer la répartition empirique ?	<code>plot(ecdf(x), do.points=FALSE, verticals=TRUE)</code>
Que faire avant un Q-Q ?	<code>par(pty = "s")</code>
Les deux fonctions du Q-Q normal ?	<code>qqnorm()</code> et <code>qqline()</code>

Question	Réponse
Comparer à une loi choisie ?	<code>qqplot(qt(ppoints(n), df), x)</code>
Que fabrique <code>ppoints(n)</code> ?	Les probabilités théoriques
Le test de normalité de R ?	<code>shapiro.test()</code>
Son résultat sur <code>long</code> ?	$W = 0,9793, p = 0,01052$
Le test d'ajustement à une loi ?	<code>ks.test(x, "pnorm", ...)</code>
Son résultat sur <code>long</code> ?	$D = 0,0661, p = 0,4284$
Pourquoi ce désaccord ?	Les paramètres sont estimés sur le même échantillon
Où sont les tests classiques ?	Le paquet <code>stats</code> , « <i>normally loaded</i> »
Que fait <code>t.test(A, B)</code> par défaut ?	Le test de Welch
À quoi le voit-on ?	Au df non entier — 12,027
Son résultat ?	$t = 3,2499, p = 0,00694$
Le test d'égalité des variances ?	<code>var.test()</code>
Que suppose-t-il ?	Deux populations normales
Son résultat ?	$F = 0,5837, p = 0,3938$
Ses degrés de liberté ?	12 et 7 — soit $n - 1$ de chaque
Le test t classique ?	<code>t.test(A, B, var.equal = TRUE)</code>
Son df ?	19 — soit $13 + 8 - 2$
Son résultat ?	$t = 3,4722, p = 0,002551$
Que coûte l'hypothèse en moins ?	De la puissance — IC plus large
Les deux moyennes ?	80,02077 et 79,97875
Leur différence ?	0,04202 — le centre des deux IC
Le test sans normalité ?	<code>wilcox.test()</code>

Question	Réponse
Que suppose-t-il ?	Une loi continue commune
Son résultat ?	$W = 89, p = 0,007497$
Que teste <code>ks.test</code> à deux échantillons ?	L' écart vertical maximal des deux ecdf
Son résultat ?	$D = 0,5962, p = 0,05919$
Pourquoi est-il moins concluant ?	Il teste toute différence , donc moins puissant
Que signalent les avertissements d'ex æquo ?	Des données discrètes ou arrondies
Que faut-il avec deux <code>ecdf</code> superposées ?	<code>xlim = range(A, B)</code>