

Fiche 404 — Calcul vectoriel : gradients, jacobiennes, rétropropagation, Taylor multivarié

Matière	Maths · Apprentissage automatique
Cours source	Deisenroth, Faisal & Ong, <i>Mathematics for Machine Learning</i> , Cambridge University Press — chapitre 5 « Vector Calculus » (p. 139-178)
Difficulté	Avancé — l'outil qui rend l'apprentissage possible
Temps d'étude estimé	140 min
Prérequis	Fiche 401 (matrices, applications linéaires) · Fiche 403 (déterminant, trace)
Concepts clés	Quotient différentiel, dérivée, polynôme de Taylor, série de Taylor, série de Maclaurin, fonction analytique, règles de dérivation, dérivée partielle, gradient, règle de la chaîne multivariée, fonction à valeurs vectorielles, jacobienne, disposition au numérateur, déterminant jacobien, gradient de matrices, tenseur, identités utiles, rétropropagation, différentiation automatique, mode direct et mode inverse, graphe de calcul, variables intermédiaires, dérivées d'ordre supérieur, hessienne, linéarisation, série de Taylor multivariée, produit extérieur d'ordre k
Poids à l'examen	Le gradient est un VECTEUR LIGNE $1 \times n$ · la jacobienne $J(i, j) = \partial f_i / \partial x_j$ de taille $m \times n$ · la règle de la chaîne $\frac{\partial}{\partial x} g(f(x)) = \frac{\partial g}{\partial f} \frac{\partial f}{\partial x} \cdot \det J $ = facteur d'échelle des volumes · les dix identités de gradients matriciels · la rétropropagation = mode INVERSE de la différentiation automatique · la hessienne symétrique · le Taylor multivarié $\sum_k \frac{D_x^k f(x_0)}{k!} \delta^k$.

Vue d'ensemble

LE FIL DU CHAPITRE : dériver – de $\mathbb{R} \rightarrow \mathbb{R}$ jusqu'aux TENSEURS

- §5.1 UNIVARIÉ $df/dx := \lim_{h \rightarrow 0} (f(x+h) - f(x))/h$
TAYLOR $T_n(x) = \sum_{k \leq n} f^{(k)}(x_0)/k! (x - x_0)^k \quad x_0 = 0 \rightarrow$ MACLAURIN
RÈGLES produit · quotient · somme · CHAÎNE $(g \circ f)' = g'(f) f'$
- §5.2 DÉRIVÉES PARTIELLES ET GRADIENT $\nabla_x f = df/dx \in \mathbb{R}^{(1 \times n)}$ ⚠ VECTEUR LIGNE
CHAÎNE MULTIVARIÉE $\partial g / \partial x = (\partial g / \partial f)(\partial f / \partial x) \leftarrow$ « les dimensions voisines s'annulent »
- §5.3 FONCTIONS À VALEURS VECTORIELLES $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$
JACOBIENNE $J = df/dx \in \mathbb{R}^{(m \times n)}$, $J(i, j) = \partial f_i / \partial x_j$ (disposition au NUMÉRATEUR)

$|\det J|$ = facteur d'échelle des AIRES / VOLUMES

$f: \mathbb{R} \rightarrow \mathbb{R}$ scalaire · $f: \mathbb{R}^D \rightarrow \mathbb{R}$ ligne $1 \times D$ · $f: \mathbb{R} \rightarrow \mathbb{R}^E$ colonne $E \times 1$ · $f: \mathbb{R}^D \rightarrow \mathbb{R}^E$ matrice $E \times D$

§5.4 GRADIENTS DE MATRICES

résultat = TENSEUR multidimensionnel

astuce : APLATIR (isomorphisme $\mathbb{R}^{(m \times n)} \cong \mathbb{R}^{(mn)}$) → la chaîne redevient un produit matriciel

§5.5 DIX IDENTITÉS UTILES

tr , $\det$, inverse , $x^T a$, $a^T X b$, $x^T B x \dots$

§5.6 RÉTROPROPAGATION ET DIFF. AUTOMATIQUE

réseau profond $y = (f_K \circ \dots \circ f_1)(x)$, $L(\theta) = \|y - f_K(\theta, x)\|^2$

$\partial L / \partial \theta_i = (\partial L / \partial f_K)(\partial f_K / \partial f^{K-1}) \dots (\partial f^{i+1} / \partial \theta_i)$ ← on RÉUTILISE les calculs

MODE INVERSE = rétropropagation (⚠ le moins cher quand entrée >> sortie)

MODE DIRECT = les gradients suivent le flot des données

§5.7 ORDRE SUPÉRIEUR HESSIENNE $H = \nabla^2 f \in \mathbb{R}^{(n \times n)}$, SYMÉTRIQUE si f deux fois C^1

§5.8 LINÉARISATION ET TAYLOR MULTIVARIÉ

$f(x) \approx f(x_0) + (\nabla_x f)(x_0)(x - x_0)$

$f(x) = \sum_k D^k_x f(x_0) / k! \delta^k$, $\delta := x - x_0$, δ^k = produit EXTÉRIEUR k fois

$k=0$: $f(x_0)$ $k=1$: $\nabla f \cdot \delta$ $k=2$: $\frac{1}{2} \delta^T H \delta$ $k=3$: tenseur d'ordre 3

LE MOT D'ORDRE « LE GRADIENT POINTE DANS LA DIRECTION DE LA PLUS FORTE PENTE »

La phrase-programme. « Nous discuterons de comment calculer les gradients de fonctions, ce qui est souvent essentiel pour faciliter l'apprentissage dans les modèles d'apprentissage automatique, puisque **le gradient pointe dans la direction de la plus forte montée**. Le calcul vectoriel est donc l'un des outils mathématiques fondamentaux dont nous avons besoin. »

L'hypothèse de travail. « Dans tout ce livre, nous supposons que les fonctions sont **DIFFÉRENTIABLES**. » Les extensions aux **sous-différentiels** (fonctions continues mais non différentiables en certains points) et aux fonctions **avec contraintes** (ch. 7) ne sont pas couvertes ici.

● Concept 1 — Dérivation d'une fonction d'une variable (§5.1)

1.1 Quotient différentiel et dérivée

DÉFINITION 5.1 (QUOTIENT DIFFÉRENTIEL).

$$\frac{\delta y}{\delta x} := \frac{f(x + \delta x) - f(x)}{\delta x}$$

calcule la **pende de la SÉCANTE** passant par deux points du graphe de f .

C'est aussi la **pende MOYENNE** de f entre x et $x + \delta x$, si l'on suppose f linéaire. À la limite $\delta x \rightarrow 0$, on obtient la **TANGENTE**.

DÉFINITION 5.2 (DÉRIVÉE).

Pour $h > 0$, la dérivée de f en x est la limite

$$\frac{df}{dx} := \lim_{h \rightarrow 0} \frac{f(x + h) - f(x)}{h}$$

et la sécante devient une **tangente**.

La phrase à retenir. « La dérivée de f pointe dans la direction de la **PLUS FORTE MONTÉE** de f . »

Exemple 5.2 — la dérivée de x^n retrouvée par la définition. On sait que la réponse est nx^{n-1} , mais le livre la **dérive** à partir de la limite du quotient différentiel, via le développement du binôme de $(x + h)^n$: tous les termes en h^2 et au-delà s'annulent à la limite, seul $nx^{n-1}h/h$ survit.

1.2 Séries de Taylor

DÉFINITION 5.3 (POLYNÔME DE TAYLOR).

Le **polynôme de Taylor de degré n** de $f : \mathbb{R} \rightarrow \mathbb{R}$ en x_0 est

$$T_n(x) := \sum_{k=0}^n \frac{f^{(k)}(x_0)}{k!} (x - x_0)^k$$

où $f^{(k)}(x_0)$ est la k -ième dérivée de f en x_0 (supposée exister) et $\frac{f^{(k)}(x_0)}{k!}$ les **coefficients** du polynôme.

DÉFINITION 5.4 (SÉRIE DE TAYLOR).

Pour $f \in C^\infty$ (indéfiniment continûment différentiable),

$$T_\infty(x) = \sum_{k=0}^{\infty} \frac{f^{(k)}(x_0)}{k!} (x - x_0)^k$$

Pour $x_0 = 0$, on obtient la **SÉRIE DE MACLAURIN**. Si $f(x) = T_\infty(x)$, alors f est dite **ANALYTIQUE**.

La remarque critique. *« En général, un polynôme de Taylor de degré n est une **APPROXIMATION** d'une fonction, qui n'a pas à être un polynôme. Le polynôme de Taylor est similaire à f dans un **VOISINAGE** de x_0 . Cependant, un polynôme de Taylor de degré n est une **REPRÉSENTATION EXACTE** d'un polynôme f de degré $k \leq n$, puisque toutes les dérivées $f^{(i)}$, $i > k$, s'annulent. »*

Exemple 5.3 — le cas exact. $f(x) = x^4$ et T_6 en $x_0 = 1$. Les coefficients :

$$f(1) = 1, \quad f'(1) = 4, \quad f''(1) = 12, \quad f^{(3)}(1) = 24, \quad f^{(4)}(1) = 24, \quad f^{(5)}(1) = f^{(6)}(1) = 0$$

$$T_6(x) = 1 + 4(x - 1) + \frac{12}{2!}(x - 1)^2 + \frac{24}{3!}(x - 1)^3 + \frac{24}{4!}(x - 1)^4 = x^4$$

T_6 reproduit f **EXACTEMENT** : il n'y a **aucune erreur d'approximation**, car f est un polynôme de degré $4 \leq 6$.

$T_6(x) - x^4$ évalué en $x = 0,3 ; 1,0 ; 2,0 ; -1,5 ; 3,7$ donne **0 partout** (à la précision machine). Le polynôme de Taylor coïncide donc **globalement**, pas seulement au voisinage de 1

Exemple 5.4 — la série de Maclaurin de $\sin + \cos$. Pour $f(x) = \sin(x) + \cos(x) \in C^\infty$ en $x_0 = 0$:

$$f(0) = 1, \quad f'(0) = 1, \quad f''(0) = -1, \quad f^{(3)}(0) = -1, \quad f^{(4)}(0) = f(0) = 1, \dots$$

Le motif. « Les coefficients de notre série de Taylor sont **uniquement** ± 1 (puisque $\sin(0) = 0$), chacun apparaissant **DEUX FOIS** avant de basculer sur l'autre. De plus, $f^{(k+4)}(0) = f^{(k)}(0)$ » — période 4.

$$T_\infty(x) = 1 + x - \frac{1}{2!}x^2 - \frac{1}{3!}x^3 + \frac{1}{4!}x^4 + \frac{1}{5!}x^5 - \dots$$

En regroupant :

$$T_\infty(x) = \underbrace{\sum_{k=0}^{\infty} \frac{(-1)^k}{(2k)!} x^{2k}}_{=\cos(x)} + \underbrace{\sum_{k=0}^{\infty} \frac{(-1)^k}{(2k+1)!} x^{2k+1}}_{=\sin(x)}$$

$f(0,7) = \sin(0,7) + \cos(0,7) = 1,4090598745$ et $T_{13}(0,7) = 1,4090598745$ — **identiques à 10 décimales** Les coefficients utilisés sont bien $[1, 1, -1, -1, 1, 1, -1, -1, \dots]$, de période 4.

1.3 Les quatre règles de dérivation

Produit : $(f(x)g(x))' = f'(x)g(x) + f(x)g'(x)$

Quotient : $\left(\frac{f(x)}{g(x)}\right)' = \frac{f'(x)g(x) - f(x)g'(x)}{(g(x))^2}$

Somme : $(f(x) + g(x))' = f'(x) + g'(x)$

CHAÎNE : $(g(f(x)))' = (g \circ f)'(x) = g'(f(x)) f'(x)$

où $g \circ f$ dénote la composition $x \mapsto f(x) \mapsto g(f(x))$.

Exemple 5.5. Pour $h(x) = (2x + 1)^4$: on pose $f(x) = 2x + 1$ et $g(f) = f^4$, d'où $f'(x) = 2$ et $g'(f) = 4f^3$:

$$h'(x) = g'(f)f'(x) = 4f^3 \cdot 2 = 4(2x + 1)^3 \cdot 2 = 8(2x + 1)^3$$

x	dérivée numérique	$8(2x + 1)^3$
0,3	32,768	32,768
-1,2	-21,952	-21,952
2,0	1000,0	1000,0

• Concept 2 — Dérivées partielles et gradient (§5.2)

La méthode. « On trouve le gradient de f relativement à x en **faisant varier UNE variable à la fois et en gardant les autres CONSTANTES**. Le gradient est alors la collection de ces dérivées partielles. »

DÉFINITION 5.5 (DÉRIVÉE PARTIELLE).

Pour $f : \mathbb{R}^n \rightarrow \mathbb{R}$ de n variables $x_1, \dots, x_n$:

$$\frac{\partial f}{\partial x_1} = \lim_{h \rightarrow 0} \frac{f(x_1 + h, x_2, \dots, x_n) - f(x)}{h}, \quad \dots, \quad \frac{\partial f}{\partial x_n} = \lim_{h \rightarrow 0} \frac{f(x_1, \dots, x_{n-1}, x_n + h) - f(x)}{h}$$

et on les rassemble dans le **VECTEUR LIGNE**

$$\nabla_x f = \text{grad } f = \frac{df}{dx} = \left[\frac{\partial f(x)}{\partial x_1} \quad \frac{\partial f(x)}{\partial x_2} \quad \dots \quad \frac{\partial f(x)}{\partial x_n} \right] \in \mathbb{R}^{1 \times n}$$

Ce vecteur ligne est le **GRADIENT** de f , ou la **JACOBIENNE**.

La convention du livre — à ne surtout pas oublier. « Il n'est pas rare dans la littérature de définir le vecteur gradient comme un **vecteur COLONNE**, suivant la convention que les vecteurs sont généralement des colonnes. La raison pour laquelle nous définissons le gradient comme un **vecteur LIGNE** est double :

1. on peut généraliser le gradient de façon **cohérente** aux fonctions à valeurs vectorielles $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ (le gradient devient alors une **matrice**) ;
2. on peut appliquer **immédiatement** la règle de la chaîne multivariée **sans se soucier de la dimension** du gradient. »

Exemple 5.6 — dérivées partielles avec la règle de la chaîne. Pour $f(x, y) = (x + 2y^3)^2$:

$$\frac{\partial f}{\partial x} = 2(x + 2y^3) \frac{\partial}{\partial x} (x + 2y^3) = 2(x + 2y^3)$$

$$\frac{\partial f}{\partial y} = 2(x + 2y^3) \frac{\partial}{\partial y} (x + 2y^3) = 12(x + 2y^3)y^2$$

Exemple 5.7 — un gradient complet. Pour $f(x_1, x_2) = x_1^2 x_2 + x_1 x_2^3 \in \mathbb{R}$:

$$\frac{\partial f}{\partial x_1} = 2x_1 x_2 + x_2^3, \quad \frac{\partial f}{\partial x_2} = x_1^2 + 3x_1 x_2^2$$

$$\frac{df}{dx} = \left[2x_1 x_2 + x_2^3 \quad x_1^2 + 3x_1 x_2^2 \right] \in \mathbb{R}^{1 \times 2}$$

Ex. 5.6, en $(x, y) = (0,4; 1,1)$: $\partial f/\partial x$ numérique = 6,124 contre $2(x + 2y^3) = 6,124$; $\partial f/\partial y$ numérique = 44,46024 contre $12(x + 2y^3)y^2 = 44,46024$ (idem en $(-1,0; 0,5)$: -1,5 et -2,25).

Ex. 5.7, en $(1,3; 0,7)$: 2,163 contre $2x_1x_2 + x_2^3 = 2,163$ et 3,601 contre $x_1^2 + 3x_1x_2^2 = 3,601$

2.2 Les règles multivariées

L'avertissement. « Quand on calcule des dérivées **relativement à des vecteurs** $x \in \mathbb{R}^n$, il faut faire attention : nos gradients impliquent maintenant des **vecteurs et des matrices**, et la multiplication matricielle **n'est PAS commutative** — l'ORDRE COMPTE. »

$$\text{Produit : } \frac{\partial}{\partial x} (f(x)g(x)) = \frac{\partial f}{\partial x} g(x) + f(x) \frac{\partial g}{\partial x}$$

$$\text{Somme : } \frac{\partial}{\partial x} (f(x) + g(x)) = \frac{\partial f}{\partial x} + \frac{\partial g}{\partial x}$$

$$\text{CHAÎNE : } \frac{\partial}{\partial x} (g(f(x))) = \frac{\partial g}{\partial f} \frac{\partial f}{\partial x}$$

Le mnémonique des « dimensions voisines ». *« La règle de la chaîne ressemble aux règles de multiplication matricielle où les **dimensions voisines** doivent correspondre. En allant de gauche à droite, ∂f apparaît au « **dénominateur** » du premier facteur et au « **numérateur** » du second. En multipliant les facteurs, la multiplication est définie, les dimensions de ∂f correspondent, et ∂f « s'annule », laissant $\partial g/\partial x$. »*

« Ce n'est **qu'une INTUITION**, pas mathématiquement correct, puisque la dérivée partielle **n'est PAS une fraction**. »

2.3 La règle de la chaîne appliquée

Cas 1 — $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ avec $x_1(t), x_2(t)$:

$$\frac{df}{dt} = \begin{bmatrix} \frac{\partial f}{\partial x_1} & \frac{\partial f}{\partial x_2} \end{bmatrix} \begin{bmatrix} \frac{\partial x_1(t)}{\partial t} \\ \frac{\partial x_2(t)}{\partial t} \end{bmatrix} = \frac{\partial f}{\partial x_1} \frac{\partial x_1}{\partial t} + \frac{\partial f}{\partial x_2} \frac{\partial x_2}{\partial t}$$

Exemple 5.8. Pour $f(x_1, x_2) = x_1^2 + 2x_2$ avec $x_1 = \sin t$, $x_2 = \cos t$:

$$\frac{df}{dt} = 2 \sin t \cdot \cos t + 2 \cdot (-\sin t) = 2 \sin t \cos t - 2 \sin t = \boxed{2 \sin t (\cos t - 1)}$$

t	dérivée numérique	$2 \sin t (\cos t - 1)$
0,4	-0,061481	-0,061481
1,9	-2,504458	-2,504458
-0,8	0,435139	0,435139

Cas 2 — $x_1(s, t)$ et $x_2(s, t)$:

$$\frac{\partial f}{\partial s} = \frac{\partial f}{\partial x_1} \frac{\partial x_1}{\partial s} + \frac{\partial f}{\partial x_2} \frac{\partial x_2}{\partial s}, \quad \frac{\partial f}{\partial t} = \frac{\partial f}{\partial x_1} \frac{\partial x_1}{\partial t} + \frac{\partial f}{\partial x_2} \frac{\partial x_2}{\partial t}$$

et, sous forme de **produit matriciel** :

$$\frac{df}{d(s, t)} = \underbrace{\frac{\partial f}{\partial x}}_{1 \times 2} \underbrace{\frac{\partial x}{\partial (s, t)}}_{2 \times 2}$$

Le contrôle de sécurité recommandé. « Cette écriture compacte n'est correcte que si l'on est attentif à la **DÉFINITION du gradient**. » Vérifier systématiquement les **dimensions** de chaque facteur.

● Concept 3 — Gradients de fonctions à valeurs vectorielles (§5.3)

3.1 La jacobienne

Pour $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ (un **champ de vecteurs**), $f(x) = [f_1(x), \dots, f_m(x)]^\top$: chaque $f_i : \mathbb{R}^n \rightarrow \mathbb{R}$ se dérive **exactement comme au §5.2**.

La dérivée partielle relativement à x_i est un **vecteur COLONNE** :

$$\frac{\partial f}{\partial x_i} = \begin{bmatrix} \partial f_1 / \partial x_i \\ \vdots \\ \partial f_m / \partial x_i \end{bmatrix} \in \mathbb{R}^m$$

DÉFINITION 5.6 (JACOBienne).

La collection de **toutes** les dérivées partielles du **premier ordre** d'une fonction à valeurs vectorielles $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ est la **JACOBIENNE**. C'est une matrice $m \times n$:

$$J = \nabla_x f = \frac{df(x)}{dx} = \begin{bmatrix} \frac{\partial f_1(x)}{\partial x_1} & \dots & \frac{\partial f_1(x)}{\partial x_n} \\ \vdots & & \vdots \\ \frac{\partial f_m(x)}{\partial x_1} & \dots & \frac{\partial f_m(x)}{\partial x_n} \end{bmatrix}, \quad J(i, j) = \frac{\partial f_i}{\partial x_j}$$

La convention de disposition. « Dans ce livre, nous utilisons la **DISPOSITION AU NUMÉRATEUR** : la dérivée df/dx de $f \in \mathbb{R}^m$ relativement à $x \in \mathbb{R}^n$ est une matrice $m \times n$, où les éléments de f définissent les **LIGNES** et les éléments de x définissent les **COLONNES**. Il existe aussi la **disposition au DÉNOMINATEUR**, qui en est la **TRANSPOSÉE**. »

3.2 Le tableau des dimensions (figure 5.6) — à mémoriser

Fonction	Gradient	Taille
$f : \mathbb{R} \rightarrow \mathbb{R}$	Un scalaire	1×1
$f : \mathbb{R}^D \rightarrow \mathbb{R}$	Un vecteur LIGNE	$1 \times D$
$f : \mathbb{R} \rightarrow \mathbb{R}^E$	Un vecteur COLONNE	$E \times 1$
$f : \mathbb{R}^D \rightarrow \mathbb{R}^E$	Une MATRICE	$E \times D$

Le réflexe méthodologique du livre. Dans chaque exemple, il **commence par déterminer la DIMENSION du gradient cherché**, avant tout calcul. C'est le meilleur garde-fou.

3.3 Le déterminant jacobien comme facteur d'échelle

Le problème. Les vecteurs $b_1 = [1, 0]^\top$, $b_2 = [0, 1]^\top$ engendrent le carré unité d'aire $\det \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = 1$. Les vecteurs $c_1 = [-2, 1]^\top$, $c_2 = [1, 1]^\top$ engendrent un parallélogramme d'aire

$$\left| \det \begin{bmatrix} -2 & 1 \\ 1 & 1 \end{bmatrix} \right| = |-3| = 3$$

Approche 1 — algèbre linéaire. C'est un **changement de base** de (b_1, b_2) vers (c_1, c_2) , de matrice

$$J = \begin{bmatrix} -2 & 1 \\ 1 & 1 \end{bmatrix} \quad \text{telle que} \quad Jb_1 = c_1, Jb_2 = c_2$$

et $|\det(J)| = 3$.

Approche 2 — dérivées partielles (celle qui **se généralise au non linéaire**). Avec $y_1 = -2x_1 + x_2$ et $y_2 = x_1 + x_2$:

$$\frac{\partial y_1}{\partial x_1} = -2, \quad \frac{\partial y_1}{\partial x_2} = 1, \quad \frac{\partial y_2}{\partial x_1} = 1, \quad \frac{\partial y_2}{\partial x_2} = 1 \quad \implies \quad J = \begin{bmatrix} -2 & 1 \\ 1 & 1 \end{bmatrix}$$

Le résultat général. « La jacobienne représente la transformation de coordonnées cherchée. Elle est **EXACTE** si la transformation est **LINÉAIRE**. Si la transformation est **NON LINÉAIRE**, la jacobienne **approche localement** cette transformation par une transformation linéaire. »

$|\det(J)| = \text{le facteur par lequel les AIRES ou VOLUMES sont mis à l'échelle}$

Où cela resservira. « Le déterminant jacobien et les transformations de variables deviendront pertinents au §6.7, quand on transformera des variables aléatoires et des lois de probabilité. Ces transformations sont extrêmement pertinentes en apprentissage automatique dans le contexte de l'entraînement de réseaux profonds par la **REPARAMÉTRISATION**, aussi appelée analyse de perturbation infinitésimale. »

3.4 Trois exemples fondateurs

Exemple 5.9 — le gradient de $f(x) = Ax$.

Étape 1 — la dimension. $f : \mathbb{R}^N \rightarrow \mathbb{R}^M$, donc $df/dx \in \mathbb{R}^{M \times N}$.

Étape 2 — les partielles. $f_i(x) = \sum_{j=1}^N A_{ij}x_j$ donne $\frac{\partial f_i}{\partial x_j} = A_{ij}$.

Étape 3 — le résultat.

$\frac{df}{dx} = A \in \mathbb{R}^{M \times N}$

Le résultat est **la matrice A elle-même** — l'analogue matriciel de $(ax)' = a$.

Exemple 5.10 — chaîne avec composition. Pour $h = f \circ g$ avec

$$f : \mathbb{R}^2 \rightarrow \mathbb{R}, f(x) = \exp(x_1 x_2^2) \quad g : \mathbb{R} \rightarrow \mathbb{R}^2, x = g(t) = \begin{bmatrix} t \cos t \\ t \sin t \end{bmatrix}$$

Les dimensions d'abord : $\frac{\partial f}{\partial x} \in \mathbb{R}^{1 \times 2}$ et $\frac{\partial g}{\partial t} \in \mathbb{R}^{2 \times 1}$.

$$\frac{dh}{dt} = \frac{\partial f}{\partial x} \frac{\partial x}{\partial t} = \begin{bmatrix} \exp(x_1 x_2^2) x_2^2 & 2 \exp(x_1 x_2^2) x_1 x_2 \end{bmatrix} \begin{bmatrix} \cos t - t \sin t \\ \sin t + t \cos t \end{bmatrix}$$

$$\boxed{\frac{dh}{dt} = \exp(x_1 x_2^2) \left[x_2^2 (\cos t - t \sin t) + 2 x_1 x_2 (\sin t + t \cos t) \right]}$$

avec $x_1 = t \cos t$ et $x_2 = t \sin t$.

t	dérivée numérique de h	formule (5.74c)
0,6	0,435521	0,435521
1,4	-2,358059	-2,358059

Exemple 5.11 — le gradient d'une perte des moindres carrés. Le modèle linéaire

$$y = \Phi \theta, \quad \theta \in \mathbb{R}^D, \quad \Phi \in \mathbb{R}^{N \times D}, \quad y \in \mathbb{R}^N$$

avec

$$L(e) := \|e\|^2, \quad e(\theta) := y - \Phi \theta$$

Étape 1 — la dimension. $\frac{\partial L}{\partial \theta} \in \mathbb{R}^{1 \times D}$.

Étape 2 — la chaîne. $\frac{\partial L}{\partial \theta} = \frac{\partial L}{\partial e} \frac{\partial e}{\partial \theta}$, dont le d -ième élément est $\sum_{n=1}^N \frac{\partial L}{\partial e}[n] \frac{\partial e}{\partial \theta}[n, d]$.

Étape 3 — les deux facteurs. Comme $\|e\|^2 = e^\top e$:

$$\frac{\partial L}{\partial e} = 2e^\top \in \mathbb{R}^{1 \times N}, \quad \frac{\partial e}{\partial \theta} = -\Phi \in \mathbb{R}^{N \times D}$$

Étape 4 — le résultat.

$$\boxed{\frac{\partial L}{\partial \theta} = -2e^\top \Phi = -2 \underbrace{(y^\top - \theta^\top \Phi^\top)}_{1 \times N} \underbrace{\Phi}_{N \times D} \in \mathbb{R}^{1 \times D}}$$

La remarque du livre. « On aurait obtenu le même résultat *sans la règle de la chaîne*, en regardant directement $L_2(\theta) := \|y - \Phi\theta\|^2 = (y - \Phi\theta)^\top (y - \Phi\theta)$. Cette approche reste praticable pour des fonctions simples comme L_2 , mais devient **IMPRATICABLE pour des compositions PROFONDES**. »

● Concept 4 — Gradients de matrices et identités (§5.4-5.5)

4.1 Le problème du tenseur

Le gradient d'une matrice $m \times n$ relativement à une matrice $p \times q$ est une jacobienne de taille $(m \times n) \times (p \times q)$ — un **tenseur à QUATRE dimensions**, d'entrées $J_{ijkl} = \partial A_{ij} / \partial B_{kl}$.

L'astuce de l'aplatissement. « Puisque les matrices représentent des applications linéaires, on peut exploiter le fait qu'il existe un **ISOMORPHISME d'espaces vectoriels** entre $\mathbb{R}^{m \times n}$ et $\mathbb{R}^{mn}$. On peut donc **remodeler** nos matrices en vecteurs de longueurs mn et pq , et le gradient devient une jacobienne de taille $mn \times pq$. »

POURQUOI C'EST PRÉFÉRABLE.

« En pratique, il est souvent souhaitable de remodeler la matrice en vecteur : la **règle de la chaîne se réduit à une simple MULTIPLICATION MATRICIELLE**, alors qu'avec une jacobienne-tenseur, il faut faire davantage attention **aux dimensions sur lesquelles sommer**. »

Exemple 5.12 — $f = Ax$, gradient relativement à A .

Étape 1 — la dimension. $\frac{df}{dA} \in \mathbb{R}^{M \times (M \times N)}$.

Étape 2 — expliciter. $f_i = \sum_{j=1}^N A_{ij}x_j$, donc

$$\frac{\partial f_i}{\partial A_{iq}} = x_q, \quad \frac{\partial f_i}{\partial A_{kq}} = 0 \text{ pour } k \neq i$$

Étape 3 — le résultat. $\frac{\partial f_i}{\partial A_{i,:}} = x^\top \in \mathbb{R}^{1 \times 1 \times N}$ et $0^\top$ pour les autres lignes.

Exemple 5.13 — $f(R) = R^\top R =: K$, gradient relativement à R .

Étape 1 — la dimension. $\frac{dK}{dR} \in \mathbb{R}^{(N \times N) \times (M \times N)}$, un **tenseur**, avec $\frac{dK_{pq}}{dR} \in \mathbb{R}^{1 \times M \times N}$.

Étape 2 — expliciter. En notant r_i la i -ème colonne de R , chaque entrée de K est un produit scalaire de deux colonnes :

$$K_{pq} = r_p^\top r_q = \sum_{m=1}^M R_{mp} R_{mq}$$

Étape 3 — la partielle, par cas.

$$\frac{\partial K_{pq}}{\partial R_{ij}} = \partial_{pqij} = \begin{cases} R_{iq} & \text{si } j = p, p \neq q \\ R_{ip} & \text{si } j = q, p \neq q \\ 2R_{iq} & \text{si } j = p, p = q \\ 0 & \text{sinon} \end{cases}$$

Le facteur **2** apparaît **seulement sur la diagonale** ($p = q$), où R_{mp} et R_{mq} sont **la même variable**.

4.2 Les dix identités à connaître

Avec $\text{tr}(\cdot)$ la trace, $\det(\cdot)$ le déterminant et $f(X)^{-1}$ l'inverse (supposé exister) :

$$\frac{\partial}{\partial X} f(X)^\top = \left(\frac{\partial f(X)}{\partial X} \right)^\top$$

$$\frac{\partial}{\partial X} \text{tr}(f(X)) = \text{tr} \left(\frac{\partial f(X)}{\partial X} \right)$$

$$\frac{\partial}{\partial X} \det(f(X)) = \det(f(X)) \text{tr} \left(f(X)^{-1} \frac{\partial f(X)}{\partial X} \right)$$

$$\frac{\partial}{\partial X} f(X)^{-1} = -f(X)^{-1} \frac{\partial f(X)}{\partial X} f(X)^{-1}$$

$$\frac{\partial a^\top X^{-1} b}{\partial X} = -(X^{-1})^\top a b^\top (X^{-1})^\top$$

$$\frac{\partial x^\top a}{\partial x} = a^\top \qquad \frac{\partial a^\top x}{\partial x} = a^\top$$

$$\frac{\partial a^\top X b}{\partial X} = ab^\top$$

$$\frac{\partial x^\top B x}{\partial x} = x^\top (B + B^\top)$$

$$\frac{\partial}{\partial s} (x - As)^\top W (x - As) = -2(x - As)^\top W A \quad \text{pour } W \text{ SYMÉTRIQUE}$$

Deux pièges dans cette liste. (i) $\frac{\partial x^\top B x}{\partial x} = x^\top (B + B^\top)$, pas $2x^\top B$ — sauf si B est **symétrique**. (ii) La dernière identité exige explicitement **W symétrique** ; c'est elle qui donne le gradient des moindres carrés pondérés.

La remarque sur les tenseurs. « Ce livre ne couvre que les traces et transposées **de matrices**. Mais les dérivées peuvent être des tenseurs de dimension supérieure, où la trace et la transposée usuelles **ne sont pas définies**. Dans ces cas, la trace d'un tenseur $D \times D \times E \times F$ serait une matrice de dimension $E \times F$ — un cas particulier de **CONTRACTION TENSORIELLE**. De même, « transposer » un tenseur veut dire **échanger les deux premières dimensions**. »

● Concept 5 — Rétropropagation et différentiation automatique (§5.6)

5.1 Le problème

Considérons

$$f(x) = \sqrt{x^2 + \exp(x^2)} + \cos(x^2 + \exp(x^2))$$

Par la règle de la chaîne :

$$\begin{aligned} \frac{df}{dx} &= \frac{2x + 2x \exp(x^2)}{2\sqrt{x^2 + \exp(x^2)}} - \sin(x^2 + \exp(x^2)) (2x + 2x \exp(x^2)) \\ &= 2x \left(\frac{1}{2\sqrt{x^2 + \exp(x^2)}} - \sin(x^2 + \exp(x^2)) \right) (1 + \exp(x^2)) \end{aligned}$$

Le diagnostic. « Écrire le gradient explicitement de cette façon est souvent **impraticable**, car cela donne une expression très longue. En pratique, si l'on n'est pas prudent, l'implémentation du gradient pourrait être **SIGNIFICATIVEMENT PLUS COÛTEUSE** que le calcul de la **fonction elle-même** — ce qui impose une surcharge inutile. »

x	dérivée numérique	formule (5.110)
0,5	-1,360431	-1,360431
1,1	11,713402	11,713402
-0,7	1,874002	1,874002

5.2 Gradients dans un réseau profond

Un réseau profond calcule

$$y = (f_K \circ f_{K-1} \circ \dots \circ f_1)(x) = f_K(f_{K-1}(\dots(f_1(x))\dots))$$

où x sont les entrées (par exemple des images), y les observations (par exemple des étiquettes de classe), et **chaque f_i possède ses propres paramètres**.

Dans un réseau multicouche, $f_i(x_{i-1}) = \sigma(A_{i-1}x_{i-1} + b_{i-1})$ où σ est une **fonction d'activation** : **sigmoïde** $\frac{1}{1+e^{-x}}$, **tanh**, ou **ReLU** (*rectified linear unit*).

$$f_0 := x, \quad f_i := \sigma_i(A_{i-1}f_{i-1} + b_{i-1}), \quad i = 1, \dots, K$$

et on minimise la **perte quadratique**

$$L(\theta) = \|y - f_K(\theta, x)\|^2, \quad \theta = \{A_0, b_0, \dots, A_{K-1}, b_{K-1}\}$$

Les gradients par la règle de la chaîne :

$$\frac{\partial L}{\partial \theta_{K-1}} = \frac{\partial L}{\partial f_K} \frac{\partial f_K}{\partial \theta_{K-1}}$$

$$\frac{\partial L}{\partial \theta_{K-2}} = \frac{\partial L}{\partial f_K} \frac{\partial f_K}{\partial f_{K-1}} \frac{\partial f_{K-1}}{\partial \theta_{K-2}}$$

$$\frac{\partial L}{\partial \theta_{K-3}} = \frac{\partial L}{\partial f_K} \frac{\partial f_K}{\partial f_{K-1}} \frac{\partial f_{K-1}}{\partial f_{K-2}} \frac{\partial f_{K-2}}{\partial \theta_{K-3}}$$

$$\boxed{\frac{\partial L}{\partial \theta_i} = \frac{\partial L}{\partial f_K} \frac{\partial f_K}{\partial f_{K-1}} \dots \frac{\partial f_{i+2}}{\partial f_{i+1}} \frac{\partial f_{i+1}}{\partial \theta_i}}$$

La lecture des deux types de termes. Les termes $\frac{\partial f_{j+1}}{\partial f_j}$ sont les dérivées partielles de la **sortie** d'une couche relativement à ses **ENTRÉES** ; le dernier terme $\frac{\partial f_{i+1}}{\partial \theta_i}$ est la dérivée de la sortie d'une couche relativement à ses **PARAMÈTRES**.

L'idée centrale de la rétropropagation. « En supposant qu'on a **déjà calculé** les dérivées partielles $\partial L / \partial \theta_{i+1}$, **L'ESSENTIEL DU CALCUL PEUT ÊTRE RÉUTILISÉ** pour calculer $\partial L / \partial \theta_i$. »

La chronologie. Kelley (1960), Bryson (1961), Dreyfus (1962), Rumelhart et al. (1986).

5.3 La différentiation automatique

Le statut. « Il se trouve que la **rétropropagation est un CAS PARTICULIER** d'une technique générale de l'analyse numérique appelée **DIFFÉRENTIATION AUTOMATIQUE**. »

CE QUE C'EST.

« Un ensemble de techniques pour évaluer **NUMÉRIQUEMENT (par opposition à SYMBOLIQUEMENT) le gradient EXACT (à la précision machine près)** d'une fonction, en travaillant avec des **variables intermédiaires** et en appliquant la règle de la chaîne. » Elle applique une série d'opérations arithmétiques élémentaires (addition, multiplication) et de fonctions élémentaires (**sin, cos, exp, log**).

Trois choses différentes, à ne pas confondre :

différentiation AUTOMATIQUE $\neq$ différentiation SYMBOLIQUE $\neq$ approximation NUMÉRIQUE (différences finies)

Les deux modes. Pour un graphe $x \rightarrow a \rightarrow b \rightarrow y$, la chaîne donne $\frac{dy}{dx} = \frac{dy}{db} \frac{db}{da} \frac{da}{dx}$. Par **associativité** du produit matriciel, on peut choisir l'ordre :

$$\text{MODE INVERSE : } \frac{dy}{dx} = \left(\frac{dy}{db} \frac{db}{da} \right) \frac{da}{dx}$$

$$\text{MODE DIRECT : } \frac{dy}{dx} = \frac{dy}{db} \left(\frac{db}{da} \frac{da}{dx} \right)$$

Mode	Sens	Quand l'utiliser
INVERSE (reverse)	Les gradients se propagent EN ARRIÈRE , à rebours du flot des données	C'est la RÉTROPROPAGATION. Significativement moins cher quand la dimension d' entrée est BEAUCOUP PLUS GRANDE que celle de la sortie — le cas des réseaux de neurones
DIRECT (forward)	Les gradients suivent les données, de gauche à droite	Moins cher dans le cas inverse (peu d'entrées, beaucoup de sorties)

Référence donnée : Baydin et al. (2018) pour un panorama de la différentiation automatique en apprentissage automatique.

5.4 Exemple 5.14 — le graphe de calcul en pratique

Pour la fonction $f(x) = \sqrt{x^2 + \exp(x^2)} + \cos(x^2 + \exp(x^2))$, on introduit des **variables intermédiaires** :

$$a = x^2, \quad b = \exp(a), \quad c = a + b, \quad d = \sqrt{c}, \quad e = \cos(c), \quad f = d + e$$

« C'est le même processus de pensée qui se produit quand on applique la règle de la chaîne. Et cet ensemble d'équations demande **MOINS d'opérations** qu'une implémentation directe. »

Les dérivées élémentaires (chacune **triviale**) :

$$\frac{\partial a}{\partial x} = 2x, \quad \frac{\partial b}{\partial a} = \exp(a), \quad \frac{\partial c}{\partial a} = 1 = \frac{\partial c}{\partial b}, \quad \frac{\partial d}{\partial c} = \frac{1}{2\sqrt{c}}, \quad \frac{\partial e}{\partial c} = -\sin(c), \quad \frac{\partial f}{\partial d} = 1 = \frac{\partial f}{\partial e}$$

La remontée — en travaillant à rebours depuis la sortie :

$$\frac{\partial f}{\partial c} = \frac{\partial f}{\partial d} \frac{\partial d}{\partial c} + \frac{\partial f}{\partial e} \frac{\partial e}{\partial c} = 1 \cdot \frac{1}{2\sqrt{c}} + 1 \cdot (-\sin c)$$

$$\frac{\partial f}{\partial b} = \frac{\partial f}{\partial c} \frac{\partial c}{\partial b} = \frac{\partial f}{\partial c} \cdot 1$$

$$\frac{\partial f}{\partial a} = \frac{\partial f}{\partial b} \frac{\partial b}{\partial a} + \frac{\partial f}{\partial c} \frac{\partial c}{\partial a} = \frac{\partial f}{\partial b} \exp(a) + \frac{\partial f}{\partial c} \cdot 1$$

$$\frac{\partial f}{\partial x} = \frac{\partial f}{\partial a} \frac{\partial a}{\partial x} = \frac{\partial f}{\partial a} \cdot 2x$$

L'observation contre-intuitive du livre. « En pensant à chacune de ces dérivées comme à une *variable*, on observe que **le calcul requis pour obtenir la dérivée est de COMPLEXITÉ SIMILAIRE au calcul de la fonction elle-même**. C'est assez contre-intuitif, puisque l'expression mathématique de la dérivée est **significativement plus compliquée** que celle de la fonction. »

Noter les **deux chemins** dans $\partial f / \partial c$ et $\partial f / \partial a$: le nœud c est utilisé **deux fois** (d et e), donc les contributions **s'additionnent**.

5.5 Le formalisme général

Soient $x_1, \dots, x_d$ les variables d'**entrée**, $x_{d+1}, \dots, x_{D-1}$ les variables **intermédiaires**, et x_D la variable de **sortie**. Le graphe de calcul s'écrit

$$\text{Pour } i = d + 1, \dots, D : \quad x_i = g_i(x_{\text{Pa}(x_i)})$$

où les g_i sont des fonctions élémentaires et $x_{\text{Pa}(x_i)}$ les **nœuds PARENTS** de x_i . Avec $f = x_D$, on a $\frac{\partial f}{\partial x_D} = 1$, puis, **à rebours** :

$$\frac{\partial f}{\partial x_i} = \sum_{x_j: x_i \in \text{Pa}(x_j)} \frac{\partial f}{\partial x_j} \frac{\partial x_j}{\partial x_i}$$

- L'équation $x_i = g_i(x_{\text{Pa}(x_i)})$ est la **PROPAGATION AVANT** de la fonction.
- L'équation de la somme est la **RÉTROPROPAGATION** du gradient à travers le graphe.

Les limites. « L'approche fonctionne dès qu'on a une fonction exprimable comme un graphe de calcul dont les fonctions élémentaires sont différentiables. En fait, ce peut même ne pas être une fonction mathématique mais un **PROGRAMME INFORMATIQUE**. Cependant, tous les programmes ne peuvent pas être automatiquement différentiés — par exemple si l'on ne trouve pas de fonctions élémentaires différentiables. Les structures de programmation comme les **boucles for** et les **instructions if** demandent aussi plus de soin. »

● Concept 6 — Dérivées d'ordre supérieur et hessienne (§5.7)

La notation, pour $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ de variables x, y :

Notation	Signification
$\frac{\partial^2 f}{\partial x^2}$	Dérivée partielle seconde de f relativement à x
$\frac{\partial^n f}{\partial x^n}$	Dérivée partielle n-ième relativement à x
$\frac{\partial^2 f}{\partial y \partial x} = \frac{\partial}{\partial y} \left(\frac{\partial f}{\partial x} \right)$	D'abord relativement à x , PUIS relativement à y
$\frac{\partial^2 f}{\partial x \partial y}$	D'abord y , puis x

Le théorème de symétrie. Si $f(x, y)$ est **deux fois (continûment) différentiable**, alors

$$\boxed{\frac{\partial^2 f}{\partial x \partial y} = \frac{\partial^2 f}{\partial y \partial x}}$$

« l'ORDRE de différentiation N'IMPORTE PAS », et la matrice hessienne est **SYMÉTRIQUE**.

La hessienne. C'est la **collection de toutes les dérivées partielles du SECOND ordre** :

$$H = \begin{bmatrix} \frac{\partial^2 f}{\partial x^2} & \frac{\partial^2 f}{\partial x \partial y} \\ \frac{\partial^2 f}{\partial x \partial y} & \frac{\partial^2 f}{\partial y^2} \end{bmatrix}$$

notée $\nabla_{x,y}^2 f(x,y)$. En général, pour $x \in \mathbb{R}^n$ et $f : \mathbb{R}^n \rightarrow \mathbb{R}$, H est une matrice $n \times n$.

Ce qu'elle mesure. « La hessienne mesure la **COURBURE** de la fonction localement autour de (x,y) .
» Elle est requise par la **méthode de Newton** pour l'optimisation (Nocedal & Wright 2006).

Cas vectoriel. « Si $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ est un champ de vecteurs, la hessienne est un **TENSEUR** $(m \times n \times n)$. »

● Concept 7 — Linéarisation et série de Taylor multivariée (§5.8)

7.1 La linéarisation

$$f(x) \approx f(x_0) + (\nabla_x f)(x_0)(x - x_0)$$

C'est une **approximation LOCALEMENT LINÉAIRE** de f autour de x_0 — le **Taylor d'ordre 1**. Elle n'est bonne **qu'au voisinage** de x_0 .

7.2 La série de Taylor multivariée

DÉFINITION 5.7 (SÉRIE DE TAYLOR MULTIVARIÉE).

Pour $f : \mathbb{R}^D \rightarrow \mathbb{R}$ lisse en x_0 , en posant $\delta := x - x_0$:

$$f(x) = \sum_{k=0}^{\infty} \frac{D_x^k f(x_0)}{k!} \delta^k$$

où $D_x^k f(x_0)$ est la **k -ième dérivée TOTALE** de f relativement à x , évaluée en x_0 .

DÉFINITION 5.8 (POLYNÔME DE TAYLOR).

Le polynôme de Taylor de degré n contient les $n + 1$ **premières** composantes :

$$T_n(x) = \sum_{k=0}^n \frac{D_x^k f(x_0)}{k!} \delta^k$$

La notation δ^k est « légèrement relâchée ». « δ^k n'est pas défini pour des vecteurs $x \in \mathbb{R}^D$, $D > 1$, et $k > 1$. » En réalité, $D_x^k f$ et δ^k sont des **TENSEURS d'ordre k** . Le tenseur $\delta^k \in \mathbb{R}^{D \times D \times \dots \times D}$ (k fois) est le **produit EXTÉRIEUR k -uple**, noté $\otimes$:

$$\delta^2 := \delta \otimes \delta = \delta \delta^\top, \quad \delta^2[i, j] = \delta[i] \delta[j]$$

$$\delta^3 := \delta \otimes \delta \otimes \delta, \quad \delta^3[i, j, k] = \delta[i] \delta[j] \delta[k]$$

Les quatre premiers termes, explicitement :

$$k = 0 : \quad D_x^0 f(x_0) \delta^0 = f(x_0) \in \mathbb{R}$$

$$k = 1 : \quad D_x^1 f(x_0) \delta^1 = \underbrace{\nabla_x f(x_0)}_{1 \times D} \underbrace{\delta}_{D \times 1} = \sum_{i=1}^D \nabla_x f(x_0)[i] \delta[i] \in \mathbb{R}$$

$$k = 2 : \quad D_x^2 f(x_0) \delta^2 = \text{tr} \left(\underbrace{H(x_0)}_{D \times D} \underbrace{\delta}_{D \times 1} \underbrace{\delta^\top}_{1 \times D} \right) = \delta^\top H(x_0) \delta = \sum_{i=1}^D \sum_{j=1}^D H[i, j] \delta[i] \delta[j]$$

$$k = 3 : \quad D_x^3 f(x_0) \delta^3 = \sum_{i=1}^D \sum_{j=1}^D \sum_{k=1}^D D_x^3 f(x_0)[i, j, k] \delta[i] \delta[j] \delta[k] \in \mathbb{R}$$

Le terme $D_x^k f(x_0) \delta^k$ contient **exactement des polynômes d'ordre k** .

Le livre note aussi les implémentations `np.einsum('i,i',Df1,d)`, `np.einsum('ij,i,j',Df2,d,d)`,
`np.einsum('ijk,i,j,k',Df3,d,d,d)`.

7.3 Exemple 5.15 — le développement complet en deux variables

$$f(x, y) = x^2 + 2xy + y^3 \quad \text{autour de } (x_0, y_0) = (1, 2)$$

La prédiction avant le calcul. « La fonction est un polynôme de degré 3. On cherche un développement de Taylor, qui est lui-même une combinaison linéaire de polynômes. On **ne s'attend donc PAS** à ce que le développement contienne des termes d'ordre 4 ou plus. Il devrait suffire de déterminer les **QUATRE PREMIERS termes** pour une représentation **EXACTE**. »

Ordre 0 : $f(1, 2) = 1 + 4 + 8 = 13$

Ordre 1 :

$$\frac{\partial f}{\partial x} = 2x + 2y \Rightarrow \frac{\partial f}{\partial x}(1, 2) = 6, \quad \frac{\partial f}{\partial y} = 2x + 3y^2 \Rightarrow \frac{\partial f}{\partial y}(1, 2) = 14$$

$$\frac{D_{x,y}^1 f(1, 2)}{1!} \delta = [6 \quad 14] \begin{bmatrix} x-1 \\ y-2 \end{bmatrix} = 6(x-1) + 14(y-2)$$

Ordre 2 :

$$\frac{\partial^2 f}{\partial x^2} = 2, \quad \frac{\partial^2 f}{\partial y^2} = 6y, \quad \frac{\partial^2 f}{\partial y \partial x} = \frac{\partial^2 f}{\partial x \partial y} = 2$$

$$H = \begin{bmatrix} 2 & 2 \\ 2 & 6y \end{bmatrix} \Rightarrow H(1, 2) = \begin{bmatrix} 2 & 2 \\ 2 & 12 \end{bmatrix}$$

$$\frac{D_{x,y}^2 f(1,2)}{2!} \delta^2 = \frac{1}{2} \delta^\top H(1,2) \delta = (x-1)^2 + 2(x-1)(y-2) + 6(y-2)^2$$

Ordre 3 : la seule dérivée troisième non nulle est $\frac{\partial^3 f}{\partial y^3} = 6$, donc

$$D_{x,y}^3 f[:, :, 1] = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}, \quad D_{x,y}^3 f[:, :, 2] = \begin{bmatrix} 0 & 0 \\ 0 & 6 \end{bmatrix}$$

$$\frac{D_{x,y}^3 f(1,2)}{3!} \delta^3 = \frac{6}{6} (y-2)^3 = (y-2)^3$$

Le résultat final :

$$f(x,y) = 13 + 6(x-1) + 14(y-2) + (x-1)^2 + 2(x-1)(y-2) + 6(y-2)^2 + (y-2)^3$$

(x,y)	$f(x,y)$	$T_3(x,y)$	écart
(0,3 ; 1,4)	3,674000	3,674000	0
(2,5 ; -1,0)	0,250000	0,250000	0
(1,0 ; 2,0)	13,000000	13,000000	0
(-3,0 ; 4,5)	73,125000	73,125000	0

L'écart est **nul même TRÈS LOIN** de $(1,2)$: c'est la marque d'un développement de Taylor d'un **polynôme** de degré $\leq n$ — il est **exact globalement**, pas seulement localement.

Contrôles intermédiaires : $f(1,2) = 13$; $f_x(1,2) = 2 \cdot 1 + 2 \cdot 2 = 6$; $f_y(1,2) = 2 \cdot 1 + 3 \cdot 4 = 14$; $H(1,2) = \begin{bmatrix} 2 & 2 \\ 2 & 12 \end{bmatrix}$; $\partial^3 f / \partial y^3 = 6$

Comment reconnaître le type d'exercice

L'énoncé dit...	Le type	La méthode
« Calculer $f'(x)$ »	§5.1.2	Produit / quotient / somme / chaîne
« Développement de Taylor de degré n en x_0 »	Déf. 5.3	Calculer $f^{(k)}(x_0)$ pour $k \leq n$, puis $\sum f^{(k)}(x_0)(x - x_0)^k / k!$
« Série de Maclaurin »	Déf. 5.4	Taylor en $x_0 = 0$; chercher un motif périodique dans les dérivées
« Calculer le gradient de $f : \mathbb{R}^n \rightarrow \mathbb{R}$ »	Déf. 5.5	Une partielle par variable, rangées en vecteur LIGNE $1 \times n$
« Calculer la jacobienne »	Déf. 5.6	$J(i, j) = \partial f_i / \partial x_j$, taille $m \times n$ (m = sorties, n = entrées)
« f dépend de $x(t)$ »	Chaîne multivariée	$\frac{df}{dt} = \frac{\partial f}{\partial x} \frac{\partial x}{\partial t}$; vérifier les dimensions
« De combien l'aire est-elle multipliée ? »	Déterminant jacobien	$ \det J $
« Gradient de Ax relativement à x »	Ex. 5.9	$\frac{d(Ax)}{dx} = A$
« Gradient d'une perte des moindres carrés »	Ex. 5.11	Poser $L(e) = \ e\ ^2$, $e(\theta) = y - \Phi\theta$, puis $\frac{\partial L}{\partial \theta} = -2e^\top \Phi$
« Dérivée relativement à une MATRICE »	§5.4	Déterminer la taille du tenseur ; envisager d' aplatir
« $\frac{\partial}{\partial X} \text{tr} / \det / X^{-1}$ »	§5.5	Chercher dans la table des dix identités
« Rétropropager le gradient »	§5.6	Graphe de calcul, variables intermédiaires, remontée depuis la sortie
« Mode direct ou inverse ? »	§5.6.2	Entrée $\gg$ sortie $\Rightarrow$ INVERSE (rétropropagation)
« Calculer la hessienne »	§5.7	Toutes les partielles secondes ; elle est symétrique si f est deux fois C^1
« Linéariser f autour de x_0 »	§5.8	$f(x_0) + (\nabla_x f)(x_0)(x - x_0)$

L'énoncé dit...	Le type	La méthode
« Développement de Taylor multivarié »	Déf. 5.7	$k = 0 : f(x_0) ; k = 1 : \nabla f \cdot \delta ; k = 2 : \frac{1}{2} \delta^T H \delta ;$ $k = 3 : \text{tenseur}$

Comment résoudre : les cinq méthodes pas-à-pas

Méthode A — Tout calcul de gradient (le protocole du livre).

1. **DÉTERMINER LA DIMENSION du résultat AVANT tout calcul** — $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ donne $m \times n$.
2. Décomposer en fonctions élémentaires.
3. Calculer les partielles **une variable à la fois**.
4. Ranger dans la jacobienne : **lignes = sorties, colonnes = entrées**.
5. Contrôle : la dimension obtenue correspond-elle à l'étape 1 ?

Méthode B — Règle de la chaîne multivariée.

1. Identifier la composition $x \rightarrow f \rightarrow g$.
2. Écrire les **dimensions** de $\partial g / \partial f$ et $\partial f / \partial x$.
3. Vérifier que les **dimensions voisines s'annulent**.
4. Multiplier **dans le bon ordre** : $\frac{\partial g}{\partial f} \frac{\partial f}{\partial x}$ — jamais l'inverse.
5. Substituer les variables intermédiaires par leurs expressions.
6. Contrôle numérique par **différences finies centrées** sur deux ou trois points.

Méthode C — Taylor univarié.

1. Calculer $f^{(k)}(x_0)$ pour $k = 0, \dots, n$.
2. Chercher un **motif** ou une **périodicité** (Ex. 5.4 : période 4).
3. Assembler $\sum_k f^{(k)}(x_0)(x - x_0)^k / k!$.
4. Si f est un **polynôme de degré $\leq n$** , le développement est **EXACT** : le vérifier en développant.

Méthode D — Taylor multivarié.

1. Poser $\delta = x - x_0$.
2. $k = 0 : f(x_0)$.
3. $k = 1 : \nabla_x f(x_0) \delta$ — un produit $(1 \times D)(D \times 1)$.
4. $k = 2 : \frac{1}{2} \delta^T H(x_0) \delta$ — développer explicitement en $\sum_{i,j} H[i,j] \delta_i \delta_j / 2$.

5. $k = 3$: identifier les **rares** dérivées troisièmes non nulles.
6. Contrôle : si f est un polynôme de degré d , s'arrêter à $n = d$ et vérifier l'**égalité exacte**.

Méthode E — Rétropropagation.

1. Construire le **graphe de calcul** avec des variables intermédiaires.
2. **Propagation avant** : évaluer chaque nœud.
3. Initialiser $\partial f / \partial x_D = 1$ à la sortie.
4. Remonter : pour chaque nœud, **SOMMER sur tous ses enfants** $\sum_j \frac{\partial f}{\partial x_j} \frac{\partial x_j}{\partial x_i}$.
5. Un nœud utilisé **plusieurs fois** reçoit **plusieurs contributions additives**.
6. Contrôle : comparer à une **différence finie** sur un point.

● Common mistakes

Erreur	Correction
Écrire le gradient en colonne	Dans ce livre, le gradient est un VECTEUR LIGNE $1 \times n$ — c'est ce qui rend la chaîne automatique
Confondre disposition au numérateur et au dénominateur	Elles sont TRANSPOSÉES l'une de l'autre ; le livre utilise la disposition au numérateur
Inverser lignes et colonnes de la jacobienne	$J(i, j) = \partial f_i / \partial x_j$: lignes = SORTIES, colonnes = ENTRÉES
Multiplier les facteurs de la chaîne dans le mauvais ordre	$\frac{\partial g}{\partial f} \frac{\partial f}{\partial x}$, jamais $\frac{\partial f}{\partial x} \frac{\partial g}{\partial f}$ — la multiplication matricielle n'est pas commutative
Traiter $\partial f / \partial x$ comme une fraction	Le livre le dit : « <i>ce n'est qu'une intuition, pas mathématiquement correct</i> »
Se lancer dans le calcul sans vérifier les dimensions	Toujours déterminer la taille du résultat en PREMIER — c'est le protocole du livre
Croire qu'un polynôme de Taylor est toujours approximatif	Pour un polynôme de degré $k \leq n$, $T_n = f$ EXACTEMENT (Ex. 5.3 et 5.15)
Croire que Taylor converge partout	Le polynôme est similaire à f dans un VOISINAGE de x_0 ; hors voisinage, il peut diverger
Oublier le $k!$ au dénominateur	Il vient de la dérivation répétée de $(x - x_0)^k$
Écrire $\frac{\partial x^\top B x}{\partial x} = 2x^\top B$	C'est $x^\top (B + B^\top)$ — l'égalité avec $2x^\top B$ n'a lieu que si B est symétrique
Oublier la condition « W symétrique »	L'identité $\frac{\partial}{\partial s} (x - As)^\top W (x - As) = -2(x - As)^\top W A$ l'exige explicitement
Écrire $\frac{\partial}{\partial X} f(X)^{-1} = -f(X)^{-2} \frac{\partial f}{\partial X}$	C'est $-f(X)^{-1} \frac{\partial f}{\partial X} f(X)^{-1}$ — l'inverse encadre la dérivée des deux côtés
Oublier le facteur 2 sur la diagonale dans l'exemple 5.13	Quand $p = q$, $\partial K_{pq} / \partial R_{ij} = 2R_{iq}$ car la variable apparaît deux fois
Négliger les chemins multiples en rétropropagation	Un nœud utilisé plusieurs fois reçoit une contribution ADDITIVE par chemin

Erreur	Correction
Croire que la rétropropagation est propre aux réseaux de neurones	C'est un cas particulier de la différentiation automatique en mode inverse
Confondre différentiation automatique et symbolique	Trois choses distinctes : automatique (numérique exacte), symbolique , différences finies (approchée)
Utiliser le mode direct pour un réseau profond	Le mode INVERSE est bien moins cher quand la dimension d'entrée dépasse celle de la sortie
Croire que tout programme est différentiable automatiquement	Les boucles for et instructions if demandent du soin ; certaines fonctions élémentaires ne sont pas différentiables
Croire la hessienne toujours symétrique	Elle l'est si f est deux fois continûment différentiable — l'hypothèse compte
Croire la hessienne toujours une matrice	Pour un champ de vecteurs $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$, c'est un TENSEUR ($m \times n \times n$)
Écrire δ^2 comme δ au carré	C'est le produit EXTÉRIEUR $\delta\delta^T$, une matrice $D \times D$
Oublier le $\frac{1}{2}$ du terme quadratique de Taylor	$\frac{D_x^2 f(x_0)}{2!} \delta^2 = \frac{1}{2} \delta^T H \delta$
Croire $ \det J $ exact pour une transformation non linéaire	La jacobienne approche LOCALEMENT la transformation ; elle n'est exacte que dans le cas linéaire
Croire que calculer un gradient coûte bien plus cher que la fonction	Avec la diff. automatique, le coût est de complexité SIMILAIRE — le livre insiste sur ce point contre-intuitif

Ultimate Review

===== LES NEUF FORMULES À SAVOIR SANS HÉSITER =====

- $df/dx := \lim_{h \rightarrow 0} (f(x+h) - f(x))/h$
- $T_n(x) = \sum_{k=0..n} f^{(k)}(x_0)/k! \cdot (x - x_0)^k$ $x_0 = 0 \rightarrow$ Maclaurin
- CHAÎNE $(g \circ f)' = g'(f) f'$ $\partial/\partial x g(f(x)) = (\partial g/\partial f)(\partial f/\partial x)$
- $\forall x \ f = df/dx \in \mathbb{R}^{(1 \times n)}$ ⚠ VECTEUR LIGNE
- JACOBIENNE $J(i,j) = \partial f_i / \partial x_j \in \mathbb{R}^{(m \times n)}$ lignes = sorties
- $|\det J|$ = facteur d'échelle des volumes
- $d(Ax)/dx = A$ $\partial(x^T B x)/\partial x = x^T (B + B^T)$
 $\partial L / \partial \theta = -2 e^T \Phi$ pour $L = \|y - \Phi \theta\|^2$
- $H = \nabla^2 f$ SYMÉTRIQUE si f deux fois C^1 • mesure la COURBURE

9. TAYLOR MULTIVARIÉ $f(x) = \sum_k \frac{1}{k!} \nabla^k f(x_0) \cdot \delta^k$, $\delta = x - x_0$
 $k=0$: $f(x_0)$ $k=1$: $\nabla f \cdot \delta$ $k=2$: $\frac{1}{2} \delta^T H \delta$

Le tableau des dimensions — la référence de survie :

f	df/dx	Taille
$\mathbb{R} \rightarrow \mathbb{R}$	scalaire	1×1
$\mathbb{R}^D \rightarrow \mathbb{R}$	vecteur ligne	$1 \times D$
$\mathbb{R} \rightarrow \mathbb{R}^E$	vecteur colonne	$E \times 1$
$\mathbb{R}^D \rightarrow \mathbb{R}^E$	matrice	$E \times D$
$\mathbb{R}^{m \times n} \rightarrow \mathbb{R}^{p \times q}$	tenseur	$(p \times q) \times (m \times n)$

Les trois façons de calculer une dérivée :

Méthode	Nature	Coût	Exactitude
Symbolique	Expression fermée	Explosion de la taille de l'expression	Exacte
Différences finies	$\frac{f(x+h) - f(x-h)}{2h}$	Une évaluation par variable	Approchée
Automatique	Graphe + chaîne	Même ordre que f	Exacte à la précision machine

Les deux modes de la différentiation automatique :

	Mode DIRECT	Mode INVERSE (= rétropropagation)
Sens	Avec le flot des données	À rebours
Paranthésage	$\frac{dy}{db} \left(\frac{db}{da} \frac{da}{dx} \right)$	$\left(\frac{dy}{db} \frac{db}{da} \right) \frac{da}{dx}$
Bon quand	Peu d'entrées, beaucoup de sorties	Beaucoup d'entrées, peu de sorties (réseaux de neurones)

Où chaque notion resservira dans le livre :

Notion du ch. 5	Suite
Gradient, descente de gradient	Optimisation continue (ch. 7)
Déterminant jacobien	Transformation de variables aléatoires (§6.7), reparamétrisation
Perte des moindres carrés et son gradient	Régression linéaire (ch. 9)
Hessienne	Méthode de Newton , convexité (ch. 7)
Rétropropagation	Entraînement des réseaux profonds
Taylor multivarié	Approximations locales, Laplace , méthodes du second ordre

Active Recall

Dérivation univariée

1. Écrire le quotient différentiel. Que calcule-t-il géométriquement ?
2. Écrire la définition de la dérivée. Que devient la sécante ?
3. Dans quelle direction pointe la dérivée ?
4. Écrire le polynôme de Taylor de degré n et la série de Taylor.
5. Qu'est-ce que la série de Maclaurin ? Une fonction analytique ?
6. Quand un polynôme de Taylor est-il une représentation **exacte** ?
7. Dans l'exemple 5.3, pourquoi $T_6 = x^4$ exactement ?
8. Quel motif suivent les coefficients dans l'exemple 5.4 ? Quelle est la période ?
9. Donner les quatre règles de dérivation.
10. Détailler l'exemple 5.5.

Dérivées partielles et gradient 11. Comment calcule-t-on une dérivée partielle ? 12. Quelle est la taille du gradient de $f : \mathbb{R}^n \rightarrow \mathbb{R}$? 13. Donner les **deux raisons** pour lesquelles le livre choisit un vecteur ligne. 14. Écrire la règle de la chaîne multivariée. 15. Expliquer le mnémonique des « dimensions voisines ». Quelle réserve le livre y met-il ? 16. Écrire df/dt quand $f(x_1, x_2)$ avec $x_1(t)$, $x_2(t)$. 17. Détailler l'exemple 5.8.

Jacobienne 18. Définir la jacobienne. Quelle est sa taille ? Quelle convention de disposition ? 19. Donner le tableau des quatre dimensions de gradient. 20. Que représente $|\det J|$? 21. La jacobienne est-elle exacte pour une transformation non linéaire ? 22. Que vaut le gradient de

$f(x) = Ax$? 23. Détailler l'exemple 5.10 (les deux dimensions, puis le produit). 24. Détailler l'exemple 5.11 : dimension, chaîne, les deux facteurs, résultat. 25. Pourquoi le livre dit-il que l'approche directe devient impraticable ?

Gradients de matrices 26. Quelle est la taille du gradient d'une matrice $m \times n$ relativement à une $p \times q$? 27. Quelle astuce le livre propose-t-il et pourquoi ? 28. Détailler l'exemple 5.13. D'où vient le facteur **2** ? 29. Écrire les identités pour **tr**, **det** et $f(X)^{-1}$. 30. Écrire $\frac{\partial x^\top Bx}{\partial x}$ et $\frac{\partial a^\top Xb}{\partial X}$. 31. Que devient la trace pour un tenseur ? Et la transposée ?

Rétropropagation 32. Pourquoi écrire un gradient explicitement est-il impraticable ? 33. Écrire la composition d'un réseau profond et sa perte. 34. Citer trois fonctions d'activation. 35. Écrire $\partial L / \partial \theta_i$. Quel est l'apport de la rétropropagation ? 36. Qu'est-ce que la différentiation automatique ? De quoi diffère-t-elle ? 37. Distinguer mode direct et mode inverse. Lequel est la rétropropagation ? 38. Pourquoi le mode inverse est-il moins cher pour les réseaux ? 39. Détailler les six variables intermédiaires de l'exemple 5.14. 40. Quelle est l'observation contre-intuitive sur le coût ? 41. Écrire la formule générale de la propagation avant et de la rétropropagation. 42. Quelles sont les limites de la différentiation automatique ?

Ordre supérieur et Taylor multivarié 43. Distinguer $\frac{\partial^2 f}{\partial y \partial x}$ et $\frac{\partial^2 f}{\partial x \partial y}$. 44. Sous quelle condition la hessienne est-elle symétrique ? 45. Que mesure la hessienne ? Quelle est sa taille pour $f : \mathbb{R}^n \rightarrow \mathbb{R}$? Pour un champ de vecteurs ? 46. Écrire la linéarisation de f autour de x_0 . 47. Écrire la série de Taylor multivariée. Qu'est-ce que δ ? 48. Qu'est-ce que δ^k exactement ? 49. Écrire les termes $k = 0, 1, 2, 3$. 50. Détailler l'exemple 5.15 : ordre 0, 1, 2, 3. 51. Pourquoi le développement est-il exact et pas seulement local ?

Flashcards

Question	Réponse
Quotient différentiel ?	$\frac{f(x + \delta x) - f(x)}{\delta x}$ — la pente de la SÉCANTE
Dérivée ?	$\frac{df}{dx} = \lim_{h \rightarrow 0} \frac{f(x + h) - f(x)}{h}$ — la TANGENTE
Direction de la dérivée ?	La plus forte MONTÉE
Polynôme de Taylor de degré n ?	$T_n(x) = \sum_{k=0}^n \frac{f^{(k)}(x_0)}{k!} (x - x_0)^k$
Série de Taylor ?	La même somme, jusqu'à ∞ , pour $f \in C^\infty$
Série de Maclaurin ?	Taylor en $x_0 = 0$
Fonction analytique ?	$f(x) = T_\infty(x)$
Quand T_n est-il exact ?	Pour un polynôme de degré $k \leq n$ — toutes les dérivées $f^{(i)}, i > k$, s'annulent
T_6 de x^4 en $x_0 = 1$?	$= x^4$ exactement ; coefficients 1, 4, 12, 24, 24, 0, 0
Motif des coefficients de sin + cos ?	Seulement ± 1 , chacun DEUX FOIS , avec $f^{(k+4)}(0) = f^{(k)}(0)$
Règle du produit ?	$(fg)' = f'g + fg'$
Règle du quotient ?	$\left(\frac{f}{g}\right)' = \frac{f'g - fg'}{g^2}$
Règle de la chaîne ?	$(g \circ f)'(x) = g'(f(x))f'(x)$
Dérivée de $(2x + 1)^4$?	$8(2x + 1)^3$
Comment calcule-t-on une partielle ?	Une variable à la fois , les autres constantes
Taille du gradient de $f : \mathbb{R}^n \rightarrow \mathbb{R}$?	$1 \times n$ — un VECTEUR LIGNE
Les deux raisons du vecteur ligne ?	Généralisation cohérente aux fonctions vectorielles · application immédiate de la chaîne
Autres noms du gradient ?	$\nabla_x f$, grad f , df/dx , la jacobienne

Question	Réponse
Chaîne multivariée ?	$\frac{\partial}{\partial x} g(f(x)) = \frac{\partial g}{\partial f} \frac{\partial f}{\partial x}$
Le mnémonique ?	Les dimensions voisines correspondent, ∂f « s'annule »
La réserve du livre ?	« <i>Ce n'est qu'une intuition</i> » — $\partial f / \partial x$ n'est pas une fraction
Gradient de l'exemple 5.7 ?	$[2x_1x_2 + x_2^3 \quad x_1^2 + 3x_1x_2^2]$
Résultat de l'exemple 5.8 ?	$2 \sin t (\cos t - 1)$
Jacobienne ?	La collection des partielles du premier ordre , $J(i, j) = \partial f_i / \partial x_j$
Sa taille ?	$m \times n$: lignes = SORTIES, colonnes = ENTRÉES
Disposition au numérateur ?	$df/dx \in \mathbb{R}^{m \times n}$ — la disposition au dénominateur en est la transposée
Gradient de $f : \mathbb{R}^D \rightarrow \mathbb{R}$?	Vecteur ligne $1 \times D$
Gradient de $f : \mathbb{R} \rightarrow \mathbb{R}^E$?	Vecteur colonne $E \times 1$
Gradient de $f : \mathbb{R}^D \rightarrow \mathbb{R}^E$?	Matrice $E \times D$
$ \det J $?	Le facteur d'échelle des AIRES / VOLUMES
Exact ou approché ?	Exact si linéaire · approximation LOCALE si non linéaire
$ \det J $ dans l'exemple du §5.3 ?	3 (matrice $\begin{bmatrix} -2 & 1 \\ 1 & 1 \end{bmatrix}$)
Où le déterminant jacobien resservira-t-il ?	§6.7 — transformation de variables aléatoires, reparamétrisation
$d(Ax)/dx$?	A
Le protocole du livre avant tout calcul ?	Déterminer la DIMENSION du gradient
$\partial L / \partial \theta$ pour $L = \ y - \Phi \theta\ ^2$?	$-2e^\top \Phi = -2(y^\top - \theta^\top \Phi^\top) \Phi \in \mathbb{R}^{1 \times D}$
$\partial L / \partial e$ pour $L = \ e\ ^2$?	$2e^\top \in \mathbb{R}^{1 \times N}$
Gradient d'une matrice relativement à une matrice ?	Un TENSEUR $(m \times n) \times (p \times q)$
L'astuce du livre ?	Aplatir : $\mathbb{R}^{m \times n}$ est isomorphe à $\mathbb{R}^{mn}$

Question	Réponse
Pourquoi ?	La chaîne redevient une simple multiplication matricielle
Le facteur 2 de l'exemple 5.13 ?	Quand $p = q$, la variable R_{iq} apparaît deux fois dans $K_{pp} = \sum_m R_{mp}^2$
$\frac{\partial}{\partial X} \text{tr}(f(X))$?	$\text{tr} \left(\frac{\partial f(X)}{\partial X} \right)$
$\frac{\partial}{\partial X} \det(f(X))$?	$\det(f(X)) \text{tr} \left(f(X)^{-1} \frac{\partial f(X)}{\partial X} \right)$
$\frac{\partial}{\partial X} f(X)^{-1}$?	$-f(X)^{-1} \frac{\partial f(X)}{\partial X} f(X)^{-1}$
$\frac{\partial x^\top a}{\partial x}$?	$a^\top$
$\frac{\partial a^\top X b}{\partial X}$?	$ab^\top$
$\frac{\partial x^\top B x}{\partial x}$?	$x^\top (B + B^\top)$ — pas $2x^\top B$
$\frac{\partial}{\partial s} (x - As)^\top W (x - As)$?	$-2(x - As)^\top W A$ pour W SYMÉTRIQUE
Trace d'un tenseur $D \times D \times E \times F$?	Une matrice $E \times F$ — une contraction tensorielle
« Transposer » un tenseur ?	Échanger les deux premières dimensions
Composition d'un réseau profond ?	$y = (f_K \circ \dots \circ f_1)(x)$, $f_i = \sigma(A_{i-1}f_{i-1} + b_{i-1})$
Trois fonctions d'activation ?	Sigmoïde $\frac{1}{1+e^{-x}}$ · tanh · ReLU
La perte quadratique ?	$L(\theta) = \ y - f_K(\theta, x)\ ^2$
$\partial L / \partial \theta_i$?	$\frac{\partial L}{\partial f_K} \frac{\partial f_K}{\partial f_{K-1}} \dots \frac{\partial f_{i+1}}{\partial \theta_i}$
L'idée-clé de la rétropropagation ?	RÉUTILISER les calculs déjà faits pour la couche $i + 1$
Les auteurs cités ?	Kelley (1960), Bryson (1961), Dreyfus (1962), Rumelhart et al. (1986)
Différentiation automatique ?	Évaluation numérique du gradient EXACT (à la précision machine) via variables intermédiaires + chaîne
Elle diffère de ?	La différentiation symbolique et les différences finies

Question	Réponse
Mode inverse ?	Les gradients remontent à rebours du flot des données — c'est la rétropropagation
Mode direct ?	Les gradients suivent les données de gauche à droite
Quand le mode inverse gagne-t-il ?	Quand la dimension d' entrée est bien plus grande que celle de la sortie
Sur quoi repose le choix de mode ?	L' ASSOCIATIVITÉ du produit matriciel
Les six variables de l'exemple 5.14 ?	$a = x^2, b = \exp(a), c = a + b, d = \sqrt{c}, e = \cos(c), f = d + e$
L'observation contre-intuitive ?	Le calcul du gradient est de complexité SIMILAIRE à celui de la fonction
Propagation avant, formule générale ?	$x_i = g_i(x_{Pa(x_i)})$ pour $i = d + 1, \dots, D$
Rétropropagation, formule générale ?	$\frac{\partial f}{\partial x_i} = \sum_{j: x_i \in Pa(x_j)} \frac{\partial f}{\partial x_j} \frac{\partial x_j}{\partial x_i}$
Initialisation de la remontée ?	$\partial f / \partial x_D = 1$
Les limites de la diff. automatique ?	Boucles for, instructions if , fonctions élémentaires non différentiables
$\frac{\partial^2 f}{\partial y \partial x}$ signifie ?	D'abord relativement à x , PUIS à y
Quand l'ordre n'importe-t-il pas ?	Si f est deux fois (continûment) différentiable
Hessienne ?	La collection de toutes les partielles du SECOND ordre , notée $\nabla^2 f$
Sa taille ?	$n \times n$ pour $f : \mathbb{R}^n \rightarrow \mathbb{R}$; un tenseur $(m \times n \times n)$ pour un champ de vecteurs
Que mesure-t-elle ?	La COURBURE locale
Où sert-elle ?	La méthode de NEWTON pour l'optimisation
Linéarisation ?	$f(x) \approx f(x_0) + (\nabla_x f)(x_0)(x - x_0)$
Série de Taylor multivariée ?	$f(x) = \sum_{k=0}^{\infty} \frac{D_x^k f(x_0)}{k!} \delta^k$ avec $\delta := x - x_0$
Qu'est-ce que δ^k ?	Le produit EXTÉRIEUR k -uple : $\delta^2 = \delta \delta^\top, \delta^3[i, j, k] = \delta_i \delta_j \delta_k$
Terme $k = 1$?	$\nabla_x f(x_0) \delta$ — produit $(1 \times D)(D \times 1)$

Question	Réponse
Terme $k = 2$?	$\frac{1}{2} \delta^T H(x_0) \delta = \frac{1}{2} \text{tr}(H \delta \delta^T)$
Ordre des polynômes dans le terme k ?	Exactement k
$f(1, 2)$ dans l'exemple 5.15 ?	13
Gradient en $(1, 2)$?	$[6 \quad 14]$
Hessienne en $(1, 2)$?	$\begin{bmatrix} 2 & 2 \\ 2 & 12 \end{bmatrix}$
Seule dérivée troisième non nulle ?	$\partial^3 f / \partial y^3 = 6$
Le développement complet ?	$13 + 6(x - 1) + 14(y - 2) + (x - 1)^2 + 2(x - 1)(y - 2) + 6(y - 2)^2 + (y - 2)^3$
Est-il exact ?	OUI, globalement — car f est un polynôme de degré 3