

Fiche 405 — Probabilités et distributions : Bayes, gaussiennes, famille exponentielle

Matière	Maths · Apprentissage automatique
Cours source	Deisenroth, Faisal & Ong, <i>Mathematics for Machine Learning</i> , Cambridge University Press — chapitre 6 « Probability and Distributions » (p. 172-224)
Difficulté	Avancé — la fondation probabiliste de tout l'apprentissage automatique
Temps d'étude estimé	160 min
Prérequis	Fiche 402 (produit intérieur) · Fiche 403 (matrices SDP, Cholesky, déterminant) · Fiche 404 (jacobienne)
Concepts clés	Espace probabilisé, univers, tribu des événements, mesure de probabilité, variable aléatoire, espace cible, loi, fonction de masse, densité, fonction de répartition, probabilité jointe / marginale / conditionnelle, règle de la somme, règle du produit, théorème de Bayes, a priori, vraisemblance, a posteriori, vraisemblance marginale, espérance, moyenne, médiane, mode, covariance, variance, matrice de covariance, corrélation, statistiques empiriques, formule brute de la variance, indépendance statistique, i.i.d., indépendance conditionnelle, produit intérieur de variables aléatoires, loi gaussienne, marginales et conditionnelles gaussiennes, produit de gaussiennes, mélange, échantillonnage, Bernoulli, binomiale, bêta, conjugaison, a priori conjugué, statistiques exhaustives, théorème de Fisher-Neyman, famille exponentielle, paramètres naturels, log-partition, sigmoïde, changement de variables, transformation intégrale de probabilité
Poids à l'examen	La règle de la somme et la règle du produit · le théorème de Bayes et ses quatre noms · $\text{Cov}[x, y] = \mathbb{E}[xy] - \mathbb{E}[x]\mathbb{E}[y]$ · $\mathbb{V}[Ax + b] = A\Sigma A^T$ · les conditionnelles gaussiennes $\mu_{x y} = \mu_x + \Sigma_{xy}\Sigma_{yy}^{-1}(y - \mu_y)$ · la conjugaison bêta-binomiale · la forme $p(x \theta) = h(x) \exp(\langle \theta, \phi(x) \rangle - A(\theta))$ · le changement de variables avec $ \det J $.

Vue d'ensemble

LE FIL DU CHAPITRE : quantifier l'INCERTITUDE

§6.1 ESPACE PROBABILISÉ (Ω , $\mathcal{A}$, P)

UNIVERS Ω · TRIBU DES ÉVÉNEMENTS $\mathcal{A}$ · PROBABILITÉ P avec $P(\Omega) = 1$

VARIABLE ALÉATOIRE $X : \Omega \rightarrow \mathbb{T}$ ⚠ ni aléatoire ni variable — c'est une FONCTION

LOI de X : $P_X(S) = P(X \in S) = P(X^{-1}(S))$

§6.2 DISCRET / CONTINU

DISCRET $P(X = x)$ fonction de MASSE (pmf)

CONTINU $P(X \leq x)$ fonction de RÉPARTITION (cdf) ; densité $f \geq 0$, $\int f = 1$

⚠ une densité PEUT dépasser 1 · ⚠ $P(X = x) = 0$ en continu

§6.3 LES DEUX RÈGLES FONDAMENTALES

SOMME $p(x) = \sum_y p(x,y)$ ou $\int p(x,y) dy$ (marginalisation)

PRODUIT $p(x,y) = p(y|x) p(x)$

BAYES $p(x|y) = p(y|x) p(x) / p(y)$

postérieur = vraisemblance × a priori / évidence

§6.4 STATISTIQUES RÉSUMÉES ET INDÉPENDANCE

$E[g(x)] = \int g(x)p(x)dx$ · moyenne, MÉDIANE, MODE

$\text{Cov}[x,y] = E[xy] - E[x]E[y]$ · $V[x] = \text{Cov}[x,x]$ · $\text{corr} \in [-1,1]$

AFFINE $E[Ax+b] = A\mu+b$ $V[Ax+b] = A \Sigma A^T$ $\text{Cov}[x, Ax+b] = \Sigma A^T$

INDÉPENDANCE $p(x,y) = p(x)p(y) \Rightarrow \text{Cov} = 0$ ⚠ RÉCIPROQUE FAUSSE

GÉOMÉTRIE $\langle X, Y \rangle := \text{Cov}[x,y]$ · $\|X\| = \sigma[x]$ · $\cos \theta = \text{corrélation}$

§6.5 GAUSSIENNE

$p(x|\mu, \Sigma) = (2\pi)^{-D/2} |\Sigma|^{-1/2} \exp(-\frac{1}{2} (x-\mu)^T \Sigma^{-1} (x-\mu))$

MARGINALE $p(x) = N(\mu_x, \Sigma_{xx})$ ← on IGNORE ce qui ne nous intéresse pas

CONDITIONNELLE $\mu_{\{x|y\}} = \mu_x + \Sigma_{xy} \Sigma_{yy}^{-1} (y - \mu_y)$

$\Sigma_{\{x|y\}} = \Sigma_{xx} - \Sigma_{xy} \Sigma_{yy}^{-1} \Sigma_{yx}$

SOMME de gaussiennes INDÉPENDANTES → gaussienne · toute AFFINE → gaussienne

ÉCHANTILLONNER : uniforme → Box-Müller → $N(0, I) \rightarrow y = Ax + \mu$ avec $AA^T = \Sigma$ (CHOLESKY)

§6.6 CONJUGAISON ET FAMILLE EXPONENTIELLE

Bernoulli · Binomiale · Bêta · BÊTA conjugué de BINOMIALE et de BERNOULLI

STATISTIQUES EXHAUSTIVES · FISHER-NEYMAN $p(x|\theta) = h(x) g_{\theta}(\phi(x))$

FAMILLE EXPONENTIELLE $p(x|\theta) = h(x) \exp(\langle \theta, \phi(x) \rangle - A(\theta))$

§6.7 CHANGEMENT DE VARIABLES

DISCRET $P(Y = y) = P(X = U^{-1}(y))$

CONTINU $f(y) = f_x(U^{-1}(y)) \cdot |d/dy U^{-1}(y)|$ ⚠ le facteur JACOBIEN en plus

MULTIVARIÉ $f(y) = f_x(U^{-1}(y)) \cdot |\det \partial/\partial y U^{-1}(y)|$

La phrase d'ouverture. « *La probabilité, grossièrement, concerne l'étude de l'INCERTITUDE. Elle peut être vue comme la **fraction des fois où un événement se produit**, ou comme un **DEGRÉ DE CROYANCE** au sujet d'un événement.* » En apprentissage automatique, on quantifie l'incertitude **dans les données, dans le modèle et dans les prédictions.**

● Concept 1 — L'espace probabilisé (§6.1)

1.1 La justification philosophique

Le programme. « *La théorie des probabilités peut être considérée comme une **GÉNÉRALISATION DE LA LOGIQUE BOOLÉENNE**.* » La logique classique ne permet pas d'exprimer certaines formes de **raisonnement plausible** : on observe que **A** est faux, **B** devient **moins plausible** sans qu'aucune conclusion logique ne suive.

L'exemple de l'ami en retard. Trois hypothèses : **H_1** , elle est à l'heure ; **H_2** , elle est retardée par le trafic ; **H_3** , elle a été enlevée par des extraterrestres. Observant le retard, on **exclut logiquement H_1** , on tend à considérer **H_2 plus probable** (sans y être logiquement contraint), et on garde **H_3 possible mais très improbable**.

Les trois critères de E. T. Jaynes (1922-1998) :

1. Les degrés de plausibilité sont représentés par des **nombre réels**.
2. Ces nombres doivent être fondés sur les **règles du sens commun**.
3. Le raisonnement doit être **CONSISTANT**, en trois sens :
 - (a) **Consistance / non-contradiction** : quand un même résultat peut être atteint par des voies différentes, la **même valeur de plausibilité** doit être trouvée dans tous les cas.
 - (b) **Honnêteté** : **toutes** les données disponibles doivent être prises en compte.
 - (c) **Reproductibilité** : si notre état de connaissance sur deux problèmes est le même, il faut leur assigner **le même degré de plausibilité**.

Le théorème de Cox-Jaynes prouve que ces plausibilités suffisent à définir les règles mathématiques universelles applicables à la plausibilité **p** , à **transformation par une fonction monotone arbitraire près**. Et **ces règles sont les règles de la probabilité**.

Les deux interprétations, à connaître.

- **BAYÉSIENNE** : la probabilité spécifie le **degré d'incertitude que l'utilisateur a** au sujet d'un événement. Aussi appelée « probabilité **subjective** » ou « **degré de croyance** ».
- **FRÉQUENTISTE** : la probabilité est la **fréquence relative** de l'événement d'intérêt sur le nombre total d'événements, **à la limite d'une infinité de données**.

1.2 Les trois concepts de Kolmogorov

Concept	Notation	Définition
L'univers (<i>sample space</i>)	Ω	L'ensemble de tous les résultats possibles de l'expérience. Ex. : deux lancers de pièce $\rightarrow \{hh, tt, ht, th\}$
La tribu des événements (<i>event space</i>)	$\mathcal{A}$	L'espace des résultats potentiels . $A \subseteq \Omega$ est dans $\mathcal{A}$ si, à la fin de l'expérience, on peut observer si un résultat $\omega \in \Omega$ est dans A . Pour les lois discrètes, $\mathcal{A}$ est souvent l'ensemble des parties de Ω
La probabilité	P	À chaque $A \in \mathcal{A}$ on associe $P(A)$, la probabilité ou degré de croyance que l'événement se produira

$$P(A) \in [0, 1] \quad \text{et} \quad P(\Omega) = 1$$

Les autres noms de Ω , source de confusion : « **espace d'états** » (*state space*), « **espace de description des échantillons** », « **espace des possibilités** », et même « **espace des événements** ». Le livre le signale explicitement.

1.3 La variable aléatoire

DÉFINITION.

On introduit une fonction $X : \Omega \rightarrow \mathcal{T}$ qui prend un élément de Ω (un résultat) et renvoie une **quantité d'intérêt** x , valeur dans l'**ESPACE CIBLE** $\mathcal{T}$. Cette association est la **VARIABLE ALÉATOIRE**.

L'avertissement du livre, mot pour mot. « Le nom « variable aléatoire » est une **grande source de malentendus**, car elle n'est **ni aléatoire ni une variable**. **C'est une FONCTION.** »

Le lien entre Ω et $\mathcal{T}$. Pour $S \subseteq \mathcal{T}$, soit $X^{-1}(S)$ l'**image réciproque** de S par X , c'est-à-dire $\{\omega \in \Omega : X(\omega) \in S\}$. Alors

$$P_X(S) = P(X \in S) = P(X^{-1}(S)) = P(\{\omega \in \Omega : X(\omega) \in S\})$$

La fonction P_X , ou de façon équivalente $P \circ X^{-1}$, est la **LOI** (*law*) ou **distribution** de X .

Le classement par espace cible :

- $\mathcal{T}$ **fini ou dénombrable** $\Rightarrow$ variable aléatoire **DISCRÈTE** (§6.2.1).
- $\mathcal{T} = \mathbb{R}$ ou $\mathbb{R}^D \Rightarrow$ variable aléatoire **CONTINUE** (§6.2.2).

Exemple 6.1 — le jeu de fête foraine. On tire deux pièces d'un sac **avec remise**. Il y a des pièces américaines (notées D) et britanniques (notées L). Un tirage rend D avec probabilité **0,3**.

$$\Omega = \{(D, D), (D, L), (L, D), (L, L)\}$$

X compte le nombre de D , donc $\mathcal{T} = \{0, 1, 2\}$:

$$X((D, D)) = 2, \quad X((D, L)) = 1, \quad X((L, D)) = 1, \quad X((L, L)) = 0$$

Comme on **remet la première pièce** avant de tirer la seconde, les deux tirages sont **indépendants**. **Deux résultats expérimentaux différents s'envoient sur le même événement** ($X = 1$), d'où le facteur 2 :

$$P(X = 2) = 0,3 \cdot 0,3 = \boxed{0,09}$$

$$P(X = 1) = 0,3 \cdot 0,7 + 0,7 \cdot 0,3 = \boxed{0,42}$$

$$P(X = 0) = 0,7 \cdot 0,7 = \boxed{0,49}$$

$0,09 + 0,42 + 0,49 = 1,00$ exactement La pmf est bien normalisée.

1.4 Probabilités contre statistiques

La distinction, en une phrase chacune.

- **PROBABILITÉ** : « on considère un *MODÈLE* d'un processus, où l'incertitude sous-jacente est capturée par des variables aléatoires, et on utilise les règles de la probabilité pour **DÉRIVER CE QUI SE PASSE** ».
- **STATISTIQUE** : « on observe que quelque chose **s'est produit** et on essaie de **retrouver le PROCESSUS SOUS-JACENT** qui explique les observations ».

L'apprentissage automatique est **proche de la statistique** dans ses buts.

● Concept 2 — Probabilités discrètes et continues (§6.2)

2.1 Le vocabulaire — le tableau 6.1 du livre

Type	« Probabilité ponctuelle »	« Probabilité d'intervalle »
Discret	$P(X = x)$ — fonction de MASSE (pmf)	Sans objet
Continu	$p(x)$ — fonction de DENSITÉ (pdf)	$P(X \leq x)$ — fonction de RÉPARTITION (cdf)

Univarié contre multivarié. « Loi UNIVARIÉE » = loi d'une SEULE variable aléatoire (états notés x , non gras). « Loi MULTIVARIÉE » = plus d'une variable aléatoire (états notés $\mathbf{x}$, en gras).

2.2 Le cas discret

$$P(X = x_i, Y = y_j) = \frac{n_{ij}}{N}$$

où n_{ij} est le nombre d'événements d'états x_i et y_j , et N le nombre total. C'est la **probabilité JOINTE** — la probabilité de l'**intersection** : $P(X = x_i \cap Y = y_j)$.

L'espace cible de la probabilité jointe est le **PRODUIT CARTÉSIEN** des espaces cibles individuels.

Exemple 6.2 — la table à cinq colonnes et trois lignes. Avec $c_i = \sum_{j=1}^3 n_{ij}$ (somme de la colonne i) et $r_j = \sum_{i=1}^5 n_{ij}$ (somme de la ligne j) :

Quantité	Formule	Lecture
Marginale de X	$P(X = x_i) = \frac{c_i}{N} = \sum_{j=1}^3 \frac{n_{ij}}{N}$	La somme d'une COLONNE
Marginale de Y	$P(Y = y_j) = \frac{r_j}{N} = \sum_{i=1}^5 \frac{n_{ij}}{N}$	La somme d'une LIGNE
Conditionnelle	$P(Y = y_j X = x_i) = \frac{n_{ij}}{c_i}$	La fraction d'une colonne dans une cellule

Et la convention de normalisation : $\sum_{i=1}^5 P(X = x_i) = 1$ et $\sum_{j=1}^3 P(Y = y_j) = 1$.

Les notations paresseuses (le livre les qualifie ainsi) : $p(x, y)$ pour la jointe, $p(x)$ pour la marginale, $p(y | x)$ pour la conditionnelle, et $X \sim p(x)$ pour « X suit la loi $p(x)$ ».

2.3 Le cas continu

DÉFINITION 6.1 (DENSITÉ DE PROBABILITÉ).

Une fonction $f : \mathbb{R}^D \rightarrow \mathbb{R}$ est une **densité de probabilité** (*pdf*) si

1. $\forall x \in \mathbb{R}^D : f(x) \geq 0$
2. Son intégrale existe et $\int_{\mathbb{R}^D} f(x) dx = 1$

L'association avec une variable aléatoire :

$$P(a \leq X \leq b) = \int_a^b f(x) dx$$

C'est la **LOI** de X .

La conséquence la plus contre-intuitive. « Contrairement aux variables aléatoires discrètes, la probabilité qu'une variable aléatoire CONTINUE prenne une valeur particulière, $P(X = x)$, est **ZÉRO**. C'est comme spécifier un intervalle avec $a = b$. » ($\{x\}$ est un ensemble de **mesure nulle**.)

DÉFINITION 6.2 (FONCTION DE RÉPARTITION).

Pour X à états $x \in \mathbb{R}^D$:

$$F_X(x) = P(X_1 \leq x_1, \dots, X_D \leq x_D) = \int_{-\infty}^{x_1} \cdots \int_{-\infty}^{x_D} f(z_1, \dots, z_D) dz_1 \cdots dz_D$$

Deux concepts distincts à ne pas confondre. (i) La **densité** $f(x)$: une fonction non négative d'intégrale 1. (ii) La **LOI** de X : l'**association** de la variable aléatoire X à la densité $f(x)$. « Il existe des cdf qui n'ont pas de pdf correspondante. »

2.4 Le contraste discret / continu — Exemple 6.3

Cas discret. Z uniforme sur trois états $\{-1,1; 0,3; 1,5\}$: chaque état a probabilité $\frac{1}{3}$. **Chaque valeur est dans $[0, 1]$.**

Cas continu. X uniforme sur $0,9 \leq X \leq 1,6$, un intervalle de **longueur 0,7**. La densité vaut donc $1/0,7 \approx 1,43$:

$$\int_{0,9}^{1,6} p(x) dx = 1$$

LA DIFFÉRENCE ESSENTIELLE. « Pour les variables aléatoires discrètes, la probabilité de chaque état doit être dans $[0, 1]$. Cependant, pour les variables continues, la normalisation **N'IMPLIQUE PAS** que la valeur de la densité soit ≤ 1 pour toute valeur. » **Une densité peut dépasser 1.**

Une subtilité sur les états discrets. « Les états $z_1, \dots, z_d$ n'ont en principe **aucune structure** : il n'y a généralement aucun moyen de les comparer — par exemple $z_1 = \text{rouge}$, $z_2 = \text{vert}$, $z_3 = \text{bleu}$. » Mais en apprentissage automatique ils prennent souvent des **valeurs numériques**, ce qui permet de considérer des **espérances**.

● Concept 3 — Somme, produit et Bayes (§6.3)

L'affirmation centrale. « Une fois les lois de probabilité définies, il n'y a que **DEUX RÈGLES FONDAMENTALES** : la règle de la somme et la règle du produit. »

3.1 La règle de la somme (marginalisation)

$$p(x) = \begin{cases} \sum_{y \in \mathcal{Y}} p(x, y) & \text{si } y \text{ est discret} \\ \int_{\mathcal{Y}} p(x, y) dy & \text{si } y \text{ est continu} \end{cases}$$

On « **somme** » ou « **intègre** » l'ensemble des états de $\mathbf{Y}$. C'est la **PROPRIÉTÉ DE MARGINALISATION** : elle **relie la loi jointe à une loi marginale**.

En dimension supérieure, avec $\mathbf{x} = [x_1, \dots, x_D]^\top$:

$$p(x_i) = \int p(x_1, \dots, x_D) dx_{\setminus i}$$

où $\setminus i$ se lit « **tous sauf i** ».

Le coût algorithmique. « Beaucoup des défis computationnels de la modélisation probabiliste viennent de l'application de la règle de la somme. Quand il y a beaucoup de variables, ou des variables discrètes à nombreux états, la règle de la somme se ramène à une **SOMME ou INTÉGRALE DE GRANDE DIMENSION** — ce qui est **généralement difficile**, au sens où il **n'existe pas d'algorithme polynomial connu** pour les calculer exactement. »

3.2 La règle du produit

$$p(x, y) = p(y | x) p(x) = p(x | y) p(y)$$

L'interprétation. « Toute loi jointe de deux variables aléatoires peut être **FACTORISÉE** en produit de deux autres lois : la **marginale de la première** et la **conditionnelle de la seconde sachant la première**. » L'ordre étant arbitraire, les deux factorisations sont valables.

3.3 Le théorème de Bayes

$$\underbrace{p(x | y)}_{\text{A POSTERIORI}} = \frac{\overbrace{p(y | x)}^{\text{VRAISEMBLANCE A PRIORI}} \overbrace{p(x)}^{\text{VRAISEMBLANCE A PRIORI}}}{\underbrace{p(y)}_{\text{ÉVIDENCE}}}$$

Les quatre termes, définis par le livre :

Terme	Rôle
A priori $p(x)$	« Encapsule notre connaissance a priori subjective de la variable latente x AVANT d'observer toute donnée. » « Il est critique de s'assurer que l'a priori a une densité NON NULLE sur tous les x plausibles , même s'ils sont très rares. »
Vraisemblance $p(y x)$	Décrit comment x et y sont reliés . *« La vraisemblance n'est PAS une loi en x , seulement en y . On l'appelle "vraisemblance de x (sachant y)" ou "probabilité de y sachant x ", mais JAMAIS la vraisemblance de y (MacKay, 2003). »* Aussi appelée le modèle de mesure
A posteriori $p(x y)$	*« La quantité d'intérêt en statistique bayésienne, car elle exprime exactement ce qu'on veut : ce qu'on sait de x APRÈS avoir observé y . »*
Vraisemblance marginale / évidence $p(y)$	$p(y) := \int p(y x)p(x) dx = \mathbb{E}_X[p(y x)]$

Trois faits sur l'évidence :

- Elle est **indépendante de x** et assure que l'a posteriori est **normalisé**.
- Elle s'interprète comme la **vraisemblance ESPÉRÉE**, l'espérance étant prise **par rapport à l'a priori**.
- Elle joue un rôle important dans la **SÉLECTION DE MODÈLE bayésienne** (§8.6). « Du fait de l'intégration, l'évidence est souvent **DIFFICILE À CALCULER**. »

L'autre nom du théorème. « Bayes permet d'**INVERSER** la relation entre **x** et **y** donnée par la vraisemblance. C'est pourquoi on l'appelle parfois l'**INVERSE PROBABILISTE**. »

POURQUOI GARDER L'A POSTERIORI ENTIER.

« Se concentrer sur une statistique de l'a posteriori (par exemple son maximum) conduit à une **PERTE D'INFORMATION**. » Le livre donne un exemple concret : en **apprentissage par renforcement fondé sur un modèle**, Deisenroth *et al.* (2015) montrent qu'utiliser **la loi a posteriori COMPLÈTE** des fonctions de transition plausibles conduit à un apprentissage **très rapide** (efficace en données), alors que se concentrer sur le maximum mène à des **échecs systématiques**.

● Concept 4 — Statistiques résumées et indépendance (§6.4)

4.1 Espérance, moyenne, médiane, mode

DÉFINITION 6.3 (ESPÉRANCE).

L'espérance d'une fonction $g : \mathbb{R} \rightarrow \mathbb{R}$ d'une variable aléatoire **continue** $X \sim p(x)$:

$$\mathbb{E}_X[g(x)] = \int_{\mathcal{X}} g(x)p(x) dx$$

et pour une variable **discrète** :

$$\mathbb{E}_X[g(x)] = \sum_{x \in \mathcal{X}} g(x)p(x)$$

L'espérance d'une fonction d'une variable aléatoire est parfois appelée la **loi du statisticien inconscient** (law of the unconscious statistician).

Cas multivarié : élément par élément, $\mathbb{E}_X[g(x)] = [\mathbb{E}_{X_1}[g(x_1)], \dots, \mathbb{E}_{X_D}[g(x_D)]]^\top \in \mathbb{R}^D$.

DÉFINITION 6.4 (MOYENNE).

C'est le **cas particulier** de l'espérance obtenu en choisissant $g = \text{l'identité}$:

$$\mathbb{E}_X[x] = [\mathbb{E}_{X_1}[x_1], \dots, \mathbb{E}_{X_D}[x_D]]^\top \in \mathbb{R}^D$$

L'espérance est un OPÉRATEUR LINÉAIRE. Pour $f(x) = ag(x) + bh(x)$:

$$\boxed{\mathbb{E}_X[f(x)] = a \mathbb{E}_X[g(x)] + b \mathbb{E}_X[h(x)]}$$

Les deux autres notions de « moyenne » :

Notion	Définition	Propriétés
MÉDIANE	La valeur « du milieu » : 50 % des valeurs au-dessus, 50 % en dessous. En continu : la valeur où la cdf vaut 0,5	Pour les lois asymétriques ou à queues longues , elle donne une valeur typique plus proche de l'intuition humaine que la moyenne. Elle est PLUS ROBUSTE AUX VALEURS EXTRÊMES . Sa généralisation en dimension > 1 est non triviale — il n'y a pas de façon évidente de « trier »
MODE	La valeur la plus fréquente . En continu : un PIC de la densité $p(x)$	Une densité peut avoir plusieurs modes ; en grande dimension il peut y en avoir énormément , ce qui rend leur recherche computationnellement difficile

Exemple 6.4 — le mélange bimodal.

$$p(x) = 0,4 \mathcal{N}\left(x \mid \begin{bmatrix} 10 \\ 2 \end{bmatrix}, \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}\right) + 0,6 \mathcal{N}\left(x \mid \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 8,4 & 2,0 \\ 2,0 & 1,7 \end{bmatrix}\right)$$

Deux leçons. (i) « La loi est **BIMODALE** (deux modes), mais **l'une des marginales est UNIMODALE** ». (ii) « Il est tentant de définir la médiane bidimensionnelle comme la concaténation des médianes de chaque dimension, mais le fait qu'on **ne puisse pas définir d'ORDRE** sur des points bidimensionnels rend cela difficile. » Le livre précise : il y a **plus d'une façon** de définir la relation $<$ telle que $[3, 0]^T < [2, 3]^T$.

$0,4 \cdot [10, 2]^T + 0,6 \cdot [0, 0]^T = [4,0 ; 0,8]^T$ La moyenne d'un mélange est la **somme pondérée des moyennes** — même quand la loi est bimodale et que la moyenne ne tombe **près d'aucun mode**.

4.2 Covariance, variance, corrélation

DÉFINITION 6.5 (COVARIANCE, UNIVARIÉE).

$$\text{Cov}_{X,Y}[x, y] := \mathbb{E}_{X,Y}[(x - \mathbb{E}_X[x])(y - \mathbb{E}_Y[y])]$$

Par linéarité de l'espérance, elle se réécrit

$$\boxed{\text{Cov}[x, y] = \mathbb{E}[xy] - \mathbb{E}[x]\mathbb{E}[y]}$$

Vocabulaire. $\text{Cov}[x, x] = \mathbb{V}_X[x]$ est la **VARIANCE** ; sa racine carrée est l'**ÉCART-TYPE** $\sigma(x)$. Pour des variables multivariées, $\text{Cov}[x, y]$ est parfois appelée **COVARIANCE CROISÉE**.

DÉFINITION 6.6 (COVARIANCE, MULTIVARIÉE).

Pour $x \in \mathbb{R}^D$ et $y \in \mathbb{R}^E$:

$$\text{Cov}[x, y] = \mathbb{E}[xy^\top] - \mathbb{E}[x]\mathbb{E}[y]^\top = \text{Cov}[y, x]^\top \in \mathbb{R}^{D \times E}$$

DÉFINITION 6.7 (VARIANCE).

$$\boxed{\mathbb{V}_X[x] = \text{Cov}_X[x, x] = \mathbb{E}_X[(x - \mu)(x - \mu)^\top] = \mathbb{E}_X[xx^\top] - \mathbb{E}_X[x]\mathbb{E}_X[x]^\top}$$

La matrice $D \times D$ résultante est la **MATRICE DE COVARIANCE**.

Ses trois propriétés :

- Elle est **SYMÉTRIQUE** et **semi-définie positive**.
- Sur sa **diagonale** : les **variances des marginales**.
- Hors diagonale : les **covariances croisées** $\text{Cov}[x_i, x_j]$ pour $i \neq j$.

DÉFINITION 6.8 (CORRÉLATION).

$$\text{corr}[x, y] = \frac{\text{Cov}[x, y]}{\sqrt{\mathbb{V}[x] \mathbb{V}[y]}} \in [-1, 1]$$

« La **matrice de corrélation** est la matrice de covariance des variables **STANDARDISÉES** $x/\sigma(x)$. »
Corrélation **positive** : quand x croît, y est attendu croissant. Corrélation **négative** : quand x croît, y décroît.

4.3 Statistiques empiriques

Vocabulaire. Les définitions du §6.4.1 sont aussi appelées la **moyenne et la covariance de POPULATION**, car elles font référence aux vraies statistiques de la population. En apprentissage, on part d'**observations empiriques**.

DÉFINITION 6.9 (MOYENNE ET COVARIANCE EMPIRIQUES).

$$\bar{x} := \frac{1}{N} \sum_{n=1}^N x_n \quad \Sigma := \frac{1}{N} \sum_{n=1}^N (x_n - \bar{x})(x_n - \bar{x})^\top$$

Le biais. « Dans tout le livre, nous utilisons la covariance empirique, qui est une estimation **BIAISÉE**. La version **non biaisée** (dite corrigée) a le facteur $N - 1$ au dénominateur au lieu de N . »

Les deux étapes conceptuelles pour passer de la population à l'empirique : (1) utiliser le fait qu'on a un jeu **fini** (N) pour construire une statistique fonction de N variables aléatoires identiques ; (2) **observer** les réalisations $x_1, \dots, x_N$ et appliquer la statistique empirique.

4.4 Les trois expressions de la variance

Expression 1 — la définition (espérance de l'écart au carré) :

$$\mathbb{V}_X[x] := \mathbb{E}_X[(x - \mu)^2]$$

Elle exige un **algorithme à DEUX PASSES** : une passe pour calculer μ , une seconde pour la variance.

Expression 2 — la formule brute (*raw-score formula*) :

$$\mathbb{V}_X[x] = \mathbb{E}_X[x^2] - (\mathbb{E}_X[x])^2$$

Le mnémonique : « *la moyenne du carré MOINS le carré de la moyenne* ». Elle se calcule en **UNE SEULE PASSE** (on accumule x_i et x_i^2 simultanément).

Le prix à payer. « *Malheureusement, implémentée de cette façon, elle peut être NUMÉRIQUEMENT INSTABLE.* » Le livre précise : « *si les deux termes sont énormes et approximativement égaux, on peut souffrir d'une perte inutile de précision en arithmétique flottante.* » Elle reste utile en théorie, par exemple pour dériver la **décomposition biais-variance**.

Expression 3 — la somme des différences par paires :

$$\frac{1}{N^2} \sum_{i,j=1}^N (x_i - x_j)^2 = 2 \left[\frac{1}{N} \sum_{i=1}^N x_i^2 - \left(\frac{1}{N} \sum_{i=1}^N x_i \right)^2 \right]$$

C'est **DEUX FOIS** l'expression brute.

La lecture géométrique. « On peut exprimer la somme des distances par paires (il y en a N^2) comme une somme d'écarts à la moyenne (il y en a N). Géométriquement, cela signifie qu'il y a une **ÉQUIVALENCE entre les distances par paires et les distances au CENTRE** de l'ensemble de points.
 » Du point de vue computationnel : en calculant la moyenne (N termes) puis la variance (N termes), on obtient une expression qui en compte N^2 .

4.5 Sommes et transformations

Sommes de variables aléatoires ($x, y \in \mathbb{R}^D$) :

$$\mathbb{E}[x + y] = \mathbb{E}[x] + \mathbb{E}[y] \qquad \mathbb{E}[x - y] = \mathbb{E}[x] - \mathbb{E}[y]$$

$$\boxed{\mathbb{V}[x + y] = \mathbb{V}[x] + \mathbb{V}[y] + \text{Cov}[x, y] + \text{Cov}[y, x]}$$

$$\boxed{\mathbb{V}[x - y] = \mathbb{V}[x] + \mathbb{V}[y] - \text{Cov}[x, y] - \text{Cov}[y, x]}$$

Même pour une DIFFÉRENCE, les variances S'AJOUTENT ; ce sont les covariances qui changent de signe.

Transformation affine $y = Ax + b$, avec X de moyenne μ et covariance Σ :

$$\boxed{\mathbb{E}_Y[y] = A\mu + b \qquad \mathbb{V}_Y[y] = A\Sigma A^\top \qquad \text{Cov}[x, y] = \Sigma A^\top}$$

Le vecteur b DISPARAÎT de la variance : une translation ne change pas la dispersion.

$$\begin{aligned} \text{Cov}[x, y] &= \mathbb{E}[x(Ax + b)^\top] - \mathbb{E}[x]\mathbb{E}[Ax + b]^\top = \mathbb{E}[x]b^\top + \mathbb{E}[xx^\top]A^\top - \mu b^\top - \mu\mu^\top A^\top \\ &= \underbrace{\mu b^\top - \mu b^\top}_{=0} + (\mathbb{E}[xx^\top] - \mu\mu^\top)A^\top = \Sigma A^\top \end{aligned}$$

où l'on a utilisé $\Sigma = \mathbb{E}[xx^\top] - \mu\mu^\top$ (définition 6.7).

4.6 Indépendance

DÉFINITION 6.10 (INDÉPENDANCE).

X et Y sont **statistiquement indépendantes** si et seulement si

$$p(x, y) = p(x)p(y)$$

L'intuition. « X et Y sont indépendantes si la valeur de y (une fois connue) **n'ajoute aucune information supplémentaire** sur x (et réciproquement). »

Les quatre conséquences :

$$p(y | x) = p(y) \quad p(x | y) = p(x) \quad \mathbb{V}_{X,Y}[x + y] = \mathbb{V}_X[x] + \mathbb{V}_Y[y] \quad \text{Cov}_{X,Y}[x, y] = 0$$

LA RÉCIPROQUE EST FAUSSE. « Deux variables aléatoires peuvent avoir une covariance NULLE sans être statistiquement indépendantes. La covariance mesure **UNIQUEMENT LA DÉPENDANCE LINÉAIRE**. Des variables **non linéairement dépendantes** peuvent avoir une covariance nulle. »

Exemple 6.5 — le contre-exemple. Soit X de moyenne nulle ($\mathbb{E}_X[x] = 0$) avec aussi $\mathbb{E}_X[x^3] = 0$. Posons $y = x^2$ — donc Y **DÉPEND** de X . Pourtant :

$$\text{Cov}[x, y] = \mathbb{E}[xy] - \mathbb{E}[x]\mathbb{E}[y] = \mathbb{E}[x^3] - 0 = \boxed{0}$$

i.i.d. « Indépendantes et identiquement distribuées » : pour plus de deux variables, « **indépendantes** » signifie **MUTUELLEMENT indépendantes** — **tous les sous-ensembles** sont indépendants. « **Identiquement distribuées** » signifie que toutes viennent de **la même loi**.

DÉFINITION 6.11 (INDÉPENDANCE CONDITIONNELLE).

X et Y sont **conditionnellement indépendantes sachant Z** si et seulement si

$$p(x, y | z) = p(x | z) p(y | z) \quad \text{POUR TOUT } z \in \mathcal{Z}$$

Noté $X \perp\!\!\!\perp Y | Z$.

La relation doit tenir **pour CHAQUE valeur de z** . L'interprétation : « sachant z , la loi de x et y **SE FACTORISE** ».

La forme équivalente, via la règle du produit $p(x, y | z) = p(x | y, z)p(y | z)$:

$$p(x | y, z) = p(x | z)$$

*« Sachant qu'on connaît z , la connaissance de y **ne change pas notre connaissance de x** . »* Et l'indépendance simple est le cas particulier $X \perp\!\!\!\perp Y | \emptyset$.

4.7 La géométrie des variables aléatoires

Le point de départ : pour X, Y **non corrélées**, $\mathbb{V}[x + y] = \mathbb{V}[x] + \mathbb{V}[y]$. « Comme les variances se mesurent en unités au carré, cela ressemble beaucoup au **THÉORÈME DE PYTHAGORE** $c^2 = a^2 + b^2$. »

La construction. Pour des variables **centrées** X, Y , on définit

$$\langle X, Y \rangle := \text{Cov}[x, y]$$

qui est bien un **produit intérieur** : symétrique, défini positif, linéaire en chaque argument. En effet $\text{Cov}[x, x] = 0 \iff x = 0$ et $\text{Cov}[\alpha x + z, y] = \alpha \text{Cov}[x, y] + \text{Cov}[z, y]$.

Le dictionnaire géométrique complet :

Notion géométrique	Traduction probabiliste
Produit intérieur $\langle X, Y \rangle$	Covariance $\text{Cov}[x, y]$
Longueur $\ X\ = \sqrt{\langle X, X \rangle}$	ÉCART-TYPE $\sigma[x] = \sqrt{\mathbb{V}[x]}$
Longueur nulle	Variable déterministe
Longueur grande	Variable plus incertaine
$\cos \theta = \frac{\langle X, Y \rangle}{\ X\ \ Y\ }$	La CORRÉLATION
Orthogonalité $X \perp Y$	$\text{Cov}[x, y] = 0$, c'est-à-dire NON CORRÉLÉES
Théorème de Pythagore	$\mathbb{V}[x + y] = \mathbb{V}[x] + \mathbb{V}[y]$

La formule à retenir. « On peut penser à la **CORRÉLATION** comme au **COSINUS DE L'ANGLE** entre deux variables aléatoires quand on les considère géométriquement. »

● Concept 5 — La loi gaussienne (§6.5)

5.1 Les deux densités

La motivation. « La loi la plus étudiée pour les variables continues, aussi appelée loi NORMALE. Son importance vient du fait qu'elle a **beaucoup de propriétés computationnellement commodes**. »

$$p(x \mid \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

$$p(x \mid \mu, \Sigma) = (2\pi)^{-\frac{D}{2}} |\Sigma|^{-\frac{1}{2}} \exp\left(-\frac{1}{2}(x - \mu)^\top \Sigma^{-1}(x - \mu)\right)$$

Notation : $p(x) = \mathcal{N}(x \mid \mu, \Sigma)$ ou $X \sim \mathcal{N}(\mu, \Sigma)$. Le cas $\mu = 0$, $\Sigma = I$ est la **LOI NORMALE STANDARD**.

L'origine naturelle. « La gaussienne apparaît naturellement quand on considère des **SOMMES de variables aléatoires i.i.d.** — c'est le **THÉORÈME CENTRAL LIMITE**. »

Où elle sert : vraisemblance et a priori en **régression linéaire** (ch. 9), **mélanges gaussiens** pour l'estimation de densité (ch. 11), **processus gaussiens**, **inférence variationnelle**, **apprentissage par renforcement**, **filtre de Kalman** (traitement du signal), **régulateur linéaire quadratique** (contrôle), **tests d'hypothèses** (statistique).

L'avantage décisif. « Un avantage majeur de la modélisation par variables gaussiennes est que **les transformations de variables (§6.7) ne sont souvent PAS NÉCESSAIRES**. Puisque la gaussienne est entièrement spécifiée par sa moyenne et sa covariance, on peut souvent obtenir la loi transformée **en appliquant la transformation à la moyenne et à la covariance**. »

5.2 Marginales et conditionnelles — les formules-clés

Pour la loi jointe des états concaténés $[x^\top \ y^\top]^\top$:

$$p(x, y) = \mathcal{N}\left(\begin{bmatrix} \mu_x \\ \mu_y \end{bmatrix}, \begin{bmatrix} \Sigma_{xx} & \Sigma_{xy} \\ \Sigma_{yx} & \Sigma_{yy} \end{bmatrix}\right)$$

LA MARGINALE — par la règle de la somme :

$$p(x) = \int p(x, y) dy = \mathcal{N}(x \mid \mu_x, \Sigma_{xx})$$

L'intuition. « En regardant la loi jointe, on **IGNORE (c'est-à-dire on intègre) tout ce qui ne nous intéresse pas**. » Il suffit de **prendre le bloc correspondant**.

LA CONDITIONNELLE — elle est **aussi gaussienne** :

$$p(x \mid y) = \mathcal{N}(\mu_{x|y}, \Sigma_{x|y})$$

$$\mu_{x|y} = \mu_x + \Sigma_{xy} \Sigma_{yy}^{-1} (y - \mu_y)$$

$$\Sigma_{x|y} = \Sigma_{xx} - \Sigma_{xy} \Sigma_{yy}^{-1} \Sigma_{yx}$$

Le point qui piège. « Dans le calcul de la moyenne, **la valeur y est une OBSERVATION et n'est plus aléatoire.** » Et : la variance conditionnelle **ne dépend PAS de y** — conditionner réduit toujours la variance de la même quantité.

Où les conditionnelles gaussiennes apparaissent.

- Le **FILTRE DE KALMAN** (Kalman, 1960), « l'un des algorithmes les plus centraux pour l'estimation d'état en traitement du signal, **ne fait rien d'autre que calculer des conditionnelles gaussiennes de lois jointes** ».
- Les **PROCESSUS GAUSSIENS** (Rasmussen & Williams, 2006) — une implémentation pratique d'une **loi sur les fonctions**.
- Les **modèles gaussiens linéaires latents**, dont l'**ACP probabiliste** (Tipping & Bishop, 1999), traitée au §10.7.

Exemple 6.6 — le calcul complet.

$$p(x_1, x_2) = \mathcal{N}\left(\begin{bmatrix} 0 \\ 2 \end{bmatrix}, \begin{bmatrix} 0,3 & -1 \\ -1 & 5 \end{bmatrix}\right)$$

Conditionnelle en $x_2 = -1$:

$$\mu_{x_1|x_2=-1} = 0 + (-1) \cdot 0,2 \cdot (-1 - 2) = 0,6$$

$$\sigma_{x_1|x_2=-1}^2 = 0,3 - (-1) \cdot 0,2 \cdot (-1) = 0,1$$

$$p(x_1 | x_2 = -1) = \mathcal{N}(0,6 ; 0,1)$$

Marginale :

$$p(x_1) = \mathcal{N}(0 ; 0,3)$$

$$\Sigma_{yy}^{-1} = 1/5 = 0,2 \text{ et } \Sigma_{xy} = -1, \text{ donc } \Sigma_{xy}\Sigma_{yy}^{-1} = -0,2.$$

$$\text{Moyenne : } 0 + (-0,2) \cdot (-1 - 2) = (-0,2) \cdot (-3) = 0,6$$

$$\text{Variance : } 0,3 - (-0,2) \cdot (-1) = 0,3 - 0,2 = 0,1$$

Deux effets remarquables : (i) la moyenne s'est **déplacée** de 0 à 0,6 — connaître x_2 informe sur x_1 , car ils sont **corrélés** ; (ii) la variance a **CHUTÉ** de 0,3 à 0,1 — conditionner **réduit toujours** l'incertitude quand la corrélation est non nulle.

5.3 Produit, sommes et transformations

PRODUIT de deux densités gaussiennes. Le produit $\mathcal{N}(x \mid a, A) \mathcal{N}(x \mid b, B)$ est une gaussienne **MISE À L'ÉCHELLE** par un $c \in \mathbb{R}$, soit $c \mathcal{N}(x \mid c, C)$ avec

$$C = (A^{-1} + B^{-1})^{-1} \quad c = C(A^{-1}a + B^{-1}b) \quad c = (2\pi)^{-\frac{D}{2}} |A + B|^{-\frac{1}{2}} \exp(\dots)$$

Le produit de deux densités n'est PAS une densité : il faut le facteur de normalisation c . C'est exactement ce qui se passe quand on multiplie **vraisemblance** $\times$ **a priori** dans Bayes (ch. 9).

SOMME de gaussiennes INDÉPENDANTES :

$$p(x + y) = \mathcal{N}(\mu_x + \mu_y, \Sigma_x + \Sigma_y)$$

Exemple 6.7 — somme pondérée (l'espérance étant linéaire) :

$$p(ax + by) = \mathcal{N}(a\mu_x + b\mu_y, a^2\Sigma_x + b^2\Sigma_y)$$

Les coefficients entrent **AU CARRÉ** dans la variance.

La distinction cruciale. « Un cas utile au chapitre 11 est la **somme pondérée de DENSITÉS gaussiennes**. C'est **DIFFÉRENT** de la somme pondérée de **VARIABLES ALÉATOIRES gaussiennes**. »

THÉORÈME 6.12 (MÉLANGE DE DEUX GAUSSIENNES UNIVARIÉES).

Pour

$$p(x) = \alpha p_1(x) + (1 - \alpha)p_2(x), \quad 0 < \alpha < 1$$

avec $(\mu_1, \sigma_1^2) \neq (\mu_2, \sigma_2^2)$:

$$\mathbb{E}[x] = \alpha\mu_1 + (1 - \alpha)\mu_2$$

$$\mathbb{V}[x] = \underbrace{\alpha\sigma_1^2 + (1 - \alpha)\sigma_2^2}_{\text{variance conditionnelle espérée}} + \underbrace{\alpha\mu_1^2 + (1 - \alpha)\mu_2^2 - [\alpha\mu_1 + (1 - \alpha)\mu_2]^2}_{\text{variance de la moyenne conditionnelle}}$$

La lecture. L'expression est un exemple de la **FORMULE DE LA VARIANCE CONDITIONNELLE**, aussi appelée **LOI DE LA VARIANCE TOTALE** :

$$\mathbb{V}_X[x] = \mathbb{E}_Y[\mathbb{V}_X[x | y]] + \mathbb{V}_Y[\mathbb{E}_X[x | y]]$$

« La variance (totale) de X est la **variance conditionnelle ESPÉRÉE** plus la **VARIANCE de la moyenne conditionnelle**. »

Avec $\alpha = 0,4$, $(\mu_1, \sigma_1) = (10; 1)$ et $(\mu_2, \sigma_2) = (0; 2,9)$, intégration numérique de $\int x p(x) dx$ et $\int x^2 p(x) dx$ sur $[-40, 50]$ avec 400 000 points (règle du point milieu) :

Quantité	Intégration numérique	Formule (6.81)/(6.82)
$\mathbb{E}[x]$	4,000000	4,000000
$\mathbb{V}[x]$	29,446	29,446

Noter que $\mathbb{V}[x] = 29,45$ est **bien supérieure** aux deux variances composantes (1 et 8,41) : c'est le **second terme**, l'écartement des moyennes, qui domine.

TRANSFORMATIONS LINÉAIRES. Pour $X \sim \mathcal{N}(\mu, \Sigma)$ et $y = Ax$:

$$p(y) = \mathcal{N}(y \mid A\mu, A\Sigma A^\top)$$

La règle générale. « *TOUTE transformation linéaire/affine d'une variable aléatoire gaussienne est gaussienne.* » Ajouter un vecteur constant **change la moyenne sans affecter la variance.**

La transformation INVERSE. Si $p(y) = \mathcal{N}(y \mid Ax, \Sigma)$ avec $A \in \mathbb{R}^{M \times N}$ de **rang plein**, $M \geq N$: en général A n'est pas inversible, on utilise l'approche de la **pseudo-inverse** — prémultiplier par $A^\top$ puis inverser $A^\top A$ (symétrique définie positive) :

$$y = Ax \iff (A^\top A)^{-1} A^\top y = x$$

$$p(x) = \mathcal{N}(x \mid (A^\top A)^{-1} A^\top y, (A^\top A)^{-1} A^\top \Sigma A (A^\top A)^{-1})$$

5.4 Échantillonner une gaussienne multivariée

Le protocole en trois étapes :

Étape 1. Une source de **nombre pseudo-aléatoires** donnant un échantillon **uniforme sur** $[0, 1]$.

Étape 2. Une transformation **non linéaire** — la **transformation de Box-Müller** (Devroye, 1986) — pour obtenir un échantillon d'une gaussienne **univariée**.

Étape 3. Assembler un vecteur de ces échantillons pour obtenir un échantillon de $\mathcal{N}(0, I)$.

Pour une gaussienne générale, on utilise la propriété des transformations linéaires : si $x \sim \mathcal{N}(0, I)$, alors

$$y = Ax + \mu \sim \mathcal{N}(\mu, \Sigma) \quad \text{où } AA^\top = \Sigma$$

Le choix commode de A : la **DÉCOMPOSITION DE CHOLESKY** de Σ (§4.3). Elle exige que la matrice soit **symétrique définie positive** — « *les matrices de covariance possèdent cette propriété* ».

● Concept 6 — Conjugaison et famille exponentielle (§6.6)

6.1 Les trois desiderata

Ce qu'on veut d'une famille de lois en apprentissage automatique :

1. Une **PROPRIÉTÉ DE CLÔTURE** en appliquant les règles de la probabilité (Bayes) : « l'opération renvoie un objet **du même TYPE** ».
2. En collectant plus de données, on n'a **PAS besoin de plus de paramètres** pour décrire la loi.
3. L'**estimation des paramètres** doit **bien se comporter**.

La réponse. « La classe de lois appelée **FAMILLE EXPONENTIELLE** fournit le **bon équilibre entre généralité** et propriétés favorables de calcul et d'inférence. »

6.2 Les trois lois nommées

Exemple 6.8 — la loi de BERNOULLI. Pour une seule variable binaire $x \in \{0, 1\}$, gouvernée par un paramètre continu $\mu \in [0, 1]$ (la probabilité de $X = 1$) :

$$p(x | \mu) = \mu^x(1 - \mu)^{1-x}, \quad \mathbb{E}[x] = \mu, \quad \mathbb{V}[x] = \mu(1 - \mu)$$

L'astuce d'écriture. « Cette réécriture, où l'on utilise les variables booléennes comme 0 ou 1 numériques **exprimés dans les EXPOSANTS**, est un truc souvent utilisé dans les manuels d'apprentissage automatique. » (Idem pour la multinomiale.)

Exemple 6.9 — la loi BINOMIALE. La généralisation à N tirages : la probabilité d'observer m occurrences de $X = 1$ sur N échantillons de Bernoulli de paramètre μ :

$$p(m | N, \mu) = \binom{N}{m} \mu^m (1 - \mu)^{N-m}, \quad \mathbb{E}[m] = N\mu, \quad \mathbb{V}[m] = N\mu(1 - \mu)$$

Exemple 6.10 — la loi BÊTA. Une loi sur une variable **continue** $\mu \in [0, 1]$, « souvent utilisée pour représenter la probabilité d'un événement binaire — par exemple le paramètre gouvernant une Bernoulli ».

Gouvernée par $\alpha > 0, \beta > 0$:

$$p(\mu \mid \alpha, \beta) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \mu^{\alpha-1} (1 - \mu)^{\beta-1}$$

$$\mathbb{E}[\mu] = \frac{\alpha}{\alpha + \beta}, \quad \mathbb{V}[\mu] = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$$

avec la **fonction Gamma**

$$\Gamma(t) := \int_0^\infty x^{t-1} \exp(-x) dx, \quad t > 0, \quad \Gamma(t+1) = t \Gamma(t)$$

La fraction de fonctions Gamma **normalise** la loi bêta.

L'intuition sur les paramètres. « α déplace la masse de probabilité **vers 1**, tandis que β la déplace **vers 0**. »

Les quatre cas particuliers :

Condition	Forme
$\alpha = 1 = \beta$	La loi UNIFORME $\mathcal{U}[0, 1]$
$\alpha, \beta < 1$	BIMODALE , avec des pics en 0 et en 1
$\alpha, \beta > 1$	UNIMODALE
$\alpha, \beta > 1$ et $\alpha = \beta$	Unimodale, symétrique , centrée : le mode/moyenne est en $\frac{1}{2}$

Bêta : $(\alpha, \beta) = (2, 3)$ donne $\mathbb{E} = 0,4$ et $\mathbb{V} = 0,04$; $(5, 1)$ donne $\mathbb{E} = 0,8333$ et $\mathbb{V} = 0,019841$;
 $(0,5; 0,5)$ donne $\mathbb{E} = 0,5$ et $\mathbb{V} = 0,125$ (cas bimodal, variance maximale)

Bernoulli avec $\mu = 0,3$: $\mathbb{E} = 0,3$, $\mathbb{V} = 0,21$

Binomiale avec $N = 15$, $\mu = 0,3$: $\mathbb{E} = 4,5$, $\mathbb{V} = 3,15$, et $\sum_{m=0}^{15} \binom{15}{m} 0,3^m 0,7^{15-m} = 1,0$
exactement

6.3 La conjugaison

DÉFINITION 6.13 (A PRIORI CONJUGUÉ).

« Un a priori est **CONJUGUÉ** pour la fonction de vraisemblance si l'**A POSTERIORI** est de la **MÊME FORME/DU MÊME TYPE** que l'a priori. »

POURQUOI C'EST DÉCISIF.

« La conjugaison est particulièrement commode car on peut calculer **ALGÈBRIQUEMENT** notre loi a posteriori **en METTANT À JOUR LES PARAMÈTRES** de la loi a priori. »

Les deux difficultés que cela résout : (i) « l'a priori devrait encapsuler notre connaissance avant de voir les données — c'est souvent difficile à décrire » ; (ii) « il est souvent impossible de calculer la loi a posteriori **ANALYTIQUEMENT** ».

Exemple 6.11 — la conjugaison BÊTA-BINOMIALE. Avec $x \sim \text{Bin}(N, \mu)$ et un a priori $\mu \sim \text{Beta}(\alpha, \beta)$, observant $x = h$ (h faces sur N lancers) :

$$\begin{aligned} p(\mu \mid x = h, N, \alpha, \beta) &\propto p(x \mid N, \mu) p(\mu \mid \alpha, \beta) \propto \mu^h (1 - \mu)^{N-h} \mu^{\alpha-1} (1 - \mu)^{\beta-1} \\ &= \mu^{h+\alpha-1} (1 - \mu)^{(N-h)+\beta-1} \end{aligned}$$

$$\propto \text{Beta}(h + \alpha, N - h + \beta)$$

La mise à jour est une simple ADDITION : $\alpha \leftarrow \alpha + h$ (le nombre de succès) et $\beta \leftarrow \beta + (N - h)$ (le nombre d'échecs).

Exemple 6.12 — la conjugaison BÊTA-BERNOULLI. Avec $p(x \mid \theta) = \theta^x (1 - \theta)^{1-x}$ et $p(\theta \mid \alpha, \beta) \propto \theta^{\alpha-1} (1 - \theta)^{\beta-1}$:

$$p(\theta \mid x, \alpha, \beta) \propto \theta^x (1 - \theta)^{1-x} \theta^{\alpha-1} (1 - \theta)^{\beta-1} = \theta^{\alpha+x-1} (1 - \theta)^{\beta+(1-x)-1}$$

$$\propto p(\theta \mid \alpha + x, \beta + (1 - x))$$

Le tableau 6.2 — les couples conjugués standard :

Vraisemblance	A priori conjugué	A posteriori
Bernoulli	Bêta	Bêta
Binomiale	Bêta	Bêta
Gaussienne (univariée)	Gaussienne / Gamma inverse	Gaussienne / Gamma inverse
Gaussienne (multivariée)	Gaussienne / Wishart inverse	Gaussienne / Wishart inverse
Multinomiale	Dirichlet	Dirichlet

Les précisions du livre. (i) La gaussienne apparaît **deux fois** car il faut distinguer univarié et multivarié. (ii) Dans le cas **scalaire**, la **Gamma inverse** est conjuguée pour la **variance** ; dans le cas **multivarié**, la **Wishart inverse** pour la **matrice de covariance**. (iii) De façon équivalente : « l'a priori **Gamma** est conjugué pour la **PRÉCISION** (variance inverse) dans la vraisemblance gaussienne univariée, et l'a priori **Wishart** pour la **matrice de précision** (covariance inverse) dans le cas multivarié. »

6.4 Statistiques exhaustives

L'idée de Sir Ronald Fisher. « Il existe des statistiques qui contiennent **TOUTE l'information disponible** qui peut être inférée des données correspondant à la loi considérée. Autrement dit, les **STATISTIQUES EXHAUSTIVES** portent toute l'information nécessaire pour faire de l'inférence sur la population. »

THÉORÈME 6.14 (FISHER-NEYMAN).

Soit X de densité $p(x | \theta)$. Les statistiques $\phi(x)$ sont **exhaustives** pour θ **si et seulement si** $p(x | \theta)$ peut s'écrire

$$p(x | \theta) = h(x) g_{\theta}(\phi(x))$$

où $h(x)$ est une loi **indépendante de θ** , et g_{θ} capture **toute la dépendance en θ via $\phi(x)$** .

Si $p(x | \theta)$ ne dépend pas de θ , alors $\phi(x)$ est **trivialement** exhaustive pour toute fonction ϕ . Le cas intéressant est celui où $p(x | \theta)$ ne dépend **que de $\phi(x)$** et pas de x lui-même.

La question qui mène à la famille exponentielle. « À mesure qu'on observe plus de données, a-t-on besoin de plus de paramètres θ pour décrire la loi ? **La réponse est OUI en général**, et c'est l'objet de la statistique NON PARAMÉTRIQUE. La question réciproque est : quelle classe de lois a des statistiques exhaustives **de dimension FINIE** ? La réponse : **les lois de la FAMILLE EXPONENTIELLE**. »

6.5 La famille exponentielle

L'anecdote historique. « Dans les années 1935-1936, **Edwin Pitman** en Tasmanie, **Georges Darmois** à Paris et **Bernard Koopman** à New York ont montré INDÉPENDAMMENT que les familles exponentielles sont **les SEULES familles** à jouir de statistiques exhaustives de dimension finie sous échantillonnage indépendant répété. »

La forme générale. Une **famille exponentielle** est une famille de lois paramétrées par $\theta \in \mathbb{R}^D$ de la forme

$$p(x | \theta) = h(x) \exp (\langle \theta, \phi(x) \rangle - A(\theta))$$

où $\phi(x)$ est le **vecteur des STATISTIQUES EXHAUSTIVES** et $A(\theta)$ la constante de normalisation, appelée la **FONCTION DE LOG-PARTITION**.

Les trois niveaux d'abstraction, à distinguer :

Niveau	Objet	Exemple
1 (le plus concret)	Une loi nommée à paramètres FIXÉS	$\mathcal{N}(0, 1)$
2 (le plus courant en ML)	Forme paramétrique fixée, paramètres INFÉRÉS des données	$\mathcal{N}(\mu, \sigma^2)$ ajustée par maximum de vraisemblance
3	Des FAMILLES de lois	La famille exponentielle

Simplifications. Le facteur $h(x)$ peut être **absorbé dans le produit scalaire** en ajoutant l'entrée $\log h(x)$ à $\phi(x)$ et en contraignant $\theta_0 = 1$. En ignorant les deux termes annexes :

$$p(x | \theta) \propto \exp(\theta^\top \phi(x))$$

Dans cette paramétrisation, les θ sont les **PARAMÈTRES NATURELS**.

Exemple 6.13 — la GAUSSIENNE comme famille exponentielle. Avec $\phi(x) = [x, x^2]^\top$:

$$p(x | \theta) \propto \exp(\theta_1 x + \theta_2 x^2)$$

En posant

$$\theta = \left[\frac{\mu}{\sigma^2}, -\frac{1}{2\sigma^2} \right]^\top$$

on retrouve $p(x | \theta) \propto \exp\left(\frac{\mu x}{\sigma^2} - \frac{x^2}{2\sigma^2}\right) \propto \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$.

Exemple 6.14 — la BERNOULLI comme famille exponentielle.

$$p(x | \mu) = \mu^x (1 - \mu)^{1-x} = \exp [x \log \mu + (1 - x) \log(1 - \mu)] = \exp \left[x \log \frac{\mu}{1 - \mu} + \log(1 - \mu) \right]$$

D'où l'identification :

$$h(x) = 1, \quad \theta = \log \frac{\mu}{1 - \mu}, \quad \phi(x) = x, \quad A(\theta) = -\log(1 - \mu) = \log(1 + \exp(\theta))$$

Et la relation **inversible** :

$$\mu = \frac{1}{1 + \exp(-\theta)}$$

LA SIGMOÏDE. *« La relation entre le paramètre original μ et le paramètre naturel θ est connue sous le nom de **SIGMOÏDE** ou **fonction LOGISTIQUE**. Observer que $\mu \in (0, 1)$ mais $\theta \in \mathbb{R}$: la sigmoïde **COMPRI**ME un réel dans l'intervalle $(0, 1)$. »* Elle sert en **régression logistique** et comme **fonction d'activation non linéaire** dans les réseaux de neurones.

θ	$\mu = \frac{1}{1 + e^{-\theta}}$	$\log \frac{\mu}{1 - \mu}$	$A(\theta) = \log(1 + e^\theta)$	$-\log(1 - \mu)$
-2,0	0,119203	-2,000000	0,126928	0,126928
0,0	0,500000	0,000000	0,693147	0,693147
1,5	0,817574	1,500000	1,701413	1,701413

Les deux expressions de $A(\theta)$ coïncident exactement, et la sigmoïde inverse bien le logit

L'a priori conjugué GÉNÉRAL. « *Tout membre de la famille exponentielle* **A UN A PRIORI CONJUGUÉ** (Brown, 1986) » :

$$p(\theta \mid \gamma) = h_c(\theta) \exp \left(\left\langle \begin{bmatrix} \gamma_1 \\ \gamma_2 \end{bmatrix}, \begin{bmatrix} \theta \\ -A(\theta) \end{bmatrix} \right\rangle - A_c(\gamma) \right)$$

où γ a la dimension $\dim(\theta) + 1$, et les statistiques exhaustives de l'a priori conjugué sont $\begin{bmatrix} \theta \\ -A(\theta) \end{bmatrix}$.

L'apport pratique. « *Il est souvent peu évident de trouver la forme paramétrique de la loi conjuguée d'une loi donnée. Les familles exponentielles fournissent une façon COMMUNE de TROUVER des couples conjugués.* »

Exemple 6.15 — l'a priori conjugué canonique de la Bernoulli. Avec $\gamma := [\alpha, \beta + \alpha]^\top$ et $h_c(\mu) := \mu/(1 - \mu)$:

$$p(\mu \mid \alpha, \beta) = \frac{\mu}{1 - \mu} \exp \left(\alpha \log \frac{\mu}{1 - \mu} + (\beta + \alpha) \log(1 - \mu) - A_c(\gamma) \right)$$

— on retrouve la forme d'une **BÊTA**.

● Concept 7 — Changement de variables (§6.7)

7.1 Le problème

La motivation. « Il semble y avoir beaucoup de lois connues, mais en réalité l'ensemble des lois **qui ont un NOM est assez limité**. Il est donc utile de comprendre comment sont distribuées les variables aléatoires **TRANSFORMÉES**. » Exemples : si $X \sim \mathcal{N}(0, 1)$, quelle est la loi de X^2 ? Si X_1, X_2 sont normales standard, quelle est la loi de $\frac{1}{2}(X_1 + X_2)$?

Calculer moyenne et variance **ne suffit pas** : « on peut ne pas être capable d'obtenir la **FORME FONCTIONNELLE** de la loi sous transformation. »

7.2 Le cas discret — direct

Pour X discrète de pmf $P(X = x)$ et U **inversible**, avec $Y := U(X)$:

$$P(Y = y) = P(U(X) = y) = P(X = U^{-1}(y))$$

« Pour les variables discrètes, les transformations **changent directement les événements individuels** (avec les probabilités transformées de façon appropriée). » Il faut garder en tête que le **DOMAINE** peut avoir changé.

7.3 Le cas continu — l'approche par la cdf

Exemple 6.16 — la recette en cinq lignes. Soit X continue de densité $f(x) = 3x^2$ sur $0 \leq x \leq 1$. On cherche la densité de $Y = X^2$.

Étape 1 — définition de la cdf : $F_Y(y) = P(Y \leq y)$

Étape 2 — transformation d'intérêt : $= P(X^2 \leq y)$

Étape 3 — inverse : $= P(X \leq y^{1/2}) = F_X(y^{1/2})$

Étape 4 — cdf comme intégrale définie : $= \int_0^{y^{1/2}} 3t^2 dt = [t^3]_0^{y^{1/2}}$

Étape 5 — résultat :

$$F_Y(y) = y^{3/2}, \quad 0 \leq y \leq 1$$

Étape 6 — dériver pour obtenir la densité :

$$f(y) = \frac{d}{dy} F_Y(y) = \frac{3}{2} y^{1/2}, \quad 0 \leq y \leq 1$$

y	$\int_0^{\sqrt{y}} 3t^2 dt$ (numérique)	$y^{3/2}$	$f_Y(y)$ (dérivée num.)	$\frac{3}{2} \sqrt{y}$
0,25	0,125000	0,125000	0,750000	0,750000
0,50	0,353553	0,353553	1,060660	1,060660
0,81	0,729000	0,729000	1,350000	1,350000

Les fonctions ayant un inverse sont dites **BIJECTIVES** (§2.7). Le livre insiste sur le fait que $f(x) = 3x^2$ est **strictement croissante** sur le domaine considéré, ce qui rend l'inverse calculable.

7.4 La transformation intégrale de probabilité

THÉORÈME 6.15.

Soit X continue de **fonction de répartition STRICTEMENT MONOTONE** $F_X(x)$. Alors

$$Y := F_X(X) \quad \text{a une loi UNIFORME}$$

Ses trois usages :

1. **Échantillonnage** — « l'algorithme fonctionne en générant d'abord un échantillon uniforme, puis en le transformant par la **cdf INVERSE** (si elle est disponible) pour obtenir un échantillon de la loi désirée. »
2. **Tests d'hypothèses** — savoir si un échantillon vient d'une loi particulière (Lehmann & Romano, 2005).
3. **Copules** (Nelsen, 2006) — l'idée que la sortie d'une cdf donne une uniforme en est la base.

7.5 Le changement de variables — la formule générale

Cas UNIVARIÉ :

$$f(y) = f_x(U^{-1}(y)) \cdot \left| \frac{d}{dy} U^{-1}(y) \right|$$

POURQUOI LA VALEUR ABSOLUE.

« On a supposé U strictement croissante. Pour des fonctions décroissantes, il se trouve qu'on obtient un **SIGNE NÉGATIF** en suivant la même dérivation. On introduit la valeur absolue pour avoir la **MÊME EXPRESSION dans les deux cas**. »

CE QUE MESURE LE FACTEUR.

« Le terme $\left| \frac{d}{dy} U^{-1}(y) \right|$ mesure **de combien un volume unité change** quand on applique U » — c'est exactement le rôle de la jacobienne (§5.3). « Par comparaison au cas discret, on a un **FACTEUR SUPPLÉMENTAIRE**. »

Cas MULTIVARIÉ :

THÉORÈME 6.16.

Soit $f(x)$ la densité de la variable multivariée continue X . Si la fonction vectorielle $y = U(x)$ est **différentiable et inversible** pour toutes les valeurs du domaine de x , alors

$$f(y) = f_x(U^{-1}(y)) \cdot \left| \det \frac{\partial}{\partial y} U^{-1}(y) \right|$$

POURQUOI LE DÉTERMINANT ET NON LA VALEUR ABSOLUE.

« La valeur absolue ne peut pas être utilisée pour les fonctions multivariées. À la place, on utilise le **déterminant de la matrice JACOBIENNE**. Le déterminant apparaît parce que nos différentielles (des cubes de volume) sont **transformées en PARALLÉLÉPIPÈDES** par la jacobienne. »

La recette en trois pas : (1) trouver la **transformation inverse** ; (2) la **substituer** dans la densité de $\mathbf{x}$; (3) calculer le **déterminant de la jacobienne** et **multiplier**.

Exemple 6.17 — la gaussienne standard bivariée transformée. Avec

$$f\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \frac{1}{2\pi} \exp\left(-\frac{1}{2} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}^\top \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}\right)$$

et $\mathbf{y} = \mathbf{A}\mathbf{x}$ avec $\mathbf{A} = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$:

Étape 1 — l'inverse : $\mathbf{x} = \mathbf{A}^{-1}\mathbf{y} = \frac{1}{ad-bc} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix} \mathbf{y}$. $ad-bc$ est le **déterminant** de $\mathbf{A}$.

Étape 2 — substituer : $f(\mathbf{A}^{-1}\mathbf{y}) = \frac{1}{2\pi} \exp\left(-\frac{1}{2} \mathbf{y}^\top \mathbf{A}^{-\top} \mathbf{A}^{-1} \mathbf{y}\right)$

Étape 3 — la jacobienne : la dérivée partielle d'une matrice fois un vecteur par rapport au vecteur **est la matrice elle-même** (§5.5), donc $\frac{\partial}{\partial \mathbf{y}} \mathbf{A}^{-1} \mathbf{y} = \mathbf{A}^{-1}$, et le déterminant de l'inverse est l'inverse du déterminant :

$$\det\left(\frac{\partial}{\partial \mathbf{y}} \mathbf{A}^{-1} \mathbf{y}\right) = \frac{1}{ad-bc}$$

Le résultat :

$$f(\mathbf{y}) = \frac{1}{2\pi} \exp\left(-\frac{1}{2} \mathbf{y}^\top \mathbf{A}^{-\top} \mathbf{A}^{-1} \mathbf{y}\right) |ad-bc|^{-1}$$

La lecture finale du livre. *« La densité $f(\mathbf{x})$ est en fait la gaussienne standard, et la densité transformée $f(\mathbf{y})$ est une **gaussienne bivariée de COVARIANCE** $\Sigma = \mathbf{A}\mathbf{A}^\top$. »* On retrouve exactement la règle du §6.5.3 — mais **dérivée depuis les premiers principes**.

Comment reconnaître le type d'exercice

L'énoncé dit...	Le type	La méthode
« Décrire l'univers, les événements »	§6.1.2	Ω = tous les résultats ; $\mathcal{A}$ = les parties observables ; $X : \Omega \rightarrow \mathcal{T}$
« Calculer $P(X = k)$ »	pmf	Compter les antécédents dans Ω ; plusieurs résultats peuvent donner le même k
« La marginale de X »	Règle de la somme	Sommer/intégrer sur tout ce qu'on ne veut pas
« La conditionnelle $p(y x)$ »	Règle du produit	$p(x, y)/p(x)$; en discret : la fraction d'une colonne
« Sachant qu'on a observé... quelle est la probabilité que... »	Bayes	$p(x y) = p(y x)p(x)/p(y)$; identifier a priori, vraisemblance, évidence
« Calculer $\mathbb{E}[g(X)]$ »	Déf. 6.3	$\int g(x)p(x)dx$ ou $\sum g(x)p(x)$
« Moyenne, médiane, mode »	§6.4.1	Moyenne = espérance ; médiane = cdf = 0,5 ; mode = pic de la densité
« Calculer la covariance / variance »	Déf. 6.5-6.7	$\mathbb{E}[xy] - \mathbb{E}[x]\mathbb{E}[y]$; contrôle : matrice symétrique, semi-définie positive
« Que devient la loi après $y = Ax + b$? »	§6.4.4	$\mathbb{E} = A\mu + b$, $\mathbb{V} = A\Sigma A^T$; si gaussienne, le résultat reste gaussien
« X et Y sont-elles indépendantes ? »	Déf. 6.10	Vérifier $p(x, y) = p(x)p(y)$; Cov = 0 ne suffit PAS
« Marginale/conditionnelle d'une gaussienne »	§6.5.1	Marginale : prendre le bloc . Conditionnelle : $\mu_x + \Sigma_{xy}\Sigma_{yy}^{-1}(y - \mu_y)$ et $\Sigma_{xx} - \Sigma_{xy}\Sigma_{yy}^{-1}\Sigma_{yx}$
« Somme de gaussiennes indépendantes »	§6.5.3	Moyennes et covariances s'ajoutent ; pour $ax + by$, les coefficients entrent au carré dans la variance
« Moyenne/variance d'un mélange »	Th. 6.12	Moyenne : somme pondérée. Variance : DEUX termes (variance conditionnelle espérée + variance des moyennes)
« Échantillonner $\mathcal{N}(\mu, \Sigma)$ »	§6.5.4	$\mathcal{N}(0, I)$ puis $y = Ax + \mu$ avec $AA^T = \Sigma$ par Cholesky

L'énoncé dit...	Le type	La méthode
« Quel a priori choisir ? »	Déf. 6.13	Le conjugué : bêta pour Bernoulli/binomiale, gaussien pour la moyenne gaussienne, Dirichlet pour multinomiale
« Mettre à jour l'a posteriori »	Ex. 6.11-6.12	Bêta-binomiale : $\alpha \rightarrow \alpha + h, \beta \rightarrow \beta + (N - h)$
« Cette loi est-elle dans la famille exponentielle ? »	§6.6.3	La mettre sous la forme $h(x) \exp(\langle \theta, \phi(x) \rangle - A(\theta))$; identifier ϕ et θ
« Quelle est la loi de $Y = U(X)$? »	§6.7	Discret : $P(X = U^{-1}(y))$. Continu : passer par la cdf , ou la formule avec $ dU^{-1}/dy $
« Cas multivarié de la transformation »	Th. 6.16	$f_x(U^{-1}(y)) \cdot \det \partial U^{-1}/\partial y $

Comment résoudre : les cinq méthodes pas-à-pas

Méthode A — Un problème de Bayes.

1. **Nommer** les variables : quelle est la latente x ? l'observée y ?
2. Écrire l'a priori $p(x)$ — vérifier qu'il est **non nul sur tous les x plausibles**.
3. Écrire la **vraisemblance** $p(y | x)$ — c'est une fonction de y , **pas une loi en x** .
4. Calculer l'**évidence** $p(y) = \int p(y | x)p(x)dx$ — ou reconnaître qu'elle **normalise** simplement.
5. Combiner : $p(x | y) \propto p(y | x)p(x)$.
6. **Contrôle** : l'a posteriori intègre-t-il à 1 ?

Méthode B — Conditionnement gaussien.

1. Écrire la loi jointe en **blocs** : $\mu = [\mu_x; \mu_y]$ et $\Sigma = \begin{bmatrix} \Sigma_{xx} & \Sigma_{xy} \\ \Sigma_{yx} & \Sigma_{yy} \end{bmatrix}$.
2. Marginale de x : **prendre directement** $\mathcal{N}(\mu_x, \Sigma_{xx})$.
3. Conditionnelle : calculer $K := \Sigma_{xy}\Sigma_{yy}^{-1}$ (le « **gain** », comme dans Kalman).
4. $\mu_{x|y} = \mu_x + K(y - \mu_y)$ et $\Sigma_{x|y} = \Sigma_{xx} - K\Sigma_{yx}$.
5. **Contrôles** : $\Sigma_{x|y} \preceq \Sigma_{xx}$ (conditionner **réduit** la variance) ; si $\Sigma_{xy} = 0$, on retrouve la marginale.

Méthode C — Statistiques d'une transformation.

1. Si la transformation est **affine** et la loi **gaussienne** : appliquer directement $A\mu + b$ et $A\Sigma A^T$. Fin.
2. Sinon, si l'on veut seulement les **moments** : utiliser la linéarité de $\mathbb{E}$ et les identités (6.46)-(6.52).

3. Si l'on veut la **loi entière** : passer au changement de variables (méthode D).

Méthode D — Changement de variables.

1. Vérifier que U est **différentiable et inversible** sur le domaine.
2. Calculer explicitement $x = U^{-1}(y)$.
3. Substituer : $f_x(U^{-1}(y))$.
4. Calculer la **jacobienn**e $\partial U^{-1}/\partial y$ puis $|\det|$.
5. Multiplier. **Ne pas oublier de recalculer le DOMAINE** de y .
6. **Contrôle** : $\int f(y)dy = 1$.

Méthode E — Mise à jour conjuguée.

1. Identifier la **vraisemblance** et chercher son conjugué dans le tableau 6.2.
2. Écrire a priori et vraisemblance **en gardant seulement les termes en le paramètre** (le $\propto$ suffit).
3. **Regrouper les exposants** de même base.
4. **Lire** les nouveaux paramètres.
5. **Contrôle** : la forme obtenue est-elle bien celle de l'a priori ?

● Common mistakes

Erreur	Correction
Croire qu'une variable aléatoire est une variable	« <i>Ni aléatoire ni une variable</i> — c'est une FONCTION » $X : \Omega \rightarrow \mathcal{T}$
Confondre Ω , $\mathcal{T}$ et X	Ω = les résultats bruts ; $\mathcal{T}$ = les quantités d'intérêt ; X = la fonction qui relie les deux
Croire qu'une densité est ≤ 1	FAUX . Seules les pmf sont dans $[0, 1]$. Une densité sur $[0,9; 1,6]$ vaut $1/0,7 \approx 1,43$
Écrire $P(X = x) > 0$ pour X continue	$P(X = x) = 0$ — c'est un ensemble de mesure nulle
Confondre densité et loi	La densité est une fonction ; la loi est l'association de X à cette densité. Il existe des cdf sans pdf
Appeler $p(y x)$ « la vraisemblance de y »	JAMAIS . C'est la « vraisemblance de x sachant y » ou « la probabilité de y sachant x »
Traiter la vraisemblance comme une loi en x	Elle n'est PAS normalisée en x : $\int p(y x) dx \neq 1$ en général
Oublier l'évidence dans Bayes	Elle normalise l'a posteriori ; elle est indépendante de x mais souvent difficile à calculer
Résumer l'a posteriori par son maximum	PERTE D'INFORMATION ; le livre cite des échecs systématiques en apprentissage par renforcement
Croire que $\text{Cov} = 0$ implique l'indépendance	FAUX . La covariance ne mesure que la dépendance LINÉAIRE . Contre-exemple 6.5 : $y = x^2$
Croire que la moyenne est toujours représentative	Pour une loi bimodale , la moyenne peut ne tomber près d'aucun mode (exemple 6.4)
Définir la médiane multivariée composante par composante	Il n'existe pas d'ORDRE naturel en dimension > 1
Écrire $\mathbb{V}[x - y] = \mathbb{V}[x] - \mathbb{V}[y]$	C'est $\mathbb{V}[x] + \mathbb{V}[y] - \text{Cov}[x, y] - \text{Cov}[y, x]$ — les variances S'AJOUTENT
Écrire $\mathbb{V}[Ax] = A\Sigma$	C'est $A\Sigma A^T$ — il faut les deux côtés
Croire que b affecte la variance dans $Ax + b$	Non : une translation ne change pas la dispersion

Erreur	Correction
Utiliser N au dénominateur de la covariance en croyant que c'est non biaisé	La version du livre est BIAISÉE ; la corrigée utilise $N - 1$
Implémenter la formule brute de la variance sans précaution	NUMÉRIQUEMENT INSTABLE si les deux termes sont grands et proches
Écrire $\mu_{x y} = \mu_x + \Sigma_{yy}^{-1} \Sigma_{xy} (y - \mu_y)$	L'ordre est $\Sigma_{xy} \Sigma_{yy}^{-1}$ — vérifier les dimensions
Croire que $\Sigma_{x y}$ dépend de y	NON : elle est constante . Seule la moyenne dépend de l'observation
Confondre somme de variables et somme de densités	La première donne une gaussienne ; la seconde donne un MÉLANGE , généralement multimodal
Oublier le second terme de la variance d'un mélange	$\mathbb{V}$ = variance conditionnelle espérée + variance des moyennes (loi de la variance totale)
Croire que le produit de deux densités gaussiennes est une densité	C'est une gaussienne MISE À L'ÉCHELLE par c
Utiliser Σ au lieu de A pour échantillonner	Il faut A tel que $AA^T = \Sigma$ — la CHOLESKY de Σ
Chercher un a priori conjugué à la main	Utiliser le tableau 6.2, ou la construction générale des familles exponentielles
Croire qu'un a priori conjugué existe toujours	Il existe pour tout membre de la famille exponentielle — mais pas pour n'importe quelle loi
Oublier le facteur jacobien en changement de variables	Le cas continu exige $ dU^{-1}/dy $; le cas discret non
Utiliser la valeur absolue en multivarié	Utiliser le DÉTERMINANT de la jacobienne
Oublier de recalculer le domaine après transformation	« <i>Le domaine de la variable aléatoire peut avoir changé du fait de la transformation</i> »
Appliquer $Y = F_X(X)$ sans monotonie stricte	Le théorème 6.15 exige une cdf strictement monotone

Ultimate Review

===== LES DIX FORMULES À SAVOIR SANS HÉSITER =====

1. SOMME $p(x) = \sum_y p(x,y)$ ou $\int p(x,y) dy$

2. PRODUIT $p(x,y) = p(y|x) p(x) = p(x|y) p(y)$
 3. BAYES $p(x|y) = p(y|x) p(x) / p(y)$
postérieur = vraisemblance × a priori / évidence
 4. Cov[x,y] = E[xy] - E[x]E[y] V[x] = E[x²] - (E[x])²
 5. AFFINE $E[Ax+b] = A\mu+b$ V[Ax+b] = A Σ A^T Cov[x,Ax+b] = Σ A^T
 6. corr[x,y] = Cov[x,y]/√(V[x]V[y]) ∈ [-1,1] = COSINUS de l'angle
 7. GAUSSIENNE $p(x|\mu,\Sigma) = (2\pi)^{-D/2} |\Sigma|^{-1/2} \exp(-\frac{1}{2}(x-\mu)^T \Sigma^{-1} (x-\mu))$
 8. MARGINALE $p(x) = N(\mu_x, \Sigma_{xx})$ ← prendre le BLOC
CONDITIONNELLE $\mu_{\{x|y\}} = \mu_x + \Sigma_{xy} \Sigma_{yy}^{-1} (y - \mu_y)$
 $\Sigma_{\{x|y\}} = \Sigma_{xx} - \Sigma_{xy} \Sigma_{yy}^{-1} \Sigma_{yx}$
 9. FAMILLE EXP. $p(x|\theta) = h(x) \exp(\langle \theta, \phi(x) \rangle - A(\theta))$
Bernoulli : $\theta = \log(\mu/(1-\mu))$, $\mu = 1/(1+e^{-\theta})$ ← SIGMOÏDE
 10. CHANGT VAR. $f(y) = f_x(U^{-1}(y)) \cdot |\det \partial U^{-1}/\partial y|$
-

Le tableau discret / continu :

	Discret	Continu
Espace cible	Fini ou dénombrable	$\mathbb{R}$ ou $\mathbb{R}^D$
« Probabilité ponctuelle »	$P(X = x)$ — pmf	$p(x)$ — densité , mais $P(X = x) = 0$
« Probabilité d'intervalle »	Sans objet	$P(X \leq x)$ — cdf
Normalisation	$\sum_x P(X = x) = 1$	$\int f(x) dx = 1$
Borne sur les valeurs	∈ [0,1]	PEUT dépasser 1
Marginalisation	Somme	Intégrale
Changement de variables	$P(X = U^{-1}(y))$	× facteur jacobien

Le dictionnaire géométrie / probabilité :

Géométrie (ch. 3)	Probabilité (ch. 6)
Produit intérieur	Covariance
Norme	Écart-type
Angle (cos)	Corrélation
Orthogonalité	Non-corrélation
Pythagore	$\mathbb{V}[x + y] = \mathbb{V}[x] + \mathbb{V}[y]$
Vecteur nul	Variable déterministe

Les propriétés qui font la gaussienne :

Opération	Résultat
Marginaliser	Reste gaussienne — il suffit de prendre le bloc
Conditionner	Reste gaussienne — formules fermées
Somme (variables indépendantes)	Gaussienne, paramètres additifs
Transformation affine	Gaussienne, $A\mu + b$ et $A\Sigma A^T$
Produit de densités	Gaussienne mise à l'échelle
Mélange de densités	PAS gaussienne — multimodale

Où chaque notion resservira dans le livre :

Notion du ch. 6	Suite
Gaussienne, vraisemblance et a priori	Régression linéaire (ch. 9)
Mélange de gaussiennes	Estimation de densité (ch. 11)
Bayes, a posteriori	Modélisation probabiliste (§8.4), sélection de modèle (§8.6)
Loi jointe, factorisation	Modèles graphiques (§8.5)
Conditionnelles gaussiennes	ACP probabiliste (§10.7), filtre de Kalman, processus gaussiens
Changement de variables, jacobien	Reparamétrisation , auto-encodeurs variationnels
Famille exponentielle, sigmoïde	Régression logistique , activations de réseaux, noyaux (ch. 12)

Active Recall

Espace probabilisé

1. Quels sont les trois concepts de Kolmogorov ? Que vaut $P(\Omega)$?
2. Qu'est-ce qu'une variable aléatoire ? Pourquoi le nom est-il trompeur ?
3. Écrire $P_X(S)$ en fonction de l'image réciproque.
4. Qu'est-ce que la loi d'une variable aléatoire ?
5. Distinguer les interprétations bayésienne et fréquentiste.
6. Citer les trois critères de Jaynes.
7. Distinguer probabilité et statistique en une phrase chacune.
8. Dans l'exemple 6.1, pourquoi $P(X = 1) = 0,42$ et non $0,21$?

Discret et continu 9. Que sont pmf, pdf, cdf ? Compléter le tableau 6.1. 10. Écrire les deux conditions de la définition 6.1. 11. Une densité peut-elle dépasser 1 ? Donner l'exemple du livre. 12. Que vaut $P(X = x)$ pour X continue ? Pourquoi ? 13. Distinguer la densité et la loi. 14. Comment lit-on marginales et conditionnelles sur une table discrète ?

Les deux règles et Bayes 15. Écrire la règle de la somme dans les deux cas. Quel est son autre nom ? 16. Quel est le défi computationnel qu'elle pose ? 17. Écrire la règle du produit. Pourquoi y a-t-il deux factorisations ? 18. Écrire Bayes et nommer les quatre termes. 19. Quelle est la mise en garde sur le mot « vraisemblance » ? 20. Écrire l'évidence. Donner ses trois interprétations. 21. Pourquoi ne pas résumer l'a posteriori à son maximum ?

Statistiques résumées 22. Écrire la définition de l'espérance dans les deux cas. 23. Pourquoi la moyenne est-elle un cas particulier ? 24. L'espérance est-elle linéaire ? Le montrer. 25. Définir médiane et mode. Quels sont leurs avantages et difficultés ? 26. Écrire les deux expressions de la covariance. 27. Écrire la variance multivariée. Quelles sont les trois propriétés de la matrice de covariance ? 28. Définir la corrélation. Dans quel intervalle vit-elle ? 29. Écrire moyenne et covariance empiriques. Le livre utilise-t-il la version biaisée ? 30. Donner les trois expressions de la variance. Quel est l'avantage et le danger de la deuxième ? 31. Écrire $\mathbb{E}$ et $\mathbb{V}$ pour $x \pm y$ et pour $Ax + b$. 32. Que devient $\text{Cov}[x, Ax + b]$?

Indépendance et géométrie 33. Définir l'indépendance. Donner ses quatre conséquences. 34. L'implication « $\text{Cov} = 0 \Rightarrow$ indépendance » est-elle vraie ? Donner le contre-exemple. 35. Que signifie i.i.d. exactement ? 36. Définir l'indépendance conditionnelle. Donner sa forme équivalente. 37. Compléter le dictionnaire géométrie/probabilité. 38. À quoi correspond la corrélation géométriquement ?

Gaussienne 39. Écrire les densités univariée et multivariée. 40. Qu'est-ce que la loi normale standard ? 41. Quel théorème explique son omniprésence ? 42. Écrire la marginale et la conditionnelle d'une gaussienne jointe. 43. Dans l'exemple 6.6, que valent la moyenne et la variance conditionnelles ? 44. Pourquoi la variance conditionnelle ne dépend-elle pas de y ? 45. Citer trois algorithmes qui reposent sur les conditionnelles gaussiennes. 46. Que donne le produit de deux densités gaussiennes ? 47. Que donne la somme de deux gaussiennes indépendantes ? Et $ax + by$? 48. Énoncer le théorème 6.12. Quel est le nom de la formule sous-jacente ? 49. Décrire les trois étapes de l'échantillonnage. 50. Quel est le rôle de Cholesky ?

Conjugaison et famille exponentielle 51. Quels sont les trois desiderata ? 52. Écrire Bernoulli, binomiale et bêta avec leurs moments. 53. Quels sont les quatre cas particuliers de la bêta ? 54. Définir un a priori conjugué. Pourquoi est-ce commode ? 55. Dérivée la conjugaison bêta-binomiale. 56. Compléter le tableau 6.2. 57. Qu'est-ce qu'une statistique exhaustive ? Énoncer Fisher-Neyman. 58. Écrire la forme de la famille exponentielle. Nommer chaque terme. 59. Donner ϕ et θ pour la gaussienne. Pour la Bernoulli. 60. Qu'est-ce que la sigmoïde ? Que fait-elle ? 61. Quel résultat historique de 1935-1936 caractérise les familles exponentielles ?

Changement de variables 62. Écrire la transformation dans le cas discret. 63. Détailler les six étapes de l'exemple 6.16. 64. Énoncer le théorème 6.15. Citer ses trois usages. 65. Écrire la formule univariée. Pourquoi la valeur absolue ? 66. Écrire le théorème 6.16. Pourquoi le déterminant ? 67. Dans l'exemple 6.17, que vaut la covariance de la loi transformée ?

Flashcards

Question	Réponse
Les trois concepts de Kolmogorov ?	Univers Ω · tribu des événements $\mathcal{A}$ · probabilité P
Que vaut $P(\Omega)$?	1
Qu'est-ce qu'une variable aléatoire ?	Une FONCTION $X : \Omega \rightarrow \mathcal{T}$ — ni aléatoire ni une variable
Espace cible ?	$\mathcal{T}$, l'ensemble des quantités d'intérêt
Loi de X ?	$P_X = P \circ X^{-1}$, avec $P_X(S) = P(X^{-1}(S))$
Variable discrète ?	$\mathcal{T}$ fini ou dénombrable
Variable continue ?	$\mathcal{T} = \mathbb{R}$ ou $\mathbb{R}^D$
Interprétation bayésienne ?	Le degré de croyance , la « probabilité subjective »
Interprétation fréquentiste ?	La fréquence relative à la limite d'une infinité de données
Probabilité contre statistique ?	Probabilité : du modèle vers les données . Statistique : des données vers le processus
Ce que le théorème de Cox-Jaynes prouve ?	Les règles de la plausibilité SONT les règles de la probabilité, à fonction monotone près
Fonction de masse (pmf) ?	$P(X = x)$, cas discret
Fonction de densité (pdf) ?	$p(x)$, cas continu — elle peut dépasser 1
Fonction de répartition (cdf) ?	$P(X \leq x)$
Les deux conditions d'une densité ?	$f(x) \geq 0 \cdot \int f(x)dx = 1$
$P(X = x)$ pour X continue ?	ZÉRO — ensemble de mesure nulle
Marginale sur une table discrète ?	La somme d'une ligne ou d'une colonne
Conditionnelle sur une table ?	$P(Y = y_j \mid X = x_i) = n_{ij}/c_i$ — la fraction d'une colonne
Règle de la somme ?	$p(x) = \sum_y p(x, y)$ ou $\int p(x, y)dy$
Son autre nom ?	La MARGINALISATION

Question	Réponse
Son défi ?	Somme/intégrale de grande dimension — pas d'algorithme polynomial connu
Règle du produit ?	$p(x, y) = p(y x)p(x) = p(x y)p(y)$
Théorème de Bayes ?	$p(x y) = \frac{p(y x)p(x)}{p(y)}$
A priori ?	$p(x)$ — la connaissance AVANT de voir les données
Vraisemblance ?	$p(y x)$ — PAS une loi en x ; aussi appelée le modèle de mesure
A posteriori ?	$p(x y)$ — ce qu'on sait APRÈS avoir observé
Évidence ?	$p(y) = \int p(y x)p(x)dx = \mathbb{E}_X[p(y x)]$
Ses trois rôles ?	Normalise l'a posteriori · vraisemblance espérée sous l'a priori · sélection de modèle
Autre nom du théorème de Bayes ?	L' INVERSE PROBABILISTE
Danger de résumer l'a posteriori ?	Perte d'information — échecs systématiques en apprentissage par renforcement
Espérance ?	$\mathbb{E}_X[g(x)] = \int g(x)p(x)dx$ ou $\sum g(x)p(x)$
Son autre nom cocasse ?	La loi du statisticien inconscient
Moyenne ?	L'espérance avec $g = \text{identité}$
L'espérance est-elle linéaire ?	OUI : $\mathbb{E}[ag + bh] = a\mathbb{E}[g] + b\mathbb{E}[h]$
Médiane ?	La valeur où la cdf vaut 0,5
Ses deux avantages ?	Plus proche de l' intuition pour les lois asymétriques · plus ROBUSTE aux valeurs extrêmes
Sa difficulté ?	Pas d' ORDRE naturel en dimension > 1
Mode ?	La valeur la plus fréquente ; en continu, un pic de la densité
Sa difficulté ?	Il peut y en avoir beaucoup en grande dimension
Covariance ?	$\text{Cov}[x, y] = \mathbb{E}[xy] - \mathbb{E}[x]\mathbb{E}[y]$

Question	Réponse
Variance multivariée ?	$\mathbb{V}[\mathbf{x}] = \mathbb{E}[\mathbf{x}\mathbf{x}^\top] - \mathbb{E}[\mathbf{x}]\mathbb{E}[\mathbf{x}]^\top$
Trois propriétés de la matrice de covariance ?	Symétrique · semi-définie positive · variances sur la diagonale
Corrélation ?	$\frac{\text{Cov}[\mathbf{x}, \mathbf{y}]}{\sqrt{\mathbb{V}[\mathbf{x}]\mathbb{V}[\mathbf{y}]}} \in [-1, 1]$
Matrice de corrélation ?	La covariance des variables STANDARDISÉES $\mathbf{x}/\sigma(\mathbf{x})$
Moyenne empirique ?	$\bar{\mathbf{x}} = \frac{1}{N} \sum_n \mathbf{x}_n$
Covariance empirique ?	$\Sigma = \frac{1}{N} \sum_n (\mathbf{x}_n - \bar{\mathbf{x}})(\mathbf{x}_n - \bar{\mathbf{x}})^\top$ — BIAISÉE
Version non biaisée ?	Avec $N - 1$ au dénominateur
Formule brute de la variance ?	$\mathbb{V}[\mathbf{x}] = \mathbb{E}[\mathbf{x}^2] - (\mathbb{E}[\mathbf{x}])^2$
Son mnémonique ?	« La moyenne du carré moins le carré de la moyenne »
Son avantage ?	Calcul en UNE passe
Son danger ?	Instabilité numérique si les deux termes sont grands et proches
Troisième expression ?	$\frac{1}{N^2} \sum_{i,j} (\mathbf{x}_i - \mathbf{x}_j)^2 = 2 \times$ la formule brute
Sa lecture géométrique ?	Équivalence entre distances par paires et distances au centre
$\mathbb{V}[\mathbf{x} + \mathbf{y}]$?	$\mathbb{V}[\mathbf{x}] + \mathbb{V}[\mathbf{y}] + \text{Cov}[\mathbf{x}, \mathbf{y}] + \text{Cov}[\mathbf{y}, \mathbf{x}]$
$\mathbb{V}[\mathbf{x} - \mathbf{y}]$?	$\mathbb{V}[\mathbf{x}] + \mathbb{V}[\mathbf{y}] - \text{Cov}[\mathbf{x}, \mathbf{y}] - \text{Cov}[\mathbf{y}, \mathbf{x}]$ — les variances S'AJOUTENT
$\mathbb{E}[\mathbf{A}\mathbf{x} + \mathbf{b}]$?	$\mathbf{A}\mu + \mathbf{b}$
$\mathbb{V}[\mathbf{A}\mathbf{x} + \mathbf{b}]$?	$\mathbf{A}\Sigma\mathbf{A}^\top$ — le b disparaît
$\text{Cov}[\mathbf{x}, \mathbf{A}\mathbf{x} + \mathbf{b}]$?	$\Sigma\mathbf{A}^\top$
Indépendance ?	$p(\mathbf{x}, \mathbf{y}) = p(\mathbf{x})p(\mathbf{y})$
Ses quatre conséquences ?	$p(\mathbf{y} \mathbf{x}) = p(\mathbf{y}) \cdot p(\mathbf{x} \mathbf{y}) = p(\mathbf{x}) \cdot \mathbb{V}[\mathbf{x} + \mathbf{y}] = \mathbb{V}[\mathbf{x}] + \mathbb{V}[\mathbf{y}] \cdot \text{Cov} = 0$
Cov = 0 implique-t-il l'indépendance ?	NON — la covariance ne mesure que la dépendance LINÉAIRE

Question	Réponse
Le contre-exemple 6.5 ?	$\mathbb{E}[x] = 0, \mathbb{E}[x^3] = 0, y = x^2 : \text{Cov}[x, y] = \mathbb{E}[x^3] = 0$ mais Y dépend de X
i.i.d. ?	Mutuellement indépendantes (tous les sous-ensembles) et de même loi
Indépendance conditionnelle ?	$p(x, y z) = p(x z)p(y z)$ pour TOUT z
Sa forme équivalente ?	$p(x y, z) = p(x z)$
$\langle X, Y \rangle$ en probabilité ?	La covariance
$\ X\ $?	L' écart-type $\sigma[x]$
$\cos \theta$?	La CORRÉLATION
Orthogonalité ?	$\text{Cov}[x, y] = 0$, c'est-à-dire non corrélées
Le théorème de Pythagore probabiliste ?	$\mathbb{V}[x + y] = \mathbb{V}[x] + \mathbb{V}[y]$ pour des variables non corrélées
Densité gaussienne univariée ?	$\frac{1}{\sqrt{2\pi}\sigma^2} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$
Densité multivariée ?	$(2\pi)^{-D/2} \Sigma ^{-1/2} \exp\left(-\frac{1}{2}(x - \mu)^\top \Sigma^{-1}(x - \mu)\right)$
Loi normale standard ?	$\mu = 0$ et $\Sigma = I$
Pourquoi la gaussienne apparaît-elle naturellement ?	Le THÉORÈME CENTRAL LIMITE — sommes de variables i.i.d.
Marginale d'une gaussienne jointe ?	$\mathcal{N}(\mu_x, \Sigma_{xx})$ — il suffit de prendre le bloc
Moyenne conditionnelle ?	$\mu_{x y} = \mu_x + \Sigma_{xy}\Sigma_{yy}^{-1}(y - \mu_y)$
Covariance conditionnelle ?	$\Sigma_{x y} = \Sigma_{xx} - \Sigma_{xy}\Sigma_{yy}^{-1}\Sigma_{yx}$
Dépend-elle de y ?	NON — elle est constante
Exemple 6.6, conditionnelle ?	$\mathcal{N}(0,6 ; 0,1)$
Exemple 6.6, marginale ?	$\mathcal{N}(0 ; 0,3)$
Trois algorithmes fondés sur les conditionnelles gaussiennes ?	Le filtre de KALMAN · les PROCESSUS GAUSSIENS · l' ACP PROBABILISTE

Question	Réponse
Produit de deux densités gaussiennes ?	Une gaussienne MISE À L'ÉCHELLE : $C = (A^{-1} + B^{-1})^{-1}$, $c = C(A^{-1}a + B^{-1}b)$
Somme de gaussiennes indépendantes ?	$\mathcal{N}(\mu_x + \mu_y, \Sigma_x + \Sigma_y)$
Somme pondérée $ax + by$?	$\mathcal{N}(a\mu_x + b\mu_y, a^2\Sigma_x + b^2\Sigma_y)$ — coefficients au carré
Moyenne d'un mélange ?	$\alpha\mu_1 + (1 - \alpha)\mu_2$
Variance d'un mélange ?	$\alpha\sigma_1^2 + (1 - \alpha)\sigma_2^2 + \alpha\mu_1^2 + (1 - \alpha)\mu_2^2 - [\alpha\mu_1 + (1 - \alpha)\mu_2]^2$
Le nom de cette formule ?	La LOI DE LA VARIANCE TOTALE : $\mathbb{V}[x] = \mathbb{E}_Y[\mathbb{V}[x y]] + \mathbb{V}_Y[\mathbb{E}[x y]]$
Transformation linéaire d'une gaussienne ?	Toujours gaussienne : $\mathcal{N}(A\mu, A\Sigma A^\top)$
Les trois étapes de l'échantillonnage ?	Uniforme $[0, 1] \rightarrow$ BOX-MÜLLER $\rightarrow \mathcal{N}(0, I)$, puis $y = Ax + \mu$
Quel A choisir ?	Celui avec $AA^\top = \Sigma$ — la CHOLESKY de Σ
Les trois desiderata du §6.6 ?	Clôture sous Bayes · pas plus de paramètres avec plus de données · bonne estimation
Loi de Bernoulli ?	$p(x \mu) = \mu^x(1 - \mu)^{1-x}$; $\mathbb{E} = \mu$, $\mathbb{V} = \mu(1 - \mu)$
Loi binomiale ?	$\binom{N}{m}\mu^m(1 - \mu)^{N-m}$; $\mathbb{E} = N\mu$, $\mathbb{V} = N\mu(1 - \mu)$
Loi bêta ?	$\frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)}\mu^{\alpha-1}(1 - \mu)^{\beta-1}$
Ses moments ?	$\mathbb{E} = \frac{\alpha}{\alpha + \beta}$, $\mathbb{V} = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$
Rôle de α et β ?	α pousse la masse vers 1 , β vers 0
Bêta avec $\alpha = 1 = \beta$?	La loi UNIFORME $\mathcal{U}[0, 1]$
Bêta avec $\alpha, \beta < 1$?	BIMODALE , pics en 0 et 1
A priori conjugué ?	Un a priori tel que l' a posteriori soit du MÊME TYPE
Son avantage ?	On calcule l'a posteriori en METTANT À JOUR LES PARAMÈTRES
Conjugué de la binomiale ?	La BÊTA : Beta ($h + \alpha$, $N - h + \beta$)

Question	Réponse
Conjugué de la Bernoulli ?	La BÊTA : $\text{Beta}(\alpha + x, \beta + 1 - x)$
Conjugué de la multinomiale ?	La DIRICHLET
Conjugué pour la variance gaussienne (scalaire) ?	La Gamma INVERSE (ou Gamma sur la précision)
Conjugué pour la covariance (multivarié) ?	La Wishart INVERSE (ou Wishart sur la matrice de précision)
Statistique exhaustive ?	Une statistique portant TOUTE l'information inférable sur θ
Théorème de Fisher-Neyman ?	$\phi(x)$ exhaustive $\iff p(x \theta) = h(x)g_\theta(\phi(x))$
Forme de la famille exponentielle ?	$p(x \theta) = h(x) \exp(\langle \theta, \phi(x) \rangle - A(\theta))$
Que sont $\phi(x)$, θ , $A(\theta)$?	Statistiques exhaustives · paramètres naturels · fonction de LOG-PARTITION
ϕ pour la gaussienne ?	$[x, x^2]^\top$, avec $\theta = [\mu/\sigma^2, -1/(2\sigma^2)]^\top$
θ pour la Bernoulli ?	$\log \frac{\mu}{1-\mu}$, avec $\phi(x) = x$ et $A(\theta) = \log(1 + e^\theta)$
La relation inverse ?	$\mu = \frac{1}{1 + \exp(-\theta)}$ — la SIGMOÏDE
Ce que fait la sigmoïde ?	Comprime un réel dans $(0, 1)$
Où sert-elle ?	Régression logistique · activations de réseaux de neurones
Le résultat de 1935-1936 ?	Pitman, Darmois, Koopman : les familles exponentielles sont les SEULES à statistiques exhaustives de dimension finie
Tout membre de la famille exponentielle a-t-il un conjugué ?	OUI (Brown, 1986)
Transformation, cas discret ?	$P(Y = y) = P(X = U^{-1}(y))$
Transformation, cas continu univarié ?	$f(y) = f_x(U^{-1}(y)) \cdot \left \frac{d}{dy} U^{-1}(y) \right $
Pourquoi la valeur absolue ?	Pour couvrir les U décroissantes avec la même formule
Théorème 6.16, cas multivarié ?	$f(y) = f_x(U^{-1}(y)) \cdot \left \det \frac{\partial}{\partial y} U^{-1}(y) \right $

Question	Réponse
Pourquoi le déterminant ?	Les cubes de volume sont transformés en parallélépipèdes par la jacobienne
Résultat de l'exemple 6.16 ?	$F_Y(y) = y^{3/2}$ et $f_Y(y) = \frac{3}{2}y^{1/2}$ sur $[0, 1]$
Théorème 6.15 ?	Si F_X est strictement monotone , $Y := F_X(X)$ est UNIFORME
Son nom ?	La TRANSFORMATION INTÉGRALE DE PROBABILITÉ
Ses trois usages ?	Échantillonnage par cdf inverse · tests d'hypothèses · copules
Covariance obtenue dans l'exemple 6.17 ?	$\Sigma = AA^T$
Ce qu'il faut ne jamais oublier après une transformation ?	Recalculer le DOMAINE