

Fiche 407 — Quand les modèles rencontrent les données : risque empirique, MLE, MAP, sélection de modèle

Matière	Maths · Apprentissage automatique
Cours source	Deisenroth, Faisal & Ong, <i>Mathematics for Machine Learning</i> , Cambridge University Press — chapitre 8 « When Models Meet Data » (p. 251-292)
Difficulté	Intermédiaire — le PONT entre les six fondations et les quatre piliers
Temps d'étude estimé	130 min
Prérequis	Fiche 405 (Bayes, gaussienne, conjugaison) · Fiche 406 (descente de gradient) · Fiche 401 (algèbre linéaire)
Concepts clés	Donnée tabulaire, exemple, attribut, étiquette, prédicteur comme fonction, prédicteur comme loi de probabilité, trois phases algorithmiques, minimisation du risque empirique, classe d'hypothèses, fonction de perte, risque empirique, risque espéré, surapprentissage, régularisation, régularisateur de Tikhonov, validation croisée à K plis, maximum de vraisemblance, log-vraisemblance négative, maximum a posteriori, sur-ajustement et sous-ajustement, modélisation probabiliste, inférence bayésienne, variables latentes, modèle graphique orienté, notation en plaques, d -séparation, sélection de modèle, validation croisée imbriquée, évidence, rasoir d'Occam, facteur de Bayes, paradoxe de Jeffreys-Lindley
Poids à l'examen	Les trois phases (prédiction, entraînement, sélection) · le risque empirique $\frac{1}{N} \sum \ell(y_n, \hat{y}_n)$ contre le risque espéré $\mathbb{E}_{x,y}[\ell]$ · la correspondance perte $\leftrightarrow$ vraisemblance et régularisation $\leftrightarrow$ a priori · $L(\theta) = -\sum_n \log p(y_n x_n, \theta)$ · la factorisation $p(x) = \prod_k p(x_k \mathbf{Pa}_k)$ · l' évidence $p(\mathcal{D} M) = \int p(\mathcal{D} \theta)p(\theta M)d\theta$ et le rasoir d'Occam .

Vue d'ensemble

LE PONT : la partie I (maths) rejoint la partie II (les quatre piliers)

§8.1 DONNÉES, MODÈLES, APPRENTISSAGE

DONNÉES tabulaires N exemples (lignes) $\times$ D attributs (colonnes) $\rightarrow$ $X \in \mathbb{R}^{(N \times D)}$

⚠ standardiser : moyenne empirique 0, variance empirique 1

MODÈLE, deux visions : (a) une FONCTION $f : \mathbb{R}^D \rightarrow \mathbb{R}$

(b) une LOI DE PROBABILITÉ (elle exprime l'INCERTITUDE)

TROIS PHASES 1. PRÉDICTION / inférence 2. ENTRAÎNEMENT 3. SÉLECTION de modèle

§8.2 MINIMISATION DU RISQUE EMPIRIQUE – la voie NON probabiliste

4 choix de conception classe d'hypothèses · perte · régularisation · recherche

RISQUE EMPIRIQUE $R_{\text{emp}}(f, X, y) = (1/N) \sum_n \ell(y_n, \hat{y}_n)$

RISQUE ESPÉRÉ $R_{\text{true}}(f) = E_{\{x, y\}}[\ell(y, f(x))]$ ← ce qu'on VEUT vraiment

RÉGULARISATION $\min (1/N) \|y - X\theta\|^2 + \lambda \|\theta\|^2$ ← contre le SURAPPRENTISSAGE

VALIDATION CROISÉE à K plis K-1 morceaux d'entraînement, 1 de validation

§8.3 ESTIMATION DE PARAMÈTRES – la voie probabiliste

MLE $L(\theta) = -\log p(Y|X, \theta) = -\sum_n \log p(y_n|x_n, \theta)$

⚠ vraisemblance GAUSSIENNE $\Leftrightarrow$ MOINDRES CARRÉS

MAP $p(\theta|x) \propto p(x|\theta) p(\theta)$ ⚠ A PRIORI $\Leftrightarrow$ RÉGULARISATION

AJUSTEMENT sur-ajustement · sous-ajustement · bon ajustement

§8.4 MODÉLISATION PROBABILISTE ET INFÉRENCE

⚠ un modèle probabiliste EST la LOI JOINTE $p(x, \theta)$ de TOUTES ses variables

INFÉRENCE BAYÉSIENNE : on garde la loi a posteriori ENTIÈRE, pas un point

$p(x) = \int p(x|\theta) p(\theta) d\theta = E_{\theta}[p(x|\theta)]$

VARIABLES LATENTES z $p(x|\theta) = \int p(x|z, \theta) p(z) dz$ (algorithme EM)

§8.5 MODÈLES GRAPHIQUES ORIENTÉS (réseaux bayésiens)

nœuds = variables aléatoires · flèches = probabilités conditionnelles

$p(x) = \prod_k p(x_k | Pa_k)$ Pa_k = les nœuds PARENTS de x_k

PLAQUE = boîte qui répète son contenu N fois · nœud GRISÉ = variable OBSERVÉE

d-SÉPARATION → lire l'indépendance conditionnelle SUR LE GRAPHE

§8.6 SÉLECTION DE MODÈLE

VALIDATION CROISÉE IMBRIQUÉE boucle interne = choix ; externe = généralisation

BAYÉSIENNE $p(M_k | D) \propto p(M_k) p(D | M_k)$

ÉVIDENCE $p(D | M_k) = \int p(D | \theta_k) p(\theta_k | M_k) d\theta_k$ ← RASOIR D'OCCAM automatique

FACTEUR DE BAYES $p(D|M_1)/p(D|M_2)$

LES DEUX MONDES, TERME À TERME

NON PROBABILISTE

PROBABILISTE

fonction de PERTE $\leftrightarrow$ VRAISEMBLANCE

RÉGULARISATION $\leftrightarrow$ A PRIORI

min du risque empirique $\leftrightarrow$ max de vraisemblance / MAP

La question centrale. « La question principale de l'apprentissage automatique est : "**Qu'entend-on par de BONS modèles ?**" L'un des principes directeurs est que **de bons modèles doivent bien se comporter sur des données NON VUES.** »

● Concept 1 — Données, modèles, apprentissage (§8.1)

1.1 Les données comme vecteurs

Le format de travail. Les données sont supposées **TABULAIRES** : chaque **ligne** est un **exemple** (une instance), chaque **colonne** un **attribut**.

Terme	Synonymes donnés par le livre
Un exemple x_n	point de donnée (<i>data point</i>)
Un attribut	caractéristique (<i>feature</i>), covariable (<i>covariate</i>)
Une étiquette y_n	cible (<i>target</i>), variable de réponse , annotation

Les notations à fixer :

N = nombre d'exemples, $n = 1, \dots, N$ D = nombre d'attributs, $d = 1, \dots, D$

Jeu de données : $\{(x_1, y_1), \dots, (x_N, y_N)\}$ $X \in \mathbb{R}^{N \times D}$

L'exemple de la base de données RH. Le livre part d'une table **non numérique** (nom, genre, diplôme, code postal, âge, salaire) et montre les **choix de conversion** :

- Le **genre** (variable **catégorielle**) peut devenir $\{0, 1\}$ ou $\{-1, +1\}$.
- « Il est souvent important d'utiliser la **CONNAISSANCE DU DOMAINE** : savoir que les diplômes universitaires progressent de la licence au master au doctorat, ou réaliser que le code postal n'est pas juste une chaîne de caractères mais **encode une zone de Londres** » — d'où sa conversion en **latitude et longitude**.
- La colonne **Nom** est **supprimée**, pour deux raisons : « (1) on ne s'attend pas à ce que l'identifiant soit informatif ; (2) on peut vouloir **ANONYMISER** les données pour protéger la vie privée des employés. »

La règle par défaut. « Sans information supplémentaire, on devrait **DÉCALER** et **METTRE À L'ÉCHELLE** toutes les colonnes du jeu de données de sorte qu'elles aient une **moyenne empirique de 0** et une **variance empirique de 1**. »

La chaîne des chapitres. Représenter les données comme vecteurs $\Rightarrow$ **algèbre linéaire** (ch. 2). Comparer deux vecteurs $\Rightarrow$ **géométrie** (ch. 3). Optimiser le problème résultant $\Rightarrow$ **ch. 7**. Approximation de basse dimension $\Rightarrow$ **ACP** (ch. 10, via ch. 4). Représentation non linéaire de plus haute dimension $\Rightarrow$ **application d'attributs** $\phi(\cdot)$ (§9.2) puis **NOYAU** (§12.4).

1.2 Les deux visions du modèle

Vision A — le PRÉDICTEUR comme FONCTION.

$$f : \mathbb{R}^D \rightarrow \mathbb{R}$$

Le livre se restreint aux **fonctions LINÉAIRES** :

$$f(x) = \theta^\top x + \theta_0$$

« Les fonctions linéaires trouvent un bon équilibre entre la **généralité des problèmes solubles** et la **quantité de mathématiques de fond nécessaire**. »

Vision B — le PRÉDICTEUR comme LOI DE PROBABILITÉ.

La motivation. « On considère souvent les données comme des **observations BRUITÉES** d'un vrai effet sous-jacent... On aimerait aussi des prédicteurs qui expriment une **sorte d'INCERTITUDE**, par exemple pour quantifier la **CONFIANCE** qu'on a dans la valeur de la prédiction pour un point de test particulier. »

Le livre se limite aux **lois à paramètres de dimension FINIE**, « ce qui permet de décrire les modèles probabilistes sans avoir besoin de processus stochastiques ni de mesures aléatoires ».

1.3 Apprendre, c'est trouver des paramètres

Les TROIS phases algorithmiques, distinctes :

1. **PRÉDICTION** ou **inférence**
2. **ENTRAÎNEMENT** ou **estimation de paramètres**
3. **RÉGLAGE DES HYPERPARAMÈTRES** ou **sélection de modèle**

Phase	Ce qui s'y passe
Prédiction	Les paramètres et le choix de modèle sont déjà fixés ; on applique le prédicteur à de nouveaux points. Pour un modèle probabiliste, on parle d' INFÉRENCE
Entraînement	On ajuste le modèle sur les données d'entraînement. Deux stratégies : une estimation ponctuelle (applicable aux deux types de prédicteurs) ou l' INFÉRENCE BAYÉSIENNE (qui exige un modèle probabiliste)
Sélection	Choix des hyperparamètres et de la structure du modèle

L'avertissement terminologique. « Il n'y a **PAS de nommage consensuel** pour les différentes phases algorithmiques. Le mot "**inférence**" est parfois aussi utilisé pour désigner l'**ESTIMATION DE PARAMÈTRES** d'un modèle probabiliste, et plus rarement la **PRÉDICTION** pour des modèles non probabilistes. »

Les deux principes correspondants :

Modèle NON probabiliste → MINIMISATION DU RISQUE EMPIRIQUE (§8.2)

Modèle statistique → MAXIMUM DE VRAISEMBLANCE (§8.3)

Le signe moins expliqué. « La convention en OPTIMISATION est de **MINIMISER** les objectifs. D'où le **signe MOINS supplémentaire** souvent présent dans les objectifs d'apprentissage automatique. »

L'ABDUCTION. « Pour bien se comporter sur des données non vues, il faudra **équilibrer** un bon ajustement aux données d'entraînement et la recherche d'explications "**SIMPLES**" du phénomène. Ce compromis s'obtient par la **RÉGULARISATION** (§8.2.3) ou en ajoutant un **A PRIORI** (§8.3.2). En philosophie, ce n'est considéré ni comme de l'**induction** ni comme de la **déduction**, mais comme de l'**ABDUCTION** — le processus d'inférence vers la **MEILLEURE EXPLICATION**. »

Paramètre contre hyperparamètre. « La distinction est **quelque peu ARBITRAIRE**, et surtout guidée par la distinction entre **ce qui peut être NUMÉRIQUEMENT OPTIMISÉ** et **ce qui doit passer par des techniques de RECHERCHE**. » Autre façon de voir : les **paramètres** sont ceux du modèle probabiliste ; les **hyperparamètres** (paramètres de niveau supérieur) **contrôlent la loi de ces paramètres**.

● Concept 2 — Minimisation du risque empirique (§8.2)

L'origine. « Popularisée à l'origine par la proposition de la **MACHINE À VECTEURS DE SUPPORT** (ch. 12). Mais ses principes généraux sont **largement applicables** et permettent de poser la question de ce qu'est l'apprentissage **SANS construire explicitement de modèles probabilistes**. »

Les QUATRE choix de conception :

§	Question
8.2.1	« Quel est l' ensemble de FONCTIONS qu'on autorise pour le prédicteur ? »
8.2.2	« Comment MESURE-T-ON la performance du prédicteur sur les données d'entraînement ? »
8.2.3	« Comment construire, à partir des seules données d'entraînement , des prédicteurs qui se comportent bien sur des données de TEST non vues ? »
8.2.4	« Quelle est la PROCÉDURE de recherche dans l'espace des modèles ? »

2.1 La classe d'hypothèses

On cherche un prédicteur $f(\cdot, \theta) : \mathbb{R}^D \rightarrow \mathbb{R}$ tel que

$$f(x_n, \theta^*) \approx y_n \quad \text{pour tout } n = 1, \dots, N$$

en notant $\hat{y}_n = f(x_n, \theta^*)$.

Exemple 8.1 — les moindres carrés ordinaires. L'astuce de notation compacte : **concaténer un attribut unité** $x^{(0)} = 1$ à x_n , soit $x_n = [1, x_n^{(1)}, \dots, x_n^{(D)}]^\top$ et $\theta = [\theta_0, \theta_1, \dots, \theta_D]^\top$:

$$f(x_n, \theta) = \theta^\top x_n \iff f(x_n, \theta) = \theta_0 + \sum_{d=1}^D \theta_d x_n^{(d)}$$

Le prédicteur devient $f : \mathbb{R}^{D+1} \rightarrow \mathbb{R}$.

Le glissement de vocabulaire. « Les fonctions **AFFINES** sont souvent appelées **fonctions LINÉAIRES** en apprentissage automatique. » (Voir la fiche 401 : $\phi(x) = a + \Phi(x)$ n'est linéaire que si $a = 0$.)

2.2 La fonction de perte et le risque

La **fonction de perte** $\ell(y_n, \hat{y}_n)$ prend l'étiquette **vraie** et la **prédiction**, et produit un **nombre NON NÉGATIF** représentant l'erreur commise. « L'expression "**erreur**" est souvent utilisée pour dire *perte*. »

$$R_{\text{emp}}(f, X, y) = \frac{1}{N} \sum_{n=1}^N \ell(y_n, \hat{y}_n)$$

C'est le **RISQUE EMPIRIQUE**, qui dépend de **trois arguments** : le prédicteur f et les données X, y . Le minimiser est la **MINIMISATION DU RISQUE EMPIRIQUE**.

Exemple 8.2 — la perte quadratique. Avec $\ell(y_n, \hat{y}_n) = (y_n - \hat{y}_n)^2$:

$$\min_{\theta \in \mathbb{R}^D} \frac{1}{N} \sum_{n=1}^N (y_n - f(x_n, \theta))^2 \xrightarrow{f=\theta^\top x_n} \min_{\theta \in \mathbb{R}^D} \frac{1}{N} \sum_{n=1}^N (y_n - \theta^\top x_n)^2$$

$$\min_{\theta \in \mathbb{R}^D} \frac{1}{N} \|y - X\theta\|^2$$

C'est le **PROBLÈME DES MOINDRES CARRÉS**, qui a « une solution analytique en forme fermée, obtenue en résolvant les **ÉQUATIONS NORMALES** » (§9.2 et fiche 402).

Le RISQUE ESPÉRÉ — ce qu'on veut vraiment :

$$R_{\text{true}}(f) = \mathbb{E}_{x,y}[\ell(y, f(x))]$$

« La notation R_{true} indique que c'est le **VRAI risque** si l'on avait accès à une **quantité INFINIE de données**. L'espérance porte sur l'ensemble (infini) de toutes les données et étiquettes possibles. » Autre nom : le **risque de POPULATION**.

Les deux questions pratiques qui en découlent : (i) « Comment changer la procédure d'entraînement pour **BIEN GÉNÉRALISER** ? » (ii) « Comment **ESTIMER** le risque espéré à partir de données **FINIES** ? »

Le décalage perte / métrique. « En principe, la conception de la fonction de perte devrait correspondre **DIRECTEMENT** à la mesure de performance spécifiée par la tâche. En pratique, il y a **souvent un DÉCALAGE** — dû à la **facilité d'implémentation** ou à l'**efficacité de l'optimisation**. »

2.3 La régularisation

L'idée. « La régularisation **DÉCOURAGE** les solutions **COMPLEXES** ou **EXTRÊMES** d'un problème d'optimisation. »

$$\min_{\theta} \frac{1}{N} \|y - X\theta\|^2 + \lambda \|\theta\|^2$$

Terme	Nom
$\ \theta\ ^2$	Le RÉGULARISATEUR (aussi appelé terme de PÉNALITÉ)
λ	Le PARAMÈTRE DE RÉGULARISATION

Le compromis. « Le paramètre de régularisation **arbitre** entre minimiser la perte sur l'ensemble d'entraînement et la **MAGNITUDE des paramètres θ** . Il arrive souvent que la magnitude des valeurs des paramètres devienne **relativement GRANDE en cas de SURAPPRENTISSAGE**. »

Les **TROIS visages de la même idée** — le livre les relie explicitement :

RÉGULARISATEUR $\equiv$ A PRIORI sur les paramètres (§8.3.2) $\equiv$ GRANDE MARGE (ch. 12)

Et « le terme de pénalité **BIAISE le vecteur θ vers l'ORIGINE** ».

L'approche présentée est la **régularisation de TIKHONOV** ; il existe une version contrainte proche, la **régularisation d'IVANOV**. Racine historique : la **résolution de problèmes inverses MAL POSÉS** (Neumaier, 1998).

2.4 La validation croisée

Le dilemme. « La quantité de données est **LIMITÉE**, et idéalement on utiliserait autant de données que possible pour entraîner. Cela nous obligerait à garder un ensemble de validation **PETIT** — ce qui conduirait alors à une estimation **BRUITÉE (à forte variance)** de la performance prédictive. »

La validation croisée à K plis. « Elle partitionne les données en K morceaux, dont $K - 1$ forment l'ensemble d'entraînement $\mathcal{R}$, et le dernier sert d'ensemble de validation $\mathcal{V}$. Elle **itère à travers TOUTES les combinaisons** d'affectations, et la performance des K passages est **MOYENNÉE**. »

$$\mathcal{D} = \mathcal{R} \cup \mathcal{V}, \quad \mathcal{R} \cap \mathcal{V} = \emptyset$$

$$\mathbb{E}_{\mathcal{V}}[R(f, \mathcal{V})] \approx \frac{1}{K} \sum_{k=1}^K R(f^{(k)}, \mathcal{V}^{(k)})$$

Le bon côté du coût. « La validation croisée est un problème **EMBARRASSAMMENT PARALLÈLE** : peu d'effort est nécessaire pour le séparer en tâches parallèles. Avec des ressources de calcul suffisantes, elle **ne prend pas plus longtemps qu'une SEULE évaluation de performance**. »

Une remarque de sécurité du livre. « Même connaître **seulement la performance** du prédicteur sur l'ensemble de test **FAIT FUITER de l'information** » (Blum & Hardt, 2015).

Le « sans probabilité » est une erreur. « Penser à la minimisation du risque empirique comme "**exempte de probabilité**" est **INCORRECT**. Il y a une loi de probabilité inconnue sous-jacente $p(x, y)$ qui gouverne la génération des données. Mais l'approche est **AGNOSTIQUE** quant à ce choix de loi — en contraste avec les approches statistiques standard qui exigent **explicitement** la connaissance de $p(x, y)$. Comme la loi est jointe sur **x et y** , les étiquettes peuvent être **NON DÉTERMINISTES** : on n'a **PAS besoin de spécifier la loi du BRUIT** sur les étiquettes. »

● Concept 3 — Estimation de paramètres : MLE et MAP (§8.3)

La correspondance annoncée. « La **VRAISEMBLANCE** (§8.3.1) est **analogue** au concept de **FONCTION DE PERTE** (§8.2.2). Le concept d'**A PRIORI** (§8.3.2) est **analogue** au concept de **RÉGULARISATION** (§8.2.3). »

3.1 Le maximum de vraisemblance

$$\mathcal{L}_x(\theta) = -\log p(x \mid \theta)$$

C'est la **LOG-VRAISEMBLANCE NÉGATIVE**. « La notation $\mathcal{L}_x(\theta)$ souligne que **le paramètre θ VARIE et que la donnée x est FIXÉE**. »

Les deux lectures, complémentaires :

Vue	Ce que dit $p(x \mid \theta)$
θ fixé	« Une loi qui modélise l' INCERTITUDE DES DONNÉES pour un réglage donné du paramètre. »
x fixé (observé), θ varie	« Elle nous dit à quel point un réglage particulier de θ est PROBABLE pour les observations x . »

Le piège d'interprétation, signalé mot pour mot. *« Bien qu'il soit tentant d'interpréter le fait que θ soit à droite du conditionnement dans $p(y_n | x_n, \theta)$ — et donc qu'il faudrait l'interpréter comme **observé et fixé** —, **cette interprétation est INCORRECTE**. La log-vraisemblance négative $L(\theta)$ est une **FONCTION DE θ** . »*

Exemple 8.4 — la vraisemblance gaussienne. « On suppose qu'on peut expliquer notre incertitude d'observation par un **BRUIT GAUSSIEN INDÉPENDANT de moyenne nulle**, $\varepsilon_n \sim \mathcal{N}(0, \sigma^2)$, et que le modèle linéaire $x_n^\top \theta$ sert à la prédiction » :

$$p(y_n | x_n, \theta) = \mathcal{N}(y_n | x_n^\top \theta, \sigma^2)$$

L'hypothèse i.i.d. « Le mot **INDÉPENDANT** implique que la vraisemblance sur tout le jeu de données **SE FACTORISE** en un produit des vraisemblances individuelles » :

$$p(\mathcal{Y} | \mathcal{X}, \theta) = \prod_{n=1}^N p(y_n | x_n, \theta)$$

« **IDENTIQUEMENT DISTRIBUÉES** signifie que chaque terme du produit est de **la MÊME loi** et que **tous PARTAGENT les mêmes paramètres**. »

POURQUOI LE LOGARITHME.

« Il est souvent plus facile, du point de vue de l'optimisation, de calculer des fonctions **DÉCOMPOSABLES EN SOMMES** de fonctions plus simples. »

$$L(\theta) = -\log p(\mathcal{Y} | \mathcal{X}, \theta) = -\sum_{n=1}^N \log p(y_n | x_n, \theta)$$

L'origine du signe moins. « Un **ARTEFACT HISTORIQUE** : par convention on veut **MAXIMISER** la vraisemblance, mais la littérature d'optimisation numérique tend à étudier la **MINIMISATION** de fonctions. »

Exemple 8.5 — LE RÉSULTAT CENTRAL DU CHAPITRE. En développant la vraisemblance gaussienne :

$$L(\theta) = - \sum_{n=1}^N \log \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left(- \frac{(y_n - x_n^\top \theta)^2}{2\sigma^2} \right)$$

$$L(\theta) = \underbrace{\frac{1}{2\sigma^2} \sum_{n=1}^N (y_n - x_n^\top \theta)^2}_{\text{le problème des MOINDRES CARRÉS}} - \underbrace{\sum_{n=1}^N \log \frac{1}{\sqrt{2\pi\sigma^2}}}_{\text{CONSTANTE si } \sigma \text{ est donné}}$$

LA CORRESPONDANCE À RETENIR.

$$\text{VRAISEMBLANCE GAUSSIENNE} \iff \text{MOINDRES CARRÉS}$$

« Comme σ est donné, le second terme est **CONSTANT**, et minimiser $L(\theta)$ revient à résoudre le **problème des moindres carrés** exprimé dans le premier terme » — exactement l'équation (8.8) de l'exemple 8.2.

$$\begin{aligned} & -\log \prod_n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-(y_n - x_n^\top \theta)^2 / (2\sigma^2)} \\ &= -\sum_n \left[\log \frac{1}{\sqrt{2\pi\sigma^2}} - \frac{(y_n - x_n^\top \theta)^2}{2\sigma^2} \right] \text{ (car } \log(ab) = \log a + \log b \text{)} \\ &= \frac{1}{2\sigma^2} \sum_n (y_n - x_n^\top \theta)^2 - N \log \frac{1}{\sqrt{2\pi\sigma^2}} \end{aligned}$$

Le facteur $\frac{1}{2\sigma^2}$ est une **constante positive** : il ne change pas l'argmin. La minimisation de $L(\theta)$ et celle de $\sum_n (y_n - x_n^\top \theta)^2$ ont **exactement la même solution**.

« Pour d'autres fonctions de vraisemblance — si l'on modélise le bruit par des lois **NON gaussiennes** — l'estimation du maximum de vraisemblance peut **ne pas avoir de solution analytique fermée**. On recourt alors aux **méthodes numériques du chapitre 7**. »

Les deux propriétés asymptotiques de θ_{ML} (Lehmann & Casella 1998 ; Efron & Hastie 2016) :

1. **CONSISTANCE ASYMPTOTIQUE** : « l'estimateur converge vers la **vraie valeur** à la limite d'une infinité d'observations, plus une erreur aléatoire **approximativement normale** ». « La taille d'échantillon nécessaire peut être **assez GRANDE**. »

2. La **variance de l'erreur décroît en $1/N$** . « Surtout dans le régime des "**PETITES**" données, le maximum de vraisemblance peut mener au **SURAPPRENTISSAGE**. »

3.2 Le maximum a posteriori

$$p(\theta | x) = \frac{p(x | \theta)p(\theta)}{p(x)} \implies \boxed{p(\theta | x) \propto p(x | \theta)p(\theta)}$$

« Comme $p(x)$ ne dépend pas de θ , on peut ignorer la valeur du dénominateur pour l'optimisation. » On minimise alors la **log-a-posteriori NÉGATIVE** : c'est l'**ESTIMATION DU MAXIMUM A POSTERIORI (MAP)**.

Exemple 8.6 — l'a priori gaussien. En plus de la vraisemblance gaussienne, « on suppose que le vecteur de paramètres est distribué comme une gaussienne multivariée de moyenne nulle, $p(\theta) = \mathcal{N}(0, \Sigma)$. Le conjugué d'une gaussienne étant une gaussienne (§6.6.1), on s'attend donc à ce que l'a posteriori soit aussi une gaussienne. »

L'effet de l'a priori, vu sur la figure 8.6. « L'a priori **BIAISE la PENTE à être MOINS RAIDE** et l'**ORDONNÉE À L'ORIGINE à être plus PROCHE DE ZÉRO**. » « Dans cet exemple, le biais qui rapproche l'ordonnée de zéro **AUGMENTE en fait la PENTE**. »

La position du MAP. « Le maximum a posteriori peut être considéré comme **faisant le PONT entre les mondes NON PROBABILISTE et PROBABILISTE** : il reconnaît explicitement le besoin d'une loi a priori, **mais il ne produit encore qu'une ESTIMATION PONCTUELLE** des paramètres. »

3.3 L'ajustement de modèle : les trois régimes

Le cadre. La paramétrisation définit une **classe de modèles M_θ** . Les données viennent d'un modèle **M^* inconnu**. On part de M_{θ_0} et on optimise pour approcher **M^*** , la « proximité » étant définie par l'objectif optimisé.

Régime	Diagnostic
SUR-AJUSTEMENT (overfitting)	« La classe de modèles est TROP RICHE : M_θ pourrait modéliser des jeux de données bien plus compliqués. » Exemple : données linéaires, modèle polynomial de degré 7 . « Les modèles qui surajustent ont typiquement un grand NOMBRE DE PARAMÈTRES ... la classe trop flexible utilise TOUTE sa puissance de modélisation pour réduire l'erreur d'ENTRAÎNEMENT . Si les données sont bruitées, elle trouvera donc un signal utile DANS LE BRUIT lui-même — ce qui causera d'énormes problèmes en prédiction loin des données. »
SOUS-AJUSTEMENT (underfitting)	« Le problème OPPOSÉ : la classe M_θ n'est PAS assez riche . » Exemple : données sinusoïdales , modèle linéaire
BON AJUSTEMENT	La classe est adaptée à M^*

● Concept 4 — Modélisation probabiliste et inférence (§8.4)

4.1 Ce qu'est un modèle probabiliste

LA DÉFINITION. « En modélisation probabiliste, la **LOI JOINTE** $p(x, \theta)$ des variables observées x et des paramètres cachés θ est **d'importance CENTRALE**. »

Elle **encapsule** à elle seule :

Objet	Comment on l'obtient de la jointe
L'a priori et la vraisemblance	Par la RÈGLE DU PRODUIT (§6.3)
La vraisemblance marginale $p(x)$	En INTÉGRANT les paramètres — la règle de la SOMME
L'a posteriori	En divisant la jointe par la vraisemblance marginale

SEULE la loi JOINTE a cette propriété. Un modèle probabiliste **EST** donc la loi jointe de **TOUTES** ses variables aléatoires.

4.2 L'inférence bayésienne

$$p(\theta | \mathcal{X}) = \frac{p(\mathcal{X} | \theta)p(\theta)}{p(\mathcal{X})}, \quad p(\mathcal{X}) = \int p(\mathcal{X} | \theta)p(\theta) d\theta$$

La différence avec MLE/MAP. « Dans les deux cas, on obtient une **valeur UNIQUE, la meilleure** pour θ : le problème algorithmique clé est de résoudre un **problème d'OPTIMISATION**. » L'inférence bayésienne, elle, « est **l'apprentissage de la LOI** des variables aléatoires ».

Le coût de l'estimation ponctuelle. « Se concentrer uniquement sur une statistique de l'a posteriori conduit à une **PERTE D'INFORMATION**, ce qui peut être **CRITIQUE** dans un système qui utilise la prédiction $p(x | \theta^*)$ pour **prendre des DÉCISIONS**. Ces systèmes ont typiquement des **fonctions objectifs DIFFÉRENTES** de la vraisemblance, d'une perte quadratique ou d'une erreur de mauvaise classification. Avoir la **loi a posteriori COMPLÈTE** peut donc être **extrêmement utile et mène à des décisions PLUS ROBUSTES**. »

La prédiction bayésienne — la propagation de l'incertitude :

$$p(x) = \int p(x | \theta) p(\theta) d\theta = \mathbb{E}_{\theta}[p(x | \theta)]$$

« L'a posteriori sur les paramètres **PROPAGÉ l'incertitude des paramètres vers les données**. »

4.3 Les modèles à variables latentes

Les variables latentes z « sont **DIFFÉRENTES des paramètres θ** car elles **ne paramétrisent PAS le modèle explicitement**. »

Leurs trois vertus :

1. Elles peuvent **décrire le processus générateur**, contribuant à l'**INTERPRÉTABILITÉ**.
2. Elles **simplifient souvent la structure** du modèle et permettent des structures **plus simples ET plus riches**.
3. « La simplification de la structure va souvent de pair avec un **plus PETIT nombre de paramètres**. »

L'algorithme dédié : l'ESPÉRANCE-MAXIMISATION (EM) (Dempster *et al.*, 1977).

Les exemples cités : **ACP** pour la réduction de dimension (ch. 10), **mélanges gaussiens** pour l'estimation de densité (ch. 11), **modèles de Markov cachés, systèmes dynamiques** pour les séries temporelles, **méta-apprentissage**.

La procédure en deux temps :

Étape 1 — la vraisemblance, en marginalisant les latentes :

$$p(x \mid \theta) = \int p(x \mid z, \theta) p(z) dz$$

« La vraisemblance est une fonction **des données et des paramètres**, mais elle est **INDÉPENDANTE des variables latentes**. »

Étape 2 — l'estimation ou l'inférence, exactement comme aux §8.3 et §8.4.2 :

$$p(\theta \mid \mathcal{X}) = \frac{p(\mathcal{X} \mid \theta)p(\theta)}{p(\mathcal{X})}$$

LE DÉFI. « Sauf si l'on choisit un a priori **CONJUGUÉ** $p(z)$ pour $p(x \mid z, \theta)$, la **marginalisation n'est PAS ANALYTIQUEMENT TRAITABLE**, et il faut recourir à des **APPROXIMATIONS**. » Et : « l'apprentissage dans les modèles à variables latentes est **généralement DIFFICILE**, comme on le verra au chapitre 11. »

● Concept 5 — Les modèles graphiques orientés (§8.5)

5.1 La sémantique du graphe

CE QUE C'EST.

« Une façon **COMPACTE et SUCCINCTE** de spécifier des modèles probabilistes, qui permet de **parser VISUELLEMENT les dépendances** entre variables aléatoires. »

NŒUDS = variables aléatoires **FLÈCHES** = probabilités conditionnelles

Une flèche de **a** vers **b** donne la **probabilité conditionnelle** $p(b \mid a)$. « Avec des hypothèses supplémentaires, les flèches peuvent indiquer des **relations CAUSALES** (Pearl, 2009). »

La motivation. « La loi jointe **en elle-même** peut être assez compliquée et **ne nous dit RIEN des propriétés STRUCTURELLES** du modèle. Par exemple, $p(a, b, c)$ ne nous dit rien sur les **relations d'INDÉPENDANCE**. C'est là qu'interviennent les modèles graphiques. »

Les quatre propriétés commodes :

1. Une façon **simple de VISUALISER** la structure.
2. Ils servent à **concevoir ou motiver de NOUVEAUX modèles** statistiques.
3. « L'**INSPECTION du graphe SEUL** donne un aperçu de propriétés comme l'**indépendance conditionnelle**. »
4. « Des calculs complexes d'inférence et d'apprentissage s'expriment en termes de **MANIPULATIONS GRAPHIQUES**. »

La limite. « *Toute loi ne peut PAS être représentée dans un choix particulier de modèle graphique.* »

5.2 Les deux sens de traduction

De la **FACTORISATION** vers le **GRAPHE (exemple 8.7)**. Pour

$$p(a, b, c) = p(c \mid a, b) p(b \mid a) p(a)$$

la factorisation dit que : c dépend **directement** de a et b ; b dépend directement de a ; a ne dépend **ni de b ni de c** .

La recette :

1. **Créer un nœud** pour chaque variable aléatoire.
2. Pour chaque loi conditionnelle, **ajouter une flèche** depuis les nœuds **sur lesquels on conditionne**.

« La disposition du graphe **DÉPEND du choix de FACTORISATION** de la loi jointe. »

Du **GRAPHE** vers la **FACTORISATION (exemple 8.8)**. Deux propriétés :

- « La loi jointe est le **produit d'un ensemble de conditionnelles, UNE PAR NŒUD** du graphe. »

- « Chaque conditionnelle ne dépend **QUE des PARENTS** du nœud correspondant. »

Pour la figure 8.9(b) :

$$p(x_1, x_2, x_3, x_4, x_5) = p(x_1) p(x_5) p(x_2 | x_5) p(x_3 | x_1, x_2) p(x_4 | x_2)$$

$$p(x) = p(x_1, \dots, x_K) = \prod_{k=1}^K p(x_k | \mathbf{Pa}_k)$$

où $\mathbf{Pa}_k$ désigne « les nœuds **PARENTS** de x_k », c'est-à-dire « les nœuds qui ont des flèches pointant vers x_k ».

5.3 Les conventions graphiques

L'exemple canonique — le lancer de pièce répété. Avec $p(x | \mu) = \text{Ber}(\mu)$ répété N fois :

$$p(x_1, \dots, x_N | \mu) = \prod_{n=1}^N p(x_n | \mu)$$

« Le membre de droite est un **produit de lois de Bernoulli** parce que les expériences sont **INDÉPENDANTES** — l'indépendance statistique signifie que la loi **SE FACTORISE**. »

Convention	Signification
Nœud GRISÉ / ombré	Variable OBSERVÉE
Nœud blanc	Variable latente / non observée
PLAQUE (une boîte)	« Elle RÉPÈTE tout ce qui est à l'intérieur N fois » — les deux graphiques sont équivalents , mais la plaque est plus compacte

L'HYPER-A-PRIORI. « Les modèles graphiques permettent immédiatement de placer un **HYPER-A-PRIORI** sur μ : une **SECONDE COUCHE de lois a priori sur les paramètres de la première couche** » — c'est la figure 8.10(c), avec α et β au-dessus de μ .

Le livre observe : « le **paramètre UNIQUE** μ est **LE MÊME** pour tous les x_n , puisque les résultats sont **identiquement distribués**. »

5.4 La d -séparation

Le but. Déterminer si l'énoncé $A \perp\!\!\!\perp B \mid C$ (« A est conditionnellement indépendant de B sachant C ») est **impliqué par le graphe orienté acyclique**, pour des ensembles de nœuds A, B, C disjoints.

La procédure. Considérer **toutes les traînes** (*trails*) — les chemins **ignorant le sens des flèches** — de tout nœud de A vers tout nœud de B . Une traîne est **BLOQUÉE** si elle inclut un nœud tel que l'une des conditions suivantes est vraie :

1. Les flèches se rencontrent **TÊTE-À-QUEUE** ou **QUEUE-À-QUEUE** au nœud, **ET** le nœud est **DANS** C

2. Les flèches se rencontrent **TÊTE-À-TÊTE** au nœud, **ET NI** le nœud **NI** AUCUN de ses DESCENDANTS n'est dans C

Si **TOUTES** les traînes sont bloquées, A est **d -SÉPARÉ** de B par C , et $A \perp\!\!\!\perp B \mid C$

Noter l'asymétrie du cas 2 : pour une rencontre **tête-à-tête** (une « collision »), c'est l'**ABSENCE** du nœud et de ses descendants dans C qui bloque — l'inverse des deux autres configurations.

Exemple 8.9 — la lecture visuelle sur le graphe $a \rightarrow b, a \rightarrow c, \dots$ de la figure 8.11 :

$$b \perp\!\!\!\perp d \mid a, c \quad a \perp\!\!\!\perp c \mid b$$

$$b \not\perp\!\!\!\perp d \mid c \quad a \not\perp\!\!\!\perp c \mid b, e$$

Les **deux dernières lignes montrent la sensibilité** : ajouter e à l'ensemble conditionnant **DÉTRUIT** l'indépendance $a \perp\!\!\!\perp c \mid b$ — signature d'une **collision** dont e est un descendant.

Les trois familles de modèles graphiques (figure 8.12) : les **ORIENTÉS** (réseaux bayésiens), les **NON ORIENTÉS** (champs de Markov aléatoires), et les **GRAPHES DE FACTEURS**.

● Concept 6 — La sélection de modèle (§8.6)

6.1 Le problème

Le dilemme d'expressivité. « Un polynôme de degré 1 ne peut décrire que des relations linéaires ; un polynôme de degré 2 peut aussi décrire des relations quadratiques. » « Un polynôme $y = a_0 + a_1x + a_2x^2$ peut **AUSSI** décrire des fonctions linéaires en posant $a_2 = 0$: il est **STRICTEMENT PLUS EXPRESSIF** qu'un polynôme d'ordre 1. »

POURQUOI NE PAS TOUJOURS PRENDRE LE PLUS FLEXIBLE.

« À l'entraînement, on ne peut utiliser que l'ensemble d'entraînement pour évaluer la performance. Mais **la performance sur l'ensemble d'entraînement n'est PAS ce qui nous intéresse vraiment.** »

6.2 La validation croisée imbriquée

L'idée : appliquer la validation croisée **UNE FOIS DE PLUS** — pour chaque découpe, effectuer un **autre tour** de validation croisée.

Boucle	Rôle	Nom de l'ensemble
INTERNE	« Estimer la performance d'un choix particulier de MODÈLE ou d'HYPERPARAMÈTRE »	Ensemble de VALIDATION
EXTERNE	« Estimer la performance de GÉNÉRALISATION pour le meilleur choix issu de la boucle interne »	Ensemble de TEST

$$\mathbb{E}_{\mathcal{V}}[R(\mathcal{V} \mid M)] \approx \frac{1}{K} \sum_{k=1}^K R(\mathcal{V}^{(k)} \mid M)$$

Un bonus. « La validation croisée ne donne pas seulement l'erreur de généralisation espérée : on peut aussi obtenir des **statistiques d'ordre SUPÉRIEUR**, par exemple l'**ERREUR-TYPE** » :

$$\text{erreur-type} = \frac{\sigma}{\sqrt{K}}$$

où K est le nombre d'expériences et σ l'écart-type du risque de chaque expérience.

6.3 La sélection bayésienne et le rasoir d'Occam

Le principe commun. « Toutes les approches tentent d'**ARBITRER** entre **COMPLEXITÉ** du modèle et **AJUSTEMENT** aux données. On suppose que les modèles plus simples sont **moins sujets au surapprentissage**, et l'objectif est donc de trouver **le modèle LE PLUS SIMPLE qui explique raisonnablement bien les données** — c'est le **RASOIR D'OCCAM**. »

LE POINT REMARQUABLE. « On pourrait envisager de placer un *a priori* sur les modèles qui favorise les modèles simples. **CE N'EST PAS NÉCESSAIRE** : un "**RASOIR D'OCCAM AUTOMATIQUE**" est quantitativement **incorporé dans l'application de la probabilité BAYÉSIENNE**. »

L'intuition de la figure 8.14 (adaptée de MacKay, 2003) — l'axe horizontal représente l'espace de tous les jeux de données possibles $\mathcal{D}$:

- Un modèle **SIMPLE** M_1 ne peut prédire qu'un **petit nombre** de jeux de données : $p(\mathcal{D} \mid M_1)$ est **concentrée**.
- Un modèle **PUISSANT** M_2 (plus de paramètres libres) prédit une **plus grande variété** de jeux — « mais cela signifie que M_2 **ne prédit PAS aussi bien** les jeux de la région C que M_1 . »
- **La contrainte cachée** : « ces prédictions sont quantifiées par une **loi de probabilité NORMALISÉE** sur $\mathcal{D}$: elle doit **intégrer/sommer à 1**. » C'est cette normalisation qui **pénalise automatiquement** la complexité.
- **Conclusion** : « si le jeu de données tombe dans la région C , le modèle **MOINS puissant** M_1 est le **PLUS PROBABLE**. »

Le processus génératif hiérarchique. Pour un ensemble fini de modèles $\mathcal{M} = \{M_1, \dots, M_K\}$:

$$M_k \sim p(M), \quad \theta_k \sim p(\theta \mid M_k), \quad \mathcal{D} \sim p(\mathcal{D} \mid \theta_k)$$

$$p(M_k | \mathcal{D}) \propto p(M_k) p(\mathcal{D} | M_k)$$

Le point clé. *« Cet a posteriori **NE DÉPEND PLUS** des paramètres θ_k , car ils ont été **INTÉGRÉS** dans le cadre bayésien »* :

$$p(\mathcal{D} | M_k) = \int p(\mathcal{D} | \theta_k) p(\theta_k | M_k) d\theta_k$$

C'est l'**ÉVIDENCE DU MODÈLE** (ou **vraisemblance marginale**), et l'on choisit $M^* = \arg \max_{M_k} p(M_k | \mathcal{D})$.

VRAISEMBLANCE contre VRAISEMBLANCE MARGINALE — la différence décisive. « Alors que la *vraisemblance* est **SUJETTE AU SURAPPRENTISSAGE**, la *vraisemblance MARGINALE* ne l'est **typiquement PAS**, puisque les paramètres du modèle ont été **MARGINALISÉS** (on n'a plus à les ajuster). De plus, la vraisemblance marginale **incorpore AUTOMATIQUEMENT un compromis** entre complexité du modèle et ajustement aux données — le **rasoir d'Occam**. »

6.4 Les facteurs de Bayes

Pour comparer deux modèles M_1 et M_2 :

$$\frac{p(M_1 | \mathcal{D})}{p(M_2 | \mathcal{D})} = \underbrace{\frac{p(M_1)}{p(M_2)}}_{\text{RAPPORT A PRIORI}} \cdot \underbrace{\frac{p(\mathcal{D} | M_1)}{p(\mathcal{D} | M_2)}}_{\text{FACTEUR DE BAYES}}$$

Terme	Ce qu'il mesure
Rapport A POSTERIORI (<i>posterior odds</i>)	Le rapport des a posteriori
Rapport A PRIORI (<i>prior odds</i>)	« À quel point nos croyances initiales favorisent M_1 sur M_2 »
FACTEUR DE BAYES	« À quel point les données $\mathcal{D}$ sont bien PRÉDITES par M_1 comparé à M_2 »

Avec un a priori **UNIFORME** sur les modèles, le rapport a priori vaut **1** :

$$\text{rapport a posteriori} = \frac{p(\mathcal{D} | M_1)}{p(\mathcal{D} | M_2)}$$

Facteur de Bayes $> 1 \Rightarrow$ choisir M_1 ; sinon M_2

« De façon similaire aux statistiques fréquentistes, il existe des **lignes directrices sur la TAILLE du rapport** à considérer avant de parler de "significativité" (Jeffreys, 1961). »

LE PARADOXE DE JEFFREYS-LINDLEY. « Le facteur de Bayes **FAVORISE TOUJOURS le modèle PLUS SIMPLE**, puisque la probabilité des données sous un **modèle complexe avec un a priori DIFFUS sera très PETITE** » (Murphy, 2012). Un **a priori diffus** est un a priori qui **ne favorise aucun modèle** en particulier — **beaucoup de modèles sont a priori plausibles**.

Comment reconnaître le type d'exercice

L'énoncé dit...	Le type	La méthode
« Convertir cette table en format numérique »	§8.1.1	Encoder les catégorielles ; utiliser la connaissance du domaine ; standardiser (moyenne 0, variance 1) ; supprimer les identifiants
« Écrire le prédicteur affine »	Ex. 8.1	Concaténer $x^{(0)} = 1$, écrire $f(x_n, \theta) = \theta^\top x_n$
« Écrire le risque empirique »	§8.2.2	$\frac{1}{N} \sum_n \ell(y_n, \hat{y}_n)$
« Quelle est la différence avec le risque espéré ? »	§8.2.2	Empirique : moyenne sur N points . Espéré : espérance sur la vraie loi (infinie)
« Le modèle sur-apprend »	§8.2.3	Ajouter $\lambda \ \theta\ ^2$; les magnitudes des paramètres deviennent grandes en surapprentissage
« Estimer l'erreur de généralisation »	§8.2.4	Validation croisée à K plis ; moyenner les K risques empiriques
« Écrire la log-vraisemblance négative »	§8.3.1	$L(\theta) = -\sum_n \log p(y_n x_n, \theta)$
« Bruit gaussien, modèle linéaire »	Ex. 8.5	Le MLE SE RAMÈNE aux moindres carrés
« On a une connaissance a priori sur θ »	§8.3.2	MAP : $p(\theta x) \propto p(x \theta)p(\theta)$; l'a priori est la régularisation
« Le modèle sur-ajuste ou sous-ajuste ? »	§8.3.3	Classe trop riche $\Rightarrow$ sur-ajustement ; pas assez riche $\Rightarrow$ sous-ajustement
« Spécifier un modèle probabiliste »	§8.4.1	Donner la LOI JOINTE de toutes les variables
« Faire une prédiction bayésienne »	§8.4.2	$p(x) = \int p(x \theta)p(\theta)d\theta$ — intégrer , ne pas brancher θ^*
« Le modèle a des variables latentes »	§8.4.3	$p(x \theta) = \int p(x z, \theta)p(z)dz$; algorithme EM
« Dessiner le modèle graphique »	§8.5.1	Un nœud par variable ; une flèche depuis chaque variable conditionnante

L'énoncé dit...	Le type	La méthode
« Lire la loi jointe sur le graphe »	Ex. 8.8	$\prod_k p(x_k \mid \mathbf{Pa}_k)$
« N observations i.i.d. »	§8.5.1	Utiliser une PLAQUE ; griser les nœuds observés
« A et B sont-elles indépendantes sachant C ? »	d-séparation	Examiner toutes les traînes ; appliquer les deux règles de blocage
« Choisir entre plusieurs modèles »	§8.6	Validation croisée imbriquée ou évidence bayésienne
« Comparer deux modèles bayésiennement »	§8.6.3	Le facteur de Bayes $p(\mathcal{D} \mid M_1)/p(\mathcal{D} \mid M_2)$

Comment résoudre : les quatre méthodes pas-à-pas

Méthode A — Poser un problème de minimisation du risque empirique.

1. Fixer la **classe d'hypothèses** (affine, polynomiale...) et sa paramétrisation.
2. Choisir la **fonction de perte** ℓ ; elle doit **correspondre à la métrique de performance** de la tâche.
3. Écrire $R_{\text{emp}} = \frac{1}{N} \sum_n \ell(y_n, f(x_n, \theta))$.
4. Ajouter un **régularisateur** $\lambda \|\theta\|^2$ si le modèle risque de sur-apprendre.
5. Optimiser (fermé si moindres carrés, sinon ch. 7).
6. **Estimer la généralisation** par validation croisée.

Méthode B — Dériver un estimateur du maximum de vraisemblance.

1. Spécifier $p(y_n \mid x_n, \theta)$ — la loi du **bruit**.
2. Invoquer l'i.i.d. pour **factoriser** : $\prod_n p(y_n \mid x_n, \theta)$.
3. Prendre le **logarithme négatif** : $-\sum_n \log p(y_n \mid x_n, \theta)$.
4. **Développer** et **écarter les constantes** en θ .
5. **Reconnaître** l'objectif classique obtenu (moindres carrés pour un bruit gaussien).
6. Minimiser ; vérifier si une **solution fermée** existe.

Méthode C — Passer de MLE à MAP.

1. Choisir un **a priori** $p(\theta)$; le prendre **CONJUGUÉ** de la vraisemblance rend l'a posteriori de même forme.

2. Écrire $p(\theta | x) \propto p(x | \theta)p(\theta)$ — **ignorer** $p(x)$.
3. Prendre le **logarithme négatif** des **deux** termes.
4. Le terme issu de l'a priori **EST** le régularisateur ; l'identifier.
5. Minimiser.
6. **Contrôle qualitatif** : l'a priori doit **biaiser les paramètres vers l'origine**.

Méthode D — Lire un modèle graphique.

1. **Lister les nœuds** ; distinguer **observés (grisés)** et **latents (blancs)**.
2. **Dérouler les plaques** mentalement.
3. Pour chaque nœud, identifier ses **PARENTS**.
4. Écrire $p(x) = \prod_k p(x_k | \mathbf{Pa}_k)$.
5. Pour une question d'indépendance : lister **toutes les traînes**, tester le **blocage** de chacune.
6. Attention aux **collisions** (tête-à-tête) : elles bloquent **par défaut** et se **débloquent** en conditionnant.

● Common mistakes

Erreur	Correction
Oublier de standardiser les colonnes	« Sans information supplémentaire », viser moyenne 0 et variance 1
Garder un identifiant comme attribut	Non informatif et problème de vie privée
Croire qu'« affine » et « linéaire » sont interchangeables	Le livre le signale : en ML on dit « linéaire » pour « affine » — c'est un abus
Confondre les trois phases	Prédiction (paramètres fixés) · entraînement (on les ajuste) · sélection (on choisit les hyperparamètres)
Croire que « inférence » a un sens unique	« Pas de nommage consensuel » — le mot désigne parfois la prédiction , parfois l' estimation de paramètres
Optimiser le risque empirique et s'en satisfaire	Ce qui compte est le risque ESPÉRÉ sur des données non vues
Croire que la MRE est « exempte de probabilité »	Incorrect : il y a une $p(x, y)$ sous-jacente ; l'approche y est seulement AGNOSTIQUE
Concevoir la perte sans regarder la métrique de la tâche	Le décalage est fréquent mais reste un défaut
Prendre λ trop grand	Le prédicteur est biaisé vers l'origine et sous-ajuste
Prendre un ensemble de validation trop petit	Estimation BRUITÉE, à forte variance — d'où la validation croisée
Croire la validation croisée trop coûteuse	Elle est EMBARRASSAMMENT PARALLÈLE
Regarder la performance sur le test « juste pour voir »	Même cela fait fuir de l'information (Blum & Hardt, 2015)
Interpréter θ comme observé dans $p(y_n x_n, \theta)$	« Cette interprétation est INCORRECTE » — $L(\theta)$ est une fonction de θ
Chercher un sens profond au signe moins	C'est un artefact HISTORIQUE : on maximise la vraisemblance mais on minimise en optimisation
Croire que le MLE a toujours une solution fermée	Seulement pour certaines vraisemblances (gaussienne) ; sinon, méthodes numériques

Erreur	Correction
Faire confiance au MLE sur peu de données	« Surtout dans le régime des PETITES données, il peut mener au SURAPPRENTISSAGE » — la variance décroît en $1/N$
Croire que le MAP donne une loi	NON : il ne produit encore qu'une ESTIMATION PONCTUELLE
Croire régularisation et a priori sans rapport	Ce sont la même idée dans deux langages
Croire qu'un modèle plus flexible est toujours meilleur	Il utilise sa puissance à trouver du signal DANS LE BRUIT
Spécifier un modèle probabiliste par sa seule vraisemblance	Un modèle probabiliste EST la LOI JOINTE de toutes ses variables
Prédire avec $p(x \theta^*)$ en contexte bayésien	Prédire avec $\int p(x \theta)p(\theta)d\theta$ — propager l'incertitude
Confondre paramètres et variables latentes	Les latentes ne paramétrisent PAS le modèle explicitement
Croire la marginalisation des latentes toujours faisable	Analytiquement intraitable sauf a priori conjugué
Oublier un parent en lisant un graphe	$p(x_k \mathbf{Pa}_k)$ demande TOUS les parents
Croire que le graphe est unique	« La disposition dépend du CHOIX de FACTORISATION »
Croire que toute loi a un modèle graphique	NON — le livre le signale
Appliquer la d -séparation en suivant le sens des flèches	On considère les TRAÎNES — des chemins ignorant le sens
Traiter la collision comme les autres configurations	Tête-à-tête : bloquée SI le nœud ET ses descendants sont HORS de C' — la règle est inversée
Sélectionner un modèle sur l'ensemble de test	La sélection se fait sur la VALIDATION (boucle interne) ; le test estime la généralisation
Croire qu'il faut un a priori favorisant la simplicité	NON : le rasoir d'Occam est AUTOMATIQUE dans l'évidence
Confondre vraisemblance et vraisemblance marginale	La marginale intègre les paramètres et ne sur-apprend typiquement pas

Erreur	Correction
Oublier le paradoxe de Jeffreys-Lindley	Avec un a priori DIFFUS , le facteur de Bayes favorise toujours le modèle simple

Ultimate Review

===== LES SEPT FORMULES À SAVOIR SANS HÉSITER =====

1. RISQUE EMPIRIQUE $R_{emp}(f, X, y) = (1/N) \sum_n \ell(y_n, \hat{y}_n)$
2. RISQUE ESPÉRÉ $R_{true}(f) = E_{\{x,y\}}[\ell(y, f(x))]$
3. RÉGULARISÉ $\min (1/N) \|y - X\theta\|^2 + \lambda \|\theta\|^2$
4. LOG-VRAISEMBLANCE NÉGATIVE $L(\theta) = -\sum_n \log p(y_n | x_n, \theta)$
🚨 bruit GAUSSIEN $\Rightarrow L(\theta) = (1/2\sigma^2) \sum_n (y_n - x_n^T \theta)^2 + \text{const}$
5. MAP $p(\theta | x) \propto p(x | \theta) p(\theta)$
6. PRÉDICTION BAYÉSIENNE $p(x) = \int p(x|\theta) p(\theta) d\theta = E_{\theta}[p(x|\theta)]$
LATENTES $p(x|\theta) = \int p(x|z, \theta) p(z) dz$
7. GRAPHE $p(x) = \prod_k p(x_k | Pa_k)$
ÉVIDENCE $p(D | M_k) = \int p(D | \theta_k) p(\theta_k | M_k) d\theta_k$
FACTEUR DE BAYES $p(D|M1) / p(D|M2)$

LE TABLEAU DE CORRESPONDANCE — le cœur du chapitre :

Monde NON PROBABILISTE (§8.2)	Monde PROBABILISTE (§8.3-8.4)
Fonction de PERTE ℓ	VRAISEMBLANCE $p(y x, \theta)$
Perte QUADRATIQUE	Vraisemblance GAUSSIENNE
RÉGULARISATEUR $\lambda \ \theta\ ^2$	A PRIORI $p(\theta) = \mathcal{N}(0, \Sigma)$
Minimiser le RISQUE EMPIRIQUE	Minimiser la LOG-VRAISEMBLANCE NÉGATIVE
Risque empirique RÉGULARISÉ	MAP
Validation croisée pour la généralisation	ÉVIDENCE / vraisemblance marginale
Estimation ponctuelle	Loi a posteriori COMPLÈTE (inférence bayésienne)

Les trois régimes d'ajustement :

Régime	Classe M_θ	Erreur d'entraînement	Erreur de test
Sur-ajustement	Trop riche	Très faible — le modèle apprend le bruit	Élevée
Sous-ajustement	Pas assez riche	Élevée	Élevée
Bon ajustement	Adaptée	Modérée	Faible

Les trois niveaux de « prendre en compte l'incertitude » :

Niveau	Ce qu'on obtient	Coût
MLE	Une estimation ponctuelle	Optimisation
MAP	Une estimation ponctuelle biaisée par un a priori	Optimisation
Bayésien complet	La LOI a posteriori entière	Intégration (souvent intraitable)

Où chaque notion resservira dans le livre :

Notion du ch. 8	Suite
Moindres carrés, MLE, MAP	Régression linéaire (ch. 9)
Application d'attributs $\phi(\cdot)$	§9.2, puis NOYAUX (§12.4)
Variables latentes, EM	ACP (ch. 10), mélanges gaussiens (ch. 11)
Modèles graphiques	Chapitres 9, 10 et 11
Régularisation	GRANDE MARGE des SVM (ch. 12)
Évidence, sélection de modèle	Choix du degré du polynôme (§9.3)

Active Recall

Données et modèles

1. Quelle est la question centrale de l'apprentissage automatique ?
2. Quels sont les synonymes d'« attribut » ? d'« étiquette » ?
3. Que valent N , D et X ?

4. Quelle règle par défaut le livre donne-t-il sur la mise à l'échelle ?
5. Pourquoi supprimer la colonne Nom ? Deux raisons.
6. Donner les deux visions du modèle.
7. Pourquoi le livre se restreint-il aux fonctions linéaires ?
8. Quelles sont les trois phases algorithmiques ? Quel est l'avertissement terminologique ?
9. Quelles sont les deux stratégies d'entraînement ? Laquelle exige un modèle probabiliste ?
10. D'où vient le signe moins dans les objectifs ?
11. Qu'est-ce que l'abduction ? Pourquoi le mot ici ?
12. Comment distinguer paramètre et hyperparamètre ?

Minimisation du risque empirique 13. Citer les quatre choix de conception. 14. Écrire le prédicteur affine avec l'astuce de l'attribut unité. 15. Écrire le risque empirique et le risque espéré. Quelle est la différence essentielle ? 16. Détailler l'exemple 8.2 jusqu'à la forme matricielle. 17. Quelles sont les deux questions pratiques posées par le risque espéré ? 18. Quel décalage le livre signale-t-il entre perte et métrique ? 19. Écrire le problème des moindres carrés régularisé. Nommer les deux termes ajoutés. 20. Quel signe empirique accompagne le surapprentissage ? 21. Citer les trois formes équivalentes de l'idée de régularisation. 22. Décrire la validation croisée à K plis et écrire son estimateur. 23. Pourquoi le coût n'est-il pas un obstacle ? 24. Pourquoi « exempt de probabilité » est-il incorrect ?

MLE et MAP 25. Écrire la log-vraisemblance négative. Que souligne la notation ? 26. Donner les deux lectures de $p(\mathbf{x} \mid \boldsymbol{\theta})$. 27. Quel piège d'interprétation le livre signale-t-il ? 28. Écrire la vraisemblance gaussienne de l'exemple 8.4. 29. Que signifient « indépendantes » et « identiquement distribuées » ici ? 30. Dériver l'exemple 8.5. Quelle est la conclusion ? 31. Écrire le MAP. Pourquoi peut-on ignorer $p(\mathbf{x})$? 32. Quel a priori choisit l'exemple 8.6 ? Quelle est sa vertu ? 33. Quel effet l'a priori a-t-il sur la pente et l'ordonnée à l'origine ? 34. Quelle est la position intermédiaire du MAP ? 35. Donner les deux propriétés asymptotiques du MLE. 36. Distinguer sur-ajustement, sous-ajustement, bon ajustement.

Modélisation probabiliste 37. Qu'est-ce qui spécifie un modèle probabiliste ? 38. Comment obtenir a priori, vraisemblance marginale et a posteriori de la jointe ? 39. Quelle est la différence entre inférence bayésienne et estimation ponctuelle ? 40. Écrire la prédiction bayésienne. 41. Qu'est-ce qu'une variable latente ? En quoi diffère-t-elle d'un paramètre ? 42. Citer trois vertus des variables latentes et trois modèles qui en utilisent. 43. Écrire la vraisemblance marginalisée. Quel est le défi ?

Modèles graphiques 44. Que représentent nœuds et flèches ? 45. Citer les quatre propriétés commodes. 46. Donner la recette factorisation $\rightarrow$ graphe. 47. Donner les deux propriétés graphe $\rightarrow$ factorisation. Écrire la formule générale. 48. Que signifie un nœud grisé ? une plaque ? 49. Qu'est-

ce qu'un hyper-a-priori ? 50. Énoncer les deux règles de blocage de la *d*-séparation. 51. Pourquoi la règle de la collision est-elle inversée ? 52. Citer les trois familles de modèles graphiques.

Sélection de modèle 53. Pourquoi un modèle plus expressif n'est-il pas toujours préférable ? 54. Décrire la validation croisée imbriquée. Quel rôle a chaque boucle ? 55. Écrire l'erreur-type. 56. Qu'est-ce que le rasoir d'Occam ? 57. Expliquer la figure 8.14. Quelle contrainte rend le rasoir automatique ? 58. Écrire le processus génératif hiérarchique et l'évidence. 59. Quelle est la différence essentielle entre vraisemblance et vraisemblance marginale ? 60. Écrire le rapport a posteriori et nommer ses deux facteurs. 61. Énoncer le paradoxe de Jeffreys-Lindley. Qu'est-ce qu'un a priori diffus ?

Flashcards

Question	Réponse
La question centrale de l'apprentissage automatique ?	« Qu'entend-on par de BONS modèles ? »
Le principe directeur ?	Bien se comporter sur des données NON VUES
Synonymes d'attribut ?	Caractéristique (<i>feature</i>) · covariable
Synonymes d'étiquette ?	Cible · variable de réponse · annotation
Notation du jeu de données ?	$\{(x_1, y_1), \dots, (x_N, y_N)\}$ et $X \in \mathbb{R}^{N \times D}$
Règle de mise à l'échelle par défaut ?	Moyenne empirique 0, variance empirique 1 sur chaque colonne
Pourquoi supprimer les noms ?	Non informatifs · ANONYMISATION
Les deux visions du modèle ?	Une FONCTION $f : \mathbb{R}^D \rightarrow \mathbb{R}$ · une LOI DE PROBABILITÉ
Le prédicteur linéaire ?	$f(x) = \theta^\top x + \theta_0$
Pourquoi les fonctions linéaires ?	Bon équilibre entre généralité et mathématiques nécessaires
Pourquoi la vision probabiliste ?	Pour exprimer l' INCERTITUDE et la CONFIANCE dans une prédiction
Les trois phases ?	Prédiction/inférence · Entraînement · Sélection de modèle
L'avertissement terminologique ?	« <i>Pas de nommage consensuel</i> » — « inférence » a plusieurs sens
Les deux stratégies d'entraînement ?	Estimation ponctuelle · Inférence bayésienne (modèle probabiliste requis)
Le principe non probabiliste ?	La minimisation du RISQUE EMPIRIQUE
Le principe probabiliste ?	Le MAXIMUM DE VRAISEMBLANCE
D'où vient le signe moins ?	On MINIMISE en optimisation, mais on MAXIMISE la vraisemblance
Qu'est-ce que l'abduction ?	Ni induction ni déduction — l' inférence vers la MEILLEURE EXPLICATION
Paramètre contre hyperparamètre ?	Ce qui est numériquement optimisable contre ce qui exige une RECHERCHE

Question	Réponse
Les quatre choix de la MRE ?	Classe d'hypothèses · perte · régularisation · procédure de recherche
L'astuce de l'attribut unité ?	Concaténer $\mathbf{x}^{(0)} = \mathbf{1}$ pour écrire l'affine comme $\boldsymbol{\theta}^T \mathbf{x}_n$
« Affine » en ML ?	Souvent appelé « linéaire » — abus signalé par le livre
Risque empirique ?	$R_{\text{emp}} = \frac{1}{N} \sum_n \ell(y_n, \hat{y}_n)$
Ses trois arguments ?	Le prédicteur f , les données $\mathbf{X}, \mathbf{y}$
Risque espéré ?	$R_{\text{true}}(f) = \mathbb{E}_{\mathbf{x}, \mathbf{y}}[\ell(\mathbf{y}, f(\mathbf{x}))]$
Son autre nom ?	Le risque de POPULATION
La différence essentielle ?	Le risque espéré suppose une quantité INFINIE de données
La perte quadratique en forme matricielle ?	$\min_{\boldsymbol{\theta}} \frac{1}{N} \ \mathbf{y} - \mathbf{X}\boldsymbol{\theta}\ ^2$
Comment se résout-il ?	Par les ÉQUATIONS NORMALES , en forme fermée
Le décalage signalé ?	La perte devrait correspondre à la métrique de performance ; en pratique elle diverge
Le problème régularisé ?	$\min_{\boldsymbol{\theta}} \frac{1}{N} \ \mathbf{y} - \mathbf{X}\boldsymbol{\theta}\ ^2 + \lambda \ \boldsymbol{\theta}\ ^2$
Les deux noms des termes ?	Le RÉGULARISATEUR (ou terme de pénalité) · le paramètre de régularisation λ
Que fait le terme de pénalité ?	Il BIAISE $\boldsymbol{\theta}$ vers l' ORIGINE
Le signe empirique du surapprentissage ?	La magnitude des paramètres devient GRANDE
Les trois visages de la régularisation ?	Régularisateur · A PRIORI · GRANDE MARGE (SVM)
Le nom de cette régularisation ?	La régularisation de TIKHONOV (variante contrainte : IVANOV)
Validation croisée à K plis ?	$K - 1$ morceaux d'entraînement, 1 de validation, K passages moyennés
Le dilemme qu'elle résout ?	Grand ensemble d'entraînement contre grand ensemble de validation
Son coût ?	Embarrassamment PARALLÈLE — pas plus long qu'une seule évaluation

Question	Réponse
Le risque de regarder le test ?	« Même connaître la performance sur le test FAIT FUITER de l'information »
La MRE est-elle « sans probabilité » ?	NON — elle est seulement AGNOSTIQUE à $p(x, y)$
Log-vraisemblance négative ?	$\mathcal{L}_x(\theta) = -\log p(x \theta)$
Ce que souligne la notation $\mathcal{L}_x(\theta)$?	θ VARIE, x est FIXÉE
Lecture avec θ fixé ?	L'incertitude des DONNÉES pour ce réglage
Lecture avec x fixé ?	À quel point ce θ est PROBABLE pour ces observations
Le piège d'interprétation ?	Croire θ observé parce qu'il est à droite du conditionnement — INCORRECT
La vraisemblance de l'exemple 8.4 ?	$\mathcal{N}(y_n x_n^\top \theta, \sigma^2)$, bruit $\varepsilon_n \sim \mathcal{N}(0, \sigma^2)$
Que donne « indépendantes » ?	La vraisemblance SE FACTORISE en un produit
Que donne « identiquement distribuées » ?	Chaque terme est de la MÊME loi et partage les mêmes paramètres
Pourquoi le logarithme ?	Transformer un PRODUIT en SOMME — plus facile à optimiser
Le résultat de l'exemple 8.5 ?	Vraisemblance GAUSSIENNE $\iff$ MOINDRES CARRÉS
La forme obtenue ?	$L(\theta) = \frac{1}{2\sigma^2} \sum_n (y_n - x_n^\top \theta)^2 - N \log \frac{1}{\sqrt{2\pi\sigma^2}}$
Pourquoi le second terme disparaît-il ?	Il est CONSTANT en θ (si σ est donné)
Le MLE a-t-il toujours une solution fermée ?	NON — seulement pour certaines vraisemblances
Consistance asymptotique ?	Le MLE converge vers la vraie valeur à la limite infinie, avec une erreur approximativement normale
Décroissance de la variance ?	En $1/N$
Le danger sur peu de données ?	SURAPPRENTISSAGE
L'estimation MAP ?	$p(\theta x) \propto p(x \theta)p(\theta)$
Pourquoi ignorer $p(x)$?	Elle ne dépend pas de θ

Question	Réponse
L'a priori de l'exemple 8.6 ?	$p(\theta) = \mathcal{N}(0, \Sigma)$ — conjugué , donc a posteriori gaussien
Son effet visible ?	Pente moins raide · ordonnée plus proche de zéro
La position du MAP ?	Un PONT : il reconnaît l'a priori mais ne donne qu'une ESTIMATION PONCTUELLE
Sur-ajustement ?	Classe TROP RICHE ; elle trouve du signal DANS LE BRUIT
Sous-ajustement ?	Classe PAS ASSEZ RICHE (données sinusoïdales, modèle linéaire)
Qu'est-ce qui spécifie un modèle probabiliste ?	La LOI JOINTE $p(x, \theta)$ de toutes ses variables
Comment obtenir la vraisemblance marginale ?	En INTÉGRANT les paramètres (règle de la somme)
Comment obtenir l'a posteriori ?	En divisant la jointe par la vraisemblance marginale
Inférence bayésienne ?	Apprendre la LOI des variables, pas une valeur
Le coût de l'estimation ponctuelle ?	Perte d'information — critique pour la prise de DÉCISION
La prédiction bayésienne ?	$p(x) = \int p(x \theta)p(\theta)d\theta = \mathbb{E}_{\theta}[p(x \theta)]$
Variable latente ?	Une variable qui NE paramétrise PAS le modèle explicitement
Ses trois vertus ?	Interprétabilité du processus générateur · structures plus simples et plus riches · moins de paramètres
L'algorithme dédié ?	L' ESPÉRANCE-MAXIMISATION (EM)
La vraisemblance marginalisée ?	$p(x \theta) = \int p(x z, \theta)p(z)dz$
Dépend-elle des latentes ?	NON — c'est tout l'intérêt
Le défi ?	Analytiquement INTRAITABLE sauf a priori CONJUGUÉ
Nœuds et flèches d'un modèle graphique ?	Nœuds = variables aléatoires · flèches = probabilités conditionnelles
Autre nom des modèles orientés ?	Les RÉSEAUX BAYÉSIENS

Question	Réponse
Recette factorisation → graphe ?	1. un nœud par variable 2. une flèche depuis chaque variable conditionnante
Formule graphe → factorisation ?	$p(x) = \prod_{k=1}^K p(x_k \mid \mathbf{Pa}_k)$
Que signifie $\mathbf{Pa}_k$?	Les nœuds PARENTS de x_k — ceux dont les flèches pointent vers x_k
Le graphe est-il unique ?	NON — il dépend du choix de factorisation
Toute loi a-t-elle un graphe ?	NON
Nœud grisé ?	Variable OBSERVÉE
Plaque ?	Une boîte qui RÉPÈTE son contenu N fois
Hyper-a-priori ?	Une SECONDE COUCHE d'a priori sur les paramètres de la première
d -séparation, règle 1 ?	Flèches tête-à-queue ou queue-à-queue , et le nœud EST DANS C
d -séparation, règle 2 ?	Flèches TÊTE-À-TÊTE , et NI le nœud NI aucun descendant n'est dans C
Que sont les traînes ?	Des chemins qui IGNORENT le sens des flèches
Conclusion si toutes les traînes sont bloquées ?	$A \perp\!\!\!\perp B \mid C$
Les trois familles de modèles graphiques ?	Orientés (bayésiens) · non orientés (champs de Markov) · graphes de FACTEURS
Un polynôme de degré 2 contient-il les linéaires ?	OUI — poser $a_2 = 0$; il est strictement plus expressif
Validation croisée imbriquée, boucle interne ?	Estimer la performance d'un choix de modèle / hyperparamètre — ensemble de VALIDATION
Boucle externe ?	Estimer la GÉNÉRALISATION du meilleur choix — ensemble de TEST
Erreur-type ?	$\sigma/\sqrt{K}$
Rasoir d'Occam ?	Chercher le modèle le plus SIMPLE qui explique raisonnablement les données
Faut-il un a priori favorisant la simplicité ?	NON — le rasoir est AUTOMATIQUE dans l'évidence bayésienne

Question	Réponse
Pourquoi ?	Parce que $p(\mathcal{D} \mid M_i)$ doit INTÉGRER À 1 sur l'espace des jeux de données
Le processus génératif hiérarchique ?	$M_k \sim p(M), \theta_k \sim p(\theta \mid M_k), \mathcal{D} \sim p(\mathcal{D} \mid \theta_k)$
L'a posteriori sur les modèles ?	$p(M_k \mid \mathcal{D}) \propto p(M_k)p(\mathcal{D} \mid M_k)$
L'évidence ?	$p(\mathcal{D} \mid M_k) = \int p(\mathcal{D} \mid \theta_k)p(\theta_k \mid M_k)d\theta_k$
Son autre nom ?	La VRAISEMBLANCE MARGINALE
Vraisemblance contre marginale ?	La vraisemblance SUR-APPREND ; la marginale NON (paramètres marginalisés)
Rapport a posteriori ?	$\frac{p(M_1)}{p(M_2)} \cdot \frac{p(\mathcal{D} \mid M_1)}{p(\mathcal{D} \mid M_2)}$
Ses deux facteurs ?	Le rapport A PRIORI · le FACTEUR DE BAYES
Que mesure le facteur de Bayes ?	À quel point les données sont PRÉDITES par M_1 comparé à M_2
Facteur de Bayes > 1 ?	On choisit M_1
Paradoxe de Jeffreys-Lindley ?	Avec un a priori DIFFUS , le facteur de Bayes favorise TOUJOURS le modèle simple
A priori diffus ?	Un a priori qui ne favorise aucun modèle — beaucoup sont a priori plausibles