

Fiche 408 — Régression linéaire : MLE, MAP, régression bayésienne, projection orthogonale

Matière	Maths · Apprentissage automatique
Cours source	Deisenroth, Faisal & Ong, <i>Mathematics for Machine Learning</i> , Cambridge University Press — chapitre 9 « Linear Regression » (p. 289-320)
Difficulté	Avancé — le premier pilier , celui qui mobilise les six fondations d'un coup
Temps d'étude estimé	140 min
Prérequis	Fiche 402 (projection orthogonale, équation normale) · Fiche 405 (gaussiennes, conjugaison) · Fiche 407 (MLE, MAP, régularisation)
Concepts clés	Modèle de régression, vraisemblance gaussienne, bruit i.i.d., linéarité en les paramètres , matrice de conception, estimateur du maximum de vraisemblance, équations normales, application d'attributs, régression polynomiale, matrice d'attributs, estimation de la variance du bruit, RMSE, surapprentissage, estimation MAP, a priori gaussien, moindres carrés régularisés, LASSO, régression linéaire bayésienne, prédictions a priori, loi a posteriori des paramètres, prédictions a posteriori, loi sur les fonctions, vraisemblance marginale, projection orthogonale
Poids à l'examen	$\theta_{\text{ML}} = (\Phi^T \Phi)^{-1} \Phi^T y$ · $\theta_{\text{MAP}} = (\Phi^T \Phi + \frac{\sigma^2}{b^2} I)^{-1} \Phi^T y$ · $\sigma_{\text{ML}}^2 = \frac{1}{N} \sum_n (y_n - \phi^T(x_n) \theta)^2$ · le théorème 9.1 (S_N, m_N) · $p(y_* \mathcal{X}, \mathcal{Y}, x_*) = \mathcal{N}(\phi^T(x_*) m_N, \phi^T(x_*) S_N \phi(x_*) + \sigma^2)$ · MLE = PROJECTION ORTHOGONALE.

Vue d'ensemble

LE FIL DU CHAPITRE : trois niveaux de sophistication sur le MÊME modèle

§9.1 FORMULATION $y = f(x) + \varepsilon$, $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ i.i.d.

VRAISEMBLANCE $p(y | x, \theta) = \mathcal{N}(y | \phi^T(x)\theta, \sigma^2)$

⚠ « LINÉAIRE » veut dire LINÉAIRE EN LES PARAMÈTRES — pas en x

§9.2 ESTIMATION PONCTUELLE

MLE $L(\theta) = (1/2\sigma^2) \|y - \Phi\theta\|^2 \rightarrow \theta_{\text{ML}} = (\Phi^T \Phi)^{-1} \Phi^T y \leftarrow \text{ÉQUATIONS NORMALES}$

$\sigma_{\text{ML}}^2 = (1/N) \sum_n (y_n - \phi^T(x_n)\theta)^2$

⚠ SURAPPRENTISSAGE : à $M = N-1$ le polynôme passe par CHAQUE point

$RMSE = \sqrt{((1/N)\|y - \Phi\theta\|^2)} \leftarrow$ comparable entre jeux, MÊMES UNITÉS que y
 MAP a priori $N(\theta, b^2 I) \rightarrow \theta_{MAP} = (\Phi^T \Phi + (\sigma^2/b^2) I)^{-1} \Phi^T y$
 ⚠ SEULE différence : le terme $(\sigma^2/b^2)I$ qui rend l'inverse TOUJOURS possible
 RLS $\min \|y - \Phi\theta\|^2 + \lambda \|\theta\|^2 \rightarrow \theta_{RLS} = (\Phi^T \Phi + \lambda I)^{-1} \Phi^T y$
 ⚠ IDENTIQUE au MAP pour $\lambda = \sigma^2/b^2$

§9.3 RÉGRESSION LINÉAIRE BAYÉSIENNE – on ne fixe PLUS aucun paramètre

MODÈLE $p(\theta) = N(m_0, S_0) \quad p(y|x, \theta) = N(y \mid \phi^T(x)\theta, \sigma^2)$
 A PRIORI $p(y^* \mid x^*) = N(\phi^T(x^*)m_0, \phi^T(x^*)S_0\phi(x^*) + \sigma^2)$
 A POSTERIORI (Th. 9.1) $SN = (S_0^{-1} + \sigma^{-2} \Phi^T \Phi)^{-1}$, $m_N = SN(S_0^{-1}m_0 + \sigma^{-2}\Phi^T y)$
 PRÉDICTION $p(y^*|X, Y, x^*) = N(\phi^T(x^*)m_N, \phi^T(x^*)SN\phi(x^*) + \sigma^2)$
 ⚠ la MOYENNE prédictive COÏNCIDE avec la prédiction du MAP

SANS BRUIT même moyenne, variance SANS le $+\sigma^2$

VRAISEMBLANCE MARGINALE $p(Y|X) = N(y \mid X m_0, X S_0 X^T + \sigma^2 I)$

§9.4 GÉOMÉTRIE $MLE =$ PROJECTION ORTHOGONALE de y sur l'espace des COLONNES de Φ
 $P\pi = \Phi(\Phi^T \Phi)^{-1} \Phi^T$ • si les ϕ_k sont ORTHONORMÉES, $P\pi = \Phi\Phi^T$

LA HIÉRARCHIE DES TROIS RÉPONSES

MLE	un point	• sur-apprend en régime de petites données
MAP	un point BIAISÉ	• l'a priori JOUE le rôle du régularisateur
BAYES	une LOI COMPLÈTE	• aucune estimation, on MOYENNE sur tous les θ plausibles

Le programme du chapitre. Après le pont du chapitre 8, la régression linéaire est le **premier pilier** — et le seul où **tout est calculable en forme fermée**. Elle mobilise l'**algèbre linéaire** (ch. 2), la **projection orthogonale** (ch. 3), le **calcul de gradients** (ch. 5), les **gaussiennes et la conjugaison** (ch. 6) et l'**optimisation** (ch. 7).

● Concept 1 — La formulation du problème (§9.1)

1.1 Le modèle

$$p(y \mid x) = \mathcal{N}(y \mid f(x), \sigma^2) \iff y = f(x) + \epsilon, \quad \epsilon \sim \mathcal{N}(0, \sigma^2)$$

avec $x \in \mathbb{R}^D$ les **entrées** et $y \in \mathbb{R}$ les **valeurs de fonction bruitées** (les **cibles**). Le bruit ϵ est **i.i.d. gaussien** de moyenne **0** et variance σ^2 .

L'objectif. « Trouver une fonction **PROCHE de la fonction INCONNUE** f qui a généré les données et qui **GÉNÉRALISE bien**. »

Le cas linéaire :

$$p(y | x, \theta) = \mathcal{N}(y | x^\top \theta, \sigma^2) \iff y = x^\top \theta + \epsilon$$

LA DÉFINITION EXACTE DE « LINÉAIRE ». *« La régression linéaire désigne les modèles qui sont "**LINÉAIRES EN LES PARAMÈTRES**", c'est-à-dire les modèles qui décrivent une fonction par une **COMBINAISON LINÉAIRE D'ATTRIBUTS d'entrée**. »* Un **attribut** est une **représentation** $\phi(x)$ des entrées x .

$$y = \phi^\top(x)\theta + \epsilon \text{ EST une régression linéaire, même si } \phi \text{ est NON LINÉAIRE}$$

Exemple 9.1. Pour $x, \theta \in \mathbb{R}$, le modèle décrit des **droites passant par l'origine**, et θ est la **PENTE**.

La seule source d'incertitude. « La seule source d'incertitude vient du **BRUIT D'OBSERVATION** (puisque x et θ sont supposés connus). **Sans bruit d'observation**, la relation entre x et y serait **DÉTERMINISTE** et la vraisemblance serait un **DELTA DE DIRAC** » — une fonction nulle partout sauf en un point, d'intégrale 1, qu'on peut voir comme une gaussienne à la limite $\sigma^2 \rightarrow 0$.

Les hypothèses de travail : on considère des **modèles PARAMÉTRIQUES**, et « pour le moment, on suppose que la variance du bruit σ^2 est **CONNUE** ».

1.2 La factorisation de la vraisemblance

Avec $\mathcal{D} := \{(x_1, y_1), \dots, (x_N, y_N)\}$:

La clé graphique. « y_i et y_j sont **CONDITIONNELLEMENT INDÉPENDANTES** sachant leurs entrées respectives x_i, x_j , de sorte que la vraisemblance **SE FACTORISE** » :

$$p(\mathcal{Y} | \mathcal{X}, \theta) = \prod_{n=1}^N p(y_n | x_n, \theta) = \prod_{n=1}^N \mathcal{N}(y_n | x_n^\top \theta, \sigma^2)$$

Et une fois θ^* trouvé, la prédiction en une entrée de test x_* est

$$p(y_* | x_*, \theta^*) = \mathcal{N}(y_* | x_*^\top \theta^*, \sigma^2)$$

Le modèle graphique (figure 9.3) : θ et σ en haut, une **plaque** sur $n = 1, \dots, N$ contenant x_n et y_n ; les variables **observées** sont **grisées**, les valeurs **déterministes/connues** sont **sans cercle**.

● Concept 2 — Le maximum de vraisemblance (§9.2.1)

2.1 La dérivation

$$\theta_{\text{ML}} \in \arg \max_{\theta} p(\mathcal{Y} | \mathcal{X}, \theta)$$

LA REMARQUE À CONNAÎTRE. *« La vraisemblance $p(y | x, \theta)$ n'est PAS une loi de probabilité en θ : c'est simplement une **FONCTION** des paramètres, elle n'intègre PAS à 1 (elle est non normalisée), et elle **peut même ne pas être INTÉGRABLE** par rapport à θ . En revanche, la vraisemblance **EST une loi normalisée en y** . »*

POURQUOI LA TRANSFORMATION LOGARITHMIQUE

(deux raisons données) :

- **(a)** « Elle **ne souffre PAS de SOUS-DÉBORDEMENT NUMÉRIQUE** (*underflow*) » — un produit de N densités devient vite inférieur à la précision machine.
- **(b)** « Les règles de dérivation se révéleront **PLUS SIMPLES** » — un produit devient une somme.

La log-vraisemblance négative :

$$L(\theta) := \frac{1}{2\sigma^2} \sum_{n=1}^N (y_n - x_n^\top \theta)^2 = \frac{1}{2\sigma^2} (y - X\theta)^\top (y - X\theta) = \frac{1}{2\sigma^2} \|y - X\theta\|^2$$

« La log-vraisemblance négative est aussi appelée la **FONCTION D'ERREUR**. »

Objet	Définition
Matrice de conception (<i>design matrix</i>)	$X := [x_1, \dots, x_N]^\top \in \mathbb{R}^{N \times D}$ — la n -ième LIGNE est l'entrée x_n
Vecteur des cibles	$y := [y_1, \dots, y_N]^\top \in \mathbb{R}^N$

L'observation décisive. *« L est **QUADRATIQUE** en θ . Cela signifie qu'on peut trouver une solution **GLOBALE UNIQUE** θ_{ML} . »*

Le gradient :

$$\frac{dL}{d\theta} = \frac{1}{2\sigma^2} \frac{d}{d\theta} (y^\top y - 2y^\top X\theta + \theta^\top X^\top X\theta) = \frac{1}{\sigma^2} (-y^\top X + \theta^\top X^\top X) \in \mathbb{R}^{1 \times D}$$

L'annulation :

$$\frac{dL}{d\theta} = 0^\top \iff \theta_{\text{ML}}^\top X^\top X = y^\top X \iff \theta_{\text{ML}}^\top = y^\top X (X^\top X)^{-1}$$

$$\boxed{\theta_{\text{ML}} = (X^\top X)^{-1} X^\top y}$$

Les trois justifications à ne pas sauter :

1. « On a pu multiplier à droite par $(X^\top X)^{-1}$ parce que $X^\top X$ est **DÉFINIE POSITIVE** si $\text{rk}(X) = D$ » — ce qui est le cas si $N \geq D$ « en ignorant la possibilité de points de données dupliqués ».
2. « Annuler le gradient est une condition **NÉCESSAIRE ET SUFFISANTE**, et l'on obtient un **MINIMUM GLOBAL** puisque la hessienne $\nabla_\theta^2 L(\theta) = X^\top X$ est **définie positive**. »
3. « La solution requiert de résoudre un **système linéaire** $A\theta = b$ avec $A = X^\top X$ et $b = X^\top y$. »
En pratique on **résout le système**, on **n'inverse pas** la matrice.

2.2 La régression polynomiale — Exemple 9.3

L'application d'attributs. « On "**SOULÈVE**" l'espace d'entrée unidimensionnel original dans un espace d'attributs de dimension K constitué de **tous les MONÔMES** x^k » :

$$\phi(x) = [\phi_0(x), \phi_1(x), \dots, \phi_{K-1}(x)]^\top = [1, x, x^2, x^3, \dots, x^{K-1}]^\top \in \mathbb{R}^K$$

$$f(x) = \sum_{k=0}^{K-1} \theta_k x^k = \phi^\top(x) \theta$$

La matrice d'attributs (aussi appelée **matrice de conception**) :

$$\Phi := \begin{bmatrix} \phi^\top(x_1) \\ \vdots \\ \phi^\top(x_N) \end{bmatrix} = \begin{bmatrix} \phi_0(x_1) & \cdots & \phi_{K-1}(x_1) \\ \vdots & & \vdots \\ \phi_0(x_N) & \cdots & \phi_{K-1}(x_N) \end{bmatrix} \in \mathbb{R}^{N \times K}, \quad \Phi_{ij} = \phi_j(x_i)$$

La conséquence — il n'y a RIEN à refaire :

$$-\log p(\mathcal{Y} \mid \mathcal{X}, \theta) = \frac{1}{2\sigma^2} (y - \Phi\theta)^\top (y - \Phi\theta) + \text{const}$$

« En comparant avec la log-vraisemblance négative du modèle "sans attributs", on voit immédiatement qu'il suffit de **REEMPLACER X par Φ** » :

$$\theta_{\text{ML}} = (\Phi^\top \Phi)^{-1} \Phi^\top y$$

La condition devient $\text{rk}(\Phi) = K$, pour que $\Phi^\top \Phi \in \mathbb{R}^{K \times K}$ soit **inversible**.

2.3 Estimer la variance du bruit

Même procédure : écrire la log-vraisemblance, dériver **par rapport à σ^2** , annuler, résoudre.

$$\log p(\mathcal{Y} \mid \mathcal{X}, \theta, \sigma^2) = -\frac{N}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \underbrace{\sum_{n=1}^N (y_n - \phi^\top(x_n)\theta)^2}_{=:s} + \text{const}$$

$$\frac{\partial}{\partial \sigma^2} = -\frac{N}{2\sigma^2} + \frac{1}{2\sigma^4} s = 0 \iff \frac{N}{2\sigma^2} = \frac{s}{2\sigma^4}$$

$$\sigma_{\text{ML}}^2 = \frac{s}{N} = \frac{1}{N} \sum_{n=1}^N (y_n - \phi^\top(x_n)\theta)^2$$

L'interprétation. « L'estimation du maximum de vraisemblance de la variance du bruit est la **MOYENNE EMPIRIQUE des DISTANCES au CARRÉ** entre les valeurs de fonction **SANS BRUIT** $\phi^\top(x_n)\theta$ et les observations **BRUITÉES** correspondantes y_n . »

Sur un jeu simulé de $N = 10$ points ($f(x) = \sin x + 0,3x$, bruit $\sigma = 0,4$), ajustement polynomial de degré 4 :

$$\sigma_{\text{ML}}^2 = 0,094126 \quad \sqrt{\sigma_{\text{ML}}^2} = 0,3068$$

et la RMSE d'entraînement calculée indépendamment vaut **0,3068** — les deux quantités **coïncident par construction**.

2.4 La RMSE et le surapprentissage

$$\text{RMSE} = \sqrt{\frac{1}{N} \|y - \Phi\theta\|^2} = \sqrt{\frac{1}{N} \sum_{n=1}^N (y_n - \phi^\top(x_n)\theta)^2}$$

Ses deux vertus. « (a) Elle permet de **COMPARER les erreurs de jeux de TAILLES DIFFÉRENTES** ; (b) elle a **la MÊME ÉCHELLE et les MÊMES UNITÉS** que les valeurs observées y_n . » L'exemple du livre : si l'on ajuste un modèle codes postaux $\rightarrow$ prix immobiliers en EUR, « la RMSE est **aussi en EUR**, alors que l'erreur quadratique est en **EUR au CARRÉ** ». « La log-vraisemblance négative, elle, est **SANS UNITÉ**. »

L'expérience de la figure 9.5-9.6 ($N = 10$ points, test sur **200 points** sur une grille linéaire de $[-5, 5]$) :

Degré M	Ce qu'on observe
$M = 0, 1$	« Ajustent MAL les données, mauvaises représentations de la vraie fonction » — SOUS-AJUSTEMENT
$M = 3, \dots, 6$	« Les ajustements semblent PLAUSIBLES et interpolent les données de façon LISSE »
M grand	« Ils ajustent les données de mieux en mieux » — sur l'entraînement
$M = N - 1 = 9$	« La fonction PASSE PAR CHAQUE point de donnée . Mais ces polynômes de haut degré OSCILLENT SAUVAGEMENT et sont une mauvaise représentation de la fonction sous-jacente : on souffre de SURAPPRENTISSAGE . »

L'erreur de TEST, elle, raconte une autre histoire : « elle **décroît d'abord...** pour les polynômes d'ordre 4 elle est relativement basse et reste constante jusqu'au degré 5. **Mais à partir du degré 6 elle AUGMENTE SIGNIFICATIVEMENT**, et les polynômes d'ordre élevé ont de **très mauvaises propriétés de généralisation**.

»

Simulation ($N = 10$ points d'entraînement, 200 de test, $\sigma = 0,4$) :

M	RMSE entraînement	RMSE test
0	1,2148	1,1032
1	0,8094	0,8764
3	0,3339	0,8436
5	0,1255	0,7795 ← minimum
7	0,1071	1,1490
8	0,0056	8,5955
9	0,0000	9,0400

Les deux signatures du surapprentissage sont là : l'erreur d'entraînement **décroît MONOTONEMENT** jusqu'à 0 exactement en $M = N - 1 = 9$, tandis que l'erreur de test **explose d'un facteur ~ 12** à partir du degré 8.

Le cas $M = N - 1$ est extrême « au sens où, autrement, le NOYAU du système linéaire correspondant serait non trivial et l'on aurait une INFINITÉ de solutions optimales ». Et pour $M \geq N$: « on aurait **plus de paramètres que de points de données** et il faudrait résoudre un système **SOUS-DÉTERMINÉ** — $\Phi^T \Phi$ ne serait **plus inversible** — donc une **infinité** d'estimateurs du maximum de vraisemblance. »

● Concept 3 — Le maximum a posteriori (§9.2.3-9.2.4)

3.1 La dérivation

Le diagnostic. « On observe souvent que la **MAGNITUDE des valeurs des paramètres devient RELATIVEMENT GRANDE** en cas de surapprentissage » (Bishop, 2006). *« Pour atténuer l'effet d'énormes valeurs de paramètres, on peut placer une **loi A PRIORI** $p(\theta)$. »*

La lecture concrète d'un a priori. « Un a priori gaussien $p(\theta) = \mathcal{N}(0, 1)$ sur un paramètre unique θ encode que les valeurs sont attendues dans l'intervalle $[-2, 2]$ » — **deux écarts-types** autour de la moyenne.

$$p(\theta \mid \mathcal{X}, \mathcal{Y}) = \frac{p(\mathcal{Y} \mid \mathcal{X}, \theta)p(\theta)}{p(\mathcal{Y} \mid \mathcal{X})}$$

$$\log p(\theta \mid \mathcal{X}, \mathcal{Y}) = \log p(\mathcal{Y} \mid \mathcal{X}, \theta) + \log p(\theta) + \text{const}$$

Le compromis rendu visible. « La log-a-posteriori est la **SOMME** de la log-vraisemblance et du **LOG-A-PRIORI**, de sorte que l'estimation MAP sera un "**COMPROMIS**" entre l'**A PRIORI** (notre suggestion de valeurs plausibles **avant** d'observer les données) et la **VRAISEMBLANCE dépendante des données**. »

$$\theta_{\text{MAP}} \in \arg \min_{\theta} \{ -\log p(\mathcal{Y} \mid \mathcal{X}, \theta) - \log p(\theta) \}$$

Avec l'a priori conjugué gaussien $p(\theta) = \mathcal{N}(0, b^2 I)$:

$$\theta_{\text{MAP}} = \left(\Phi^T \Phi + \frac{\sigma^2}{b^2} I \right)^{-1} \Phi^T y$$

LA COMPARAISON À RETENIR. « En comparant avec l'estimation du maximum de vraisemblance $\theta_{\text{ML}} = (\Phi^T \Phi)^{-1} \Phi^T y$, on voit que **la SEULE différence entre les deux solutions est le terme additionnel $\frac{\sigma^2}{b^2} I$ dans la matrice à inverser.** »

POURQUOI CE TERME EST DÉCISIF.

« $\Phi^T \Phi$ est symétrique et **SEMI**-définie positive. Le terme additionnel est **STRICTEMENT DÉFINI POSITIF**, de sorte que **L'INVERSE EXISTE** » — la somme $\Phi^T \Phi + \frac{\sigma^2}{b^2} I$ est « symétrique et **strictement définie positive** : son inverse existe, et l'estimation MAP est **L'UNIQUE solution** d'un système linéaire. De plus, **elle reflète l'impact du RÉGULARISATEUR.** »

L'a priori RÉSOUT à la fois le SURAPPRENTISSAGE ET l'éventuelle NON-INVERSIBILITÉ.

3.2 MAP = moindres carrés régularisés

Les moindres carrés régularisés :

$$\min_{\theta} \underbrace{\|y - \Phi\theta\|^2}_{\text{terme d'AJUSTEMENT (\textit{\textbf{misfit}})}} + \underbrace{\lambda \|\theta\|_2^2}_{\text{RÉGULARISATEUR}}$$

avec $\lambda \geq 0$ contrôlant « la "**SÉVÉRITÉ**" de la régularisation ». Le premier terme est « **proportionnel à la log-vraisemblance négative** ».

La solution :

$$\theta_{\text{RLS}} = (\Phi^T \Phi + \lambda I)^{-1} \Phi^T y$$

L'IDENTITÉ EXACTE. Avec $p(\theta) = \mathcal{N}(0, b^2 I)$, le log-a-priori gaussien négatif vaut

$$-\log p(\theta) = \frac{1}{2b^2} \|\theta\|_2^2 + \text{const}$$

Pour $\lambda = \frac{1}{2b^2}$, le régularisateur ET le log-a-priori négatif sont IDENTIQUES

Et en comparant les deux solutions : $\theta_{\text{RLS}} = \theta_{\text{MAP}}$ exactement lorsque $\lambda = \frac{\sigma^2}{b^2}$.

Le choix de la norme. *« Au lieu de la norme euclidienne, on peut choisir **n'importe quelle p -norme**. En pratique, des **valeurs plus PETITES de p** conduisent à des solutions **plus PARCIMONIEUSES** — "parcimonieux" signifiant que **beaucoup de $\theta_d = 0$** , ce qui est utile pour la **SÉLECTION DE VARIABLES**. Pour $p = 1$, le régularisateur s'appelle le **LASSO** (*least absolute shrinkage and selection operator*), proposé par **Tibshirani (1996)**. »*

1. L'a priori réduit bien la magnitude. Ajustement polynomial de degré 9 sur $N = 10$ points :

$$\|\theta_{\text{ML}}\| = 1,7638 \quad \|\theta_{\text{MAP}}\| = 0,8652$$

La norme est **divisée par 2** — exactement l'effet annoncé par le livre.

2. MAP = RLS, à la précision machine. Avec $\lambda = \sigma^2/b^2 = 0,125$ et $K = 5$, les deux calculs donnent

$$\theta = [-0,155749 ; 1,030929 ; 0,091578 ; -0,058583 ; -0,005083]$$

et la comparaison bit à bit renvoie **True**

● Concept 4 — La régression linéaire bayésienne (§9.3)

4.1 Le changement de perspective

LE SAUT CONCEPTUEL. « La régression linéaire bayésienne pousse l'idée de l'a priori **UN CRAN PLUS LOIN** et n'essaie même **PAS de calculer une estimation ponctuelle** des paramètres : c'est la **LOI A POSTERIORI COMPLÈTE** qui est prise en compte pour faire des prédictions. **On n'AJUSTE aucun paramètre**, on calcule une **MOYENNE sur TOUS les réglages plausibles** (selon l'a posteriori). »

Le modèle :

$$\text{a priori : } p(\theta) = \mathcal{N}(m_0, S_0) \quad \text{vraisemblance : } p(y | x, \theta) = \mathcal{N}(y | \phi^\top(x)\theta, \sigma^2)$$

« On place explicitement un a priori gaussien sur θ , ce qui **TRANSFORME le vecteur de paramètres en VARIABLE ALÉATOIRE**. » Le modèle probabiliste complet est la **loi jointe** :

$$p(y, \theta | x) = p(y | x, \theta) p(\theta)$$

4.2 Les prédictions a priori

$$p(y_* | x_*) = \int p(y_* | x_*, \theta) p(\theta) d\theta = \mathbb{E}_\theta[p(y_* | x_*, \theta)]$$

« La **prédiction MOYENNE** de $y_* | x_*$, θ pour tous les θ plausibles selon l'a priori. » « Les prédictions avec l'a priori ne requièrent de spécifier que l'entrée x_* , **AUCUNE donnée d'entraînement**. »

Le résultat, en forme fermée grâce à la conjugaison :

$$p(y_* | x_*) = \mathcal{N}(\phi^\top(x_*)m_0, \phi^\top(x_*)S_0\phi(x_*) + \sigma^2)$$

Les trois ingrédients de la dérivation :

1. La prédiction est **gaussienne** par **CONJUGAISON** (§6.6) et par la propriété de **MARGINALISATION** des gaussiennes (§6.5).
2. Le bruit gaussien est **indépendant**, donc $\mathbb{V}[y_*] = \mathbb{V}_\theta[\phi^\top(x_*)\theta] + \mathbb{V}_\epsilon[\epsilon]$.

3. y_* est une **transformation LINÉAIRE de θ** : on applique (6.50) et (6.51), soit $A\mu$ et $A\Sigma A^\top$.

Le terme $\phi^\top(x_*)S_0\phi(x_*)$ est la contribution de l'incertitude **sur les paramètres** ; le $+\sigma^2$ est celle du **bruit de mesure**.

4.3 L'a posteriori des paramètres — le théorème 9.1

THÉORÈME 9.1 (A POSTERIORI DES PARAMÈTRES).

Dans le modèle (9.35), l'a posteriori se calcule **EN FORME FERMÉE** :

$$p(\theta \mid \mathcal{X}, \mathcal{Y}) = \mathcal{N}(\theta \mid m_N, S_N)$$

$$S_N = (S_0^{-1} + \sigma^{-2}\Phi^\top\Phi)^{-1}$$

$$m_N = S_N(S_0^{-1}m_0 + \sigma^{-2}\Phi^\top y)$$

« L'indice N indique la **TAILLE de l'ensemble d'entraînement**. »

La vraisemblance marginale (évidence) au dénominateur :

$$p(\mathcal{Y} \mid \mathcal{X}) = \int p(\mathcal{Y} \mid \mathcal{X}, \theta)p(\theta) d\theta = \mathbb{E}_\theta[p(\mathcal{Y} \mid \mathcal{X}, \theta)]$$

« Elle est **indépendante de θ** et assure que l'a posteriori est **NORMALISÉ**. On peut y penser comme à la **vraisemblance MOYENNÉE sur tous les réglages possibles** de paramètres (selon l'a priori). »

La lecture des deux formules :

Formule	Lecture
$S_N^{-1} = S_0^{-1} + \sigma^{-2}\Phi^\top\Phi$	Les PRÉCISIONS S'AJOUTENT : celle de l'a priori plus celle apportée par les données. La covariance a posteriori ne peut que DIMINUER
$m_N = S_N(S_0^{-1}m_0 + \sigma^{-2}\Phi^\top y)$	Une moyenne PONDÉRÉE par les précisions entre l'a priori m_0 et le terme de données $\Phi^\top y$

Le cas limite : si $S_0 = b^2 I$ et $m_0 = 0$, on retrouve $m_N = (\Phi^\top \Phi + \frac{\sigma^2}{b^2} I)^{-1} \Phi^\top y = \theta_{\text{MAP}}$.

Avec $K = 4$, $\sigma^2 = 0,16$, $b^2 = 1$, $m_0 = 0$, $S_0 = I$:

	Valeurs
m_N (par le théorème 9.1)	$[-0,00698999 ; 1,02724769 ; 0,0096369 ; -0,0583119]$
θ_{MAP} (par la formule 9.31)	$[-0,00698999 ; 1,02724769 ; 0,0096369 ; -0,0583119]$

Écart maximal : 0,0 Les deux voies de calcul — inversion de $S_0^{-1} + \sigma^{-2} \Phi^\top \Phi$ d'un côté, formule directe de l'autre — **coïncident à la précision machine**.

4.4 Les prédictions a posteriori

$$p(y_* | \mathcal{X}, \mathcal{Y}, x_*) = \int p(y_* | x_*, \theta) p(\theta | \mathcal{X}, \mathcal{Y}) d\theta = \mathcal{N}(\phi^\top(x_*)m_N, \phi^\top(x_*)S_N\phi(x_*) + \sigma^2)$$

LE PONT AVEC LE MAP. « La **MOYENNE prédictive** $\phi^\top(x_*)m_N$ **COÏNCIDE** avec les prédictions faites avec l'estimation **MAP** θ_{MAP} . »

$$\mathbb{E}[y_* | \mathcal{X}, \mathcal{Y}, x_*] = \phi^\top(x_*)m_N = \phi^\top(x_*)\theta_{\text{MAP}}$$

Ce que le MAP perd, c'est donc **uniquement la VARIANCE** — le terme $\phi^\top(x_*)S_N\phi(x_*)$, qui « reflète l'incertitude a posteriori associée aux paramètres ». Noter que S_N **dépend des entrées d'entraînement** via Φ .

Les valeurs de fonction SANS bruit. Pour $f(x_*) = \phi^\top(x_*)\theta$:

$$\mathbb{E}[f(x_*) | \mathcal{X}, \mathcal{Y}] = \phi^\top(x_*)m_N \quad \mathbb{V}_\theta[f(x_*) | \mathcal{X}, \mathcal{Y}] = \phi^\top(x_*)S_N\phi(x_*)$$

« La moyenne prédictive est **LA MÊME** que pour les observations bruitées, puisque le bruit est de moyenne 0. La variance prédictive ne diffère que de σ^2 : quand on prédit des valeurs **bruitées**, il faut inclure σ^2 comme **source d'incertitude**, mais **PAS** pour les prédictions sans bruit — la seule incertitude restante vient alors de **l'a posteriori des paramètres**. »

UNE LOI SUR LES FONCTIONS. « Le fait qu'on **INTÈGRE les paramètres** **INDUIT une LOI SUR LES FONCTIONS** : si l'on échantillonne $\theta_i \sim p(\theta \mid \mathcal{X}, \mathcal{Y})$, on obtient **une réalisation de fonction** $\theta_i^\top \phi(\cdot)$. » C'est le germe des **processus gaussiens**.

Marginale contre prédictive a posteriori — les DEUX différences. *« (i) La vraisemblance marginale peut être vue comme **prédisant les cibles d'ENTRAÎNEMENT y** , et **non** les cibles de test y_* ; (ii) la vraisemblance marginale moyenne **par rapport à l'A PRIORI**, et non à l'a posteriori. »*

4.5 La vraisemblance marginale

Le processus génératif : $\theta \sim \mathcal{N}(m_0, S_0)$, puis $y_n \mid x_n, \theta \sim \mathcal{N}(x_n^\top \theta, \sigma^2)$.

Le calcul en deux étapes.

Étape 1 — montrer qu'elle est GAUSSIENNE. « (i) Le **produit de deux gaussiennes** est une gaussienne (non normalisée) ; (ii) une **transformation LINÉAIRE** d'une gaussienne est gaussienne. » L'intégrale se résout alors en forme fermée et « le résultat est **la CONSTANTE DE NORMALISATION** du produit des deux gaussiennes — laquelle a elle-même une forme gaussienne ».

Étape 2 — moyenne et covariance, par les règles des transformations affines (§6.4.4) :

$$\mathbb{E}[\mathcal{Y} \mid \mathcal{X}] = \mathbb{E}_{\theta, \epsilon}[X\theta + \epsilon] = X \mathbb{E}_{\theta}[\theta] = X m_0$$

$$\text{Cov}[\mathcal{Y} \mid \mathcal{X}] = \text{Cov}_{\theta}[X\theta] + \sigma^2 I = X \text{Cov}_{\theta}[\theta] X^\top + \sigma^2 I = X S_0 X^\top + \sigma^2 I$$

$$p(\mathcal{Y} \mid \mathcal{X}) = \mathcal{N}(y \mid X m_0, X S_0 X^\top + \sigma^2 I)$$

« Étant donné la proximité avec la loi prédictive a posteriori, la **forme fonctionnelle** de la vraisemblance marginale **ne devrait pas trop surprendre**. »

● Concept 5 — Le MLE comme projection orthogonale (§9.4)

5.1 Le cas unidimensionnel

Pour $y = x\theta + \epsilon$ — des droites $f : \mathbb{R} \rightarrow \mathbb{R}$ passant par l'origine :

$$\theta_{\text{ML}} = (X^\top X)^{-1} X^\top y = \frac{X^\top y}{X^\top X} \in \mathbb{R}$$

La **reconstruction optimale** des cibles d'entraînement :

$$X\theta_{\text{ML}} = X \frac{X^\top y}{X^\top X} = \underbrace{\frac{XX^\top}{X^\top X}}_{\text{MATRICE DE PROJECTION}} y$$

L'IDENTIFICATION, terme à terme avec le §3.8. « La régression linéaire par maximum de vraisemblance effectue une **PROJECTION ORTHOGONALE**. »

Objet de la régression	Objet géométrique du chapitre 3
$\frac{XX^\top}{X^\top X}$	La MATRICE DE PROJECTION P_π
θ_{ML}	Les COORDONNÉES de la projection dans le sous-espace de dimension 1 engendré par X
$X\theta_{\text{ML}}$	La PROJECTION ORTHOGONALE de y sur ce sous-espace

La conclusion. « La solution du maximum de vraisemblance fournit aussi une **solution GÉOMÉTRIQUEMENT OPTIMALE** : elle trouve les vecteurs, dans le sous-espace engendré par X , qui sont "**LES PLUS PROCHES**" des observations y — "proche" au sens de la **plus petite distance QUADRATIQUE**. C'est ce qu'accomplissent les projections orthogonales. »

« La régression linéaire peut donc être vue comme une **méthode pour RÉSOUDRE des systèmes d'équations linéaires** » — insoluble exactement, résolu au sens des moindres carrés (fiche 402, §3.8).

5.2 Le cas général et le cas orthonormé

Pour $\mathbf{y} = \Phi^\top(\mathbf{x})\boldsymbol{\theta} + \epsilon$ avec $\phi(\mathbf{x}) \in \mathbb{R}^K$:

$$\mathbf{y} \approx \Phi\boldsymbol{\theta}_{\text{ML}}, \quad \boldsymbol{\theta}_{\text{ML}} = (\Phi^\top\Phi)^{-1}\Phi^\top\mathbf{y}$$

$$P_\pi = \Phi(\Phi^\top\Phi)^{-1}\Phi^\top$$

« Une projection sur un sous-espace de dimension K de $\mathbb{R}^N$, engendré par **les COLONNES de la matrice d'attributs Φ** » (§3.8.2).

Le cas particulier ORTHONORMÉ. « Si les fonctions d'attributs ϕ_k sont **ORTHONORMÉES**, les colonnes de Φ forment une **base orthonormée**, si bien que $\Phi^\top\Phi = \mathbf{I}$ » :

$$\Phi(\Phi^\top\Phi)^{-1}\Phi^\top\mathbf{y} = \Phi\Phi^\top\mathbf{y}$$

Plus aucune inversion — c'est exactement la simplification annoncée à la fiche 402 pour les bases orthonormées.

Sur les données simulées avec $K = 4$ attributs polynomiaux et $N = 10$ points :

Propriété	Test	Résultat
Idempotence $P_\pi^2 = P_\pi$	$\max P_\pi^2 - P_\pi $	0,0
Symétrie $P_\pi = P_\pi^\top$	$\max P_\pi - P_\pi^\top $	0,0
Trace = rang	$\text{tr}(P_\pi)$	4,0 = K
Résidu orthogonal	$\max_j (\Phi^\top\mathbf{r})_j $ avec $\mathbf{r} = \mathbf{y} - \Phi\boldsymbol{\theta}_{\text{ML}}$	0,0

La dernière ligne **EST** l'équation normale : $\Phi^\top(\mathbf{y} - \Phi\boldsymbol{\theta}) = 0 \iff \Phi^\top\Phi\boldsymbol{\theta} = \Phi^\top\mathbf{y}$. La **condition d'optimalité du MLE et la condition d'orthogonalité de la projection sont LA MÊME ÉQUATION.**

Comment reconnaître le type d'exercice

L'énoncé dit...	Le type	La méthode
« Ce modèle est-il une régression linéaire ? »	§9.1	Vérifier la linéarité EN LES PARAMÈTRES — ϕ peut être non linéaire
« Écrire la vraisemblance »	§9.1	$\prod_n \mathcal{N}(y_n \phi^\top(x_n)\theta, \sigma^2)$ — la conditionnelle indépendance justifie la factorisation
« Trouver θ_{ML} »	§9.2.1	$\theta_{\text{ML}} = (\Phi^\top \Phi)^{-1} \Phi^\top y$; en pratique résoudre $\Phi^\top \Phi \theta = \Phi^\top y$
« Régression polynomiale de degré M »	Ex. 9.3	$\phi(x) = [1, x, \dots, x^M]^\top$, $K = M + 1$; remplacer X par Φ
« Estimer la variance du bruit »	§9.2.1	$\sigma_{\text{ML}}^2 = \frac{1}{N} \sum_n (y_n - \phi^\top(x_n)\theta)^2$
« Comparer deux modèles »	RMSE	$\sqrt{\frac{1}{N} \ y - \Phi \theta\ ^2}$; mêmes unités que y
« Le modèle sur-apprend »	§9.2.2	Signes : $\ \theta\ $ grande · train $\rightarrow 0$ · test qui explose
« Trouver θ_{MAP} »	§9.2.3	$(\Phi^\top \Phi + \frac{\sigma^2}{b^2} I)^{-1} \Phi^\top y$
« Moindres carrés régularisés »	§9.2.4	$\theta_{\text{RLS}} = (\Phi^\top \Phi + \lambda I)^{-1} \Phi^\top y$; identique au MAP pour $\lambda = \sigma^2/b^2$
« On veut des solutions parcimonieuses »	§9.2.4	Norme ℓ_1 : le LASSO
« Prédire sans données d'entraînement »	§9.3.2	Prédiction a priori : $\mathcal{N}(\phi^\top(x_*)m_0, \phi^\top(x_*)S_0\phi(x_*) + \sigma^2)$
« Calculer l'a posteriori des paramètres »	Th. 9.1	$S_N = (S_0^{-1} + \sigma^{-2} \Phi^\top \Phi)^{-1}$, $m_N = S_N(S_0^{-1}m_0 + \sigma^{-2} \Phi^\top y)$
« Prédire avec incertitude »	§9.3.4	$\mathcal{N}(\phi^\top(x_*)m_N, \phi^\top(x_*)S_N\phi(x_*) + \sigma^2)$
« Valeurs de fonction sans bruit »	§9.3.4	Même moyenne , variance sans le $+\sigma^2$
« Calculer la vraisemblance marginale »	§9.3.5	$\mathcal{N}(y X m_0, X S_0 X^\top + \sigma^2 I)$
« Interpréter géométriquement »	§9.4	PROJECTION ORTHOGONALE de y sur l'espace des colonnes de Φ

L'énoncé dit...	Le type	La méthode
« Les attributs sont orthonormés »	\$9.4	$\Phi^T \Phi = I$, donc $P_\pi = \Phi \Phi^T$ — plus d'inversion

Comment résoudre : les cinq méthodes pas-à-pas

Méthode A — Ajuster un modèle par maximum de vraisemblance.

1. Choisir les **attributs** ϕ ; construire $\Phi \in \mathbb{R}^{N \times K}$ ligne par ligne.
2. **Vérifier** $\text{rk}(\Phi) = K$ (sinon $\Phi^T \Phi$ n'est pas inversible).
3. Former $A = \Phi^T \Phi$ et $b = \Phi^T y$.
4. **Résoudre** $A\theta = b$ (pas d'inversion explicite).
5. **Contrôles** : la hessienne $\Phi^T \Phi$ est définie positive $\Rightarrow$ minimum **global** ; le résidu $y - \Phi\theta$ doit être **orthogonal à toutes les colonnes** de Φ .
6. Si nécessaire : $\sigma_{\text{ML}}^2 = \frac{1}{N} \|y - \Phi\theta\|^2$.

Méthode B — Diagnostiquer et corriger le surapprentissage.

1. Calculer la **RMSE d'entraînement ET de test** pour plusieurs degrés M .
2. Chercher le **point de divergence** : train qui continue de baisser, test qui remonte.
3. Vérifier $\|\theta\|$: elle **explose** en surapprentissage.
4. Placer un a priori $\mathcal{N}(0, b^2 I)$ ou ajouter $\lambda \|\theta\|^2$.
5. Recalculer $\theta_{\text{MAP}} = (\Phi^T \Phi + \frac{\sigma^2}{b^2} I)^{-1} \Phi^T y$.
6. **Contrôle** : $\|\theta_{\text{MAP}}\| < \|\theta_{\text{ML}}\|$.

Méthode C — Régression bayésienne complète.

1. Fixer l'a priori (m_0, S_0) et σ^2 .
2. Construire Φ .
3. $S_N^{-1} = S_0^{-1} + \sigma^{-2} \Phi^T \Phi$, puis **inverser** pour S_N .
4. $m_N = S_N(S_0^{-1} m_0 + \sigma^{-2} \Phi^T y)$.
5. Prédire : moyenne $\phi^T(x_*) m_N$, variance $\phi^T(x_*) S_N \phi(x_*) + \sigma^2$.
6. **Contrôles** : $S_N \preceq S_0$ (l'observation **réduit** l'incertitude) ; si $m_0 = 0$ et $S_0 = b^2 I$, alors $m_N = \theta_{\text{MAP}}$.

Méthode D — Passer d'un langage à l'autre.

1. Perte quadratique $\longleftrightarrow$ **vraisemblance gaussienne**.

2. $\lambda \|\theta\|^2 \longleftrightarrow \text{a priori } \mathcal{N}(0, b^2 I)$, avec $\lambda = \frac{1}{2b^2}$ pour les objectifs et $\lambda = \frac{\sigma^2}{b^2}$ pour les solutions.
3. $\theta_{\text{ML}} \longleftrightarrow \text{projection orthogonale.}$
4. Équation normale $\longleftrightarrow \text{condition d'orthogonalité du résidu.}$
5. $\theta_{\text{MAP}} \longleftrightarrow \text{moyenne a posteriori } m_N.$

Méthode E — Vérification géométrique.

1. Calculer $P_\pi = \Phi(\Phi^\top \Phi)^{-1} \Phi^\top$.
2. **Idempotence** : $P_\pi^2 = P_\pi$.
3. **Symétrie** : $P_\pi = P_\pi^\top$.
4. **Trace = rang** = K .
5. **Résidu** : $\Phi^\top (y - \Phi \theta_{\text{ML}}) = 0$.
6. Si attributs orthonormés : vérifier $\Phi^\top \Phi = I$ et $P_\pi = \Phi \Phi^\top$.

● Common mistakes

Erreur	Correction
Croire que « linéaire » veut dire linéaire en x	Cela veut dire LINÉAIRE EN LES PARAMÈTRES — ϕ peut être un polynôme, une sinusoïde...
Traiter la vraisemblance comme une loi en θ	Elle n'intègre PAS à 1 en θ et peut même ne pas être intégrable
Ne pas passer au logarithme	SOUS-DÉBORDEMENT numérique garanti pour N grand, et dérivées inutilement compliquées
Ranger les x_n en colonnes de X	La n -ième LIGNE de X est x_n — $X \in \mathbb{R}^{N \times D}$
Inverser $\Phi^T \Phi$ explicitement	Résoudre le système $\Phi^T \Phi \theta = \Phi^T y$ est plus stable
Oublier de vérifier $\text{rk}(\Phi) = K$	Sinon pas d'inverse et une infinité de solutions
Prendre $K > N$	Système SOUS-DÉTERMINÉ : infinité d'estimateurs
Croire que $M = N - 1$ est le meilleur ajustement	Le polynôme passé par chaque point (train = 0) mais oscille sauvagement
Juger un modèle sur l'erreur d'entraînement	Elle décroît MONOTONEMENT avec M — elle ne détecte jamais le surapprentissage
Comparer des erreurs quadratiques brutes	Utiliser la RMSE : comparable entre tailles, mêmes unités que y
Croire la log-vraisemblance interprétable en unités	Elle est SANS UNITÉ
Oublier le $\frac{1}{N}$ dans σ_{ML}^2	C'est une moyenne empirique des carrés des résidus
Écrire $\theta_{\text{MAP}} = (\Phi^T \Phi)^{-1} \Phi^T y + \text{qqch}$	Le terme s'ajoute DANS l'inverse : $(\Phi^T \Phi + \frac{\sigma^2}{b^2} I)^{-1}$
Croire que $\Phi^T \Phi$ est toujours inversible	Elle est SEMI -définie positive ; c'est le terme de régularisation qui garantit l'inverse
Confondre $\lambda = \frac{1}{2b^2}$ et $\lambda = \frac{\sigma^2}{b^2}$	Le premier identifie les objectifs , le second les solutions
Croire que la norme ℓ_2 donne de la parcimonie	NON — il faut p petit ; $p = 1$ est le LASSO
Croire que la régression bayésienne ajuste des paramètres	« On n'ajuste AUCUN paramètre » — on moyenne sur tous les θ plausibles

Erreur	Correction
Oublier le $+\sigma^2$ dans la variance prédictive	Il représente le bruit de mesure ; il disparaît pour les valeurs de fonction sans bruit
Croire S_N indépendante des données	Elle dépend des entrées d'entraînement via Φ (mais pas des cibles y)
Croire que la variance prédictive est constante	$\phi^T(x_*)S_N\phi(x_*)$ dépend de x_* : l'incertitude grandit loin des données
Croire que MAP et bayésien donnent la même chose	Même MOYENNE prédictive , mais le MAP perd toute la VARIANCE
Confondre vraisemblance marginale et prédictive a posteriori	La marginale prédit les cibles d'ENTRAÎNEMENT et moyenne selon L'A PRIORI
Croire que la projection orthogonale est une analogie	C'est une IDENTITÉ : l'équation normale EST la condition d'orthogonalité du résidu
Oublier que P_π est singulière	$P_\pi^2 = P_\pi$ et $P_\pi \neq I$: $\det P_\pi = 0$, $\text{tr } P_\pi = K < N$
Inverser $\Phi^T \Phi$ quand les attributs sont orthonormés	$\Phi^T \Phi = I$: la projection est simplement $\Phi \Phi^T$

Ultimate Review

===== LES HUIT FORMULES À SAVOIR SANS HÉSITER =====

- MODÈLE $y = \phi^T(x)\theta + \varepsilon$, $\varepsilon \sim N(0, \sigma^2)$ i.i.d.
 ⚠ « linéaire » = LINÉAIRE EN LES PARAMÈTRES
- ERREUR $L(\theta) = (1/2\sigma^2) \|y - \Phi\theta\|^2$
- MLE $\theta_{ML} = (\Phi^T\Phi)^{-1} \Phi^T y$ ← ÉQUATIONS NORMALES
 BRUIT $\sigma^2_{ML} = (1/N) \|y - \Phi\theta\|^2$
 RMSE $\sqrt{(1/N) \|y - \Phi\theta\|^2}$
- MAP $\theta_{MAP} = (\Phi^T\Phi + (\sigma^2/b^2) I)^{-1} \Phi^T y$
 RLS $\theta_{RLS} = (\Phi^T\Phi + \lambda I)^{-1} \Phi^T y$ ← IDENTIQUE pour $\lambda = \sigma^2/b^2$
- A POSTERIORI (Th. 9.1)
 $S_N = (S_0^{-1} + \sigma^{-2} \Phi^T\Phi)^{-1}$ $m_N = S_N (S_0^{-1} m_0 + \sigma^{-2} \Phi^T y)$
- PRÉDICTION A PRIORI $N(\phi^T(x^*)m_0, \phi^T(x^*)S_0\phi(x^*) + \sigma^2)$
 PRÉDICTION A POSTERIORI $N(\phi^T(x^*)m_N, \phi^T(x^*)S_N\phi(x^*) + \sigma^2)$
 ⚠ moyenne prédictive = $\phi^T(x^*) \theta_{MAP}$

7. VRAISEMBLANCE MARGINALE $N(y \mid X m_0, X S_0 X^T + \sigma^2 I)$

8. GÉOMÉTRIE $P\pi = \Phi(\Phi^T\Phi)^{-1}\Phi^T$ · attributs ORTHONORMÉS $\rightarrow P\pi = \Phi\Phi^T$

LES TROIS NIVEAUX, terme à terme :

	MLE	MAP	BAYÉSIEEN
Ce qu'on obtient	Un point	Un point biaisé	Une LOI COMPLÈTE
A priori	Aucun	$\mathcal{N}(0, b^2 I)$	$\mathcal{N}(m_0, S_0)$
Solution	$(\Phi^T\Phi)^{-1}\Phi^T y$	$(\Phi^T\Phi + \frac{\sigma^2}{b^2}I)^{-1}\Phi^T y$	$\mathcal{N}(m_N, S_N)$
Inversibilité	exige rk $\Phi = K$	toujours garantie	toujours
Surapprentissage	oui , surtout si N petit	atténué	intrinsèquement traité
Incertitude prédictive	σ^2 seul	σ^2 seul	$\phi^T S_N \phi + \sigma^2$
Coût	Un système linéaire	Un système linéaire	Une inversion de $K \times K$

LE DICTIONNAIRE PROBABILISTE / GÉOMÉTRIQUE / OPTIMISATION :

Probabiliste (ch. 6, 8)	Géométrie (ch. 3)	Optimisation (ch. 7)
Vraisemblance gaussienne	Distance quadratique	Objectif quadratique
Maximiser la vraisemblance	Projection orthogonale	Minimum global (hessienne $\succ 0$)
A priori $\mathcal{N}(0, b^2 I)$	—	Régularisation $\lambda \ \theta\ ^2$
Annuler le gradient	Résidu $\perp$ colonnes de Φ	Condition d'optimalité
Conjugaison gaussienne	—	Forme fermée

Ce que chaque chapitre antérieur apporte ici :

Chapitre	Ce qu'il fournit
2 — algèbre linéaire	Matrice de conception, rang, systèmes linéaires
3 — géométrie	Projection orthogonale , équation normale, pseudo-inverse
4 — décompositions	Définie positivité de $\Phi^T \Phi$, inversibilité
5 — calcul vectoriel	Le gradient de $\ y - \Phi\theta\ ^2$, la hessienne
6 — probabilités	Gaussiennes, conjugaison, transformations affines des moments
7 — optimisation	Minimum global d'un objectif quadratique
8 — le pont	MLE, MAP, régularisation, surapprentissage

Active Recall

Formulation

1. Écrire le modèle de régression et la vraisemblance.
2. Que signifie exactement « linéaire » en régression linéaire ?
3. Quelle est la seule source d'incertitude ? Que se passerait-il sans bruit ?
4. Pourquoi la vraisemblance se factorise-t-elle ?
5. Que représente θ dans l'exemple 9.1 ?

Maximum de vraisemblance 6. Pourquoi la vraisemblance n'est-elle pas une loi en θ ? 7. Donner les deux raisons de la transformation logarithmique. 8. Écrire la log-vraisemblance négative sous ses trois formes. 9. Qu'est-ce que la matrice de conception ? Comment sont rangés les x_n ? 10. Calculer le gradient et en déduire θ_{ML} . 11. Donner les trois justifications de la dérivation. 12. Qu'est-ce qu'une application d'attributs ? Écrire ϕ pour la régression polynomiale. 13. Que devient θ_{ML} avec des attributs ? Quelle condition de rang ? 14. Dériver σ_{ML}^2 et l'interpréter. 15. Écrire la RMSE. Donner ses deux vertus. 16. Décrire l'expérience des figures 9.5-9.6. Que se passe-t-il à $M = N - 1$? 17. Pourquoi $M \geq N$ est-il impossible ?

MAP et régularisation 18. Quel est le signe empirique du surapprentissage ? 19. Que signifie concrètement un a priori $\mathcal{N}(0, 1)$? 20. Écrire la log-a-posteriori. Pourquoi parle-t-on de « compromis » ? 21. Écrire θ_{MAP} . Quelle est la seule différence avec θ_{ML} ? 22. Quelles sont les DEUX choses que ce terme additionnel résout ? 23. Écrire les moindres carrés régularisés et leur solution.

24. Pour quelle valeur de λ le régularisateur et le log-a-priori négatif coïncident-ils ? 25. Qu'apporte la norme ℓ_1 ? Comment s'appelle-t-elle ?

Régression bayésienne 26. En quoi la régression bayésienne diffère-t-elle du MAP ? 27. Écrire le modèle (a priori et vraisemblance). 28. Écrire la prédiction a priori. Que faut-il fournir ? 29. Donner les trois ingrédients de sa dérivation. 30. Énoncer le théorème 9.1. 31. Comment lire $\mathbf{S}_N^{-1}$? et $\mathbf{m}_N$? 32. Que vaut $\mathbf{m}_N$ quand $\mathbf{m}_0 = \mathbf{0}$ et $\mathbf{S}_0 = b^2 \mathbf{I}$? 33. Écrire la prédiction a posteriori. Que vaut sa moyenne ? 34. Que change-t-on pour des valeurs de fonction sans bruit ? 35. Qu'est-ce qu'une « loi sur les fonctions » ? 36. Donner les deux différences entre vraisemblance marginale et prédictive a posteriori. 37. Dériver la vraisemblance marginale en deux étapes.

Géométrie 38. Écrire $\mathbf{X}\boldsymbol{\theta}_{\text{ML}}$ dans le cas 1D et identifier les trois objets géométriques. 39. Quelle est la formule générale de $\mathbf{P}_\pi$? 40. Que devient-elle si les attributs sont orthonormés ? 41. Quelles sont les quatre propriétés de $\mathbf{P}_\pi$? 42. Pourquoi l'équation normale et la condition d'orthogonalité sont-elles la même équation ?

Flashcards

Question	Réponse
Le modèle de régression ?	$y = f(x) + \epsilon$ avec $\epsilon \sim \mathcal{N}(0, \sigma^2)$ i.i.d.
La vraisemblance ?	$p(y x, \theta) = \mathcal{N}(y \phi^\top(x)\theta, \sigma^2)$
Que signifie « linéaire » ?	LINÉAIRE EN LES PARAMÈTRES — une combinaison linéaire d'ATTRIBUTS
$y = \phi^\top(x)\theta$ avec ϕ non linéaire est-il linéaire ?	OUI — c'est bien une régression linéaire
La seule source d'incertitude ?	Le BRUIT D'OBSERVATION
Sans bruit ?	Relation DÉTERMINISTE ; la vraisemblance serait un DELTA DE DIRAC
Delta de Dirac ?	Nul partout sauf en un point, d'intégrale 1 — une gaussienne à la limite $\sigma^2 \rightarrow 0$
Pourquoi la vraisemblance se factorise-t-elle ?	Les y_i sont conditionnellement indépendantes sachant leurs x_i
Que représente θ pour $x, \theta \in \mathbb{R}$?	La PENTE de la droite (passant par l'origine)
La vraisemblance est-elle une loi en θ ?	NON — non normalisée, peut même ne pas être intégrable
En y ?	OUI , elle est normalisée
Les deux raisons du logarithme ?	Éviter le SOUS-DÉBORDEMENT numérique · simplifier les dérivées
La log-vraisemblance négative ?	$L(\theta) = \frac{1}{2\sigma^2} \ y - X\theta\ ^2$
Son autre nom ?	La FONCTION D'ERREUR
Matrice de conception ?	$X = [x_1, \dots, x_N]^\top \in \mathbb{R}^{N \times D}$ — la n-ième LIGNE est x_n
Le gradient de L ?	$\frac{1}{\sigma^2} (-y^\top X + \theta^\top X^\top X) \in \mathbb{R}^{1 \times D}$
L'estimateur du maximum de vraisemblance ?	$\theta_{\text{ML}} = (X^\top X)^{-1} X^\top y$
Le nom de cette équation ?	Les ÉQUATIONS NORMALES

Question	Réponse
Pourquoi peut-on inverser $\mathbf{X}^\top \mathbf{X}$?	Elle est définie positive si $\text{rk}(\mathbf{X}) = D$
Nécessaire et suffisant ?	OUI — la hessienne $\mathbf{X}^\top \mathbf{X}$ est définie positive , donc minimum GLOBAL
Que faut-il faire en pratique ?	Résoudre $\mathbf{A}\theta = \mathbf{b}$, pas inverser
L'application d'attributs polynomiale ?	$\phi(\mathbf{x}) = [1, \mathbf{x}, \mathbf{x}^2, \dots, \mathbf{x}^{K-1}]^\top$
Ce qu'elle fait ?	Elle SOULÈVE l'espace 1D en un espace de dimension K de MONÔMES
Matrice d'attributs ?	$\Phi \in \mathbb{R}^{N \times K}$ avec $\Phi_{ij} = \phi_j(\mathbf{x}_i)$
θ_{ML} avec attributs ?	$(\Phi^\top \Phi)^{-1} \Phi^\top \mathbf{y}$ — il suffit de remplacer $\mathbf{X}$ par Φ
La condition de rang ?	$\text{rk}(\Phi) = K$
σ_{ML}^2 ?	$\frac{1}{N} \sum_n (\mathbf{y}_n - \phi^\top(\mathbf{x}_n) \theta)^2$
Son interprétation ?	La moyenne empirique des distances au carré entre valeurs sans bruit et observations bruitées
La RMSE ?	$\sqrt{\frac{1}{N} \ \mathbf{y} - \Phi \theta\ ^2}$
Ses deux vertus ?	Comparer des jeux de tailles différentes · mêmes unités que $\mathbf{y}$
La log-vraisemblance a-t-elle des unités ?	NON — elle est sans unité
Que se passe-t-il à $M = N - 1$?	Le polynôme PASSE PAR CHAQUE POINT ; RMSE d'entraînement = 0
Et pour la généralisation ?	Oscillations sauvages — mauvaise représentation, SURAPPRENTISSAGE
À partir de quel degré le test se dégrade-t-il ?	Degré 6 dans l'expérience du livre
Pourquoi $M \geq N$ est-il impossible ?	Système SOUS-DÉTERMINÉ ; $\Phi^\top \Phi$ non inversible ; infinité de solutions
Le signe empirique du surapprentissage ?	La MAGNITUDE des paramètres devient GRANDE
Que signifie l'a priori $\mathcal{N}(\mathbf{0}, \mathbf{1})$?	Les valeurs sont attendues dans $[-2, 2]$ — deux écarts-types
La log-a-posteriori ?	$\log p(\mathcal{Y} \mathcal{X}, \theta) + \log p(\theta) + \text{const}$

Question	Réponse
Pourquoi un « compromis » ?	C'est une SOMME : l'a priori plus la vraisemblance
θ_{MAP} ?	$(\Phi^T \Phi + \frac{\sigma^2}{b^2} I)^{-1} \Phi^T y$
La seule différence avec le MLE ?	Le terme $\frac{\sigma^2}{b^2} I$ DANS l'inverse
Les DEUX problèmes qu'il résout ?	Le surapprentissage ET l' existence de l'INVERSE
Pourquoi ?	$\Phi^T \Phi$ est SEMI -définie positive ; le terme ajouté est STRICTEMENT défini positif
Les moindres carrés régularisés ?	$\min_{\theta} \ y - \Phi \theta\ ^2 + \lambda \ \theta\ _2^2$
Le nom du premier terme ?	Le terme d' AJUSTEMENT (<i>misfit</i>)
θ_{RLS} ?	$(\Phi^T \Phi + \lambda I)^{-1} \Phi^T y$
Quand RLS = MAP ?	Pour $\lambda = \frac{\sigma^2}{b^2}$
Quand le régularisateur = le log-a-priori négatif ?	Pour $\lambda = \frac{1}{2b^2}$
Qu'apporte une norme p petite ?	Des solutions PARCIMONIEUSES (beaucoup de $\theta_d = 0$) — utile pour la sélection de variables
Le régularisateur ℓ_1 ?	Le LASSO (Tibshirani, 1996)
Ce que fait la régression bayésienne ?	Elle n'ajuste AUCUN paramètre — elle MOYENNE sur tous les θ plausibles
Le modèle bayésien ?	$p(\theta) = \mathcal{N}(m_0, S_0)$ et $p(y x, \theta) = \mathcal{N}(y \phi^T(x)\theta, \sigma^2)$
Que devient θ ?	Une VARIABLE ALÉATOIRE
La prédiction a priori ?	$\mathcal{N}(\phi^T(x_*)m_0, \phi^T(x_*)S_0\phi(x_*) + \sigma^2)$
Que faut-il fournir ?	Seulement x_* — aucune donnée d'entraînement
Les trois ingrédients de sa dérivation ?	Conjugaison + marginalisation gaussienne · indépendance du bruit · transformation linéaire de gaussienne
Théorème 9.1, la covariance ?	$S_N = (S_0^{-1} + \sigma^{-2} \Phi^T \Phi)^{-1}$
Théorème 9.1, la moyenne ?	$m_N = S_N(S_0^{-1}m_0 + \sigma^{-2} \Phi^T y)$

Question	Réponse
Comment lire S_N^{-1} ?	Les PRÉCISIONS S'AJOUTENT : a priori plus données
Comment lire m_N ?	Une moyenne pondérée par les PRÉCISIONS
m_N si $m_0 = 0$ et $S_0 = b^2 I$?	$= \theta_{\text{MAP}}$ exactement
Rôle de la vraisemblance marginale ?	Elle NORMALISE l'a posteriori ; c'est la vraisemblance moyennée sur l'a priori
La prédiction a posteriori ?	$\mathcal{N}(\phi^\top(x_*)m_N, \phi^\top(x_*)S_N\phi(x_*) + \sigma^2)$
Sa moyenne ?	$= \phi^\top(x_*)\theta_{\text{MAP}}$ — le MAP ne perd que la VARIANCE
Que reflète $\phi^\top(x_*)S_N\phi(x_*)$?	L' incertitude a posteriori sur les PARAMÈTRES
S_N dépend-elle des données ?	De Φ oui (les entrées), des cibles y non
Valeurs de fonction sans bruit ?	Même moyenne , variance SANS le $+\sigma^2$
Pourquoi la moyenne est-elle la même ?	Le bruit est de moyenne 0
Loi sur les fonctions ?	Échantillonner $\theta_i \sim p(\theta \mid \mathcal{X}, \mathcal{Y})$ donne une réalisation de FONCTION $\theta_i^\top \phi(\cdot)$
Marginale contre prédictive a posteriori ?	La marginale prédit les cibles d'ENTRAÎNEMENT · elle moyenne sur l' A PRIORI
La vraisemblance marginale ?	$\mathcal{N}(y \mid X m_0, X S_0 X^\top + \sigma^2 I)$
Sa moyenne ?	$\mathbb{E}_{\theta, \epsilon}[X\theta + \epsilon] = X m_0$
Sa covariance ?	$X S_0 X^\top + \sigma^2 I$
$X\theta_{\text{ML}}$ en 1D ?	$\frac{XX^\top}{X^\top X} y$
Les trois identifications géométriques ?	$\frac{XX^\top}{X^\top X} = P_\pi \cdot \theta_{\text{ML}} = \text{coordonnées} \cdot X\theta_{\text{ML}} = \text{projection orthogonale}$
Que fait le MLE, géométriquement ?	Une PROJECTION ORTHOGONALE de y sur l'espace des COLONNES de Φ
P_π dans le cas général ?	$\Phi(\Phi^\top \Phi)^{-1} \Phi^\top$
Sur quel sous-espace projette-t-on ?	Le sous-espace de dimension K de $\mathbb{R}^N$ engendré par les colonnes de Φ

Question	Réponse
Si les attributs sont orthonormés ?	$\Phi^T \Phi = I$, donc $P_\pi = \Phi \Phi^T$ — plus d'inversion
Les quatre propriétés de P_π ?	Idempotente · symétrique · tr = rang = K · singulière
Le lien entre équation normale et orthogonalité ?	$\Phi^T (y - \Phi \theta) = 0 \iff \Phi^T \Phi \theta = \Phi^T y$ — la MÊME équation
Ce qu'est fondamentalement la régression linéaire ?	Une méthode pour résoudre des SYSTÈMES d'équations linéaires insolubles, au sens des moindres carrés