

Fiche 409 — Réduction de dimension par ACP : variance maximale, projection, ACP probabiliste

Matière	Maths · Apprentissage automatique
Cours source	Deisenroth, Faisal & Ong, <i>Mathematics for Machine Learning</i> , Cambridge University Press — chapitre 10 « Dimensionality Reduction with Principal Component Analysis » (p. 317-348)
Difficulté	Avancé — le deuxième pilier , la synthèse la plus complète du livre
Temps d'étude estimé	140 min
Prérequis	Fiche 401 (base, changement de base) · Fiche 402 (projections) · Fiche 403 (valeurs propres, SVD, Eckart-Young) · Fiche 405 (gaussiennes) · Fiche 406 (optimisation sous contraintes)
Concepts clés	Matrice de covariance des données, code, sous-espace principal, matrice de projection, perspective de la variance maximale, composante principale, chargement, perspective de la projection, erreur de reconstruction, coordonnées optimales, complément orthogonal, approximation de rang faible, itération de la puissance, ACP en grande dimension, centrage, standardisation, ACP probabiliste (PPCA), processus génératif, échantillonnage ancestral, vraisemblance, a posteriori latente
Poids à l'examen	$S = \frac{1}{N} \sum_n x_n x_n^T \cdot z_n = B^T x_n$ et $\tilde{x}_n = B B^T x_n \cdot S b_m = \lambda_m b_m$ et $V_m = \lambda_m \cdot J_M = \sum_{j=M+1}^D \lambda_j$ · l'équivalence variance maximale $\Leftrightarrow$ erreur de reconstruction minimale · l'astuce $\frac{1}{N} X^T X$ en grande dimension · PPCA : $p(x) = \mathcal{N}(\mu, B B^T + \sigma^2 I)$.

Vue d'ensemble

LE FIL DU CHAPITRE : DEUX dérivations, UNE seule réponse – les VECTEURS PROPRES de S

§10.1 CADRE données centrées $x_n \in \mathbb{R}^D$, COVARIANCE $S = (1/N) \sum_n x_n x_n^T$

CODE $z_n = B^T x_n \in \mathbb{R}^M$ ($M < D$)

RECONSTRUCTION $\tilde{x}_n = B B^T x_n \in \mathbb{R}^D$

$B = [b_1, \dots, b_M] \in \mathbb{R}^{(D \times M)}$ à colonnes ORTHONORMÉES

§10.2 PERSPECTIVE « VARIANCE MAXIMALE »

$\max_{\|b\|^2=1} b^T S b$ s.c. $\|b\|^2 = 1 \rightarrow$ LAGRANGE $\rightarrow S b_1 = \lambda_1 b_1$

⚠ $V_1 = b_1^T S b_1 = \lambda_1$ la variance EST la valeur propre

la m-ième CP : même résultat, sur les données DÉFLATÉES $\hat{S} b_m = S b_m = \lambda_m b_m$

VARIANCE RETENUE par M composantes = $\lambda_1 + \dots + \lambda_M$

§10.3 PERSPECTIVE « PROJECTION »

$J_M = (1/N) \sum_n \|x_n - \tilde{x}_n\|^2 \leftarrow$ ERREUR DE RECONSTRUCTION

COORDONNÉES OPTIMALES $z_{in} = b_i^T x_n \leftarrow$ la PROJECTION ORTHOGONALE

$x_n - \tilde{x}_n$ vit ENTIÈREMENT dans le COMPLÉMENT ORTHOGONAL

$J_M = \sum_{j>M} b_j^T S b_j = \text{tr}(\sum_{j>M} b_j b_j^T S) = \sum_{j>M} \lambda_j$

⚠ MINIMISER l'erreur $\Leftrightarrow$ MAXIMISER la variance retenue – MÊME SOLUTION

§10.4 CALCUL eigendécomposition de S OU SVD de X (⚠ $\lambda_i = \sigma_i^2$)

ECKART-YOUNG : la meilleure approximation de rang M est la SVD TRONQUÉE

ITÉRATION DE LA PUISSANCE $x_{k+1} = S x_k / \|S x_k\| \rightarrow$ le 1er vecteur propre

§10.5 GRANDE DIMENSION ($N \ll D$)

⚠ diagonaliser $(1/N) X^T X \in \mathbb{R}^{(N \times N)}$ au lieu de $(1/N) X X^T \in \mathbb{R}^{(D \times D)}$

MÊMES valeurs propres non nulles ; b_m se retrouve par $c_m = X^T b_m$

§10.6 LES CINQ ÉTAPES EN PRATIQUE

1. CENTRER 2. STANDARDISER 3. EIGENDÉCOMPOSITION

4. PROJETER $z^* = B^T x^*$ 5. DÉ-STANDARDISER pour revenir dans l'espace original

§10.7 PERSPECTIVE VARIABLE LATENTE – l'ACP PROBABILISTE (PPCA)

$z \sim N(0, I)$, $x = Bz + \mu + \varepsilon$, $\varepsilon \sim N(0, \sigma^2 I)$

VRAISEMBLANCE $p(x) = N(x \mid \mu, B B^T + \sigma^2 I)$

A POSTERIORI $p(z|x) = N(m, C)$, $m = B^T (B B^T + \sigma^2 I)^{-1} (x - \mu)$

$C = I - B^T (B B^T + \sigma^2 I)^{-1} B$

⚠ la covariance a posteriori NE DÉPEND PAS de x

LE RÉSULTAT UNIQUE Les colonnes de B sont les M VECTEURS PROPRES de S
associés aux M PLUS GRANDES VALEURS PROPRES.

L'intuition fondatrice. « La réduction de dimension exploite une propriété des données de grande dimension (par exemple les images) : elles **résident souvent sur un SOUS-ESPACE de basse dimension**. » L'exemple de la figure 10.1 : les données *« ne résident pas tout à fait sur une droite, mais elles **ne varient pas beaucoup dans la direction x_2** , si bien qu'on peut les exprimer **comme si** elles étaient sur une droite — **presque sans perte** »*.

Autres noms de l'ACP. Dans la communauté du **traitement du signal**, l'ACP est aussi connue sous le nom de **transformée de KARHUNEN-LOÈVE**.

● Concept 1 — Le cadre (§10.1)

Le jeu de données : $\mathcal{X} = \{x_1, \dots, x_N\}$, $x_n \in \mathbb{R}^D$, i.i.d., **de moyenne 0**, avec la **matrice de covariance des données** :

$$S = \frac{1}{N} \sum_{n=1}^N x_n x_n^\top$$

Les deux objets centraux :

$$\underbrace{z_n = B^\top x_n \in \mathbb{R}^M}_{\text{le CODE (représentation compressée)}} \quad \underbrace{\tilde{x}_n = BB^\top x_n \in \mathbb{R}^D}_{\text{la RECONSTRUCTION}}$$

avec la **matrice de projection** $B := [b_1, \dots, b_M] \in \mathbb{R}^{D \times M}$ à colonnes **ORTHONORMÉES** : $b_i^\top b_j = 0$ si $i \neq j$ et $b_i^\top b_i = 1$.

L'objectif. « Trouver des projections $\tilde{x}_n$ des points x_n qui soient **AUSSI SEMBLABLES QUE POSSIBLE** aux points originaux, mais qui aient une **dimensionnalité INTRINSÈQUE significativement PLUS BASSE**. »

Trois espaces à distinguer (figure 10.2) :

Objet	Espace	Rôle
x	$\mathbb{R}^D$	Original
z	$\mathbb{R}^M$	Compressé — c'est ce que l'ACP RENVOIE
$\tilde{x}$	$\mathbb{R}^D$	Reconstruit — il vit dans l'espace original mais a une représentation intrinsèque de plus basse dimension

La remarque clé. « Bien que $\tilde{x}_n$ soit un vecteur de dimension D , il **ne requiert qu'une SEULE coordonnée** z_{1n} pour être représenté par rapport au vecteur de base $b_1 \in \mathbb{R}^D$. »

Exemple 10.1 — coordonnées contre représentation. Dans $\mathbb{R}^2$ avec la base canonique, $[5, 3]^\top = 5e_1 + 3e_2$ demande **deux** coordonnées. Mais un vecteur de la forme $\tilde{x} = [z, 0]^\top$ **ne demande qu'UNE** coordonnée par rapport à e_1 : « il vit dans un sous-espace de dimension 1 ».

La remarque de notation, propre à ce chapitre. « Nous **NE suivons PAS** la convention de collecter les données en LIGNES de la matrice : nous les définissons comme les **COLONNES** de $\mathbf{X}$. Notre matrice $\mathbf{X}$ est donc $D \times N$ et non $N \times D$. La raison : les **opérations algébriques se déroulent SANS AVOIR À TRANSPOSER** la matrice ni redéfinir les vecteurs comme vecteurs lignes. »

● Concept 2 — La perspective de la variance maximale (§10.2)

2.1 Le principe

L'idée. « Si l'on interprète le **contenu informationnel** des données comme leur caractère "**REEMPLISSANT L'ESPACE**", alors on peut décrire l'information contenue en regardant l'**ÉTALEMENT** des données. La **VARIANCE** est un indicateur de cet étalement. »

Conserver le plus d'information $\equiv$ capturer la PLUS GRANDE VARIANCE dans le code de basse dimension (Hotelling, 1933)

POURQUOI LE CENTRAGE EST SANS PERTE DE GÉNÉRALITÉ.

$$\mathbb{V}_z[z] = \mathbb{V}_x[B^\top(x - \mu)] = \mathbb{V}_x[B^\top x - B^\top \mu] = \mathbb{V}_x[B^\top x]$$

« La variance du code de basse dimension **NE DÉPEND PAS de la MOYENNE** des données. » Et avec cette hypothèse, la moyenne du code est aussi **0** puisque $\mathbb{E}_z[z] = B^\top \mathbb{E}_x[x] = 0$.

2.2 La direction de variance maximale

Étape 1 — l'objectif. On maximise la variance de la première coordonnée :

$$V_1 := \mathbb{V}[z_1] = \frac{1}{N} \sum_{n=1}^N z_{1n}^2 \quad \text{avec} \quad z_{1n} = b_1^\top x_n$$

Étape 2 — la réécriture matricielle.

$$V_1 = \frac{1}{N} \sum_{n=1}^N (b_1^\top x_n)^2 = \frac{1}{N} \sum_{n=1}^N b_1^\top x_n x_n^\top b_1 = b_1^\top \left(\frac{1}{N} \sum_{n=1}^N x_n x_n^\top \right) b_1$$

$$V_1 = b_1^\top S b_1$$

Étape 3 — la contrainte. « **Augmenter arbitrairement la MAGNITUDE de b_1 AUGMENTE V_1** : un vecteur deux fois plus long peut donner un V_1 potentiellement **QUATRE fois plus grand**. On restreint donc toutes les solutions à $\|b_1\|^2 = 1$. »

$$\max_{b_1} b_1^\top S b_1 \quad \text{s.c.} \quad \|b_1\|^2 = 1$$

Étape 4 — le lagrangien (§7.2) :

$$\mathcal{L}(b_1, \lambda) = b_1^\top S b_1 + \lambda_1 (1 - b_1^\top b_1)$$

$$\frac{\partial \mathcal{L}}{\partial b_1} = 2b_1^\top S - 2\lambda_1 b_1^\top, \quad \frac{\partial \mathcal{L}}{\partial \lambda_1} = 1 - b_1^\top b_1$$

Étape 5 — l'annulation.

$$S b_1 = \lambda_1 b_1 \quad \text{et} \quad b_1^\top b_1 = 1$$

LA RÉVÉLATION. *« En comparant avec la définition d'une décomposition en valeurs propres (§4.4), on voit que b_1 est un **VECTEUR PROPRE** de la **matrice de covariance S** , et que le **multiplicateur de LAGRANGE λ_1** joue le rôle de la **VALEUR PROPRE** correspondante. »*

Étape 6 — la conséquence.

$$V_1 = b_1^\top S b_1 = \lambda_1 b_1^\top b_1 = \lambda_1$$

LA CONCLUSION. « La variance des données projetées sur un sous-espace de dimension 1 **ÉGALE LA VALEUR PROPRE** associée au vecteur de base qui engendre ce sous-espace. Donc, pour **MAXIMISER** la variance du code, on choisit le vecteur de base associé à **LA PLUS GRANDE valeur propre** de S . Ce vecteur propre est la **PREMIÈRE COMPOSANTE PRINCIPALE**. »

Vocabulaire. « La quantité $\sqrt{\lambda_1}$ est appelée le **CHARGEMENT** (loading) du vecteur unitaire b_1 et représente l'**ÉCART-TYPE** des données pris en compte par le sous-espace principal. »

2.3 Le sous-espace de dimension M

L'idée de DÉFLATION. « La m -ième composante principale se trouve en **SOUSTRAYANT l'effet des $m - 1$ premières** composantes des données, essayant ainsi de trouver des composantes qui compressent l'**information RESTANTE**. »

$$\hat{X} := X - \sum_{i=1}^{m-1} b_i b_i^\top X = X - B_{m-1} X$$

où $B_{m-1} := \sum_{i=1}^{m-1} b_i b_i^\top$ projette sur le sous-espace engendré par $b_1, \dots, b_{m-1}$. « $\hat{X}$ contient l'information des données **qui n'a PAS ENCORE été compressée**. »

Le résultat remarquable. Les vecteurs propres de S et de $\hat{S}$ sont **IDENTIQUES** :

$$\hat{S}b_i = (S - SB_{m-1} - B_{m-1}S + B_{m-1}SB_{m-1})b_i$$

Les deux cas :

$$B_{m-1}b_i = b_i \text{ si } i < m \quad B_{m-1}b_i = 0 \text{ si } i \geq m$$

Cas	Résultat
$i \geq m$	$\hat{S}b_i = (S - B_{m-1}S)b_i = Sb_i = \lambda_i b_i$ — même vecteur propre, MÊME valeur propre
$i < m$	$\hat{S}b_i = 0 = 0 \cdot b_i$ — valeur propre NULLE : $b_1, \dots, b_{m-1}$ engendrent le NOYAU de $\hat{S}$

La conclusion. *« Tout vecteur propre de S est aussi vecteur propre de $\hat{S}$. Mais si le vecteur propre fait partie du sous-espace principal de dimension $m - 1$, sa valeur propre pour $\hat{S}$ est 0. »*
Donc λ_m est la **plus grande** valeur propre de $\hat{S}$ et la m -ième **plus grande** de S .

$$V_m = b_m^\top S b_m = \lambda_m \quad \Rightarrow \quad \text{Variance retenue par } M \text{ composantes} = \sum_{m=1}^M \lambda_m$$

Sur un jeu simulé ($D = 4$, $N = 200$, structure latente de rang 2 plus bruit) :

Valeurs propres de S : $[4,112758 ; 1,937579 ; 0,102982 ; 0,093462]$, et
 $\text{tr}(S) = 6,246782 = \sum_m \lambda_m$ (théorème 4.17)

$V_m = b_m^\top S b_m = \lambda_m$:

m	$b_m^\top S b_m$	λ_m	écart
1	4,11275820	4,11275820	$8,9 \cdot 10^{-16}$
2	1,93757947	1,93757947	0
3	0,10298190	0,10298190	$3,5 \cdot 10^{-16}$
4	0,09346227	0,09346227	$6,9 \cdot 10^{-17}$

Variance du code $= \sum_{m \leq M} \lambda_m$:

M	Variance de z mesurée	$\sum_{m \leq M} \lambda_m$
1	4,11275820	4,11275820
2	6,05033767	6,05033767
3	6,15331957	6,15331957
4	6,24678184	6,24678184

Exemple 10.2 — les « 8 » de MNIST. Sur tous les chiffres « 8 » de l'ensemble d'entraînement, « *on voit que **seules quelques** valeurs propres diffèrent significativement de 0. Donc **l'essentiel de la variance est capturé par SEULEMENT quelques composantes principales.*** »

● Concept 3 — La perspective de la projection (§10.3)

3.1 L'objectif

La reformulation. « On dérive l'ACP comme un algorithme qui **MINIMISE DIRECTEMENT L'ERREUR DE RECONSTRUCTION MOYENNE**. Cette perspective permet d'interpréter l'ACP comme un **AUTO-ENCODEUR LINÉAIRE OPTIMAL**. »

Avec une **base orthonormée ordonnée** $(b_1, \dots, b_D)$ de $\mathbb{R}^D$:

$$x = \sum_{d=1}^D \zeta_d b_d = \underbrace{\sum_{m=1}^M \zeta_m b_m}_{\text{retenu}} + \underbrace{\sum_{j=M+1}^D \zeta_j b_j}_{\text{abandonné}}$$

$$J_M := \frac{1}{N} \sum_{n=1}^N \|x_n - \tilde{x}_n\|^2$$

C'est l'**ERREUR DE RECONSTRUCTION** (Pearson, 1901). « On rend explicite que M est la dimension du sous-espace sur lequel on projette. »

La stratégie en deux temps : « D'abord on **optimise les COORDONNÉES** z_n pour une base orthonormée donnée ; ensuite on trouve la **base OPTIMALE**. »

3.2 Les coordonnées optimales

$$\frac{\partial J_M}{\partial z_{in}} = \frac{\partial J_M}{\partial \tilde{x}_n} \frac{\partial \tilde{x}_n}{\partial z_{in}}, \quad \frac{\partial J_M}{\partial \tilde{x}_n} = -\frac{2}{N} (x_n - \tilde{x}_n)^\top, \quad \frac{\partial \tilde{x}_n}{\partial z_{in}} = b_i$$

$$\frac{\partial J_M}{\partial z_{in}} = -\frac{2}{N} (x_n - \tilde{x}_n)^\top b_i \stackrel{\text{ONB}}{=} -\frac{2}{N} (x_n^\top b_i - z_{in})$$

$$z_{in} = x_n^\top b_i = b_i^\top x_n$$

LA CONCLUSION GÉOMÉTRIQUE. « Les coordonnées de la projection optimale de x_n par rapport aux vecteurs de base sont **les coordonnées de la PROJECTION ORTHOGONALE de x_n sur le sous-espace principal**. » C'est exactement le résultat du §3.8 (fiche 402), retrouvé ici **par le calcul**.

3.3 Le déplacement vit dans le complément orthogonal

$$\begin{aligned}\tilde{x}_n &= \sum_{m=1}^M z_{mn} b_m = \sum_{m=1}^M (x_n^\top b_m) b_m = \left(\sum_{m=1}^M b_m b_m^\top \right) x_n \\ x_n &= \left(\sum_{d=1}^D b_d b_d^\top \right) x_n = \underbrace{\left(\sum_{m=1}^M b_m b_m^\top \right) x_n}_{=\tilde{x}_n} + \left(\sum_{j=M+1}^D b_j b_j^\top \right) x_n\end{aligned}$$

$$x_n - \tilde{x}_n = \left(\sum_{j=M+1}^D b_j b_j^\top \right) x_n$$

« La différence est **EXACTEMENT la PROJECTION du point sur le COMPLÉMENT ORTHOGONAL** du sous-espace principal. Le vecteur de déplacement $x_n - \tilde{x}_n$ vit dans le sous-espace **ORTHOGONAL** au sous-espace principal. »

Le lien avec Eckart-Young. La matrice de projection est

$$\sum_{m=1}^M b_m b_m^\top = B B^\top$$

*« Par construction comme **somme de matrices de RANG 1** $b_m b_m^\top$, $B B^\top$ est **symétrique et de RANG M** . »* Et

$$\frac{1}{N} \sum_{n=1}^N \|x_n - \tilde{x}_n\|^2 = \frac{1}{N} \sum_{n=1}^N \|(I - B B^\top) x_n\|^2$$

« Trouver les $b_1, \dots, b_M$ qui minimisent la différence est **ÉQUIVALENT à trouver la MEILLEURE APPROXIMATION DE RANG M de la MATRICE IDENTITÉ I** » (§4.6).

Avec $M = 2$ et $D = 4$:

Propriété	Test	Résultat
Idempotence de $BB^\top$	$\max P^2 - P $	0,0
Symétrie	$\max P - P^\top $	0,0
Trace = M	$\text{tr}(BB^\top)$	2,0
Déplacement orthogonal	$\max_{n,m} (x_n - \tilde{x}_n) \cdot b_m $	0,0

3.4 La reformulation de la perte — le point culminant

$$J_M = \frac{1}{N} \sum_{n=1}^N \left\| \sum_{j=M+1}^D (b_j^\top x_n) b_j \right\|^2 \stackrel{\text{ONB}}{=} \frac{1}{N} \sum_{n=1}^N \sum_{j=M+1}^D (b_j^\top x_n)^2$$

En échangeant les sommes :

$$J_M = \sum_{j=M+1}^D b_j^\top \left(\frac{1}{N} \sum_{n=1}^N x_n x_n^\top \right) b_j = \sum_{j=M+1}^D b_j^\top S b_j$$

Puis, par **linéarité et invariance CYCLIQUE de la trace** (fiche 403) :

$$J_M = \sum_{j=M+1}^D \text{tr} (b_j^\top S b_j) = \text{tr} \left(\underbrace{\left(\sum_{j=M+1}^D b_j b_j^\top \right)}_{\text{matrice de projection, de rang } D-M} S \right)$$

L'ÉQUIVALENCE DES DEUX PERSPECTIVES, énoncée par le livre : « On peut formuler l'erreur de reconstruction quadratique moyenne comme **la COVARIANCE des données PROJETÉE sur le COMPLÉMENT ORTHOGONAL** du sous-espace principal. **Minimiser l'erreur de reconstruction moyenne est donc ÉQUIVALENT à MINIMISER la variance des données projetée sur le sous-espace QU'ON IGNORE** — ou, de façon équivalente, à **MAXIMISER la variance de la projection qu'on RETIENT**. »

ERREUR MINIMALE $\iff$ VARIANCE MAXIMALE $\implies$ MÊME SOLUTION

La conséquence chiffrée — l'équation (10.62) :

$$J_M = \frac{1}{N} \sum_{n=1}^N \|x_n - \tilde{x}_n\|^2 = \sum_{i=M+1}^D \lambda_i$$

« L'erreur de reconstruction est la **SOMME des valeurs propres ABANDONNÉES**. »

M	J_M mesurée	$\sum_{j>M} \lambda_j$	écart
1	2,13402364	2,13402364	$4,4 \cdot 10^{-16}$
2	0,19644416	0,19644416	$2,8 \cdot 10^{-17}$
3	0,09346227	0,09346227	$2,1 \cdot 10^{-16}$
4	0,00000000	0,00000000	$2,6 \cdot 10^{-31}$

Le contrôle de cohérence global : pour tout M , on a **variance retenue + erreur = $\text{tr}(S)$** .
En $M = 2$: $6,05034 + 0,19644 = 6,24678 = \text{tr}(S)$ — les deux perspectives partagent **le même budget total**.

● **Concept 4 — Calcul des vecteurs propres (§10.4)**

4.1 Les deux voies

$$S = \frac{1}{N} \sum_{n=1}^N x_n x_n^\top = \frac{1}{N} X X^\top, \quad X = [x_1, \dots, x_N] \in \mathbb{R}^{D \times N}$$

Voie	Comment
Eigendécomposition	Directement sur S (§4.2)
SVD de X	$X = U \Sigma V^\top$; « Comme S est symétrique et se factorise en $X X^\top$ (au facteur $\frac{1}{N}$ près), les valeurs propres de S sont les CARRÉS des valeurs SINGULIÈRES de X »

$$\lambda_i = \sigma_i^2 \quad \text{et} \quad U = B$$

4.2 Eckart-Young appliqué à l'ACP

« Le théorème d'Eckart-Young (théorème 4.25) offre une façon **DIRECTE** d'estimer la représentation de basse dimension. » La meilleure approximation de rang M

$$\tilde{X}_M := \underset{\text{rk}(A) \leq M}{\text{argmin}} \|X - A\|_2$$

est donnée par la **SVD TRONQUÉE** au top- M :

$$\tilde{X}_M = U_M \Sigma_M V_M^\top \in \mathbb{R}^{D \times N}$$

avec $U_M \in \mathbb{R}^{D \times M}$, $\Sigma_M \in \mathbb{R}^{M \times M}$ diagonale des M plus grandes valeurs singulières, $V_M \in \mathbb{R}^{N \times M}$.

4.3 Aspects pratiques

POURQUOI ON NE PASSE PAS PAR LE POLYNÔME CARACTÉRISTIQUE.

« Pour les matrices plus grandes que 4×4 , ce n'est **PAS possible** : il faudrait trouver les racines d'un polynôme de degré 5 ou plus — et le **théorème d'ABEL-RUFFINI** (Ruffini 1799 ; Abel 1826) établit qu'il **n'existe AUCUNE solution ALGÈBRIQUE** à ce problème. »

POURQUOI NE PAS TOUT CALCULER.

« Dans beaucoup d'applications on n'a besoin que de **quelques vecteurs propres**. Il serait **GASPILLEUR** de calculer la décomposition complète pour ensuite jeter tout le reste. Les **processus ITÉRATIFS** qui optimisent directement ces vecteurs propres sont **computationnellement plus efficaces**. »

L'ITÉRATION DE LA PUISSANCE — le cas extrême du premier vecteur propre seul. On choisit x_0 hors du noyau de S , puis :

$$x_{k+1} = \frac{Sx_k}{\|Sx_k\|}, \quad k = 0, 1, \dots$$

« Le vecteur est multiplié par S à chaque itération puis **NORMALISÉ** — on a toujours $\|x_k\| = 1$. Cette suite **CONVERGE vers le vecteur propre associé à la PLUS GRANDE valeur propre de S** . »

Après 300 itérations depuis un x_0 aléatoire :

$$|x_k \cdot b_1| = 1,0000000000 \quad (\text{alignement PARFAIT})$$

Quotient de Rayleigh $x_k^\top S x_k = 4,1127582$ contre $\lambda_1 = 4,1127582$

● Concept 5 — L'ACP en grande dimension (§10.5)

Le problème. *« En D dimensions, la covariance est une matrice $D \times D$; calculer ses valeurs et vecteurs propres coûte **CUBIQUEMENT en D** . Pour des images de 100×100 pixels, il faudrait diagonaliser une matrice $10\,000 \times 10\,000$. »*

L'ASTUCE — quand $N \ll D$. Partant de $Sb_m = \frac{1}{N} X X^\top b_m = \lambda_m b_m$, multiplier à gauche par $X^\top \in \mathbb{R}^{N \times D}$:

$$\frac{1}{N} X^\top X \underbrace{X^\top b_m}_{=: c_m} = \lambda_m X^\top b_m \quad \Longleftrightarrow \quad \boxed{\frac{1}{N} X^\top X c_m = \lambda_m c_m}$$

Le gain. *« $\frac{1}{N} X^\top X$ a **LES MÊMES valeurs propres NON NULLES** que la matrice de covariance S . Mais c'est maintenant une matrice $N \times N$, dont on peut calculer valeurs et vecteurs propres **BEAUCOUP plus efficacement**. »* On récupère ensuite b_m en **remultipliant par X** et en normalisant.

Avec $D = 8$, $N = 3$:

Matrice	Valeurs propres
$\frac{1}{N} X X^\top (8 \times 8)$	[5,102489 ; 3,067560 ; 0,453579 ; 0; 0; 0; 0; 0]
$\frac{1}{N} X^\top X (3 \times 3)$	[5,102489 ; 3,067560 ; 0,453579]

Les trois plus grandes **coïncident exactement**

Une inexactitude d'une unité dans l'énoncé du §10.5. Le livre écrit : « le rang de la matrice de covariance S est N , elle a donc $D - N + 1$ valeurs propres nulles ». Les deux affirmations sont **incohérentes** : un rang N donnerait $D - N$ zéros. Vérification numérique avec $D = 8, N = 3$:

Données	Rang de S	Nombre de valeurs propres nulles
Non centrées	$3 = N$	$5 = D - N$
CENTRÉES (l'hypothèse du §10.5)	$2 = N - 1$	$6 = D - N + 1$

C'est donc le **comptage $D - N + 1$ qui est CORRECT** — mais il découle du rang $N - 1$, pas N : le **CENTRAGE** fait perdre exactement un degré de liberté. Cela ne change rien à la validité de l'astuce.

● Concept 6 — Les cinq étapes en pratique (§10.6)

Étape 1 — SOUSTRACTION DE LA MOYENNE. Calculer μ et le soustraire de chaque point. « La soustraction de la moyenne n'est pas **strictement nécessaire**, mais elle **RÉDUIT le RISQUE de PROBLÈMES NUMÉRIQUES**. »

Étape 2 — STANDARDISATION. Diviser par l'écart-type σ_d de chaque dimension d . « Les données sont maintenant **SANS UNITÉ** et de **variance 1 le long de chaque axe**. »

Étape 3 — EIGENDÉCOMPOSITION. Calculer S , ses valeurs et vecteurs propres. « Comme la covariance est **SYMÉTRIQUE**, le théorème spectral (4.15) garantit qu'on peut trouver une **ONB de vecteurs propres**. » Sur la figure 10.11(d), « les vecteurs propres sont mis à l'échelle par la magnitude de la valeur propre correspondante ; le **plus LONG engendre le sous-espace principal** ».

Étape 4 — PROJECTION. Standardiser d'abord le point de test avec la moyenne et l'écart-type des données d'ENTRAÎNEMENT :

$$x_*^{(d)} \leftarrow \frac{x_*^{(d)} - \mu_d}{\sigma_d}, \quad d = 1, \dots, D$$

$$\tilde{x}_* = BB^T x_* \quad \text{avec les coordonnées} \quad z_* = B^T x_*$$

CE QUE L'ACP RENVOIE.

*« L'ACP renvoie les **COORDONNÉES** z_* , **PAS** les projections $\tilde{x}_*$. »*

Étape 5 — DÉ-STANDARDISATION. « Ayant standardisé le jeu de données, $\tilde{x}_* = BB^T x_*$ ne donne les projections que **dans le contexte du jeu STANDARDISÉ** » — il faut **multiplier par σ_d et rajouter μ_d** pour revenir dans l'espace original.

Exemple 10.4 — MNIST. 60 000 chiffres manuscrits en images $28 \times 28 = 784$ pixels, donc $x \in \mathbb{R}^{784}$. Sur 5 389 images du chiffre « 8 » :

Nombre de CP	Qualité de la reconstruction
1	« Une reconstruction à moitié décente , mais FLOUE et GÉNÉRIQUE »
10, 100	« Les reconstructions deviennent plus NETTES , plus de détails sont pris en compte »
500	« Une reconstruction quasi PARFAITE »
784	« On récupérerait le chiffre EXACT , sans AUCUNE perte de compression »

« L'importance des composantes principales **CHUTE RAPIDEMENT**, et seuls des gains marginaux s'obtiennent en ajoutant davantage de CP. »

● Concept 7 — L'ACP probabiliste (§10.7)

7.1 Les neuf raisons d'un modèle probabiliste

*« Une ACP dérivée sans notion de modèle probabiliste permet de **contourner toutes les difficultés mathématiques** de la théorie des probabilités, mais un modèle probabiliste offrirait **plus de FLEXIBILITÉ et des APERÇUS utiles* ». Il permettrait de :

1. Disposer d'une **fonction de VRAISEMBLANCE**, et traiter explicitement les **observations BRUITÉES**.
2. Faire de la **comparaison de modèles BAYÉSIENNE** via la vraisemblance marginale (§8.6).

3. Voir l'ACP comme un **modèle GÉNÉRATIF** — donc **SIMULER de nouvelles données**.
4. Établir des **connexions directes** avec des algorithmes apparentés.
5. Traiter les **dimensions MANQUANTES au hasard** en appliquant le théorème de Bayes.
6. Disposer d'une notion de **NOUVEAUTÉ** d'un point de donnée.
7. **Étendre** le modèle de façon principielle, par exemple à un **mélange de modèles d'ACP**.
8. Retrouver l'**ACP classique comme CAS PARTICULIER**.
9. Permettre un **traitement pleinement bayésien** en marginalisant les paramètres.

La PPCA a été proposée par **Tipping et Bishop (1999)**. « *La solution d'ACP obtenue en maximisant la variance ou en minimisant l'erreur de reconstruction est obtenue comme le **cas particulier du maximum de vraisemblance dans un cadre SANS BRUIT**.* »

7.2 Le processus génératif

$$z \sim \mathcal{N}(0, I) \in \mathbb{R}^M \quad x = Bz + \mu + \epsilon \in \mathbb{R}^D, \quad \epsilon \sim \mathcal{N}(0, \sigma^2 I)$$

$$p(x \mid z, B, \mu, \sigma^2) = \mathcal{N}(x \mid Bz + \mu, \sigma^2 I)$$

L'ÉCHANTILLONNAGE ANCESTRAL. « Pour générer un point typique : on échantillonne d'abord une variable latente z_n de $p(z)$; **puis** on l'utilise pour échantillonner un point **CONDITIONNÉ** sur ce z_n . »

Le **modèle probabiliste** (la loi jointe, §8.4) :

$$p(x, z \mid B, \mu, \sigma^2) = p(x \mid z, B, \mu, \sigma^2) p(z)$$

7.3 La vraisemblance

On **marginalise la variable latente** (§8.4.3) :

$$p(x \mid B, \mu, \sigma^2) = \int \mathcal{N}(x \mid Bz + \mu, \sigma^2 I) \mathcal{N}(z \mid 0, I) dz$$

Les deux moments, par les règles des transformations affines (§6.4.4) :

$$\mathbb{E}_x[x] = \mathbb{E}_z[Bz + \mu] + \mathbb{E}_\epsilon[\epsilon] = \mu$$

$$\mathbb{V}[x] = \mathbb{V}_z[Bz] + \sigma^2 I = B \mathbb{V}_z[z] B^\top + \sigma^2 I = BB^\top + \sigma^2 I$$

$$p(x | B, \mu, \sigma^2) = \mathcal{N}(x | \mu, BB^\top + \sigma^2 I)$$

POURQUOI ON NE PEUT PAS UTILISER $p(x | z)$ DIRECTEMENT.

« On ne peut **pas** utiliser la loi conditionnelle pour le maximum de vraisemblance car elle **DÉPEND ENCORE des variables latentes**. La fonction de vraisemblance requise **ne doit dépendre QUE des données et des paramètres**. »

La loi jointe complète. La covariance croisée manquante :

$$\text{Cov}[x, z] = \text{Cov}_z[Bz + \mu] = B \text{Cov}_z[z, z] = B$$

$$p(x, z | B, \mu, \sigma^2) = \mathcal{N} \left(\begin{bmatrix} x \\ z \end{bmatrix} \middle| \begin{bmatrix} \mu \\ 0 \end{bmatrix}, \begin{bmatrix} BB^\top + \sigma^2 I & B \\ B^\top & I \end{bmatrix} \right)$$

de vecteur moyenne de longueur $D + M$ et covariance $(D + M) \times (D + M)$.

Avec B construite à partir des deux premières composantes principales mises à l'échelle par $\sqrt{\lambda_m}$ et $\sigma^2 = 0,09$, $D = 4$:

$$\text{tr}(BB^\top + \sigma^2 I) = 6,410338$$

$$\lambda_1 + \lambda_2 + D\sigma^2 = 6,050338 + 4 \times 0,09 = 6,410338$$

La lecture est limpide : la trace de la covariance PPCA se **décompose exactement** en **variance expliquée par le sous-espace** ($\lambda_1 + \lambda_2$) **plus bruit isotrope** ($D\sigma^2$).

7.4 L'a posteriori latente

Le **conditionnement gaussien** (§6.5.1) appliqué à la jointe donne immédiatement :

$$p(z | x) = \mathcal{N}(z | m, C)$$

$$m = B^{\top}(BB^{\top} + \sigma^2 I)^{-1}(x - \mu)$$

$$C = I - B^{\top}(BB^{\top} + \sigma^2 I)^{-1}B$$

LE POINT REMARQUABLE. *« La covariance a posteriori **NE DÉPEND PAS** des données observées x . »* — exactement comme pour la régression bayésienne (fiche 408). « Pour une nouvelle observation x_* , on utilise (10.73) pour déterminer la loi a posteriori de la variable latente correspondante z_* . La matrice de covariance C permet d'**évaluer la CONFIANCE** dans l'encodage. »

Comment reconnaître le type d'exercice

L'énoncé dit...	Le type	La méthode
« Calculer la matrice de covariance »	§10.1	CENTRER d'abord , puis $S = \frac{1}{N} \sum_n x_n x_n^\top = \frac{1}{N} X X^\top$
« Trouver la direction de variance maximale »	§10.2.1	Lagrangien $\Rightarrow S b_1 = \lambda_1 b_1$: le vecteur propre dominant
« Quelle variance conserve-t-on ? »	§10.2.2	$\sum_{m \leq M} \lambda_m$; en proportion : $\frac{\sum_{m \leq M} \lambda_m}{\text{tr } S}$
« Quelle est l'erreur de reconstruction ? »	(10.62)	$J_M = \sum_{j > M} \lambda_j$ — la somme des vp ABANDONNÉES
« Coder / décoder un point »	§10.1	Code $z = B^\top x$; reconstruction $\tilde{x} = B B^\top x$
« Montrer que la projection est orthogonale »	§10.3.2	Dériver J_M par z_{in} , annuler $\Rightarrow z_{in} = b_i^\top x_n$
« Où vit le vecteur d'erreur ? »	§10.3.3	Dans le COMPLÉMENT ORTHOGONAL : $(\sum_{j > M} b_j b_j^\top) x_n$
« Relier ACP et Eckart-Young »	§10.4.1	La SVD tronquée au top- M est la meilleure approximation de rang M
« Passer de la SVD aux valeurs propres »	§10.4	$\lambda_i = \sigma_i^2$ et $U = B$
« $N \ll D$, comment faire ? »	§10.5	Diagonaliser $\frac{1}{N} X^\top X \in \mathbb{R}^{N \times N}$; puis $c_m = X^\top b_m$
« Trouver seulement le premier vecteur propre »	§10.4.2	Itération de la puissance : $x_{k+1} = S x_k / \ S x_k\ $
« Appliquer l'ACP à un nouveau point »	§10.6	Standardiser avec la moyenne et l'écart-type d'ENTRAÎNEMENT
« Écrire le modèle génératif de la PPCA »	§10.7.1	$z \sim \mathcal{N}(0, I)$, $x = Bz + \mu + \epsilon$
« Quelle est la vraisemblance de la PPCA ? »	§10.7.2	$\mathcal{N}(x \mid \mu, B B^\top + \sigma^2 I)$
« Encoder probabilistiquement »	§10.7.3	$p(z \mid x) = \mathcal{N}(m, C)$ par conditionnement gaussien

Comment résoudre : les cinq méthodes pas-à-pas

Méthode A — Faire une ACP complète.

1. **Centrer** : $x_n \leftarrow x_n - \mu$.
2. **Standardiser** : $x_n^{(d)} \leftarrow x_n^{(d)} / \sigma_d$.
3. $S = \frac{1}{N} X X^\top$; vérifier la **symétrie**.
4. **Eigendécomposition** ; trier les λ par ordre **décroissant**.
5. B = les M premiers vecteurs propres **en colonnes**.
6. **Coder** : $z_n = B^\top x_n$.
7. **Contrôles** : $\sum_m \lambda_m = \text{tr}(S)$; variance du code = $\sum_{m \leq M} \lambda_m$; $J_M = \sum_{j > M} \lambda_j$.

Méthode B — Choisir M .

1. Tracer les λ_m par ordre décroissant (le **spectre**).
2. Chercher le « **coude** » — la chute rapide.
3. Calculer la **variance cumulée** $\frac{\sum_{m \leq M} \lambda_m}{\text{tr } S}$.
4. Choisir M pour un seuil (90 %, 95 %...).
5. **Contrôle** : la variance perdue est **exactement** l'erreur de reconstruction.

Méthode C — Dériver l'ACP par la variance maximale.

1. Écrire $V_1 = b_1^\top S b_1$ en développant $\frac{1}{N} \sum (b_1^\top x_n)^2$.
2. **Imposer** $\|b_1\|^2 = 1$, sinon le problème est **non borné**.
3. Lagrangien $\mathcal{L} = b_1^\top S b_1 + \lambda_1(1 - b_1^\top b_1)$.
4. Annuler les deux dérivées partielles.
5. Reconnaître l'**équation aux valeurs propres**.
6. Conclure $V_1 = \lambda_1$: **prendre la plus grande**.

Méthode D — Dériver l'ACP par la projection.

1. Décomposer x sur une ONB complète : partie **retenue** + partie **abandonnée**.
2. Dériver J_M par rapport à z_{in} ; annuler $\Rightarrow z_{in} = b_i^\top x_n$.
3. Réinjecter : $\tilde{x}_n = B B^\top x_n$, donc $x_n - \tilde{x}_n = (\sum_{j > M} b_j b_j^\top) x_n$.
4. Développer J_M en exploitant l'**orthonormalité**.
5. Échanger les sommes pour faire apparaître S .
6. Utiliser la **trace** et son invariance cyclique.
7. Conclure : **même problème** que la variance maximale.

Méthode E — PPCA.

1. Écrire le processus génératif.
2. **Marginaliser** z pour la vraisemblance ; utiliser $\mathbb{E}[Ax + b] = A\mu + b$ et $\mathbb{V}[Ax] = A\Sigma A^\top$.
3. Calculer la **covariance croisée** $\text{Cov}[x, z] = B$.
4. Assembler la **jointe en blocs**.
5. **Conditionner** (§6.5.1) pour $p(z \mid x)$.
6. **Contrôle** : C ne dépend pas de x .

● Common mistakes

Erreur	Correction
Oublier de centrer les données	$S = \frac{1}{N} \sum x_n x_n^T$ n'est la covariance que si la moyenne est 0
Croire que le centrage change la solution	NON : $\mathbb{V}[B^T(x - \mu)] = \mathbb{V}[B^T x]$ — c'est sans perte de généralité
Ranger les x_n en lignes de X	Dans ce chapitre , X est $D \times N$ — les points sont des COLONNES
Maximiser $b^T S b$ sans contrainte	Le problème serait NON BORNÉ : doubler b quadruple l'objectif
Prendre le plus PETIT vecteur propre	On veut la variance MAXIMALE , donc la plus GRANDE valeur propre
Croire que $\hat{S}$ a d'autres vecteurs propres que S	Les mêmes — seules les valeurs propres des CP déjà extraites passent à 0
Croire que les deux perspectives donnent des résultats différents	La MÊME solution : minimiser l'erreur $\equiv$ maximiser la variance
Confondre variance retenue et erreur	Retenue = $\sum_{m \leq M} \lambda_m$; erreur = $\sum_{j > M} \lambda_j$; somme = $\text{tr } S$
Croire que $BB^T = I$	NON : $B^T B = I_M$ (colonnes orthonormées), mais BB^T est une projection de rang M, singulière
Croire que le vecteur d'erreur est arbitraire	Il vit ENTIÈREMENT dans le complément orthogonal
Rendre l'ACP $\tilde{x}$ au lieu de z	*« L'ACP renvoie les COORDONNÉES z_* , pas les projections »*
Confondre λ_i et σ_i	$\lambda_i = \sigma_i^2$ — les valeurs propres sont les CARRÉS des valeurs singulières
Chercher les valeurs propres par le polynôme caractéristique	Impossible au-delà de 4×4 — théorème d'ABEL-RUFFINI
Calculer la décomposition complète pour M petit	Gaspillage : préférer les méthodes itératives
Démarrer l'itération de la puissance dans le noyau de S	Le livre l'exige explicitement : x_0 hors du noyau
Oublier de normaliser à chaque itération de la puissance	La suite diverge ou s'effondre sans normalisation

Erreur	Correction
Diagonaliser $\mathbf{X}\mathbf{X}^\top$ quand $N \ll D$	Diagonaliser $\mathbf{X}^\top \mathbf{X}$ ($N \times N$) : mêmes valeurs propres non nulles
Standardiser un point de test avec ses propres statistiques	Utiliser la moyenne et l'écart-type d'ENTRAÎNEMENT
Oublier de dé-standardiser	$\mathbf{B}\mathbf{B}^\top \mathbf{x}_*$ vit dans l'espace STANDARDISÉ
Utiliser $p(\mathbf{x} \mathbf{z})$ pour le maximum de vraisemblance	Elle dépend encore de $\mathbf{z}$ — il faut marginaliser
Écrire $\mathbb{V}[\mathbf{x}] = \mathbf{B}^\top \mathbf{B} + \sigma^2 \mathbf{I}$	C'est $\mathbf{B}\mathbf{B}^\top + \sigma^2 \mathbf{I}$ — une matrice $D \times D$
Croire que $\mathbf{C}$ dépend de l'observation	« La covariance a posteriori NE DÉPEND PAS des données observées $\mathbf{x}$ »
Croire que la PPCA remplace l'ACP	L'ACP classique est le CAS PARTICULIER sans bruit de la PPCA

Ultimate Review

===== LES SEPT FORMULES À SAVOIR SANS HÉSITER =====

1. $\mathbf{S} = (1/N) \sum \mathbf{x}_n \mathbf{x}_n^\top = (1/N) \mathbf{X} \mathbf{X}^\top$ ⚠ données CENTRÉES, $\mathbf{X}$ est $D \times N$
2. CODE $\mathbf{z} = \mathbf{B}^\top \mathbf{x}$ RECONSTRUCTION $\tilde{\mathbf{x}} = \mathbf{B} \mathbf{B}^\top \mathbf{x}$
3. $\mathbf{S} \mathbf{b}_m = \lambda_m \mathbf{b}_m$ et $\mathbf{V}_m = \mathbf{b}_m^\top \mathbf{S} \mathbf{b}_m = \lambda_m$
4. VARIANCE RETENUE $= \lambda_1 + \dots + \lambda_M$
ERREUR $J_M = \sum_{j=M+1..D} \lambda_j$ ⚠ somme + retenue $= \text{tr}(\mathbf{S})$
5. COORDONNÉES OPTIMALES $\mathbf{z}_{in} = \mathbf{b}_i^\top \mathbf{x}_n$ ← projection ORTHOGONALE
 $\mathbf{x}_n - \tilde{\mathbf{x}}_n = (\sum_{j>M} \mathbf{b}_j \mathbf{b}_j^\top) \mathbf{x}_n$ ← COMPLÉMENT ORTHOGONAL
6. SVD $\mathbf{X} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^\top \rightarrow \lambda_i = \sigma_i^2$ et $\mathbf{B} = \mathbf{U}_M$
GRANDE DIM. diagonaliser $(1/N) \mathbf{X}^\top \mathbf{X} \in \mathbb{R}^{(N \times N)}$, $\mathbf{c}_m = \mathbf{X}^\top \mathbf{b}_m$
PUISSANCE $\mathbf{x}_{k+1} = \mathbf{S} \mathbf{x}_k / \|\mathbf{S} \mathbf{x}_k\|$
7. PPCA $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, $\mathbf{x} = \mathbf{B}\mathbf{z} + \boldsymbol{\mu} + \boldsymbol{\varepsilon}$
 $p(\mathbf{x}) = \mathcal{N}(\boldsymbol{\mu}, \mathbf{B}\mathbf{B}^\top + \sigma^2 \mathbf{I})$
 $p(\mathbf{z} | \mathbf{x}) = \mathcal{N}(\mathbf{B}^\top (\mathbf{B}\mathbf{B}^\top + \sigma^2 \mathbf{I})^{-1} (\mathbf{x} - \boldsymbol{\mu}), \mathbf{I} - \mathbf{B}^\top (\mathbf{B}\mathbf{B}^\top + \sigma^2 \mathbf{I})^{-1} \mathbf{B})$

LES DEUX PERSPECTIVES — même point d'arrivée :

	VARIANCE MAXIMALE (§10.2)	PROJECTION (§10.3)
Objectif	$\max b^\top S b$ s.c. $\ b\ = 1$	$\min \frac{1}{N} \sum_n \ x_n - \tilde{x}_n\ ^2$
Outil	Multiplicateurs de Lagrange (ch. 7)	Dérivation puis trace (ch. 5, 4)
Ce qu'on retient	$\sum_{m \leq M} \lambda_m$	—
Ce qu'on perd	—	$\sum_{j > M} \lambda_j$
Interprétation	Conserver l'information	Auto-encodeur linéaire optimal
Solution	LES MÊMES M vecteurs propres dominants de S	IDEM

Ce que chaque chapitre antérieur apporte ici :

Chapitre	Ce qu'il fournit
2 — base, changement de base	Le code comme coordonnées dans une nouvelle base
3 — projections	$\tilde{x} = BB^\top x$, le complément orthogonal , l'ONB
4 — valeurs propres, SVD	La solution elle-même · $\lambda_i = \sigma_i^2$ · Eckart-Young · trace = $\sum \lambda_i$
6 — gaussiennes	La PPCA , le conditionnement, les transformations affines
7 — optimisation sous contraintes	Le lagrangien de la variance maximale
8 — variables latentes	Le cadre de la PPCA et de l'algorithme EM

Les trois lectures d'une valeur propre λ_m :

Lecture	Énoncé
Variance	La variance des données projetées sur b_m
Erreur	Si b_m est abandonné , sa contribution exacte à l'erreur de reconstruction
Singulière	$\lambda_m = \sigma_m^2$, le carré de la m -ième valeur singulière de X

Active Recall

Cadre

1. Écrire la matrice de covariance. Quelle hypothèse sur les données ?
2. Écrire le code et la reconstruction. Dans quels espaces vivent-ils ?
3. Quelle condition sur les colonnes de $\mathbf{B}$?
4. Pourquoi $\tilde{\mathbf{x}}_n$ a-t-il D composantes mais une seule coordonnée pour $\mathbf{M} = 1$?
5. Quelle convention de notation ce chapitre adopte-t-il pour $\mathbf{X}$? Pourquoi ?

Variance maximale 6. Pourquoi la variance mesure-t-elle l'information ? 7. Montrer que le centrage est sans perte de généralité. 8. Dériver $\mathbf{V}_1 = \mathbf{b}_1^\top \mathbf{S} \mathbf{b}_1$. 9. Pourquoi faut-il la contrainte $\|\mathbf{b}_1\|^2 = 1$? 10. Écrire le lagrangien et ses deux dérivées partielles. 11. Que révèle l'annulation ? Quel est le rôle de λ_1 ? 12. Que vaut $\mathbf{V}_1$? Quelle est la conclusion ? 13. Qu'est-ce que le chargement ? 14. Comment obtient-on la m -ième composante ? Qu'est-ce que $\hat{\mathbf{X}}$? 15. Que valent $\mathbf{B}_{m-1} \mathbf{b}_i$ dans les deux cas ? 16. Quelle est la relation entre les vecteurs propres de $\mathbf{S}$ et $\hat{\mathbf{S}}$? 17. Que vaut la variance retenue par M composantes ?

Projection 18. Écrire l'erreur de reconstruction. Quelle est la stratégie en deux temps ? 19. Dériver les coordonnées optimales. Quelle interprétation géométrique ? 20. Où vit le vecteur $\mathbf{x}_n - \tilde{\mathbf{x}}_n$? 21. Quelles sont les propriétés de $\mathbf{B} \mathbf{B}^\top$? 22. Quel lien avec l'approximation de rang faible de $\mathbf{I}$? 23. Reformuler $\mathbf{J}_M$ avec la trace. 24. Énoncer l'équivalence des deux perspectives. 25. Écrire l'équation (10.62).

Calcul 26. Quelles sont les deux voies de calcul ? Quel est le lien $\lambda_i - \sigma_i$? 27. Énoncer Eckart-Young appliqué à l'ACP. 28. Pourquoi ne peut-on pas passer par le polynôme caractéristique ? 29. Décrire l'itération de la puissance. Quelle condition sur $\mathbf{x}_0$? 30. Décrire l'astuce de la grande dimension. Quel gain ?

Pratique et PPCA 31. Citer les cinq étapes de l'ACP en pratique. 32. Que renvoie l'ACP exactement ? 33. Comment standardiser un point de test ? 34. Citer cinq des neuf raisons d'une ACP probabiliste. 35. Écrire le processus génératif de la PPCA. 36. Qu'est-ce que l'échantillonnage ancestral ? 37. Dériver la vraisemblance de la PPCA. 38. Pourquoi ne peut-on pas utiliser $p(\mathbf{x} | \mathbf{z})$? 39. Écrire la loi jointe en blocs. Que vaut $\text{Cov}[\mathbf{x}, \mathbf{z}]$? 40. Écrire l'a posteriori latente. Quelle particularité de $\mathbf{C}$?

Flashcards

Question	Réponse
Autre nom de l'ACP en traitement du signal ?	La transformée de KARHUNEN-LOÈVE
Matrice de covariance des données ?	$S = \frac{1}{N} \sum_n x_n x_n^\top = \frac{1}{N} X X^\top$ — données CENTRÉES
Le code ?	$z_n = B^\top x_n \in \mathbb{R}^M$
La reconstruction ?	$\tilde{x}_n = B B^\top x_n \in \mathbb{R}^D$
Condition sur B ?	Colonnes ORTHONORMÉES : $B^\top B = I_M$
Que renvoie l'ACP ?	Les COORDONNÉES z , PAS les projections $\tilde{x}$
Convention sur X dans ce chapitre ?	$X \in \mathbb{R}^{D \times N}$ — les points sont les COLONNES
Pourquoi ?	Les opérations algébriques se déroulent sans transposer
Pourquoi la variance mesure-t-elle l'information ?	Elle mesure l' ÉTALEMENT — le caractère « remplissant l'espace »
Le centrage change-t-il la solution ?	NON : $\mathbb{V}[B^\top (x - \mu)] = \mathbb{V}[B^\top x]$
V_1 en fonction de S ?	$V_1 = b_1^\top S b_1$
Pourquoi la contrainte $\ b_1\ = 1$?	Sinon non borné : un b deux fois plus long quadruple V_1
Le lagrangien ?	$\mathcal{L} = b_1^\top S b_1 + \lambda_1 (1 - b_1^\top b_1)$
Ce que donne l'annulation ?	$S b_1 = \lambda_1 b_1$ — une équation aux valeurs propres
Le rôle du multiplicateur λ_1 ?	Il EST la VALEUR PROPRE
Que vaut V_1 ?	λ_1 — la variance EST la valeur propre
Quelle valeur propre choisir ?	LA PLUS GRANDE

Question	Réponse
Première composante principale ?	Le vecteur propre de $\mathcal{S}$ associé à $\lambda_{\max}$
Le chargement (<i>loading</i>) ?	$\sqrt{\lambda_1}$ — l'ÉCART-TYPE pris en compte par le sous-espace
Comment trouver la m -ième CP ?	En SOUSTRAYANT l'effet des $m - 1$ premières : $\hat{X} = X - B_{m-1}X$
Que contient $\hat{X}$?	L'information PAS ENCORE compressée
$B_{m-1}b_i$ pour $i < m$?	$= b_i$
$B_{m-1}b_i$ pour $i \geq m$?	$= 0$
Vecteurs propres de $\mathcal{S}$ et $\hat{\mathcal{S}}$?	IDENTIQUES ; mais ceux du sous-espace principal ont valeur propre 0 pour $\hat{\mathcal{S}}$
Que vaut V_m ?	λ_m
Variance retenue par M composantes ?	$\sum_{m=1}^M \lambda_m$
L'erreur de reconstruction ?	$J_M = \frac{1}{N} \sum_n \ x_n - \tilde{x}_n\ ^2$
Son autre nom ?	L' auto-encodeur linéaire optimal (Pearson, 1901)
Les coordonnées optimales ?	$z_{in} = b_i^\top x_n$ — la PROJECTION ORTHOGONALE
Où vit $x_n - \tilde{x}_n$?	ENTIÈREMENT dans le COMPLÉMENT ORTHOGONAL
Sa formule ?	$(\sum_{j=M+1}^D b_j b_j^\top) x_n$
Les trois propriétés de $BB^\top$?	Symétrique · idempotente · de RANG M
Sa trace ?	M
Le lien avec l'approximation de rang faible ?	Trouver $B \equiv$ trouver la meilleure approximation de rang M de l'IDENTITÉ
J_M avec la trace ?	$\text{tr}((\sum_{j>M} b_j b_j^\top) \mathcal{S})$
L'équivalence des deux perspectives ?	Minimiser l'erreur $\equiv$ maximiser la variance retenue

Question	Réponse
L'équation (10.62) ?	$J_M = \sum_{i=M+1}^D \lambda_i$ — la somme des vp ABANDONNÉES
Le contrôle de cohérence ?	Variance retenue + erreur = $\text{tr}(S)$
Les deux voies de calcul ?	Eigendécomposition de S · SVD de X
Le lien λ - σ ?	$\lambda_i = \sigma_i^2$
Eckart-Young appliqué ?	La meilleure approximation de rang M est la SVD TRONQUÉE $U_M \Sigma_M V_M^T$
Pourquoi pas le polynôme caractéristique ?	ABEL-RUFFINI : pas de solution algébrique au-delà du degré 4
L'itération de la puissance ?	$x_{k+1} = \frac{Sx_k}{\ Sx_k\ }$
Vers quoi converge-t-elle ?	Le vecteur propre de plus grande valeur propre
La condition sur x_0 ?	Hors du NOYAU de S
Le problème en grande dimension ?	Le coût est CUBIQUE en D
L'astuce quand $N \ll D$?	Diagonaliser $\frac{1}{N} X^T X \in \mathbb{R}^{N \times N}$
Pourquoi ça marche ?	MÊMES valeurs propres NON NULLES que S
Comment retrouver b_m ?	Via $c_m = X^T b_m$, en remultipliant par X et en normalisant
Les cinq étapes en pratique ?	1. centrer 2. standardiser 3. eigendécomposition 4. projeter 5. dé-standardiser
Le centrage est-il indispensable ?	Pas strictement, mais il réduit le risque de problèmes NUMÉRIQUES
Qu'apporte la standardisation ?	Données SANS UNITÉ , de variance 1 sur chaque axe
Standardiser un point de test ?	Avec la moyenne et l'écart-type d'ENTRAÎNEMENT
MNIST : combien de dimensions ?	$28 \times 28 = 784$ pixels, donc $x \in \mathbb{R}^{784}$
Reconstruction avec 1 CP ?	« À moitié décente, mais FLOUE et GÉNÉRIQUE »

Question	Réponse
Avec 784 CP ?	Le chiffre EXACT, sans aucune perte
Neuf raisons de la PPCA ?	Vraisemblance · comparaison bayésienne · modèle GÉNÉRATIF · connexions · données manquantes · nouveauté · extensions · ACP comme cas particulier · traitement pleinement bayésien
Qui a proposé la PPCA ?	Tipping et Bishop (1999)
L'a priori latente ?	$z \sim \mathcal{N}(0, I)$
Le lien latent-observé ?	$x = Bz + \mu + \epsilon$ avec $\epsilon \sim \mathcal{N}(0, \sigma^2 I)$
L'échantillonnage ancestral ?	Échantillonner z_n D'ABORD , puis x_n conditionné sur z_n
La vraisemblance de la PPCA ?	$p(x) = \mathcal{N}(x \mid \mu, BB^\top + \sigma^2 I)$
Sa moyenne ?	μ
Sa covariance ?	$BB^\top + \sigma^2 I$
Pourquoi pas $p(x \mid z)$ pour le MLE ?	Elle dépend encore des variables LATENTES
$\text{Cov}[x, z]$?	B
La loi jointe ?	$\mathcal{N}\left(\begin{bmatrix} \mu \\ 0 \end{bmatrix}, \begin{bmatrix} BB^\top + \sigma^2 I & B \\ B^\top & I \end{bmatrix}\right)$
Sa taille ?	Moyenne de longueur $D + M$, covariance $(D + M) \times (D + M)$
L'a posteriori latente ?	$p(z \mid x) = \mathcal{N}(m, C)$
m ?	$B^\top (BB^\top + \sigma^2 I)^{-1} (x - \mu)$
C ?	$I - B^\top (BB^\top + \sigma^2 I)^{-1} B$
La particularité de C ?	Elle NE DÉPEND PAS des données observées x
À quoi sert C ?	Évaluer la CONFIANCE dans l'encodage
L'ACP classique dans ce cadre ?	Le cas particulier du maximum de vraisemblance SANS BRUIT