

Fiche 410 — Estimation de densité par mélanges gaussiens : responsabilités et algorithme EM

Matière	Maths · Apprentissage automatique
Cours source	Deisenroth, Faisal & Ong, <i>Mathematics for Machine Learning</i> , Cambridge University Press — chapitre 11 « Density Estimation with Gaussian Mixture Models » (p. 348-370)
Difficulté	Avancé — le troisième pilier , et le premier où aucune solution fermée n'existe
Temps d'étude estimé	130 min
Prérequis	Fiche 405 (gaussiennes, Bayes) · Fiche 406 (multiplicateurs de Lagrange) · Fiche 407 (MLE, variables latentes)
Concepts clés	Estimation de densité, modèle de mélange, combinaison convexe, poids de mélange, mélange gaussien (GMM), multimodalité, log-vraisemblance non factorisable, responsabilité, affectation douce, responsabilité totale N_k , mise à jour des moyennes, des covariances, des poids, algorithme espérance-maximisation, étape E, étape M, monotonie, variable indicatrice binaire, encodage one-hot, représentation 1-parmi- K , multinoulli, marginalisation des latentes, a posteriori latente
Poids à l'examen	$p(x \theta) = \sum_k \pi_k \mathcal{N}(x \mu_k, \Sigma_k)$ avec $\sum_k \pi_k = 1$ · la responsabilité r_{nk} · les trois mises à jour μ_k , Σ_k , π_k · le cycle E-step / M-step · la responsabilité EST l'a posteriori $p(z_k = 1 x)$.

Vue d'ensemble

LE FIL DU CHAPITRE : quand une SEULE gaussienne ne suffit plus

§11.1 MODÈLE DE MÉLANGE $p(x) = \sum_k \pi_k p_k(x)$, $0 \leq \pi_k \leq 1$, $\sum_k \pi_k = 1$

⚠ COMBINAISON CONVEXE de lois de base → permet la MULTIMODALITÉ

GMM : $p(x | \theta) = \sum_k \pi_k \mathcal{N}(x | \mu_k, \Sigma_k)$ $\theta = \{\pi_k, \mu_k, \Sigma_k\}$

§11.2 APPRENTISSAGE PAR MAXIMUM DE VRAISEMBLANCE

$L = \sum_n \log (\sum_k \pi_k \mathcal{N}(x_n | \mu_k, \Sigma_k))$

⚠ le LOG NE PEUT PAS ENTRER dans la somme → PAS de solution fermée

RESPONSABILITÉ $r_{nk} = \pi_k \mathcal{N}(x_n | \mu_k, \Sigma_k) / \sum_j \pi_j \mathcal{N}(x_n | \mu_j, \Sigma_j)$

⚠ vecteur de PROBABILITÉ : $\sum_k r_{nk} = 1$ → AFFECTATION DOUCE

$N_k := \sum_n r_{nk}$ = responsabilité TOTALE de la composante k

MISE À JOUR DES MOYENNES $\mu_k = (1/N_k) \sum_n r_{nk} x_n$
 MISE À JOUR DES COVARIANCES $\Sigma_k = (1/N_k) \sum_n r_{nk} (x_n - \mu_k)(x_n - \mu_k)^T$
 MISE À JOUR DES POIDS $\pi_k = N_k / N$ ← via LAGRANGE
 ⚠ les trois dépendent des r_{nk} , qui dépendent des trois → ITÉRER

§11.3 ALGORITHME EM (Dempster et al., 1977)

1. INITIALISER μ_k, Σ_k, π_k
2. ÉTAPE E : évaluer les r_{nk} avec les paramètres COURANTS
3. ÉTAPE M : réestimer μ_k, Σ_k, π_k avec les r_{nk} COURANTES
4. répéter jusqu'à convergence

⚠ CHAQUE étape AUGMENTE la log-vraisemblance (Neal & Hinton, 1999)

§11.4 PERSPECTIVE VARIABLE LATENTE – latente DISCRÈTE (contraste avec l'ACP)

$z \in \{0,1\}^K$, ONE-HOT, $p(z_k = 1) = \pi_k$, $p(x | z_k = 1) = N(x | \mu_k, \Sigma_k)$
 VRAISEMBLANCE $p(x|\theta) = \sum_z p(x|\theta, z) p(z|\theta) = \sum_k \pi_k N(x|\mu_k, \Sigma_k)$ ← LE MÊME MODÈLE
 A POSTERIORI $p(z_k = 1 | x) = \pi_k N(x|\mu_k, \Sigma_k) / \sum_j \pi_j N(x|\mu_j, \Sigma_j)$
 ⚠ ⚠ C'EST EXACTEMENT LA RESPONSABILITÉ

LA LEÇON CENTRALE La RESPONSABILITÉ n'est pas une astuce de calcul :
 c'est la LOI A POSTERIORI de la variable latente.

La motivation. « En estimation de densité, on représente les données **de façon COMPACTE** par une densité d'une famille paramétrique. » Mais « la gaussienne (comme toutes les lois rencontrées jusqu'ici) a des **capacités de modélisation LIMITÉES** : une approximation gaussienne de la densité qui a généré les données de la figure 11.1 serait une **MAUVAISE approximation**. »

● Concept 1 — Le modèle de mélange (§11.1)

$$p(x) = \sum_{k=1}^K \pi_k p_k(x), \quad 0 \leq \pi_k \leq 1, \quad \sum_{k=1}^K \pi_k = 1$$

« Une **COMBINAISON CONVEXE** de K lois simples (de base). » Les p_k appartiennent à une famille de base (gaussiennes, Bernoulli, gamma...) et les π_k sont les **POIDS DE MÉLANGE**.

LA raison d'être. *« Les modèles de mélange sont **PLUS EXPRESSIFS** que les lois de base correspondantes, car ils permettent des représentations **MULTIMODALES** : ils peuvent décrire des jeux de données à **plusieurs "CLUSTERS"**. »*

Le mélange gaussien (GMM) :

$$p(x | \theta) = \sum_{k=1}^K \pi_k \mathcal{N}(x | \mu_k, \Sigma_k), \quad \theta := \{\pi_k, \mu_k, \Sigma_k : k = 1, \dots, K\}$$

L'exemple de la figure 11.2 — un mélange à trois composantes :

$$p(x | \theta) = 0,5 \mathcal{N}(x | -2, \frac{1}{2}) + 0,2 \mathcal{N}(x | 1, 2) + 0,3 \mathcal{N}(x | 4, 1)$$

Intégration numérique sur $[-30, 40]$ avec 400 000 points (règle du point milieu) :

$$\int p(x) dx = 1,00000000$$

$$\mathbb{E}[x]_{\text{numérique}} = 0,400000 \quad \text{formule : } 0,5(-2) + 0,2(1) + 0,3(4) = 0,4$$

Un mélange de **densités** est bien une densité — mais **la moyenne n'est PAS un mode** : ici 0,4 tombe dans un **creux** entre les composantes.

● Concept 2 — Pourquoi il n'y a pas de solution fermée (§11.2)

La vraisemblance factorisée (hypothèse i.i.d.) :

$$p(\mathcal{X} | \theta) = \prod_{n=1}^N p(x_n | \theta), \quad p(x_n | \theta) = \sum_{k=1}^K \pi_k \mathcal{N}(x_n | \mu_k, \Sigma_k)$$

La log-vraisemblance :

$$\mathcal{L} = \log p(\mathcal{X} | \theta) = \sum_{n=1}^N \log \left(\underbrace{\sum_{k=1}^K \pi_k \mathcal{N}(x_n | \mu_k, \Sigma_k)}_{\text{une SOMME sous le LOG}} \right)$$

LE BLOCAGE, expliqué par le livre. « Notre procédure "**NORMALE**" serait de calculer le gradient $d\mathcal{L}/d\theta$, l'annuler et résoudre. Mais contrairement aux exemples précédents (la régression linéaire du §9.2), **on ne peut PAS obtenir de solution en FORME FERMÉE.** »

La comparaison qui éclaire tout. « Si l'on considérait une **SEULE gaussienne**, la somme sur k **DISPARAÎT** et le log peut s'appliquer **DIRECTEMENT** à la composante gaussienne » :

$$\log \mathcal{N}(x \mid \mu, \Sigma) = -\frac{D}{2} \log(2\pi) - \frac{1}{2} \log \det \Sigma - \frac{1}{2} (x - \mu)^\top \Sigma^{-1} (x - \mu)$$

Tout est alors quadratique et se résout d'un coup. C'est la somme sur k à l'intérieur du log qui casse cette possibilité.

La parade. « On peut exploiter un **SCHÉMA ITÉRATIF...** L'**IDÉE CLÉ** est de mettre à jour **UN paramètre à la fois en GARDANT les autres FIXÉS.** »

L'exemple courant du chapitre (figure 11.3) :

$$\mathcal{X} = \{-3, -2, 5, -1, 0, 2, 4, 5\} \quad (N = 7, K = 3)$$

$$p_1 = \mathcal{N}(x \mid -4, 1), \quad p_2 = \mathcal{N}(x \mid 0, 0,2), \quad p_3 = \mathcal{N}(x \mid 8, 3), \quad \pi_1 = \pi_2 = \pi_3 = \frac{1}{3}$$

● Concept 3 — Les responsabilités (§11.2.1)

$$r_{nk} := \frac{\pi_k \mathcal{N}(x_n \mid \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(x_n \mid \mu_j, \Sigma_j)}$$

La définition. « La **RESPONSABILITÉ** de la k -ième composante pour le n -ième point. Elle est **PROPORTIONNELLE À LA VRAISEMBLANCE** $\pi_k \mathcal{N}(x_n \mid \mu_k, \Sigma_k)$ de la composante étant donné le point. Les composantes ont donc une **haute responsabilité** pour un point quand celui-ci **pourrait être un échantillon PLAUSIBLE** de cette composante. »

Les trois propriétés :

Propriété	Énoncé
Vecteur de probabilité	$\mathbf{r}_n := [r_{n1}, \dots, r_{nK}]^T \in \mathbb{R}^K$ avec $\sum_k r_{nk} = 1$ et $r_{nk} \geq 0$
Affectation douce	« Ce vecteur DISTRIBUE la masse de probabilité parmi les K composantes : on peut penser à $\mathbf{r}_n$ comme à une " AFFECTATION DOUCE " (<i>soft assignment</i>) de $\mathbf{x}_n$ »
Interprétation probabiliste	« r_{nk} représente la PROBABILITÉ que $\mathbf{x}_n$ ait été GÉNÉRÉ par la k-ième composante »

La responsabilité totale :

$$N_k := \sum_{n=1}^N r_{nk} \quad \text{avec} \quad \sum_{k=1}^K N_k = N$$

Exemple 11.2 — la matrice des responsabilités. Pour le jeu courant, $\mathbf{R} \in \mathbb{R}^{7 \times 3}$:

$$\mathbf{R} = \begin{bmatrix} 1,0 & 0,0 & 0,0 \\ 1,0 & 0,0 & 0,0 \\ 0,057 & 0,943 & 0,0 \\ 0,001 & 0,999 & 0,0 \\ 0,0 & 0,066 & 0,934 \\ 0,0 & 0,0 & 1,0 \\ 0,0 & 0,0 & 1,0 \end{bmatrix}$$

La lecture, ligne et colonne :

Lecture	Ce qu'elle donne
Une LIGNE n	Les responsabilités de toutes les composantes pour $\mathbf{x}_n$; elle somme à 1
Une COLONNE k	Un aperçu de la responsabilité de la composante k sur tout le jeu
Somme d'une colonne	N_k , la responsabilité totale

« On voit que la **troisième composante n'est responsable d'AUCUN des quatre premiers points**, mais prend **beaucoup** de responsabilité des points restants. »

Recalcul à pleine précision depuis les paramètres initiaux :

x_n	r_{n1}	r_{n2}	r_{n3}	somme
-3,0	0,9999999977	≈ 0	≈ 0	1,0
-2,5	0,9999988536	≈ 0	≈ 0	1,0
-1,0	0,0570694724	0,9429	≈ 0	1,0
0,0	0,0001500000	0,9999	≈ 0	1,0
2,0	0,0000099371	0,0662	0,9338	1,0
4,0	≈ 0	≈ 0	1,0	1,0
5,0	≈ 0	≈ 0	1,0	1,0

La matrice est reproduite à l'identique aux arrondis du livre près.

Une divergence de troisième décimale sur N_k . Calcul exact : $N_1 = 2,057228$, $N_2 = 2,009008$, $N_3 = 2,933763$. Le livre imprime $N_1 = 2,058$, $N_2 = 2,008$, $N_3 = 2,934$. Noter que **la somme de la première colonne de la matrice IMPRIMÉE par le livre** vaut $1,0 + 1,0 + 0,057 = 2,057$ — donc le **2,058** annoncé **ne concorde ni avec la matrice du livre ni avec le calcul exact**. Les deux jeux somment bien à $7 = N$ et **toutes les mises à jour en aval concordent**, donc c'est sans conséquence.

● Concept 4 — Les trois mises à jour (§11.2.2-11.2.4)

4.1 Les moyennes — Théorème 11.1

$$\mu_k^{\text{nouveau}} = \frac{\sum_{n=1}^N r_{nk} x_n}{\sum_{n=1}^N r_{nk}} = \frac{1}{N_k} \sum_{n=1}^N r_{nk} x_n$$

Le pas clé de la preuve — seule la k -ième composante dépend de μ_k :

$$\frac{\partial p(x_n | \theta)}{\partial \mu_k} = \pi_k \frac{\partial \mathcal{N}(x_n | \mu_k, \Sigma_k)}{\partial \mu_k} = \pi_k (x_n - \mu_k)^\top \Sigma_k^{-1} \mathcal{N}(x_n | \mu_k, \Sigma_k)$$

LES TROIS INTERPRÉTATIONS, données par le livre.

1. **Estimateur de Monte-Carlo pondéré par importance** : « les poids d'importance du point x_n sont les **responsabilités** r_{nk} ».
2. **Attraction** : *« La moyenne μ_k est **TIRÉE VERS** un point x_n avec une **FORCE** donnée par r_{nk} . Les moyennes sont tirées **plus fortement** vers les points pour lesquels la composante a une **haute responsabilité**. »*
3. **Espérance sous une loi induite** : avec $r_k := [r_{1k}, \dots, r_{Nk}]^\top / N_k$, un vecteur de probabilité normalisé,

$$\mu_k \leftarrow \mathbb{E}_{r_k}[\mathcal{X}]$$

La remarque qui explique tout le chapitre. « La mise à jour des μ_k **dépend de TOUTES les moyennes, covariances et poids** via r_{nk} . On **NE PEUT DONC PAS** obtenir de solution fermée pour tous les μ_k **d'un coup**. »

Exemple 11.3 : $\mu_1 : -4 \rightarrow -2,7$; $\mu_2 : 0 \rightarrow -0,4$; $\mu_3 : 8 \rightarrow 3,7$. « Les moyennes de la première et de la troisième composante **se déplacent vers le régime des données**, alors que celle de la deuxième **ne change pas si dramatiquement**. »

4.2 Les covariances — Théorème 11.2

$$\Sigma_k^{\text{nouveau}} = \frac{1}{N_k} \sum_{n=1}^N r_{nk} (x_n - \mu_k)(x_n - \mu_k)^\top$$

L'interprétation parallèle. « Comme pour μ_k , on peut interpréter cette mise à jour comme une **espérance PONDÉRÉE PAR IMPORTANCE du CARRÉ des données CENTRÉES**

$\tilde{\mathcal{X}}_k := \{x_1 - \mu_k, \dots, x_N - \mu_k\}$. »

Exemple 11.4 : $\sigma_1^2 : 1 \rightarrow 0,14$; $\sigma_2^2 : 0,2 \rightarrow 0,44$; $\sigma_3^2 : 3 \rightarrow 1,53$. « Les variances de la première et de la troisième composante **RÉTRÉCISSENT significativement**, alors que celle de la deuxième **AUGMENTE légèrement**. »

4.3 Les poids — Théorème 11.3

$$\pi_k^{\text{nouveau}} = \frac{N_k}{N}$$

Le seul endroit où Lagrange intervient. « Pour trouver la dérivée partielle par rapport aux π_k , on doit **tenir compte de la CONTRAINT** $\sum_k \pi_k = 1$ en utilisant les **MULTIPLICATEURS DE LAGRANGE** (§7.2) » :

$$\mathcal{L} = \mathcal{L} + \lambda \left(\sum_{k=1}^K \pi_k - 1 \right)$$

La formule est d'une simplicité remarquable : **la fraction de responsabilité totale.**

Exemple 11.5 : $\pi_1 : \frac{1}{3} \rightarrow 0,29$; $\pi_2 : \frac{1}{3} \rightarrow 0,29$; $\pi_3 : \frac{1}{3} \rightarrow 0,42$. « La troisième composante gagne **plus de poids/importance.** »

Paramètre	Calcul à pleine précision	Valeur du livre
μ	$[-2,7012 ; -0,4034 ; 3,7043]$	$[-2,7 ; -0,4 ; 3,7]$
σ^2	$[0,1440 ; 0,4385 ; 1,5266]$	$[0,14 ; 0,44 ; 1,53]$
π	$[0,2939 ; 0,2870 ; 0,4191]$	$[0,29 ; 0,29 ; 0,42]$

Les trois arrondissent EXACTEMENT aux valeurs annoncées, et $\sum_k \pi_k = 1,0$ à la précision machine. **L'ordre compte** : les variances de l'exemple 11.4 se calculent avec les **NOUVELLES** moyennes de l'exemple 11.3.

● Concept 5 — L'algorithme EM (§11.3)

Le diagnostic. « Les mises à jour **NE CONSTITUENT PAS une solution en forme fermée**, parce que les responsabilités r_{nk} **dépendent de ces paramètres de façon COMPLEXE**. Mais les résultats **SUGGÈRENT un schéma ITÉRATIF simple**. »

*L'algorithme d'**ESPÉRANCE-MAXIMISATION** a été proposé par **Dempster et al. (1977)** ; c'est « un schéma itératif GÉNÉRAL pour apprendre les paramètres (maximum de vraisemblance ou MAP) dans les modèles de mélange et, **plus généralement, les modèles à VARIABLES LATENTES** ».

L'algorithme pour un GMM :

Étape 1 — INITIALISER μ_k, Σ_k, π_k .

Étape 2 — ÉTAPE E. « Évaluer les responsabilités r_{nk} pour chaque point avec les paramètres COURANTS »
— c'est la **probabilité A POSTERIORI** que le point n appartienne à la composante k :

$$r_{nk} = \frac{\pi_k \mathcal{N}(x_n | \mu_k, \Sigma_k)}{\sum_j \pi_j \mathcal{N}(x_n | \mu_j, \Sigma_j)}$$

Étape 3 — ÉTAPE M. « Réestimer les paramètres avec les responsabilités COURANTES » :

$$\mu_k = \frac{1}{N_k} \sum_n r_{nk} x_n, \quad \Sigma_k = \frac{1}{N_k} \sum_n r_{nk} (x_n - \mu_k)(x_n - \mu_k)^\top, \quad \pi_k = \frac{N_k}{N}$$

Étape 4 — répéter jusqu'à convergence.

LA GARANTIE. « **CHAQUE** étape de l'algorithme EM **AUGMENTE** la fonction de **LOG-VRAISEMBLANCE** (Neal et Hinton, 1999). » « Pour la convergence, on peut vérifier **la log-vraisemblance** ou les paramètres directement. »

Exemple 11.6. « Après **CINQ itérations**, l'algorithme EM converge. »

Log-vraisemblance **négative** (plus bas est meilleur) par itération :

Itération	$-\mathcal{L}$	μ
0	28,3255	$[-4,000 ; 0,000 ; 8,000]$
1	14,4105	$[-2,701 ; -0,403 ; 3,704]$
2	13,9771	$[-2,750 ; -0,501 ; 3,655]$
3	13,9733	$[-2,750 ; -0,504 ; 3,647]$
4	13,9733	$[-2,750 ; -0,504 ; 3,645]$
5	13,9733	$[-2,750 ; -0,504 ; 3,645]$

La convergence en cinq itérations est confirmée — la log-vraisemblance est stable à quatre décimales dès l'itération 3, et les paramètres dès l'itération 4. Cohérent avec la figure 11.8(b).

Test de MONOTONIE : sur **30 itérations**, aucune violation de $\mathcal{L}^{(t+1)} \geq \mathcal{L}^{(t)}$ — la garantie de Neal et Hinton est vérifiée numériquement.

Noter aussi le **saut initial énorme** : la première itération fait chuter $-\mathcal{L}$ de **28,33** à **14,41**, soit **plus de la moitié du gain total** en une seule passe.

Le second exemple (figures 11.9-11.10) — un jeu bidimensionnel, 3 composantes, convergence en 62 itérations. *« Alors qu'une **SEULE** composante est clairement responsable des données de gauche, le **CHEVAUCHEMENT des deux clusters de droite** pourrait avoir été généré par **DEUX** composantes. Il devient clair qu'il y a des points **qui ne peuvent PAS être affectés de façon UNIQUE** à une seule composante — les responsabilités de ces deux clusters sont alors **autour de 0,5**. »*

● Concept 6 — La perspective variable latente (§11.4)

6.1 Le contraste avec l'ACP

La différence structurelle. *« On peut voir le GMM comme un modèle à variable latente **DISCRÈTE** — où z ne peut prendre qu'un **ensemble FINI de valeurs**. C'est en **CONTRASTE** avec l'ACP, où les variables latentes étaient des nombres **CONTINUS** dans $\mathbb{R}^M$. »*

6.2 Le processus génératif

L'hypothèse fondatrice. « Un point x peut être généré par **EXACTEMENT UNE** composante de mélange. »

On introduit une **variable indicatrice BINAIRE** $z_k \in \{0, 1\}$:

$$p(x \mid z_k = 1) = \mathcal{N}(x \mid \mu_k, \Sigma_k)$$

$$z := [z_1, \dots, z_K]^\top \in \mathbb{R}^K \text{ avec } K - 1 \text{ zéros et EXACTEMENT UN } 1$$

Par exemple pour $K = 3$, $z = [0, 1, 0]^\top$ sélectionne la **deuxième composante**. Comme $\sum_k z_k = 1$, z est un **ENCODAGE ONE-HOT** (aussi : **représentation 1-parmi- K**).

Le nom de cette loi. « Ce genre de loi est parfois appelé "**MULTINOULLI**", une généralisation de la Bernoulli à **plus de deux valeurs** » (Murphy, 2012).

L'a priori sur la latente :

$$p(z) = \pi = [\pi_1, \dots, \pi_K]^\top, \quad \sum_k \pi_k = 1, \quad \pi_k = p(z_k = 1)$$

« π_k décrit la **PROBABILITÉ** que la **k -ième composante ait généré** le point x . »

6.3 La vraisemblance — le modèle est le même

On **marginalise la latente** (§8.4.3) :

$$p(x | \theta) = \sum_z p(x | \theta, z) p(z | \theta)$$

Le pas de simplification. « Puisqu'il n'y a qu'**UNE SEULE entrée non nulle** dans chaque z , il n'y a que **K configurations possibles**. Sommer sur toutes les configurations **équivaut à regarder l'entrée non nulle** » :

$$p(x | \theta) = \sum_{k=1}^K p(x | \theta, z_k = 1) p(z_k = 1 | \theta)$$

$$p(x | \theta) = \sum_{k=1}^K \pi_k \mathcal{N}(x | \mu_k, \Sigma_k)$$

« qu'on **IDENTIFIE au modèle GMM** de (11.3). » Et sur tout le jeu :

$$p(\mathcal{X} | \theta) = \prod_{n=1}^N \sum_{k=1}^K \pi_k \mathcal{N}(x_n | \mu_k, \Sigma_k)$$

Le modèle à indicateurs latents est une façon ÉQUIVALENTE de penser un GMM.

6.4 L'a posteriori — LA révélation

Par le théorème de Bayes :

$$p(z_k = 1 | x) = \frac{p(z_k = 1) p(x | z_k = 1)}{\sum_{j=1}^K p(z_j = 1) p(x | z_j = 1)}$$

$$p(z_k = 1 | x) = \frac{\pi_k \mathcal{N}(x | \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(x | \mu_j, \Sigma_j)}$$

LE POINT CULMINANT DU CHAPITRE. « ...qu'on **IDENTIFIE** comme la **RESPONSABILITÉ** de la k -ième composante pour le point x . »

$$r_{nk} = p(z_{nk} = 1 \mid x_n)$$

La responsabilité **n'était donc pas une astuce de calcul** : c'est la **LOI A POSTERIORI** de la variable **latente**. C'est exactement pourquoi l'étape E s'appelle l'étape « **espérance** ».

6.5 Extension à tout le jeu de données

« Dans l'interprétation probabiliste, **chaque point x_n possède SA PROPRE variable latente**

$z_n = [z_{n1}, \dots, z_{nK}]^\top \in \mathbb{R}^K$. » « On **PARTAGE le même a priori π** entre toutes les variables latentes z_n » — d'où la **notation en PLAQUES** de la figure 11.12 : π hors de la plaque, z_n et x_n dedans, μ_k et Σ_k dans une plaque sur k .

$$p(x_1, \dots, x_N \mid z_1, \dots, z_N) = \prod_{n=1}^N p(x_n \mid z_n)$$

Comment reconnaître le type d'exercice

L'énoncé dit...	Le type	La méthode
« Une gaussienne ne suffit pas »	§11.1	Passer à un mélange : $\sum_k \pi_k p_k(x)$
« Vérifier que c'est une densité »	§11.1	$\pi_k \geq 0$ et $\sum_k \pi_k = 1$ — c'est une combinaison CONVEXE
« Écrire la log-vraisemblance »	§11.2	$\sum_n \log(\sum_k \pi_k \mathcal{N})$; le log ne rentre PAS
« Pourquoi pas de solution fermée ? »	§11.2	La somme sur k SOUS le log ; les r_{nk} dépendent de tous les paramètres
« Calculer les responsabilités »	§11.2.1	$r_{nk} = \frac{\pi_k \mathcal{N}(x_n \mu_k, \Sigma_k)}{\sum_j \pi_j \mathcal{N}(x_n \mu_j, \Sigma_j)}$; contrôle : chaque ligne somme à 1
« Que vaut N_k ? »	§11.2.1	La somme d'une COLONNE de R ; $\sum_k N_k = N$
« Mettre à jour les moyennes »	Th. 11.1	$\mu_k = \frac{1}{N_k} \sum_n r_{nk} x_n$
« Mettre à jour les covariances »	Th. 11.2	$\Sigma_k = \frac{1}{N_k} \sum_n r_{nk} (x_n - \mu_k)(x_n - \mu_k)^\top$; avec les NOUVELLES μ_k
« Mettre à jour les poids »	Th. 11.3	$\pi_k = N_k / N$; dérivé par LAGRANGE
« Décrire l'algorithme EM »	§11.3	Initialiser · E (responsabilités) · M (paramètres) · répéter
« L'algorithme converge-t-il ? »	§11.3	Chaque étape AUGMENTE la log-vraisemblance ; vers un optimum LOCAL
« Écrire le modèle latent »	§11.4.1	z one-hot , $p(z_k = 1) = \pi_k$, $p(x z_k = 1) = \mathcal{N}(\mu_k, \Sigma_k)$
« Retrouver le GMM depuis le modèle latent »	§11.4.2	Marginaliser z : la somme sur les K configurations donne le mélange
« Que vaut $p(z_k = 1 x)$? »	§11.4.3	EXACTEMENT la responsabilité r_{nk}
« Dessiner le modèle graphique »	§11.4.4	$\pi \rightarrow z_n \rightarrow x_n$; plaque sur n ; μ_k, Σ_k dans une plaque sur k

Comment résoudre : les quatre méthodes pas-à-pas

Méthode A — Un tour complet d'EM à la main.

1. Écrire les paramètres courants $\{\pi_k, \mu_k, \Sigma_k\}$.
2. **Étape E** : pour chaque n et k , calculer $\pi_k \mathcal{N}(x_n | \mu_k, \Sigma_k)$.
3. **Normaliser chaque ligne** pour obtenir r_{nk} ; **contrôler que chaque ligne somme à 1**.
4. Calculer $N_k = \sum_n r_{nk}$; **contrôler** $\sum_k N_k = N$.
5. **Étape M** : μ_k d'abord, **puis** Σ_k avec ces nouvelles μ_k , **puis** $\pi_k = N_k/N$.
6. **Contrôle** : la log-vraisemblance doit avoir **augmenté**.

Méthode B — Diagnostiquer un GMM.

1. Regarder la matrice R : des lignes **proches de** $[1, 0, 0]$ signalent une affectation **nette** ; des lignes proches de $[0,5; 0,5]$ un **chevauchement**.
2. Regarder les N_k : un N_k **très petit** signale une composante **mourante**.
3. Regarder les Σ_k : une variance qui **tend vers 0** signale une composante **collapsée sur un point** (singularité classique du MLE des GMM).
4. Tracer la log-vraisemblance par itération : elle doit être **monotone**.

Méthode C — Passer du mélange au modèle latent.

1. Introduire z **one-hot** de dimension K .
2. Poser l'a priori $p(z_k = 1) = \pi_k$.
3. Poser la conditionnelle $p(x | z_k = 1) = \mathcal{N}(\mu_k, \Sigma_k)$.
4. **Marginaliser** : $\sum_z p(x | z)p(z) = \sum_k \pi_k \mathcal{N}(\mu_k, \Sigma_k)$.
5. **Conditionner** (Bayes) pour retrouver **la responsabilité**.

Méthode D — Vérifier une densité de mélange.

1. Chaque p_k est-elle une densité ?
2. $\pi_k \geq 0$ pour tout k ?
3. $\sum_k \pi_k = 1$?
4. **Contrôle numérique** : intégrer $p(x)$ et vérifier $= 1$.
5. Moyenne du mélange : $\sum_k \pi_k \mu_k$; **elle peut tomber dans un CREUX**.

● Common mistakes

Erreur	Correction
Croire qu'un mélange de gaussiennes est gaussien	NON — c'est précisément ce qui le rend MULTIMODAL et expressif
Oublier la contrainte $\sum_k \pi_k = 1$	Sans elle $p(x)$ n'intègre pas à 1 ; c'est aussi elle qui impose Lagrange
Faire entrer le log dans la somme	$\log \sum_k \neq \sum_k \log$ — c'est LA raison de l'absence de solution fermée
Croire qu'une seule gaussienne pose le même problème	NON : la somme disparaît, le log s'applique directement, tout devient quadratique
Oublier de normaliser les responsabilités	Chaque LIGNE de R doit sommer à 1
Sommer les responsabilités par ligne pour obtenir N_k	N_k est la somme d'une COLONNE
Croire N_k entier	C'est une affectation DOUCE : N_k est un réel
Traiter les r_{nk} comme des constantes lors de la dérivation	Elles dépendent de tous les paramètres — d'où l'itération
Calculer Σ_k avec les anciennes moyennes	Utiliser les NOUVELLES μ_k (ordre de l'étape M)
Diviser par N au lieu de N_k dans μ_k et Σ_k	C'est N_k — la responsabilité TOTALE de la composante
Diviser par N_k dans π_k	C'est $\pi_k = N_k/N$ — le nombre total de points
Oublier Lagrange pour les poids	Sans la contrainte, la maximisation ne donnerait pas N_k/N
Croire qu'EM converge vers l'optimum global	Optimum LOCAL — le résultat dépend de l'initialisation
Croire qu'EM peut faire baisser la vraisemblance	Chaque étape l'AUGMENTE (Neal & Hinton, 1999) — une baisse signale un bug
Confondre étapes E et M	E = calculer les responsabilités (les latentes) · M = réestimer les paramètres
Croire les responsabilités binaires	Affectation DOUCE : un point ambigu a des responsabilités autour de 0,5

Erreur	Correction
Croire la latente du GMM continue	Elle est DISCRÈTE (one-hot) — c'est le contraste avec l'ACP
Croire que z peut avoir plusieurs 1	Exactement UN : $\sum_k z_k = 1$
Sommer sur 2^K configurations de z	Il n'y a que K configurations one-hot valides
Croire que le modèle latent est un modèle différent	« Une façon ÉQUIVALENTE de penser un GMM »
Croire que la responsabilité est une astuce de calcul	C'est LA LOI A POSTERIORI $p(z_k = 1 \mid x)$
Donner un π différent à chaque point	« On PARTAGE le même a priori π » — d'où la plaque
Croire que la moyenne du mélange est un mode	Elle peut tomber dans un CREUX entre composantes

Ultimate Review

===== LES SIX FORMULES À SAVOIR SANS HÉSITER =====

1. MÉLANGE $p(x) = \sum_k \pi_k p_k(x)$, $\pi_k \geq 0$, $\sum_k \pi_k = 1$
GMM $p(x|\theta) = \sum_k \pi_k N(x \mid \mu_k, \Sigma_k)$
2. LOG-VRAISEMBLANCE $L = \sum_n \log(\sum_k \pi_k N(x_n \mid \mu_k, \Sigma_k))$
⚠ le LOG ne rentre PAS → PAS de solution fermée
3. RESPONSABILITÉ $r_{nk} = \pi_k N(x_n \mid \mu_k, \Sigma_k) / \sum_j \pi_j N(x_n \mid \mu_j, \Sigma_j)$
 $\sum_k r_{nk} = 1$ (par LIGNE) $N_k = \sum_n r_{nk}$ (par COLONNE) , $\sum_k N_k = N$
4. ÉTAPE M $\mu_k = (1/N_k) \sum_n r_{nk} x_n$
 $\Sigma_k = (1/N_k) \sum_n r_{nk} (x_n - \mu_k)(x_n - \mu_k)^T$
 $\pi_k = N_k / N$ ← via LAGRANGE
5. EM initialiser → E (responsabilités) → M (paramètres) → répéter
⚠ chaque étape AUGMENTE la log-vraisemblance
6. LATENT z one-hot , $p(z_k = 1) = \pi_k$, $p(x \mid z_k = 1) = N(\mu_k, \Sigma_k)$
MARGINALISER → le GMM CONDITIONNER → la RESPONSABILITÉ

LES TROIS PILIERS COMPARÉS :

	Régression (ch. 9)	ACP (ch. 10)	GMM (ch. 11)
Tâche	Prédire y	Compresser x	Estimer une densité
Latente	— (ou θ en bayésien)	Continue $z \in \mathbb{R}^M$	Discrète one-hot
Solution	Fermée (θ_{ML})	Fermée (vecteurs propres)	ITÉRATIVE (EM)
Obstacle	—	—	Le log d'une somme
Optimum	Global (objectif quadratique)	Global (spectral)	LOCAL

LE CYCLE EM, terme à terme :

Étape	Ce qu'on fixe	Ce qu'on calcule	Nature
E	Les paramètres θ	Les responsabilités r_{nk}	A posteriori des latentes
M	Les responsabilités r_{nk}	Les paramètres μ_k, Σ_k, π_k	Maximum de vraisemblance pondéré

Les trois lectures d'une responsabilité :

Lecture	Énoncé
Algorithmique	Un poids d'importance dans les moyennes pondérées de l'étape M
Géométrique	La force d'attraction de x_n sur μ_k
Probabiliste	LA LOI A POSTERIORI $p(z_{nk} = 1 \mid x_n)$

Ce que chaque chapitre antérieur apporte ici :

Chapitre	Ce qu'il fournit
5 — calcul vectoriel	Les gradients des trois preuves
6 — probabilités	La gaussienne , le théorème de Bayes , la marginalisation
7 — optimisation	Les multiplicateurs de LAGRANGE pour les poids
8 — modèles et données	MLE, variables latentes, modèles graphiques, plaques
10 — ACP	Le contraste latente continue / latente discrète

Active Recall

Modèle de mélange

1. Pourquoi une gaussienne ne suffit-elle pas toujours ?
2. Écrire un modèle de mélange et ses deux contraintes.
3. Pourquoi les mélanges sont-ils plus expressifs ?
4. Écrire un GMM. Quels sont ses paramètres ?
5. Donner le mélange de la figure 11.2.

Le blocage 6. Écrire la vraisemblance factorisée et la log-vraisemblance. 7. Pourquoi la procédure « normale » échoue-t-elle ? 8. Que se passerait-il avec une seule gaussienne ? 9. Quelle est l'idée clé de la parade ? 10. Donner le jeu de données et l'initialisation de l'exemple courant.

Responsabilités 11. Écrire r_{nk} . À quoi est-elle proportionnelle ? 12. Quelles sont ses trois propriétés ? 13. Que signifie « affectation douce » ? 14. Comment lit-on une ligne ? une colonne ? 15. Écrire N_k . Que vaut $\sum_k N_k$? 16. Donner les N_k de l'exemple 11.2.

Les trois mises à jour 17. Énoncer le théorème 11.1. Quelle est la remarque qui l'accompagne ? 18. Donner les trois interprétations de la mise à jour des moyennes. 19. Énoncer le théorème 11.2 et son interprétation. 20. Énoncer le théorème 11.3. Quel outil sa preuve exige-t-elle ? 21. Donner les valeurs numériques des exemples 11.3, 11.4 et 11.5. 22. Dans quel ordre effectue-t-on les trois mises à jour ?

EM 23. Qui a proposé l'algorithme EM et quand ? 24. Décrire les quatre étapes. 25. Que fait l'étape E ? l'étape M ? 26. Quelle est la garantie de convergence ? Vers quel type d'optimum ? 27. Comment vérifier la convergence ? 28. En combien d'itérations converge l'exemple 11.6 ? 29. Que révèle la figure 11.10(b) sur les points ambigus ?

Perspective latente 30. En quoi la latente du GMM diffère-t-elle de celle de l'ACP ? 31. Écrire z et ses propriétés. Comment s'appelle cet encodage ? 32. Qu'est-ce qu'une loi « multinoulli » ? 33. Écrire l'a priori et la conditionnelle. 34. Dériver la vraisemblance par marginalisation. Combien de configurations ? 35. Écrire l'a posteriori. Que reconnaît-on ? 36. Comment le modèle s'étend-il à N points ? Que partage-t-on ?

Flashcards

Question	Réponse
Le troisième pilier ?	L' ESTIMATION DE DENSITÉ
Pourquoi une gaussienne ne suffit pas ?	Capacités de modélisation LIMITÉES — elle est unimodale
Modèle de mélange ?	$p(x) = \sum_k \pi_k p_k(x)$
Les deux contraintes ?	$0 \leq \pi_k \leq 1$ et $\sum_k \pi_k = 1$
Le nom de cette combinaison ?	Une combinaison CONVEXE
Pourquoi plus expressif ?	Il permet des représentations MULTIMODALES — plusieurs clusters
Un GMM ?	$p(x \theta) = \sum_k \pi_k \mathcal{N}(x \mu_k, \Sigma_k)$
Ses paramètres ?	$\theta = \{\pi_k, \mu_k, \Sigma_k : k = 1, \dots, K\}$
La log-vraisemblance ?	$\mathcal{L} = \sum_n \log \left(\sum_k \pi_k \mathcal{N}(x_n \mu_k, \Sigma_k) \right)$
Pourquoi pas de solution fermée ?	Le LOG d'une SOMME — il ne peut pas entrer
Avec une seule gaussienne ?	La somme disparaît , le log s'applique directement , tout est quadratique
L'idée clé de la parade ?	Mettre à jour UN paramètre à la fois en gardant les autres fixés
Le jeu de l'exemple courant ?	$\{-3; -2,5; -1; 0; 2; 4; 5\}$, $N = 7$, $K = 3$
L'initialisation ?	$\mathcal{N}(-4, 1)$, $\mathcal{N}(0; 0, 2)$, $\mathcal{N}(8, 3)$, $\pi_k = \frac{1}{3}$
La responsabilité ?	$r_{nk} = \frac{\pi_k \mathcal{N}(x_n \mu_k, \Sigma_k)}{\sum_j \pi_j \mathcal{N}(x_n \mu_j, \Sigma_j)}$
À quoi est-elle proportionnelle ?	À la VRAISEMBLANCE $\pi_k \mathcal{N}(x_n \mu_k, \Sigma_k)$
Quand est-elle élevée ?	Quand le point pourrait être un échantillon PLAUSIBLE de la composante
Que somme à 1 ?	Chaque LIGNE : $\sum_k r_{nk} = 1$
Son autre nom ?	Une AFFECTATION DOUCE (<i>soft assignment</i>)

Question	Réponse
Son sens probabiliste ?	La probabilité que x_n ait été GÉNÉRÉ par la composante k
N_k ?	$\sum_n r_{nk}$ — la responsabilité TOTALE de la composante k
Comment l'obtenir sur la matrice ?	En sommant une COLONNE
$\sum_k N_k$?	N
N_k est-il entier ?	NON — affectation douce
Les N_k de l'exemple 11.2 ?	2,058 ; 2,008 ; 2,934 (somme = 7)
Mise à jour des moyennes ?	$\mu_k^{\text{new}} = \frac{1}{N_k} \sum_n r_{nk} x_n$
Interprétation 1 ?	Un estimateur de Monte-Carlo PONDÉRÉ PAR IMPORTANCE
Interprétation 2 ?	μ_k est TIRÉE vers x_n avec une FORCE r_{nk}
Interprétation 3 ?	$\mu_k \leftarrow \mathbb{E}_{r_k}[\mathcal{X}]$ avec $r_k = [r_{1k}, \dots, r_{Nk}]^\top / N_k$
Pourquoi pas de solution fermée pour les μ_k ?	Les r_{nk} dépendent de TOUS les paramètres
Mise à jour des covariances ?	$\Sigma_k^{\text{new}} = \frac{1}{N_k} \sum_n r_{nk} (x_n - \mu_k)(x_n - \mu_k)^\top$
Son interprétation ?	Une espérance pondérée du CARRÉ des données CENTRÉES
Mise à jour des poids ?	$\pi_k^{\text{new}} = \frac{N_k}{N}$
Quel outil pour la démontrer ?	Les MULTIPLICATEURS DE LAGRANGE (contrainte $\sum_k \pi_k = 1$)
L'ordre des mises à jour ?	μ_k d'abord , puis Σ_k avec les nouvelles μ_k , puis π_k
Les moyennes de l'exemple 11.3 ?	$-4 \rightarrow -2,7 \cdot 0 \rightarrow -0,4 \cdot 8 \rightarrow 3,7$
Les variances de l'exemple 11.4 ?	$1 \rightarrow 0,14 \cdot 0,2 \rightarrow 0,44 \cdot 3 \rightarrow 1,53$
Les poids de l'exemple 11.5 ?	$\frac{1}{3} \rightarrow 0,29 \cdot \frac{1}{3} \rightarrow 0,29 \cdot \frac{1}{3} \rightarrow 0,42$
Qui a proposé EM ?	Dempster et al. (1977)
Les quatre étapes ?	1. initialiser 2. étape E 3. étape M 4. répéter

Question	Réponse
Que fait l'étape E ?	Évaluer les responsabilités avec les paramètres courants
Que fait l'étape M ?	Réestimer μ_k, Σ_k, π_k avec les responsabilités courantes
Que garantit chaque étape ?	Elle AUGMENTE la log-vraisemblance (Neal & Hinton, 1999)
Vers quel optimum ?	Un optimum LOCAL
Comment vérifier la convergence ?	La log-vraisemblance ou les paramètres directement
Convergence de l'exemple 11.6 ?	En CINQ itérations
À quoi sert EM au-delà des GMM ?	À tous les modèles à VARIABLES LATENTES
Ce que montre la figure 11.10(b) ?	Des points NON affectables uniquement — responsabilités autour de 0,5
La latente du GMM ?	DISCRÈTE — un ensemble FINI de valeurs
Le contraste avec l'ACP ?	L'ACP a une latente CONTINUE dans $\mathbb{R}^M$
L'hypothèse fondatrice ?	Un point est généré par EXACTEMENT UNE composante
La forme de $\mathbf{z}$?	$K - 1$ zéros et exactement un 1
Le nom de cet encodage ?	ONE-HOT (ou représentation 1-parmi-K)
Le nom de cette loi ?	MULTINOULLI — généralisation de la Bernoulli
L'a priori latent ?	$p(\mathbf{z}) = \boldsymbol{\pi}$, avec $\pi_k = p(\mathbf{z}_k = 1)$
La conditionnelle ?	$p(\mathbf{x} \mid \mathbf{z}_k = 1) = \mathcal{N}(\mathbf{x} \mid \mu_k, \Sigma_k)$
Combien de configurations de $\mathbf{z}$?	K seulement (une entrée non nulle)
Ce que donne la marginalisation ?	EXACTEMENT le GMM $\sum_k \pi_k \mathcal{N}(\mathbf{x} \mid \mu_k, \Sigma_k)$
L'a posteriori $p(\mathbf{z}_k = 1 \mid \mathbf{x})$?	EXACTEMENT la RESPONSABILITÉ
Pourquoi l'étape E porte ce nom ?	Parce que la responsabilité EST l'a posteriori de la latente
Combien de latentes pour N points ?	N — chacune $\mathbf{z}_n \in \mathbb{R}^K$
Que partage-t-on entre elles ?	Le même a priori $\boldsymbol{\pi}$

Question	Réponse
Comment le représenter graphiquement ?	Avec une PLAQUE sur n ; π hors de la plaque
Le modèle latent est-il un autre modèle ?	NON — une façon ÉQUIVALENTE de penser le GMM