

Fiche 411 — Classification par machines à vecteurs de support : marge, dualité, noyaux

Matière	Maths · Apprentissage automatique
Cours source	Deisenroth, Faisal & Ong, <i>Mathematics for Machine Learning</i> , Cambridge University Press — chapitre 12 « Classification with Support Vector Machines » (p. 370-396)
Difficulté	Avancé — le quatrième et dernier pilier , et le point de convergence de tout le livre
Temps d'étude estimé	140 min
Prérequis	Fiche 401 (hyperplan affine) · Fiche 402 (produit intérieur, projection orthogonale) · Fiche 406 (Lagrange, dualité, programmation quadratique) · Fiche 407 (minimisation du risque empirique)
Concepts clés	Classification binaire, hyperplan séparateur, vecteur normal, règle de décision, marge, SVM à marge dure, échelle de la marge, théorème 12.1, SVM à marge souple, variable d'écart, paramètre de régularisation C , perte 0-1, perte charnière, sous-gradient, SVM dual, multiplicateurs α et γ , théorème du représentant, vecteurs de support, contraintes de boîte, enveloppe convexe, noyau, application d'attributs canonique, astuce du noyau, matrice de Gram, programmation quadratique
Poids à l'examen	$y_n(\langle w, x_n \rangle + b) \geq 1 \cdot r = \frac{1}{\ w\ }$ · la marge dure $\min \frac{1}{2} \ w\ ^2$ · la marge souple avec $C \sum_n \xi_n$ · la perte CHARNIÈRE $\max\{0, 1 - t\}$ · le DUAL et ses contraintes de boîte · le THÉORÈME DU REPRÉSENTANT $w = \sum_n \alpha_n y_n x_n$ · l' astuce du noyau .

Vue d'ensemble

LE FIL DU CHAPITRE : classer en RAISONNANT GÉOMÉTRIQUEMENT

§12.1 HYPERPLAN SÉPARATEUR $f(x) = \langle w, x \rangle + b$, hyperplan = $\{x : f(x) = 0\}$

⚠ w est le VECTEUR NORMAL – orthogonal à tout vecteur de l'hyperplan

RÈGLE $\langle w, x_n \rangle + b \geq 0$ si $y_n = +1$ · < 0 si $y_n = -1$ → $y_n(\langle w, x_n \rangle + b) \geq 0$

§12.2 SVM PRIMAL

MARGE = distance de l'hyperplan aux exemples LES PLUS PROCHES

⚠ il faut CHOISIR UNE ÉCHELLE – deux conventions ÉQUIVALENTES :

(a) $\|w\| = 1 \rightarrow \max r$ s.c. $y_n(\langle w, x_n \rangle + b) \geq r$

(b) marge = 1 → $\min \frac{1}{2} \|w\|^2$ s.c. $y_n(\langle w, x_n \rangle + b) \geq 1$ (Th. 12.1)

car ⚠ $r = 1/\|w\|$

MARGE SOUPLE $\min \frac{1}{2}\|w\|^2 + C \sum_n \xi_n$ s.c. $y_n(\langle w, x_n \rangle + b) \geq 1 - \xi_n$, $\xi_n \geq 0$

⚠ GRAND C = FAIBLE régularisation

VUE PERTE $\min \frac{1}{2}\|w\|^2 + C \sum_n \max\{0, 1 - y_n f(x_n)\}$ ← PERTE CHARNIÈRE

⚠ la MARGE EST le RÉGULARISATEUR

§12.3 SVM DUAL (Lagrange : α pour la marge, γ pour $\xi_n \geq 0$)

$\min_{\alpha} \frac{1}{2} \sum_i \sum_j y_i y_j \alpha_i \alpha_j \langle x_i, x_j \rangle - \sum_i \alpha_i$

s.c. $\sum_i y_i \alpha_i = 0$ et $0 \leq \alpha_i \leq C$ ← CONTRAINTES DE BOÎTE

THÉORÈME DU REPRÉSENTANT $w^* = \sum_n \alpha_n y_n x_n$

⚠ les x_n avec $\alpha_n > 0$ sont les VECTEURS DE SUPPORT – les seuls qui comptent
 $b^* = y_n - \langle w^*, x_n \rangle$ pour un x_n exactement sur la marge ($0 < \alpha_n < C$)

VUE ENVELOPPE CONVEXE : l'hyperplan BISSECTE le segment entre les deux enveloppes

§12.4 NOYAUX ⚠ le dual ne contient QUE des produits intérieurs $\langle x_i, x_j \rangle$

$k(x_i, x_j) = \langle \phi(x_i), \phi(x_j) \rangle_H$ ← ASTUCE DU NOYAU

MATRICE DE GRAM K, SYMÉTRIQUE SEMI-DÉFINIE POSITIVE

⚠ la frontière devient NON LINÉAIRE, mais on résout TOUJOURS un hyperplan

§12.5 RÉOLUTION NUMÉRIQUE

vue perte → SOUS-GRADIENT (la charnière n'est pas différentiable en $t = 1$)

primal et dual → PROGRAMMES QUADRATIQUES CONVEXES

LA DIFFÉRENCE DE PHILOSOPHIE AVEC LE CHAPITRE 9

Vraisemblance max : on part d'un MODÈLE PROBABILISTE, on en dérive une optimisation.

SVM : on CONÇOIT D'ABORD une fonction à optimiser, par INTUITION GÉOMÉTRIQUE.

Les deux raisons du choix des SVM par les auteurs. « Premièrement, le SVM permet une **façon GÉOMÉTRIQUE de penser** l'apprentissage supervisé... il s'appuie fortement sur les **produits intérieurs et les PROJECTIONS** (ch. 3). Deuxièmement, contrairement au chapitre 9, **le problème d'optimisation du SVM N'ADMET PAS de solution ANALYTIQUE** : il faut recourir à la variété d'outils d'optimisation du chapitre 7. »

● Concept 1 — Classification binaire et hyperplan séparateur (§12.1)

Le cadre. Un prédicteur $f : \mathbb{R}^D \rightarrow \{+1, -1\}$, à partir de paires exemple-étiquette $\{(x_1, y_1), \dots, (x_N, y_N)\}$.

Une mise en garde sur les signes. *« Il faut prendre garde à **ne PAS inférer des attributs intuitifs de "positivité"** de la classe $+1$. Par exemple, dans une tâche de détection de cancer, **un patient ATTEINT est souvent étiqueté $+1$** . »* En principe, deux valeurs distinctes quelconques conviennent : $\{\text{vrai, faux}\}$, $\{0, 1\}$, $\{\text{rouge, bleu}\}$. « Pour les modèles PROBABILISTES, il est mathématiquement commode d'utiliser $\{0, 1\}$. »

L'hyperplan.

$$f : \mathbb{R}^D \rightarrow \mathbb{R}, \quad x \mapsto f(x) := \langle w, x \rangle + b$$

$$\boxed{\text{L'hyperplan séparateur} = \{x \in \mathbb{R}^D : f(x) = 0\}}$$

paramétré par $w \in \mathbb{R}^D$ (le **vecteur NORMAL**) et $b \in \mathbb{R}$ (l'**ordonnée à l'origine**).

La preuve que w est normal. Pour deux exemples x_a, x_b sur l'hyperplan :

$$f(x_a) - f(x_b) = \langle w, x_a \rangle + b - (\langle w, x_b \rangle + b) = \langle w, x_a - x_b \rangle$$

Comme $f(x_a) = f(x_b) = 0$, on obtient $\langle w, x_a - x_b \rangle = 0$. « w est **orthogonal à TOUT vecteur DE l'hyperplan**. »

Avec $w = [2; -1; 0,5]$, $b = -1$, et deux points construits sur l'hyperplan :

$$f(x_a) = 0,0 \quad f(x_b) = 0,0 \quad \langle w, x_a - x_b \rangle = 0,0$$

Exactement zéro — la démonstration en deux lignes du livre est confirmée.

La remarque sur les deux natures de vecteur. « Dans ce chapitre, on pense au vecteur de paramètres w comme à une **FLÈCHE indiquant une DIRECTION** — un **vecteur GÉOMÉTRIQUE**. En revanche, on pense au vecteur d'exemple x comme à un **POINT de donnée** — les **COORDONNÉES** d'un vecteur dans la base standard. »

La règle de décision, en trois écritures :

$$\langle w, x_n \rangle + b \geq 0 \text{ si } y_n = +1 \quad \langle w, x_n \rangle + b < 0 \text{ si } y_n = -1$$

$$y_n(\langle w, x_n \rangle + b) \geq 0$$

« Les deux conditions sont souvent présentées en **UNE SEULE équation** » — on multiplie chacune par $y_n = \pm 1$.

● Concept 2 — Le SVM primal : la marge (§12.2)

2.1 Pourquoi la marge

Le problème. « Pour un jeu **linéairement séparable**, on a une **INFINITÉ d'hyperplans candidats** (figure 12.3). Pour trouver une solution **UNIQUE**, une idée est de choisir l'hyperplan séparateur qui **MAXIMISE la MARGE** entre exemples positifs et négatifs. »

La justification théorique. « Un classifieur à **GRANDE MARGE** se révèle **BIEN GÉNÉRALISER** » (Steinwart & Christmann, 2008).

La marge. « La **DISTANCE de l'hyperplan séparateur aux exemples LES PLUS PROCHES** du jeu de données, en supposant celui-ci linéairement séparable. » Le point le plus proche de l'hyperplan s'obtient par **PROJECTION ORTHOGONALE** (§3.8).

LE PIÈGE TECHNIQUE, signalé explicitement. « En essayant de formaliser cette distance, il y a une **SUBTILITÉ TECHNIQUE qui peut prêter à confusion** : il faut définir **UNE ÉCHELLE à laquelle mesurer la distance**. Une échelle possible serait celle des données, c'est-à-dire les valeurs brutes de x_n . **Il y a des problèmes avec cela** : on pourrait **CHANGER LES UNITÉS de mesure** de x_n , changer ses valeurs et donc **changer la distance** à l'hyperplan. On définit l'échelle **à partir de l'ÉQUATION DE L'HYPERPLAN elle-même**. »

2.2 Première convention : $\|w\| = 1$

Par **addition vectorielle** (§2.4), avec x'_a la projection orthogonale de x_a :

$$x_a = x'_a + r \frac{w}{\|w\|}$$

*« Une autre façon de penser à r : c'est **LA COORDONNÉE** de x_a dans le sous-espace engendré par $w/\|w\|$. »*

En imposant $\|w\| = 1$ — « puisque seule la **DIRECTION** nous intéresse », et « cela permet une interprétation plus intuitive de r , qui est alors le **facteur d'échelle d'un vecteur de longueur 1** » :

$$\max_{w,b,r} \underbrace{r}_{\text{marge}} \quad \text{s.c.} \quad \underbrace{y_n(\langle w, x_n \rangle + b) \geq r}_{\text{ajustement aux données}} \quad \underbrace{\|w\| = 1}_{\text{normalisation}}, \quad r > 0$$

2.3 Seconde convention : la marge vaut 1

Le changement d'hypothèse. « Au lieu de choisir que le vecteur de paramètres est **NORMALISÉ**, on choisit une **ÉCHELLE POUR LES DONNÉES** : telle que la valeur du prédicteur $\langle w, x \rangle + b$ vaille 1 à l'exemple le plus proche. »

La dérivation de r . Comme x'_a est sur l'hyperplan, $\langle w, x'_a \rangle + b = 0$. En substituant $x'_a = x_a - r \frac{w}{\|w\|}$:

$$\left\langle w, x_a - r \frac{w}{\|w\|} \right\rangle + b = 0 \quad \xRightarrow{\text{bilinéarité}} \quad \underbrace{\langle w, x_a \rangle + b}_{=1 \text{ par hypothèse d'échelle}} - \underbrace{r \frac{\langle w, w \rangle}{\|w\|}}_{=r\|w\|} = 0$$

$$r = \frac{1}{\|w\|}$$

La remarque du livre sur le caractère contre-intuitif. *« À première vue cette équation est **contre-intuitive**, car on semble avoir dérivé la distance en termes de la **LONGUEUR du vecteur w** , qu'on **ne connaît pas encore**. Une façon d'y penser : considérer w comme une **VARIABLE TEMPORAIRE** qui ne sert qu'à cette dérivation. »*

On peut aussi « penser à la distance comme à l'**ERREUR DE PROJECTION** encourue en projetant x_a sur l'hyperplan ».

Avec $w = [2; -1; 0,5]$, $b = -1$ et x_a construit tel que $\langle w, x_a \rangle + b = 1$:

Quantité	Valeur
$\langle w, x_a \rangle + b$	1,0
$\langle w, x'_a \rangle + b$ (projection)	0,0
$\ x_a - x'_a\ $	0,4364357805
$1/\ w\ $	0,4364357805

Écart : $5,6 \cdot 10^{-17}$ — l'identité est exacte.

Le SVM à MARGE DURE :

$$\max_{w,b} \frac{1}{\|w\|} \quad \text{s.c.} \quad y_n(\langle w, x_n \rangle + b) \geq 1$$

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad \text{s.c.} \quad y_n(\langle w, x_n \rangle + b) \geq 1 \quad \text{pour tout } n$$

Trois justifications de cette forme. (i) On **minimise le carré** plutôt que de maximiser l'inverse. (ii) On inclut le facteur $\frac{1}{2}$ « qui **n'affecte pas** le w, b optimal mais donne une forme **plus propre** quand on calcule le gradient ». (iii) « La norme au carré donne un **problème de PROGRAMMATION QUADRATIQUE CONVEXE** » (§12.5).

POURQUOI « DURE ».

« Parce que la formulation **N'AUTORISE AUCUNE violation** de la condition de marge. »

2.4 L'équivalence — Théorème 12.1

THÉORÈME 12.1.

Maximiser la marge r avec **poids normalisés**

$$\max_{w,b,r} r \quad \text{s.c.} \quad y_n(\langle w, x_n \rangle + b) \geq r, \quad \|w\| = 1, \quad r > 0$$

est **ÉQUIVALENT** à mettre les données à l'échelle telle que **la marge vaille l'unité** :

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad \text{s.c.} \quad y_n(\langle w, x_n \rangle + b) \geq 1$$

Les trois pas de la preuve :

1. « Le **CARRÉ est une transformation strictement monotone** pour des arguments non négatifs : le maximum reste le même si l'on considère r^2 . »
2. « Puisque $\|w\| = 1$, on peut **REPARAMÉTRISER** avec un nouveau vecteur w' **non normalisé** en utilisant explicitement $\frac{w'}{\|w'\|}$. »
3. « r est **strictement positif** (on a supposé la séparabilité linéaire), donc on peut **DIVISER la première contrainte par r** » — ce qui donne $\|w'\| = 1/r$ et transforme le max en min.

Sur 8 points de $\mathbb{R}^2$ (4 positifs, 4 négatifs, linéairement séparables), recherche exhaustive sur **3 600** directions unitaires :

Formulation (a), $\|w\| = 1$: $r^* = 2,49999965$, $w = [0,799685 ; 0,600420]$, $b = -0,300210$

Formulation (b), en posant $w' = w/r$ et $b' = b/r$:

Contrôle	Valeur
w'	[0,319874 ; 0,240168]
$\ w'\ $	0,40000006
$1/r^*$	0,40000006
$\min_n y_n(\langle w', x_n \rangle + b')$	1,00000000
$\frac{1}{2} \ w'\ ^2$	0,08000002

La contrainte devient exactement ≥ 1 et $\|w'\| = 1/r$: les deux formulations décrivent le même hyperplan.

● Concept 3 — La marge souple (§12.2.4-12.2.5)

3.1 La vue géométrique

Le besoin. « Quand les données **ne sont PAS linéairement séparables**, on peut vouloir permettre à certains exemples de tomber **DANS la région de marge**, ou même **du MAUVAIS CÔTÉ** de l'hyperplan. »

L'idée clé. « Introduire une **VARIABLE D'ÉCART** (slack variable) ξ_n pour **chaque** paire (x_n, y_n) . On **SOUSTRAIT ξ_n de la marge**, en contraignant ξ_n à être **non négative**. Pour **encourager la classification correcte**, on **AJOUTE ξ_n à l'objectif**. »

$$\min_{w,b,\xi} \frac{1}{2} \|w\|^2 + C \sum_{n=1}^N \xi_n \quad \text{s.c.} \quad y_n(\langle w, x_n \rangle + b) \geq 1 - \xi_n, \quad \xi_n \geq 0$$

LE SENS DE C , contre-intuitif. « Le paramètre $C > 0$ **ARBITRE** entre la **TAILLE de la marge** et la **quantité totale d'écart**. On l'appelle le **PARAMÈTRE DE RÉGULARISATION** puisque le terme de marge **EST un terme de régularisation**. Le terme $\|w\|^2$ est le **RÉGULARISATEUR**, et dans beaucoup de livres d'optimisation numérique le paramètre de régularisation **MULTIPLIE CE TERME-LÀ** — c'est en contraste avec notre formulation. Ici, une **GRANDE** valeur de C implique une **FAIBLE** régularisation, puisqu'on donne **plus de poids aux variables d'écart**, donnant plus de priorité aux exemples qui ne sont pas du bon côté de la marge. »

« Cette formulation est aussi souvent appelée le **C -SVM**. »

3.2 La vue fonction de perte

La perspective. On suit le **principe de MINIMISATION DU RISQUE EMPIRIQUE** (§8.2), avec les **hyperplans comme classe d'hypothèses**. « On verra que **LA MARGE CORRESPOND AU TERME DE RÉGULARISATION**. Reste la question : quelle est la **fonction de PERTE** ? »

POURQUOI PAS LA PERTE QUADRATIQUE.

« La perte quadratique utilisée en régression **n'est PAS appropriée** à la classification binaire. »

La perte idéale — et pourquoi on ne l'utilise pas.

$$\text{PERTE 0-1} : 1(f(x_n) \neq y_n)$$

« Malheureusement, la perte **0-1** donne un problème d'**OPTIMISATION COMBINATOIRE** pour trouver les meilleurs w, b . Les problèmes combinatoires sont en général **PLUS DIFFICILES à résoudre** que les problèmes continus. »

LA PERTE CHARNIÈRE (hinge loss) :

$$\ell(t) = \max\{0, 1 - t\} \quad \text{où} \quad t = y f(x) = y(\langle w, x \rangle + b)$$

Sa lecture en trois régimes :

Régime	Situation	Perte
$t \geq 1$	Du bon côté et plus loin que la distance 1	0
$0 < t < 1$	Du bon côté mais DANS la marge	Positive
$t < 0$	Du MAUVAIS côté	Encore plus grande, croissance LINÉAIRE

« On **PAIE** une **pénalité** dès qu'on est plus proche que la marge, **MÊME SI** la **prédiction** est **CORRECTE**, et la pénalité croît **linéairement**. »

L'écriture en deux morceaux linéaires :

$$\ell(t) = \begin{cases} 0 & \text{si } t \geq 1 \\ 1 - t & \text{si } t < 1 \end{cases}$$

$$\ell(t) = \underbrace{\begin{cases} 0 & \text{si } t \geq 1 \\ \infty & \text{si } t < 1 \end{cases}}_{\text{la perte de la MARGE DURE}}$$

La propriété qui justifie tout. *« La perte charnière est un **MAJORANT CONVEXE** de la perte 0-1. »*

t	Perte 0-1	Charnière	Majoration
-2,0	1,0	3,000	
-0,5	1,0	1,500	
0,0	1,0	1,000	(égalité)
0,5	0,0	0,500	(pénalité alors que la prédiction est CORRECTE)
1,0	0,0	0,000	(égalité)
1,5	0,0	0,000	
3,0	0,0	0,000	

La ligne $t = 0,5$ montre l'essentiel : la charnière **pénalise une prédiction correcte mais peu confiante** — c'est ce qui **crée** la marge.

Le problème **SANS** contraintes :

$$\min_{w,b} \underbrace{\frac{1}{2} \|w\|^2}_{\text{RÉGULARISATEUR}} + C \sum_{n=1}^N \underbrace{\max\{0, 1 - y_n(\langle w, x_n \rangle + b)\}}_{\text{PERTE}}$$

LA LECTURE. « Le terme $\frac{1}{2} \|w\|^2$ **provient DIRECTEMENT de la MARGE**. Autrement dit, **la MAXIMISATION de la MARGE peut être interprétée comme une RÉGULARISATION**. »

L'équivalence avec la forme contrainte — le pas de traduction :

$$\min_t \max\{0, 1 - t\} \quad \Longleftrightarrow \quad \min_{\xi, t} \xi \quad \text{s.c.} \quad \xi \geq 0, \quad \xi \geq 1 - t$$

« En substituant cette expression et en réarrangeant une des contraintes, on obtient **EXACTEMENT le SVM à marge souple**. »

● Concept 4 — Le SVM dual (§12.3)

4.1 Pourquoi le dual

Le problème de dimension. *« Puisque w est de la **même dimension que x** , le nombre de paramètres **croît LINÉAIREMENT avec le nombre d'ATTRIBUTS**. »*

Les trois avantages du dual.

1. Il est **INDÉPENDANT** du nombre d'ATTRIBUTS ; le nombre de paramètres croît avec le nombre d'EXEMPLES.
2. « Utile pour les problèmes où l'on a **plus d'attributs que d'exemples**. »
3. « Il permet **FACILEMENT d'appliquer les NOYAUX**. »

4.2 La dérivation

Deux multiplicateurs, avec la notation usuelle de la littérature SVM (et non λ) :

Multiplicateur	Contrainte associée
$\alpha_n \geq 0$	La classification correcte : $y_n(\langle w, x_n \rangle + b) \geq 1 - \xi_n$
$\gamma_n \geq 0$	La non-négativité de l'écart : $\xi_n \geq 0$

$$\mathcal{L}(w, b, \xi, \alpha, \gamma) = \frac{1}{2} \|w\|^2 + C \sum_n \xi_n - \sum_n \alpha_n (y_n(\langle w, x_n \rangle + b) - 1 + \xi_n) - \sum_n \gamma_n \xi_n$$

Les trois dérivées, annulées :

$$\frac{\partial \mathcal{L}}{\partial w} = w^\top - \sum_n \alpha_n y_n x_n^\top = 0 \implies \boxed{w = \sum_{n=1}^N \alpha_n y_n x_n}$$

$$\frac{\partial \mathcal{L}}{\partial b} = - \sum_n \alpha_n y_n = 0 \implies \boxed{\sum_{n=1}^N y_n \alpha_n = 0}$$

$$\frac{\partial \mathcal{L}}{\partial \xi_n} = C - \alpha_n - \gamma_n = 0 \xRightarrow{\gamma_n \geq 0} \boxed{\alpha_n \leq C}$$

LE THÉORÈME DU REPRÉSENTANT. La première équation dit que w est une **COMBINAISON LINÉAIRE DES DONNÉES**. C'est la clé qui rend les noyaux possibles.

Le dual obtenu :

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N y_i y_j \alpha_i \alpha_j \langle x_i, x_j \rangle - \sum_{i=1}^N \alpha_i$$

$$\text{s.c.} \quad \sum_{i=1}^N y_i \alpha_i = 0 \quad \text{et} \quad 0 \leq \alpha_i \leq C$$

« On **MAXIMISE le problème dual**, ce qui équivaut à **MINIMISER le dual NÉGATIF** — d'où la forme ci-dessus. »

Les CONTRAINTES DE BOÎTE. « Ces inégalités sont appelées "**contraintes de BOÎTE**" parce qu'elles limitent le vecteur $\alpha \in \mathbb{R}^N$ à être **dans la boîte définie par 0 et C sur chaque axe**. Ces boîtes **alignées sur les axes** sont **particulièrement efficaces** à implémenter dans les solveurs numériques » (Dostál, 2009).

4.3 Récupérer les paramètres primaux

$$w^* = \sum_n \alpha_n y_n x_n$$

Pour b^* : « considérer un exemple x_n qui se trouve **EXACTEMENT sur la frontière de la marge** », c'est-à-dire $\langle w^*, x_n \rangle + b = y_n$:

$$b^* = y_n - \langle w^*, x_n \rangle$$

Le cas où aucun exemple n'est exactement sur la marge. « En principe, il peut n'y avoir **aucun** exemple exactement sur la marge. Dans ce cas, on devrait calculer $|y_n - \langle w^*, x_n \rangle|$ pour **tous les vecteurs de support** et prendre la **MÉDIANE** de cette différence absolue. »

COMMENT RECONNAÎTRE CES EXEMPLES.

« Les exemples qui se trouvent exactement sur la marge sont ceux dont les paramètres duaux sont **STRICTEMENT à l'INTÉRIEUR** des contraintes de boîte : $0 < \alpha_i < C$. Cela se dérive des conditions de **KARUSH-KUHN-TUCKER**. »

Sur le même jeu de 8 points, dual à marge dure (C très grand), résolu par **misés à jour par PAIRES** (SMO simplifié — ce qui préserve exactement $\sum_i y_i \alpha_i = 0$) :

$$\alpha = [0,08 ; 0 ; 0 ; 0 ; 0,08 ; 0 ; 0 ; 0]$$

Contrôle	Valeur
$\sum_i y_i \alpha_i$	0,000000000000
Objectif dual	−0,08000000
Vecteurs de support	indices 0 et 4 seulement : $[2; 2]$ ($y = +1$) et $[-2; -1]$ ($y = -1$)
Les 6 autres	$\alpha = 0$ — ils n'influencent PAS la solution
$w^* = \sum \alpha_n y_n x_n$	$[0,320000 ; 0,240000]$
b^*	−0,120000
$\ w^*\ $	0,400000
Marge $1/\ w^*\ $	2,500000
$y_n(\langle w^*, x_n \rangle + b^*)$ aux deux SV	1,00000000 et 1,00000000

LA DUALITÉ FORTE, vérifiée numériquement — comparaison avec la recherche exhaustive du primal :

	w	b	Marge
Primal (grille de 3 600 directions)	$[0,319874 ; 0,240168]$	−0,120084	2,500000
Dual (SMO)	$[0,320000 ; 0,240000]$	−0,120000	2,500000

Écart relatif sur w : $5 \cdot 10^{-4}$ — imputable à la résolution de $0,1^\circ$ de la grille du primal. Et l'objectif dual −0,08 est **exactement l'opposé** du primal $\frac{1}{2} \|w\|^2 = \frac{1}{2} (0,4)^2 = 0,08$: **les deux problèmes ont la même valeur optimale** (dualité forte, §7.3).

4.4 La vue enveloppe convexe

L'idée. « Considérer l'ensemble des exemples de même étiquette et construire un **ENSEMBLE CONVEXE** les contenant tous, **LE PLUS PETIT possible** — c'est l'**ENVELOPPE CONVEXE**. »

La construction, en montant en dimension :

Points	Objet engendré
x_1, x_2 avec $\alpha_1 + \alpha_2 = 1$, $\alpha_i \geq 0$	« Chaque point sur une LIGNE entre x_1 et x_2 »
x_1, x_2, x_3	« Une AIRE bidimensionnelle ; l'enveloppe est le TRIANGLE formé par les arêtes »
Plus de points que de dimensions	« Certains points seront À L'INTÉRIEUR de l'enveloppe »

$$\text{conv}(X) = \left\{ \sum_{n=1}^N \alpha_n x_n : \sum_{n=1}^N \alpha_n = 1 \text{ et } \alpha_n \geq 0 \right\}$$

La troisième interprétation du SVM. « Un hyperplan qui **BISSECTE le SEGMENT** entre les **ENVELOPPES CONVEXES** correspondant aux exemples positifs et négatifs. »

● Concept 5 — Les noyaux (§12.4)

5.1 L'observation qui rend tout possible

LE POINT DE DÉPART. *« Remarquer que le **produit intérieur** dans l'objectif n'apparaît QU'ENTRE exemples x_i et x_j . Il n'y a **AUCUN produit intérieur** entre les exemples et les **PARAMÈTRES**. Donc, si l'on considère un ensemble d'attributs $\phi(x_i)$, le **SEUL** changement dans le SVM dual sera de **REEMPLACER** le produit intérieur. »*

La modularité. « Cette **MODULARITÉ** — où le choix de la **méthode de classification** (le SVM) et le choix de la **représentation d'attributs** $\phi(x)$ peuvent être considérés **SÉPARÉMENT** — offre la flexibilité d'**explorer les deux problèmes INDÉPENDAMMENT**. »

5.2 La définition

Un **NOYAU** est une fonction $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ « pour laquelle il **EXISTE un espace de HILBERT** $\mathcal{H}$ et une application d'attributs $\phi : \mathcal{X} \rightarrow \mathcal{H}$ telle que »

$$k(x_i, x_j) = \langle \phi(x_i), \phi(x_j) \rangle_{\mathcal{H}}$$

« Au lieu de définir explicitement une application non linéaire $\phi(\cdot)$ et de calculer le produit intérieur résultant, on définit une **FONCTION DE SIMILARITÉ** $k(x_i, x_j)$. Pour une certaine classe de fonctions de similarité — les **NOYAUX** — la fonction de similarité **définit IMPLICITEMENT une application d'attributs NON LINÉAIRE**. »

Le vocabulaire :

Terme	Définition
Application d'attributs CANONIQUE	$\phi(x) = k(\cdot, x)$ — « il existe un espace de Hilbert à noyau REPRODUISANT (RKHS) UNIQUE associé à chaque noyau » (Aronszajn, 1950)
ASTUCE DU NOYAU (<i>kernel trick</i>)	La généralisation du produit intérieur à k , « car elle CACHE l'application non linéaire EXPLICITE »
Matrice de GRAM (ou matrice de noyau)	$K \in \mathbb{R}^{N \times N}$ résultant de l'application de $k(\cdot, \cdot)$ au jeu de données

La condition sur les noyaux :

Les noyaux doivent être SYMÉTRIQUES et SEMI-DÉFINIS POSITIFS : $\forall z \in \mathbb{R}^N, z^\top K z \geq 0$

Avec le noyau linéaire $k(x_i, x_j) = \langle x_i, x_j \rangle$ sur les 8 points :

Propriété	Test	Résultat
Symétrie	$\max_{i,j} K_{ij} - K_{ji} $	exactement 0
Semi-définie positivité	$\min z^T K z$ sur 20 000 tirages gaussiens	+0,000112 > 0

Ce n'est pas un hasard : $K = X^T X$ est **toujours** symétrique semi-définie positive (théorème 4.14, fiche 403).

Les noyaux usuels cités pour $x_i \in \mathbb{R}^D$: le noyau POLYNOMIAL, le noyau GAUSSIEN à base radiale (RBF), le noyau QUADRATIQUE RATIONNEL.

LA MISE EN GARDE ESSENTIELLE. « *Note that we are still solving for HYPERPLANES : la classe d'hypothèses de fonctions reste LINÉAIRE. Les surfaces NON LINÉAIRES sont dues à la FONCTION NOYAU.* »

Les TROIS sens du mot « noyau », signalés par le livre.

1. Ici : le **RKHS** (Aronszajn 1950 ; Saitoh 1988).
2. En **algèbre linéaire** (§2.7.3) : un **autre mot pour l'ESPACE NUL** (fiche 401).
3. En **estimation de densité à noyau** (§11.5) : le noyau **LISSANT**.

Le choix du noyau. « *Le choix du noyau, ainsi que ses paramètres, est souvent fait par VALIDATION CROISÉE IMBRIQUÉE (§8.6.1).* » Et : « *un praticien conçoit souvent la fonction noyau de sorte qu'elle puisse être calculée PLUS EFFICACEMENT que le produit intérieur entre applications d'attributs explicites.* »

● Concept 6 — La résolution numérique (§12.5)

6.1 La vue perte : le sous-gradient

Le problème. « La vue fonction de perte est un problème d'optimisation **CONVEXE SANS contraintes**, mais la **perte charnière N'EST PAS DIFFÉRENTIABLE**. On applique donc une approche par **SOUS-GRADIENT**. »

*« La charnière est différentiable **PRESQUE PARTOUT**, sauf en **UN SEUL point : la charnière $t = 1$** . En ce point, le gradient est un **ENSEMBLE de valeurs possibles entre 0 et -1** . »*

$$g(t) = \begin{cases} -1 & t < 1 \\ [-1, 0] & t = 1 \\ 0 & t > 1 \end{cases}$$

Avec ce sous-gradient, on applique les **méthodes du §7.1** (descente de gradient, momentum, SGD).

6.2 Les programmes quadratiques

Le choix stratégique. « Le SVM **PRIMAL** a des variables d'optimisation de la taille de la **DIMENSION D** des exemples. Le SVM **DUAL** a des variables de la taille du **NOMBRE N d'exemples**. » — on choisit selon lequel est le plus petit.

La mise en forme standard du primal (§7.3.2), avec le produit scalaire :

$$\min_{w, b, \xi} \frac{1}{2} \|w\|^2 + C \sum_n \xi_n \quad \text{s.c.} \quad -y_n x_n^\top w - y_n b - \xi_n \leq -1, \quad -\xi_n \leq 0$$

« En **CONCATÉNANT** les variables w , b , ξ_n en un **SEUL vecteur** et en collectant soigneusement les termes, on obtient la forme matricielle. » Les deux problèmes sont des **programmes quadratiques CONVEXES**.

Comment reconnaître le type d'exercice

L'énoncé dit...	Le type	La méthode
« Montrer que w est normal à l'hyperplan »	§12.1	Prendre x_a, x_b sur l'hyperplan, calculer $f(x_a) - f(x_b) = \langle w, x_a - x_b \rangle = 0$
« Écrire la règle de décision »	§12.1	En une seule inégalité : $y_n(\langle w, x_n \rangle + b) \geq 0$
« Calculer la distance d'un point à l'hyperplan »	§12.2.1	Projection orthogonale ; $r = \frac{ \langle w, x \rangle + b }{\ w\ }$
« Pourquoi faut-il fixer une échelle ? »	§12.2.1	Changer les UNITÉS de x_n changerait la distance
« Écrire le SVM à marge dure »	§12.2.2	$\min \frac{1}{2} \ w\ ^2$ s.c. $y_n(\langle w, x_n \rangle + b) \geq 1$
« Montrer l'équivalence des deux formulations »	Th. 12.1	Carré monotone · reparamétriser par $w'/\ w'\ $ · diviser par $r > 0$
« Les données ne sont pas séparables »	§12.2.4	Marge souple : ajouter $\xi_n \geq 0$ et $C \sum_n \xi_n$
« Quel est l'effet d'un grand C ? »	§12.2.4	FAIBLE régularisation — plus de poids aux écarts
« Écrire la perte du SVM »	§12.2.5	CHARNIÈRE : $\max\{0, 1 - yf(x)\}$
« Pourquoi pas la perte 0-1 ? »	§12.2.5	Problème COMBINATOIRE
« Dériver le dual »	§12.3.1	Lagrangien avec α et γ ; annuler en w, b, ξ ; substituer
« Que valent les contraintes du dual ? »	§12.3.1	$\sum_i y_i \alpha_i = 0$ (de ∂b) et $0 \leq \alpha_i \leq C$ (de $\partial \xi$ plus $\gamma_i \geq 0$)
« Retrouver w à partir de α »	Représentant	$w^* = \sum_n \alpha_n y_n x_n$
« Retrouver b »	§12.3.1	$b^* = y_n - \langle w^*, x_n \rangle$ pour un n avec $0 < \alpha_n < C$
« Identifier les vecteurs de support »	§12.3.1	Ceux avec $\alpha_n > 0$; les autres n'influencent pas la solution
« Rendre le classifieur non linéaire »	§12.4	Remplacer $\langle x_i, x_j \rangle$ par $k(x_i, x_j)$ — rien d'autre à changer
« Cette fonction est-elle un noyau valide ? »	§12.4	Symétrique et semi-définie positive : $z^T K z \geq 0$

L'énoncé dit...	Le type	La méthode
« Comment optimiser la perte charnière ? »	\$12.5	SOUS-GRADIENT (non différentiable en $t = 1$)
« Primal ou dual ? »	\$12.5	Primal : D variables. Dual : N variables. Choisir le plus petit

Comment résoudre : les cinq méthodes pas-à-pas

Méthode A — Calculer une marge.

1. Vérifier que les données sont **linéairement séparables**.
2. Choisir une convention d'échelle : $\|w\| = 1$ ou marge = 1.
3. Projeter orthogonalement le point le plus proche : $x'_a = x_a - \frac{\langle w, x_a \rangle + b}{\|w\|^2} w$.
4. $r = \|x_a - x'_a\|$.
5. **Contrôle** : $r = \frac{1}{\|w\|}$ si l'on a normalisé les données ; $r = \frac{|\langle w, x_a \rangle + b|}{\|w\|}$ en général.

Méthode B — Passer du primal au dual.

1. Écrire le lagrangien avec **UN multiplicateur par contrainte** (α_n et γ_n).
2. Dériver par rapport à **chaque** variable primale : w, b, ξ .
3. **Annuler** les trois : on obtient le **représentant**, la contrainte $\sum y_n \alpha_n = 0$, et $\alpha_n + \gamma_n = C$.
4. **Substituer** dans le lagrangien ; les termes en b et en ξ **disparaissent**.
5. Traduire « maximiser le dual » en « minimiser son opposé ».
6. **Contrôles** : le dual ne contient **que des produits intérieurs entre exemples** ; les contraintes forment une **boîte**.

Méthode C — Résoudre le dual et revenir au primal.

1. Construire la **matrice de Gram** $K_{ij} = \langle x_i, x_j \rangle$ (ou $k(x_i, x_j)$).
2. Résoudre le PQ sous $\sum_i y_i \alpha_i = 0$ et $0 \leq \alpha_i \leq C$. Les mises à jour **par PAIRES** préservent la contrainte d'égalité.
3. Identifier les **vecteurs de support** : $\alpha_n > 0$.
4. $w^* = \sum_n \alpha_n y_n x_n$.
5. b^* depuis un SV **strictement intérieur** ($0 < \alpha_n < C$), ou la **médiane** sinon.
6. **Contrôles** : $\sum_i y_i \alpha_i = 0$; $y_n (\langle w^*, x_n \rangle + b^*) = 1$ aux SV ; objectif dual = $-\frac{1}{2} \|w^*\|^2$ (dualité forte).

Méthode D — Appliquer un noyau.

1. Vérifier que k est **symétrique**.
2. Vérifier que la matrice de Gram est **semi-définie positive**.
3. Remplacer $\langle x_i, x_j \rangle$ par $k(x_i, x_j)$ **dans le dual** — rien d'autre à modifier.
4. **Le prédicteur s'écrit alors** $f(x) = \sum_n \alpha_n y_n k(x_n, x) + b$ — on n'a jamais besoin de w explicitement.
5. Choisir noyau et hyperparamètres par **validation croisée imbriquée**.

Méthode E — Diagnostiquer un SVM entraîné.

1. Compter les **vecteurs de support** : beaucoup $\Rightarrow$ problème difficile ou C trop petit.
2. Regarder les $\alpha_n = C$: ce sont les points **dans la marge ou mal classés**.
3. Regarder les $0 < \alpha_n < C$: ceux **exactement sur la marge** — ils donnent b .
4. Regarder les $\alpha_n = 0$: **sans influence**, on pourrait les supprimer du jeu.
5. Calculer la marge $1/\|w\|$.

● Common mistakes

Erreur	Correction
Croire que la classe $+1$ est « la bonne »	En détection de cancer, le patient ATTEINT est étiqueté $+1$
Utiliser $\{0, 1\}$ dans les formules du SVM	Le SVM exige $\{+1, -1\}$ pour que $y_n(\cdot \cdot \cdot) \geq 1$ fonctionne ; $\{0, 1\}$ est pour les modèles probabilistes
Croire que w est un point de données	w est une FLÈCHE (vecteur géométrique) ; x est un POINT (coordonnées)
Mesurer la marge à l'échelle des données	Changer les UNITÉS changerait la marge — il faut l'échelle de L'ÉQUATION de l'hyperplan
Croire les deux conventions différentes	Théorème 12.1 : elles sont ÉQUIVALENTES
Oublier $r > 0$ dans la preuve du théorème 12.1	C'est ce qui autorise la division par r ; garanti par la séparabilité
Croire que le $\frac{1}{2}$ change la solution	Il n'affecte pas l'optimum — il rend seulement le gradient plus propre
Croire qu'un grand C régularise fort	L'INVERSE : grand C = FAIBLE régularisation
Placer C sur $\ w\ ^2$	Ici C multiplie les ÉCARTS — c'est l'inverse de la convention des livres d'optimisation
Oublier $\xi_n \geq 0$	Sans elle, on pourrait « gagner » de la marge avec des ξ négatifs
Utiliser la perte quadratique	Inadaptée à la classification binaire
Utiliser la perte 0-1	Problème COMBINATOIRE , beaucoup plus difficile
Croire que la charnière ne pénalise que les erreurs	Elle pénalise DÈS $t < 1$, même quand la prédiction est correcte
Oublier que la charnière majore la perte 0-1	C'est un majorant CONVEXE — c'est ce qui rend l'optimisation traitable
Oublier que la marge est la régularisation	$\frac{1}{2} \ w\ ^2$ provient de la marge et joue le rôle de régularisateur
N'utiliser qu'un multiplicateur dans le dual	Il en faut DEUX : α_n et γ_n
Oublier d'où vient $\alpha_i \leq C$	De $C - \alpha_n - \gamma_n = 0$ avec $\gamma_n \geq 0$

Erreur	Correction
Oublier la contrainte $\sum_i y_i \alpha_i = 0$	Elle vient de $\partial \mathcal{L} / \partial b = 0$; c'est elle qui impose des mises à jour par PAIRES
Croire que tous les points contribuent à w	Seuls les VECTEURS DE SUPPORT ($\alpha_n > 0$) — les autres ont $\alpha_n = 0$
Prendre b depuis n'importe quel SV	Il faut $0 < \alpha_n < C$; sinon médiane sur tous les SV
Croire que le dual a autant de variables que le primal	Primal : D (attributs). Dual : N (exemples)
Croire que le noyau rend le modèle non linéaire	« On résout TOUJOURS un hyperplan » — c'est la frontière qui devient non linéaire
Confondre les trois sens de « noyau »	RKHS (ici) · espace nul (algèbre linéaire) · noyau lissant (estimation de densité)
Utiliser une fonction de similarité arbitraire	Un noyau doit être symétrique ET semi-défini positif
Calculer $\phi(x)$ explicitement	Tout l'intérêt de l'astuce du noyau est de ne jamais le faire
Appliquer une descente de gradient à la charnière	Elle n'est pas différentiable en $t = 1$ — utiliser le SOUS-GRADIENT
Croire que la charnière n'est différentiable nulle part	Elle l'est presque partout , sauf en UN point

Ultimate Review

===== LES HUIT FORMULES À SAVOIR SANS HÉSITER =====

- HYPERPLAN** $\{x : \langle w, x \rangle + b = 0\}$, w = VECTEUR NORMAL
RÈGLE $y_n(\langle w, x_n \rangle + b) \geq 0$
- DISTANCE** $x_a = x_{a'} + r w / \|w\| \rightarrow r = 1 / \|w\|$
- MARGE DURE** $\min \frac{1}{2} \|w\|^2 \quad \text{s.c.} \quad y_n(\langle w, x_n \rangle + b) \geq 1$
- MARGE SOUPLE** $\min \frac{1}{2} \|w\|^2 + C \sum_n \xi_n \quad \text{s.c.} \quad y_n(\langle w, x_n \rangle + b) \geq 1 - \xi_n, \xi_n \geq 0$
⚠ GRAND C = FAIBLE régularisation
- PERTE CHARNIÈRE** $\ell(t) = \max\{0, 1 - t\}$, $t = y f(x)$
 $\min \frac{1}{2} \|w\|^2 + C \sum_n \max\{0, 1 - y_n f(x_n)\} \leftarrow \text{MARGE} = \text{RÉGULARISATEUR}$
- DUAL** $\min_{\alpha} \frac{1}{2} \sum_i \sum_j y_i y_j \alpha_i \alpha_j \langle x_i, x_j \rangle - \sum_i \alpha_i$

$$\text{s.c. } \sum_i y_i a_i = 0, \quad 0 \leq a_i \leq C \quad \leftarrow \text{BOÎTE}$$

$$7. \text{ REPRÉSENTANT } w^* = \sum_n a_n y_n x_n \quad b^* = y_n - \langle w^*, x_n \rangle \quad (0 < a_n < C)$$

VECTEURS DE SUPPORT : les x_n avec $a_n > 0$

$$8. \text{ NOYAU } k(x_i, x_j) = \langle \phi(x_i), \phi(x_j) \rangle_H \quad \cdot \quad K \text{ symétrique semi-déf. positive}$$

$$\text{PRÉDICTEUR À NOYAU } f(x) = \sum_n a_n y_n k(x_n, x) + b$$

LES TROIS VUES DU MÊME SVM :

Vue	Point de départ	Ce qu'elle éclaire
GÉOMÉTRIQUE (§12.2.4)	Variables d'écart ξ_n	L' intuition : distance, marge, violations
PERTE (§12.2.5)	Minimisation du risque empirique	La marge EST la régularisation ; connexion au chapitre 8
ENVELOPPE CONVEXE (§12.3.2)	Le dual	L'hyperplan BISSECTE le segment entre enveloppes

PRIMAL contre DUAL :

	PRIMAL	DUAL
Variables	$w \in \mathbb{R}^D, b, \xi \in \mathbb{R}^N$	$\alpha \in \mathbb{R}^N$
Taille	Croît avec les ATTRIBUTS	Croît avec les EXEMPLES
Contraintes	$2N$ inégalités	1 égalité + boîte
Bon quand	$D < N$	$D > N$
Noyaux	Impossible directement	Immédiat
Nature	PQ convexe	PQ convexe

Les correspondances avec les chapitres antérieurs :

Chapitre	Ce qu'il fournit
2 — hyperplan affine	La définition même de l'objet à trouver
3 — produit intérieur, projection	La marge , le vecteur normal, la distance
4 — matrices SDP	La condition sur la matrice de Gram
5 — gradients	Les trois dérivées du lagrangien
7 — Lagrange, dualité, PQ	Toute la §12.3 ; sous-gradient ; forme standard
8 — risque empirique, régularisation	La vue perte ; validation croisée imbriquée
9 — application d'attributs ϕ	Le pont vers les noyaux

Le classement des points par leur α_n :

α_n	Position du point	Rôle
$\alpha_n = 0$	Au-delà de la marge, bien classé	AUCUNE influence — supprimable
$0 < \alpha_n < C$	Exactement SUR la marge	Vecteur de support ; sert à calculer b
$\alpha_n = C$	Dans la marge ou mal classé	Vecteur de support ; $\xi_n > 0$

Active Recall

Hyperplan

1. Quelle mise en garde le livre donne-t-il sur l'étiquette **+1** ?
2. Écrire f et définir l'hyperplan séparateur.
3. Démontrer que w est orthogonal à tout vecteur de l'hyperplan.
4. Quelle distinction le livre fait-il entre w et x ?
5. Écrire la règle de décision en une seule inégalité.

Marge 6. Pourquoi maximiser la marge ? Que garantit-elle ? 7. Quelle est la subtilité technique de la définition de la marge ? 8. Écrire la décomposition $x_a = x'_a + r \frac{w}{\|w\|}$ et interpréter r . 9. Écrire la formulation avec $\|w\| = 1$. 10. Dériver $r = 1/\|w\|$ sous l'hypothèse d'échelle. 11. Pourquoi cette équation est-elle contre-intuitive ? Comment le livre la justifie-t-il ? 12. Écrire le SVM à marge dure

et justifier ses trois choix de forme. 13. Énoncer le théorème 12.1 et donner les trois pas de sa preuve. 14. Pourquoi « dure » ?

Marge souple 15. Quel est le besoin ? Quelle est l'idée clé ? 16. Écrire le SVM à marge souple. 17. Que fait le paramètre C ? Un grand C régularise-t-il fort ? 18. Pourquoi appelle-t-on la marge un régularisateur ? 19. Pourquoi la perte quadratique est-elle inadaptée ? 20. Qu'est-ce que la perte 0-1 ? Pourquoi ne l'utilise-t-on pas ? 21. Écrire la perte charnière et ses trois régimes. 22. Quelle est sa propriété par rapport à la perte 0-1 ? 23. Écrire le problème sans contraintes et identifier ses deux termes. 24. Comment montre-t-on l'équivalence avec la forme contrainte ?

Dual 25. Donner les trois avantages du dual. 26. Quels sont les deux multiplicateurs et à quelles contraintes correspondent-ils ? 27. Écrire les trois dérivées annulées et ce que chacune donne. 28. Écrire le dual complet. 29. Pourquoi « contraintes de boîte » ? Quel avantage numérique ? 30. Énoncer le théorème du représentant. 31. Comment calcule-t-on b^* ? Que faire si aucun point n'est sur la marge ? 32. Comment reconnaît-on les points exactement sur la marge ? 33. Qu'est-ce qu'une enveloppe convexe ? Quelle troisième interprétation donne-t-elle ?

Noyaux et numérique 34. Quelle observation sur le dual rend les noyaux possibles ? 35. Qu'est-ce que la modularité évoquée par le livre ? 36. Définir un noyau. Qu'est-ce que l'application d'attributs canonique ? 37. Qu'est-ce que l'astuce du noyau ? la matrice de Gram ? 38. Quelles sont les deux conditions sur un noyau ? 39. La frontière devient non linéaire — que résout-on toujours ? 40. Citer les trois sens du mot « noyau ». 41. Comment choisir le noyau et ses paramètres ? 42. Pourquoi faut-il un sous-gradient ? Écrire $g(t)$. 43. Comment choisir entre primal et dual pour la résolution ?

Flashcards

Question	Réponse
Le quatrième pilier ?	La CLASSIFICATION
Les valeurs d'étiquette ?	$\{+1, -1\} - \{0, 1\}$ est réservé aux modèles probabilistes
La mise en garde sur +1 ?	En détection de cancer, le patient ATTEINT est +1 — ne rien inférer de « positif »
L'hyperplan séparateur ?	$\{x \in \mathbb{R}^D : \langle w, x \rangle + b = 0\}$
Que représente w ?	Le VECTEUR NORMAL à l'hyperplan
La preuve de l'orthogonalité ?	$f(x_a) - f(x_b) = \langle w, x_a - x_b \rangle = 0$ pour x_a, x_b sur l'hyperplan
w et x , deux natures ?	w = FLÈCHE (vecteur géométrique) · x = POINT (coordonnées)
La règle de décision ?	$y_n(\langle w, x_n \rangle + b) \geq 0$
La marge ?	La distance de l'hyperplan aux exemples LES PLUS PROCHES
Pourquoi la maximiser ?	Un classifieur à grande marge GÉNÉRALISE bien (Steinwart & Christmann)
La subtilité technique ?	Il faut DÉFINIR UNE ÉCHELLE — sinon changer les unités changerait la marge
La décomposition vectorielle ?	$x_a = x'_a + r \frac{w}{\ w\ }$
Que représente r ?	La COORDONNÉE de x_a dans le sous-espace engendré par $w/\ w\ $
La formulation avec $\ w\ = 1$?	$\max_{w,b,r} r$ s.c. $y_n(\langle w, x_n \rangle + b) \geq r, \ w\ = 1, r > 0$
L'autre convention d'échelle ?	Le prédicteur vaut 1 à l'exemple le plus proche
Le résultat qui les relie ?	$r = \frac{1}{\ w\ }$
Pourquoi contre-intuitif ?	On dérive la distance en fonction de $\ w\ $, qu'on ne connaît pas encore
La justification du livre ?	Voir r comme une VARIABLE TEMPORAIRE de la dérivation
Autre lecture de la distance ?	L'ERREUR DE PROJECTION sur l'hyperplan
Le SVM à marge dure ?	$\min \frac{1}{2} \ w\ ^2$ s.c. $y_n(\langle w, x_n \rangle + b) \geq 1$

Question	Réponse
Pourquoi le carré ?	Il donne un programme quadratique CONVEXE
Pourquoi le $\frac{1}{2}$?	Il n'affecte pas l'optimum — il rend le gradient plus propre
Pourquoi « dure » ?	Aucune violation de la condition de marge n'est autorisée
Théorème 12.1 ?	Les deux formulations ($\ w\ = 1$ et marge = 1) sont ÉQUIVALENTES
Ses trois pas de preuve ?	Le carré est monotone · reparamétriser par $w'/\ w'\ $ · diviser par $r > 0$
Où sert la séparabilité linéaire ?	Elle garantit $r > 0$, donc la division licite
Le besoin de la marge souple ?	Données non linéairement séparables
L'idée clé ?	Une VARIABLE D'ÉCART ξ_n par exemple, soustraite de la marge
Le SVM à marge souple ?	$\min \frac{1}{2} \ w\ ^2 + C \sum_n \xi_n$ s.c. $y_n(\cdot \cdot \cdot) \geq 1 - \xi_n, \xi_n \geq 0$
Que fait C ?	Il arbitre entre taille de la marge et quantité totale d'écart
Grand C ?	FAIBLE régularisation — plus de poids aux écarts
Où C est-il placé ?	Sur les ÉCARTS — l'inverse de la convention des livres d'optimisation
Autre nom de cette formulation ?	Le C-SVM
Le régularisateur ?	$\ w\ ^2$ — le terme de MARGE
Pourquoi pas la perte quadratique ?	Inadaptée à la classification binaire
La perte 0-1 ?	$\mathbb{1}(f(x_n) \neq y_n)$
Pourquoi l'éviter ?	Elle donne un problème d'optimisation COMBINATOIRE
La perte charnière ?	$\ell(t) = \max\{0, 1 - t\}$ avec $t = yf(x)$
Régime $t \geq 1$?	Perte nulle
Régime $0 < t < 1$?	Perte positive alors que la prédiction est CORRECTE — on est dans la marge
Régime $t < 0$?	Perte croissant linéairement — mauvais côté
Sa propriété-clé ?	C'est un MAJORANT CONVEXE de la perte 0-1

Question	Réponse
La perte de la marge dure ?	0 si $t \geq 1$, ∞ si $t < 1$
Le problème sans contraintes ?	$\min \frac{1}{2} \ w\ ^2 + C \sum_n \max\{0, 1 - y_n f(x_n)\}$
Sa lecture ?	Maximiser la marge = RÉGULARISER
L'équivalence avec la forme contrainte ?	$\min_t \max\{0, 1 - t\} \iff \min_{\xi} \xi \text{ s.c. } \xi \geq 0, \xi \geq 1 - t$
Les trois avantages du dual ?	Indépendant du nombre d'attributs · bon si $D > N$ · permet les NOYAUX
Les deux multiplicateurs ?	α_n (classification correcte) et γ_n (non-négativité de ξ_n)
Ce que donne $\partial \mathcal{L} / \partial w = 0$?	Le THÉORÈME DU REPRÉSENTANT $w = \sum_n \alpha_n y_n x_n$
Ce que donne $\partial \mathcal{L} / \partial b = 0$?	$\sum_n y_n \alpha_n = 0$
Ce que donne $\partial \mathcal{L} / \partial \xi_n = 0$?	$C - \alpha_n - \gamma_n = 0$, donc $\alpha_n \leq C$
Le SVM dual ?	$\min_{\alpha} \frac{1}{2} \sum_i \sum_j y_i y_j \alpha_i \alpha_j \langle x_i, x_j \rangle - \sum_i \alpha_i$
Ses contraintes ?	$\sum_i y_i \alpha_i = 0$ et $0 \leq \alpha_i \leq C$
Leur nom ?	Les CONTRAINTES DE BOÎTE
Leur avantage ?	Boîtes alignées sur les axes — très efficaces dans les solveurs
Pourquoi minimiser et non maximiser ?	On minimise le dual NÉGATIF — équivalent
Les vecteurs de support ?	Les x_n avec $\alpha_n > 0$
Les autres points ?	$\alpha_n = 0$ — ils n'influencent PAS la solution
Comment calculer b^* ?	$b^* = y_n - \langle w^*, x_n \rangle$ pour un x_n sur la marge
Si aucun n'y est exactement ?	Prendre la MÉDIANE de $ y_n - \langle w^*, x_n \rangle $ sur les SV
Comment reconnaître les points sur la marge ?	$0 < \alpha_n < C$ (strictement à l'intérieur de la boîte), par les conditions KKT
L'enveloppe convexe ?	$\{ \sum_n \alpha_n x_n : \sum_n \alpha_n = 1, \alpha_n \geq 0 \}$

Question	Réponse
La troisième interprétation du SVM ?	L'hyperplan BISSECTE le segment entre les deux enveloppes convexes
L'observation qui rend les noyaux possibles ?	Le dual ne contient QUE des produits intérieurs ENTRE EXEMPLES
La modularité ?	Choix du classifieur et choix de la représentation sont SÉPARABLES
Définition d'un noyau ?	$k(x_i, x_j) = \langle \phi(x_i), \phi(x_j) \rangle_{\mathcal{H}}$ pour un espace de HILBERT $\mathcal{H}$
L'application d'attributs canonique ?	$\phi(x) = k(\cdot, x)$, dans le RKHS unique associé
L'astuce du noyau ?	Elle CACHE l'application non linéaire explicite
La matrice de Gram ?	$K \in \mathbb{R}^{N \times N}$ des $k(x_i, x_j)$; aussi « matrice de noyau »
Les deux conditions sur un noyau ?	SYMÉTRIQUE et SEMI-DÉFINI POSITIF ($z^T K z \geq 0$)
Trois noyaux usuels ?	Polynomial · gaussien RBF · quadratique rationnel
Que résout-on avec un noyau ?	TOUJOURS un HYPERPLAN — c'est la frontière qui devient non linéaire
Les trois sens de « noyau » ?	RKHS (ici) · ESPACE NUL (algèbre linéaire) · noyau LISSANT (densité)
Comment choisir le noyau ?	Par VALIDATION CROISÉE IMBRIQUÉE (§8.6.1)
Le prédicteur à noyau ?	$f(x) = \sum_n \alpha_n y_n k(x_n, x) + b$ — w n'est jamais formé explicitement
Pourquoi un sous-gradient ?	La charnière n'est pas différentiable en $t = 1$
Le sous-gradient ?	-1 si $t < 1$ · $[-1, 0]$ si $t = 1$ · 0 si $t > 1$
Où est-elle différentiable ?	PRESQUE PARTOUT — un seul point pose problème
Taille du primal ?	La dimension D des exemples
Taille du dual ?	Le nombre N d'exemples
Nature des deux problèmes ?	Des programmes quadratiques CONVEXES
La différence de philosophie avec le ch. 9 ?	Vraisemblance : partir d'un modèle probabiliste . SVM : CONCEVOIR d'abord l'objectif par intuition géométrique